

计算机自适应测试综述：机器学习视角 (Survey of Computerized Adaptive Testing: A Machine Learning Perspective)

原文: survey-cat-ml-perspective_3.pdf (arXiv:2404.00712v4 [cs.LG], 2026-03-15) ·译者: Claude ·译于 2026-06-25
术语对照: Computerized Adaptive Testing (CAT, 计算机自适应测试) ·Item Response Theory (IRT, 项目反应理论) ·Cognitive Diagnostic Model (CDM, 认知诊断模型) ·Measurement Model (测量模型) ·Selection Algorithm (选题算法) ·proficiency (能力/熟练度) ·Fisher Information (Fisher 信息) ·Subset Selection (子集选择)

摘要

计算机自适应测试 (Computerized Adaptive Testing, CAT) 通过根据个体表现动态调整测试题目, 为评估被试能力提供了一种高效且个性化的方法。与传统的、非个性化的测试方法相比, CAT 所需题目更少, 却能提供更准确的评估。因此, CAT 已被广泛应用于教育、医疗、体育、社会学以及 AI 模型评估等众多领域。传统方法主要依赖心理测量学 (psychometrics) 和统计学, 但随着大规模测试日益复杂, 机器学习技术被逐步引入。本文旨在从机器学习的视角对 CAT 进行综述, 为这一自适应测试范式提供全新视角。我们深入探讨 CAT 中的测量模型、选题算法、题库构建与测试控制, 剖析机器学习如何优化这些组件。通过分析现有方法的优势、局限与挑战, 我们力求构建鲁棒、公平且高效的 CAT 系统。本综述通过将心理测量学驱动的 CAT 研究与机器学习相结合, 倡导一种更具包容性、跨学科的自适应测试未来发展路径。

索引词: 自适应测试、机器学习、能力评估、AI 评估、深度学习。

1 引言

对智能体 (无论是人类还是 AI 系统) 的评估, 对于确保个体做好准备、胜任各自角色的要求至关重要。对人类而言, 评估结果可以决定其是否有资格获得诸如入学或就业等机会; 对 AI 模型而言, 评估结果可以表明系统是否适合部署、是否能够做出真实世界中的决策。传统上, 评估往往采用「一刀切」的方式, 即所有被试回答同一组题目, 并计算出最终分数。例如, 针对人类的传统纸笔测试, 以及针对 AI 模型各类「黄金标准」基准测试 (benchmark)。

然而, 随着测试规模扩大、智能体复杂度与多样性增长, 传统评估方法在效率和可靠性上面临挑战。源自心理测量学的计算机自适应测试 (CAT) 通过为每位被试识别并呈现最具信息量、最有价值的题目, 提供了一种个性化的测试范式。这一方法已在面向人类的高利害 (high-stakes) 测试场景中广泛应用, 例如 SAT、GRE 和 GMAT。近年来, CAT 也越来越多地用于评估 AI 能力, 例如文本蕴含识别、聊天机器人、机器翻译以及通用 AI 系统。CAT 方法已被证明, 对人类和 AI 系统而言, 达到相同评估准确度所需的题目都更少。本质上, CAT 旨在解决一个关于准确性与效率的关键问题: 如何在尽量减少题目数量的同时, 准确估计被试的真实能力?

CAT 是被试 (人类或 AI 模型) 与测试系统之间一个动态、交互的过程。测试系统包含四个轮流运作的主要组件: 在每一个测试步骤中, 作为用户模型的测量模型 (Measurement Model) 首先基于认知科学或心理测量学, 利用被试此前的作答来估计其当前能力; 随后, 选题算法 (Selection Algorithm) 依据特定准则, 从题库 (Question Bank) 中挑选下一道题。大多数传统准则是统计意义上的信息量度量, 例如选择难度与被试当前能力估计相匹配的题目, 即被试答对的概率约为 50%。上述过程不断重复, 直至满足预先设定的停止规则。在整个评估过程中, 测试控制 (Test Control) 负责管理曝光均衡、公平性、鲁棒性等各类因素。CAT 结束时, 最终的能力估计——或诊断报告——即为评估结果。

CAT 是机器智能与评估技术的复杂融合。它需要管理庞大的题库、适应各异的被试能力, 并进行实时决策。此外, 实际的 CAT 还涉及保证可靠性、公平性、搜索效率等。这些挑战使 CAT 成为一个多维度的决策问题。随着大规模、多样化的在线测试平台兴起, 这些挑战变得更加显著。机器学习 (ML), 尤其是深度学习, 为提升测试的效率与准确性提供了有前景的解决方案。以往的 CAT 综述主要聚焦于统计与心理测量学视角, 且主要关注人类评估。鉴于 CAT 的跨学科特性, 本文力图从机器学习视角探索并梳理相关方法论。它对更广泛的读者更易理解, 并为构建面向人类和人工智能的强大测试系统提供洞见。

在机器学习领域, CAT 可被概念化为一个聚焦数据效率 (data efficiency) 的参数估计问题: 目标是利用最少的观测数据 (即被试作答的题目尽可能少), 来确定模型中潜在参数的取值 (即被试的真实能力)。近年来, 将 ML 技术用于研究 CAT 四大组件的兴趣日益增长。例如, 深度学习技术可用于诊断被试能力、自动化构建题库; 数据驱动的方法通过从大规模作答数据中学习来优化选题算法。尽管已有这些努力, 从机器学习视角全面捕捉 CAT 解决方案广度的综述仍然缺失。此外, 机器学习的持续演进也为测试带来了新的面向。本文的贡献如下:

- 据我们所知, 这是首次尝试通过机器学习的视角全面梳理 CAT 解决方案。通过探讨测量模型、选题算法、题库构建与测试控制方面的现有工作, 本文提供了一个统一框架, 涵盖 CAT 系统的整个生命周期。
- 我们总结现有工作, 并就机器学习成功与失败尝试得出结论。此外, 我们识别出构建可靠、有效的 CAT 系统 (无论用于人类还是 AI 模型评估) 所必需的关键因素, 包括曝光控制、公平性、鲁棒性与搜索效率, 从而提供更全面的视角。
- 我们已在 <https://github.com/bigdata-ustc/EduCAT> 开源了现有 CAT 模型及相关资源的可扩展、统一实现。该库旨在帮助研究者快速开发 CAT 系统、鼓励协作, 并最终推动构建更精巧、更有效的 CAT 系统。

本文结构如下。第 2 节介绍 CAT 的背景; 第 3 节给出 CAT 任务的形式化定义; 随后第 4、5、6 节分别梳理测量模型、选题算法和题库构建的现有方法。鉴于选题算法是实现自适应性的核心组件, 本综述主要聚焦其在机器学习与深度学习方面的最新进展。第 7 节总结 CAT 应用中的关键

因素；第 8 节讨论如何评估 CAT。

2 CAT 的演进

CAT 的演进是一段引人入胜的历史旅程，标志着若干重要里程碑。自适应测试始于 1905 年 Alfred Binet 的智力测验。20 世纪 50 年代计算机问世，将自适应测试转变为 CAT。20 世纪 70、80 年代的关键进展，尤其是心理测量学模型的引入，提升了评估准确性。20 世纪 90 年代的互联网浪潮使 CAT 得以广泛普及，进而被用于 GRE、GMAT、SAT 等重大考试。这些考试尽管历经演变，至今仍依赖自适应原理。各种统计方法优化了测试体验，CAT 成为人类测量领域的重要焦点，覆盖教育、医疗、社会学和体育等。

近年来，研究者越来越多地探索将 CAT 应用于 AI 模型评估。现有基准测试常含有冗余、低质量、被污染甚至错误的题目，影响 AI 评估的效率与可靠性。借助自适应测试，研究者可以分析基准题目的特征，为每个 AI 系统定制评估，并估计每个模型作答背后的潜在特质，而非仅仅计算准确率。在 CAT 与心理测量学的指引下，AI 评估的各个方面涌现出多种高效方法，包括性能估计、题目选择以及对实验结果的理解。这些方法旨在从大规模数据集中识别出有信息量、有价值的子集，以提升 AI 系统评估的可靠性。

当前的 CAT 研究涵盖广泛主题，包括题库开发、题目选择、能力估计，以及与测试安全性和可靠性相关的各类问题。它们对于确保 CAT 始终是一种可靠、有效且公平的评估至关重要。机器学习正在通过对大规模数据集的精细分析、详尽的行为建模以及对多样测试环境的灵活适应，彻底革新 CAT。尽管 CAT 中的 ML 仍处于早期阶段，其潜力已显而易见。机器学习为我们定义、分析和应用 CAT 提供了新的解决方案。本综述旨在概述并理解基于传统统计的 CAT 与近期基于 ML 的 CAT。

3 总览

CAT 的一个重要假设是：被试的真实能力水平 $\theta_0 \in \mathbb{R}^d$ 在整个测试过程中保持恒定。其中 d 表示能力的维度——例如 θ 可对应一个单维的总体能力水平 ($d = 1$)，或一个表示在 d 个不同知识概念上掌握程度的多维向量。CAT 的首要目标是通过让被试作答，准确且高效地估计其真实能力水平。因此，CAT 系统旨在实现两个关键目标：(1) 利用作答来估计被试能力 θ ，使其在测试结束时尽可能逼近真实能力 θ_0 ；(2) 为每位被试选择最有价值、最契合的题目，从而缩短测试长度。

3.1 任务形式化

为实现上述目标，CAT 以一个迭代、交互的过程运作：如图 1 所示，在 CAT 的测试步骤 $t \in [1, 2, \dots, T]$ 中，利用此前 t 次作答估计被试当前能力 $\hat{\theta}_t$ ；随后用 $\hat{\theta}_t$ 从题库 Q 中检索下一题 q_{t+1} 给被试作答，并接收下一个作答标签 y_{t+1} 。这些交互构成一个作答序列 $\{(q_1, y_1), (q_2, y_2), \dots, (q_T, y_T)\}$ ，其中若对 q_t 作答正确则 $y_t = 1$ ，否则为 0。为实现 CAT 的目标，每个测试步骤涉及两个关键过程：

图 1：CAT 工作流程——在步骤 t ，选题算法基于测量模型估计出的被试当前能力 $\hat{\theta}_t$ ，自适应地选择下一题 q_{t+1} 。

(1) 能力估计。测量模型记为 $f(\cdot)$ ，充当用户模型，预测能力为 θ 的被试答对的概率，记为 $f(q, \theta) = P(y = 1 | q, \theta)$ 。测量模型的实现常借鉴认知科学或心理测量学。为在每一步准确估计被试能力，可采用多种估计方法，如极大似然估计 (Maximum Likelihood Estimation, MLE) 或贝叶斯估计。在应用中常使用二元交叉熵损失：在步骤 t ，给定此前 t 次作答 $D_{1:t} = \{(q_1, y_1), \dots, (q_t, y_t)\}$ ，对应的经验损失为：

$$L(\theta) = \sum_{(q, y) \in D_{1:t}} \ell(y, f(q, \theta)) = - \sum_{(q, y) \in D_{1:t}} y \log f(q, \theta) + (1 - y) \log(1 - f(q, \theta)),$$

因此当前能力估计 $\hat{\theta}_t$ 通过最小化损失函数 $L(\theta)$ 得到： $\hat{\theta}_t = \arg \min_{\theta} L(\theta)$ 。

(2) 题目选择。CAT 的核心是一个算法，它以被试当前能力估计 $\hat{\theta}_t$ 为指引，从题库 Q 中挑选下一题 q_{t+1} ：

$$q_{t+1} = \arg \max_{q \in Q} V_q(\hat{\theta}_t),$$

其中 $V_q(\hat{\theta}_t)$ 是题目 q 的价值。例如， V 可以衡量该题将提供多少关于被试能力的信息，也可以是专门为决定选题而设计的策略 π 的输出。

在接收到新的作答标签 y_{t+1} 后，测量模型更新并估计能力 $\hat{\theta}_{t+1}$ 。上述过程重复 T 次，确保最终步骤的估计 $\hat{\theta}_T$ 逼近真实的 θ_0 ，即：

定义 1 (CAT 的定义)。CAT 的目标是找到一个规模为 T 的题目集合 $S = \{q_1, q_2, \dots, q_T\}$ ，使得由 S 及其对应作答标签 y 导出的最终步骤估计 $\hat{\theta}_T$ 尽可能逼近被试真实能力 θ_0 ：

$$\min_{|S|=T} \|\hat{\theta}_T - \theta_0\|.$$

然而，直接求解这一优化问题并不现实，因为真实能力 θ_0 不可观测，甚至被试本人也未必知道自己确切的能力水平。因此，现有方法都是对该目标的近似。例如，传统统计选题方法利用 MLE 的渐近统计性质来降低估计的不确定性，如选择难度与被试当前能力估计 $\hat{\theta}_t$ 紧密匹配的题目；较新的子集选择 (Subset Selection) 方法则试图找到 θ_0 的某个理论近似，作为新的优化目标。更多细节见第 5 节。

同时，作为一个实际系统，需考虑的因素超出能力估计目标 (定义 1) 本身。题目曝光控制、鲁棒性、公平性以及搜索效率等因素也必须加以处理。对这些因素的详尽讨论见第 7 节。

评估方法：为验证估计能力的准确性，采用两种主要途径：1) **性能预测：**利用测量模型中被试的估计值，在被试预留的作答数据上预测作答的正误标签 y ，通常以交叉熵衡量；2) **能力估计：**通过仿真生成真实能力值 θ_0 ，模拟被试对每道题的作答，然后计算估计值与仿真真实值之间的均方误差 (MSE)。细节见第 8 节。

3.2 分类体系

如图 2 所示，我们将现有 CAT 研究归入上述测试过程涉及的四大组件：1) 测量模型，2) 选题算法，3) 题库构建，4) 测试控制。

图 2：从机器学习视角对代表性 CAT 方法的总结。每一部分进一步依据所采用的不同技术细分：- **测量模型 (第 4 节)：**项目反应理论 (IRT、MIRT、VI-IRT)；认知诊断模型 (DINA、G-DINA、AHM、FuzzyCDF)；深度学习模型 (DIRT、NeuralCD、IRR、RCD、HierCDF、DeepCDF、BETA-CD、AGCDM、SCD)。- **选题算法 (第 5 节)：**统计算法 (经典信息：Fisher 信息、KL 信息；附加信息：MPWI、MEI、thOpt；CD-CAT：KL 算法、Shannon 熵；双目标 CD-CAT)；主动学习算法 (不确定性方法、期望模型变化)；强化学习 (SSP、POMDP、DQN、GMOCAT、NCAT)；元学习算法 (BOBCAT、DL-CAT、SACAT、UATS)；子集选择算法 (BECAT、SEM、聚类)。- **题库构建 (第 6 节)：**题目特征分析 (基于专家、基于统计、深度学习：CNN/RNN/NLP)；题库开发 (基于专家)。- **测试控制 (第 7 节)：**曝光控制 (Sympton-Hetter、A-Stratified)；公平性 (测量模型偏倚、题库偏倚、选题算法偏倚、等值 Equating)；鲁棒性 (Robust CAT)；搜索效率 (PSO、SECAT)。

接下来的四节 (第 4–7 节) 将对这些组件进行详细介绍和文献综述，尤其关注其从机器学习视角出发的理论基础与方法学发展。

4 测量模型

测量模型的现有方法可归为三大类：**项目反应理论 (IRT)**、**认知诊断模型 (CDM)** 和 **深度学习模型**。在 CAT 发展的前 50 年里，IRT 是主导的建模框架，并在实际运行系统中广泛采用。直到 2009 年 CD-CAT 提出后，CDM 才开始被用作自适应测试的底层测量模型。最近，随着自适应评估的规模与复杂度增长以及深度学习兴起，超越传统 IRT 和 CDM 的多种新型测量模型应运而生。

这种分类的依据是 **CAT 中能力表示 (θ) 的本质**——从总体的数值能力值 (即 IRT)，到跨不同知识概念的离散认知状态 (即 CDM)，再到通过深度学习技术实现的统一建模方式 (即深度学习模型)。模型的选择应取决于评估的具体目标、数据的性质以及可用资源。无论选择何种测量模型来估计能力，目标始终一致：最小化每一步估计值与真实值之间的误差，即 $\|\hat{\theta}_t - \theta_0\| \rightarrow 0$ 。

4.1 项目反应理论 (IRT)

在 IRT 中，被试能力通常表示为一个连续的标量变量，称为总体能力 (overall ability)。作为测量模型的基础框架，IRT 用一个潜在特质参数 θ 来表示被试的总体能力水平。IRT 中应用最广的模型之一是三参数 Logistic 模型 (3PL-IRT)。它利用一个类 Logistic 的交互函数来建模被试答对题目 j 的概率，即：

$$f(q_j, \theta) = c_j + \frac{1 - c_j}{1 + e^{-\alpha_j(\theta - \beta_j)}}.$$

3PL-IRT 模型为每道测试题 j 引入三个参数 (β_j, α_j, c_j)：**难度参数 β_j** 对应被试答对该题概率为 50% 时的能力水平；**区分度参数 α_j** 描述该题区分不同能力被试的程度；**猜测参数 c_j** 表示能力极低的被试答对该题的概率。在 CAT 系统中，这些参数经预先标定，并在测试过程中保持固定，标注与标定方法详见第 6 节。IRT 同时考虑答对题目的数量与题目难度。几乎所有面向人类的主要自适应测试 (如 SAT 和 GRE) 都采用 IRT 开发，因为该方法能显著提升测量的可靠性与可解释性。最近，在 AI 系统评估方面，Polo 等人成功地从 MMLU (一个由 14K 道题构成的流行多选 QA 基准) 中筛选出 100 道有信息量的精选题目，准确估计了大语言模型 (LLM) 的性能。

另一方面，多维 IRT (MIRT) 将 IRT 扩展到多个维度，允许同时建模多个潜在特质。尽管 (M)IRT 模型具有很强的可解释性，但其性能受限于交互函数的简单性，且缺乏对被试在各个知识概念上认知状态的细粒度建模。

4.2 认知诊断模型 (CDM)

认知诊断模型 (CDM) 是另一类代表性的测量模型，聚焦于离散的知识概念。具体而言，在 CDM 中，被试能力是按知识概念划分的，且通常是二分的，即表示被试是否掌握了某一知识概念。例如，在一次数学评估中，知识概念可能包括加法、分数或解一元一次方程。为保持一致，我们仍

用 θ 表示被试能力。例如，DINA 方法将被试能力 $\theta = \{\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(K)}\}$ 建模为其在全部 K 个概念上的二分掌握水平。给定 Q 矩阵 $Q \in \mathbb{R}^{|Q| \times K}$ （一个二元矩阵，指示题库 Q 中每道题关联哪些知识概念），DINA 方法只关注与目标题 j 相关的知识概念（即 $Q_{jk} = 1$ ）。因此，能力为 θ 的被试对题目 j 的二元作答变量为 $\prod_{k, Q_{jk}=1} \theta^{(k)}$ ，并以「失误 (slip)」和「猜测 (guess)」参数对题目建模：

$$f(q_j, \theta) = (1 - s_j)^{\prod_{k, Q_{jk}=1} \theta^{(k)}} g_j^{1 - \prod_{k, Q_{jk}=1} \theta^{(k)}},$$

其中 s_j 是失误参数，表示已掌握却仍答错的可能性； g_j 是猜测参数，反映未掌握却蒙对的概率。其扩展 G-DINA 提供了对被试能力更精细的视角，而 FuzzyCDF 利用模糊集理论，从客观和主观数据中得到细致的诊断。另一种方法——属性层级方法 (Attribute Hierarchy Method)——运用规则空间理论来组织知识依赖关系，并将被试能力与最接近的理想认知模式对齐，从而获得诊断结果。

与 IRT 相比，CDM 提供了对被试能力更细粒度、更全面的评估。它们尤其擅长针对个体在多个知识概念上的优势与不足提供详尽反馈，这对 CAT 和有针对性的后续干预十分重要。这些模型凸显了一种关键转向：迈向对学习 with 能力更细致的理解，承认知识习得与自适应测试的多面性。

4.3 深度学习模型

近年来，深度学习技术的迅猛发展激发了深度学习驱动的测量模型。与传统模型相比，深度学习方法因其高效性和学习被试与题目之间复杂交互模式的能力，更适用于大规模数据场景（如在线学习平台）的测量。

在这些模型中，被试能力 θ 通常由一个高维潜在向量（嵌入 embedding）表示。类似地，每道题也被编码为题目嵌入 $e_j = \text{Embed}(q_j)$ 。这些嵌入经过一个多层神经网络来预测答对的概率：

$$f(q_j, \theta) = \phi_n(\dots \phi_1(W[\theta; e_j] + b) \dots),$$

其中 W 和 b 分别为权重矩阵和偏置向量， $\phi_k(\cdot)$ 表示第 k 层的激活函数（如 ReLU、Tanh 或 Sigmoid）。

基于这一框架，若干基于深度学习的测量模型展现出强劲性能。例如，DIRT 利用神经网络从题目文本中捕捉语义信息以提升准确性；NeuralCD 利用一个非负全连接神经网络来捕捉复杂交互，并能泛化到其他测量模型。考虑到被试、题目与知识概念之间复杂的异构关系，大量工作也致力于利用这些关系来增强测量。

讨论：在 CAT 过程中，只能获得有限数量的被试作答用于能力估计。从某种程度上说，CAT 可被视为一种冷启动 (cold start) 场景下的能力测量。测量模型的性能是确保 CAT 中能力估计准确性的关键因素。同时需要注意，测量模型的选择会显著影响对应选题算法的选取。

5 选题算法

选题算法是 CAT 实现自适应性的核心，也是本综述的焦点。它利用从测量模型（上一节介绍）获得的能力估计来挑选下一道最合适的题目，从而在使用尽可能少题目的同时确保对能力的准确估计。选题算法可分为基于统计信息的传统方法，以及更近期的机器学习方法，例如数据驱动方法（即强化学习和元学习）；此外子集选择也日益流行。

5.1 统计算法

一般而言，设计选题算法的一种实用思路是：开发定量方法，为题库 Q 中每道题赋予一个数值。经典统计选题算法将一道题的价值定义为它对被试潜在能力估计所提供的信息量。下一题索引 j_{t+1} 可基于当前估计 $\hat{\theta}_t$ 从题库 Q 中选出：

$$j_{t+1} = \arg \max_{q_j \in Q} I_j(\hat{\theta}_t),$$

其中 $I_j(\cdot)$ 是题目 q_j 的信息量（如 Fisher 信息）。如定义 1 所述，CAT 假设每位被试存在一个真实能力值 (θ_0)，并将其视为一个参数估计过程。因此，一道题的信息量可被解读为该题作答对参数估计的期望贡献。这一概念将在后文讨论的各类选题算法中得到体现。

Fisher 信息。在参数估计问题中，Fisher 信息是信息论与统计学中的一个概念，衡量一个可观测随机变量所携带的关于未知参数的信息量。在 CAT 中，Fisher 信息常用于量化一道题所提供的关于被试能力的信息量。具体地，考虑随机变量 $D_j = (q_j, y_j)$ ，其概率密度或概率质量函数为 $f(q_j, \theta)$ ，其中 θ 为未知参数。变量 D_j 所含的 Fisher 信息定义为： $I_j(\theta) = E_{y_j}[(\nabla_{\theta} L(D_j|\theta))^2] = \frac{(\nabla_{\theta} f(q_j, \theta))^2}{f(q_j, \theta)(1-f(q_j, \theta))}$ ，其中 $L(D|\theta) = y \log f(q, \theta) + (1 - y) \log(1 - f(q, \theta))$ 是 D 关于参数 θ 的似然函数。

因此，当用 3PL-IRT 建模 $f(q, \theta)$ 并给定当前估计 $\hat{\theta}_t$ 时，题目 j 的 Fisher 信息可计算为：

$$I_j(\hat{\theta}_t) = \frac{(1 - c_j)\alpha_j^2 e^{-\alpha_j(\hat{\theta}_t - \beta_j)}}{(1 + e^{-\alpha_j(\hat{\theta}_t - \beta_j)})^2 [1 - c_j + c_j(1 + e^{-\alpha_j(\hat{\theta}_t - \beta_j)})]}.$$

Fisher 信息的一个关键性质是：其倒数（矩阵情形为逆矩阵）即为能力估计渐近分布的方差（协方差矩阵）：

定理 1 (MLE 能力估计的渐近分布)。在每一步 t ，基于对被试此前 t 次作答的观测，由 MLE 估计的当前能力估计 $\hat{\theta}_t$ 满足渐近正态分布： $\hat{\theta}_t \sim N\left(\theta_0, \frac{1}{tI(\theta_0)}\right)$ 。

显然，随着题目数 t 或 Fisher 信息 $I(\theta_0)$ 增大，估计的方差减小。由于 $\hat{\theta}_t$ 渐近无偏（即 $E[\hat{\theta}_t] = \theta_0$ ），方差越小意味着分布越集中于 θ_0 周围，从而降低估计不确定性、提升估计效率。

数十年来，Fisher 信息在个性化测试的发展中颇为流行，并被广泛应用于各类标准化人类评估。同样，对 AI 模型评估（尤其是 LLM），简单的 Fisher 方法仅用少量测试数据就能实现准确的性能估计。例如，Kipnis 等人将六个常用基准压缩到原规模的不到 3%，同时准确估计了 5000 多个 LLM 的性能。

当测量模型为 MIRT 时，Fisher 信息自然从标量扩展为矩阵。具体地，题目 j 在能力 θ （此时为向量）处提供的信息矩阵定义为： $I_j(\theta) = E_{y_j}[\nabla \log L(D_j|\theta) \nabla \log L(D_j|\theta)^\top]$ 。该矩阵的逆近似 MLE 能力估计的协方差。基于此，提出了多种选题算法，包括 D-最优（最大化行列式）、A-最优（最小化逆矩阵的迹）和 E-最优（最大化最小特征值）。

Kullback-Leibler 信息。Fisher 信息因其理论基础和数学简洁性在 CAT 中应用广泛。然而，当能力估计偏离真实值 θ_0 时，其有效性会下降。这一问题在测试早期尤为明显，因为此时作答有限、估计仍不稳定。为解决此问题，Chang 等人提出了一种基于 Kullback-Leibler (KL) 散度的全局信息度量。对给定题目 q_j （作答为 D_j ），候选能力水平 θ 与真实能力 θ_0 之间的 KL 散度定义为：

$$KL_j(\theta\|\theta_0) = E_{y_j} \log \frac{L(D_j|\theta_0)}{L(D_j|\theta)} = f(q_j, \theta_0) \log \frac{f(q_j, \theta_0)}{f(q_j, \theta)} + (1 - f(q_j, \theta_0)) \log \frac{1 - f(q_j, \theta_0)}{1 - f(q_j, \theta)}.$$

对应的选题算法在当前估计 $\hat{\theta}_t$ 的一个邻域上对 KL 积分：

$$I_j(\hat{\theta}_t) = \int_{\hat{\theta}_t - \delta}^{\hat{\theta}_t + \delta} KL_j(\theta\|\hat{\theta}_t) d\theta,$$

其中 $\delta = 3/\sqrt{t}$ 。积分范围在测试开始时较宽，随 t 增大逐渐收窄。在 MIRT 中，这自然扩展为多元积分。本质上，KL 信息识别那些能在被试可能的能力水平之间提供最大区分度的题目。与依赖单点估计的 Fisher 信息不同，KL 信息度量两个能力水平 θ 与 θ_0 之间的差异，即便二者相差显著仍然有效。这正是 KL 信息是全局的、而 Fisher 信息是局部的原因。两者对比的具体示例见附录。

高级统计算法。基于 Fisher 与 KL 信息，已提出大量工作。这些方法试图在选题中引入更多信息，以提升能力估计的效率。极大似然加权信息 (Maximum Likelihood Weighted Information, MLWI) 用被试当前作答结果的似然函数对 Fisher 信息加权。其原理与 KL 信息类似，旨在改善 Fisher 信息的局部局限性：选择使「似然函数与 Fisher $I_j(\theta)$ 之积在能力水平上的积分」最大的题目：

$I_j(\hat{\theta}_t) = \int_{\hat{\theta}_t - \delta}^{\hat{\theta}_t + \delta} L(D_{1:t-1}|\theta) I_j(\theta) d\theta$ ，其中 $L(D_{1:t-1}|\theta) = \sum_{j=1}^{t-1} L(D_j|\theta)$ 是此前 t 次作答的似然函数。此外，极大后验加权信息 (Maximum Posterior Weighted Information, MPWI) 进一步用一个附加的后验概率分布 $P(\theta|D_{1:t-1})$ 对 Fisher 和 KL 信息加权： $I_j(\hat{\theta}_t) = \int_{\hat{\theta}_t - \delta}^{\hat{\theta}_t + \delta} P(\theta|D_{1:t-1}) L(D_{1:t-1}|\theta) I_j(\theta) d\theta$ ，其中 $I(\theta)$ 可以是 Fisher 信息或 KL 散度。极大期望信息 (Maximum Expected Information, MEI) 在对 Fisher 信息加权时，考虑了所有可能的结果 y_t 及其对更新后能力估计的影响。最后，theta 优化 (thOpt) 过程通过将最大化的信息与当前能力估计对齐来选题。一些非参数机器学习方法（如决策树）也可被探索，研究表明：少量题目即可在准确性上匹敌甚至超越传统方法，尤其在高维和不平衡数据条件下。

前述选题算法均基于 IRT，不能直接应用于其他测量模型。如第 4 节所述，CDM 等测量模型将能力 θ 表示为跨不同知识概念的离散状态。在这类模型下的自适应选题算法称为认知诊断 CAT (CD-CAT)。虽然选题原则相似（最大化所选题目的信息），但信息度量不同。在 CD-CAT 中，基于 KL 散度和 Shannon 熵的技术较为常用。尽管连续特质 (IRT 建模) 与离散状态 (DINA 建模) 描述能力的不同侧面，二者却是互补的。这催生了双目标 CD-CAT 方法，旨在同时评估两者。

讨论：CAT 中的选题算法主要依赖上述统计启发式方法，需要领域专家考虑每一种可能的测试场景并手工设计相应的选题算法。这些方法是「模型特定的」，不同测量模型需要不同的选题算法。例如，上述 Fisher 信息专为 (M)IRT 设计。因此，以往的统计方法缺乏灵活性——一旦底层测量模型改变，选题算法就必须重新设计。

5.2 主动学习算法

为设计在不同测量模型间都有效（即「模型无关 model-agnostic」）的选题算法，研究者探索了一种通用的机器学习数据选择技术：主动学习（Active Learning）。主动学习是主动挑选一些有价值的数据，从而用更少的数据训练出更好的模型。该技术已在众多学习任务中提升了数据效率。

如图 3 所示，主动学习以循环方式运作：选题算法依据模型当前表现迭代地挑选未标注样本，并向人类标注者查询标签。此过程扩充有限的标注数据以提升模型性能。核心挑战在于设计有效的样本选择算法，通常基于两个准则：信息量（informativeness），选择能降低模型不确定性的样本；以及代表性（representativeness），选择能反映整体数据分布的样本，或两者的结合。主动学习与 CAT 结构相似：此处，测量模型扮演学习模型的角色，题目选择对应样本选择，被试作答充当标注。目标是用尽可能少的题目估计能力。这种模型无关的视角避免了对特定测量模型假设的依赖。Bi 等人提出 MAAT，一个模型无关的自适应测试框架，它评估每次作答后能力估计的变化（类比梯度）：

$$j_{t+1} = \arg \max_{q_j \in Q} E_{y_j} \|\nabla_{\theta} L(D_{1:t} \cup \{(q_j, y_j)\})\|.$$

由于选题时无法获得候选题目的真实作答，它针对每道候选题计算关于作答标签 y 的期望梯度范数。该期望量化了每道题对能力估计的潜在影响。该框架背后的直觉是：它偏好那些最可能影响能力估计（即对其参数影响最大）的题目。值得注意的是，这一方法对测量模型的具体类型不作限制，只要它支持基于梯度的优化即可。

图 3：主动学习框架，以及主动学习各组件与 CAT 各组件之间的对应关系。

讨论：随着智能测试平台（从人类的在线测试系统到 AI 模型的评估排行榜）的快速发展，已积累了大规模的被试作答数据。然而，上述基于规则的方法（即统计算法和主动学习算法）无法有效利用此类数据。相比之下，近期基于强化学习（第 5.3 节）和元学习（第 5.4 节）的数据驱动方法日益受到关注。它们能从大规模作答数据中自动学习/优化有效的选题算法，而无需依赖手工定义的启发式或规则，并展现出更优的性能。

5.3 强化学习算法

强化学习（RL）是机器学习的一个子领域，是一种使智能体能够自动学习如何做出最优决策的强大方法。它已在机器人、自动驾驶、教育和医疗等多个领域成功应用。在 RL 中，智能体与环境交互，并根据其动作以奖励或惩罚的形式接收反馈。目标是学习一个策略 π ，使长期累积奖励最大化。如图 4 所示，策略可通过探索环境、从动作后果中学习而习得。本质上，CAT 研究者运用 RL 方法论来解决一个问题：选题算法（策略）能否从数或被试交互中自动学习和优化，从而规避对专家干预的需求？

马尔可夫决策过程形式化。智能体与环境的交互可视为一个马尔可夫决策过程（MDP）。具体地，在每一步，智能体观测当前环境状态（ s ），并通过选择动作（ a ）与环境交互。同时，智能体从这些交互中获得奖励（ r ），影响或改变环境的当前状态。目标是选择最优的动作序列，使累积奖励最高（ $\sum_t r_t$ ）。因此，大多数 RL 问题被形式化地描述为：估计智能体在给定状态下行为的最优性（基于值的方法 value-based），或动作策略本身的最优性（基于策略的方法 policy-based），或二者的混合方法。CAT 的整体 RL 框架如图 4 所示。我们将 CAT 问题形式化为一个 MDP，测试系统中的关键 RL 组件定义如下：

- **状态 (State)**：状态 $s_t \in S$ 表示每个测试步骤 t 的当前状况，捕捉关于被试和 CAT 系统的相关信息。一般而言，状态包括被试此前的作答序列（或一个表示当前能力估计的潜在向量）以及题库中的候选题目： $s_t = (\{q_1, y_1, \dots, q_t, y_t\}, Q)$ 。
- **动作 (Action)**：动作 a 指 CAT 系统在当前状态 s_t 下可采取的选择，即从题库中选择下一题 $q_{t+1} \in Q$ 。
- **转移 (Transition)**：转移函数是在当前状态 s_t 下采取动作 q_t 后观察到状态 s_{t+1} 的概率： $P(s_{t+1}|s_t, q_{t+1})$ 。每一步的不确定性来自被试对题目 q_{t+1} 的作答正误标签 y_{t+1} 。
- **奖励 (Reward)**：奖励 r 是 CAT 为被试选题后收到的标量反馈。为实现定义 1 中 CAT 的目标，奖励函数可定义为每一步能力估计的准确度，即 $\|\hat{\theta}_t - \theta_0\|$ ；或 $\hat{\theta}_t$ 在留出作答数据 D 上的性能预测损失，即 $L(D|\hat{\theta}_t)$ 。该奖励信号对引导策略 π 选择能降低估计误差的最契合题目至关重要。（注：由于真实值常不可获得，通常通过仿真实验导出。）

近年来，随着深度学习的进步，越来越多的研究利用深度强化学习来处理 CAT 中的 MDP 问题。Li 等人利用深度 Q 网络（Deep Q-Network）表示动作-值函数 $Q_w(s, q)$ ，表示在状态 s 下选择题目 q 的价值， w 为网络全连接层的参数。最合适的题目依据策略选出：

$$\pi^*(q|s) = \arg \max_{q \in Q} Q_w(s, q).$$

为进一步捕捉实际测试场景中被试与题目之间的复杂交互，提出了一个基于 Transformer 的 Q 网络 NCAT。NCAT 包含多个功能模块，包括一个独立捕捉被试表现多方面信息的双通道性能学习（Double-Channel Performance Learning）模块，以及一个识别并提取被试行为不一致性（如猜测和失误）的矛盾学习（Contradiction Learning）模块。

图 4：CAT 的整体强化学习框架。目标是通过探索大规模被试作答数据（即环境）来优化选题算法 π （即策略）。

随机最短路径形式化。此外，CAT 可定义为一个随机最短路径（Stochastic Shortest Path, SSP）问题，它是 MDP 的一个特例。在 SSP 中，目标是找到从给定初始状态 s_0 到目标状态的最短路径（即最少测试步数）。在 CAT 中，目标状态通常表示测试完成或达到预定的能力估计

精度。Gilavert 等人用线性规划求解最优测试策略 π^* ，将 CAT 视为一个流网络，其中每个状态的流入与流出必须平衡（起点和终点除外）。它将变量 $x_{s,q}$ 记为每个（状态 $s \in S$ ，题目 $q \in Q$ ）对的期望累积出现频率，并对每个状态 s 令流入 $in(s)$ 与流出 $out(s)$ 相等。流入状态 s 的流量是所有其他状态 s' 中所有导向 s 的题目的期望频率之和： $in(s) = \sum_{s',q} x_{s',q} P(s|s',q)$ 。流出状态 s 的流量是状态 s 中所有题目的期望频率之和： $out(s) = \sum_q x_{s,q}$ 。目标函数是最大化总期望奖励 r ，即所有状态-动作对的期望频率乘以即时奖励 $r(s,q)$ 之和： $\min_{x_{s,q}} \sum_{s \in S, q \in Q} x_{s,q} r(s,q)$ 。于是最优选题策略 π^* 可由下式获得：

$$\pi^*(q|s) = \frac{x_{s,q}}{\sum_{q' \in Q} x_{s,q'}}.$$

部分可观测 MDP 形式化。部分可观测 MDP (POMDP) 将标准 MDP 框架扩展到环境仅部分可观测的设定。传统 CAT 模型常假设被试能力可从此前作答中完全推断，从而可将其视为以能力估计为状态的 MDP。然而实际上，由于某些固有的不确定性，能力无法被完美推断。

为此，许多工作将 CAT 建模为 POMDP。与 MDP 相比，POMDP 模型有两个额外元素： O ，观测集合； Z ，观测概率。 $Z(o|s',q)$ 是在选择题目 q 并转移到状态 s' 后做出观测 o 的概率。虽然底层状态（能力）仍然存在，但它不可完全观测。取而代之，这些方法维护一个信念状态 $b(s)$ ，即可能能力上的概率分布，并通过贝叶斯法则更新：当智能体在信念状态 b 下选择动作（题目） q 并做出观测 o 时，它将信念状态更新为 $b'(s')$ ： $b'(s') = \eta Z(o|s',q) \sum_{s \in S} P(s'|s,q) b(s)$ ，其中 η 是归一化常数。POMDP 可由多种算法求解，如基于网格的算法、蒙特卡洛树搜索。然而，由于环境的部分可观测性，POMDP 比 MDP 更难求解。

5.4 元学习算法

另一种能够应对这一复杂 CAT 问题的数据驱动机器学习方法是元学习 (meta-learning)：它通过在多种任务上训练模型，来获取跨任务知识或学会如何高效学习。具体地，基学习器 (base-learner) 在一系列相关任务上训练，从而汇集跨任务洞见和关于如何高效学习的通用知识；随后，元学习器 (meta-learner) 利用这些知识快速适应新的、未见过的任务。在 CAT 中，每位被试的测试过程都可视为一个任务，因为它涉及根据能力水平选择合适的测试题目。选题算法可被看作一种通用知识，因为它代表了从多样被试群体中积累的知识与经验（图 5）。这种知识可包括最优的选题策略、不同测试题目特征的信息、被试能力先验等。通过从大规模作答数据集集中的这些多样被试（任务）中学习，它能习得一种可适应个体被试的良好选题方式。

图 5：CAT 的整体元学习框架（改编自 BOBCAT）。目标是通过探索大规模被试作答数据来优化选题算法 π 。每位被试是一个独特的学习任务；元学习器充当选题算法设计者，基学习器充当被试能力估计器。

双层优化 (Bi-Level Optimization)。双层优化是 CAT 中常用的经典元学习方法。它将学习过程分解为两个嵌套层级：适应个体被试的内层，以及学习通用知识的外层。Ghosh 等人提出了一个用于 CAT 的双层优化框架 (BOBCAT)，直接学习数据驱动的选题算法 π 。具体地：设 N 为训练 π 的作答数据集集中的被试数。每位被试 i 的作答被随机划分为支持集 D_s^i 和查询集 D_u^i ，其中 π 从 D_s^i 中依次选出共 t 道题 $\{q_1, \dots, q_t\}$ ，观测其作答，并预测其在留出查询集 D_u^i 上的作答。全局知识（即选题算法 π 和全局参数 γ ）被重新定义为双层优化的目标：

$$\begin{aligned} \min_{\pi, \gamma} \frac{1}{N} \sum_{i=1}^N \sum_{(q,y) \in D_u^i} \ell(y, f(q, \hat{\theta}_i)), \\ \text{s.t. } \hat{\theta}_i = \arg \min_{\theta_i} \sum_{(q,y) \in D_s^i} \ell(y, f(q, \theta_i)), \\ \text{其中 } q_{t+1} \sim \pi(q|q_1, y_{i(1)}, \dots, q_t, y_{i(t)}) \in D_s^i. \end{aligned}$$

图 5 展示了整体元学习框架。在内层中，被试 i 支持集 D_s^i 中的题目由 π 根据此前作答依次选出；随后最小化 D_s^i 上的二元交叉熵损失 $\ell(\cdot)$ ，以估计供外层使用的能力 $\hat{\theta}_i$ 。在外层中，最小化估计 $\hat{\theta}_i$ 在查询集 D_u^i 上的损失，以学习选题算法 π 和全局参数 γ （如题目特征）。算法 π 同样是模型无关的，通过优化该问题可自动适应给定的测量模型 f 以实现高效选题。

通过大规模采样和训练，该框架学会针对不同被试、在不同情境下估计和量化每道题的价值。即便对于训练集中未出现 ID 的题目，也可通过 γ 从其特征推断其价值。一旦选题算法训练完成，其参数在 CAT 过程中不再更新，而是依据此前作答行为自适应地选择下一题。

在 BOBCAT 基础上，已有越来越多改进工作。Ma 等人提出灵活优化框架解耦学习 CAT (Decoupled Learning CAT, DL-CAT)。原始 BOBCAT 通过耦合的内外层优化获得两个模块（即被试能力估计和选题算法）的参数，即用外层优化模型的结果来衡量内层的质量。DL-CAT 设计了一种真值构造策略和成对损失函数，使这两个模型可以独立训练；Feng 等人引入了 BOBCAT 的约束版本，以处理题目曝光和测试重叠问题；Yu 等人最近在优化该双层问题时引入被试的协同信息，实现了能力估计的快速收敛。

元学习 vs 强化学习。在 CAT 中，元学习方法可被视为一种更高层的学习过程，它学习如何将通用的选题策略适配到具体被试（基于其作答）。实际上，它可被重新表述为一个 RL 问题。Zhuang 等人提出 NCAT，将 CAT 中的元学习问题转化为 RL 问题。由于测试可能根据不同停止规则在任意步停止，NCAT 简化了原始目标，对所有步骤求和以最小化损失：

$$\min_{\pi} \frac{1}{N} \sum_{i=1}^N \sum_{t=1}^T \sum_{(q,y) \in D_u^i} \ell(y, f(q, \hat{\theta}_i^t)) \triangleq \max_{\pi} E_{i \sim \pi} \left[\sum_{t=1}^T - \sum_{(q,y) \in D_u^i} \ell(y, f(q, \hat{\theta}_i^t)) \right] = \max_{\pi} E_{i \sim \pi} \left[\sum_{t=1}^T -L(D_u^i | \hat{\theta}_i^t) \right],$$

其中 $\hat{\theta}_i^t = \arg \min_{\theta} \sum_{(q,y) \in D_s^{i(t)}} \ell(y, f(q, \theta))$ ，且 $D_s^{i(t)} = \{q_1, y_{i(1)}, \dots, q_t, y_{i(t)}\}$ 。于是，双层优化被转化为在 RL 设定下最大化期望累积奖励（即 $-L(D_u^i | \hat{\theta}_i^t)$ ），奖励为被试 i 在步骤 t 时其估计能力在查询集上的负损失。最近提出的 GMOCAT 是一个多目标 RL 框架。GMOCAT 使用图神经网络捕捉题目与技能之间的复杂关系，采用 Actor-Critic 架构，并将三个目标纳入奖励函数：(1) 提升预测准确度，(2) 增强概念（技能）多样性，(3) 降低题目曝光。

讨论：上述数据驱动的机器学习方法（即强化学习和元学习）能够从数据中发掘潜在模式和相关性，并直接优化选题策略。通过拟合大规模数据，它们能逼近 CAT 的终极目标。然而，数据偏倚、模型过拟合和高昂训练开销等潜在问题不应被忽视。

5.5 子集选择算法

CAT 的终极目标是既高效又准确地测量被试能力。具体地，如定义 1 所示，目标是从题库 Q 中找到一个含 T 道题的子集 S ，使最终能力估计 $\hat{\theta}_T$ 能逼近真实能力 θ_0 ：

$$\min_{|S|=T} \|\hat{\theta}_T - \theta_0\|,$$

其中 $\hat{\theta}_T = \arg \min_{\theta} \sum_{(q,y) \in S} \ell(y, f(q, \theta))$ 是测试以对应 T 次作答结束时的最终能力估计。与此前的序贯选题方法不同，它本质上并不要求每一步都做出完美选择，而是强调最终估计的准确性。

图 6：子集优化问题示意（改编自 BECAT）——选择子集 S 以覆盖题库 Q 。矩形代表不同题目， $w(i, j)$ 衡量题目对的相似度。其涉及三个要素：元素属性（题目在估计能力中的重要性，或决定其信息价值的特征）、目标函数（识别最有信息量或最具代表性的题目子集以使估计准确）、约束（测试长度要求）。

从全局视角看，CAT 本质上是一个子集选择（Subset Selection）问题，这是机器学习与优化中的一个基础挑战。它围绕从一个更大集合 Q 中选择元素子集 S ，在满足特定约束的同时优化某一目标函数 $F(S)$ 。然而，我们无法直接求解上述优化问题，主要挑战在于：被试的真实能力 θ_0 未知，它不存在于数据集中，这使我们无法直接优化或设计选题算法。为解决此问题，一些研究者开发了启发式方法。例如，Mujtaba 等人将测量标准误（standard error of measurement）作为目标 $F(S)$ ，它衡量对测试估计的置信度。在每一步，它用多目标进化算法，通过最大化精度并最小化题目数量，来获得 Pareto 最优解集。最近，在 AI 模型评估中，聚类技术（如 K-means）被用于从基准中选择代表性子集 S 。

为开发更通用、可扩展的 CAT 框架，Zhuang 等人提出 BECAT，以数据摘要（data summary）的方式重新表述选题问题。由于真实能力 θ_0 不可观测，他们用 θ^* 来近似它：即从被试对整个题库 Q 的全部作答中估计出的能力，即 $\theta^* \approx \theta_0$ 。这一近似使选题算法可以以 θ^* 而非未知的 θ_0 为目标：选择题目子集 $S \subseteq Q$ ，使基于 S 的能力估计尽可能逼近 θ^* （即在对 Q 的全部作答上优化所得的估计）。

$$\begin{aligned} \min_{|S|=T} \|\hat{\theta}_T - \theta_0\| &\Rightarrow \min_{|S|=T} \|\hat{\theta}_T - \theta^*\| \\ &\Rightarrow \min_{|S|=T} \max_{\theta \in \Theta} \left\| \sum_{(q,y) \in S} \gamma \nabla \ell(y, f(q, \theta)) - \sum_{(q,y) \in Q} \nabla \ell(y, f(q, \theta)) \right\| \\ &\Rightarrow \min_{|S|=T} \max_{\theta \in \Theta} \sum_{i \in Q} \min_{j \in S} \|\nabla \ell_i(\theta) - \nabla \ell_j(\theta)\| \Rightarrow \max_{|S|=T} \sum_{i \in Q} \max_{j \in S} w(i, j), \end{aligned}$$

其中 $w(i, j) \triangleq d - \max_{\theta \in \Theta} \|\nabla \ell_i(\theta) - \nabla \ell_j(\theta)\|$ 是该被试题目对 (q_i, q_j) 之间的梯度相似度，于是目标函数 $F(S) = \sum_{i \in Q} \max_{j \in S} w(i, j)$ 。BECAT 子集选择算法的核心是找到一个规模为 T 的子集 S ，使其对 Q 的覆盖度（由相似度度量 $w(i, j)$ 量化）最大化。这一方法（图 6）本质上寻求最具代表性的题目，与此前的选题算法一致，但置于一个全新、更严格的理论框架之下。

鉴于该优化问题的 NP-Hard 性质，BECAT 采用次模函数 (submodular function) 近似。一个简单的贪心算法最终即可求解该子集选择问题，BECAT 确保估计误差在每一步都有上界。CAT 中的子集选择问题是一个具有巨大潜力的新方向。该方法为选题提供了一个通用框架，适用于各种可利用基于梯度估计的复杂测量模型，包括神经网络模型。

讨论：值得注意的是，尽管最新的机器学习与深度学习方法展现出更优性能，它们在实践中尚未取代传统统计方法。尤其在优先考虑可解释性或效率的测试场景中，统计方法仍占主导。在附录中，我们对 CAT 系统中这五类选题算法进行了比较，凸显各类的通用性与可解释性，以及它们的主要优势和局限。这一概览有助于研究者在效率与复杂度之间权衡，为其 CAT 应用识别最合适的算法。

6 题库构建

要开发高质量的 CAT，基础步骤是构建高质量的题库。题库构建可分解为两个主要阶段：题目特征分析和题库开发：(1) 题目特征分析首先详细考查潜在题目的属性和特征；随后，(2) 题库开发从分析过的题目中组装出最终题库 Q 。

6.1 题目特征分析

第一阶段——题目特征分析——涉及对潜在题目属性和特征的详细考查，如难度、区分度以及解答该题所需的知识概念。例如，当基于 Fisher 信息选题时，必须利用预先标定的参数（如难度 β_j 、区分度 α_j 、猜测因子 c_j ），结合当前能力估计，来计算每道题 j 的信息值 $I_j(\theta)$ 。特征分析方法可分为三大类：基于专家、基于统计和基于深度学习的方法。

基于专家的特征标注。在基于专家的标注中，领域专家评估题目参数，如在线 CAT 系统 SIETTE 和 GenTAI 即如此。有效的专家估计通常涉及结构化问卷，随后通过讨论解决意见分歧。结果通过对连续属性取平均、对离散属性投票的方式聚合。专家判断可能带有主观性，导致潜在的不准确，尤其在专家输入有限或不一致时。随着生成式 AI 的进步，LLM 也可用于标注题目特征。

基于统计的特征标注。基于统计的题目特征标注方法需要收集大量被试的作答。它资源消耗高，且涉及对被试进行预测试。在经典测试理论中，题目难度计算为被试中答对的比例，区分度则由高能力与低能力被试之间的表现差异导出。Q 矩阵是题目的另一关键特征，它是一个指示题目关联哪些知识概念的二元矩阵。众多研究者尝试采用一些参数估计方法（如极大似然估计和贝叶斯估计），从作答数据中学习这些特征参数。

基于深度学习的特征标注。随着自然语言处理 (NLP) 的兴起，近年来直接利用题目文本信息分析各类属性的趋势日益增长。对于难度预测，基于注意力的 CNN 模型和领域自适应策略已被用于评估阅读题和医学题的复杂度。对于通常呈层级结构的知识概念 (Q 矩阵) 预测，提出了基于层级注意力的循环神经网络。Lei 等人进一步考虑题目的多模态特征，如图像和公式。预训练 NLP 模型也已被证明对自动化题目分析有效。

6.2 题库开发

第二阶段——题库开发——涉及从第一阶段分析过的题目中实际组装题库。这一过程应致力于创建一个均衡、多样的题库，以满足不同能力水平和不同知识领域的需求。根据不同场景，开发题库的方法可分为以下三个方面。

题库蓝图设计。蓝图设计的目标是为题库创建最优框架，依据各类属性勾勒题目分布。Reckase 等人分析了在采用最大 Fisher 信息选题算法的 1PL-IRT 模型的 CAT 系统中，最优题库的特征。他们提出「分箱-合并 (bin-and-union)」方法，允许最优难度与估计能力之间存在最大偏差 r ，并将这些方法扩展到大规模 CAT 系统和持续的新题预测试。

题库组装。蓝图设计聚焦于创建最优框架，而组装过程涉及根据特定需求从现有主题库 (master bank) 生成题库。Way 等人讨论了主题库的开发与维护，包括确保组装的题库满足期望规格的约束。有研究提出混合整数规划，以创建一个满足内容规格、并在选定能力值处最大化信息的题库。

题库轮换。题库轮换涉及将主题库划分为若干带有重叠元素的小题库，以确保曝光率均衡。Ariel 等人提出用 Gulliksen 的匹配随机子测验方法将主题库划分为小题库，以防止过度或不足曝光。加权偏差模型 (Weighted Deviation Model) 管理重叠程度，保持代表性并防止题目过度曝光。

讨论：可将整个题库开发过程类比为创建和管理一座图书馆。蓝图设计如同图书馆的建筑规划，定义各区域（如小说、非小说）的位置；组装过程类似根据特定需求从供应商处采购书籍；题库轮换则类似定期轮换陈列的书籍——尽管图书馆藏书浩瀚，任一时刻只有一部分被显著陈列。这种轮换确保不同书籍都能获得曝光，访客随时能接触到各种书籍。尽管本节迄今聚焦经典方法，题库构建流程也可纳入 LLM 作为辅助组件。换言之，LLM 可被整合进题库开发阶段以提升可扩展性、降低人工成本，而 CAT 的心理测量学原理保持不变。在这一类比中，LLM（或智能体）可被视为「图书馆员」，帮助扩展和加速内容遴选：它们可在明确约束下按需起草候选题目，并生成有用的元数据（主题标签、预期解题思路、常见错误模式），以支持索引和检索。本节介绍的高质量题库构建不仅是 CAT 的前提，也是一个持续过程，需要定期更新和优化，以确保自适应测试系统的相关性与有效性。

7 CAT 的测试控制

在实施测试系统时，除考虑上述三大组件外，还需考虑若干关键因素，如曝光控制、公平性、鲁棒性和搜索效率。

7.1 曝光控制

曝光控制旨在均衡题库中每道题的使用频率。恰当的曝光控制有助于降低题目过度曝光的风险、减少题目浪费，并最大化测试覆盖。两种流行的曝光控制策略是 Sympon-Hetter 方法和 A-Stratified 方法：(1) **Sympon-Hetter** 方法使用条件概率管理题目曝光率。它不会立即将选中的题目分配给被试，而是让其通过一个概率过滤器。一道题实际被分配给被试的机会取决于其被选中的可能性和一个曝光控制参数，从而将题目曝光保持在可接受范围内。然而，该方法可能无法有效提升低曝光题目的使用率。已有改进工作来弥补这些局限。(2) **A-Stratified** 方法及其后续研究旨在抵消算法偏好某些题目的选择偏倚（例如 Fisher 信息偏好高分度题目）。另一方面，众多研究尝试将知识概念覆盖度纳入选题准则，以使评估更全面。

这一因素对人类和 AI 都至关重要。当学生事先熟悉考题时，测试结果就失去可信度。同样，对 AI 模型评估而言，已观察到：在 LLM 训练数据创建日期之前发布的基准，通常表现优于之后发布的基准。AI 评估的数据污染问题正日益受到质疑。因此，控制题目曝光率是提升评估可靠性的必要措施。

7.2 公平性

公平性在教育 and 机器学习研究领域都是具有深远社会意义的议题，引发了大量讨论，并催生了许多公平性感知（fairness-aware）的学习算法。作为一项在高利害测试中有潜在应用的技术，CAT 中的公平性是首要关切。在 CAT 中，导致公平性问题的偏倚可经由三个组件引入：

- **测量模型中的偏倚。**测量模型中的偏倚可能源自有偏的训练数据，它可能反映某些群体的代表性不足或既有的教育差距。此类偏倚可能导致对被试能力 θ 的不准确、有偏的估计，从而产生不公平的结果。一种实用的缓解措施是评估各子群体间的标定和模型拟合（如不变性检验），并在需要时应用多群体标定。公平性感知的标定目标也可作为轻量正则项，以减少虚假的群体效应。
- **题库中的偏倚。**如果题目并非对所有被试同等适用或贴切，题库可能含有偏倚，从而可能使某些群体处于劣势。例如，NAPLAN 中的一些题目被认为对农村被试不公平，因为这些题目与他们的现实生活经验无关。已提出多种方法来检测此类偏倚。例如，缓解通常遵循「审计-修复」循环：DIF（differential item functioning，项目功能差异）分析标记出潜在有偏的题目，随后对其修订、替换或退役。这通常与专家评审配合，以区分非预期的情境偏倚和与构念相关的差异。
- **选题算法中的偏倚。**选题算法可能引入偏倚，因为每种算法都有其自身的「选择偏好」。例如，最大 Fisher 信息倾向于选择高分度题目。如果此类题目意外地与仅某特定群体掌握的专门知识相关，便可能产生偏倚。

对 CAT 公平性的担忧还源于一个事实：被试回答的是不同的题目。等值（Equating）是一种确保不同测试间分数等价的技术，常被用于应对此类担忧。关于分数等值的许多进一步研究已经开展。在 GRE 等真实测试中，等值被用于标准化分数和百分位，并考虑所答题目的难度。这一过程确保分数能在全球不同被试间公平比较。实践中，等值还辅以例行的漂移检查和周期性的 DIF 重审，尤其在新题加入或轮换时。这有助于在题库演变时保持可比性。

7.3 鲁棒性

CAT 中的噪声会影响被试能力估计的精度，导致分数解释中的潜在错误。在 CAT 中，噪声通常指可能影响估计准确性的随机变异或测量误差。它可源自多种来源，如测试管理条件、被试行为或题目特征。例如，被试可能在测试中受环境噪声干扰而答错，未能反映其真实能力；或者，措辞拙劣或含糊的题目可能使被试困惑，给作答带来非预期的变异。

为缓解 CAT 中噪声的影响，引入鲁棒性因素，通过纳入额外信息来帮助稳定能力估计，从而抵消噪声影响、提升可靠性。在机器学习中，多种鲁棒性技术被用于增强模型在噪声下的性能，如正则化方法、数据增强、对抗方法、集成方法。在 CAT 测试过程中，被试造成的猜测和失误因素等显著噪声来源会引入不确定性。例如，被试的能力水平可能无法由其作答唯一确定，因为他们可能用不同的知识概念、甚至靠猜测来正确解答某道题。噪声和不确定性的存在对 CAT 系统的鲁棒性构成重大挑战。Veldkamp 等人也在选题过程中考虑题目参数的不确定性。更近期，集成学习被探索用于在每一步组合多个潜在估计，从而增强能力估计。

7.4 搜索效率

在大规模教育测试中，高效选题是一项关键挑战。传统选题算法常以暴力方式评估所有候选题目，导致 $O(|Q|)$ 的线性时间复杂度（ Q 为题库）。这在智能测试系统中成为计算瓶颈。为缓解此问题，GMAT 等一些机构依赖专家制定的人工筛选规则，但其人力密集且缺乏可扩展性。近期研究探索了两个改进效率的主要方向：

- **基于 PSO 的启发式搜索：**粒子群优化（Particle Swarm Optimization, PSO）已被应用于基于 IRT 的自适应测试。PSO 支持对搜索空间的并行探索，每个粒子代表一道候选题。这种并行性加速了向最优选择的收敛，降低了计算负担。
- **基于树的索引：**受推荐系统和信息检索启发，平衡树等高效搜索结构被采用。Hong 等人提出一个搜索高效 CAT（Search-Efficient CAT）框架，采用被试感知的空间划分来构建基于树的索引。该方法显著缩小搜索空间，并避免跨测试轮次的冗余计算，将搜索复杂度从 $O(|Q|)$ 降至 $O(\log |Q|)$ 。

讨论：尽管准确性和效率是首要目标，但这些因素对实际场景（尤其是高利害测试场景，如竞争性或选拔性考试）具有重要意义。然而，对这些因素的考量可能不可避免地降低准确性。例如，当考虑额外的公平性以确保不同群体间的公平时，可能需要偏离训练良好的选题算法的最优轨迹。因此，

CAT 提出了一个多维决策挑战，需要用多样的机器学习技术同时考量各种因素。在附录中，我们展示了 CAT 测试控制中不同因素的根本成因和优势。

8 评估

已开发出多种指标来评估 CAT 方法的性能，如相关系数、偏差和测量误差。本节介绍两种应用最广的评估方法：能力估计仿真和被试得分预测。

能力估计仿真。能力估计仿真是 CAT 中一项基础的评估技术。由于真实能力 θ_0 不可观测，我们通过采样一组值 $\{\theta_0^1, \theta_0^2, \dots, \theta_0^N\}$ 来代表一个虚拟被试群体以模拟它。这一方法使我们能够利用测量模型进一步模拟被试（具有这些能力）与题库中任意题目之间的交互。因此，可将估计的最终能力值 θ_T 直接与真实值 θ_0 比较。例如，通过计算均方误差 (MSE)，即 $E\|\theta_T - \theta_0\|$ ，来评估 CAT 系统的准确性。

被试得分预测。在基于机器学习的 CAT 系统中，能力估计常通过预测被试能否答对未见过的题目来验证。通常，被试被划分为训练、验证和测试集（如 70%-20%-10%），确保无重叠。训练集用于标定题目参数（第 6.1 节）和训练选题算法（第 5.3、5.4 节）。在验证或测试时，每位被试的作答进一步划分为用于选题的候选集 Q_i 和用于评估的留出元集（meta set） M_i 。候选集 Q_i （及对应作答标签 y ）用于模拟 CAT 过程：从 Q_i 中选题，每步后更新能力估计，然后通过预测 M_i 上的作答来获取估计的精度。其假设是：更好的得分预测反映更准确的能力估计。因此，可用二分类指标进行评估，如预测准确率（ACC）和 ROC 曲线下面积（AUC）。

数据集。为评估 CAT 系统的有效性和泛化性，使用既能挑战算法又能反映真实测试场景的多样数据集至关重要。此类数据集通常包含题库、被试作答数据和相关情境数据。每个组成部分对于在现实场景中验证 CAT 系统本身都不可或缺。可用于此类评估的数据有三类：

- （1）人类教育数据：**此类包括从实际教育环境（如中小学、大学和在线学习平台）收集的数据，提供被试如何在自然场景中在教育内容和评估互动的洞见。数据可涵盖被试信息、表现作答、学习行为、题目特征等。我们已开源一个全面的教育相关数据集库：<https://github.com/bigdata-ustc/EduData>。它包含一系列公开数据集以及此前的私有数据集，如 ASSISTments、Junyi、EdNet 和 Eedi2020。此外，我们还提供了详细的数据分析以支持教育场景下进一步的 CAT 研究与应用，详见 EduData GitHub 链接。
- （2）AI 模型作答数据：**CAT 范式在 AI 模型评估中正发挥关键作用。特别地，能力估计被用于评估和排名模型，尤其用于当代 LLM 评估。各种大规模基准及其对应作答数据可用于构建和测试 CAT 系统，如 Google 的 BIG-bench、HuggingFace 的 Open LLM Leaderboard、HELM 和 AlpacaEval。这些基准涵盖广泛任务，主题横跨语言学、数学、医学、常识推理、生物、物理、社会偏见、编程等。
- （3）仿真数据集：**这些是如上所述人工创建的、模拟真实被试作答特征的数据集。它们可定制以包含特定模式、噪声水平和分布，从而在各种场景下对 CAT 系统进行受控测试。蒙特卡洛仿真也可用于生成具有已知性质和真值的数据集。这些数据集有助于验证 CAT 系统准确估计能力、并适应测试过程中模拟变化的能力。

9 未来研究机遇

将机器学习整合进 CAT 有望彻底革新这一领域。本节探讨机器学习在扩展 CAT 系统的适用性、可解释性和多维性方面的未来潜力。

评估过程的多维性。未来研究应利用机器学习增强评估的多维性。这不仅涉及传统的作答模式，还包括对过程数据（如作答时间和鼠标移动）的细致分析，它们能提供对被试解题策略和投入程度的洞见。此外，整合学习数据（如被试此前与学习材料的交互）可提供其学习轨迹和对新概念准备程度的纵向视角。再者，对内容（涵盖文本、视觉和听觉材料）的分析，可更丰富地理解被试如何与多面信息互动。此类机器学习驱动的方法有望全面完善 CAT 系统，使其交付的评估不仅能准确反映被试当前能力，还能预测其未来学习的潜力。

迈向 CAT 中可解释的机器学习。传统 CAT 系统，尤其是基于信息和统计的方法，因其可解释性而受到称赞——从测量模型的参数到选题算法背后的逻辑。这种透明性为所有利益相关方（包括被试、家长和教育者）提供了宝贵洞见，并支持开发者调试和优化 CAT 系统。实践中，可解释性对于在高利害场景中部署 CAT 往往很重要：测试提供方可能需要解释为何选择某些题目、证明对各群体的公平对待，并支持审计或申诉。即便选题策略复杂，也可通过使主要约束透明、并为每次选题记录一个简单、人类可读的理由来应对。然而，近期的机器学习方法，尤其是采用深度学习的方法，在知识发现能力上具有压倒性优势，代价是可解释性降低。弥合这些范式之间的鸿沟，创建既准确又能自我解释的 CAT 系统，是未来研究必须应对的重大挑战。这对于结果具有重大后果的高利害标准化测试尤为关键。

用生成式 AI 赋能 CAT。生成式人工智能（如 LLM）在海量、跨领域数据集上训练，使其具备多功能性和深厚的世界知识储备。这些模型已在用户建模（如推荐系统）和个性化策略生成方面展现出初步进展。这一关联在概念上与 CAT 一致：两者都旨在从观测到的行为中推断潜在的用户特质（如能力），进而相应调整后交互。LLM/智能体可超越二元正误，利用中间步骤、解释、犹豫模式和错误类型来丰富观测空间，在适当标定后支持更细粒度的能力估计。未来，这些大模型有潜力在多个方面显著增强 CAT 系统，如题目选择、能力评估，乃至实时自动生成新颖、定制化的题目——这些题目并不预先存在于题库中。一种实用的整合方式是将 LLM 用作辅助模块：它们可在给定目标概念/技能标签、格式约束和预期难度区间的条件下起草候选题，并生成有用的元数据（主题标签、预期解题思路和常见误解），以帮助高效索引和检索题目。我们可以设想这样一个未来：测试范式朝着更高的智能化和自动化演进。一个训练良好的测试智能体可以用自然语言与被试互动，利用各种线索和过程细节进行全面的能力评估。这一方式将超越让被试逐个回答预定题库或基准题目的单调任务。此类进展可带来更有效、更个性化的测试体验。

改进机器智能评估。传统 AI 模型评估广泛依赖大型、黄金标准基准。「越多越好」的格言推动了使用更大基准以提供全面评估。然而，这些基准的庞大规模带来了显著的时间和计算成本，使快速、经济的评估变得困难。例如，在完整的 HELM 基准上评估单个 LLM 的性能可能消耗超过 4000 GPU 小时（或 API 花费超过 1 万美元）。此外，这些基准常被低质量题目、错误和污染问题困扰。如前所述，越来越多研究者尝试利用 CAT 和心理测量学来识别和解决这些问题，降低评估开销，并逐步将其转变为一种新的评估范式。这一转变在 AI 系统逼近人类水平表现时尤为有价值，此时 CAT 能对类认知行为提供更细粒度的分析。尽管先进 LLM 在架构上与人类有根本不同，但其学得的行为常表现出相似特征，因为它们在大规模人类产生的数据上训练，并展现出类认知的标志。CAT 并不假设模型是「人类」；它只需要可被一致评分、并与题目统计量相关联的可观测作答。最终，这一新兴范式可能带来更智能、更快速、更具成本效益的评估，深化我们对人类和机器智能的理解。

10 结论

计算机自适应测试 (CAT) 历经五十余年演进，在统计学习的支持下，在对人类和 AI 模型的智能评估方面取得了显著进展。在过去五年中，深度学习与 CAT 日益融合，催生了此前难以想象的创新方法。这些方法包括直接从大规模数据中学习的选题算法、将选题效率提升高达 200 倍的基于检索的方法，以及对估计误差上界的理论研究。尽管许多方法仍处于早期阶段、尚未在实践中广泛应用，它们清晰地指向了由当今 AI 浪潮驱动的更智能测试系统的光明未来。

这篇全面的综述凸显了 CAT 错综复杂、广阔无垠的本质，强调了整合机器学习以增强 CAT 系统的潜力与前景。本文主要聚焦机器/人类评估中准确性与效率的双重关切。所呈现的洞见不仅对教育和心理测量学的专家可及且相关，也面向广泛的研究者群体。我们鼓励感兴趣的读者探索机器学习在这一领域的变革性影响，并将本综述作为未来研究的参考。

附录

A. Fisher 信息与 KL 信息的比较

图 7 展示了两道不同题目的 KL 信息和 Fisher 信息函数。对于 θ 接近 θ_0 的情形，KL 信息与 Fisher 信息总是接近。若将 KL 信息视为一条曲线，Fisher 信息对应其在 $\theta = \theta_0$ 处的曲率（二阶导数）。这表明 Fisher 信息可由 KL 信息导出，反之则不然。

图 7：两道题目（题 1: $\alpha = 1.7, \beta = 1.9, c = 0.1$ ；题 2: $\alpha = 2.3, \beta = 0.5, c = 0.3$ ）的 KL 与 Fisher 信息函数示意。假设当前能力估计 $\hat{\theta}_t = 1$ 。给定题目的 KL 信息（左）表示以 $\hat{\theta}_t$ 为中心的一个积分，而 Fisher 信息（右）对应在特定点 $\hat{\theta}_t$ 处的值。

B. 测试中各类关键因素分析

表 2 展示了 CAT 测试控制中不同因素的根本成因和优势。

表 2：测试控制——CAT 实施中的关键因素

因素	类别	成因	优势
曝光控制	—	题目使用不均衡	缓解过度曝光；测试安全；全面评估
公平性	测量模型偏倚	训练数据有偏；某些群体代表性不足	促进公平结果；提升能力估计准确性
公平性	题库偏倚	适用性不均；文化或地域偏倚	确保内容相关性；减少对某些群体的不利
公平性	选题算法偏倚	算法偏好	减少对某些群体的不利
公平性	等值	被试间所选题目不同	分数可比性；不同测试间的公平
鲁棒性	抗噪	随机变异；猜测和失误因素	稳定估计；提升可靠性
鲁棒性	不确定性建模	作答中的不确定性	提升能力估计准确性
搜索效率	—	题库庞大；暴力搜索	降低搜索复杂度

C. 不同选题算法的比较

表 1（正文）与表 3 展示了各类选题算法的代表性方法及其在两个不同数据集上的 AUC 结果。本综述的比较聚焦测试早期阶段（step=5）和最终阶段（step=20）的结果。需要注意，如果实验设置未标准化，结果不能直接比较。尽管如此，整体而言，表格揭示出：数据驱动方法（如强化学习、元学习方法）通常优于统计方法。这是因为这些方法能从被试大规模作答数据中训练和优化选题算法，而统计方法仅遵循固定函数选题。最新的子集选择方法无需训练却显著有效，主要是因为它们试图显式逼近 CAT 的目标，并为估计误差提供理论保证。此外，可以观察到，考虑测试控制中的因素（如鲁棒性）能提升准确性。

表 1：CAT 中不同选题算法的比较

类别	通用性	可解释性	需训练	优势	劣势
统计算法	否	是	否	实现简单、运行高效	依赖 IRT，且设计需专家知识
主动学习	是	是	否	模型无关、灵活	忽略测量模型参数中的细致信息
强化学习	是	否	是	自动生成选题算法；序贯决策	带来额外训练成本，以及数据驱动选择的潜在偏倚
元学习	是	否	是	自动生成选题算法；快速适应	带来额外训练成本，以及数据驱动选择的潜在偏倚
子集选择	是	是	否	对估计准确性有强理论保证	在 CAT 初始阶段面临挑战

表 3：不同 CAT 方法报告的 AUC 结果（节选）。在 ASSISTments 和 Eedi2020 两个数据集上，分别采用 IRT 和 NeuralCD 作为测量模型，比较各选题算法在 step=5 和 step=20 的 AUC。代表性结果包括：随机选择约 67–70 (AUC@5)；Fisher 信息、KL 信息约 67–73；MAAT (主动学习) 约 68–73；GMOCAT、NCAT (强化学习) 约 69–79；BOBCAT、SACAT (元学习) 约 66–79；BECAT (子集选择) 在多数设置下取得最优，AUC@20 可达 79+ (如 Eedi2020 + NeuralCD 达 79.36)。(此处为原文表 3，含大量分项数值，仅转述其总体趋势：子集选择与数据驱动方法在最终阶段总体领先。)

D. 代表性数据集介绍

以下是几个常用数据集的介绍，更多数据集见 EduData GitHub 链接：<https://github.com/bigdata-ustc/EduData>

- **ASSISTments**: 创建于 2004 年，是美国的一个在线辅导平台，为被试提供评估和教学支持。迄今 ASSISTments 团队已发布四个公开数据集：ASSISTments2009、2012、2015 和 2017。这些数据集作为作答数据，多数采集自中学数学，还包含有价值的旁信息，如尝试次数、首次作答时间 (ms first response)、题目类型和平均信心。
- **Junyi 数据集**: 包含均一 (Junyi) 学院的日志和习题数据。该平台是 2012 年使用可汗学院 (Khan Academy) 开源代码创建的中国在线学习平台，具有由专家标注的详细题目层级和关系。
- **MOOCube**: 大规模开放在线课程 (MOOC) 是最普遍的在线学习平台之一。该数据集收集了被试对各类计算机科学概念相关题目的作答，还包括题目文本，可用于增强选题、能力估计、题目特征分析等的性能。
- **EdNet 数据集**: 来自 AI 辅导系统 Santa 的大规模被试学习记录集，该系统用于韩国的英语学习。它聚焦准备 eTOEIC (托业) 听力和阅读考试的被试，含来自约 78.4 万名被试的超过 1.31 亿条学习记录。
- **Eedi2020 数据集**: 为 NeurIPS 2020 教育挑战赛发布，含 Eedi 平台上被试对数学多选题的超过 1700 万条作答记录。它包括被试选择、人口统计学信息、知识概念的包含关系，以及相关的测验和课程元数据等详细信息。这一庞大数据集支持对被试行为的深入分析和个性化工具的开发。

E. 系统性文献综述协议

为提升本综述的透明度和可复现性，我们遵循了一个轻量级的 SLR (systematic literature review) 式协议来收集和筛选文献。我们检索了主要的学术数据库和数字图书馆 (如 Google Scholar、IEEE Xplore、ACM Digital Library 和 arXiv)，使用与计算机自适应测试和心理测量学相关的关键词组合 (如「computerized adaptive testing」「CAT」「item response theory/IRT」「exposure control」「content balancing」「online calibration」「multidimensional IRT」)，以及与 AI/LLM 评估的近期扩展相关的关键词 (如「adaptive evaluation」「LLM benchmarking」「agent-based assessment」)。我们主要聚焦 2000–2025 年间的同行评审论文和广泛使用的技术报告，并在必要时纳入更早的奠基性工作以保证完整性。我们采用的纳入标准要求文献与 CAT/IRT (或其 AI 模型评估中的应用) 具有明确的方法学相关性。筛选分两阶段进行：先做标题/摘要初筛，再对高相关候选做全文评审。所选研究随后被组织进所呈现的分类体系和各节中 (如图 2、表 2 和表 3)。

参考文献 (References) 按约定未翻译，详见原文。