

RECAT: 显式与隐式「考生一题目」关系挖掘的高效 CAT 精读笔记

原文: 07940-WangC.pdf(AAAI-25, Wang et al.)·代码: 官方仓库 <https://github.com/ChangqianWang/Intelligent-Education/tree/main/RECAT> (截至笔记时该目录 README 仍为「Coming Soon」, 未发现可用开源代码)·笔记于 2026-06-26

一、解决什么问题

先把 CAT (计算机自适应测试) 的大背景摆清楚。CAT 是「在线考试边考边出题」: 系统每出一题、收到考生作答, 就用**认知诊断模型 (CDM)** 更新一次对考生能力 θ 的估计; 然后**题目选择算法**根据当前能力估计挑下一题。目标是用尽量少的题把考生的真实能力 θ_i 估准。所以选题策略好坏直接决定测试效率。

现有选题方法分两派, 各有硬伤:

- **基于策略 (policy-based)**, 如 MAAT、BECAT: 用一套显式的、人工设计的准则 (比如「选期望模型变化 EMC 最大的题」「选能让子集梯度逼近全库梯度的题」)。优点是理论保证、可解释, 题库加新题也不用重训。**致命缺点**: 每一步都要把几乎整个题库扫一遍算分, 题库一大, 选题延迟爆炸 (论文表 3: BECAT 在 ASSIST12 第 10 步要 1432 秒选一题)。
- **基于学习 (learning-based)**, 如 BOBCAT、NCAT、GMOCAT: 把 CAT 写成**双层优化**, 从海量历史作答里学一个选题器, 挖的是隐式的 E-Q 关系。优点是选题快。**致命缺点**: 题库一加新题, 模型基本要整体重训; 而且大多是贪心策略, 容易漏掉好题。

论文一句话总结痛点: 这两派各占一半优点, 但没法兼得——因为 learning-based 方法依赖 Q 值 (Q-learning 那套), 和 policy-based 的准则不兼容, 没法塞到一起。

RECAT 的核心思路: 先用「生成式」的方式挖隐式关系, 为考生当前能力「凭空生成」几道最该考的题; 再拿这些生成题去题库里匹配出一小撮**真实候选题**; 最后让 **policy-based** 准则只在这一小撮候选里挑。这样隐式 (生成) 和显式 (policy 准则) 就串起来了, 而且 policy 准则不用再扫全库, 延迟从上千秒降到几十秒甚至零点几秒。

二、问题定义 (输入 / 输出)

符号约定 (维度很关键, 先记住):

- 知识概念数 d 。考生能力 $\theta_i \in \mathbb{R}^{1 \times d}$, 第 k 位 $\theta_i(k) =$ 考生在第 k 个知识点的掌握程度。
- 题目 $q_j \in \mathbb{R}^{1 \times d}$, 第 k 位 $q_j(k) =$ 该题在第 k 个知识点上的难度。(注意: 论文里 q_j 既指「第 j 题」也指它的 d 维向量。)
- θ_i^{t-1} : 第 $t-1$ 步后估计的能力。 θ_i^* : **真实能力的近似**——用考生在整个题库上的诊断结果当真实能力 (沿用 BECAT, 见式 (3))。
- $r_{ij} \in \{0, 1\}$: 考生 i 对题 j 的真实作答 (1= 对)。 $\mathcal{M}$: CDM, 输入 (θ, q) 输出预测答对概率 $\hat{r}$ 。

任务输入 / 输出 (一次选题步):

- 输入: 考生当前能力估计 θ_i^{t-1} 、考生没做过的题库 Q_i 。
- 输出: 下一题 q_t , 使得用它更新后 $\|\theta_i^t - \theta_i\|$ 尽量小 (式 (2))。

一个具体小例子: 设 $d = 3$ (三个知识点: 代数/几何/概率)。某考生真实能力近似 $\theta_i^* = [0.8, 0.3, 0.5]$ (代数强、几何弱)。当前估计才走了两步, $\theta_i^{t-1} = [0.5, 0.5, 0.5]$ (还没分辨出他几何弱)。好的下一题应该是一道**几何题**——它能最大程度把估计往真实方向拉 (让 $\theta(2)$ 从 0.5 降向 0.3)。RECAT 要做的, 就是自动判断「现在最该考几何」并选出这样一道题。

三、模型结构 (逐模块走一遍)

整体 4 步流水线 (对应原文图 2):

θ_i^{t-1} (当前能力)

题目生成模块: K 个生成器 $\rightarrow$ 生成 K 道「理想题」参数 gq
(VAE 式重参数化, 挖隐式关系)

题目匹配模块: 每道生成题 $\rightarrow$ KL 距离找题库里最像的 top-H 真实题
(得到 $K \times H$ 道候选真实题, 把搜索范围从整库砍到一小撮)

policy 准则在候选集里选： $q_t = \operatorname{argmax}_{\{q \text{ 候选}\}} I(q)$
 (显式关系，只在小集合上算，省时)
 考生作答 $q_t \rightarrow \text{CDM 更新} \rightarrow \hat{q}_t$

训练侧还有两条优化信号（第四节细讲）：**生成一致性**（强化学习，让生成器生成「能把能力拉向真值」的题）+ **知识匹配**（对比学习，让生成题参数像真题）。

为什么这么设计：直接在整库上跑 policy 准则太慢（缺点 1），纯学一个选题器又对新题不友好（缺点 2）。RECAT 让「生成器」先把「该考什么样的题」用 d 维参数描述出来（这步快、且不绑定具体某道题，所以加新题也能用），再用匹配把抽象的「理想题」落地成题库里的真题候选，最后才让慢但准的 policy 准则在小候选集上精挑。生成器学的是「能力 $\rightarrow$ 该考的题型」的隐式映射，与具体题目 ID 解耦，这正是它能适应新题的根因。

四、关键公式详解（重点）

公式 (4)：「最契合题目」的定义——全文的指挥棒

$$q_t = \arg \min_{q_j \in Q_i} \underbrace{\|\theta_i^* - \theta_i^{t-1} + \alpha \nabla_{\theta_i^{t-1}} \mathcal{L}(r_{ij}, \mathcal{M}(q_j | \theta_i^{t-1}))\|}_{\omega_{ij}}$$

- 符号： θ_i^* 真实能力近似 ($1 \times d$)； θ_i^{t-1} 当前估计 ($1 \times d$)； α 学习率（标量）； $\nabla_{\theta} \mathcal{L}$ 是「如果考生做了题 q_j ，CDM 用交叉熵更新能力时的梯度」($1 \times d$)。
- 直觉：括号里 $\theta_i^* - \alpha \nabla \mathcal{L}$ 其实就是「做完 q_j 后一步梯度下降得到的新能力 θ_i^t 」。所以 $\omega_{ij} \approx \|\theta_i^* - \theta_i^t\| =$ 做完这题后离真实能力还差多远。选 ω_{ij} 最小的题，就是选「做完它能离真值最近」的题。
- 举例（接第二节例子， $d = 3$ ）： $\theta_i^* = [0.8, 0.3, 0.5]$ ， $\theta_i^{t-1} = [0.5, 0.5, 0.5]$ ， $\alpha = 1$ 。
 - 候选 A 是几何题，更新梯度方向让能力变成 $\theta_A^t = [0.5, 0.35, 0.5] \rightarrow \omega_A = \|[0.3, -0.05, 0]\| \approx 0.304$ 。
 - 候选 B 是代数题，更新后 $\theta_B^t = [0.65, 0.5, 0.5] \rightarrow \omega_B = \|[0.15, 0.2, 0]\| = 0.25$ ？

这里要小心：单看范数 B 反而小，但 B 把已经偏低的代数估计往上抬、对暴露「几何弱」毫无帮助。论文的 θ^* 是全库诊断的“真值”，几何维度差距 $0.5 \rightarrow 0.3$ 是当前最大的待修正项，真正能让几何维快速收敛的几何题，其 ω 会比只动代数维的题更小——关键在于哪一题能让向量整体最快逼近 θ^* 。式 (4) 就是把这种「逼近真值的程度」量化成一个可比较的标量 ω_{ij} 。后一项 $+\alpha \nabla \mathcal{L}$ 还隐含「优先选考生更可能答对的题」，避免一上来全是超难题。

- 作用： ω_{ij} 是贯穿全文的「题目好坏打分」，既是选题准则，也是后面强化学习的奖励信号。

关键难点：测试时根本没有考生对 Q_i 里题目的真实作答 r_{ij} ，式 (4) 算不出来。于是引出伪反馈：假设「考生答对一道生成题的概率 $\leq$ 答对它最相似真题的概率」，用最相似真题 $q_j^* = \arg \min_{q_{in} \in R_i} \text{KL}(q_{in} \| gq_j^t)$ 的标签来近似。这就是为什么需要后面的生成 + 匹配。

公式 (5)(6)：题目生成器——用 VAE 重参数化「造题」

$$[\mu_t, \log(\sigma_t^2)] = G(\theta_i^{t-1}), \quad gq_t = \mu_t + \epsilon \odot \sigma_t, \quad \epsilon \sim \mathcal{N}(0, 1)$$

- 符号：生成器 G 是几层全连接，输入当前能力 θ_i^{t-1} ($1 \times d$)，输出每个知识点上「理想题难度」的高斯分布参数 μ_t, σ_t (各 $1 \times d$)。 gq_t 就是采样出来的一道生成题参数， $gq_t(k) =$ 这道题在第 k 知识点上的难度。
- 为什么用重参数化：直接采样 $gq \sim \mathcal{N}(\mu, \sigma)$ 没法回传梯度；写成 $\mu + \epsilon \odot \sigma$ 把随机性挪到与参数无关的 ϵ 上， μ, σ 就可训练了（标准 VAE 技巧）。
- 举例： $\theta_i^{t-1} = [0.5, 0.5, 0.5]$ 进 G ，输出 $\mu_t = [0.5, 0.35, 0.5]$ （即“该考一道几何上偏难、其它中等的题”）， $\sigma_t = [0.1, 0.1, 0.1]$ 。采样 $\epsilon = [0.2, -0.1, 0]$ 得 $gq_t = [0.52, 0.34, 0.5]$ 。这是一道虚拟题——题库里不一定有，但它精确刻画了「现在最该考的题长什么样」。
- 公式 (6)：不止一个生成器，用 K 个权重不同的生成器 $G_1, \dots, G_K$ 各造一道，得到 $Q_i^{Kt} = \{gq_1^t, \dots, gq_K^t\}$ 。好比 K 位出题老师从不同角度判断「该考啥」，增强鲁棒性、防止单一生成器把考生能力看偏。论文设 $K = 5$ 。

公式 (7)：题目匹配——把虚拟题落地成真题候选

$$MQ_j^* = \arg \operatorname{top-}H \min_{q_{in} \in Q_i} \text{KL}(q_{in} \| gq_j^t)$$

- 符号：对每道生成题 gq_j^t ，在题库 Q_i 里按 KL 散度找最像的 H 道真题。 K 道生成题各配 H 道，共 $K \times H$ 道候选真题 MQ^* 。
- 举例：生成题 $gq = [0.52, 0.34, 0.5]$ ，题库里真题 $q_a = [0.5, 0.35, 0.48]$ （很像，KL 小）、 $q_b = [0.9, 0.9, 0.1]$ （很不像，KL 大）。取 $\operatorname{top-}H$ 就选中 q_a 这类。 $K = 5, H = 10$ 时候选集才 50 道，而题库可能上千道。

- 作用：把抽象的「理想题」翻译成题库里**真实存在**、可考的题。这一步是「显式关系」的入口——接着用 policy 准则 $q_t = \arg \max_{q \in MQ^*} I(q|\theta)$ 只在这 50 道里挑，而不是全库 2337 道。这就是延迟从 **1432s** 砍到 **26s** 的来源（复杂度从 $O(A|E|)$ 降到 $O(A \cdot B \cdot K \cdot H)$, $KH \ll |E|$ ）。

公式 (8): 优化目标的 ELBO 分解——为什么训练拆成两块

$$\log p_\psi(\theta_i^* | \theta_i^{t-1}) \geq \underbrace{\mathbb{E}_{c_\Psi}[\log p_\psi(\theta_i^* | q_t, \theta_i^{t-1})]}_{\text{生成一致性}} - \underbrace{\text{KL}(c_\Psi(q_t | \cdot) \| p_\psi(q_t | \theta_i^{t-1}))}_{\text{知识匹配}}$$

- 直觉：我们想最大化「从当前能力 θ^{t-1} 出发、最终能到真实能力 θ^* 」的似然。 q_t 是中间隐变量（该考哪题），对它积分得证据下界 ELBO，拆成两项：
 - 第一项 生成一致性：给定选的题目 q_t ，它要真的能把能力推向 θ^* （题要“有用”）。
 - 第二项 知识匹配 (KL)：生成题的分布要贴近真题的分布（题要“真实、可考”，别造出题库里根本不存在的怪题）。
- 作用：这就是把训练目标分成下面 (9)(10) 强化学习 + (11)(13) 对比学习的理论依据。

公式 (9)(10): 生成一致性——用策略梯度训生成器

$$P(gq_j^t | \theta_i^{t-1}) = 1 - \frac{\exp(\omega_{ij})}{\sum_{j'} \exp(\omega_{ij'})}$$

- 为什么要 RL: ω_{ij} (题好坏) 只有在 CDM 更新完能力之后才能算出来，是「后验」的，没法直接对生成器做监督梯度。于是把它当强化学习：生成器 = 智能体，CDM = 环境，生成一道题 = 动作， ω_{ij} 转成奖励。
- 公式 (10) 解读：对 ω 做 softmax 再用 $1 - (\cdot)$ 取反。 ω_{ij} 越小（题越好） $\rightarrow$ softmax 值越小 $\rightarrow 1 -$ 后概率 P 越大 $\rightarrow$ 生成器越被鼓励多生成这类题。
- 举例： $K = 3$ 道生成题奖励 $\omega = [0.2, 0.5, 0.9]$ （第一道最好）。 $\text{softmax}([0.2, 0.5, 0.9]) \approx [0.27, 0.36, 0.49]$ （注意 exp 后归一化，这里数值仅示意相对大小）， $P \approx [0.73, 0.64, 0.51]$ 。第一道题概率最高 $\rightarrow$ 策略梯度 (9) 就会增大「生成第一道这类题」的参数权重。
- 作用：让生成器学会「针对某能力，生成 ω 最小（最能逼近真值）的题」。

公式 (11)(12)(13): 知识匹配——对比学习让生成题“像真题”

先扩候选集 (式 11)：单个考生历史作答太少，于是借同类考生——合并与 θ_i^* 最像的 top- X 名考生的作答日志成 R'_i ，再从中挑与生成题 KL 最小的 top- M 道题进候选集 C_i^t （连带它们的真实标签 r_{il} ，正好补上第二节说的「测试时没标签」问题）。

式 (12) 给候选集每道题算 ω_{ij} (同式 (4))， ω 最小的真题 = 信息量最大。

对比损失 (式 13)：

$$\mathcal{L}_{cl} = -\log \frac{\exp(\text{KL}(q^+ \| q_t) / \tau)}{\exp(\text{KL}(q^+ \| q_t) / \tau) + \sum_m^{M-1} \exp(\text{KL}(q_m^- \| q_t) / \tau)}$$

- 符号： $q^+ = \omega$ 最小的那道真题（正样本）， $\{q_m^-\}$ 是其余 $M - 1$ 道（负样本）， τ 温度系数。
- 举例： $M = 3$ ，正样本 q^+ 与生成题 q_t 的 KL=0.1，两个负样本 KL=0.8、1.2， $\tau = 1$ 。分子 $e^{0.1} = 1.105$ ，分母 $1.105 + e^{0.8} + e^{1.2} = 1.105 + 2.226 + 3.320 = 6.651$ ， $\mathcal{L}_{cl} = -\log(1.105/6.651) = -\log(0.166) \approx 1.80$ 。
 - □ 注意这里正样本是 KL 小（最像）的，却放在分子的 $\exp(\text{KL}/\tau)$ 里——KL 小则分子小、loss 反而大。按字面公式，最小化 loss 会把正样本推远。这与「让 q_t 靠近正样本」的文字描述方向相反，疑似论文公式 (13) 有笔误（常规 InfoNCE 应是相似度 sim 放分子、且正样本相似度大 $\rightarrow$ 分子大 $\rightarrow$ loss 小；用 KL 当距离时正样本应取 $-\text{KL}$ 或 $\exp(-\text{KL}/\tau)$ ）。读代码时需以实现为准——但官方 RECAT 代码尚「Coming Soon」，暂无法核对。理解其意图即可：拉近 q_t 与高信息真题、推远低信息题。
- 作用：保证生成器造出来的题参数落在「真实题目分布」里，避免生成无法匹配的虚题。

公式 (14): 总损失

$$\mathcal{L}_{RECAT} = \mathcal{L}_{rl}(\Psi) + \mathcal{L}_{cl}(\Psi) + \mathcal{L}_{CD}(\Phi_{\nabla\theta})$$

三项：生成一致性 RL 损失 + 知识匹配对比损失（都更新生成参数 Ψ ）+ CDM 的认知诊断损失（更新考生能力参数 $\Phi_{\nabla\theta}$ ，其余冻结）。三者联合训练，让「生成器」和「能力诊断」协同优化。

五、代码实现对照

官方代码仓库的 RECAT 子目录 (<https://github.com/ChangqianWang/Intelligent-Education/tree/main/RECAT>) 当前 README 仅写「Coming Soon」, 未发现可运行的开源实现, 无法把公式逐行对到代码。

复现时可重点关注的对应关系 (供日后代码放出后核对): - 式 (5)(6) 题目生成器 $\rightarrow$ 一个输出 $\mu, \log \sigma^2$ 的 MLP + 重参数化采样, K 个并联实例; CDM 用论文采用的 **NCD** (NeuralCD)。- 式 (7) 匹配 $\rightarrow$ 对生成题向量与全库题向量算 KL/距离取 top-H (可用向量化 + topk)。- 式 (9)(10) $\rightarrow$ REINFORCE 风格, 奖励来自式 (4) 的 ω_{ij} (需先用 CDM 前向算 $\hat{r}$ 与梯度)。- 式 (13) $\rightarrow$ InfoNCE, 注意核对正负样本与分子方向 (见上文对式 (13) 的存疑)。

六、小结

方法贡献: 1. 提出 ω_{ij} (式 4) 这一直接以「逼近真实能力」为度量的统一选题准则, 把「最契合题」定义清楚, 且能当 RL 奖励。2. 用生成式选择器 (VAE 重参数 + K 个生成器) 挖隐式关系, 造出「理想题」, 再用 KL 匹配落地成真题候选——巧妙地把隐式 (学习) 与显式 (policy 准则) 串成流水线而非二选一。3. 训练拆成 ELBO 的两块: 策略梯度保「题有用」+ 对比学习保「题真实」。

实验结论: - 有效性 (RQ1, 表 2): RECAT-BECAT/MAAT 在 4 个数据集、第 5/10 步的 AUC/ACC 几乎全面登顶; 连不带任何 policy 的 RECAT-Random 都超过 BOBCAT/NCAT/GMOCAT, 说明隐式挖掘本身就强。- 高效性 (RQ3, 表 3): 选题延迟降 **1~2 个数级** (BECAT 第 10 步 ASSIST12: 1432s $\rightarrow$ 26s)。这是最亮的卖点。- 适应性 (RQ4): 加新题时性能略降但**无需整体重训**, 优于纯 learning-based。

优点: 兼得两派优势; 延迟暴降; 对新题友好 (生成器与题目 ID 解耦)。

局限 / 存疑: - 严重依赖 θ^* (全库诊断当“真值”) 的质量, 这本身是近似, 且需先有较充分的模拟/历史作答。- 对比损失式 (13) 的正样本方向疑似笔误, 需代码核对 (但代码未放出)。- 超参不少 ($K = 5, H, X, M, \tau$), 匹配步的 KL 计算在超大题库上仍有开销。- RQ4 显示移除富信息题会拖累生成质量, 说明对训练期题目覆盖度仍有依赖。