

面向高效计算机自适应测试的显式与隐式「考生一题目」关系挖掘 (Explicit and Implicit Examinee-Question Relation Exploiting for Efficient Computerized Adaptive Testing)

原文: 07940-WangC.pdf · 译者: Claude · 译于 2026-06-26 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT)、认知诊断模型 (Cognitive Diagnosis Model, CDM)、考生一题目关系 (Examinee-Question relation, E-Q relation)、题目选择算法 (question selection algorithm)、能力估计 (ability estimation)

摘要

计算机自适应测试 (CAT) 是计算机辅助教育中的一项关键任务, 其目标是自适应地挑选合适的题目, 以诊断考生的能力状态。现有的 CAT 方法通过挖掘「考生一题目」关系 (E-Q 关系) 来提升题目选择性能。这些方法要么仅利用显式 E-Q 关系: 例如基于策略 (policy-based) 的方法根据预先设定的准则来决定题目选择, 它们对题库变化适应性好, 但在搜索合适题目时往往带来巨大的计算开销; 要么仅关注隐式 E-Q 关系: 例如基于学习 (learning-based) 的方法通过从大规模数据中学习来训练智能体 (agent) 以高效选题, 但它们在面对新加入题库的题目时往往力不从心。此外, 现有的大多数选题器都基于贪心策略, 可能会忽略掉有潜力的题目。

为了弥合上述两类方法, 我们提出了一个名为 **基于关系挖掘的 CAT (Relation Exploiting-based CAT, RECAT)** 的新框架, 同时探索并利用隐式与显式的「考生一题目」关系。具体而言, 我们首先定义了一个面向考生真实能力的选择目标, 以选取更合适的题目。接着, 为学习隐式 E-Q 关系, 我们设计了一个**题目选择器 (question selector)**, 它从两个方面——生成一致性 (generation consistency) 与知识匹配 (knowledge matching) ——出发, 探索考生能力并为特定考生能力生成最契合的题目。前者旨在最大化隐式 E-Q 关系学习过程的似然估计, 后者用于拟合真实题目的分布。为充分利用显式 E-Q 关系, 我们借助隐式 E-Q 关系为给定考生能力生成一个高质量的候选题集, 从而精简搜索过程、降低选题延迟。我们通过在真实数据集上的全面实验, 验证了该框架的有效性 & 高效性。

引言

随着计算机辅助教育的快速发展, 计算机自适应测试 (CAT) 已被广泛应用于现实场景, 如教育测量、心理评估和人才招聘等。CAT 通常由两部分组成: 认知诊断模型 (CDM) 和题目选择算法, 二者交替运行直至满足终止条件。如图 1 所示, 在第 t 步, CDM 根据考生前 $t - 1$ 步的作答记录估计其能力; 随后, 题目选择算法在诊断结果的指导下, 为考生在第 t 步挑选一道合适的题目。

图 1: CAT 示意图。CDM 根据 Bob 前 t 步的作答记录诊断其能力, 选择算法随后在第 $t + 1$ 步根据诊断结果为 Bob 选取一道合适的题目。

题目选择方法作为 CAT 系统的核心组件, 因其自适应、个性化的特性而被广泛研究。大量工作致力于理解「考生一题目」关系 (E-Q 关系)。通过分析所选题目的作答标签, 可以评估该题目对考生能力诊断所贡献的诊断价值。一些研究利用这种**显式 E-Q 关系**来建立先验的选择准则, 称为**基于策略 (policy-based) 的方法**。例如, MAAT 和 BECAT 分别将一道题目对考生的影响转化为模型期望, 并寻找一个能逼近完整题库梯度的题目子集。这类基于策略的方法具有理论基础和可解释性, 并对不断变动 (不断加入新题) 的题库表现出良好的适应性。

与此同时, 另一些研究探索了蕴含在过往「考生一题目」交互中的**隐式 E-Q 关系**, 利用这些信息训练选择器以实现自适应选题, 称为**基于学习 (learning-based) 的方法**。这一类的代表是将 CAT 问题转化为一个**双层优化 (bilevel optimization) 问题**。在这种框架下, 外层优化问题负责学习一个数据驱动的选择方法, 用以在内层优化问题中优化考生的能力。这种耦合的学习过程充分挖掘了隐式 E-Q 关系, 尤其是在 NCAT 中考虑了真实场景中存在的猜测 (guessing) 和失误 (slipping)。此外, 这些基于学习的方法选题延迟更低。

然而, 先验选择准则迫使基于策略的方法在每个测试步骤都要遍历几乎整个题库, 才能充分利用显式 E-Q 关系, 这导致了高昂的计算成本和漫长的选题延迟。利用隐式 E-Q 关系的基于学习的选择器可以解决这些缺陷, 但它们对动态变动的题库适应性差——当有新题加入题库时, 往往需要重新训练整个模型, 而这一重训练过程会带来额外成本, 恰恰是基于策略的方法所擅长规避的。因此, 一种最优策略是**整合两类方法的优势, 充分挖掘显式与隐式 E-Q 关系**。然而实现这种整合颇具挑战, 因为现有基于学习的方法依赖于 Q 值 (Q-values), 与基于策略的方法不兼容。这一鸿沟使得选择器无法同时充分利用显式与隐式 E-Q 关系, 阻碍了对考生能力的挖掘。

为弥合上述方法, 我们创新性地提出了一个新框架——**基于关系挖掘的 CAT (RECAT)**, 它同时探索并利用隐式与显式的「考生一题目」关系。我们首先定义了一个**面向考生真实能力的选择目标**, 作为全局指引, 引导对隐式与显式 E-Q 关系的探索。为探索隐式 E-Q 关系, 我们设计了一个**生成式题目选择器**, 它揭示考生能力并生成最契合的题目, 从而参与到后优化 (post-optimization) 过程中。该选择器从两个角度进行优化, 即生成一致性与知识匹配: 前者指导题目生成的质量, 后者用于拟合真实题目的参数分布。为利用显式 E-Q 关系, 我们基于隐式 E-Q 关系生成一个高质量的候选题集, 从而降低选题延迟与潜在偏差。大量真实数据集实验表明, 我们提出的 RECAT 在题目选择上表现稳健, 同时显著提升了选题效率。我们的代码已开源: <https://github.com/ChangqianWang/Intelligent-Education/tree/main/RECAT>。

相关工作

本文聚焦于 CAT 的题目选择器组件。现有的题目选择方法主要分为两类：利用显式 E-Q 关系的基于策略的选择方法，以及学习隐式 E-Q 关系的基于学习的选择方法。

基于策略的选择方法

基于策略的方法通过设计基于显式 E-Q 关系的先验选择准则来探索选择结果，无需学习。长期以来，题目选择方法是与模型绑定 (model-specific) 的，即专为 IRT 或 MIRT 设计，例如最大费舍尔信息量 (maximum Fisher information)、KL 信息指数 (Kullback-Leibler information index) 及其扩展选择算法。然而，由于这些模型结构简单，无法有效捕捉潜在的 E-Q 关系，难以适配认知诊断模型 (CDM) 的发展，IRT 专用选择算法的性能也因此受限。为解决这一局限，MAAT 首次提出了一种通用的、与模型无关 (model-agnostic) 的选择算法：它为每道题目计算期望模型变化 (Expected Model Change, EMC) 作为显式 E-Q 关系，以衡量题目的信息含量，并选取 EMC 最大的题目。MAAT 可适配不同的 CDM，极大释放了选题性能。BECAT 首次为题目选择算法逼近考生真实能力提供了理论保证：考生的真实能力由其在整个题库上的诊断结果来近似。为充分利用这种显式 E-Q 关系，BECAT 将 CAT 定义为一个子集选择问题，选取的子集需使其上作答的梯度逼近全部作答的梯度。这些与模型无关的基于策略的方法通常具有理论基础，并对动态变动的题库适应性好，但在整个题库上计算会带来很高的选题延迟。

基于学习的选择方法

基于学习的方法充分利用蕴含在考生过往作答记录中的隐式 E-Q 关系，用以训练选择器，实现自适应的选择过程。为此，一系列数据驱动的可学习方法被提出。BOBCAT 首次将 CAT 问题定义为一个双层优化问题：外层优化问题旨在利用考生的估计能力来学习选择器，内层优化问题则利用外层选择器所选的题目来优化考生能力。沿着这一思路，NCAT 考虑了考生在真实场景中可能猜测或失误的事实，设计了一个基于深度神经网络的框架来捕捉隐式 E-Q 关系。GMOCAT 对隐式 E-Q 关系进行了细粒度分析，认为知识概念的多样性会使 E-Q 关系更加耦合，因此通过图结构来捕捉这些复杂的 E-Q 关系。基于学习的方法降低了选题延迟，但对新加入题库的题目适应性差，由于通常需要重训练整个模型，导致训练成本高昂。

预备知识与问题形式化

CAT 的预备知识

任务介绍。对于一个在线智能教育平台，CAT 系统负责通过持续地为考生选题，来准确揭示考生的真实能力值。CAT 系统包含两部分：(1) 题目选择算法 Π ，根据考生先前估计的能力，从题库中选取「最契合」的题目作为下一题；(2) 认知诊断模型 (CDM) $\mathcal{M}$ ，在考生作答选择算法 Π 所选题目并得到反馈后，诊断当前考生的能力。

具体而言，给定考生 s_i 及其真实能力（标量或向量） θ_i ，CAT 在每一步的过程可表示为：

$$\begin{aligned} \min \|\theta_i^t - \theta_i\|, \quad t = 1, \dots, T, \\ \theta_i^t \leftarrow \mathcal{M}(q_t, r_{iq_t} \mid \theta_i^{t-1}), \quad q_t \leftarrow \Pi(Q_i \mid \theta_i^{t-1}), \end{aligned} \quad (1)$$

其中 q_t 表示 Π 在第 $t-1$ 步基于估计能力 θ_i^{t-1} ，从题库 Q_i 中所选的题目，题库 Q_i 只包含考生 s_i 尚未作答的题目。 r_{iq_t} 是考生 s_i 在题目 q_t 上的作答结果。 θ_i^t 是考生 s_i 作答题目 q_t 后由 $\mathcal{M}$ 估计出的能力，其中 θ_i^0 通常随机初始化。注意 T 是停止测试的最大步数；另一种常见的停止准则是预先设定一个参数 ϵ ，以保证 $\|\theta_i^T - \theta_i\| \leq \epsilon$ 。

最契合的题目。为统一不同 CAT 中「最契合」问题的定义，我们提出一个新定义。具体而言，该定义采用直接度量的方式在每一步选题，即选取能最大化「考生真实能力与估计能力之间差距改善」的题目，可粗略表示为：

$$q_t = \arg \min_{q \in Q_i} \|\theta_i^t - \theta_i\|. \quad (2)$$

该定义直接以能力差距的改善作为选题度量来寻找「最契合」的题目，更多细节将在后文给出。

训练与测试阶段。在给定平台中，假设有 N 名考生和 L 道题目，分别记为 $S = \{S_{train}, S_{val}, S_{test}\} = \{s_1, s_2, \dots, s_N\}$ 与 $Q = \{q_1, q_2, \dots, q_L\}$ 。对每名考生，其作答记录记为 $R = \{R_1, \dots, R_N\}$ ，其中 $R_i = \{(s_i, q_j, r_{ij}) \mid q_j \in Q - Q_i\}$ 是考生 s_i 的记录集合。这里 $r_{ij} = 1$ 表示考生 s_i 正确作答题目 q_j ， $r_{ij} = 0$ 则相反。CAT 过程通常有两个阶段：**训练阶段**——若需要，基于 S_{train} 中考生的作答记录训练题目选择算法；**测试阶段**——对 S_{test} 中的新考生进行测试。

考生的真实能力。我们沿用先前工作 BECAT 的做法，认为考生的真实能力 θ_i 可由其在完整题库上的诊断结果 θ_i^* 来近似，形式化为：

$$\theta_i \approx \theta_i^* = \arg \min_{\theta \in \Theta} \sum_{q_j \in E-Q_i} \mathcal{L}(r_{ij}, \mathcal{M}(q_j | \theta)). \quad (3)$$

$\mathcal{L}(r_{ij}, \mathcal{M}(q_j | \theta))$ 是真实作答 r_{ij} 与能力 θ 下对 q_j 的预测作答之间的损失， Θ 表示 θ 的搜索空间。在训练 CAT 之前，我们基于题库为考生生成模拟作答日志。当作答数量足够多时，考生的诊断能力逼近其真实能力，记为 $\theta = \{\theta_1, \dots, \theta_N\} \approx \{\theta_1^*, \dots, \theta_N^*\}$ 。此外，还可获得另一组重要参数，即与题目相关的参数 $Q^\omega = \{q_1^\omega, \dots, q_M^\omega\}$ ，其中每个 $q_j^\omega \in Q^\omega$ 是长度为嵌入维度 d 的向量。为便于阅读，后续章节中 q_j 既代表第 j 道题目，也代表该题目的 $1 \times d$ 向量表示，具体含义视上下文而定。

方法

最契合题目的定义

首先需要明确 RECAT 中「最契合」题目的定义。在第 t 步为考生 s_i 选题的过程可表示为条件概率 $p(q_t | \theta_i^{t-1})$ 。由于该条件概率无法直接获得，现有 CAT 方法采用间接方式来优化考生真实能力与估计能力之间的差距。

与之不同，本文直接以考生真实能力与估计能力之间的差距作为每一步的选题准则。RECAT 中第 t 步为考生 s_i 选取「最契合」题目的定义为：

$$q_t = \arg \min_{q_j \in Q_i} \underbrace{\left\| \theta_i^* - \theta_i^{t-1} + \alpha \nabla_{\theta_i^{t-1}} \mathcal{L}(r_{ij}, \mathcal{M}(q_j | \theta_i^{t-1})) \right\|}_{\text{记为 } \omega_{ij}}, \quad (4)$$

其中 θ_i^* 是真实能力 θ_i 的近似， α 是学习率， $\mathcal{L}(\cdot)$ 表示交叉熵损失， $\mathcal{M}(q_j | \theta_i^{t-1})$ 表示考生 s_i 在能力 θ_i^{t-1} 下对题目 q_j 的预测作答 $\hat{r}_{ij}$ 。在此定义中，前一项旨在选取使考生真实能力与估计能力差距最小的题目，后一项用于选取考生更容易答对的题目。

伪反馈 (Pseudo Feedback)。注意，如式 (4) 所示，考生 s_i 在题库 Q_i 上并没有真实的作答标签。因此，有必要为 Q_i 中的题目建立相应的伪真实作答标签。为此，我们沿用如下假设：考生正确作答一道生成题目的概率，小于等于该考生正确作答其已完成题目中（按题目分布）与之最相似的真实题目的概率。这样的真实题目 q_j^* 可由 $q_j^* = \arg \min_{q_{in} \in R_i} \text{KL}(q_{in} \| gq_j^t)$ 获得，其中 gq_j^t 表示第 t 步生成的第 j 道题目。

题目生成模块 (Question Generation Module)

基于上述「最契合」题目的定义，RECAT 的目标是在每一步生成 ω_{ij} 最小的题目。为此，我们将前述求解条件概率的问题视为一个生成后验分布的过程：给定考生的先验能力，为该能力值生成 ω_{ij} 最小的题目，此时条件概率可重写为 $p(q_t | \theta_i^{t-1}, \theta_i^*)$ 。

为生成 q_t ，我们将其编码为一个潜变量 (latent variable)，作为更新考生能力状态的隐式表示。给定 d 个知识概念，题目 q_j 与考生 s_i 的表示可由两个 $1 \times d$ 向量表示，其第 k 位分别记为 $q_j(k)$ 与 $s_i(k)$ ，分别表示题目在第 k 个知识概念上的难度与考生在第 k 个知识概念上的掌握水平。基于此，我们设计了一个面向认知诊断 (CD-specific) 的题目生成器来生成题目。

具体而言，将考生当前估计的能力 θ_i^{t-1} 输入生成器 $G(\cdot)$ ，逐维度分析以生成合适的题目参数 $gq_t \in \mathbb{R}^{1 \times d}$ 来表示所生成的题目 gq_t ，其第 k 位 $gq_t(k)$ 表示生成题目在第 k 个知识概念上的难度。生成「最契合」题目分布的过程形式化如下：

$$\begin{aligned} [\mu_t, \log(\sigma_t^2)] &= G(\theta_i^{t-1}), \\ gq_t &= \mu_t + \epsilon \odot \sigma_t, \quad \epsilon \sim \mathcal{N}(0, 1), \end{aligned} \quad (5)$$

其中生成器 $G(\cdot)$ 由多个全连接层组成， $\mu_t \in \mathbb{R}^{1 \times d}$ 与 $\sigma_t \in \mathbb{R}^{1 \times d}$ 表示为每个（对应知识概念的）维度生成的难度分布， gq_t 是第 t 步为 θ_i^{t-1} 生成的题目。

考虑到考生能力的多样性并增强选题过程的鲁棒性，我们采用 K 个持有不同权重的生成器来生成多个分布，进而生成多道 (K 道) 题目，从而能从不同维度诊断考生能力：

$$Q_i^{Kt} = \{gq_j^t | gq_j^t \sim \mathcal{N}(\mu_j^t, \sigma_j^t) = G_j(\theta_i^{t-1}), j = 1, \dots, K\}, \quad (6)$$

其中 $G_j(\cdot)$ 是第 j 个生成器， gq_j^t 是第 t 步生成的第 j 道题目， Q_i^{Kt} 是 K 道生成题目的集合。

题目匹配模块 (Question Matching Module)

为更好地利用显式 E-Q 关系, 在为考生 s_i 获得 Q_i^{Kt} 中的 K 道生成题目后, 我们需要将每道生成题目与题库中 top- H 个相似的真实题目进行匹配, 匹配过程可表示为:

$$MQ_j^* = \arg \text{top-}H \min_{q_{in} \in Q_i} \text{KL}(q_{in} \parallel gq_j^t), \quad (7)$$

其中 MQ_j^* 包含针对生成题目 gq_j^t 的 H 道题目。于是, 可获得 $K \times H$ 道真实题目 $MQ^* = \{MQ_1^*, \dots, MQ_K^*\}$, 进而基于策略的方法便可被纳入 RECAT, 通过 $q_t = \arg \max_{q \in MQ^*} I(q \mid \theta_i^{t-1})$ 来选题。该选择过程不再遍历整个题库, 而只遍历候选集, 极大地降低了选题延迟。

这些基于策略的选题策略在遍历整个题库的同时涉及 CDM 的训练 (假设其时间复杂度为 A), 总时间复杂度为 $O(A|E|)$ 。所提出的 RECAT 缩小了这些组合选择策略的选题范围, 且其网络结构相对简单 (假设计算时间复杂度为 B), 总时间复杂度为 $O(A \times B \times K \times H) \ll O(A \times |E|)$ 。

优化细节

给定第 $t-1$ 步考生的估计能力 θ_i^{t-1} 及题目生成准则, 我们的目标是增强题目生成器根据不同考生能力生成多样化「最契合」题目的能力。虽然我们可以评估所生成题目的质量, 但这种度量发生在 CDM 训练之后, 使得有效优化题目选择器变得困难。为解决此问题, 我们优化生成目标 $p(q_t \mid \theta_i^{t-1}, \theta_i^*)$ 。我们从全局优化的视角看待 q_t : 它是在 $p(\theta_i^* \mid \theta_i^{t-1})$ 过程中产生的、推动考生状态 θ_i^{t-1} 向真实能力 θ_i^* 靠拢的驱动力。因此, 我们最大化似然 $p(\theta_i^* \mid \theta_i^{t-1})$, 它代表了对所有可能的 q_t 进行边缘化 (marginalization) 的结果。最大化似然概率鼓励生成「最契合」的题目, 可作为优化目标:

$$\begin{aligned} \log p_\psi(\theta_i^* \mid \theta_i^{t-1}) &= \int_{q_t} p_\psi(\theta_i^*, q_t \mid \theta_i^{t-1}) dq_t \\ &\geq \underbrace{\mathbb{E}_{c_\Psi(q_t \mid \theta_i^*, \theta_i^{t-1})} [\log p_\psi(\theta_i^* \mid q_t, \theta_i^{t-1})]}_{\text{生成一致性 (Generation Consistency)}} - \underbrace{\text{KL}(c_\Psi(q_t \mid \theta_i^*, \theta_i^{t-1}) \parallel p_\psi(q_t \mid \theta_i^{t-1}))}_{\text{知识匹配 (Knowledge Matching)}}, \end{aligned} \quad (8)$$

其中 $c_\Psi(q_t \mid \theta_i^*, \theta_i^{t-1})$ 表示一个近似分布, 用以解决 $p(q_t \mid \theta_i^*, \theta_i^{t-1})$ 的不可解性 (intractability), 它被用于最大化不等式右侧的证据下界 (ELBO)。因此, 我们将基于 CAT 任务优化两个目标, 即生成一致性与知识匹配。

生成一致性 (Generation Consistency)。通过随机梯度下降 (SGD) 优化题目生成器是一个后验事件, 这意味着只有在用 CDM 更新考生能力之后才能评估生成器的能力。这并非易事, 因为 ω_{ij} 无法同时用于更新 CDM 和题目生成器。为应对这一挑战, 我们引入基于策略梯度 (policy gradient) 的强化学习来最大化对数似然、增强生成能力:

$$\begin{aligned} \nabla_\Psi \mathcal{L}_{rl} &= \nabla_\Psi \sum_{s_i \in S} \mathbb{E}_{gq_j^t \sim Q_i^{Kt}} [\nabla_\Phi \mathcal{M}(gq_j^t, \theta_i^{t-1})] \\ &= \sum_{s_i \in S} \mathbb{E}_{gq_j^t \sim Q_i^{Kt}} [\nabla_\Phi \mathcal{M}(gq_j^t, \theta_i^{t-1})] \nabla_\Psi P(gq_j^t \mid \theta_i^{t-1}), \end{aligned} \quad (9)$$

其中 ω_{ij} 由 CDM 在诊断每道题目后产生, 用于衡量所生成题目的质量。在优化过程中, 智能体 (即 K 个生成器) 遵循策略 $P(gq_j^t \mid \theta_i^{t-1})$, 为每名考生生成题目 $gq_j^t \in Q_i^{Kt}$ 以提供丰富的诊断价值。对每个动作 (θ_i^{t-1}, gq_j^t) , 环境 (即 CDM) 计算每道题目使考生能力状态朝真实能力 θ_i^* 更新的幅度, 并计算 ω_{ij} , 将预测概率作为奖励返回以指导优化方向。为最大化对数似然, 我们将策略 $P(gq_j^t \mid \theta_i^{t-1})$ 定义为:

$$P(gq_j^t \mid \theta_i^{t-1}) = 1 - \frac{\exp(\omega_{ij})}{\sum_{gq_{j'}^t \in Q_i^{Kt}} \exp(\omega_{ij'})}. \quad (10)$$

ω_{ij} 越小, 所生成的诊断价值越丰富, 从而鼓励生成器产出高质量的题目。

知识匹配 (Knowledge Matching)。为使生成题目的参数分布与真实题目的参数分布对齐, 我们提出使用 KL 散度。鉴于题库的庞大与多样, 仅依赖最相近的真实题目参数进行拟合可能引入偏差。为解决此问题, 我们建议从考生历史作答记录 R_i 中选取题目来扩充用于拟合的候选题集, 然后用对比学习 (contrastive learning) 优化生成题目的分布以减少偏差。然而, 由于单个考生的作答记录有限, 题目数量不足可能无法构成有效的候选题集。受相关工作启发, 我们提出基于相似真实能力来扩充考生 s_i 的作答集: 我们合并与 θ_i^* 表示最相似的 top- X 名考生的作答日志, 形成共享作答日志 R'_i 。然后从 R'_i 中选取与生成题目 q_t 具有最小 KL 散度的 top- M 道题目, 并将对应的作答标签加入候选题集 C_i^t :

$$C_i^t = \arg \min_{\text{top-}M} \left\{ \left(\text{KL}_{(q_l, r_{il}) \in R'_i} (q_l \| q_t), r_{il} \right) \right\}. \quad (11)$$

随后，我们利用候选集 C_i^t 中的题目及对应的真实作答标签来更新考生能力 θ_i^{t-1} ，得到题目评估：

$$W_i^t = \left\{ \underbrace{\|\theta_i^* - \theta_i^{t-1} + \alpha \nabla \mathcal{L}(r_{ij}, \mathcal{M}(q_j, \theta_i^{t-1}))\|}_{=\omega_{ij}} \right\}_{q_j \in C_i^t}, \quad (12)$$

其中 ω_{ij} 越小，表示真实题目 q_j 能为 θ_i^{t-1} 提供越多的诊断价值。接着，我们引入对比学习来更好地优化生成题目的参数：我们将 ω_{ij} 最小的题目参数视为正样本 q^+ ，其余 $M-1$ 道题目的参数视为负样本集 $\{q^-\}_{m=1}^{M-1}$ 。我们希望生成题目 q_t 更接近正样本：

$$\mathcal{L}_{cl} = -\log \frac{\exp(\text{KL}(q^+ \| q_t)/\tau)}{\exp(\text{KL}(q^+ \| q_t)/\tau) + \sum_m^{M-1} \exp(\text{KL}(q_m^- \| q_t)/\tau)}. \quad (13)$$

由于考生能力通过 CDM 诊断，我们使用如下损失函数来更新整个框架：

$$\mathcal{L}_{RECAT} = \mathcal{L}_{rl}(\Psi) + \mathcal{L}_{cl}(\Psi) + \mathcal{L}_{CD}(\Phi_{\nabla\theta}), \quad (14)$$

其中 Ψ 表示生成过程的训练参数， $\Phi_{\nabla\theta}$ 表示认知诊断模型中考生的参数，其余所有参数均冻结。

实验

本节我们在四个真实数据集上进行实验，以验证 RECAT 的有效性与高效性。我们关注以下研究问题：(RQ1) 在预测任务中，RECAT 能否超越仅利用显式或隐式关系所达到的性能？(RQ2) RECAT 在能力估计的模拟场景中表现如何？(RQ3) 基于 RECAT 的方法能否降低基于策略方法的延迟？(RQ4) RECAT 对新题目的适应性如何？

数据集

描述。我们在四个真实数据集上进行实验，分别是 ASSIST09、ASSIST12、Nips-EDU 和 Math。ASSIST09 和 ASSIST12 是来自在线辅导系统 ASSISTments 的公开数据集。NIPS-EDU 是 NeurIPS 2020 教育挑战赛提供的数据集，采集自教育平台 Eedi。Math 是某知名在线学习平台编纂的专有数据集，包含中小学考生的数学练习与考试记录。我们遵循先前工作的预处理流程，预处理后四个数据集的统计信息汇总于表 1。

表 1：数据集统计信息。

统计项	ASSIST09	ASSIST12	NIPS-EDU	MATH
# 考生	1,473	3,823	4,918	6,618
# 题目	903	2,337	900	326
# 知识概念	22	89	85	56
# 作答日志	58,427	444,723	1,160,925	245,155
# 人均作答数	39	116	236	37

评价指标。我们在两项 CAT 任务上评估 RECAT 的有效性与高效性：(1) 考生分数预测，用 AUC 和 ACC 评价；(2) 能力估计模拟，用 MSE 衡量。

基线方法。我们将 RECAT 与 CAT 中的两类方法对比，包括基于策略的方法 (Random、MAAT、BECAT) 和基于学习的方法 (BOBCAT、NCAT、GMOCAT)。我们用 RECAT-X 表示使用 X 方法来利用显式 E-Q 关系。RECAT 与现有基于策略的方法兼容：它通过探索隐式关系为这些依赖显式关系的方法提供候选集，从而提升原始基于策略方法的有效性与高效性。为保证公平比较，我们采用基于神经网络的认知诊断模型 NCD 作为能力评估模型。

参数设置。训练过程中，我们用 Xavier 初始化 CDM 的全部参数，使用 Adam 优化器，固定批大小为 256。我们将考生与题目的潜在特征维度都设为知识概念数量。测试过程中，设最大测试长度 $T = 10$ ，题目生成器数量设为 $N = 5$ ，并设 $k = 1$ ，即每道生成题目对应 KL 散度最小的真实题目数量为 1。所有对比方法均遵循其原文设置。RECAT 用 PyTorch 实现，所有实验在一块 NVIDIA RTX4090 GPU 上进行。

考生表现预测 (RQ1)

为验证所提框架的有效性，我们将现有基于策略的方法与 RECAT 结合，并将选题步数设为 5 和 10。表 2 展示了 RECAT-based 与基于策略、基于学习方法的对比结果。同时利用显式与隐式 E-Q 关系的 RECAT-based 方法，在四个数据集的 ACC 和 AUC 上均优于所有基线。此外可观察到：(1) 相比仅依赖显式 E-Q 关系的基于策略方法，RECAT-based 方法通过探索隐式 E-Q 关系提升了它们的选择性能。具体而言，在 NIPS-EDU 上，原始 MAAT 从第 5 步到第 10 步对考生能力表现出负优化，这可能是由于贪心策略导致陷入局部最优；相比之下，BECAT-MAAT 显著提升了选题质量，因为额外的隐式 E-Q 关系增强了选择过程的鲁棒性。(2) 相比仅利用隐式 E-Q 关系的基于学习方法，未利用任何显式关系的 RECAT-Random 展示了我们隐式 E-Q 关系挖掘方法的有效性，证明其优于现有基于学习的方法。

表 2：四个数据集上「考生表现预测」任务的 AUC 与 ACC 性能（每格为 AUC/ACC，分别在第 5、10 步）。最优结果加粗，次优结果加下划线。

类别	方法	Assist09 (5)	Assist09 (10)	NIPS- EDU (5)	NIPS- EDU (10)	Assist12 (5)	Assist12 (10)	Math (5)	Math (10)
策略	Random	0.6394/0.6014	0.6480/0.6037	0.6267	0.6703	0.6305	0.6452	0.7030	0.6488
策略	MAAT	0.6431/0.6129	0.6517/0.6170	0.6988/0.6349	0.7226/0.6329	0.6549/0.7120	0.6563/0.7137	0.7262/0.6633	0.7425/0.6800
策略	BECAT	0.6425/0.6141	0.6522/0.6191	0.7011/0.6404	0.7288/0.6491	0.6589/0.7133	0.6611/0.7172	0.7189/0.6601	0.7432/0.6822
学习	BOBCAT	0.6419/0.6136	0.6513/0.6213	0.7016/0.6395	0.7268/0.6513	0.6553/0.7125	0.6680/0.7197	0.7211/0.6649	0.7453/0.6864
学习	NCAT	0.6423/0.6184	0.6526/0.6263	0.7053/0.6421	0.7298/0.6533	0.6565/0.7134	0.6653/0.7204	0.7245/0.6673	0.7467/0.6856
学习	GMOCAT	0.6443/0.6225	0.6525/0.6283	0.7082/0.6478	0.7314/0.6546	0.6633/0.7144	0.6741/0.7188	0.7278/0.6704	0.7524/0.6933
RECAT	Random	0.6428/0.6215	0.6525/0.6322	0.7112/0.6498	0.7356/0.6615	0.6706/0.7138	0.6801/0.7211	0.7339/0.6728	0.7514/0.6923
RECAT	MAAT	0.6485/0.6249	0.6530/0.6348	0.7131/0.6525	0.7400/0.6663	0.6711/0.7170	0.6805/0.7222	0.7345/0.6737	0.7562/0.6945
RECAT	BECAT	0.6436/0.6222	0.6564/0.6307	0.7197/0.6542	0.7423/0.6632	0.6709/0.7161	0.6815/0.7213	0.7356/0.6738	0.7574/0.6956

能力估计模拟 (RQ2)

为验证 RECAT 在考生能力估计上的表现，我们在 ASSIST12 和 NIPS-EDU 数据集上进行模拟能力估计实验，用 MSE 衡量题目选择器对考生能力估计的影响。如图 3 所示，原始 MAAT 随测试步数增加，估计误差呈现不稳定的下降，这种不稳定可能源于贪心策略使其陷入局部最优，从而不利于后续选题。相比之下，RECAT-based 方法始终取得最低的估计误差。这归功于 RECAT 以考生真实能力为导向挖掘隐式关系，帮助选择器更好地学习这种隐式关系——即以低估估计误差作为学习目标，增强了选择器准确理解和预测考生能力的的能力。

图 3：能力估计模拟的 MSE。

选题延迟对比 (RQ3)

为验证 RECAT 的高效性，如表 3 所示，我们在 ASSIST12 和 NIPS-EDU 数据集上对比 RECAT-based 方法与原始基于策略方法的选题延迟。首先，BECAT 在子集选择时需要用已选题目计算整个题库，导致选题延迟随测试步数单调增加；相比之下，RECAT-BECAT 利用隐式 E-Q 关系缩小搜索空间，无需穷举计算便降低了计算成本和选题延迟。其次，随着题库规模增大，原始 MAAT 和 BECAT 在 ASSIST12 上的选题延迟明显高于 NIPS-EDU，而 RECAT-based 方法的计算成本保持相近。这是因为在选题中利用隐式关系相比梯度更新显著降低了计算复杂度，使得 RECAT-based 方法的选题延迟大幅下降。

表 3：选题延迟对比（单位：秒，格式为「原始方法 / RECAT 方法」）。

数据集	步数	方法	延迟 (s)
NIPS-EDU	5	MAAT / RECAT-MAAT	14.63 / 0.12
NIPS-EDU	5	BECAT / RECAT-BECAT	47.56 / 1.82
NIPS-EDU	10	MAAT / RECAT-MAAT	28.04 / 0.21
NIPS-EDU	10	BECAT / RECAT-BECAT	239.63 / 8.41
ASSIST12	5	MAAT / RECAT-MAAT	49.04 / 0.49
ASSIST12	5	BECAT / RECAT-BECAT	137.32 / 5.72
ASSIST12	10	MAAT / RECAT-MAAT	94.82 / 0.81
ASSIST12	10	BECAT / RECAT-BECAT	1432.15 / 26.15

对新题目的适应性 (RQ4)

为验证 RECAT 对持续变动题库的适应性,我们在训练过程中从 NIPS-EDU 题库中随机移除 $\{25, 50, 75, 100\}$ 道题目及其对应作答记录。在测试阶段,尽管保留了预训练参数,这些题目对选择器而言完全陌生。如图 4 所示,RECAT-MAAT 的实验表明,随着加入更多(新)题目,选择性能有所下降。这种下降可归因于训练时某些被移除的题目可能具有更丰富的诊断价值,这对指导隐式 E-Q 关系影响题目生成的「知识匹配」过程尤为有利;因此,生成题目参数的偏差导致候选集质量下降。然而,与其他仅依赖隐式 E-Q 关系的基于学习方法不同,我们的 RECAT 无需重训练整个模型,从而在应对新题目时节省了训练成本。

图 4: 对新题目的适应性。

结论

在本工作中,我们尝试为 CAT 同时挖掘显式与隐式的「考生-题目」(E-Q) 关系。我们提出了一个新颖且通用的框架 RECAT (基于关系挖掘的 CAT),它在考生真实能力的引导下更深入地挖掘隐式 E-Q 关系,并生成高质量候选集供显式 E-Q 关系利用。真实数据集上的实验结果证明了为 CAT 选题同时挖掘两类关系的有效性与高效性。我们计划进一步研究针对 CAT 任务特性、对两类关系进行探索的方法。

致谢与参考文献 (*References*) 按约定未翻译,详见原文。