

FACD: 面向 CAT 的快速自适应认知诊断框架 精读笔记

原文: 6447.pdf(A Fast-Adaptive Cognitive Diagnosis Framework for Computerized Adaptive Testing Systems, IJCAI 2025) 代码: <https://github.com/BW297/FACD> (已 clone 到本目录 FACD/) 笔记于 2026-06-27

一、解决什么问题

1.1 背景: CAT 是什么, CDM 在里面扮演什么角色

计算机自适应测试 (CAT, 比如 GRE、GMAT 的自适应版本) 的核心思想是: **不要让所有学生做同一套题**, 而是一边考一边根据学生的作答动态地选下一道题, 用尽量少的题 (比如 10–20 题) 就把学生的真实能力测准。

一个 CAT 系统循环地交替两件事:

1. **认知诊断模型 (CDM)**: 根据学生已经做过的题和对错, 估计他当前的能力 / 知识掌握水平 $\hat{Mas}$ 。
2. **选择策略 (selection strategy)**: 根据当前的能力估计, 挑一道“信息量最大”的题给学生做。

所以一轮是: 选题 $\rightarrow$ 学生作答 $\rightarrow$ CDM 更新能力估计 $\rightarrow$ 再选题.....如此重复 T 步。

1.2 痛点: 早期阶段 CDM 诊断不准, 拖垮整个 CAT

学界的现状是: **绝大多数论文在卷“选择策略”** (MAAT、BOBCAT、NCAT、BECAT 等), 它们都默认 CDM 的诊断是准的。但这个假设在 CAT 早期根本不成立:

- 学生才做了 3–5 道题, 数据极度稀疏。
- 传统 IRT 太简单 (每个学生就一个能力参数), 适应慢, 提升缓慢。
- 神经网络的 NCD 表达力强, 但吃数据, 早期数据不够, 表现反而很差。

论文的图 1 就是动机图: 用 BECAT 选题, 在 EDMCup2023 上看 IRT 和 NCD 每一步的准确率——两者在前几步都“爬”得很慢。而 CDM 一旦在早期估错了能力, 就会**误导选择策略选错题**, 进而让整个 CAT 流程都慢下来。这是一个恶性循环。

1.3 本文的主张

既然大家都在优化选择策略、却没人专门为 CAT 设计 CDM, 那本文就反过来做一个“**专为 CAT 早期快速适应而生**”的 CDM 框架 FACD。它不是一个全新的交互函数, 而是一个可以**套在 IRT / NCD 等已有 CDM 外面**的表示增强框架: 用两个动态模块快速、稳健地把学生表示估准, 再喂给原来的交互函数。早期阶段相比原始 CDM 能提升约 5%–10%。

二、问题定义 (输入 / 输出)

2.1 符号

- 学生集 $S = \{s_1, \dots, s_N\}$, 题目集 $E = \{e_1, \dots, e_M\}$, 概念集 $C = \{c_1, \dots, c_K\}$ 。
- **Q 矩阵** $Q \in \{0, 1\}^{M \times K}$: $Q_{ij} = 1$ 表示第 i 题考了第 j 个概念。
- 作答日志三元组 (s, e, r) : $r = 1$ 答对, $r = 0$ 答错。
- 诊断目标 $Mas \in \mathbb{R}^{N \times K}$: 每个学生对每个概念的掌握程度。

2.2 CAT 里的动态过程

对学生 i , 在时间步 t : - 他已经答过的序列 $R_{t-1,i} = \{(e_1, r_1), \dots, (e_{t-1}, r_{t-1})\}$ 。- CDM 估计 $\hat{Mas}_{t-1,i} = \mathcal{M}(R_{t-1,i})$ 。- 选择策略 π 选出下一题 $e_{t,i} \sim \pi(\hat{Mas}_{t-1,i})$ 。- 学生作答 $r_{t,i} \rightarrow$ CDM 更新 $\rightarrow \hat{Mas}_{t,i}$ 。

目标: 用尽量小的 T , 让 $\hat{Mas}_{T,i}$ 逼近真实 Mas_i^* 。

2.3 输入 / 输出，配个小例子

因为真实 Mas^* 看不见，论文实际优化的代理目标是预测学生在测评题集上的作答对错，用 AUC 衡量。

小例子。假设系统有学生 s_3 ，知识概念有 8 个 (FrcSub 数据集)。第 5 步时， s_3 已经做了 5 道题： $R_{4,s_3} = \{(e_{12}, 1), (e_3, 0), (e_{19}, 1), (e_7, 1), (e_2, 0)\}$ (做对了 12、19、7 号题，做错了 3、2 号题)。

- 输入：这 5 个 (题, 对错) 对 + Q 矩阵 + 全体学生的作答图。
- 输出： s_3 对每个概念的掌握向量 $\hat{Mas}_{5,s_3} \in [0, 1]^8$ ，例如 $[0.8, 0.3, 0.7, \dots]$ ；以及由此预测他在某道没做过的题 e_{30} 上答对的概率 $\hat{y} = 0.72$ 。
- 评价：把 $\hat{y}$ 和测评集里真实对错比，算 AUC。越早把 AUC 顶上去越好。

三、模型结构 (FACD 整体)

FACD 把“为学生 / 题目 / 概念学一个好表示”拆成三路信息，最后融合：

```

|-- (0) 初始 ID 嵌入    Z^(0)    <- 每个实体一个可学习向量
学生/题/概念  |-- (1) 动态协同表示  Z^(1)    <- 模块 A: 动态响应图 + 轻量 GCN
                |-- (2) 动态个性化表示 Z^(2)    <- 模块 B: GRU + 自注意力 (仅学生)
                |
                加权融合(alpha) -> H -> 套进 IRT/NCD 交互函数 -> 预测对错 y_hat

```

直觉上：- 模块 A (协同) 解决“早期没数据”——靠图把“和你做题表现相似的其他学生”的信息借过来，快速给你画个像 (协同过滤的味道)。这是早期性能的主要来源。- 模块 B (个性化) 解决“鲁棒性 / 后期稳定”——把你自己这条作答序列当成时间序列，用 GRU + 自注意力抓出关键作答，避免被个别噪声题带偏。这是后期稳定的主要来源。- 融合 + 交互函数：三路表示自适应加权，再接上原本 CDM (IRT 或 NCD) 的打分公式，所以 FACD 是“即插即用”的框架。

下面逐模块讲。

四、关键公式详解 (核心)

公式 (1)(2)：动态响应图的邻接矩阵

模块 A 先建一张图 $G_t = (V, E_t)$ ，节点 $V = S \cup E \cup C$ (学生 + 题 + 概念全在一张图上，节点固定不变)。边分两类：

- 学生-题目子图 (动态)： $A_t^{se} \in \mathbb{R}^{|S| \times |E|}$ ， $x_{ij} = 1$ 当且仅当学生 s_i 已经做过题 e_j (公式 1)。随 CAT 进行不断加边——每选一道新题、学生一作答，就往图里添一条边。
- 题目-概念子图 (静态)：直接就是 Q 矩阵， $A^{ec} = Q$ 。

然后拼成一个大邻接矩阵 (公式 2)：

$$A_t = \begin{pmatrix} O & A_t^{se} & O \\ A_t^{se\top} & O & A^{ec} \\ O & A^{ec\top} & O \end{pmatrix}$$

这是一个对称的三分块结构：学生只和题相连，题只和概念相连，学生和概念不直接连 (要经过题中转)。

举例。 $|S| = 3, |E| = 4, |C| = 2$ 。学生 s_1 做过 e_1, e_3 ，那么 A_t^{se} 的第 1 行是 $[1, 0, 1, 0]$ 。若 e_1 考概念 c_1 、 e_3 考 c_2 ，则 A^{ec} 中 e_1 行是 $[1, 0]$ 、 e_3 行是 $[0, 1]$ 。整张 A_t 是 $(3 + 4 + 2) = 9$ 维的方阵。CAT 走到下一步、 s_1 又做了 e_2 ，就把 A_t^{se} 第 1 行第 2 列从 0 改成 1——图在长大，这就是“动态”。

作用：把稀疏的作答日志组织成图，为下一步“用邻居信息补全自己”做准备。

公式 (3): 轻量图卷积 (LightGCN 式)

给学生/题/概念各一套可学习初始嵌入, 堆成 $Z^{(0)} \in \mathbb{R}^{(|S|+|E|+|C|) \times d}$ 。借鉴 **LightGCN**, 去掉了普通 GCN 里的线性变换 W 和非线性激活, 只保留最朴素的邻居平均:

$$Z_t^{(1,l)} = \left(D^{-\frac{1}{2}} A_t D^{-\frac{1}{2}} \right) Z_t^{(1,l-1)}$$

- D 是度矩阵 (对角), D_{ii} = 节点 i 的邻居数; $D^{-\frac{1}{2}} A_t D^{-\frac{1}{2}}$ 是对称归一化的邻接矩阵, 防止度大的节点数值爆炸。
- 每过一层, 每个节点的表示就被它邻居的表示“平均”一次。
- 最后把第 0 到 L 层的结果做均值池化: $\tilde{Z}_t^{(1)} = \frac{1}{1+L} \sum_{l=0}^L Z_t^{(1,l)}$ 。

举例 (一层卷积手算)。设 $d = 1$ (嵌入就是个标量, 方便算)。学生 s_1 做过 e_1, e_3 , 初始嵌入 $z_{s_1} = 0$ 。题 e_1, e_3 的初始嵌入分别是 0.6, 0.8。 s_1 度数为 2。对称归一化下, s_1 从 e_1 收到的权重约 $\frac{1}{\sqrt{d_{s_1}} \sqrt{d_{e_1}}}$ 。粗略地, 若只看均匀平均, 卷积一层后 s_1 的新表示 $\approx \frac{0.6+0.8}{2} = 0.7$ 。含义: 哪怕 s_1 自己初始表示是 0 (没信息), 做过题这条边把题的难度信息、以及做过同样题的其他学生的信息汇聚了过来——这就是“协同”: 用相似群体快速给冷启动学生画像。这正是早期阶段最缺、也最值钱的信息。

作用: 在数据稀疏的早期, 用图把“相似学生 / 相关题目”的信息聚合进来, 快速构建认知画像。

公式 (4): 图融合 (稳住动态图的抖动)

动态图每步都在变, 单看当前步 $\tilde{Z}_t^{(1)}$ 会抖。于是和历史的平均表示做指数平滑式融合:

$$Z_t^{(1)} = \eta_t \tilde{Z}_t^{(1)} + (1 - \eta_t) \bar{Z}_t^{(1)}, \quad \bar{Z}_t^{(1)} = \frac{1}{1+t} \sum_{i=0}^{t-1} Z_i^{(1)}$$

- $\bar{Z}_t^{(1)}$ 是过去所有步协同表示的平均 (“历史记忆”。
- η_t 是平滑权重, 论文取 $\eta_t = 0.5$ (一半信当前、一半信历史)。

举例。第 5 步当前图算出 s_1 的协同表示 $\tilde{z} = 0.9$ (这步因为某道噪声题偏高), 历史平均 $\bar{z} = 0.7$ 。则融合后 $z = 0.5 \times 0.9 + 0.5 \times 0.7 = 0.8$ 。把这一步的“过激”拉回了一些, 更平滑。

作用: 缓解动态图训练不稳定, 让协同表示随时间平滑演化, 不被单步噪声带飞。

代码差异提示: 仓库 model/FACD.py 的 forward() 里, 融合不是用固定 $\eta_t = 0.5$, 而是用一个可学习的注意力 (g_attn_1/g_attn_2 两个线性层 + softmax) 在“当前图特征 g_feature_1”和“历史特征的加性注意力聚合 g_feature_2”之间打分加权。这对应论文里说的 η_t “也可通过学习机制自适应调整”。论文正文用 0.5 是简化叙述。

公式 (5)(6): 动态个性化模块 (GRU + 自注意力)

模块 B 只针对学生自己那条作答序列建模。把学生做过的题的嵌入按时间顺序喂进 GRU:

$$h_{t,s_i} = \text{GRU}(Z_{e_t}, h_{t-1,s_i}), \quad L_{t,s_i} = \{h_{j,s_i}\}_{j=1}^t$$

得到一串隐藏状态 $L_{t,s_i} \in \mathbb{R}^{t \times d}$ (每做一题产生一个隐状态)。再用**多头自注意力**从这串状态里挑出最关键的作答信息, 压成一个向量:

$$Z_{t,s_i,h}^{(2)} = \text{softmax} \left(\frac{L_{t,s_i} W_h^Q (L_{t,s_i} W_h^K)^\top}{\sqrt{d_h}} \right) L_{t,s_i} W_h^V$$

$$Z_{t,s_i}^{(2)} = [Z_{t,s_i,1}^{(2)}, \dots, Z_{t,s_i,H}^{(2)}] W^F + b^F$$

- $W_h^Q, W_h^K, W_h^V \in \mathbb{R}^{d \times d_h}$ 是第 h 个头的 Q/K/V 投影; H 个头, $d_h = d/H$ 。
- 自注意力让每个时刻去“关注”序列里其他时刻, 从而判断哪些题对刻画这个学生最重要。

举例。 s_3 做了 5 题，GRU 输出 5 个隐状态 $h_1..h_5$ 。自注意力算出的注意力权重比如 $[0.05, 0.4, 0.05, 0.1, 0.4]$ ——说明第 2 题和第 5 题（也许是两道难题，最能区分能力）权重最大。最终 $Z^{(2)}$ 就主要由这两道题的隐状态加权而成。这样即使第 1、3 题是 noisy 的简单题，也不会主导这个学生的表示。

作用：把学生当成序列而非一堆离散点来建模，强调 CAT 选出来的题之间的先后关系，并自动给关键题更高权重 → 抗噪、稳健、个性化，是后期稳定性的来源。

代码对照：model/FACD.py 的 `encode_time_feature()`：先把每个学生做过题的嵌入 padding 成长序列喂 nn.GRU，取最后隐状态 h ，再过 `MultiHeadSelfAttention(d_model, 8)`（8 个头），最后对 layers 取 mean。题目/概念节点这部分用零向量 padding（个性化只给学生）。

公式 (7)(8)(9)：三路表示的自适应融合

对学生，把三路表示（初始 ID $Z^{(0)}$ 、协同 $Z^{(1)}$ 、个性化 $Z^{(2)}$ ）加权求和；题目和概念只有前两路（它们没有个性化序列）：

$$H_{t,s_i} = \alpha_{t,s_i}^0 Z_{s_i}^{(0)} + \alpha_{t,s_i}^1 Z_{t,s_i}^{(1)} + \alpha_{t,s_i}^2 Z_{t,s_i}^{(2)}$$

权重 α 不是固定的，而是由三路表示拼起来过线性层 + softmax 算出来（公式 8、9）：

$$\alpha_{t,s_i}^l = [Z^{(0)}, Z^{(1)}, Z^{(2)}] W_s^l + b_s^l, \quad \alpha^l = \frac{\exp(\alpha^l)}{\sum_{j=0}^2 \exp(\alpha^j)}$$

举例。第 3 步（很早），模型可能学到 $\alpha = [0.2, 0.7, 0.1]$ ——重协同，因为自己数据太少，主要靠图借来的群体信息。到第 15 步，可能变成 $\alpha = [0.3, 0.3, 0.4]$ ——个性化权重上来了，因为这时自己的序列已经够长够可信。这正好对应消融实验的结论：“早期靠协同，后期靠个性化”。

作用：让模型按 CAT 阶段动态决定信任哪路信息，这是 FACD 能“既快又稳”的关键开关。

代码对照：forward() 里第二段 `g_attn/t_attn` 做的就是图特征 vs 时间特征的 softmax 加权，最后 `output = final_x + score0*g_feature + score1*t_feature`——即 ID 表示打底，再叠加协同与个性化两路（代码实现与论文公式 7 形式略有出入，但思想一致：三路自适应融合）。

交互函数 + 公式 (10)：套进 IRT/NCD 并训练

融合后的 H 经一个变换层 ϕ （论文用线性变换）送进任意 CDM 的交互函数：

$$\hat{y}_{ij} = \mathcal{M}(\phi_s(H_{t,s_i}), \phi_e(H_{t,e_j}), \phi_c(H_{t,c}))$$

$\mathcal{M}$ 可以是 IRT 的逻辑斯蒂打分，也可以是 NCD 的 MLP 打分。这就是 FACD “即插即用”的体现——它只换了喂给交互函数的表示，没换交互函数本身。

训练用标准二元交叉熵，且在 CAT 里只对当前步新选题集 R_t 算损失（公式 10）：

$$\mathcal{L}_{BCE} = -\frac{1}{|R_t|} \sum_{(i,j,r_{ij}) \in R_t} [r_{ij} \log \hat{y}_{ij} + (1 - r_{ij}) \log(1 - \hat{y}_{ij})]$$

举例。第 5 步给 s_3 选了 e_{30} ，模型预测答对概率 $\hat{y} = 0.72$ ，真实 s_3 答对了 ($r = 1$)。这条的损失 = $-\log(0.72) \approx 0.33$ 。若答错 ($r = 0$)，损失 = $-\log(1 - 0.72) \approx 1.27$ ，惩罚更大。反向传播据此更新嵌入和各模块参数。

代码对照：`_loss_function` 即带平滑项的 BCE：`-(r*log(1e-4+p)+(1-r)*log(1.0001-p)).mean()`。`adaptest_update()` 是 CAT 每一步收到新作答后对模型做的在线微调，并把当前图特征 `append` 进 `total_graph_feature`（即累积历史，对应公式 4 的历史平均）。

五、代码实现对照

仓库结构 (FACD/):

路径	作用	对应论文
model/FACD.py → class FACD	核心框架: GCN 编码 + GRU/自注意力 + 两级注意力融合	§4.1–4.3、公式 (3)(5)(6)(7)
model/FACD.py → GNNEncoder.convolution	LightGCN 式轻量卷积 (无 W、无激活, 逐层 mean)	公式 (3)
model/FACD.py → encode_time_feature	GRU + MultiHeadSelfAttention(.,8) 抽个性化序列特征	公式 (5)(6)
model/FACD.py → forward 中两组 g_attn/t_attn	自适应融合权重 (替代固定 $\eta = 0.5$ 与公式 8)	公式 (4)(7)(8)(9)
model/IRT.py、model/NCD.py	两种交互函数 $\mathcal{M}$ (decoder)	§4.3 交互函数
model/FACD.py → adapttest_update strategy/	CAT 每步在线更新 + 累积历史图特征	公式 (10)、(4)
	Random/MAAT/BECAT/NCAT 等选择策略 π	§5.2
model/FACD.py → expected_model_change/delta_q_S_t/get_BE_weights	MAAT / BECAT 选题所需的打分	§2.1 选择策略
data/<dataset>/	FrcSub / EDMCup2023 / NeurIPS2020 数据与 Q 矩阵	表 1

几个值得实现的实现细节: - `monotonicity()` 在每次 `optimizer.step()` 后调用——这是 NCD 类模型常见的单调性约束 (保证能力越高、答对概率越高), 保留了可解释性。- `total_graph_feature` 列表逐步 `append`, `forward` 里用 `AdditiveAttention` 对历史所有图特征做加性注意力聚合得到 `g_feature_2`, 再与当前 `g_feature_1` 融合——这就是论文公式 (4)“当前 + 历史”思想的可学习版本。- 个性化模块只对学生节点生效, 题目和概念节点用零向量 `padding` 后再 `concat`。

六、小结

实验结论要点: - 在 FrcSub / EDMCup2023 / NeurIPS2020 上, 配 5 种选择策略 (Random/MAAT/BOBCAT/NCAT/BECAT)、2 种交互函数 (IRT/NCD), FACD (表里记作“FA”) 在第 5、10 步等早期阶段几乎全面碾压原始 CDM (“OL”), AUC/ACC 提升约 5%–10%, 且多数提升通过了 t 检验 (带 *)。后期差距收窄 (因为大家都逼近真值了)。- 对比表示提取类方法 RCD、ORCDF, FACD 更稳更好, 因为它们没专门处理动态图稳定性、也没建模个性化序列。- 消融 (表 4): 去掉协同模块 (FA-C) 早期掉得多, 去掉个性化模块 (FA-P) 后期稳定性差 → 印证“早期靠协同、后期靠个性化”。- 推理速度 (图 3): 因用 LightGCN 式轻量聚合, 比 RCD (复杂聚合)、ORCDF (更复杂的响应图) 都快, 适合在线平台。- t-SNE (图 5): FA-NCD 第 5 步学生表示就按正确率清晰聚类, 原始 NCD 到第 10 步才有微弱分组 → 快速适应 + 可解释。

优点: 1. 即插即用——只增强表示, 不改交互函数, 可套 IRT/NCD 等多种 CDM、兼容多种选择策略。2. 对症下药——专门解决 CAT 早期冷启动这个被忽视的痛点, 协同 + 个性化两路一快一稳。3. 轻量快速——LightGCN 式卷积, 推理开销小。

局限 (作者自述): - 缺乏足够的理论分析来保证 CDM 与选择策略之间的有效对齐; 目前是经验性地“凑”在一起。未来工作方向是补上 CD 与 CAT 交互的理论基础。