

面向计算机自适应测试系统的快速自适应认知诊断框架 (A Fast-Adaptive Cognitive Diagnosis Framework for Computerized Adaptive Testing Systems)

原文: 6447.pdf(IJCAI 2025 接收版预印本)·译者: Claude ·译于 2026-06-27 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT)、认知诊断模型 (Cognitive Diagnosis Model, CDM)、题目选择策略 (selection strategy)、项目反应理论 (Item Response Theory, IRT)、神经认知诊断模型 (Neural Cognitive Diagnosis, NCD)、门控循环单元 (Gated Recurrent Unit, GRU)、图卷积网络 (Graph Convolutional Network, GCN)

摘要

计算机自适应测试 (CAT) 通过迭代地选择信息量大的题目来测量学生能力, 其核心组件是认知诊断模型 (CDM) 和题目选择策略。当前的研究主要集中在优化选择策略, 并假设 CDM 的诊断结果相对准确。然而, 现有的静态 CDM 在 CAT 早期阶段难以做到快速且准确的诊断。为此, 本文提出了快速自适应认知诊断 (Fast Adaptive Cognitive Diagnosis, FACD) 框架, 它包含动态协同诊断模块与个性化诊断模块。具体而言, FACD 中的协同模块利用一个动态响应图来快速构建学生的认知画像, 而个性化模块则利用每个学生的作答序列来进行鲁棒且个性化的诊断。在真实数据集上的大量实验表明, 与现有静态 CDM 相比, FACD 不仅在各种选择策略下都取得了更优的预测性能 (在 CAT 早期阶段提升约 5%–10%), 而且保持了相当不错的推理速度。

1 引言

随着在线测试平台的兴起, 个性化测评的需求急剧增长。诸如 GMAT 和 GRE 等标准化考试已经采用了自适应的题目选择策略, 以更好地评估学生能力。计算机自适应测试 (CAT) 通过为每位学生量身定制题目来优化测试效率, 在保证能力评估准确性的同时减少所需的题目数量。与传统测试不同, CAT 中的认知诊断模型 (CDM) 会根据学生对选择策略所选题目的作答来估计学生当前的能力, 并为后续的题目选择提供反馈。因此, CDM 是 CAT 中一个基础且决定性的组件。

近几十年来, 人们投入了大量精力开发 CDM, 对学生与题目之间的交互进行建模。传统 CDM (如 IRT、DINA 等) 依赖专家手工设计的交互函数, 而基于神经网络的 CDM 则使用多层感知机 (MLP) 来增强泛化能力与可解释性。近来, 利用图神经网络 (GNN) 学习作答关系图的做法受到关注, 为认知诊断提供了新的思路。

图 1: 动机示例。IRT 和 NCD 在 EDMCup2023 数据集上、采用 BECAT 选择策略时, 在 CAT 每一步上的准确率 (ACC) 变化。

尽管上述 CDM 取得了显著进展, 但很少有研究关注它们对 CAT 这类下游任务的适应性——而 CAT 严重依赖于“CDM 结果相对准确”这一假设。CAT 的目标是用尽可能少的题目来评估学生能力, 这带来一个关键挑战: CDM 应当能够动态地建模学生能力, 以便在 CAT 早期阶段快速适应; 然而早期阶段数据有限, 并不利于这种快速而准确的适应。如图 1 所示, 我们用 BECAT 作为选择策略, 比较了 IRT 与 NCD 在真实 CAT 任务中的表现。IRT 过于简单, 其适应能力受限, 导致性能提升缓慢。NCD 虽然能捕捉复杂的作答模式, 但它对充足数据的依赖导致其在早期阶段表现糟糕, 与 CAT 快速准确评估的目标相冲突。

为此, 本文提出面向计算机自适应测试系统的快速自适应认知诊断框架 (FACD), 以解决上述挑战, 并有效增强 CDM 的适应能力, 尤其是在 CAT 早期阶段。具体而言, 针对整体的动态结构建模, 我们设计了一个**动态协同诊断模块**。与依赖静态作答日志的传统 CDM 不同, FACD 框架在每个 CAT 阶段动态更新一张响应图, 以传递相关的学生与知识概念信息, 从而快速构建学生的认知画像。针对个人动态作答序列的建模, 我们设计了一个**动态个性化诊断模块**, 它采用门控循环单元 (GRU) 来捕捉每个学生作答序列中的关系; 一个自注意力机制进一步突显关键的作答特征。随后, 协同信息与个性化信息被融合, 以建模最终的表示, 并送入后续的交互函数。大量实验表明, 与传统 CDM 相比, FACD 在 CAT 早期阶段性能提升约 5%–10%。

后续各节分别回顾相关工作、给出预备知识、介绍所提出的 FACD、展示实验分析并对全文进行总结。我们在第 6 节给出关于数据伦理使用与研究对象知情同意的声明。

2 相关工作

2.1 计算机自适应测试

CAT 由两个关键组件构成: 一个 CDM 和一个选择策略。传统上, IRT 和 NCD 是 CAT 中 CDM 的常用选择。如今, 大多数研究都聚焦于 CAT 中的选择策略。最常用的方法, 如最大 Fisher 信息量 (Maximum Fisher Information, MFI) 和 Kullback-Leibler 信息量 (KLI), 通常都是针对特定 CDM (如 IRT) 量身定制的。为克服这一局限, 模型无关 (model-agnostic) 的算法 (如 MAAT 和 BECAT) 被提出, 但它们仍依赖准确的 CDM 诊断, 而这在 CAT 早期阶段难以保证。不准确的 CDM 结果会误导选择策略, 拖慢整个 CAT 流程。数据驱动的策略 (如 BOBCAT 和 NCAT) 在大规模数据集上预训练策略模型, 但仍然受困于早期阶段 CDM 诊断的不稳定。因此, 一个为 CAT 量身定制的、能在早期阶段做出准确及时诊断的 CDM 至关重要。

2.2 认知诊断

传统认知诊断使用 IRT、MIRT、DINA 等模型来推断学生对知识概念的掌握水平。随着深度学习的发展，使用多层感知机 (MLP) 的模型 (如 NCD、KSCD、KaNCD) 成功地捕捉了复杂的交互关系。从作答日志中提取丰富信息的其他途径还包括符号回归、图注意力网络以及贝叶斯网络。近来，一些 CDM 被开发出来以解决静态认知诊断中的冷启动问题，例如关注跨域诊断的 TechCD 和 ZeroCD，以及处理特定学生交互数据有限问题的 BetaCD 和 AGCDM。虽然这些问题与 CAT 早期阶段的冷启动问题有相似之处，但由于 CAT 中的动态上下文，它们并不能直接套用。此外，少有 CDM 研究关注对下游任务的适应；据我们所知，尚没有 CDM 是专门为 CAT 的独特需求而设计的，这使得这种适应显得尤为关键。

3 预备知识

认知诊断基础。考虑一个含 N 个学生、 M 道题目和 K 个知识概念的教育系统，可分别记为三个集合： $S = \{s_1, \dots, s_N\}$ 、 $E = \{e_1, \dots, e_M\}$ 和 $C = \{c_1, \dots, c_K\}$ 。题目与知识概念之间的关系记录在一个二值 Q 矩阵 $Q = \{Q_{ij}\}_{M \times K}$ 中，其中 $Q_{ij} \in \{0, 1\}$ 表示该知识概念是否被该题目涉及。集合 S 中的每个学生会从集合 E 中选做一些题目，产生记录其表现的作答日志。这些作答日志表示为三元组 $R = \{(s, e, r) \mid s \in S, e \in E, r_{se} \in \{0, 1\}\}$ ，其中 $r_{se} = 1$ 表示题目 e 被学生 s 答对， $r_{se} = 0$ 则相反。基于上述信息，认知诊断旨在推断 $Mas \in \mathbb{R}^{N \times K}$ ，即一个表示每个学生在所有知识概念上掌握水平的矩阵。

计算机自适应测试。在 CAT 中，选择策略与 CDM 交替进行，构成一个循环过程。对于 CDM，我们将其定义为 $\mathcal{M}$ 。学生 i 的题目集合 E_i 可划分为候选题目集 C_i 与已测评题目集 J_i 。假设在时间步 $t \in [1, T]$ ，学生 i 已经回答了一个从候选集 C_i 中选出的题目序列 $R_{t-1,i} = \{(e_1, r_1), \dots, (e_{|t-1|}, r_{|t-1|})\}$ 。那么，CDM $\mathcal{M}$ 可以基于该作答序列 $R_{t-1,i}$ 估计学生 i 在时刻 t 的掌握水平，记为 $\hat{Mas}_{t-1,i} = \mathcal{M}(R_{t-1,i}) \in [0, 1]$ 。对于选择策略，我们将选择策略定义为 π ，它为学生 i 选择一道题目 $e_{t,i} \sim \pi(\hat{Mas}_{t-1,i})$ 。在收到学生 i 的作答 $r_{t,i}$ 后，CDM 被更新，得到新的掌握水平估计 $\hat{Mas}_{t,i}$ 。更新之后，CDM 的性能会在已测评题目集 J_i 上测试。上述过程重复 T 步。CAT 的目标是用尽可能少的测试步数 T ，让学生被估计的掌握水平 $\hat{Mas}_{T,i}$ 接近其真实值 Mas_i^* 。

问题陈述。本文主要关注于构建一个快速自适应的 CDM 模块，以帮助 CAT 系统中的 CDM 快速且稳定地估计学生的掌握水平，使其尽快逼近真实值。具体而言，我们的目标是确保在相对较早的时间步 T ，被估计的掌握水平 $\hat{Mas}_{T,i} = \mathcal{M}(R_{T-1,i})$ 尽可能接近真实掌握水平 Mas_i^* 。然而，由于无法直接观测 Mas_i^* ，我们的目标转而变为估计学生真实作答 R_i^* 的分布。估计的作答分布 $\hat{R}_{T,i}$ 越接近真实作答分布 R_i^* ，CDM 的性能就越好。这一差异通常用曲线下面积 (Area Under the Curve, AUC) 来度量，更高的 AUC($\hat{R}_{T,i}, R_i^*$) 表示 CDM 的预测更准确。

4 方法

在本节中，我们给出所提出 FACD 的技术细节 (如图 2 所示)。我们引入两个关键组件：图 2(a) 中的动态协同诊断模块和图 2(b) 中的动态个性化诊断模块。在此之后，我们将描述如何在最终的推理模块中把这些特征整合进各种 CDM 的交互函数。FACD 的详细组件如图 2(c) 所示。

图 2：所提出 FACD 的整体框架。(a) 动态协同诊断模块。(b) 动态个性化诊断模块。(c) FACD 的详细组件。

4.1 动态协同诊断模块

图的构建。首先，我们为动态协同诊断模块定义在时间步 t 的动态响应图，记为 $G_t = (V, E_t)$ 。节点集 $V = S \cup E \cup C$ 分别包含学生、题目和概念节点。 V 在 CAT 过程中保持不变，所有节点在初始时就已定义。边集 $E_t = E_t^{se} \cup E_t^{ec}$ 由两类边构成： E_t^{se} 涉及学生集 S 与题目集 E 之间的交互 (即学生 s_i 完成题目 e_j)， E_t^{ec} 涉及题目集 E 与概念集 C 之间的关系 (即题目 e_j 与概念 c_k 相关)。基于此，我们可以把图分解为两个子图。

第一个子图是**学生-题目图**，它本质上是动态的。在每个时间步 t ，边集更新为 $E_t^{se} = E_{t-1}^{se} \cup R_t$ ，其中 R_t 表示在时间步 t 所有学生新增的交互记录。对应的邻接矩阵 $A_t^{se} \in \mathbb{R}^{|S| \times |E|}$ 可表示为：

$$A_t^{se} = \{x_{ij}\}_{|S| \times |E|}, \quad x_{ij} = \begin{cases} 1 & \text{若 } (s_i, e_j, r_{ij}) \in E_t^{se}, \\ 0 & \text{其他.} \end{cases} \quad (1)$$

第二个子图是**题目-概念图**，它是一个静态图。其边集 E^{ec} 可直接从 Q 矩阵中题目与概念的关系导出。对应的矩阵 $A^{ec} \in \mathbb{R}^{|E| \times |C|}$ 可表示为 $A^{ec} = Q$ 。然后我们可以构建最终的动态响应图 G_t ，它整合了上述两个子图。其对应的矩阵 $A_t \in \mathbb{R}^{(|S|+|E|+|C|) \times (|S|+|E|+|C|)}$ 可表示为：

$$A_t = \begin{pmatrix} O & A_t^{se} & O \\ A_t^{se\top} & O & A^{ec} \\ O & A^{ec\top} & O \end{pmatrix}, \quad (2)$$

其中 O 表示零矩阵。图 G_t 在 CAT 题目选择过程中动态地建立学生与题目之间的连接，并构建题目与概念之间的关系，这是后续提取协同信息的基础。

图卷积。在 CDM 中，最基本的数据元素是作答日志和 Q 矩阵。我们需要把这些错综复杂的日志系统地拆解为其基本组成部分：学生、题目和概念。为了表示这些实体，我们采用可训练的嵌入，记为 $Z_s^{(0)} \in \mathbb{R}^{|S| \times d}$ 、 $Z_e^{(0)} \in \mathbb{R}^{|E| \times d}$ 、 $Z_c^{(0)} \in \mathbb{R}^{|C| \times d}$ ，其中 d 表示嵌入维度，作为初始的 ID 表示。为便于后续卷积过程，我们将上述嵌入堆叠起来形成 $Z^{(0)} \in \mathbb{R}^{(|S|+|E|+|C|) \times d}$ ，于是在时间步 $t = 0$ 的初始动态协同表示可定义为 $Z_0^{(1)} = Z^{(0)}$ 。鉴于 CDM 中学生、题目和知识概念的表示相对直接、仅由 ID 构成，受 LightGCN 的启发，我们去除了线性变换与非线性激活函数，转而专注于图卷积网络 (GCN) 最基本的元素。因此，时间步 t 的图嵌入传播层用矩阵形式表示为：

$$Z_t^{(1,l)} = \left(D^{-\frac{1}{2}} A_t D^{-\frac{1}{2}}\right) Z_t^{(1,l-1)}, \quad (3)$$

其中度矩阵 D 是一个尺寸为 $(|S| + |E| + |C|) \times (|S| + |E| + |C|)$ 的对角矩阵，每个元素 D_{ii} 表示邻接矩阵 A_t 第 i 行向量中非零元素的个数。通过应用式 (3)，我们可以从图 G_t 在时间步 t 的第 l 层得到卷积结果 $Z_t^{(1,l)} \in \mathbb{R}^{(|S|+|E|+|C|) \times d}$ 。时间步 t 的动态协同表示 $\tilde{Z}_t^{(1)} \in \mathbb{R}^{(|S|+|E|+|C|) \times d}$ 通过对图 G_t 每一层结果做均值池化 (mean pooling) 得到，可表示为 $\tilde{Z}_t^{(1)} = \frac{1}{1+L} \sum_{l=0}^L Z_t^{(1,l)}$ 。

图卷积过程聚合来自邻居的结果，这对于提取协同信息至关重要，因为它使我们能够识别那些反映学生在其相似邻居群体内、掌握水平上的集体强项与弱项的模式与关系。这帮助我们在 CAT 早期阶段，基于相似学生群体来快速构建该学生的画像。

图融合。鉴于训练动态图所固有的不稳定性，我们在构建最终的动态协同表示 $Z_t^{(1)} \in \mathbb{R}^{(|S|+|E|+|C|) \times d}$ 时，融合当前时间步 t 的动态协同表示 $\tilde{Z}_t^{(1)}$ 与来自此前时间步 0 到 $t-1$ 的平均动态协同表示 $\bar{Z}_t^{(1)}$ 。这种做法缓解了由动态图变化所带来的潜在训练不稳定性，可表示为：

$$Z_t^{(1)} = \eta_t \tilde{Z}_t^{(1)} + (1 - \eta_t) \bar{Z}_t^{(1)}, \quad \bar{Z}_t^{(1)} = \frac{1}{1+t} \sum_{i=0}^{t-1} Z_i^{(1)}, \quad (4)$$

其中 η_t 是动态协同特征的平滑权重，它既可以用一个预设阈值来确定融合比例，也可以通过学习机制自适应地调整。我们目前设 $\eta_t = 0.5$ 。

4.2 动态个性化诊断模块

对每一个学生 s_i ，我们基于其所选题目的作答记录，在时间步 t 构建一个动态个性化表示。为了捕捉 CAT 中选择算法为每个学生所选题目之间的序列关系，我们采用 GRU 网络。学生 i 在时间步 t 的个性化题目表示序列 $L_{t,s_i} \in \mathbb{R}^{t \times d}$ 定义如下：

$$L_{t,s_i} = \{h_{j,s_i}\}_{j=1}^t, \quad h_{t,s_i} = \text{GRU}(Z_{e_t}^{(0)}, h_{t-1,s_i}), \quad (5)$$

其中 $h_{t,s_i} \in \mathbb{R}^{1 \times d}$ 表示 GRU 中在时间步 t 所选题目的隐藏状态。然后，我们对个性化题目表示序列 L_{t,s_i} 施加多头自注意力 (multi-head self-attention)，以提取每个学生最关键的作答信息，得到学生 s_i 在时间步 t 的动态个性化表示 $Z_{t,s_i}^{(2)} \in \mathbb{R}^{1 \times d}$ ：

$$Z_{t,s_i,h}^{(2)} = \text{softmax} \left(\frac{L_{t,s_i} W_h^Q (L_{t,s_i} W_h^K)^\top}{\sqrt{d_h}} \right) L_{t,s_i} W_h^V, \quad (6)$$

$$Z_{t,s_i}^{(2)} = [Z_{t,s_i,1}^{(2)}, Z_{t,s_i,2}^{(2)}, \dots, Z_{t,s_i,H}^{(2)}] W^F + b^F,$$

其中 $W_h^Q, W_h^K, W_h^V \in \mathbb{R}^{d \times d_h}$ 分别是查询 (query) 矩阵、键 (key) 矩阵和值 (value) 矩阵的可训练参数矩阵， $W^F \in \mathbb{R}^{d \times d}$ 、 $b^F \in \mathbb{R}$ 是最终线性变换的可训练参数， $d_h = \frac{d}{H}$ 表示每个自注意力头的维度， H 表示自注意力头的数量， $\text{softmax}(\cdot)$ 和 $[\cdot]$ 分别表示按行的 softmax 函数和拼接操作。

与把学生、题目和作答记录当作离散数据点来训练的传统 CDM 相比，我们的动态个性化诊断模块为每个学生提供了对题目的序列化建模。这种方法强调了 CAT 选择策略中题目之间的相互关系，同时利用自注意力为每个学生提取相关的作答信息。因此，它为个性化建模奠定了基础，并增强了 CDM 在 CAT 快速适应中的鲁棒性。

4.3 推理模块

表示融合。在从动态协同诊断模块和动态个性化诊断模块得到表示之后，融合模块为每个学生 s_i 、每道题目 e_j 和每个概念 c_k 在时间步 t 统一地建模最终的融合表示。具体而言，我们可以将这一融合过程表示如下：

$$\begin{cases} H_{t,s_i} = \alpha_{t,s_i}^0 Z_{s_i}^{(0)} + \alpha_{t,s_i}^1 Z_{t,s_i}^{(1)} + \alpha_{t,s_i}^2 Z_{t,s_i}^{(2)}, \\ H_{t,e_j} = \alpha_{t,e_j}^0 Z_{e_j}^{(0)} + \alpha_{t,e_j}^1 Z_{t,e_j}^{(1)}, \\ H_{t,c_k} = \alpha_{t,c_k}^0 Z_{c_k}^{(0)} + \alpha_{t,c_k}^1 Z_{t,c_k}^{(1)}, \end{cases} \quad (7)$$

其中 $H_{t,s_i} \in \mathbb{R}^{1 \times d}$ 、 $H_{t,e_j} \in \mathbb{R}^{1 \times d}$ 和 $H_{t,c_k} \in \mathbb{R}^{1 \times d}$ 分别表示每个学生 s_i 、每道题目 e_j 和每个概念 c_k 在时间步 t 的最终融合表示。 $Z_{s_i}^{(0)}$ 、 $Z_{t,s_i}^{(1)}$ 和 $Z_{t,s_i}^{(2)}$ 分别表示前文提到的初始 ID 表示、动态协同表示和动态个性化表示。 α_t 是三类表示的归一化权重。以 α_{t,s_i} 为例，我们首先按如下方式计算这些权重：

$$\begin{cases} \alpha_{t,s_i}^0 = [Z_{t,s_i}^{(0)}, Z_{t,s_i}^{(1)}, Z_{t,s_i}^{(2)}] W_s^0 + b_s^0, \\ \alpha_{t,s_i}^1 = [Z_{t,s_i}^{(0)}, Z_{t,s_i}^{(1)}, Z_{t,s_i}^{(2)}] W_s^1 + b_s^1, \\ \alpha_{t,s_i}^2 = [Z_{t,s_i}^{(0)}, Z_{t,s_i}^{(1)}, Z_{t,s_i}^{(2)}] W_s^2 + b_s^2, \end{cases} \quad (8)$$

其中 $W_s^0, W_s^1, W_s^2 \in \mathbb{R}^{3d \times 1}$ ， $b_s^0, b_s^1, b_s^2 \in \mathbb{R}$ 是可训练参数， $[\cdot]$ 表示三类表示的拼接。之后，我们按如下方式归一化这些权重：

$$\alpha_{t,s_i}^l = \frac{\exp(\alpha_{t,s_i}^l)}{\sum_{j=0}^2 \exp(\alpha_{t,s_i}^j)}. \quad (9)$$

至于题目和概念的融合表示，过程与学生类似。

交互函数。给定输入表示 H_{t,s_i} 、 H_{t,e_j} 、 H_{t,c_k} ，我们的模型能够适配现有 CDM 中存在的各种交互函数，以预测学生作答题目的表现，可表示为 $\hat{y}_{ij} = \mathcal{M}(\phi_s(H_{t,s_i}), \phi_e(H_{t,e_j}), \phi_c(H_{t,c_k}))$ ，其中 $\mathcal{M}(\cdot)$ 可以是任何一种 CDM 的交互函数， $\phi(\cdot)$ 是变换层，它便于把表示与现有大多数 CDM 的交互函数整合起来，并帮助把表示的维度转换为适配特定类型 CDM 的特征空间。为简单起见，我们在框架中使用线性变换。

模型训练。在认知诊断任务中，我们主要采用二元交叉熵 (binary cross entropy) 损失函数，它度量模型预测结果与一个 mini-batch 内实际作答得分之间的差异。在 CAT 过程中，损失是在每个学生于时间步 t 新选题目集的作答集 R_t 上计算的。损失函数可表示为：

$$\mathcal{L}_{BCE} = -\frac{1}{|R_t|} \sum_{(i,j,r_{ij}) \in R_t} [r_{ij} \log \hat{y}_{ij} + (1 - r_{ij}) \log(1 - \hat{y}_{ij})]. \quad (10)$$

5 实验

5.1 实验设置

数据集描述。实验在三个真实数据集上进行，即 FrcSub、EDMCup2023 和 NeurIPS2020。数据集来源与数据预处理的细节见附录 D.1。附录 A-D 可在 <https://github.com/BW297/FACD> 找到。

表 1：三个真实数据集的统计信息。FrcSub: 536 名学生、20 道题、8 个概念、10,720 条作答日志、稀疏度 1.000、平均正确率 0.533、Q 密度 2.800；EDMCup2023: 27,178 名学生、1,687 道题、542 个概念、413,021 条作答日志、稀疏度 0.009、平均正确率 0.575、Q 密度 1.000；NeurIPS2020: 4,918 名学生、455 道题、38 个概念、494,316 条作答日志、稀疏度 0.221、平均正确率 0.546、Q 密度 1.000。

评价指标。由于难以准确评估真实学生的掌握水平 Mas^* ，评价 CAT 系统中 CDM 的性能本身就很难。为应对这一问题，常见做法是预测学生的作答得分。我们衡量模型预测学生能否成功解出某题（与测试集中真实结果相比）的能力，使用标准的分类指标，如准确率 (ACC) 和曲线下面积 (AUC)。

实现细节。参数初始化采用 Xavier，优化采用 Adam。批大小 (batch size) 在 $\{32, 64, 128, 256\}$ 范围内设置。学习率从 $\{1e-3, 3e-3, 5e-3, 7e-3, 1e-2\}$ 中选取。所有方法的 MLP 维度保持一致，为 512 和 256。为确保鲁棒性与可复现性，每个实验重复十次。实现的源代码见 <https://github.com/BW297/FACD>。更多实现细节见附录 D.3。

5.2 性能比较

为展示 FACD 的有效性，我们将其与 IRT 和 NCD 集成——这两者在 CAT 研究中被广泛使用。实验中所用基线的详细介绍见附录 D.2。

与不同 CAT 选择策略的性能比较。为证明我们的方法与各种 CAT 选择策略有很强的兼容性，我们选择了一组既经典又前沿的策略：Random、MAAT、BOBCAT、NCAT 和 BECAT。如表 2 所示，各种 CDM 在与 FACD 集成后，在所有 CAT 选择策略下都展现出很强的适应性。值得注意的是，在题目选择的初始阶段（例如回答约五道题之后），我们的模型表现出快速适应，与原始 CDM 形成了显著的性能差距。在题目选择的后期阶段，随着模型逼近学生的真实掌握水平，我们模型的性能提升变得更为渐进。这凸显了模型在有限步数内收敛的能力，能为 CAT 选择策略提供精确反馈，并支持更高效地减少所选题目的数量。

表 2：与不同 CAT 选择策略的整体性能 (AUC%/ACC%)。“OL”代表“original”（原始方法），“FA”代表施加到原始方法上的 FACD 增强。在 FrcSub、EDMCup2023、NeurIPS2020 三个数据集上，对 IRT 和 NCD 两种交互函数、Random/MAAT/BOBCAT/NCAT/BECAT 五种策略、在第 5/10/15 步分别给出结果。带“*”表示通过显著性水平 0.05 的 t 检验。整体上，FA 列在早期阶段（尤其第 5、10 步）几乎全面优于 OL 列，提升约 5%–10%。（原文为大表，结构复杂，此处仅说明含义，具体数值详见原文。）

与 CDM 中不同提取模块的性能比较。为比较不同的表示提取方法，我们用 BECAT 作为选择策略，选取若干基线与 FACD 比较：RCD 和 ORCDF。如表 3 所示，我们的 FACD 在 CAT 系统中持续优于 RCD 和 ORCDF，并在不同 CDM 上展现出相对稳定的结果。这主要是因为 RCD 和 ORCDF 缺乏对动态图模块稳定性的研究。此外，它们未能有效建模每个学生的个性化题目序列，因而无法评估学生作答信息的重要性，使它们对噪声（如低质量的作答数据）敏感，从而降低了鲁棒性。可以观察到，FACD 不仅确保了强劲的性能与鲁棒性，还有效缓解了 BECAT 原文中提到的冷启动问题。我们在附录 D.5 中还提供了与传统经典 GNN 框架的进一步比较。

表 3：在 IRT 和 NCD 中使用 BECAT、对不同提取模块的整体性能。“FA”代表所提出的 FACD，“OR”代表 ORCDF，“IF”代表交互函数（interaction function）。每列中最佳均值加粗并下划线，次优者下划线。由于标准差很低（小于 0.05），表中未展示标准差。若最佳模型的均值显著优于次优者（通过显著性水平 0.05 的 t 检验），则在相应位置标注“*”。（原文为大表，结构复杂，具体数值详见原文。）

5.3 消融实验

为展示 FACD 中每个组件的贡献，我们在数据集 EDMCup2023 上对 FACD 进行消融实验，分为以下三个版本。“FA-C”和“FA-P”分别表示移除动态协同诊断模块和动态个性化诊断模块。“OL”表示基础 CDM。如表 4 所示，所提方法优于另外两个被消融的版本，表明每个组件都对 CAT 的不同阶段有显著贡献，从而带来模型整体的有效性。早期性能依赖于动态协同诊断，而后期稳定性来自动态个性化诊断。

表 4：在 EDMCup2023 数据集上的消融实验整体性能。细节与表 3 相同。

5.4 FACD 优势的深入分析

推理时间比较。我们在 EDMCup2023 数据集上比较不同提取模块与原始 CDM 的推理速度，具体是 CAT 系统为每个学生选出一道题后，每一轮在训练和推理上花费的平均 CPU 时间。如图 3 所示，RCD 使用复杂的图聚合函数，推理速度较慢、资源消耗较高。FACD 和 ORCDF 都使用类似 LightGCN 的更轻量聚合方法，因而更快，但 ORCDF 由于其更复杂的响应图而产生额外开销。我们的方法在有限的计算资源下实现了高质量的认知诊断，使其非常适合现代在线教育平台。详细的时间与空间复杂度分析见附录 B.2。

图 3：推理时间比较。

预训练比例上的泛化分析。我们在 EDMCup2023 数据集上，在不同预训练比例 $p_t = \{0.0, 0.1, 0.2, 0.3\}$ 下，评估集成 FACD 的原始 CDM 的性能；该比例表示在 CAT 过程开始之前用于预训练的数据集占比。如图 4 所示，原始 CDM 在较小预训练比例下出现性能下降，并在 CAT 过程中需要更多步数。然而，在集成 FACD 后，模型在后续的题目选择步骤中迅速提升性能，帮助 CDM 更好地与学生的真实掌握水平对齐。

图 4：预训练比例分析。(a) 预训练比例 0；(b) 0.1；(c) 0.2；(d) 0.3。

学生 Mas 的分布偏移。学生可以自然地按其表现分组，例如高或低的正确作答率，反映其掌握水平的差异。为可视化这一点，我们使用 t-SNE 把 Mas 投影到二维平面上（t-SNE 的二维坐标轴仅用于可视化，不具特定含义），并根据正确率为散点图着色，颜色越深表示正确率越高。在图 5 中，NCD 集成 FACD 后在 NeurIPS2020 数据集上学到的学生表示，到第 5 步就呈现出清晰的聚类，到第 10 步变得更加分明。相比之下，标准 NCD 模型在第 5 步没有清晰聚类，到第 10 步才显示出微弱的分组。这证明了 FACD 在表示学习和可解释性两方面的快速适应能力。除了用可视化展示模型的可解释性外，我们还在附录 D.4 中提供了在可量化可解释性指标（如 DOA）上的进一步比较。

图 5：学生 Mas 分布偏移在 NCD 与 FA-NCD 上的 t-SNE 散点图。

5.5 超参数分析

我们在 EDMCup2023 数据集上研究动态图层数、GRU 层数、嵌入维度和图掩码比例等超参数的影响。具体来说，当图层数设为 1 和 2、GRU 层数设为 3、嵌入维度设为 32 或 64、图掩码比例设为 0.1 和 0.2 时，模型取得最优性能。详细的超参数分析与图见附录 D.6。

6 结论

本文提出了一个用于计算机自适应测试的快速自适应认知诊断框架 FACD。FACD 主要聚焦于解决 CDM 在 CAT 早期阶段提升缓慢的问题。我们引入了两个动态诊断模块，从相似学生中捕捉协同信息、从个人作答序列中捕捉关键信息，从而实现快速适应。FACD 仍存在一些局限，例如缺乏足够的理论分析来确保与 CAT 题目选择策略的有效对齐。因此，未来研究可以聚焦于加强理论基础，以增强认知诊断与 CAT 之间的交互。

伦理声明

本研究不涉及人类受试者，也不引发与隐私、安全或法律合规相关的问题。本研究所用数据集均来自公开可得的数据集，这些数据集在发布时已经过严格的伦理审查与匿名化处理。这些数据集不含任何学生隐私信息，并被广泛用于各类教育研究中。

参考文献 (*References*) 按约定未翻译，详见原文。