

用选择性 Mixup 为计算机自适应测试中的题目选择去偏 (Selective Mixup for Debiasing Question Selection in Computerized Adaptive Testing)

原文: selective-mixup-debiasing-cat_7.pdf · 译者: Claude · 译于 2026-06-27 术语对照: Computerized Adaptive Testing (CAT, 计算机自适应测试)、Cognitive Diagnosis Module (CDM, 认知诊断模块)、Question Selection Module (题目选择模块)、Item Response Theory (IRT, 项目反应理论)、Selection Bias (选择偏差)、Bias-conflicting Samples (偏差冲突样本)、meta set (元集合)、support set (支撑集)、Worst-group Accuracy (最差组准确率)。

摘要

计算机自适应测试 (Computerized Adaptive Testing, CAT) 是在线教育平台上评估考生 (examinee) 能力水平的一种广泛使用的技术。它利用对能力的先验估计来选择题目, 再根据考生的作答迭代地更新估计, 从而实现个性化的考生建模, 已经吸引了大量关注。尽管取得了这些进展, 现有工作大多集中在提升能力估计的准确性, 却忽视了自适应过程中固有的**选择偏差 (selection bias)**。选择偏差的产生是因为题目选择强烈地受到所估计能力的影响, 例如给能力较低的考生分配更容易的题目、给能力较高的考生分配更难的题目。由于选择依赖于先验估计, 这种偏差会传播进诊断模型, 并在迭代更新中被进一步放大, 导致预测出现错位和偏差。此外, 考生历史交互的不平衡往往会加剧诊断模型中的偏差。为解决这一问题, 我们提出一个由两个关键模块组成的去偏框架: **跨属性考生检索 (Cross-Attribute Examinee Retrieval)** 与**基于选择性 Mixup 的正则化 (Selective Mixup-based Regularization)**。首先, 我们检索那些正确与错误作答分布相对均衡的「平衡考生」, 把他们作为有偏考生的中性参照 (neutral reference)。然后, 在每个有偏考生和其匹配到的平衡对应者之间, 在标签一致的前提下施加 Mixup。这种数据增强丰富了偏差冲突样本的多样性, 并平滑了选择边界。最后, 我们在两个基准数据集上、用多种先进的诊断模型进行了大量实验。结果表明, 我们的方法显著提升了题目选择的泛化能力。

CCS 概念

- 应用计算 → 计算机辅助教学。

关键词

计算机自适应测试, 偏差缓解 (Bias Mitigation)

1 引言

计算机自适应测试 (CAT) 通过迭代地选择题目、更新考生状态, 能够用更少的题目实现准确的能力估计 [9, 17, 28]。早期的 CAT 依赖启发式策略, 例如最大 Fisher 信息量 (Maximum Fisher Information) [18], 而近期的进展则转向**数据驱动 (data-driven)**的方法, 即从大规模交互数据中学习「题目选择模块 (Question Selection Module)」[12, 25, 29], 取得了很强的诊断性能。然而, 关于缓解 CAT 中偏差的研究仍然有限 [13, 16]。由数据不平衡或自适应选择所引发的偏差, 可能导致系统性地分配过易或过难的题目, 从而扭曲能力估计、损害公平性。此前的工作如 UserAIF [16] 通过重新校准题目参数来缓解偏差, 但它忽视了有偏训练数据对「题目选择模块」本身的影响。

有偏选择的来源与后果仍未得到充分研究, 这在构建公平且鲁棒的 CAT 系统方面留下了空白。本工作针对这一局限, 考察有偏选择是如何在训练过程中产生、并同时影响能力估计的准确性与公平性的, 重点放在缓解数据驱动的「题目选择模块」内部的偏差上。近期的题目选择模块常采用**双层优化 (bi-level optimization)**框架 [12, 29], 其中每个考生的交互被划分为一个**支撑集 (support set)** 和一个**元集合 (meta set)**。支撑集供认知诊断模块 (Cognitive Diagnosis Module, CDM) 来估计能力, 而元集合则为训练题目选择模块提供反馈。如图 1 所示, 在每一步 t , 题目选择模块根据考生的历史选择下一道题, CDM 在收到作答后更新能力估计, 而在元集合上的预测则产生反馈以优化题目选择模块。这个过程重复 T 步, 迭代地精炼题目选择。

图 1: 数据驱动的题目选择模块的训练过程——在能力估计与元集合反馈的引导下进行迭代更新。

在这一过程中, 元集合引导着题目选择模块如何被训练, 目标是让所选题目的分布与元集合的分布对齐, 以提升能力估计的准确性。然而实践中, 元集合本身是不平衡的。随着训练推进, 题目选择模块会过拟合这些偏斜的模式, 导致所选分布与无偏分布之间出现偏离, 从而加剧选择偏差。

考生在其正确作答的比例上各不相同: 有人表现好, 有人表现差, 也有人比较均衡。我们用这一**正确率 (correct-response ratio)**来刻画每个考生。如图 2a 所示, NIPS-EDU 数据集中元集合与所选数据的分布随这一比例而变化 (密度曲线由直方图加三次样条平滑估计得到)。对于高正确率的考生, 元集合原本集中在 0.6 附近, 但训练后会向 1.0 偏移, 表明出现了一种强化强者表现的偏差。对于低正确率的考生, 分布同样会向 0.0 偏移, 强化其欠佳表现。因此, 一个原本就不平衡的元集合, 在训练中会变得更加偏斜。这种不平衡引入了**选择偏差**: 题目选择模块倾向于给高正确率考生选更容易的题、给低正确率考生选更难的题, 而忽视他们真实的能力水平。虽然数据驱动的 CAT 模型在经验上表现很强, 但这种有偏行为违背了 CAT 的核心目标, 会导致结果失真。如图 2b 所示, 这造成了不可靠的估计——系统性地高估高表现者、低估低表现者。

图 2: 元集合的不平衡分布会引起所选集合的偏移, 从而导致对考生能力的有偏估计。图 2a: 元集合与所选集合的分布。图 2b: 有偏的能力估计。

数据驱动 CAT 中的选择偏差源于不平衡的元集合，其中诸如「低正确率考生的正确作答」或「高正确率考生的错误作答」这类罕见情形代表性不足。这种不平衡使题目选择模块过拟合常见模式、削弱了泛化能力。由于 CAT 联合优化 CDM 与题目选择模块，孤立出偏差的来源是困难的。为聚焦于选择偏差，我们固定住 CDM，并通过用「与之标签相同的平衡考生的交互」来扩充罕见情形，从而缓解题目选择模块中的不平衡。通过对这些样本做**选择性 Mixup**，我们得到一个更平衡、更具代表性的训练分布，引导题目选择模块走向更平滑、偏差更小的决策边界，从而在无偏评测下提升鲁棒性与可靠性。

本文贡献如下：

- 形式化地识别并分析数据驱动 CAT 中的选择偏差问题，将其根源追溯到训练过程中不平衡的元集合分布。
- 提出一种选择性的跨属性 Mixup 策略，扩充代表性不足的交互、增强训练多样性、强化题目选择模块的泛化能力。
- 通过在两个基准数据集上的大量实验验证所提方法，展示其在缓解偏差方面的强大能力。

2 相关工作

2.1 CAT 与认知建模中的偏差

计算机自适应测试 (CAT) 自适应地选择题目以估计考生的知识能力 [5, 17]，通常由一个用于推断能力的认知诊断模块 (CDM) 和一个用于决定下一题的题目选择模块组成。早期的 CDM 建立在项目反应理论 (Item Response Theory, IRT) [10] 及其多维扩展 [1] 之上，而近期的深度学习模型如 NCDM [23]、KaNCD [24]、RCD [11]、DCD [7] 极大地提升了表征能力与能力估计的准确性。对于题目选择模块，诸如最大 Fisher 信息量 [18]、基于 KL 散度的选择 [6]、MAAT [4]、RAT [33]、BECAT [35] 等启发式方法简单且可解释，但在捕捉复杂交互方面能力有限。更近期的数据驱动方法则利用双层优化或强化学习，包括 BOBCAT [12]、NCAT [34]、GMOCAT [25]、LACAT [8]、UATS [29]。然而，数据驱动方法往往忽视了数据与选择过程中的偏差，这可能损害 CAT 的鲁棒性。

偏差在认知建模中正越来越受到重视——预测可能在性别、社会经济地位等敏感属性上出现系统性差异 [27]。诸如对抗学习或因推理 [30, 32] 等方法已被提出以缓解此类差异。然而，CAT 中的偏差缓解仍未被充分探索。实践中，CAT 交互数据本质上受选择偏差影响，直接在这种有偏数据上训练数据驱动的 CAT 模型，会扭曲能力估计、损害系统的有效性。此前的工作如 UserAIF [16] 使用影响函数 (influence function) 来识别偏差较小的样本，并重新校准 CDM 中的题目参数。

我们的区别。此前的研究聚焦于「题目侧 (question-side)」的偏差，而我们的工作针对的是题目选择模块，从源头上缓解自适应选择带来的偏差、直接加以解决，而非施加事后 (post-hoc) 去偏，从而提升 CAT 的公平性与鲁棒性。

2.2 偏差缓解方法

机器学习系统虽能把人类从繁琐任务中解放出来、以高速完成复杂计算，但其可靠性不会超过它所训练的数据 [3]。由于算法并非有意被设计来纳入偏差，它们往往会复制甚至放大真实世界数据中存在的虚假相关 (spurious correlation)，引发对公平性与问责性的担忧 [19, 21]。为应对这些问题，人们提出了多种策略。不变风险最小化 (Invariant Risk Minimization) 旨在学习对环境不变的预测器 [2]；GroupDRO 寻求最小化最差组的风险，但需要组标签 [20]；重加权 (Reweighting) 策略调整样本重要性以对抗不平衡 [14]，但它们只是重新塑造优化权重，并不能丰富数据多样性。相比之下，基于 Mixup 的方法 [31] 通过对样本与标签做插值来正则化模型，其扩展如 Manifold Mixup [22] 和 Co-Mixup [15] 改进了隐藏表征的学习与配对选择。沿着这条思路，我们的方法采用一种选择性 Mixup 策略来缓解 CAT 中的选择偏差，利用其简单与有效来增强泛化能力。

3 预备知识

3.1 计算机自适应测试

计算机自适应测试由两个主要部件构成：一个用于能力估计的认知诊断模块，以及一个题目选择模块。下面我们详细描述这两个部件的结构。

3.1.1 认知诊断模块 认知诊断模块 (CDM) 通过拟合考生的历史作答、并预测其在未见题目上的表现，来估计考生的能力 θ 。形式上，模型输出考生答对某道题的概率 $p \in [0, 1]$ 。一个有代表性的基于神经网络的 CDM 是 NCDM [23]，它利用神经网络来捕捉考生与题目之间复杂的交互。该模型包含若干组件：考生能力向量 $\theta \in (0, 1)^K$ 、表示所需知识概念的科目概念向量 $Q_i \in \{0, 1\}^{1 \times K}$ 、知识难度向量 $h_{diff} \in (0, 1)^K$ 、一个标量区分度参数 $h_{disc} \in (0, 1)$ ，以及可训练的神经网络参数。

交互函数。第一层交互受多维项目反应理论 (MIRT) [1] 模型启发，定义为：

$$x = Q_i \circ (\theta - h_{diff}) \times h_{disc}, \quad (1)$$

其中 $\circ$ 表示逐元素相乘 (element-wise product)。

中间层由两个全连接层加一个输出层构成：

$$f_1 = \varphi(W_1 x^T + b_1), \quad (2a)$$

$$f_2 = \varphi(W_2 f_1 + b_2), \quad (2b)$$

$$p = \varphi(W_3 f_2 + b_3), \quad (2c)$$

其中 φ 表示激活函数，通常取 sigmoid。单调性假设要求：答对一道题的概率，应随考生知识能力的每个维度单调递增。为强制这一性质，NCDM 采用一个简单而有效的策略——约束 W_1, W_2, W_3 的所有元素为正。

损失函数。在预测概率 $p \in [0, 1]$ 与真实作答 y 之间采用交叉熵损失：

$$\ell(y, p) = -y \log p + (1 - y) \log(1 - p), \quad (3)$$

为简便起见，我们把模型输出记作 $M(q; \theta, \zeta_q, \zeta_n) = p$ 。这里 q 表示一道题， θ 表示考生能力， ζ_q 对应题目参数（如概念向量、难度、区分度）， ζ_n 表示可训练的神经网络参数。训练完成后，所估计的能力向量 θ 作为诊断结果，刻画考生在 K 个知识概念上的能力。

3.1.2 题目选择模块 现有的数据驱动题目选择模块通常采用双层优化框架 [12]，即在大规模考生数据上训练一个选择网络。数据集 $\mathcal{D}$ 被划分为支撑集 $\mathcal{D}_u$ 与元集合 $\mathcal{D}_m$ ，用于计算损失或奖励。作为示例，我们简要介绍 BOBCAT [12]。在每一步 t ，选择网络 $\pi(\cdot)$ 根据考生当前状态 s_t 从 $\mathcal{D}_u$ 中选择一道题 q_t ；其中 s_t 由考生的交互历史 $r = \{(q_1, y_1), \dots, (q_{t-1}, y_{t-1})\}$ 编码得到， $y_i \in \{0, 1\}$ 表示该作答是否正确。

状态 s_t 表示为一个长度等于题目数量的向量，每个分量取值于 $\{-1, 0, 1\}$ ，分别对应错误、未作答、正确。形式上，选择过程定义为：

$$q_t = \pi(s_t, \mathcal{D}_u; \zeta_s), \quad (4)$$

其中 ζ_s 表示选择网络的参数。

为训练选择网络，我们采用双层优化框架。外层循环只更新选择网络 ζ_s ，因为我们假设题目选择模块是偏差的主要来源。CDM 保持固定，其参数 (ζ_q, ζ_n) 经预训练后冻结，而能力表征 θ 则在内层优化中被更新。训练完成后，选择网络仅依据每个考生当前的作答状态为其生成下一道题。数据驱动题目选择整体双层优化过程可概括如下，分为内层与外层优化。

内层优化。给定一个被选出的题目序列，在固定题目参数 (ζ_q, ζ_n) 的条件下，通过最小化考生在支撑集 $\mathcal{D}_u$ 上作答的预测损失来估计其能力 θ_i 。经此过程， θ_i 被更新以得到估计的能力向量 θ_i^* ：

$$\theta_i^* = \arg \min_{\theta_i} \sum_{t=1}^T \ell(y_{i, q_t}, M(q_t; \theta_i, \zeta_q, \zeta_n)), \quad (5)$$

其中 T 表示被选出的题目数量。

外层优化。选择网络 ζ_s 通过最小化元集合 $\mathcal{D}_m$ 上的预测损失来更新；其中使用内层优化得到的固定能力 θ_i^* 以及预训练的 CDM 参数 (ζ_q, ζ_n) ：

$$\min_{\zeta_s} \frac{1}{N} \sum_{i=1}^N \sum_{q_j \in \mathcal{D}_m} \ell(y_{i, q_j}, M(q_j; \theta_i^*, \zeta_q, \zeta_n)), \quad (6)$$

其中 N 表示考生数量。在我们的框架中，关键贡献在于这一外层优化阶段引入基于 Mixup 的数据增强，从而增强选择网络的鲁棒性、缓解偏差。

3.2 记号与问题设定

我们依据考生正确作答的比例，把 $\mathcal{D}_m$ 中的考生划分为三组： $\mathcal{D}_m^A, \mathcal{D}_m^B, \mathcal{D}_m^C$ 。这些组反映了元集合中的不同分布。令 $\mathcal{A} = \{A, B, C\}$ 表示属性类别的集合。

- **A**：正确作答比例落在 $[0, 0.4]$ ，以错误作答为主。
- **B**：正确作答比例落在 $(0.4, 0.6]$ ，正确与错误作答大致平衡。
- **C**：正确作答比例落在 $(0.6, 1.0]$ ，以正确作答为主。

我们还定义标签集 $\mathcal{Y} = \{0, 1\}$ ，其中 0 表示错误作答、1 表示正确作答。一个「组 (group)」被定义为属性 $a \in \mathcal{A}$ 与标签 $y \in \mathcal{Y}$ 的一种唯一组合。据此，交互可被归为三类：

- **偏差对齐样本 (Bias-aligned samples)**: 遵循主导属性模式、通常更易学习的交互, 例如标签为 0 的 $\mathcal{D}_m^A$ 或标签为 1 的 $\mathcal{D}_m^C$ 。
- **无偏样本 (Unbiased samples)**: 来自 $\mathcal{D}_m^B$ 的交互, 作答相对平衡、不表现出强偏差, 被视为中性。
- **偏差冲突样本 (Bias-conflicting samples)**: 偏离主导属性模式、更难学习的交互, 例如标签为 1 的 $\mathcal{D}_m^A$ 或标签为 0 的 $\mathcal{D}_m^C$ 。

在 CAT 中, 假定考生的真实能力 θ_i^* 保持恒定, 传统方法力求让最终估计 θ_i^T 尽可能逼近它。相比之下, 我们的工作聚焦于缓解数据驱动题目选择模块中的选择偏差, 在维持对分布漂移鲁棒的同时, 产出更准确、更无偏的能力估计。

4 方法

本节介绍我们缓解数据驱动 CAT 中偏差的方法。该方法通过一种由考生属性引导的选择性 Mixup 策略, 针对元集合中的选择偏差。通过从平衡的作答画像中生成增强样本, 它丰富了代表性不足的情形, 使题目选择模块能够学习更平滑、偏差更小的决策边界。该方法简单却有效, 可无缝集成进数据驱动的 CAT 题目选择中。此外, 它只需对现有训练流程做轻微改动, 因而计算高效、易于实现。这些特性确保所提方法能够便捷地应用于实际的教育评估系统。

4.1 总览

我们的方法通过一个两阶段框架缓解 CAT 中的选择偏差: **跨属性考生检索与选择性 Mixup 正则化**, 如图 3 所示。第一阶段, 对于 $\mathcal{D}_m^A$ 或 $\mathcal{D}_m^C$ 中的每个考生, 基于作答模式从 $\mathcal{D}_m^B$ 中检索出最相似的对应者。第二阶段, 重点放在偏差冲突样本上, 例如来自 $\mathcal{D}_m^A$ 的正确作答或来自 $\mathcal{D}_m^C$ 的错误作答。为丰富这些代表性不足的情形, 将 $\mathcal{D}_m^B$ 中的每个考生与一个来自 $\mathcal{D}_m^A$ 或 $\mathcal{D}_m^C$ 的对应者配对, 并且仅当两者交互标签一致时才施加 Mixup。最终的训练目标把「原始数据上的经验损失」与「来自合成样本的正则化」结合起来, 从而在有偏的元分布下增强题目选择模块的鲁棒性与泛化能力。在以下各节中, 我们主要聚焦于外层优化, 这些去偏策略正是应用于此处。

图 3: 我们用于计算机自适应测试的去偏框架总览。该方法包含两个阶段: (1) 跨属性考生检索——基于能力相似度, 从 $\mathcal{D}_m^B$ 中检索出中等表现者作为 $\mathcal{D}_m^A$ 与 $\mathcal{D}_m^C$ 中考生的中性参照; (2) 选择性 Mixup 正则化——在检索到的中等表现者与其匹配对应者 (标签一致) 之间施加 Mixup 以生成合成训练样本。这种增强降低了对偏差对齐模式的依赖, 从而缓解题目选择模块中的偏差。

4.2 跨属性考生检索

在真实的 CAT 场景中, 训练数据常受选择偏差之苦: $\mathcal{D}_m^A$ 中的考生更可能答错, 而 $\mathcal{D}_m^C$ 中的考生倾向于答对。这导致偏差对齐交互占据主导——它们容易拟合, 但易于「捷径学习 (shortcut learning)」, 鲁棒性差。相比之下, 偏差冲突情形 (例如来自 $\mathcal{D}_m^A$ 的正确作答或来自 $\mathcal{D}_m^C$ 的错误作答) 罕见, 却对实现公平与泛化至关重要。为缓解这种不平衡, 我们利用 $\mathcal{D}_m^B$ 中的考生, 他们平衡的作答模式可作为扩充代表性不足情形的可靠参照, 这也正是我们选择性 Mixup 设计的动机。具体而言, 对每个具有属性 $a \in \{A, C\}$ 的考生 e_a , 我们基于 CDM 估计的认知能力向量 θ^* , 检索出具有属性 $b \in B$ 、与之最相似的考生 e_b 。考生间的相似度用标准 L_2 范数距离来度量:

$$\text{similarity}_{i,j} = \|\theta_i^* - \theta_j^*\|_2 \quad (7)$$

其中 θ_i^* 与 θ_j^* 分别表示考生 i 与 j 的潜在知识能力向量。

这一检索过程有两重目的: 第一, 它把偏差冲突交互锚定到「语义相似但统计上更平衡」的样本上; 第二, 它为后续的增强奠定基础。通过把 $\mathcal{D}_m^A$ 与 $\mathcal{D}_m^C$ 中的考生与来自 $\mathcal{D}_m^B$ 的合适参照对齐, 该方法有效地在有偏的两极之间架起桥梁, 并促成下一阶段更平滑的决策边界学习。

4.3 基于选择性 Mixup 的正则化

为进一步缓解选择偏差, 我们提出一种选择性 Mixup 增强策略 [31]。不同于仅依赖自然出现样本的常规训练, Mixup 通过对实例插值来生成合成交互, 从而大幅丰富偏差冲突数据的多样性。这在 CAT 中尤为重要, 因为此类情形的稀缺常导致题目选择模块过拟合偏差对齐模式、忽视少数派交互。在此情境下, Mixup 带来若干优势: 平滑决策边界、减少过拟合, 并在测试分布与训练分布不同时提升泛化能力。此外, 通过稀释原始数据中虚假相关的影响, Mixup 促使模型学习更平衡、更鲁棒的表征。借助这种增强, 题目选择模块被引导向更公平、更可靠的预测, 提升了在分布漂移下的鲁棒性与泛化能力。

偏差冲突样本生成。 给定 $q_i \in \{\mathcal{D}_m^A, \mathcal{D}_m^C\}$, 其能力上最相似的对应者已在上一阶段从 $\mathcal{D}_m^B$ 中检索得到。从这个匹配到的 $\mathcal{D}_m^B$ 考生中, 采样一个与之具有相同真实标签 y 的交互 q_j , 并与 q_i 配对, 在其上通过凸组合 (convex combination) 生成合成的偏差冲突样本。有了这样的配对题目 (q_i, q_j) , 我们对它们的参数做插值, 生成多样的合成题目、丰富训练分布, 构成合成集合 $\mathcal{D}_{syn}$ 。所得的表征 Mixup 定义为关键参数的加权插值, 其中 $\lambda \sim \text{Beta}(\alpha, \alpha)$ 、 $\alpha \in [0, 1]$ 控制强度, 如下所示:

$$Q_{i,j} = \lambda Q_i + (1 - \lambda) Q_j, \quad (8a)$$

$$h_{i,j}^{diff} = \lambda h_i^{diff} + (1 - \lambda) h_j^{diff}, \quad (8b)$$

$$h_{i,j}^{disc} = \lambda h_i^{disc} + (1 - \lambda) h_j^{disc}, \quad (8c)$$

合成特征构建。把合成出的特征喂入 CDM, 计算其对应的作答概率 $M(q_{i,j}; \theta_i^*, \zeta_{q_{i,j}}, \zeta_n)$ 。由于 Mixup 只在标签相同的样本之间施加, 合成样本保留该标签。这些增强样本的损失定义为:

$$\mathcal{L}_{syn} = \frac{1}{N} \sum_{i=1}^N \sum_{q_{i,j} \in \mathcal{D}_{syn}} \ell(y_{i,q_{i,j}}, M(q_{i,j}; \theta_i^*, \zeta_{q_{i,j}}, \zeta_n)), \quad (9)$$

去偏优化。最终的外层优化目标在式 (6) 基础上扩展, 表示为经验风险最小化与合成样本正则化的组合:

$$\mathcal{L}_{emp} = \frac{1}{N} \sum_{i=1}^N \sum_{q_j \in \mathcal{D}_m} \ell(y_{i,q_j}, M(q_j; \theta_i^*, \zeta_{q_j}, \zeta_n)), \quad (10)$$

$$\min_{\zeta_s} \mathcal{L}_{final} = \mathcal{L}_{emp} + \omega \mathcal{L}_{syn}, \quad (11)$$

其中 ω 是平衡真实样本与合成样本的正则化系数。

这种双目标设计鼓励模型在真实数据上保持强预测性能的同时, 增强对偏差冲突情形的鲁棒性。在外层优化中, 题目选择模块参数 ζ_s 通过在组合损失上做梯度下降来更新。训练过程的完整总览——结合基于 Mixup 的增强与偏差感知优化——见算法 1, 它总结了关键步骤并说明这些组件如何被整合进整体框架。

算法 1: 去偏 CAT 的训练过程

1. 用预训练值 (ζ_q, ζ_n) 初始化认知诊断模块中的考生能力参数 θ , 并初始化题目选择模块的 ζ_s 。指定学习率 α 与 β 、内层优化的梯度下降步数 K 、以及测试步数 T 。
2. **while** 未收敛 **do**
3. 随机采样一个小批量考生 $\mathcal{D}$, 含支撑集与元集合 $\{\mathcal{D}_u, \mathcal{D}_m\}$, 其中 $\mathcal{D}_m = \mathcal{D}_m^A \cup \mathcal{D}_m^B \cup \mathcal{D}_m^C$ 。
4. **for** $t = 1$ 到 T **do**
5. 用考生的作答历史表示 $s_{i,t}$ 。
6. 基于当前状态 $s_{i,t}$ 为每个考生选择题目 $q_{i,t}$ (式 (4))。
7. 内层更新: 以学习率 α 在式 (5) 的预测损失上做梯度下降更新 θ_i , 重复 K 步, 得到 θ_i^* 。
8. 对 $\mathcal{D}_m^A$ 与 $\mathcal{D}_m^C$ 中的考生, 用式 (7) 从 $\mathcal{D}_m^B$ 检索最相似的考生。
9. 用式 (8) 与式 (9) 施加选择性 Mixup 正则化, 生成丰富训练分布的合成偏差冲突样本。
10. 外层更新: $\zeta_s \leftarrow \zeta_s - \beta \nabla_{\zeta_s} \mathcal{L}_{final}$ (式 (11))。
11. **end for**
12. **end while**
13. **return** 估计的能力 $\{\theta_i^*\}_{i=1}^N$ 与去偏后的题目选择模块 π 。

表 1: 数据集统计。

数据集	ASSIST0910	NIPS-EDU
考生数	1,360	4,918
题目数	17,372	948
概念数	119	86
交互数	241,156	1,382,727

原理与影响。通过在属性 A 或 C 的样本与其来自属性 B 的对应参照之间插值, 我们的方法把平衡的、标签一致的合成数据引入训练过程。这阻止了题目选择模块过拟合主导的作答模式, 并鼓励它捕捉题目难度与能力之间更细致的关系。结果是模型更少依赖有偏的历史分布, 从而提升鲁棒性、在多样化考生上缓解偏差。

5 实验

本节中, 我们首先介绍数据集与实验设置, 然后在真实世界的基准数据集上进行大量实验。实验所用代码已公开: <https://github.com/xiaoluobou/MDCAT>。

5.1 实验设置

本节给出数据集、所选基线，以及 CAT 的应用方式。所有模型均用 PyTorch 实现，并在一块 NVIDIA RTX 4090 GPU 上训练，以确保实验高效且一致。

数据集描述。我们在两个广泛使用的教育数据集上做实验。ASSIST0910 数据集包含来自 ASSISTments 在线辅导系统的考生练习日志，聚焦数学与知识概念题。NIPS-EDU 数据集发布于 NeurIPS 2020 教育挑战赛，由 Eedi 学习平台收集的考生作答构成，我们使用其中 Task 3 与 Task 4 的交互数据。对于 ASSIST0910，我们移除含缺失值的记录、并剔除交互少于 40 次的考生。数据集统计（考生、题目、概念、交互数量）汇总于表 1。

划分。我们随机把考生划分为训练集（60%）、验证集（20%）、测试集（20%）。评估时，我们在每个数据集上做 5 折验证，每一折使用不同随机种子。每一折内，把每个考生作答的题目进一步分为支撑集（ $\mathcal{D}_u$ ，80%）与元集合（ $\mathcal{D}_m$ ，20%），并为缓解过拟合，在每个训练 epoch 开始时重新生成这些划分。在独立同分布（IID）设定下，测试划分也随机采样。相比之下，分布外（out-of-distribution, OOD）设定遵循不同的划分策略，详见第 5.2 节。

表 2：在无偏的 ASSIST0910 与 NIPS-EDU 数据集上、基于 IRT 与 NCDM 认知诊断的不同 CAT 模型性能。结果分别报告 Metrics@5（上半块）与 Metrics@10（下半块）。Worst 指最差组准确率，Avg. 指总体平均准确率。（此处为原文表 2，结构复杂，下文给出关键数值。）

表 2 关键数值（OOD 评测）：在 ASSIST0910 上、NCDM-BOBCAT、Metrics@5 时，本方法把 Worst 从 0.3662（ERM）提升到 0.4989；在 ASSIST0910 上、IRT-BOBCAT、Metrics@10 时，把 Worst 从 0.4088（ERM）提升到 0.4489。Avg. 指标上，最大增益出现在 ASSIST0910、Metrics@10，从 0.6091 提升到 0.6155（相对提升约 1.05%）。

评估。我们评估所有方法在元集合 $\mathcal{D}_m$ 上预测二值作答的能力，使用两个互补指标：最差组准确率（Worst-group accuracy, Worst）与总体平均准确率（Avg.）。Worst 指标通过聚焦最弱势的组来反映模型鲁棒性，而 Avg. 指标刻画在所有考生上的整体预测性能。

基线方法。对于 CDM，我们采用 1PL IRT 模型 [10] 与 NCDM [23]，两者均在 EduStudio 框架 [26] 中实现。对于 CAT 框架，我们考虑把 CAT 表述为通过元学习求解的双层优化问题的数据驱动方法，包括 BOBCAT [12] 与 UATS [29]。BOBCAT 引入了一个可学习的题目选择模块，而 UATS 采用可微的分层优化框架以提升效率与适应性。为更好地分析题目选择中的偏差，我们在外层循环优化期间冻结 CDM 的题目参数，并用预训练值初始化它们。

为验证方法有效性，我们将其与以下去偏基线比较，它们都在同一双层训练框架内实现、并适配到 CAT 设定，以确保在不同情形下评估一致。

- **ERM（经验风险最小化）**：在整个元集合上最小化平均预测损失，不显式应对分布偏差。它是一个标准基线，但往往过拟合主导的偏差对齐模式。
- **IRM [2]（不变风险最小化）**：鼓励能在不同环境间产生一致预测的特征表征。在我们的设定中，通过采样具有不同属性值（A、B、C）的考生来模拟多个环境。这一做法确保题目选择模块在这些多样分布上都鲁棒。
- **GroupDRO [20]（组分布鲁棒优化）**：提升在预定义组上的最差情形性能。它通过最小化最大的组级损失来优化题目选择模块。该策略有助于防止在代表性不足或困难的子群体上崩溃。
- **Reweight [14]**：通过在训练中给偏差冲突样本赋更大权重来缓解不平衡。这引导模型更好地捕捉代表性不足的模式、减少对偏差对齐数据捷径信号的依赖。

参数设置。在 NCDM 中，两个隐藏层分别含 128 与 64 个神经元，用于控制网络的容量与复杂度，使其能捕捉考生与题目之间的非线性关系。Beta 分布的 α 参数从 $\{0.2, 0.4, 0.6, 0.8, 1.0\}$ 中选取，Mixup 损失中的混合系数 ω 从同一范围内选取，以确保一致的正则化强度。为逼近每个考生的能力，内层优化对潜在能力向量更新 K 次，本文实验取 $K = 5$ ，以在准确性与计算成本间取得平衡。

5.2 OOD 设定下的性能

动机。在多数现有数据驱动 CAT 研究中，用于评估题目选择性能的元集合是直接每个考生原始交互日志中采样的。这种做法隐含假设：观测到的作答分布忠实反映了考生真实的暴露与能力画像。然而实践中，这一假设是有问题的。因为 CAT 基于估计能力自适应地选题，考生只暴露于整个题库中有限且有偏的一个子集。结果是，元集合往往捕捉到的是选择所诱发的人造痕迹（selection-induced artifacts），而非真实能力，导致评估有偏且不具代表性。

为评估去偏策略的有效性，我们设计了一个分布外（OOD）测试设定。训练与验证划分与 IID 设置完全相同，只修改测试划分来构造 OOD 场景。具体地，我们的协议为每个考生在元集合中强制 1:1 的正确与错误作答平衡，其余交互归入支撑集。无法满足该平衡约束的考生被剔除。这一设计在保留标准双层框架的同时，刻意引入了分布漂移。结果是，它为评估模型鲁棒性与泛化提供了一个更严格、更可解释的基准，尤其是在评估于有偏条件下进行时。

如表 2 所示，我们的方法在两个数据集与两种诊断设定下，都在缓解选择偏差上展现出明显优势。当所选题目数从 5 增至 10 时，偏差变得更明显。Worst 指标大幅下降而 Avg. 指标相对稳定，表明更长的测试视野对代表性不足的组造成了不成比例的不利。我们方法的改进集中在 Worst 指标上，相对增益在 2.7% 到 24.64% 之间，而 Avg. 指标只提升约 0.1%–1.05%。例如，在 ASSIST0910 上、NCDM-BOBCAT、

Metrics@5 时，我们的方法把 Worst 从 0.3662 (ERM) 提升到 0.4989；在 ASSIST0910 上、IRT-BOBCAT、Metrics@10 时，把 Worst 从 0.4088 (ERM) 提升到 0.4489。Avg. 指标上，最大增益出现在 ASSIST0910、Metrics@10，从 0.6091 提升到 0.6155，相对提升 1.05%。总体上，这些结果表明我们的方法主要通过提升弱势组性能来增强鲁棒性，同时维持有竞争力的总体准确率。这与去偏框架的首要设计目标一致——减少不同组之间的系统性差异，同时确保总体性能不被牺牲、保持模型的有效性。

5.3 IID 设定下的性能

如表 2 与表 3 所示，去偏不可避免地在 IID 与 OOD 性能之间引入权衡。虽然 Reweight 与我们的方法能有效缓解偏差、提升 OOD 泛化，但它们在 IID 设定下无法超越 ERM 或 GroupDRO——后者天然更有利于那些不带去偏约束优化的模型。例如，IRM 在 ASSIST0910 上取得最佳平均性能 (0.6939)，而 ERM 在 NIPS-EDU 上取得最高平均 (0.6930)。GroupDRO 在两个数据集上也给出相对较强的 IID 结果。相比之下，我们的方法优先考虑鲁棒性：在 OOD 条件下，它在 Worst 与 Avg. 准确率上都持续超过 Reweight 基线，同时在分布内保持竞争力。这些结果证实，包括我们在内的去偏方法，用少量 IID 准确率换取了显著更强的 OOD 泛化。这一发现清楚地凸显了面向鲁棒性的学习中固有的平衡与权衡。

表 3: 作为参照纳入的 IID 结果，以说明分布内条件下的性能。(IRT-BOBCAT、Metrics@10: ASSIST0910 上本方法 Worst=0.5310、Avg.=0.6599；NIPS-EDU 上本方法 Worst=0.4911、Avg.=0.6695，Worst 均为各方法最高。)

图 4: Mixup 正则化权重 ω 在 NIPS-EDU 数据集上的超参数敏感性。

5.4 超参数分析

我们在 NIPS-EDU 数据集上对 Mixup 正则化权重 ω 做超参数分析，考察它在两种认知诊断模型与两种 CAT 框架下对 Worst 与 Avg. 准确率的影响。如图 4 所示，不同的 CDM-CAT 组合表现出不同行为：NCDM-BOBCAT 与 IRT-UATS 随 ω 增大呈稳步上升，表明更强的正则化对这些设定持续有益；而 IRT-BOBCAT 与 NCDM-UATS 则呈先升后降的模式，性能在中等 ω 处提升，但当正则化过强时下降。这表明虽然 Mixup 总体有效，但过强的插值可能引入抵消其去偏效果的噪声。总体而言，曲线在较宽的 ω 取值范围内保持相对稳定，说明我们的方法对该超参数并不高度敏感。值得注意的是，Avg. 与 Worst 指标并不总在同一 ω 处达到峰值，揭示了公平与泛化之间的权衡，需要谨慎校准才能取得平衡的改进。

5.5 消融研究

我们做消融研究以评估三种 Mixup 策略：Mixup-Self、Mixup-Inner、Mixup-B。在 Mixup-Self 中，交互在同一考生内部插值，把合成变化引入个体画像，偶尔能提升鲁棒性。Mixup-Inner 在同一属性内最相似的考生之间插值，平滑局部表征、减少对个体特异模式的过拟合。相比之下，Mixup-B 把有偏考生（如来自属性 A 或 C）与平衡对应者（属性 B）插值。通过显式生成偏差冲突交互，该策略丰富了代表性不足的模式，也提供了一种更有效、更有原则的方式来缓解选择偏差，从而提升模型鲁棒性。

如图 5 所示，Mixup-B 始终取得最佳性能，尤其在大规模的 ASSIST0910 数据集上——其更大的题库提供了更大的多样性、放大了跨属性混合的收益。在 NIPS-EDU 上，尽管数据集较小，同样的趋势依然成立，Mixup-B 在 Worst 与 Avg. 上都带来最稳定的改进。这些结果表明跨属性插值的优势并不局限于单一数据集，而是能很好地泛化到不同的 CAT 设定。同时，比较显示 Mixup-Self 与 Mixup-Inner 可带来局部增益，但其不稳定性使其不够可靠。总体上，这些发现证实偏差冲突增强对于提升鲁棒性是核心所在，并为未来工作中「组合多种 Mixup 策略的混合设计」指出了有希望的方向。

图 5: 不同 Mixup 策略 (Mixup-Self、Mixup-Inner、Mixup-B) 在 ASSIST0910 与 NIPS-EDU 上、就 Worst@10 与 Avg.@10 的消融结果。

5.6 缓解题目选择中的分布漂移

虽然前面的结果展示了我们的方法在 OOD 条件下提升题目选择模块性能的有效性，我们进一步通过分析它所引入的分布差异来考察其机制。具体地，图 6 展示了在 ERM 基线与我们方法下，考生中正正确率的分布。对于属性 A 的考生，我们的方法把分布推向更适中的范围 (0.4 附近)，表明更少地选了过难的题、降低了「过度挑战」的风险。对于属性 C 的考生，向极易题目的偏斜被有效缓解，分布以 0.6 为中心，而非像 ERM 那样趋近 1.0，整体上更少地过拟合偏差对齐模式。

图 6: 各考生所选题目正确率的分布。

总体而言，这些结果表明我们的方法有效缩小了所选题目分布与元集合之间的差距，在各考生间产生了更平衡、更具代表性的选择。通过丰富偏差冲突样本，它在把选择对齐到更公平目标分布的同时，更好地保留了个体特征，确保能力估计反映的是真实能力，而非不平衡训练数据的人造痕迹。继而，这带来了更好的泛化、更强的鲁棒性，以及更可靠的评估结果。

6 结论

本研究识别并应对了数据驱动计算机自适应测试中的选择偏差问题，聚焦于训练过程中元集合分布的不平衡。我们提出一种由中等表现考生引导的 Mixup 策略，以扩充代表性不足的交互、增强题目选择模块的泛化能力。该方法简单、有效，可无缝集成进数据驱动的 CAT 训练流程。在两个基准数据集上的实验表明，我们的方法在缓解偏差的同时提升了准确率。通过合成数据生成来丰富偏差冲突样本，模型学到了更鲁棒、偏差更小的决策边界。这项工作凸显了在智能教育系统中缓解偏差的重要性，并提出「在选择过程内部直接应对偏差」是未来研究的一个有希望方向。进一步的研究可探索把去偏策略与 CAT 的其他组件相结合，以在可靠性与有效性上取得更广泛的改进。

7 生成式 AI 使用声明

本文使用了生成式 AI 工具（如 ChatGPT）进行非实质性的辅助，例如语言润色、语法修正、简单代码生成与写作建议。所有技术内容、实验与核心贡献均由作者独立构思与实现。

致谢

本研究部分受以下基金资助：国家科技重大专项（No. 2021ZD0111802）、国家自然科学基金（Nos. 62376086, 62406096）、中央高校基本科研业务费（No. JZ2025HGTG0289）、中国博士后科学基金（No. 2024M760722）。计算在合肥工业大学 HPC 平台上完成。

参考文献 (*References*) 按约定未翻译，详见原文。