

面向高利害考试的试卷级计算机自适应测验：基于多目标优化 (Paper-Level Computerized Adaptive Testing for High-Stakes Examination via Multi-Objective Optimization)

原文: pcat-paper-level-cat-moo_8.pdf (KDD '25) ·译者: Claude ·译于 2026-06-26 术语对照: Computerized Adaptive Testing 计算机自适应测验 (CAT) ·Paper-level CAT 试卷级 CAT (PCAT) ·Cognitive Diagnosis Model 认知诊断模型 (CDM) ·Multi-Objective Optimization 多目标优化 (MOO) ·Pareto front 帕累托前沿 ·attribute coverage 属性覆盖 (COV) ·question exposure 题目曝光 (EXP) ·high-stakes examination 高利害考试 ·paper assembly 组卷

摘要

计算机自适应测验 (Computerized Adaptive Testing, CAT) 是一种用相对较少的题目就能准确推断学生能力水平的测验技术。大多数现有 CAT 系统运行在「题目级 (question-level) 自适应」范式上, 适合练习场景。然而, 在 GRE、GMAT 这类计算机化的标准化高利害考试中, 这一范式面临几个挑战: (1) 考试结果缺乏可比性; (2) 由于依赖实时交互、以及维护 CAT 测验系统的财务负担, 实施成本高; (3) 难以在诊断质量、属性覆盖、题目曝光等多个因素之间取得平衡。为应对这些挑战, 我们提出了试卷级计算机自适应测验 (Paper-level Computerized Adaptive Testing, PCAT) 及其相应的评测方法。PCAT 把一场考试划分为多个测验阶段, 考生根据其在前面阶段的表现, 自适应地拿到不同难度的试卷。PCAT 中的组卷 (paper assembly) 问题用一种基于种群 (population-based) 的多目标优化 (MOO) 方法求解。PCAT 有几个优势: 第一, 试卷级自适应机制保证考生面对的题目只取决于他/她在前面阶段的表现, 在保持自适应性的同时增强了不同考生之间结果的可比性。第二, PCAT 用一个组卷模块替换掉传统 CAT 的选题策略模块, 使得认知诊断、组卷这类计算密集任务可以在考前离线完成, 无需实时交互。此外, 基于种群的 MOO 方法一次运行就能生成一组高质量解, 满足 GRE 等标准化高利害考试频繁施测的需求, 并降低维护大规模 CAT 系统的财务负担。最后, MOO 天然地把多个因素建模为各自独立的目标, 从而能够平衡地考虑这些因素, 并允许考试管理者根据具体需求定制考试。在四个真实世界数据集上的大量实验表明, PCAT 在诊断质量、属性覆盖、题目曝光三方面均优于当前最优 (SOTA) 的 CAT 方法, 且考生作答的题量相同。这些结果凸显了 PCAT 在高利害考试场景中的潜力。

CCS 概念: 应用计算 → 教育; 计算方法学 → 机器学习。

关键词: 计算机自适应测验, 组卷, 多目标优化, 高利害考试。

1 引言

智能教育的图景正在快速演进, 其标志是个性化学习方法、基础模型 (foundation model) 增强的智能辅导系统、以及学习规律的自动发现等创新。在此背景下, 计算机自适应测验 (CAT) 已成为一种关键方法, 相比传统的纸笔测验 (paper-and-pencil testing) 有显著进步。通过根据学生持续的作答动态调整题目的难度和内容, CAT 旨在为每个学习者提供个性化、高效的诊断服务。

与传统纸笔测验不同, CAT 以「一轮接一轮」的方式与考生交互, 自适应地挑选契合考生能力水平的题目, 从而快速、准确地评估其能力。如图 1(b) 所示, 一个典型的 CAT 系统由几个关键组件构成, 并遵循特定工作流程: 在每个交互轮次中, 认知诊断模型 (cognitive diagnosis model, CDM, 常被称为「学生画像模块」) 根据考生当前作答估计其能力水平; 随后, 选题模块利用这个能力估计为考生挑出下一道最合适的题目。

大多数现有 CAT 运行在「题目级自适应」范式上, 已被证明能在练习测验中为学生提供定制化、高效的测验体验。然而, 对于 GRE、GMAT 这类高利害考试场景, 现有 CAT 方法面临几个挑战:

- **缺乏可比性:** 给不同考生提供完全不同的题目, 会妨碍对考生横向比较的能力。这降低了考试结果的透明度和说服力, 而这在高利害考试中尤为关键。
- **实施成本高:** 现有 CAT 系统依赖与考生的实时交互, 需要频繁更新 CDM。这不仅拉长了考试时长, 还增加了维护大规模 CAT 系统的财务负担, 尤其在网络不稳定或计算资源有限的环境中。此外, GRE 等标准化考试需要频繁施测, 进一步加剧了这些成本, 因为传统 CAT 系统难以高效生成和管理大量试卷。
- **难以平衡多个因素:** 传统 CAT 系统往往优先考虑测验的有效性和效率, 而较少关注属性覆盖、题目曝光等其他因素。平衡这些因素对于保证高利害考试的质量、多样性和安全性至关重要。

为应对这些挑战, 本文提出试卷级计算机自适应测验 (PCAT), 专为计算机化高利害考试设计。如图 1(c) 所示, PCAT 把考试划分为多个测验阶段, 考生根据其在前面阶段的表现自适应地拿到不同难度的试卷。与使用题目级自适应范式的传统 CAT 不同, PCAT 用一个离线的组卷模块替换在线选题策略。该模块利用基于种群的 MOO 方法生成平衡多个因素的高质量试卷, 这些因素包括诊断质量、属性覆盖 (attribute coverage, 「属性」指与题目关联的知识概念)、题目曝光。

PCAT 相比传统 CAT 系统有几个优势。第一, 通过采用试卷级自适应机制, PCAT 保证考生面对的题目只取决于他/她在前面阶段的表现。这既保持了测验的自适应本质, 又增强了不同考生结果的可比性, 从而提升考试结果的透明度和说服力。第二, PCAT 把 CDM 更新、选题这类计算密集任务转移到考前的离线组卷阶段。这消除了对实时交互的需求, 保证了考试过程的可控性, 并增强了它对设备、网络等不良条件的鲁棒性。此外, 基于种群的 MOO 方法一次运行就能生成多套高质量试卷, 满足频繁施测的需求。这些特性合在一起, 显著降低了在计算机化高利害考试中应用

CAT 的实施成本。最后, MOO 天然地把多个因素建模为各自独立的目标, 从而能够平衡地考虑诊断质量、属性覆盖、题目曝光。这种灵活性让考试管理者能根据具体需求定制组卷, 例如对参加人数众多的考试优先压低题目曝光。

在四个真实世界数据集上的大量实验结果表明, PCAT 与现有 CAT 范式下的 SOTA 方法相比, 在诊断质量、属性覆盖、题目曝光三方面均取得更优表现, 且考生作答的题量相同。具体来说, PCAT 在四个数据集上的准确率 (accuracy) 平均超过 SOTA 5%。这些发现强调了 PCAT 作为高利害考试场景下 CAT 的一种可行且有效解决方案的潜力。

本文余下部分组织如下。第 2 节全面回顾相关工作。第 3 节形式化 PCAT 任务并引入为 PCAT 量身定制的新评测方法。第 4 节给出 PCAT 框架的技术细节, 包括解的表示、适应度评估和 MOO 工作流程。第 5 节描述实验设置、数据集、对比方法, 并详细分析结果。最后, 第 6 节总结全文并讨论未来研究方向。

图 1: 三种范式的对比——(a) 传统纸笔测验, (b) 计算机自适应测验, (c) 试卷级计算机自适应测验。

2 相关工作

2.1 计算机自适应测验

传统 CAT 方法大致可分为基于统计的方法和机器学习驱动的方法。统计框架, 如费舍尔信息 (Fisher Information, FI) 和 KL 信息 (Kullback-Leibler Information, KLI), 构成了经典 CAT 系统的基础。FI 选择能在考生当前能力估计附近最大化局部信息的题目, 而 KLI 通过整合全局散度量来增强测验早期阶段的鲁棒性。近期的扩展, 如题目选择多目标优化 (Multi-Objective Optimization of Item Selection, MOOIT), 利用遗传算法对测验长度与精度之间的权衡建模, 通过帕累托最优 (Pareto-optimal) 解显式平衡估计准确性和测验效率。然而, 这些方法仍受限于僵硬的心理测量学假设, 难以应对属性覆盖、题目曝光控制等多方面挑战。

近年来, 机器学习驱动的方法通过数据驱动的学习与优化自动化了自适应策略, 彻底革新了 CAT。基于强化学习 (reinforcement learning, RL) 的方法, 如图增强多目标 CAT (GMOCAT) 和神经 CAT (NCAT), 是这一转变的典型: GMOCAT 把图神经网络与多目标 RL 结合, 同时优化多个因素; NCAT 在 CAT 的 RL 表述下采用 transformer 架构捕捉复杂的考生-题目交互。以双层优化 CAT (BOBCAT) 为代表的元学习技术采用双层优化训练与模型无关的选题策略, 能在各种测验场景间快速适应。面向搜索与优化的方法进一步提升了可扩展性和效率: 有界估计 CAT (BECAT) 把 CAT 重新定义为带理论误差保证的梯度驱动子集选择问题; 搜索高效 CAT (SECAT) 通过分层索引和多轮搜索策略降低时间复杂度; 统一自适应测验 (UAT) 引入分层结构搜索框架, 在理论保证下统一各种测验形式。作为补充, 受主动学习启发的方法, 如与模型无关的自适应测验 (MAAT), 通过不确定性采样和代表性度量来优先考虑题目多样性。

尽管有这些进步, 现有方法都遵循「一人一卷 (one-for-each)」范式, 为每个考生实时生成独特的题目序列。虽然对个性化评估有效, 但这一做法在高利害标准化考试中引入了关键局限: 实时计算带来的高昂实施成本, 以及可比性问题。

2.2 基于种群的多目标优化

MOO 通过寻找在各目标间平衡权衡的帕累托最优解, 来处理目标相互冲突的问题。经典 MOO 方法包括遗传算法 (如 NSGA-II, 它用非支配排序和拥挤距离维持解的多样性), 以及基于分解的方法 (如 MOEA/D, 它把 MOO 转化为标量子问题)。这些基于种群的方法擅长在单次优化运行中生成多样的解集, 适合需要多个高质量备选方案的场景。

在 CAT 语境下, 已有若干研究探索用 MOO 平衡诊断准确性、测验效率、题目多样性等多个因素。例如, 题目选择 MOO (MOOIT) 用遗传算法对测验长度与精度之间的权衡建模, 通过帕累托最优解显式平衡估计准确性和测验效率。类似地, 基于 RL 的方法如 GMOCAT 把 MOO 与自适应策略结合, 同时优化多个因素。这些方法虽然能有效平衡多个目标, 但仍局限于传统 CAT 范式, 其优化过程是实时针对单个考生定制的。

此外, 在组卷 (test assembly) 领域——它同样涉及试卷的构造——现有方法主要聚焦于无自适应机制的单阶段场景。值得注意的是, 并行组卷 (parallel test assembly) 方法同时生成多套试卷, 在批处理方面与我们的设定有相似之处, 但这些方法仍局限于非自适应的试卷构造。具体而言, AR-DMOE 提出了一种基于 MOO 的「即时组装多阶段自适应测验」方法。虽然 AR-DMOE 涉及多个测验阶段, 但它仍遵循「一人一卷」范式, 不同考生拿到不同的题目序列, 因此仍面临保证学生间可比性的挑战。已有研究还探索过基于表现机制 (performance mechanism) 的考试生成系统。这一领域的一个值得注意的进展是 MOEPG, 它采用 RL 驱动范式平衡多样的试卷设计目标。然而, 这些方法主要聚焦于学生级 (student-level) 适应, 而系统性地忽视了多阶段教学适应的关键需求。

总之, 虽然 MOO 在应对 CAT 的多方面挑战上展现了潜力, 但当前应用主要局限于题目级自适应范式。如何开发出既能平衡多个目标、又能保证高利害考试可比性的方法, 仍是一个挑战。

3 PCAT 形式化与评测

3.1 任务形式化

给定题库 $Q = \{Q_1, Q_2, \dots, Q_n\}$, 其中 $\mathcal{C} = \{C_1, C_2, \dots, C_d\}$ 表示属性集, $Q\text{-matrix} \in \{0, 1\}^{n \times d}$ 表示每道题考查的属性。PCAT 系统的任务是: 基于在题库 Q 的题目评测阶段收集到的作答日志 $\mathcal{R} = \{R_1, R_2, \dots, R_\ell\}$, 生成若干套试卷。生成的试卷集记为

$\mathcal{P} = \{P_1, P_2, \dots, P_m\}$ 。这里每一套试卷 $P_i \in \mathcal{P}$ 由 k 个测验阶段组成，它们共同构成一场 k 阶段考试的完整流程。在一场 k 阶段考试中，第一个测验阶段只含一份试卷，而后续每个测验阶段都包含多份不同难度的试卷。在一场考试中，每个阶段呈现给学生的试卷，根据其在前面阶段的表现、按照基于规则或启发式的策略自适应确定。形式化地，对于一套试卷 P_i ，第 t 个测验阶段 ($t \in \{2, \dots, k\}$) 可表示为 $P_{i,t} = \{P_{i,t,1}, P_{i,t,2}, \dots, P_{i,t,u}\}$ ，其中每个 $P_{i,t,j} \subseteq \mathcal{Q}$ 指一份试卷。 P_i 中涉及的题目总数记为 $|P_i|$ 。作答日志集 $\mathcal{R}$ 含 ℓ 条交互记录，每条记录表示为三元组 (S_i, Q_j, r_{ij}) 。其中 $S_i \in \mathcal{S}$ 表示学生集 $\mathcal{S}$ 中第 i 个学生， Q_j 表示题库 $\mathcal{Q}$ 中第 j 道题， $r_{ij} \in \{0, 1\}$ 表示该学生对题作答的正误，答对则 $r_{ij} = 1$ ，否则 $r_{ij} = 0$ 。

3.2 PCAT 评测

传统 CAT 的评测方法不能直接套用于 PCAT。在传统 CAT 中，给定稀疏的作答日志 $\mathcal{R}$ ，评测过程通常把学生划分为训练集和测试集。对每个测试学生， $\mathcal{R}$ 中有作答记录的题目进一步分为支持集 (support set) 和查询集 (query set)。在训练集上训练好 CDM 和选题策略后，CAT 系统从支持集中为测试学生挑出一部分题目，收集其作答，并用 CDM 推断其能力水平；然后基于在查询集上的预测准确性评测表现。然而，这一做法不能直接用于 PCAT，因为在 PCAT 中试卷是预先组好的，试卷里某些题目对某些测试学生可能在 $\mathcal{R}$ 中没有对应的作答记录。这一问题使传统评测方法对 PCAT 不可行。

为应对这一挑战，我们提出了一种为 PCAT 量身定制的新评测方法。具体来说，我们先用一个启发式算法（详见第 5.1 节）从稀疏作答日志 $\mathcal{R}$ 中抽取一个稠密子集 $\mathcal{R}_D$ 。在 $\mathcal{R}_D$ 中，每个学生对每道题都有作答记录，从而消除了评测时作答记录缺失的问题。完整评测过程如下：给定稠密作答日志 $\mathcal{R}_D$ ，把学生随机划分为训练集和测试集。组卷过程在训练集上进行，生成预先组好的试卷。对每个测试学生，按前述多阶段试卷级自适应测验范式进行考试，试卷根据学生在前面阶段的表现自适应选取。然后用 CDM 基于学生的考试结果推断其能力水平。最后，基于在查询集上的预测表现（详见第 5.3 节）计算评测指标，从而对 PCAT 系统的表现做出公平、全面的评估。这一方法不仅克服了传统 CAT 评测的局限，还契合 PCAT 的独特特性，为评估其在高利害考试场景中的有效性提供了一个稳健的框架。

4 方法：试卷级计算机自适应测验 (PCAT)

本节给出 PCAT 的技术细节。MOO 的通用框架由几个关键组件构成，即解的表示、适应度评估、初始化、变异与交叉、选择机制、终止条件。PCAT 的核心创新在于解的表示：我们为题目引入一种「双层编码」，把题目类型和难度水平结合起来。适应度评估通过一个模拟的试卷级自适应测验过程进行，评估诊断质量、属性覆盖、题目曝光。下面各小节详述解的表示、适应度评估和 PCAT 的完整工作流程。

4.1 解的表示

个体解的表示是进化算法的一个基础环节，因为它直接影响优化过程的效率和可解释性。已有把 MOO 应用于 CAT 和组卷的方法通常使用二进制表示，把一个解编码成一个长长的 0-1 向量，每个下标表示是否选中题库 $\mathcal{Q}$ 中对应的题目。这种表示虽然简单，但缺乏教育语义，且随着题池增大而变得低效，因向量的稀疏性导致大量内存浪费和计算开销。

为解决这些局限，我们提出一种新颖的题目「双层表示 (dual-layer representation)」。在这一方法中，每道题被编码为一个「类型-难度对」：第一维表示题目类型，是一个整数 $\tau \in \{1, 2, \dots, \eta\}$ ，表示所考查的属性组合（其中 η 是题目类型总数，每个类型对应属性集 $\mathcal{C}$ 中一个独特的属性组合）；第二维表示难度水平，是一个实值系数 $\delta \in \mathbb{R}$ 。形式化地，一道题表示为元组 (τ, δ) 。在进化过程中，一个解，即一套试卷，可表示为一个尺寸 $|P_i| \times 2$ 的矩阵 M_Q 。 M_Q 的解码 (decoding) 是通过一个「邻域投影 (neighborhood projection)」过程，把 M_Q 中每一行 (τ_i, δ_i) , $i = 1, 2, \dots, h$ 映射到题库 $\mathcal{Q}$ 中一道具体的题 Q_i ，即在类型 τ_i 的题目里选难度水平最接近 δ_i 的那道。形式化地可表示为：

$$Q_i = \arg \min_{q \in \mathcal{Q}_{\tau_i}} |\delta_q - \delta_i|, \quad (1)$$

其中 $\mathcal{Q}_{\tau_i} \subseteq \mathcal{Q}$ 是 $\mathcal{Q}$ 中类型为 τ_i 的题目子集， δ_q 表示题 q 的难度水平。

所提双层表示有几个优势。第一，它高度紧凑，相比传统二进制表示显著缩了解空间。例如，一份含 h 道题的试卷只需 $2h$ 个值来表示，而二进制表示需要 n 个值（其中 $n \gg h$ ）。第二，它纳入了教育语义，使解更可解释、更契合教育评估的目标。第三，它避免了稀疏二进制向量带来的内存和处理开销，提升了计算效率。这些好处使双层表示特别适合大规模、高利害的测验场景，因为那里效率和可解释性都很关键。

4.2 适应度评估

适应度评估过程模拟多阶段试卷级自适应机制，从多个因素评估一个解的适应度。具体来说，学生在第一阶段拿到同一份试卷。对后续阶段，系统根据学生在前面阶段的表现，自适应分配不同难度的试卷。具体而言，学生按其被诊断出的掌握水平排序并分成等大小的组，每组分配一份对应难度的试卷。所有阶段完成后，对考试的作答日志进行诊断，产出最终指标来评估这套试卷的整体表现。

在本文的优化过程中，我们受 GRE 考试设计的启发，采用两阶段 PCAT 场景。具体来说，给定一套含 $|P_i|$ 道题的试卷 P_i ，它会被分成 3 份不同难度（易、中、难）的试卷，每份 $|P_i|/3$ 道题。训练集中所有学生在第一阶段都拿到「中等」试卷。在第二阶段，根据学生在前一阶段的表现，表现最好的那一半学生被分配「难」卷，其余一半拿到「易」卷。最终，每个学生总共完成 $Step = \frac{2}{3}|P_i|$ 道题。

评测指标聚焦三个关键方面：诊断质量、属性覆盖、题目曝光。具体来说，我们用 CDM 在训练集上的 ROC 曲线下面积 (AUC) 和准确率 (ACC) 来衡量解 P_i 的诊断质量。这些指标计算如下：

$$\text{AUC} = \int_0^1 \text{TPR}(f) \cdot \text{FPR}(f) df, \quad \text{ACC} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}, \quad (2)$$

其中 TPR 和 FPR 分别表示真正例率和假正例率，TP、TN、FP、FN 分别表示真正例、真负例、假正例、假负例。(译注：式中 AUC 的被积式按原文照录。)

对于属性覆盖 (COV)，我们计算为每个学生所选题目覆盖的属性的平均数量。其定义为：

$$\text{COV} = \frac{1}{|\text{ST}|} \sum_{s \in \text{ST}} \left(\frac{1}{|C|} \left| \bigcup_{q \in Q_s} Q\text{-matrix}(q) \right| \right), \quad (3)$$

其中 ST 是训练集中的学生集， Q_s 是分配给学生 s 的题目集， $Q\text{-matrix}(Q_j)$ 表示题 Q_j 考查的属性。

对于题目曝光 (EXP)，我们衡量每道题在所有学生试卷中出现的频率：

$$\text{EXP} = \frac{1}{|\text{ST}|} \sum_{s \in \text{ST}} \left(\frac{\sum_{q \in Q_s} (N_q / |\mathcal{S}| - r)^2}{r} \right), \quad (4)$$

其中 $r = \text{Step}/n$ ， N_q 表示原始作答日志 $\mathcal{R}$ 中题 q 的作答次数，Step 表示测验步数，即一个学生在一场 PCAT 考试中要回答的题量。

这些指标合在一起，从诊断质量、属性多样性、题库安全性三个角度对试卷集的有效性提供了全面评估。

4.3 PCAT 中的多目标优化

我们的方法采用基于 NSGA-II 的 MOO 方法，用「类型-难度对」向量表示个体解。这一框架在遵循目标和约束的同时，保证对解空间的高效探索。

4.3.1 解的初始化 每个个体解表示为一个「类型-难度对」向量，每个对对应一道具体的题。类型是整数 $\tau \in \{1, 2, \dots, \eta\}$ ，表示所考查的属性组合；难度是实值系数 $\delta \in [\delta_{\min}, \delta_{\max}]$ 。初始化时，每个对从题目类型集中随机选取，保证同一个解内类型不重复。难度在预定义区间 $[\delta_{\min}, \delta_{\max}]$ 内均匀初始化，该区间由 CDM 导出。这保证了初始种群的多样性和可行性。

4.3.2 交叉与变异 交叉 (crossover) 和变异 (mutation) 操作用于有效探索解空间。对于交叉，我们分别对「类型」和「难度」使用旅行商交叉算子 (traveling salesman crossover operator) 和两点交叉算子 (2-point crossover operator)。对于变异，应用两点变异策略，以预定义概率扰动一个对的类型和难度。类型变异限制在合法的题目类型内，难度变异保持在区间 $[\delta_{\min}, \delta_{\max}]$ 内。形式化地，对于一个对 (τ, δ) ，变异过程可表示为：

$$\tau' = \tau + \Delta\tau, \quad \delta' = \delta + \Delta\delta, \quad (5)$$

其中 $\Delta\tau$ 和 $\Delta\delta$ 是随机扰动。

4.3.3 选择机制 选择过程结合非支配排序 (non-dominated sorting) 和拥挤距离 (crowding distance)，以在收敛性和多样性之间取得平衡。非支配排序根据支配关系给每个解赋一个等级——若解 P_i 在至少一个目标上更优、且在其他任何目标上都不更差，则 P_i 支配 P_j 。拥挤距离衡量解在目标空间中的密度，优先保留位于较稀疏区域的解。对于解 P_i ，第 j 个目标的拥挤距离 $d_j(P_i)$ 计算为：

$$d_j(P_i) = \frac{f_j(P_{i+1}) - f_j(P_{i-1})}{f_j^{\max} - f_j^{\min}}, \quad (6)$$

其中 P_{i+1} 和 P_{i-1} 是相邻的解， $f_i^{\max}$ 和 $f_i^{\min}$ 是第 i 个目标的最大值和最小值。解 P_i 的总拥挤距离计算为 $D(P_i) = \sum_{j=1}^o d_j(P_i)$ ，其中 o 是目标数量。等级更高、拥挤距离更大的解在进入下一代时被优先考虑，从而保证种群多样且高质量。PCAT 的完整工作流程见算法 1。

算法 1: PCAT 的多目标优化框架 输入: 学生集 $\mathcal{S}$, 题库 $\mathcal{Q}$, 最大迭代数 T 初始化: 随机生成一个解的种群 $\mathcal{P}$, 其中一个解 P_i 表示一套试卷。迭代指示器 $itr \leftarrow 0$. **while** $itr < T$ **do** 从 $\mathcal{P}$ 中随机采样父代, 进行交叉和变异, 生成新种群 $\mathcal{P}^*$ **for** P_i in $\mathcal{P}$ **do** **for** q in P_i **do** 通过邻域投影把 q 的「类型-难度对」解码成一道题 $Q_j \in \mathcal{Q}$ **end for** **end for** 把 P_i 转换成三份试卷 (易、中、难)。 **for** s in $\mathcal{S}$ **do** $rank \leftarrow$ 学生 s 在「中等」卷上掌握水平的百分位排名 **if** $rank > 0.5$ **then** 自适应到「难」卷 **else** 自适应到「易」卷 **end for** 根据作答计算四个目标 AUC、ACC、COV、EXP。根据四个目标上的适应度和拥挤距离, 从 $\mathcal{P}^*$ 中选出新种群 $\mathcal{P}$ 。 $itr = itr + 1$ **end while** 输出: 最终种群 $\mathcal{P}$ 。

5 实验

本节在四个真实世界数据集上进行大量实验以评估 PCAT 的表现。代码开源于 <https://github.com/ECNU-ILOG/PCAT>。

5.1 数据处理与实验设置

我们在实验中使用四个真实世界教育数据集, 即 MOOCRadar (MOOC)、Assistent 2017 (ASSIST)、ProbabilityAndStatistic (PROB-STA)、ComputationalThinking (COM-TH)。这四个数据集来自不同的在线教育平台, 已被广泛用于认知诊断、知识追踪和 CAT 领域。

表 1: 稠密化后数据集的统计信息。

数据集	ASSIST	MOOC	PROB-STA	COM-TH
学生数	120	1,230	105	2,433
题目数	83	181	263	272
属性数	43	180	63	57
记录数	9.9K	220K	28K	1.6M
每题属性数	1.51	1.64	1.00	1.01
正标签率	0.68	0.95	0.37	0.77

5.1.1 数据集稠密化 如第 3.2 节所述, 原始数据集是稀疏的, 每个学生只作答了一小部分题目, 无法直接评测 PCAT 的表现。为此, 我们的目标是把稀疏作答矩阵转换成稠密矩阵, 同时最大化其规模。这一问题本质上是「最稠密子图 (densest subgraph) 问题」的一个变体, 而后者已知是 NP 难的。为高效稠密化数据集, 我们提出一个启发式算法, 迭代地移除作答最少的学生或题目, 直到得到的子矩阵稠密。具体来说, 每一步移除作答最少的学生或作答最少的题目, 取对稀疏性贡献更大的那个。这一过程持续到剩余子矩阵稠密, 保证子集中每个学生都作答了子集中每道题。详细过程见附录 A 的算法 2。稠密化后数据集的统计信息汇总在表 1。

5.1.2 实验设置 在我们的实验中, 学生按 80%-20% 划分为训练集和测试集。训练数据用于训练 CDM 并生成 PCAT 的试卷集, 而在 CAT 中用于训练 CDM 和选题策略。在测试阶段, 测试集中的学生被当作 CAT 系统的新考生。基线 CAT 方法和我们所提的 PCAT 算法都对学生的作答记录无知 (agnostic), 所选题目的作答标签只在选题最终确定后才揭示。我们把 PCAT 和 CAT 基线的测验长度 $Step$ (即每个学生作答的题量) 设为相同, 以相对公平地比较 CAT 和 PCAT 的表现。具体来说, 我们用 $Step = 10$ 和 $Step = 20$ 评测算法, 每种设置下的实验重复 5 次。

5.2 PCAT 与对比方法的实现

本文采用受 GRE 考试模式启发的两阶段 PCAT 设置 (如第 4.2 节所述)。关键超参数和配置如下:

- **MOO**: MOO 过程中, 采用最大进化迭代数 $T = 100$, 种群规模 = 80。
- **认知诊断模型**: 采用神经认知诊断模型 (NCDM) 作为学生画像模块。
- **学习率**: CDM 训练的学习率设为 0.05。
- **批大小**: CDM 训练的批大小设为 512。
- **网络结构**: CDM 中的神经网络由两个隐藏层组成, 分别有 128 和 64 个单元。
- **优化器**: CDM 中使用 Adam 优化器。

我们选择 CAT 领域的以下方法作为对比算法, 详细信息参见相关工作第 2.1 节。

基于统计的 CAT:

- **Random**: 从 $\mathcal{Q}$ 中为学生随机选题。值得注意的是, Random 也可看作最朴素的组卷方法。
- **MFI**: 选择能为学生掌握水平修正提供最大费舍尔信息的题目。
- **KLI**: 选择能为学生掌握水平之差带来最大 KL 信息的题目。

机器学习驱动的 CAT:

- **MAAT**: 选择能平衡「学生掌握水平增益」与「属性覆盖」的题目。
- **BOBCAT**: 在内层最小化交叉熵损失以估计学生掌握水平, 在外层优化选题算法和全局参数。
- **NCAT**: 采用注意力神经网络对交互函数建模, 再用 Q-learning 选题。
- **BECAT**: 采用题对之间的相似度, 用贪心方式寻找最优题目子集。
- **GMOCAT**: 用图神经网络学习关系感知 (relation-aware) 嵌入以聚合领域信息, 引入基于 RL 的选题策略, 优化质量、多样性、新颖性三个目标。

所有实验在一台 Linux 服务器上进行, 配两块 3.00GHz Intel Xeon Gold 6354 CPU 和一块 RTX3090 GPU。代码用 PyTorch 编写, MOO 用 Pymoo 实现。

5.3 评测指标

如第 4.2 节所述, 我们 PCAT 框架的评测聚焦三个关键方面: 诊断质量、属性覆盖、题目曝光, 涵盖四个目标: AUC、ACC、COV、EXP。其中 AUC 和 ACC 的定义与式 (2) 相同。COV 指标可表示为:

$$\text{COV} = \frac{1}{|\text{SE}|} \sum_{s \in \text{SE}} \left(\frac{1}{|C|} \left| \bigcup_{q \in Q_s} Q\text{-matrix}(q) \right| \right). \quad (7)$$

EXP 指标定义为:

$$\text{EXP} = \frac{1}{|\text{SE}|} \sum_{s \in \text{SE}} \left(\frac{\sum_{q \in Q_s} (N_q / |\mathcal{S}| - r)^2}{r} \right), \quad (8)$$

其中 SE 表示测试集中的学生集, 其他记号分别与式 (3) 和式 (4) 相同。

此外, 为分析与各算法执行时间相关的实施成本, 我们根据是否需要实时学生交互, 把总的墙钟 (wall-clock) 执行时间分为离线和在线两部分。我们强调在线执行时间, 因为在高利害考试中, 考虑其时长对于保证考试过程可管理、可控至关重要。

5.4 实验结果

5.4.1 诊断质量 我们在所有基线方法和 PCAT 框架下进行学生表现预测实验, 以比较质量结果。表 2 给出各算法在 $Step = 10$ 和 $Step = 20$ 下的质量指标 (AUC 和 ACC)。值得注意的是, PCAT 的最终输出是一组试卷集组成的种群; 我们从这个种群中选出在训练集上 $AUC + ACC$ 最高的解, 并报告它在测试集上的 AUC 和 ACC。所有结果独立重复 5 次, 报告均值 $\pm$ 标准差。

表 2: 四个真实世界数据集上的 AUC 与 ACC 对比。最优加粗, 次优加下划线。「-」表示该方法无法在 7 小时在线时间内给出结果。「*」表示相比次优有统计显著提升 (t 检验, $p < 0.05$)。(此处为原文表 2, 含四数据集、Step 10/20 下各方法 AUC 与 ACC, 结构复杂。要点: PCAT 在 ASSIST 上 AUC 达 84.59%/87.19%, 显著高于次优 81.63%/83.01%; 四数据集 ACC 平均超 SOTA 约 5%。详见原文。)

从表 2 可见, PCAT 在质量目标上优于所有基线方法。这一结果是合理的, 因为相比单步方法, PCAT 的全局搜索框架考虑了全局效应, 更可能对学生能力估计达到更好的期望。在大多数数据集上, PCAT 框架在 AUC 和 ACC 上都一致取得最优或接近最优的结果。这表明多目标框架有效平衡了各目标的有效性, 对学生能力水平提供了稳健、准确的评估。

具体来说, 对 ASSIST 数据集, PCAT 在 $Step = 10$ 和 $Step = 20$ 分别取得最高 AUC 84.59% 和 87.19%, 显著高于次优的 81.63% 和 83.01%。ACC 方面 PCAT 取得 77.52% 和 79.97%, 优于所有其他方法。在 MOOC 数据集上, PCAT 取得有竞争力的结果, AUC 为 59.01% 和 61.51%, ACC 为 77.19% 和 86.86%, 与 MFI、GMOCAT 等最佳基线相当或更好。对 PROB-STA 数据集, PCAT 在 $Step = 20$ 取得最高 AUC 61.97%, 略优于 MFI 的次优 61.88%; ACC 方面 PCAT 取得 62.37%, 接近 MFI 的最佳 62.82%。最后, 在 COM-TH 数据集上, PCAT 在 $Step = 20$ 取得最高 AUC 61.00%, 优于所有其他方法; ACC 取得 85.26%, 与 KLI 的最佳 85.63% 相当。值得注意的是, PCAT 在四个数据集上的 ACC 平均超过 SOTA 5%。

总体而言, 实验结果表明 PCAT 框架在不同数据集和 $Step$ 规模下都一致取得更优或有竞争力的表现, 凸显了它在准确评估学生能力水平上的有效性。

5.4.2 属性覆盖与题目曝光 为学生所选题目的多样性是一个重要指标，反映题目覆盖的属性范围，并保证评估的全面性。值得注意的是，不同数据集上的 COV 和 EXP 指标不在同一量级，因此为便于可视化，我们展示各方法相对于 PCAT 在对应数据集上表现的比值，记为 EXP Ratio 和 COV Ratio。图 4 比较了 $Step = 20$ 下基线与 PCAT 的属性覆盖结果。PCAT 在全部四个数据集上都表现良好，一致优于所有基线方法。这一优异表现归功于 PCAT 内在的目标平衡和它有能力保证的搜索算法。相比之下，KLI、MFI、甚至把覆盖作为目标的多目标 GMOCAT，都略逊于 PCAT。我们认为这是因为 KLI、MFI、GMOCAT 等算法通过迭代选题聚焦局部效应，而 PCAT 采取全局方法、考虑整体表现。逐步选题虽然能提供个性化的评估，但 PCAT 提供了更强的公平性（如对所有学生都用多样的题目测验）和效率（如无需逐步选题或计算）。

图 4: $Step = 20$ 时的属性覆盖对比。

除了代表评估准确性的质量指标和代表题目多样性的覆盖指标外，我们还考虑曝光指标，通过限制一道题被曝光的次数来保证题库安全。图 5 展示了 $Step = 20$ 下各基线方法和 PCAT 的题目曝光结果。随机选题虽然提供了广泛的选题范围，但违背了 CAT 的本意，导致质量和覆盖上的一些损失；尽管多样，它给曝光设了上限基准。仅关注准确性的 MFI 和 KLI 在覆盖和曝光上改善甚微。GMOCAT 等多目标方法同时改善三个目标，但因其迭代本质而缺乏整体视角。相比之下，PCAT 取得最低曝光，证明了其多目标优化算法的有效性，并表明直接优化曝光能整体降低曝光。在 MOOC 数据集上，PCAT 和对比方法的 EXP 指标相等，这归因于 MOOC 数据集的独特结构——其内在均匀的题目曝光率削弱了 EXP 指标的区分力；尽管如此，为展示一致性，该指标仍保留在报告结果中。

图 5: $Step = 20$ 时的题目曝光对比。

这些结果凸显出 PCAT 不仅保持了高诊断质量，还保证了更好的属性覆盖和题目曝光，使其成为高利害考试的一个稳健解决方案。

5.4.3 执行时间 各基线和 PCAT 在四个数据集上的在线执行时间见表 3。结果清楚显示 PCAT 在实施成本上的优越性。MAAT、BECAT 等方法的在线执行时间从几分钟到 7 小时以上不等，而 PCAT 在所有数据集上都能以近乎零的时间完成任务。这一显著的时间效率凸显了 PCAT 在大规模标准化考试场景中的潜力。

表 3: $Step = 20$ 时的在线时间对比。

数据集	ASSIST	MOOC	PROB-STA	COM-TH
Random	1s	1s	1s	1s
MFI	18s	3min	25s	6min
KLI	5s	1min	5s	10min
MAAT	20min	>7h	50min	>7h
NCAT	<5s	>7h	3min	>7h
BOBCAT	3s	40s	3s	1min
BECAT	2h	>7h	>7h	>7h
GMOCAT	10min	2h	10min	4h
PCAT	1s	3s	1s	5s

5.4.4 目标对比 在训练阶段，会得到一组最优非支配解。由于 PCAT 框架涉及四个目标，我们把它分组以便展示所得帕累托前沿：(1) AUC-EXP-COV 和 (2) ACC-EXP-COV。ASSIST 和 COM-TH 上的结果见图 2 和图 3，其他数据集的结果见附录 B。在图 2 和图 3 中，我们把 EXP 和 COV 分别画在 x 轴和 y 轴上，每个个体解用一个红点表示，凸显其在解空间中的位置。此外，对数据拟合了一个帕累托前沿曲面，颜色越深表示 AUC 或 ACC 越低，越浅表示越高。如图 2 和图 3 所示，帕累托前沿形成一个近似光滑的曲面，表明 PCAT 框架有效平衡了多个相互竞争的目标，提供了一组多样的高质量解，可根据具体考试需求定制。

图 2: $Step = 20$ 时 PCAT 在 ASSIST 上组装的种群的帕累托前沿。

图 3: $Step = 20$ 时 PCAT 在 COM-TH 上组装的种群的帕累托前沿。

这些结果表明，PCAT 框架能够生成同时优化多个目标的解，保证对题目曝光、属性覆盖、诊断质量的平衡考虑。这种灵活性让考试管理者能根据具体需求定制考试过程，进一步增强了 PCAT 在高利害测验场景中的适用性。

5.4.5 超参数分析 为研究 MOO 超参数对 PCAT 结果的影响，我们比较不同种群规模和最大迭代数下的 AUC 指标。具体来说，为研究种群规模的影响，固定最大迭代数、变化种群规模；类似地，为研究最大迭代数的影响，固定种群规模、变化最大迭代数。详细结果见附录 C。

6 结论

本文提出 PCAT，一个解决高利害考试中传统题目级自适应测验关键局限的新框架。通过采用试卷级自适应机制并利用基于种群的 MOO，PCAT 增强了结果可比性、降低了实施成本，并有效平衡了多个测验因素。实验结果表明它在诊断质量、属性覆盖、题目曝光上优于 SOTA 方法。两个有

前景的未来研究方向包括：(1) 开发动态的、依赖种群的指标，如根据所选解的分布调整的题目曝光率；(2) 把 PCAT 扩展到更复杂的多阶段测验场景。这些进展能进一步提升 PCAT 的灵活性和适用性。

致谢

感谢匿名审稿人的建设性意见。本文的算法和数据集不涉及任何伦理问题。本工作受国家自然科学基金（项目号 62476091）资助。

参考文献 (*References*) 按约定未翻译，详见原文。