

TestAgent: 用 LLM 做自适应测试 精读笔记

原文: testagent-llm-adaptive-testing_9.pdf (ACL 2025 Findings, pp.724–747, 中科大 Qi Liu / Enhong Chen 组) · 代码: 未发现开源代码 · 笔记于 2026-06-27

这篇文章是把大语言模型 (LLM) 接到计算机化自适应测试 (CAT) 里的第一篇工作。读者如果做 KT/CAT, 会对里面的「认知诊断 + 选题算法」这套老框架很熟, 本文的新意全在「用 LLM 把死板的选择题测试变成对话, 并解决对话带来的标签噪声」。下面按「问题 → 定义 → 结构 → 公式 → 小结」来讲透。

一、解决什么问题

传统 CAT 的标准回路是: 认知诊断模型根据已答题目估出能力 θ → 选题算法 (FSI/KLI/MAAT 等) 挑一道「信息量最大」的题 → 受测者作答 → 更新 θ → 循环。它的优点是题少、估得准, 缺点本文归纳为三条「痛点」:

1. 机械化 (Mechanized): 只能做固定答案格式 (选择题)。结果是受测者容易蒙对——蒙对的题会让 θ 被高估; 而且开放题 (观点、创意、解题过程) 根本套不进选择题框架。
2. 作答有噪声 (Noisy): 人格测试、心理测试里, 人会给「社会期许答案」、会隐瞒症状, 作答标签 y 不等于真实状态。
3. 输出太粗 (Coarse-Grained): 最后只丢给你一个分数 / 一个能力向量 θ 。对 MBTI 这种, θ 是个不可解释的向量, 用户看不懂, 还得请专家解读, 成本高。

本文的解法 = TestAgent: 用 LLM 当「测试专家」, 把整个测试变成多轮自然语言对话。- 对应痛点 1: 题目由 LLM 用一个角色 C 包装成口语化问句 $b = C(q)$, 受测者用对话回答, 不再是 ABCD。- 对应痛点 2: 加两个 LLM 模块——自主反馈机制 (AFM) 和 异常管理 (AM)——专门把含糊/异常的对话清洗成可靠标签 y 。- 对应痛点 3: 训练分类器 + 微调 LLM, 把 θ 翻译成「人格类型 + 诊断报告」。

效果: 在 MBTI / MATH / SCL 三个数据集上, 达到同样的能力估计精度可少用约 20% 的题; 50 名真人志愿者评测, 在流畅度、交互、速度 (以及准确性) 上更喜欢 TestAgent。

二、问题定义 (输入 / 输出)

形式化 (论文定义 1): 第 t 步, 受测者对题目 q 的作答是 y 。历史序列

$$S = \{(q_1, y_1), \dots, (q_t, y_t)\}.$$

认知诊断模型用交叉熵损失、基于 S 更新能力 θ_t ; 选题算法 π 据 θ_t 选下一题 $q_{t+1} \sim \pi(\theta_t)$ 。迭代 T 步后停, 返回 θ_T 。

- 输入: 题库 Q ; 当前能力估计 θ_t ; 历史作答 S 。
- 输出: 最终能力 θ_T , 再加上一份诊断报告 (这是本文相对传统 CAT 多出来的输出)。
- 符号维度: θ 的维度 = 测试维度 M 。MBTI 是 4 维 (I/E、N/S、T/F、J/P); MATH 这类能力测试常是 1 维 (一个能力标量); $y \in [0, M]$ 表示「作答契合等级」, MBTI 用 7 级李克特量表所以 $M = 7$ 。

举个具体小例子 (MBTI): - 题库里第 23 题原文是「You prefer busy places to quiet, private places (你更喜欢热闹而非安静私密的地方)」。- LLM 把它包装成对话:「你好! 日常生活里, 你更喜欢人多有活力的地方, 还是安静私密的环境? 能聊聊你的偏好吗?」- 受测者回答:「大多数时候我还是喜欢独处, 人太多让我心烦。」- AFM 分析出这条对话在「内向 vs 外向」维度上的契合等级, 比如标签 $y = 4$ (Mildly Agree, 偏向内向)。- 这个 y 喂给认知诊断更新 θ , 再用 FSI 选下一题 (比如第 49 题关于 deadline 的 J/P 维度题)。- 跑若干轮后 θ → 分类器 → 「INTJ」→ 微调好的 LLM 生成一段诊断报告。

三、模型结构 (三大块, 逐步讲)

整个系统 (图 2) 分三块: 通用数据基础设施 → TestAgent Planning → 报告生成。

块 1: 通用数据基础设施 (建题库 + 训认知诊断)

痛点: 要训认知诊断模型得有「学生 × 题目」的大量作答记录, 但新领域往往没有。做法 (图 3 三步): 1. 领域验证: 定测试维度 M (MBTI→4 维)。2. 数据整合: 让 GPT-4 扮演不同能力/人格的虚拟受测者, 对题库所有题作答, 合成大量交互记录。已有研究证明 LLM 模拟受测者是靠谱的。3. 认知诊断训练: 用合成记录训练 IRT 等级反应模型, 得到每道题的特征向量 β 。> 直觉: 先用 GPT-4「自问自答」造出一个虚拟人群的答题大数据, 把每道题的难度/区分度 (β) 标定好, 题库就能用了。

块 2: TestAgent Planning (测试主循环)

在传统「诊断 → 选题」回路里塞进两个 LLM 模块 (图 4):

- **题目生成**: 从题库取题 q , LLM 用角色 C 包装成口语问句 $b = C(q)$ 。
- **受测者对话作答**。
- **自主反馈机制 AFM**: 判断这段对话能不能可靠地抽出标签 y 。它查三件事——**领域相关性** (答的是不是这题)、**作答契合度** (落在 M 个等级里的哪个, 模糊就算失败)、**逻辑连贯性** (有没有自相矛盾)。三项全过 → 输出 y ; 任一不过 → LLM 生成一道相似题重问, 直到能定标签。
 - 典型触发: 受测者答「我不知道该怎么办」——契合度无法判定 → 失败 → 换个相似问法再问。
- **异常管理 AM**: 处理三类心理学常见异常:
 - **猜测异常**: 用当前 θ 估 $P(q, y)$, 若「以现在的能力几乎不可能答出这个 y 」却答出了 y , 疑似蒙的, 触发 AFM 复核。
 - **误导异常**: 追踪上下文, 发现同主题多题前后矛盾 (前面说对、后面打脸) → 判为故意误导, 拆题细问。
 - **过度自信异常**: 接受答案但追问理由; 高自信却给不出充分理由 → 判为无依据。
- 标签 y 干净后 → **认知诊断更新 θ** → **自适应选题** (FSI/KLI/MAAT) 取下一题。循环。

块 3: 报告生成 (把 θ 变成人话)

- 训一个分类器 g : 输入 θ , 输出可读标签 (MBTI 的 4 维 0/1 向量 → 拼成 INTJ 等)。
- 再用「测试结果 + 文本作答记录 + 专家报告」微调 (LoRA) ChatGLM, 让它据标签生成**诊断报告** (优势/劣势/建议)。

四、关键公式详解 (核心, 逐个带数字走一遍)

公式 1: IRT 等级反应模型——「答到第 m 级」的概率

$$p_{\theta}(y = m | q) = p_{\theta}(y \geq m | q) - p_{\theta}(y \geq m + 1 | q),$$

其中累积概率

$$p_{\theta}(y_i \geq m | q_i) = (1 + \exp(\theta - \beta_i^{(m)}))^{-1}.$$

- 符号: θ 是受测者能力 (标量, 越大越倾向某极/能力越高); $\beta_i^{(m)}$ 是题目 i 跨过第 m 级的「阈值」参数, 级别越高阈值越大 (越难达到), 即 $\beta^{(1)} < \beta^{(2)} < \dots$; $y \in [0, M]$ 是作答等级。注意这是把二分类 IRT (答对/答错) 推广到**多级有序作答** (如李克特 7 级)。
- 为什么相减: 「恰好答到第 m 级」= 「至少到 m 级」减「至少到 $m + 1$ 级」, 这是有序回归的标准技巧; 所有等级的概率相加正好等于 1。
- 举例 (三档 $y \in \{0, 1, 2\}$, 某题阈值取递增的 $\beta^{(1)} = -1, \beta^{(2)} = 1$, 某人 $\theta = 0$)。先算累积概率 $p(y \geq m) = (1 + e^{\theta - \beta^{(m)}})^{-1}$:
 - $p(y \geq 1) = \frac{1}{1 + e^{0 - (-1)}} = \frac{1}{1 + e^1} = \frac{1}{1 + 2.718} = 0.269$.
 - $p(y \geq 2) = \frac{1}{1 + e^{0 - 1}} = \frac{1}{1 + e^{-1}} = \frac{1}{1 + 0.368} = 0.731$.这里出现 $p(y \geq 2) > p(y \geq 1)$, 说明原文给的参数化 $(1 + e^{\theta - \beta})^{-1}$ 写得偏简略 (要让累积概率随级别递减, 指数项符号应取 $\beta - \theta$)。领会要点即可: 每个等级对应一条 sigmoid 曲线, 相邻两条之差就是「恰好落在该等级」的概率。若按正确方向取 $p(y \geq m) = (1 + e^{\beta^{(m)} - \theta})^{-1}$, 则 $p(y \geq 1) = \frac{1}{1 + e^{-1}} = 0.731$ 、 $p(y \geq 2) = \frac{1}{1 + e^1} = 0.269$, 于是:
 - $p(y = 0) = 1 - 0.731 = 0.269$; $p(y = 1) = 0.731 - 0.269 = 0.462$; $p(y = 2) = 0.269$ 。三档概率和为 1, 这个能力中等的人最可能落在中间档 $y = 1$ 。
- 作用: 它把「能力 θ + 题目阈值 β 」映射成各作答等级的概率分布, 是认知诊断的似然核心, 也是后面算「这个作答是不是异常」的概率来源。
- 作用: 它把「能力 θ + 题目阈值 β 」映射成各作答等级的概率分布, 是认知诊断的似然核心, 也是后面算「这个作答是不是异常」的概率来源。

公式 2: 题目特征 β 的拟合 (认知诊断训练)

$$\beta_i = \arg \min_{\beta} \sum_{e \in E} \sum_{i \in F} y_i \log p(y = y_i | q_i).$$

- 符号: E 是 GPT-4 合成的全部交互记录, F 是题目特征集, y_i 是观测作答等级, $p(\cdot)$ 来自公式 1。本质是用合成作答数据做**最大似然 / 交叉熵拟合**, 把每道题的 β_i 学出来。
- 举例: 某题被 1000 个虚拟受测者作答, 其中 700 人答对。最朴素地, 题目「答对率」= 0.7 就能当作难度特征的一个估计; 更严格地, 用上面的损失对 β 求梯度下降, 使模型预测的 $p(y | q)$ 尽量贴合这 1000 条真实作答。
- 作用: 完成题库标定——每道题有了 β , 测试时才能反过来根据某人的作答去估他的 θ 。

公式 3：猜测异常的概率判据

异常管理用当前能力 θ 估「这个人以 y 作答题 q 」的概率 $P(q, y)$ (就是公式 1 给出的那个概率)。- 举例：MATH 测试里某人 θ 很低，对一道难题 q (高 β)，模型算 $P(q, y = \text{答对}) = 0.08$ 。结果他答对了——一个 8% 的小概率事件发生了，系统判「疑似蒙的」，触发 AFM 换相似题复核。若复核仍对，说明是真会；若复核错，说明确实是蒙的，避免 θ 被一道蒙对题抬高。- 作用：这是把传统 IRT「猜测参数」的思想用对话复核来落地——不靠固定的 guessing 参数，而是动态用 θ 当先验去筛可疑作答。

公式 4：数据生成的训练损失 (算法 1 第 7 行)

$$L(q, y; \theta) = E_{y \sim p(y|q)} [-\log p_{\theta}(y | q)].$$

- 标准的负对数似然 (交叉熵) 期望形式。 $p(y | q)$ 是合成数据的真实分布, p_{θ} 是模型分布, 最小化它就是让认知诊断模型拟合合成作答。- 举例：一道题真实作答分布是 $[0.1, 0.2, 0.7]$ (三档), 模型当前预测 $[0.3, 0.3, 0.4]$, 则该样本损失主要由真实占比大的第三档贡献： $-0.7 \log 0.4 \approx 0.64$, 梯度会把模型第三档概率往上推。

公式 5：报告生成的分类器损失

$$L(\theta) = \text{CrossEntropyLoss}(g(\theta), f(Y_{\text{label}})),$$

其中 f 把人格类型映射成 0/1 向量, 如 $f(\text{ENFJ}) = [1, 0, 1, 0]$; g 是待训分类器。- 举例：某人诊断向量 $\theta = [0.8, -0.3, 0.6, -0.1]$ (四维), 真实人格是 ENFJ $\rightarrow$ 目标 $[1, 0, 1, 0]$ 。分类器 $g(\theta)$ 输出 $[0.9, 0.2, 0.7, 0.4]$, 逐维算二元交叉熵求和作为损失, 训练 g 把连续 θ 切成四个二分类度 (I/E、N/S、T/F、J/P), 最终拼出可读的「ENFJ」标签喂给报告生成 LLM。- 作用：这是「 θ 不可解释」到「人能看懂的人格类型」之间的桥。

五、代码实现对照

未发现开源代码。全文 (含脚注、致谢、附录) 未给出 GitHub/GitLab 等仓库地址, 仅在附录给了算法 1 伪代码和 LoRA 超参 ($r = 8, \alpha = 32, \text{dropout} = 0.1, \text{lr} 2 \times 10^{-6}, 10 \text{ epoch}, \text{max_len} 1024, \text{fp16}$, 基座 ChatGLM2-6B, 框架 torchkeras)。若要复现, 核心要自己实现的是: (1) IRT 等级反应模型 + 交叉熵拟合 β (公式 1、2); (2) AFM/AM 三类判据的 prompt (附录表 8-12 给了 prompt 模板的输入说明, 但未给完整文本); (3) $\theta \rightarrow$ 人格的分类器 (公式 5); (4) LoRA 微调报告生成器。

六、小结

实验结论：- 准确性 (表 1)：TestAgent 叠加到 FSI/KLI/MAAT 上, 在 MBTI/MATH/SCL 三数据集多数步数 ACC/AUC 都有提升, AUC@5 平均相对提升 1.77%、ACC@5 提升 0.91%, 第 5 步 (短测试) 增益最大——说明它在「题少」时尤其管用, 正是 CAT 最看重的场景。- 能力估计 (图 5/9)：达到相同 MSE 平均少 20% 的题, SCL 上第 15 步就追平。- 真人评测 (图 6 + 配对 t 检验)：流畅度、速度、交互、准确性四维 p 值全 < 0.05 , 显著优于传统 MBTI 测试; 而性别/年龄/学历分组 t 检验/ANOVA 的 p 值都 > 0.05 , 说明打分没有明显的人群偏差。

优点：(1) 第一个把 LLM 用进 CAT, 把死板选择题变对话, 体验和开放题能力都上来了; (2) AFM+AM 是有意思的设计, 用「换相似题复核」和「用 θ 当先验筛可疑作答」来对抗对话噪声和蒙答; (3) 产出可读诊断报告, 解决输出太粗的问题; (4) 认知诊断那套 (IRT+ 选题) 完全沿用, 与现有 CAT/KT 生态兼容, TestAgent 是「即插即用」的增强层。

局限 (作者自陈)：LLM 不稳定, 50 条失败样本里幻觉 34%、不当角色扮演 28%、冗余 26%、假阴性 12%; 用 LLM 会增大测试方差。另外「真实能力 θ_0 」是用「答完全题库」近似的, 本身是个代理指标; MATH 是私有数据集, 复现性受限; 公平性问题作者明确划到讨论范围之外。

对 KT/CAT 读者的启发：这套「LLM 当对话外壳 + 传统认知诊断当内核 + LLM 模块清洗标签」的范式, 可以迁移到知识追踪的对话式练习、开放题自动判分、以及用 θ 生成可解释学情报告等方向; 而「用当前能力估计当先验来检测异常作答」对处理 KT 里的 guessing/slipping 噪声也有借鉴意义。