

TestAgent: 用于人类测评的自适应智能专家 (TestAgent: An Adaptive and Intelligent Expert for Human Assessment)

原文: testagent-llm-adaptive-testing_9.pdf ·译者: Claude ·译于 2026-06-27 出处: Findings of the Association for Computational Linguistics: ACL 2025, pages 724–747 术语对照: Adaptive Testing 自适应测试 / 计算机化自适应测试 (CAT) ·Cognitive Diagnosis 认知诊断 ·Item Response Theory (IRT) 项目反应理论 ·Question Selection 题目选择 ·ability 能力值 θ ·Large Language Model (LLM) 大语言模型

摘要

准确评估人类的内在状态, 对于理解人的偏好、提供个性化服务、识别现实应用中的难题至关重要。自适应测试 (Adaptive Testing) 起源于心理测量学 (psychometrics), 如今已成为人类测评的主流方法, 并广泛应用于教育、医疗、体育和社会学等领域。它通过用最少的测试题目来定制评估过程。然而, 当前的自适应测试方法面临若干挑战: 大多数算法机械化的本质会导致受测者「猜答」行为, 并且难以处理开放式题目; 此外, 主观性的测评还受困于带噪声的作答数据和粒度粗糙的测试输出, 进一步限制了其有效性。为了更接近理想的自适应测试过程, 我们提出了 **TestAgent**——一个由大语言模型 (LLM) 驱动的智能体, 通过交互式参与来增强自适应测试。这是 LLM 在自适应测试中的首次应用。TestAgent 支持个性化的题目选择、捕捉受测者的作答行为与异常, 并通过动态的对话式交互给出精确的测评结果。在心理、教育和生活方式等测评任务上的实验表明, 我们的方法在比当前最先进 (state-of-the-art) 基线少用 **20% 题目** 的情况下取得了更准确的结果, 且受测者在速度、流畅度等多个维度上更偏好它。

1 引言

设计有效的测评来评价人类状态, 在多种场景下都至关重要, 例如分析人格特质、诊断心理健康问题、衡量学习能力 (Kaufman 等, 2022; Laher 等, 2022)。一种传统而直接的测评形式是纸笔测试 (paper-and-pencil tests), 所有受测者回答同一套题目。根据受测者的表现或得分, 专家评估其状态并给出反馈。

近年来, 自适应测试逐渐成为测评的主流方法。与传统的静态测试不同, 自适应测试通过根据受测者的作答动态调整题目, 为每位受测者量身定制评估过程。它不仅提升了评估精度, 还显著缩短了测试长度 (Liu 等, 2024b)。这种自动化范式已被各类大规模测试平台广泛采用, 例如 GRE、GMAT 和 Duolingo。

然而, 现有的自适应测试系统在应用于人类受测者时, 由于人类行为本身的复杂性, 面临诸多难以预料的挑战。这些挑战长期阻碍着真正智能的自适应测试系统的发展:

机械化的测试过程 (Mechanized Testing Process): 大多数自适应算法被限制在固定答案格式 (如选择题) 上。这类格式虽然更易自动化, 但受测者更可能「猜对」他们其实并不真正掌握的答案 (Brown, 2022)。此外, 这类系统难以应对需要多样化作答形式的开放式场景, 如基于观点表达、创造性思考或问题求解的任务。

带噪声的作答数据 (Noisy Response Data): 在人格特质或个人偏好的测评中, 受测者的作答往往无法准确反映其真实内在状态。受测者可能倾向于给出「社会期许」(socially desirable) 的答案而非真实回答, 导致数据不可靠 (Stein and Swan, 2019)。同样, 在心理健康评估中, 社会压力可能促使个体隐瞒或谎报症状, 扭曲测评结果 (McDonald, 2008)。

粒度粗糙的测试输出 (Coarse-Grained Test Output): 测试的最终结果常被简化为各种分数, 几乎不能给受测者提供可操作的洞见以做出有意义的自我调整。因此, 受测者往往还需要专家/导师的额外分析与指导来解读结果并采取恰当行动。这种对专家干预的依赖大大增加了所需的时间和人力, 使得大规模实施变得不切实际 (Josephson and Shapiro, 2013; Segal 等, 2019)。

基于上述考虑, 我们引入了 **TestAgent**——一个基于 LLM 的智能体, 通过交互式参与来增强自适应测试。这是 LLM 在自适应测试领域的首次应用。为了保证测试的有效性, TestAgent 被设计为支持个性化题目选择、捕捉受测者的作答行为与异常, 以及给出精确的测评结果。具体来说, TestAgent 继承了传统自适应测试的动态题目选择能力, 在满足个性化需求的同时提升测试效率; 此外, 我们引入了**自主反馈机制和异常管理模块**, 以保证测试过程更顺畅、更智能。

设想这样一个智能体: 它像人类专家一样, 能与受测者进行交互式对话、分析其作答、并动态生成个性化题目。这样的智能体能够超越传统测评中固有的机械约束和噪声相关问题, 提升测试体验的质量与相关性。TestAgent 还会生成详细的诊断报告, 让受测者更深入地理解自己的结果, 从而使测试体验更个性化、更透明, 同时显著降低资源成本。

我们使用来自三个不同领域的数据集开展了大量实验, 包括人格测量、教育数学考试和心理健康测试。定量预测结果与定性分析表明, TestAgent 的测试效率和方法论超越了传统测试方法。此外, 在真实测试中, TestAgent 在速度、流畅度以及另外两个维度上更受受测者青睐。

图 1: 左: 传统纸笔测试, 专家根据测试题目给出答案。右: 我们的专家模型 TestAgent。它扮演专家角色, 以最少的交互逐步评估学生能力, 并最终生成诊断报告。

2 方法

2.1 问题定义

自适应测试的目标是为受测者提供量身定制的题目，并力求在最少的测试轮数内完成。它包含两个关键组件：**自适应题目选择 (Adaptive Question Selection)** 和 **认知诊断 (Cognitive Diagnosis)**。受测者回答一道题后，认知诊断会基于该题的反馈更新其能力估计，随后再根据自适应题目选择算法选取后续题目。具体定义如下：

定义 1 (自适应测试的定义): 在测试的第 t 步，受测者对题目 q 的作答为 y 。此前的测试「题目-作答」对序列记为 $S = \{(q_1, y_1), \dots, (q_t, y_t)\}$ 。此时，认知诊断模型基于 S 、采用交叉熵损失更新能力值。题目选择算法 π 根据受测者当前的能力 θ_t 为其选取最佳题目作答，即 $q_{t+1} \sim \pi(\theta_t)$ 。此过程迭代进行，直到第 T 步停止。认知诊断返回 θ_T 作为结果。

传统自适应流程存在若干问题。第一，标签 y 可能与真实能力不一致。在许多情形下（如数学能力测试），受测者可能随机猜对答案，从而显著影响测试准确性。第二，受测者可能因各种原因隐瞒自己对题目 q 的真实掌握情况，导致测试结果不准确。第三，认知诊断模型输出 θ_T 作为测试结果，但这对受测者而言可能并不直观——受测者往往更希望获得包含多种分析的诊断报告，而非仅仅一个能力估计值。我们的框架将解决这三个问题。

2.2 总览

与自适应测试的流程类似，TestAgent 也采用迭代式方法。图 2 展示了 TestAgent 整个工作流程的流水线。首先，需要建立**题库 (Question Bank)**。为此，需要先做**领域验证 (Domain Verification)** 以确定测试的维度，然后进行**数据整合 (Data Integration)**，再通过**认知诊断训练 (Cognitive Diagnosis Training)** 最终完成供 TestAgent 使用的题库构建。

与传统自适应测试不同，我们的 TestAgent 将整个测试过程转化为自然语言对话，从而在每一步打破「机械化的测试过程」。如图 1 所示，TestAgent 不让受测者直接为题目 q 选择答案 y ，而是以某个角色 C 提出的自然语言问句形式来呈现题目 q ——这正是**题目生成 (Question Generation)** 模块所做的事。受测者收到转化后的题目 $b = C(q)$ ，并以对话方式作答。接着，TestAgent 经过**自主反馈机制 (Autonomous Feedback Mechanism)** 和**异常管理 (Anomaly Management)** 模块，从对话中获得 y ，以应对「带噪声的作答数据」问题。这两个模块旨在获得更有效、更稳定的标签。

具体而言，自主反馈机制判断智能体所得到的标签 y 是否与受测者的作答一致。若不一致，系统会自动生成一道相似题目 b_{new} 让受测者作答，持续此过程直到二者一致为止。异常管理则用于处理题目作答 y 出现异常行为的情况，例如受测者试图猜答或回避作答。一旦发生异常，它会用自然语言引导、循序渐进地追问，降低收到误导性答案的可能。在获得准确标签 y 后，认知诊断模块更新受测者的能力，随后自适应题目选择模块从题库中选取最合适的题目。这一过程构成一个迭代循环。

为应对「粒度粗糙的测试输出」问题，TestAgent 利用**神经架构 (Neural Architecture)** 基于 θ_T 和作答序列 (**Response Sequence**) 给出初步分析，并结合**专家分析 (Expert Analysis)** 最终形成**诊断报告 (Diagnosis Report)**。该报告包含测试结果以及给受测者的建议。这些方法的实现细节将在后续章节展开。

图 2: TestAgent 的整体框架。通用数据基础设施 (Universal Data Infrastructure) 模块用于建立题库；TestAgent Planning 模块勾勒出 TestAgent 的工作流程；报告生成 (Report Generation) 模块用于生成诊断报告。用户回答题目后，大语言模型对题目作答进行归纳并把标签返回给认知诊断模型；认知诊断模型评估受测者当前能力，并用题目选择算法从题库中挑选最佳题目；最后大语言模型以对话方式与受测者交流。

2.3 通用数据基础设施

训练认知诊断模型是面临的首要挑战。我们提出了一种通用的认知诊断训练方法。图 3 展示了通用数据基础设施的流程。我们借助 GPT-4 的能力来**模拟不同能力的受测者**。例如，在 MBTI 测试中，可以让模型扮演不同人格来生成对话作答。已有研究表明，大语言模型能够可靠地模拟受测者 (Sekulić 等, 2024; Zhu 等, 2024)。通过让模型与所有题目持续交互，便生成了作答记录；随后基于生成的作答记录训练认知诊断模型，具体而言是训练每道题目的特征向量 β 。

对于不同的测试，第一步是确定其测试维度 M ，称为**领域验证 (Domain Verification)**。对于所有交互记录 E ，作答程度表示为 $y \in [0, M]$ ，此时可应用项目反应理论 (IRT) 中的**等级反应模型 (graded response model)**。得分小于 m 分的概率，可计算为「得 m 分或以上的概率」与「得 $m+1$ 分或以上的概率」之差。例如：

$$p_\theta(y = m | q) = p_\theta(y \geq m | q) - p_\theta(y \geq m + 1 | q).$$

其中：

$$p_\theta(y_i \geq m | q_i) = \left(1 + \exp(\theta - \beta_i^{(m)})\right)^{-1}.$$

将这些数据整合即可估计题目特征 F 。例如，题目特征可计算为答对比例。此外，也可采用诸如交叉熵损失等数据驱动技术来估计这些参数。所有题目特征通过拟合作答数据获得：

$$\beta_i = \arg \min_{\beta} \sum_{e \in E} \sum_{i \in F} y_i \log p(y = y_i | q_i).$$

通过这套方法，便可完成认知诊断模型的训练。

图 3：通用数据基础设施的流程（步骤一：领域验证；步骤二：数据整合；步骤三：认知诊断训练，基于项目反应理论）。

2.4 TestAgent Planning (规划)

TestAgent Planning 的流程如图 4 所示。与传统自适应测试不同，TestAgent 融入了两个关键模块——自主反馈机制 (**Autonomous Feedback Mechanism, AFM**) 和异常管理 (**Anomaly Management, AM**)，充分利用大语言模型的能力。这些模块有助于减少测试中的偏差、提升测试的交互体验。因此这两个组件至关重要，我们将在以下小节中详细介绍。

2.4.1 自主反馈机制 (AFM) 在对话式测试中，TestAgent 基于受测者的作答分析标签 y 。对于某些题目的测试 (如数学能力测试)，TestAgent 只需分析受测者是否答对即可；但在更一般的测试 (如人格测试) 中，TestAgent 需要从受测者的对话中分析出人格特质标签。此时很可能出现无法分析出标签的情况。例如，如果受测者回答「我不知道该怎么办」，那么显然偏离了作答，无法分析出标签。因此，我们提出自主反馈机制来解决这一问题。

当受测者给出作答时，自主反馈机制从三个角度进行评估以确定结果：**领域相关性 (domain relevance)**、**作答契合度 (response alignment)** 和 **逻辑连贯性 (logical coherence)**。

- **领域相关性**：TestAgent 将题目与答案关联起来。如果作答与原题 q 的预期答案显著偏离，则判定为不成功。
- **作答契合度**：作答被划分为表示与题目契合程度的 M 个类别。对于人格评估等复杂测试，从「完全不同意」到「完全同意」跨越七个维度，此时 $M = 7$ ，使作答分析颇具挑战。当作答契合度模糊不清时，判定为不成功。
- **逻辑连贯性**：自主反馈机制评估受测者的作答是否表现出内在逻辑一致性。即便作答与题目相关，但如果缺乏连贯性、自相矛盾或不合逻辑，也判定为不成功。逻辑连贯性确保作答不仅表面上与题目相关，而且逻辑上站得住脚。

如果以上三个方面的评估都成功，则返回标签；否则，自主反馈机制依据题目的属性、利用其智能生成一道相似题目。此过程持续进行，直到确定出标签为止。

2.4.2 异常管理 (AM) 在具体测试中，受测者可能碰巧猜对答案、故意给出错误答案，或对自己的作答表现出过度自信，这些都会扭曲评估结果。这类异常会导致错误的标签 y 。这些情况在实践中很常见。心理学中最常见的三类异常是：**猜测异常 (Guessing Anomaly)**、**误导异常 (Misleading Anomaly)** 和 **过度自信异常 (Overconfidence Anomaly)**。我们探讨这三类异常。

猜测异常：受测者可能凭运气或对题目一知半解作答，无法准确反映其真实能力。为评估异常对测试结果的影响，异常管理利用认知诊断的能力值 θ 来辅助判断。对于某道题目 q ，TestAgent 收到反馈标签 y ，认知诊断会基于当前能力 θ 估计受测者以标签 y 作答题目 q 的概率 $P(q, y)$ 。如果当前能力值使得以标签 y 作答的概率很低（即很难答出这个 y ），则启用自主反馈机制进行判断。

误导异常：在误导异常中，受测者故意给出错误答案，可能是出于对测试缺乏兴趣，或对题目存在心理抵触。异常管理基于上下文进行推理。通过追踪测试的上下文，可以识别受测者对同一主题多道题目作答中的不一致或矛盾。例如，如果受测者在某题中正确给出了一个概念的定义，却在后续题目中与之矛盾，那么很可能是故意误导。此时异常管理会拆解题目，展开更细致的对话以避免此类问题。

过度自信异常：当受测者即便在不确定时仍对答案表现出过度自信，就出现了过度自信异常。异常管理会接受作答，但要求受测者给出答案的理由。如果高自信缺乏充分的解释理由，模型则判定其缺乏依据。异常管理与自主反馈机制相辅相成：成功的异常检测往往需要新题目来验证异常，从而提升测试精度。

2.5 诊断报告生成

在进行了一定数量的测试题目后，认知诊断可以基于受测者的作答分析其能力。然而，对于像 MBTI 这样的人格测试，受测者更关心的是获得诊断报告。在这种场景下，向量 θ 本身并不可解释。因此，基于 θ 生成诊断报告就显得至关重要。

为实现这一点，我们需要基于 θ 为受测者生成文本标签（例如在 MBTI 测试中生成人格类型），并进一步生成诊断报告。首先，我们训练一个分类器，它以 θ 为输入，输出受测者的测试结果（例如在 MBTI 测试中，分类器可根据 θ 判定人格类型）。在题库构建阶段，我们保留了文本作答记录；通过结合测试结果、作答记录以及专家提供的测试报告，我们获得细粒度数据，用于微调 TestAgent 以生成诊断报告（详细实现见附录）。一旦微调完成，整个测试流程就告完成。受测者可以把 TestAgent 视为某一领域的专家，通过多轮对话来有效评估自己的技能水平并获得量身定制的建议。

3 实验

3.1 实验设置

我们使用所提出的数据合成方法标注了来自不同领域的三个数据集，包括教育数据集 **MATH**、人格测量数据集 **MBTI** 和心理健康测试集 **SCL**。**MATH** 数据集包含与数学相关的学生练习日志（私有数据集）；**MBTI** 数据集由「16 型人格」测试的题目组成；**SCL-90** 数据集则包含一项抑郁倾向测试的题目。我们使用全面的专家诊断报告和合成数据集作为微调数据，对 **ChatGLM2-6B** (GLM 等, 2024) 系列进行了微调。训练采用 **LoRA** 方法，学习率为 $2e-5$ ，全部在 Tesla A100:40G GPU 上完成。详细实现方法见附录。

3.2 准确性测试

数据划分与评估方法：为验证自适应测试方法的效率，我们将每位学生的数据随机划分为**查询集 (query set)** D_u 和**支持集 (support set)** D_t (Ghosh and Lan, 2021)。支持集 D_t 用于模拟题目选择过程以估计最终能力值 θ_t ，而查询集 D_u 用于评估这些估计的准确性。我们进行了 5 折交叉验证，其中 60% 用于训练、20% 用于验证、20% 用于测试。在验证集上采用早停 (early stopping) 来训练各方法的参数，并在每个 epoch 开始时随机打乱划分以防止过拟合。评估指标包括准确率 (Accuracy, Gao 等, 2021) 和 ROC 曲线下面积 (AUC, Bradley, 1997)。

对比方法：我们采用四个基线进行比较：**Random**——随机选题，作为相对若干基线的改进参照；**FSI** (Lord, 2012) ——利用最大 Fisher 信息选题；**KLI** (Chang and Ying, 1996) ——利用 Kullback-Leibler 信息选题；**MAAT** (Bi 等, 2020) ——采用主动学习 (active learning) 方法度量题目的信息量来选题。

表 1：不同方法在受测者成绩预测上的 ACC 与 AUC 指标的预测性能（分别在 MBTI、MATH、SCL 三个数据集上，给出测试长度为 5/10/20/50 步时的结果；加粗表示相对最优基线具有统计显著的优越性）。原文为三个子表，结构复杂，此处仅说明含义，详细数值见原文表 1。其中 TestAgent+FSI/KLI/MAAT 表示在对应选题算法上叠加 TestAgent 模块。

结果：我们的 TestAgent 算法代表了新一代自适应测试，旨在超越传统方法的局限。在表 1 中，我们将 TestAgent 与其他模型测试方法进行了全面比较，给出测试长度为 5、10、20、50 时的 ACC 和 AUC 指标作为评估各模型性能的基准。

我们的 TestAgent 框架在这三个数据集上整体表现优异。尤其值得注意的是 SCL 数据集上使用 TestAgent 模型时的出色表现，展示了 TestAgent 处理复杂数据集的卓越能力。与传统算法相比，我们的框架在大多数测试步数上都有提升，其中在测试第 5 步处的提升最为显著。平均而言，我们在 AUC@5 上取得了 1.77% 的相对提升，在 ACC@5 上取得了 0.91% 的显著提升。这些结果清楚地表明了我们的框架所提供的高精度能力估计。

3.3 能力估计模拟

在自适应测试评估中，模拟能力估计是一项关键的评估技术 (Vie 等, 2017)。测试的目的是准确估计学生的能力。我们在三个数据集上开展了模拟实验来估计能力。具体来说，我们采用真实能力 θ_0 与第 t 步能力 θ_t 之间的均方误差 (mean squared error) $E[\|\theta_t - \theta_0\|^2]$ 。由于真实能力 θ_0 未知，我们用受测者回答题库中所有题目的反馈来近似它 (Bi 等, 2020; Cheng, 2009)。

图 5 展示了基于 IRT 模型的不同方法在三个数据集上、测试题数从 1 到 20 时的指标。随着所选题目数量增加，我们发现 TestAgent 方法始终能取得更低的估计误差。与其他算法相比，TestAgent 能用更少的题目达到相同的估计误差。它在 SCL-90 数据集上表现最佳，到第 15 步就达到了与其他方法相近的水平。平均而言，TestAgent 能以少 **20% 的题目**达到相同的估计精度，体现了它在能力估计上的效率，即缩短了测试长度。

图 5：在 SCL 数据集上，这三幅图分别展示了我们方法与传统方法 (FSI/KLI/MAAT) 的均方误差对比。可以看到，在这三种算法中，引入 GPT 模块都改善了能力估计误差。

3.4 多维度评估

传统心理测试与基于 TestAgent 的测试之间，在设计理念、执行方式和用户体验上存在显著差异。由于个人偏好、测试目的和具体应用场景的不同，评判哪种方法更优往往因人而异。因此，我们采用更客观、更全面的方式来评估我们创新方法的优势。为此，我们精心招募了来自不同年龄段、性别和教育水平的 50 名志愿者参与评估活动（受测者详情见附录）。这些志愿者亲身体验了 TestAgent 与传统 MBTI 测试方法之间的差异。我们的目标是基于四个核心维度——「测试准确性」「自然语言流畅度」「交互体验」和「测试速度」——对这两种方法进行全面细致的对比评估。志愿者被分为两组，每组先做一种测试再做另一种。完成测试后，志愿者根据体验对每个维度按 1 到 5 分打分。

图 6：在准确性、流畅度、速度、交互四个维度上，TestAgent 与传统测试的箱线图对比。

图 6 显示了结果：在自然语言流畅度、交互体验和测试速度方面的体验显著超越了传统测试方法（假设检验部分见附录）。这是因为我们完全以对话形式进行测试，提升了用户体验，并结合自适应测试技术加快了测试进程。通过 50 名志愿者的真实反馈和客观打分，我们的新方法在四个维度上都展现出优势。这一结果不仅验证了我们创新方法的可行性和有效性，也为心理测试领域的未来发展提供了新思路和新方向。

3.5 案例研究

为了更好地分析 TestAgent，我们提供了对话案例研究，如图 7 所示。第一个场景代表标准情形。在正常交互中，题库初始化一道题目，由 TestAgent 归纳并以对话形式呈现；收到受测者作答后，应用异常检测模块。对于正常交互，可以直接得到分析标签；有了明确的标签，就用认知诊断模块更新学生能力，然后用自适应题目选择算法选取下一道合适的题目。第二个场景涉及标签不明确的情形——我们无法从受测者的作答中分析出标签。例如「我不知道」这样的回答无法通过作答契合度或误导异常检查来判定。在这种情况下，该情形被当作异常处理。此时，我们利用大语言模型的生成能力，基于原题生成相似题目，从而减少由主观因素引起的测试误差，并应对标签判定中的不确定性。最后，TestAgent 基于其与受测者的交互生成诊断报告。该报告的详细示例以及其他案例可在附录中找到。

图 7: TestAgent 在不同场景下的案例研究示例，展示了一般情形以及对标签模糊、过度自信、逻辑混乱等异常情形的处理。

4 结论

本文提出了一种创新的对话式测试方法，将 LLM 与自适应测试技术相结合，增强了传统测试方法的灵活性和准确性。通过引入 LLM 作为测试专家，我们能够通过多轮对话动态调整测试内容，同时提升用户体验和测试结果的准确性。实验结果表明，该方法在心理、能力和人格特质的测评中表现出色，有效缩短了测试时间，并增强了诊断报告的可解释性。未来，我们将引入利用语音、图像等模态的多模态系统来辅助大语言模型测试，从而拓展测试的维度。TestAgent 系统通过其生成的对话和个性化的题目选择，不仅提升了测试效率，也为心理测试的未来提供了新的洞见和方向。

5 局限性

TestAgent 是一种基于大语言模型的对话式测试。然而，大语言模型的输出可能存在波动甚至错误。我们在失败案例中随机抽取了 50 条交互记录：主要存在作答的回答与归纳中的幻觉 (hallucination) 问题 (34%)；其次，我们也发现使用基于大模型的指标时出现假阴性 (false negative) 的情形，即正确的预测被误判为错误，但占比相对较小 (12%)；在某些情况下，归纳和作答回复中产生了额外的冗余对话句子 (26%)；此外，模型有时会偏离 prompt 中指定的「测试专家」角色，转而以其他身份进行对话，这不符合测试规范 (28%)。具体错误示例见附录。同样，使用大语言模型会增加测试方差，这是由大语言模型本身的不稳定性导致的。这些问题将在未来工作中逐步解决。

6 影响声明

在大语言模型与自适应测试相结合时，不同受测者可能被推荐不同的题目，这引发了对公平性的担忧。本文聚焦于提出一种新颖的测试方法，而公平性是另一个独立的研究领域 (Zhang 等, 2024)，因此超出了本文的讨论范围。

致谢

本研究部分受到安徽省自然科学基金 (No. 2308085QF229) 和国家自然科学基金 (Grants No. U23A20319, 62406303, 62477044) 的支持。

附录

A 相关工作

自适应测试通常包括两个模块：认知诊断模型和题目选择算法。下面分别介绍这两个组件。

自适应测试 (1) 认知诊断模型 (Cognitive Diagnosis Models)：它建立在心理测量理论的基础上，在测评中日益流行，用于对学生潜在能力提供更个性化的反馈。它假设受测者的能力在整个测试过程中保持恒定 (Chang, 2015)，从而可以基于先前的作答、用基于梯度的优化来估计能力。最经典的形式是项目反应理论 (IRT) 模型 (Ackerman 等, 2003)。最简单的**单参数逻辑斯蒂 (1PL) 模型**表示为：

$$p(\text{答对题目}j) = \text{sigmoid}(\theta - b_j),$$

其中 $b_j \in \mathbb{R}$ 表示每道题目的特征， $\theta \in \mathbb{R}$ 是待估计的学生能力。其他代表性模型包括矩阵分解 (MF) (Koren 等, 2009; Toscher and Jahrer, 2010)、确定性输入-噪声与门 (DINA) (De La Torre, 2009; Von Davier, 2014)，以及近年提出的神经认知诊断模型 (Liu 等, 2019; Gao 等, 2022; Wang 等, 2023a; Shen 等, 2024; Liu 等, 2024a)，后者利用神经网络对学生与题目之间的交互进行建模。在给定具体的 CDM 和作答数据时，通常用最大似然估计 (二元交叉熵损失) 来估计 θ ，供后续选题算法使用。

(2) 选题算法 (Selection Algorithms)：选题算法是实现自适应测试中「自适应性」的核心组件，旨在用最少的测试步数准确估计学生能力。传统算法基于不确定性或信息度量，如著名的 Fisher 信息 (FSI) (Lord, 2012) 及其他方法 (Chang and Ying, 1996; Rudner, 2002; van der Linden, 1998; Veerkamp and Berger, 1997; Kang 等, 2017; Ma 等, 2023)。近年来也出现了一些数据驱动方法

(Nurakhmetov, 2019; Zhuang 等, 2022; Ghosh and Lan, 2021; Wang 等, 2023b; Li 等, 2023; Yu 等, 2023), 以及一些启发式方法 (Veldkamp and Verschoor, 2019; Gilavert and Freire, 2022; Feng 等, 2023; Mujtaba and Mahapatra, 2021; Yu 等, 2024)。然而, 这些方法大多基于传统纸笔测试, 缺乏通过「测试册」方式开展测评的优势, 可能无法实现全面的测评。

大语言模型与 AI 智能体: 近年来, 大语言模型在多个方向取得了诸多突破。基于大语言模型的智能体作为一个新兴领域, 正受到研究者越来越多的关注。许多应用已在特定领域和任务中被开发出来, 展示了这些智能体强大而通用的能力 (Yao 等, 2022; Wang 等, 2022; Kim 等, 2024; Chan 等, 2023)。通过领域微调、外部知识库等手段, 可以打造能在日常任务中协助用户的个人智能体。随着智能体能力的增强, 人类的参与变得愈发重要, 以有效引导和监督智能体的行为, 确保它们符合人类的需求与目标。人机交互智能体可以充当人类的向导, 已被应用于教育 (Kalvakurthi 等, 2023; Swan 等, 2023)、健康 (Ali 等, 2020; Yang 等, 2024) 等领域 (Gao 等, 2023; Schick 等, 2022), 展示了大语言模型的多样能力。大语言模型也能以与人类平等的伙伴方式使用, 例如作为富有同理心的沟通者 (Hasan 等, 2023; Liu-Thompkins 等, 2022), 或作为人类水平的参与者 (Bakhtin 等, 2023; FAIR)。本文提出的测评智能体是一种通用测评智能体: 利用相应数据集, 便可用本文方法获得对应的智能体, 从而提升各领域人类测评的有效性, 并为测试领域提供一种基于自然语言对话的新颖测评方式。

B 实现细节

本节是对前述实验的补充细节。

B.1 能力分类器训练 认知诊断模型给出向量 θ 作为诊断结果, 但它并不可解释。对于向量 θ , MBTI 测试包含四个维度: (I/E)、(N/S)、(T/F)、(J/P)。因此, 我们训练一个分类器, 其输入是诊断模型的 θ , 输出是对应这四个维度的四维向量, 从而把抽象的诊断数值转化为特征。具体而言, 对于标注为 Y_{label} 的人格分类数据, 认知诊断基于作答给出诊断结果 θ 。设 f 为一个映射函数, 可将人格分类映射为 0-1 向量, 例如 $f('ENFJ') = [1, 0, 1, 0]$ 。设 g 为我们训练的分类器, 则损失函数可写为:

$$L(\theta) = \text{CrossEntropyLoss}(g(\theta), f(Y_{label})).$$

由此即可实现分类器的训练。

B.2 微调细节 本研究的微调过程基于预训练的 ChatGLM 模型, 旨在为特定的人格诊断任务定制模型, 提升其在处理 MBTI 人格分析任务上的表现。为此, 我们通过 torchkeras 框架、采用 LoRA (Low-Rank Adaptation, 低秩适配) 技术进行微调。

数据处理: 微调数据分为三部分: 指令 (instruction)、角色标签 (character labels) 和专家报告 (expert reports)。指令是一段简单的 prompt, 格式如下: 「基于人格测试分类和相关对话, 分析角色特质并给出相应的诊断报告。」角色标签包括前述能力分类器训练所得的标签。专家报告是 MBTI 官方网站为 16 种人格类型提供的人格诊断报告。每条微调数据由「指令 + 角色标签」组合而成的输入, 以及作为输出的诊断报告建议 (对应专家的诊断报告) 构成。由此完成微调数据的构建。

参数设置: 最大序列长度设为 1024 个 token, 超过该长度的输入序列会被截断。对于 LoRA 方法, 使用三个关键参数: 秩 $r = 8$ (控制低秩矩阵的大小)、缩放因子 $\alpha = 32$ (调节低秩适配的影响)、dropout 率 $p = 0.1$ (训练时施加 10% 的 dropout 以助正则化)。训练相关超参数包括: 批大小 8、学习率 2×10^{-6} 、共 10 个训练 epoch。此外采用早停, 耐心值 (patience) 为 2 个 epoch (即验证损失连续若干 epoch 未改善则停止训练)。最后采用 'fp16' 混合精度训练以提升计算效率; 保存模型时最大分片大小设为 1GB, 以便分块保存供后续使用。

数据集信息: 下表给出各数据集的学生数、题目数和交互作答数。

指标	MBTI	SCL	MATH
受测者数	1000	500	1940
题目数	60	90	1485
交互数	60000	45000	61860

各数据集题目示例: MBTI——「你的个人工作风格更倾向于灵感迸发式的能量爆发, 而非系统化、持续性的努力。」SCL——「感到精力下降、活动变慢。」MATH——「对于底面半径为 1、高为 1 的圆柱, 其表面积是。」

B.3 多维度评估细节 多维度评估实验涉及来自不同领域的 50 名志愿者, 他们在四个维度上打分: 准确性、流畅度、速度、交互。准确性指志愿者的结果与其实际情况的契合程度, 以及最终诊断建议是否准确; 流畅度代表测试的顺畅程度; 速度指完成测试所花的时间; 交互衡量测试体验中的交互水平。然而人工标注难免存在偏差, 为减少此偏差, 我们选取了不同性别、年龄和教育背景的志愿者参与测试。

图 8: 在 MBTI 和 SCL 数据集上、使用 ChatGLM-6B 与 GLM-4-9B 在第 5、20 步的对比分析实验。

表 2: 志愿者人口统计信息——性别: 男 62%、女 38%; 年龄: 10–18 岁 10%、18–30 岁 46%、30–40 岁 20%、40–60 岁 18%、60–70 岁 6%; 教育水平: 有大学学历 46%、无大学学历 54%。

我们进行了显著性检验, 跨不同维度做了假设检验以消除人工标注的偏差:

- **性别 (独立样本 t 检验):** 原假设 H_0 为男女在某维度上的均分无显著差异, 备择假设 H_1 为存在显著差异。各维度 p 值 (准确性 0.1805、流畅度 0.1372、速度 0.2945、体验 0.3416) 均大于 0.05, 故不能拒绝原假设 (详见原文表 3)。
- **年龄 (单因素方差分析 ANOVA):** 各维度 p 值 (准确性 0.3971、流畅度 0.079、速度 0.0936、体验 0.2413) 均大于 0.05, 故不能拒绝原假设 (详见原文表 4)。
- **教育水平 (独立样本 t 检验):** 各维度 p 值 (准确性 0.1984、流畅度 0.2867、速度 0.2084、体验 0.7653) 均大于 0.05, 故不能拒绝原假设 (详见原文表 5)。
- **测试对比 (配对 t 检验):** 用配对 t 检验比较传统测试与 TestAgent 在各维度上的得分差异。原假设 H_0 为二者无显著差异, 备择假设 H_1 为 TestAgent 优于传统测试; 若 $p < 0.05$ 则认为新测试在该维度显著更优。各维度 p 值分别为: 准确性 0.01188、流畅度 $2.80\text{e-}09$ 、速度 $2.11\text{e-}08$ 、体验 $3.87\text{e-}09$, 均小于 0.05, 故拒绝原假设, 得出 TestAgent 在四个维度上均显著优于传统测试的结论 (详见原文表 6)。

图 9: 上方三图为 MBTI 数据集上的表现, 下方三图为 MATH 数据集上的表现 (各自针对 FSI/KLI/MAAT 三种算法的均方误差曲线)。

C 工作流程补充

(接正文) 当异常管理模块检测到受测者的作答很可能是猜测时, 会再次询问相似题目, 以降低随机猜测的影响。最后, TestAgent 基于其与受测者的交互生成诊断报告。通过这一过程, TestAgent 打破了传统测试方法的局限。

D 数据生成算法

为更好地理解数据生成方法, 此处给出数据合成的伪代码, 具体包括数据获取方法和认知诊断模型的训练方法 (详见算法 1)。

算法 1: 数据生成 (Data Generation)

输入: 题目集 Q , GPT-4 模型 G , 测试维度 M , 初始化参数 θ, β 。

1. 对每个 Epoch:
2. 大语言模型 G 扮演不同角色来回答题目 Q , 生成作答 Y ;
3. 将作答与题目组合, 得到数据 $\{(q_1, y_1), \dots, (q_n, y_n)\}$, 其中 $q_i \in Q, y_i \in [0, M]$;
4. 结束循环;
5. 当未收敛时:
6. 随机采样一个 mini-batch 的学生, 含训练集 Γ 和验证集 Ω ;
7. 用训练集 Γ 和损失函数 $L(q, y; \theta)$ 训练, 其中 $L(q, y; \theta) = E_{y \sim p(y|q)}[-\log p_\theta(y | q)]$;
8. 用验证集 Ω 验证, 收敛时停止训练;
9. 结束循环;
10. 得到完整的带标签数据 $\{(q_1, \beta_1), \dots, (q_n, \beta_n)\}$ 。

E 数据流案例

为更好地理解 TestAgent 的工作流程, 这里以 MBTI 测试为例说明整个测试过程:

通用数据基础设施: 1) 领域验证——MBTI 测试需要 4 个维度 (I/E、N/S、T/F、J/P); 2) 数据整合——用 GPT-4 模拟交互数据来生成 MBTI 数据; 3) 认知诊断训练——用模拟交互数据训练认知诊断模型。

TestAgent Planning: 1) 题目生成——从题库生成对话形式的题目给受测者; 2) 受测者作答; 3) 自主反馈系统与异常管理——分析作答, 若检测到标签异常则生成新题并回到步骤 2; 4) 认知诊断——基于作答记录诊断得到能力向量; 5) 自适应题目选择——从题库自适应选题; 6) 重复测试——重复步骤 1–5 直到测试完成。

报告生成: 1) 神经架构——把诊断模型的交互记录传入训练好的神经网络得到标签 (如 INTJ); 2) 专家分析——结合专家分析与神经网络结果进行微调; 3) 诊断报告——基于测试结果输出诊断报告。

F Prompt

此部分包含正文提到的若干环节的输入与 prompt, 包括标签判定、自主反馈机制、异常管理、题目转化等方法 (原文以表 8–表 12 形式给出各方法的输入和 prompt 模板, 结构复杂, 未逐字转录, 详见原文)。

G 示例

本节给出测试中失败的若干示例，以及一份诊断报告样例。

G.1 失败示例：原文表 13—表 16 分别给出幻觉 (hallucination)、假阴性 (false negative)、冗余作答、不当角色扮演 (inappropriate impersonation) 四类错误的具体例子，详见原文。

G.2 诊断报告：原文给出了为受测者「Alice」生成的完整诊断报告样例（含人格类型、优势/劣势分析与建议），详见原文。

参考文献 (*References*) 按约定未翻译，详见原文。