

调和习题检索的效率与效果：一种面向计算机自适应测试的不确定性削减哈希方法 (Reconciling Efficiency and Effectiveness of Exercise Retrieval: An Uncertainty Reduction Hashing Approach for Computerized Adaptive Testing)

原文: 3726302.3730072.pdf (SIGIR '25) · 译者: Claude · 译于 2026-06-27 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT)、认知诊断模型 (Cognitive Diagnosis Model, CDM)、习题选择模块 (Exercise Selection Module, ESM)、学习哈希 (Learning to Hash)、局部敏感哈希 (Locality-Sensitive Hashing, LSH)、信息熵 (information entropy)、不确定性削减 (Uncertainty Reduction)、项目反应理论 (Item Response Theory, IRT)

摘要

随着智能教育的快速发展，计算机自适应测试 (CAT) 因其能够为每位考生量身定制习题而受到广泛关注。CAT 的自适应性主要通过对两个核心组件——认知诊断模型与习题选择模块——的交替优化来实现。然而，现有 CAT 方法尽管取得了显著成果，却往往以高昂的时间成本为代价。基于统计的方法由于计算复杂而带来更高的时间开销；数据驱动的方法则由于强化学习中的迭代过程进一步加剧了时间上的低效，使得在评估效果与时间效率之间难以取得平衡。为此，本文提出 HashCAT，一种基于学习哈希的高效 CAT 方法，旨在平衡效率与评估效果。我们的方法包含两个阶段：哈希表征生成与习题选择。在第一阶段，我们设计了一个信息对齐模块和一个全新的认知诊断函数，用于建模考生与习题之间的交互，生成具有清晰物理意义的哈希表征。在第二阶段，我们提出一种基于不确定性削减的算法，利用信息熵来量化学生能力估计中的不确定性，并选择能最有效削减这种不确定性的习题。在四个真实数据集上的实验结果表明，所提方法在显著提升习题选择效率的同时，保持了具有竞争力的评估性能。代码匿名公开于 <https://github.com/sherklock/Intelligent-Education/tree/main/HashCAT-main>。

CCS 概念: 应用计算 → 计算机辅助教学。

关键词: 计算机自适应测试、习题检索、学习哈希。

1 引言

随着个性化学习的兴起，计算机自适应测试 (CAT) 作为一种很有前景的能力评估技术受到了广泛关注，它致力于通过结合教育学理论来有效评估学习者对特定知识概念的掌握程度。与传统的纸笔测试不同，CAT 独特的自适应特性能够为每位考生定制题目，准确刻画学习者的能力水平，常被描述为“为每位考生量身定制”。

总体而言，CAT 的自适应性是通过两个交替优化的核心组件来实现的：认知诊断模型 (CDM) 和习题选择模块 (ESM)。如图 1 所示，CDM 通过分析考生此前对习题的作答来刻画其当前的知识水平；基于得到的能力画像，ESM 个性化地选择合适且有效的题目，以辅助下一步的测量。两者相互协助、交替反复，直到满足预设的停止条件，此时记录学习者的最终能力估计，作为本次 CAT 过程的最终结果。

近年来 CAT 得到了广泛发展。研究者主要聚焦于通过引入先进的基于神经网络的认知诊断模型、以及改进习题选择策略来增强其能力评估能力。一般来说，现有 CAT 方法中的习题选择算法可分为两类：基于统计的方法和数据驱动的方法。具体而言，基于统计的方法通过为每道习题赋予一个数值（如 Fisher 信息量）来优化自适应评估过程，并基于当前对学习者的能力估计，选择能最大化信息增益的那道题。例如，MAAT 由质量、多样性、重要性三个关键模块组成，它们协同工作，通过评估“期望模型变化”来衡量每道习题的信息含量。相比之下，数据驱动的方法基于学习者以往的交互记录，自动学习并优化习题选择算法，从而避免了设计基于统计方法所带来的复杂性。例如，NCAT 将 CAT 表述为一个双层优化问题，将其作为等价的强化学习任务来求解，并提出一种注意力神经策略来建模复杂的非线性交互。

然而，无论是基于统计的方法还是数据驱动的方法，在取得卓越性能的同时，这些成果都是以巨大的时间消耗为代价的。具体而言，现有基于统计的方法在计算习题信息含量时涉及复杂运算，导致处理大规模题库时时间成本显著增加。相比之下，数据驱动的方法使用强化学习策略优化习题选择算法，由于智能体与环境的交互以及迭代过程，它们同样面临高昂的时间开销。鉴于此，本研究旨在优化 CAT 习题选择算法中时间效率与评估效果之间的平衡。受已有研究启发，我们将 CAT 概念化为一个习题检索任务。与传统 CAT 方法不同，基于信息检索的选择过程被视为考生与习题之间的匹配过程，通过利用已有信息进行快速检索来提升选择效率。在此基础上，我们引入学习哈希的思想，对考生与习题都采用离散的哈希表征，利用哈希表征较低的计算复杂度来提升检索效率。

然而，将这一思想落实到 CAT 中存在若干重大挑战。要充分发挥学习哈希在该场景下的潜力，必须解决以下关键问题：(1) 如何有效生成习题与考生的哈希表征？在 CAT 场景下，我们需要得到具有清晰物理意义的哈希表征。(2) 如何优化哈希表征的生成过程？传统的哈希表征生成方法不足以充分捕捉学习者与习题之间复杂的交互关系。针对考生与习题的离散表征，我们需要设计一个新的诊断函数来准确刻画两者之间的交互，从而优化哈希表征的生成机制。(3) 如何基于哈希表征设计有效的习题选择策略？我们需要设计一个可靠的习题选择算法，充分利用哈希表征的计算特性来提升检索效率，同时有效避免因信息损失导致评估结果可靠性下降。

为此，本文提出 HashCAT——一种基于不确定性削减与学习哈希的 CAT 方法，它包含两个阶段：哈希表征生成与习题选择。具体而言，在哈希表征生成阶段，我们基于学习者与习题的潜在嵌入得到它们的哈希表征。为了确保哈希表征与实值表征在语义信息和结构上尽可能一致，我们设计了一个信息对齐模块（原文：information unification module）。此外，为了在 CAT 场景下优化哈希表征生成过程，我们提出了一个全新的诊断函数，用于捕捉学习者与习题之间的交互关系，从而优化哈希表征生成过程。在习题选择阶段，我们设计了一个基于不确定性削减的习题选择算

法，利用得到的哈希表征和习题特征，使用信息熵量化学生能力评估中的不确定性，并选择能最有效削减这种不确定性的习题。最后，我们在四个真实数据集上验证了所提方法，展示了它在时间效率与评估效果之间的平衡。

图 1：典型 CAT 流程示意图，强调时间效率是习题检索中的一个关键问题。（学生作答 → CDM 诊断能力 → ESM 从题库选题 → 反馈，循环往复，累计时延不断增加。）

2 相关工作

2.1 计算机自适应测试

计算机自适应测试（CAT）通过在认知诊断模型与习题选择算法之间交替进行、并利用有限的选题步数，来提升对考生能力评估的准确性。

CAT 中的习题选择算法长期以来一直是研究的核心。在传统 CAT 方法中，鉴于项目反应理论（IRT）的特性，两种基于统计的选择算法——最大 Fisher 信息量（Maximum Fisher Information）和 Kullback-Leibler 信息量——使用最为广泛。相比之下，BECAT 通过理论估计找到对考生真实能力的近似估计，并在此基础上提出了一个用于 CAT 的有界能力估计框架。随后，数据驱动的方法得到了广泛关注。其中一个代表性方法是 GMOCAT，它使用图神经网络来描述习题与知识概念之间的关系。此外，针对现有选题策略的时间复杂度与习题数量呈线性关系的问题，SECAT 引入了一个具有高效搜索能力的 CAT 框架。尽管该框架能够提升习题选择效率，但它所需的前置工作复杂且耗时。这些工作几乎都聚焦于提升评估效果，却很少涉及习题选择效率这一关键问题。因此，我们的目标是设计一种在保持评估效果的同时提升时间效率的全新 CAT 方法。

2.2 学习哈希

近年来，数据的爆炸式增长激发了人们对高效检索方法的浓厚兴趣。在主流检索方法中，学习哈希因其能够利用数据的内在属性而受到广泛关注。学习哈希的主要目标是设计针对特定任务的哈希函数，将原始数据映射为紧凑的二值编码，从而在保持检索精度的同时提升检索效率。随着擅长特征表征的深度学习兴起，基于深度学习的哈希方法在各个领域展现出令人印象深刻的性能。这些方法的最新进展——如深度有监督哈希、三元组损失函数、基于神经网络的量化——进一步推动了检索效果与效率的提升。

在 CAT 中，尽管学习哈希被广泛应用，但仍存在三大主要挑战：获得具有物理意义的、刻画考生能力与习题难度的哈希表征；设计基于哈希表征的诊断函数并优化哈希生成；以及构建在时间效率与评估准确性之间取得平衡的高效习题选择策略。

3 预备知识

在常规的智能教育场景中，CAT 能够基于考生的能力反馈自适应地为其选择习题，从而准确评估其能力。在 CAT 中，考生群体用集合 $S = \{s_1, s_2, \dots, s_{|S|}\}$ 表示，题库用集合 $E = \{e_1, e_2, \dots, e_{|E|}\}$ 表示，知识概念用集合 $C = \{k_1, k_2, \dots, k_{|C|}\}$ 表示。考生的练习日志 R_s 通常定义为一个三元组 $R_s(s_i, e_j, r_{ij})$ ，若考生 s_i 正确作答习题 e_j 则 $r_{ij} = 1$ ，否则 $r_{ij} = 0$ ，其中 $s_i \in S$ 、 $e_j \in E$ 。在 CAT 系统中，假设考生的真实能力不发生变化。经典的 CAT 系统由两个核心模块组成：认知诊断模块 M 和习题选择算法 π 。CAT 过程可表示为：

$$e_i^t \leftarrow \pi(\theta_i^{t-1} \mid Q_u, \Omega), \quad \theta_i^t \leftarrow M(e_i^t \mid \xi), \quad (1)$$

其中 Q_u 表示考生 s_i 的候选题库， θ_i^{t-1} 表示考生 s_i 在测试步骤 $t-1$ 时的能力反馈， e_i^t 表示习题选择算法在步骤 t 为考生 s_i 选出的未作答习题。此外， θ_i^t 表示 M 在步骤 t 评估出的考生 s_i 的能力。 Ω 、 ξ 分别是 M 和 π 的参数。在 CAT 中， M 与 π 交替进行 T 步后过程停止， T 是终止测试的最大步数。

在本工作中，我们将考生的历史学习日志 R 输入到所设计的哈希表征提取模型中，生成考生能力的哈希表征 b_s 和习题难度的哈希表征 b_e ，以及习题的实值难度与区分度。我们还提出了一个专为哈希表征设计的全新诊断函数，用于建模考生与习题之间的交互，从而完善哈希表征生成模块。我们基于哈希的表征学习提取了多维度的习题特征。选择算法将考生能力与习题特征相结合，通过熵驱动的准则优先选择那些能最小化能力不确定性的习题。该框架在保证可靠评估的同时实现了亚线性时间的检索效率。

4 方法

概述。我们的 HashCAT 框架通过为考生与习题引入哈希表征来提升 CAT 的效率。如图 2 所示，它由四个组件构成：(1) 哈希表征生成模块 (Hash Representation Generation Module, HRGM)；(2) 信息对齐模块 (Information Alignment Module, IAM)；(3) 基于哈希的诊断模块 (Hash-based Diagnosis Module, HDM)；(4) 基于不确定性削减的习题选择。具体来说，HRGM 负责生成考生知识概念掌握向量的哈希表征以及习题难度的哈希表征。但众所周知，将实值表征转换为哈希表征会带来量化损失，导致两种表征之间存在显著差异。为解决这一问题，IAM 被设计用来在哈希表征生成过程中最小化信息损失，确保哈希表征尽可能多地保留其实值对应物的信息。此外，为了在哈希表征框架下准确刻画考生与习题之间的交互关系，我们在 HDM 中引入了一个全新的交互函数，该函数专门用于优化哈希表征生成过程。最后，利用考生与习题的哈希表征，我们在不确定性削减策略下执行真正的 CAT 习题选择过程，以确保效率与评估效果。在 CAT 过程的每一步，考生能力的实值表征由 M 提供，而我们的哈希表征生成模块产出习题的哈希表征。在选择过程中，我们对 M 生成的考生能力实值表征施以同样的生成策略，以得到学生能力的哈希表征。

图 2: HashCAT 框架示意图。(a) 与 (b) 共同构成哈希表征生成过程, 包含 HRGM、IAM、HDM 模块; (c) 表示基于不确定性削减的习题选择。

4.1 哈希表征生成

为生成适于哈希表征的输入向量, 我们从知识概念的角度刻画考生与习题的嵌入特征。基于已有的考生练习记录 R , 我们通过可训练的参数矩阵对考生、习题和知识概念进行编码, 得到初始嵌入向量。利用这些初始化的嵌入, 我们推导出有意义的考生与习题表征向量。具体而言, 我们得到考生的知识概念掌握向量 $\gamma \in \mathbb{R}^{1 \times |C|}$ 、习题的知识概念难度向量 $\delta \in \mathbb{R}^{1 \times |C|}$, 以及习题的区分度因子 $\psi \in (0, 1)$, 如式 (2) 所示:

$$\gamma = h_s \times (h_K)^T, \quad \delta = h_e \times (h_K)^T, \quad \psi = \phi(h_e \times W + b), \quad (2)$$

其中 $h_s = x_s \times W_s$ 、 $h_e = x_e \times W_e$ 、 $h_k = x_k \times W_k$, $h_s, h_e, h_k \in \mathbb{R}^{1 \times d}$ 分别表示考生 s 、习题 e 、知识概念 k 的初始嵌入表征。每个知识概念被编码为一个 d 维向量, 从而可为知识概念集合 C 推导出表征矩阵 $h_K \in \mathbb{R}^{|C| \times d}$ 。 $x_s \in \{0, 1\}^{1 \times |S|}$ 、 $x_e \in \{0, 1\}^{1 \times |E|}$ 、 $x_k \in \{0, 1\}^{1 \times |C|}$ 分别是表示考生 s 、习题 e 、知识概念 k 的独热 (one-hot) 表征向量。 $W_s \in \mathbb{R}^{|S| \times d}$ 、 $W_e \in \mathbb{R}^{|E| \times d}$ 、 $W_k \in \mathbb{R}^{|C| \times d}$ 、 $W \in \mathbb{R}^{d \times 1}$ 均为可训练矩阵, ϕ 表示激活函数。

在得到考生 s 的知识概念掌握向量 γ 和习题 e 的知识概念难度向量 δ 之后, 我们从这两个实值表征向量生成相应的哈希表征向量。下面以习题一侧为例说明该过程。

具体而言, 我们构建了一个双向信息编码机制, 将输入向量嵌入到一个分布受约束的低维潜在空间中。该生成过程包含两个关键步骤: 第一, 一个参数化的编码器将输入映射为潜在分布的统计参数 (如均值与标准差); 第二, 通过引入随机扰动, 从该分布中采样潜在变量。随后, 这些潜在变量被转换为哈希表征。

为了生成二值哈希表征 (即 0 和 1) 同时保留梯度反向传播的能力, 我们基于采样理论设计了一个平滑变换机制。具体而言, 为增强哈希表征的稀疏性与判别力, 我们在额外维度上引入零向量来扩展潜在变量, 这一操作在每个类别与其潜在哈希值之间提供了清晰的映射。随后, 将从特定噪声分布中采样的随机扰动加到扩展后的向量上, 再通过参数化变换函数进行归一化。该归一化过程确保生成的哈希表征符合期望的二值格式, 同时为优化保持可微性, 如式 (3) 所示:

$$z_e = \mu + \varepsilon \cdot \sigma, \quad b_e = \frac{\exp((\log z_e + g)/\tau)}{\sum_j \exp((\log z_{e_j} + g)/\tau)}, \quad (3)$$

其中 μ 和 σ 表示底层分布的均值与标准差, ε 是从标准正态分布中采样的随机变量, $b_e \in \{0, 1\}^{|C|}$ 表示知识概念难度向量的哈希表征, g 是从噪声分布中采样的扰动, τ 是控制变换平滑度的平滑参数。 τ 越小, 哈希表征越接近离散值; τ 越大, 则越能保持平滑性与可微性。最终, 连续采样机制生成最终的哈希表征, 在训练时保证可微, 在推理时产出离散的哈希值。

为增强模型潜在变量的泛化能力, 我们在优化目标中引入了潜在分布与标准正态分布之间的一项约束。因此, 最终的优化目标由两部分组成: 重构损失 (衡量 δ 与其重构 $\hat{\delta}$ 之间的差异) 和分布对齐损失, 如式 (4) 所示:

$$\mathcal{L}_E^H = \|\delta - \hat{\delta}\|_2^2 + D_{KL}(q(z|x) \| p(z)) \quad (4)$$

4.2 信息对齐

值得注意的是, 将实值表征转换为哈希表征长期以来已被证明会造成量化损失, 导致两种表征之间存在较大差异。为确保语义信息与结构信息之间的最大一致性, 我们为实值表征与哈希表征设计了一个信息对齐模块。为清晰起见, 仍以习题一侧为例。

为高效地从实值表征与哈希表征中聚合邻居信息, 我们采用局部敏感哈希 (LSH)。LSH 因其数据无关性与高效的时间复杂度, 被公认为是近似最近邻搜索的有效方法, 尤其适合处理大规模数据集。考虑到实值表征的连续性与哈希表征的离散性, 我们为每种表征设计了不同的哈希函数来生成哈希码。遵循 LSH 的原理, 具有相同哈希码的考生或习题被投影到同一个桶中, 并被视为一个簇。对于实值表征, 我们采用的哈希函数定义如下:

$$h_e = \left\lfloor \frac{z_e \cdot a + c}{w} \right\rfloor, \quad (5)$$

其中 a 是从标准正态分布中随机采样的向量, c 是随机数, w 是常数。对于哈希表征, 我们从已有的 C 维哈希表征中选取 d 个维度来生成哈希码: $h_{e'} = b_e[b]$ 。

从实值数据桶中, 我们可以得到相似度矩阵 $A \in \{1, 0\}^{|E| \times |E|}$ 来描述桶内的数据关系; 同理, 也可得到哈希表征的相似度矩阵 $A' \in \{1, 0\}^{|E| \times |E|}$ 。以实值表征为例, 如式 (6):

$$A_{i,j} = \begin{cases} 1, & \text{若 } h_i^e = h_j^e \\ 0, & \text{若 } h_i^e \neq h_j^e \end{cases} \quad (6)$$

基于上面得到的数据，并结合考生侧与习题侧，我们需要优化信息对齐模块，如式 (7)：

$$\mathcal{L}_{con} = \mathbb{E}_{i,j}[\|z_i^s - z_j^s\|^2 A'_{i,j}] + \mathbb{E}_{i,j}[(b_i^s)^T b_j^s A_{i,j}] + \mathbb{E}_{i,j}[\|z_i^e - z_j^e\|^2 A'_{i,j}] + \mathbb{E}_{i,j}[(b_i^e)^T b_j^e A_{i,j}], \quad (7)$$

其中 $\|z_i^e - z_j^e\|^2$ 表示两个实值表征向量之间的欧氏距离平方。优化思路是：以习题侧为例，第一项的目标是在哈希表征相似的情况下，使实值表征之间的欧氏距离尽可能小；第二项的目标是在实值表征相似的情况下，使哈希表征在内积上取得更大的值。通过这种优化方式，一致性损失在训练中促进了实值表征与哈希表征之间的一致性，确保模型学到的表征能有效捕捉考生与习题之间的潜在关系。

4.3 基于哈希的诊断

传统的哈希表征方法通常依赖内积或余弦相似度运算来优化哈希表征生成过程。然而，在教育情境下，此类运算无法捕捉考生与习题之间错综复杂的关系。为克服这一局限并更好地建模复杂的交互关系，我们提出了一个专为哈希表征量身定制的认知诊断函数，如式 (8)：

$$F_H(b_s, b_e) = Q \cdot [\alpha \cdot (1 - b_s \oplus b_e) + \beta \cdot \text{Interaction}(b_s, b_e)] \cdot \psi, \quad (8)$$

其中 Q 是诊断任务中描述习题与知识概念关系的 Q -矩阵； b_s 与 b_e 分别表示考生 s 与习题 e 的二值表征； ψ 是习题难度的区分度； $\oplus$ 是二进制中的异或 (XOR) 运算； $\text{Interaction}(b_s, b_e)$ 是内积运算； α, β 是超参数。具体而言， $b_s \oplus b_e$ 表示在哈希表征下考生 s 与习题 e 在知识概念上的差异； $1 - b_s \oplus b_e$ 评估考生对该习题的掌握程度。 $b_s \oplus b_e$ 表示的差异越大，说明考生 s 正确作答习题 e 的概率越低（由 $1 - b_s \oplus b_e$ 的值反映）。此外，受实值表征中所用操作的启发， b_s 与 b_e 之间的点积捕捉考生对知识概念的掌握与习题 e 之间的相关性。点积值越高，说明考生 s 的当前能力与习题 e 的难度越匹配，从而正确作答的可能性越大。值得注意的是，在教育场景中，单调性假设是一个不可忽视的性质，这一假设应被转化为交互函数的一个属性。

证明：我们首先定义函数 $f(b_s) = \alpha \cdot (1 - b_s \oplus b_e) + \beta \cdot \text{Interaction}(b_s, b_e)$ 。其中 $b_s \oplus b_e$ 用于度量两个哈希表征向量之间的差异： $XOR_Sum(b_s, b_e) = \sum_{k=1}^d (b_s[k] \oplus b_e[k])$ ，其中 d 是哈希向量的维度。当 b_s 与 b_e 越相似时， $XOR_Sum(b_s, b_e)$ 越小，从而使 $1 - b_s \oplus b_e$ 增大，因此 b_s 与 b_e 之间的匹配度单调增加。此外，由点积运算表示的 $\text{Interaction}(b_s, b_e)$ 一项评估考生与习题之间的匹配度，当 b_s 与 b_e 越相似时该项也单调增加。综上，当函数 $f(b_s)$ 对 b_s 求偏导时：

$$\frac{\partial(1 - b_s \oplus b_e)}{\partial b_s} \geq 0, \quad \frac{\partial \text{Interaction}(b_s, b_e)}{\partial b_s} = b_e \geq 0. \quad (9)$$

因此，总导数为：

$$\frac{\partial f(b_s)}{\partial b_s} = \alpha \cdot \frac{\partial(1 - b_s \oplus b_e)}{\partial b_s} + \beta \cdot b_e \geq 0. \quad (10)$$

由于 $\alpha, \beta > 0$ ，可见 $f(b_s)$ 对 b_s 单调递增，满足单调性假设。

最后，我们使用输出 $y_{ij} = F_H(b_s, b_e)$ 与真实标签 r_{ij} 之间的交叉熵来优化哈希表征下的诊断函数，如式 (11)：

$$\mathcal{L}_{Hcdm} = - \sum_{ij} [r_{ij} \log y_{ij} + (1 - r_{ij}) \log(1 - y_{ij})]. \quad (11)$$

综上，整个哈希表征生成过程的融合损失函数为：

$$\mathcal{L}_H = \mathcal{L}_{Hcdm} + \mathcal{L}_S^H + \mathcal{L}_E^H + \mathcal{L}_{con}. \quad (12)$$

4.4 基于不确定性削减的习题选择

经过前一阶段，我们可以得到习题的哈希表征，以及习题难度与习题区分度这两个实值信息。在 CAT 过程中，我们采用与生成习题哈希表征相同的方法，把从基础认知诊断模型得到的考生能力信息处理为哈希表征。

在设计选择策略时，我们采用了一种基于不确定性削减的方法。其核心思想是选择能最小化考生能力评估不确定性的习题。为量化这种不确定性，我们引入了信息熵这一广泛用于度量随机变量不确定性的指标。熵值越大，对考生能力评估的不确定性越高；反之，熵值越小，不确定性越低。具体而言，习题的选择是通过计算每道习题对考生能力评估所带来的不确定性削减（即熵的变化）来进行的：

$$\Delta H = H_{prior} - H_{post}, \quad (13)$$

其中 H_{prior} 是选题前的信息熵，表示作答习题之前对考生能力评估的不确定性； H_{post} 是选题后的信息熵，表示作答所选习题之后对考生能力评估的不确定性。我们的目标是选择能最大化 ΔH 的习题，从而优先选取那些能带来最大不确定性削减的习题。

具体而言，基于当前考生能力与习题特征，预测考生正确作答每道习题的概率 P_c ，并用 P_c 计算当前的信息熵：

$$P_c = \{1 + \exp\{-\kappa \cdot (M_{se}(b_s, b_e) \cdot \psi) + \zeta \cdot \mathbb{E}(\delta)\}\}^{-1}, \quad (14)$$

$$H_{prior} = -P_c \cdot \log(P_c) - (1 - P_c) \cdot \log(1 - P_c), \quad (15)$$

其中 M_{se} 表示 1 减去 b_s 与 b_e 之间汉明距离 (Hamming distance) 的运算， $\mathbb{E}(\delta)$ 表示习题难度向量 δ 的均值。在选定一道习题后，我们估计考生作答该习题之后的信息熵 H_{post} 。这里我们假设考生作答一道习题后，对其能力预测的不确定性会下降，并通过特定规则削减 H_{prior} 。我们定义一个难度调整因子并结合指数衰减来度量信息熵的变化，如下：

$$H_{post} = H_{prior} \cdot \left(-\frac{\delta_{gap}}{\exp(\mathbb{E}(\delta))} \right), \quad (16)$$

其中 $\delta_{gap} = |\mathbb{E}(\theta) - \mathbb{E}(\delta)|$ ， $\mathbb{E}(\theta)$ 表示在 CAT 选题过程中所评估的考生当前能力的均值。通过引入这一度量，我们既考虑了考生的能力，也考虑了习题的难度，从而确保为每位考生选择符合其需求的个性化习题。

此外，在 CAT 过程中，对考生能力的评估随每一步选题与作答而逐步更新，因此这一动态决策过程通常被视为一个马尔可夫过程。为此，我们将 ϵ -贪心 (ϵ -greedy) 与 UCB 策略引入选择算法，设计了一个结合两种策略的混合算法。具体而言，在选题的前 S 步采用 ϵ -贪心：以概率 ϵ 随机选择一道习题，以概率 $1 - \epsilon$ 贪心地选择 ΔH 最大的习题。同时，记录每道习题被选中的次数及其对应的 ΔH 作为奖励。在随后的 S 步中，我们采用 UCB (Upper Confidence Bound, 上置信界) 策略来进一步平衡探索与利用。UCB 策略选择 UCB 值最高的习题，该值作为每道习题的上置信界来计算。具体而言，习题的 UCB 由两部分组成，如式 (17)：

$$UCB = \frac{R_e}{N + \omega} + \sqrt{\frac{2 \cdot \ln(T_Q)}{N + \omega}}, \quad (17)$$

其中 R_e 表示习题的累计奖励，定义为该习题被选中的所有实例的 ΔH 值之和； N 表示该习题被选中的次数； T_Q 是所有习题被选择的总次数； ω 是为防止除零错误而引入的常数。准确地说，第一部分“利用项”反映习题已知的表现；第二部分“探索项”会随着习题被选中次数减少而增大，鼓励算法去探索那些较少被选中的习题。通过结合这两部分，UCB 策略确保选择那些能最小化不确定性（由 ΔH 度量）的习题，同时探索潜在的高价值习题。这种方法使算法能够随时间获得更有效且更稳健的评估结果。

5 实验

我们在四个真实教育数据集上开展实验来评估我们的 CAT 方法，旨在回答四个关键问题：**RQ1**：所提出的 CAT 方法在提升 CAT 整体性能方面的效果与效率如何？**RQ2**：所设计的关键组件是否有助于本方法性能的提升？**RQ3**：使我们的方法能够提升习题选择效率的内在机制是什么？**RQ4**：本方法对参数的敏感性如何？

5.1 实验设置

5.1.1 数据集描述 我们使用了四个真实教育数据集,分别为 NIPS-EDU、ASSIST1213、JUNYI 和 PTADISC。NIPS-EDU 是 NeurIPS 2020 教育挑战赛的数据集,来自学生在 Eedi (一个教育平台) 上对习题的作答。ASSIST1213 采集自在线辅导系统 ASSISTments, 我们使用了 2012 至 2013 年间的的历史数据。JunYi 同样采集自一个在线学习网站。PTADisc 源自在线学习平台 PTA, 这是一个面向高校与社会的自动化项目评测与开放教学辅助平台。我们采用先前工作的数据处理方式, 分别用 80%-10%-10% 的学生进行训练、验证和测试。处理后数据集的统计信息见表 1。其中, 数据驱动方法需要基于支持集 (support set) 和查询集 (query set) 进行训练和测试。

表 1: 数据集统计信息。

数据集	NIPS-2020	JUNYI	ASSIST1213	PTADISC
# 学生	3,934	54,564	16,412	18,768
# 习题	900	565	3,906	3,262
# 知识概念	56	30	119	50
# 日志	1,222,047	1,711,210	970,202	5,720,582

5.1.2 基线方法 为证明本方法的有效性, 我们将其与使用两种不同认知诊断模块的习题选择策略进行比较。认知诊断模块采用两个代表性模型: NCD 和 MIRT。我们选取以下最先进的选择策略作为基线: (1) **Random**: 随机选择算法。(2) **MKLI**: 选择 Kullback-Leibler 信息量移动平均最大的习题, 确保高效评估并支持多维学生能力。(3) **MAAT**: 一种基于主动学习的方法, 包含质量模块、多样性模块和重要性模块, 利用 CDM 的期望模型变化 (EMC) 来选题。(4) **BECAT**: 通过选择一个与完整作答梯度相吻合的习题子集, 来估计 CAT 的有界能力。(5) **NCAT**: 将 CAT 问题定义为双层优化问题, 用强化学习求解 CAT 任务, 并提出注意力神经策略来建模考生与习题之间复杂的非线性交互。(6) **GMOCAT**: 用图神经网络嵌入习题与概念之间的关系, 并在多目标强化学习框架中引入质量、多样性、新颖性三个目标。(7) **SECAT**: 一种 CAT 搜索框架, 通过递归地将整个习题空间划分为许多对数规模的子空间, 在选题过程中实现高效搜索。此处我们将该框架应用于 MAAT。

图 3: 在四个数据集上、基于 NCD 时, 本方法与所有基线方法的累计时延。

5.1.3 评估指标 我们使用两类评估指标: 效果与效率。**效果**: 我们通过预测学生对测试集中习题的二值作答, 来评估最终能力估计的准确性, 因此采用准确率 (ACC) 与 ROC 曲线下面积 (AUC) 作为指标。**效率**: 我们用在特定测试步长下每位学生的平均评估时间 (秒) 来衡量习题选择的效率。此外, 我们将数据驱动方法的训练时间 (秒) 与我们提出的哈希表征生成模块进行比较。

5.1.4 参数设置 在认知诊断模型的预训练阶段, 我们将 NCD 和 MIRT 中学生与习题的嵌入维度设为数据集中知识概念的数量, 并统一将批大小和学习率设为 128 和 0.001。在哈希表征生成阶段, 我们将考生与习题的低维嵌入维度 d 设为 20, LSH 过程中实值表征哈希函数的 w 设为 0.5, 基于哈希的诊断函数中的 α 、 β 分别设为 0.5 和 0.7; 此阶段批大小和学习率分别设为 1024 和 0.0005。我们用 Xavier 初始化所有参数, 并使用 Adam 优化器。在 CAT 评估阶段, 习题选择算法遵循原文中的设置, 测试长度设为 5、10、20。实验在一块 NVIDIA RTX 4090 GPU 上用 PyTorch 完成。

5.2 性能比较 (RQ1)

为证明 HashCAT 能够平衡时间效率与评估效果, 我们将其与其他基线方法进行了比较。表 2 给出了选题 t 步后的 ACC 与 AUC 指标, 以及 $t = 20$ 时每位学生的平均选题时间。图 3 展示了以 NCD 为 CDM 时在四个数据集上的选题时间。此外, 表 3 给出了我们的方法与两种数据驱动方法在 20 次迭代上的平均训练时间。我们有以下观察:

- (1) 我们的方法在评估效果上超越了大多数 CAT 方法, 在时间效率上仅次于随机选择, 展现出稳健的性能。这表明基于不确定性削减、利用哈希表征的习题选择策略成功平衡了评估准确性与计算效率。
- (2) 与数据驱动方法相比, 本方法在训练效率上展现出显著优势, 尤其是在使用 NCD 作为 CDM 时。虽然数据驱动方法在 NCD 上取得了更优的评估效果, 但其对强化学习选题的依赖——需要大量的智能体-环境交互与复杂的优化过程——导致训练成本显著更高。当使用 MIRT 作为 CDM 时, 本方法取得了与数据驱动方法相当的性能。相比之下, 统计方法因其更高的计算复杂度而表现出较低的时间效率, 本方法在评估性能上也超越了它们。
- (3) 在选题时间方面, 数据驱动方法表现出相近的效率, 这可能是由于训练好的智能体在评估过程中运作得更高效。BECAT 起初表现出与其他统计方法相当的时间效率, 但随着步数增加, 其时间成本显著上升, 这可能归因于其特定的子集选择策略, 随时间推移变得计算量很大。

** 表 2: 在四个公开数据集上基于 ACC、AUC 及每位学生平均选题时间的性能。最佳性能加粗, 次佳下划线, 本方法以灰色标记。“—”表示 MIRT 生成的学生能力与习题特征不适用于优化 SECAT 中的双塔模型; “*” 表示该方法在 step=20 时运行时间过长, 因此未记录。** (此处为原文表 2, 结构复杂, 仅转录关键结论: 在 NIPS-2020 上 HashCAT 于 MIRT 下 step=20 取得 ACC 69.03%/AUC 75.62%、每生选题时延 0.0093 秒, 效果领先且时延比统计方法低数个数量级; 在四个数据集上 HashCAT 的选题时延均在 0.005~0.09 秒级别, 远低于 MKLI、MAAT、BECAT 等统计方法的数十至上千秒。)

5.3 消融研究 (RQ2)

本节中，我们在 NIPS-2020 和 ASSIST1213 两个数据集上、以 NCD 为 CDM 进行消融研究，以分析 HashCAT 中关键组件的影响。为此，我们考虑 HashCAT 的三个变体，每个变体通过从原始模型中移除一个特定组件构成：(1) **w/o-IAM**，移除第 4.2 节所述的信息对齐模块 (IAM)。(2) **w/o-UR**，移除第 4.4 节所述的不确定性削减策略，选择准则仅基于选取 P_c 最大的习题。(3) **w/o-Hybrid**，移除第 4.4 节所述的混合算法组件。

表 4：关键组件消融研究。

数据集	NIPS-2020 (ACC%/AUC%)			ASSIST1213 (ACC%/AUC%)		
Step	5	15	20	5	15	20
w/o-IAM	61.35/68.00	64.13/71.27	65.20/72.05	67.41/70.61	67.98/71.10	68.14/71.32
w/o-UR	63.15/62.93	63.63/63.58	63.77/63.97	68.13/67.02	68.55/67.87	68.76/68.15
w/o-Hyb	61.46/67.97	64.48/71.58	66.09/72.87	67.67/70.56	68.18/71.14	68.84/71.63
HashCAT	61.48/68.25	64.86/71.73	66.23/73.09	67.72/70.87	68.86/71.81	69.37/72.24

从表 4 可得出几个关键结论。第一，完整模型取得了最佳的整体性能。第二，当移除所提出的不确定性削减策略时，性能显著下降，表明仅依赖哈希表征之间的汉明距离作为选择策略并不能保证准确的评估结果。第三，当移除信息对齐模块或混合策略时，性能也在一定程度上下降。这不仅凸显了哈希表征所含信息对评估结果的关键作用，也表明在 CAT 这样的马尔可夫过程中，充分探索并利用未作答习题池有助于更准确地评估学生能力。因此，所有组件都在不同程度上影响 HashCAT。

5.4 案例研究与分析 (RQ3)

为进一步说明我们选题方法的细节，我们在 NIPS-2020 数据集上对选题过程的若干关键指标进行了可视化（图 4）。从图中可见，在选题过程中，学生能力随每一步选择而逐步提升，汉明距离总体呈上升趋势，而信息熵的变化逐渐减小。这是因为随着测试的推进，选择策略从“适应学生当前能力”转向“挑战能力边界”，导致汉明距离增大；同时，信息熵变化的减小反映了能力估计不确定性的逐步收敛。我们还可以观察到，选择一道习题所需的时间极短，这主要得益于本方法利用了哈希表征在位运算上的计算优势。在选择过程中，我们通过哈希生成模块直接获得习题的哈希表征及其相关特征，从而可在选题时直接使用这些预先存储的特征数据，避免了传统基于统计的选择算法中实时数据计算的瓶颈。这表明本方法在学生能力评估与评估效率之间实现了优化，从而验证了基于哈希表征与不确定性削减的习题选择策略的有效性。

图 4：习题选择方法可视化。图最左侧是题库，包含每道习题的哈希表征与实值信息；最右侧是步骤 5、10、15、20 选题过程中的一些重要参数。

表 3：训练时间比较（秒）。

数据集	NIPS-2020	JUNYI	ASSIST1213	PTADISC
NCAT	60.979	57.339	171.193	624.324
GMOCAT	160.007	155.425	274.679	1411.577
HashCAT	44.477	39.207	137.605	447.037

5.5 超参数影响 (RQ4)

我们以 NCD 为 CDM，在 JUNYI 数据集上分析 S 、 κ 、 ζ 对实验结果的影响（图 5）。 S 是在选题算法中混合 ϵ -贪心策略与 UCB 策略的阈值，而 κ 和 ζ 是用于计算 H_{prior} 中学生正确答题概率的参数。观察发现，不同超参数会导致不同结果：如图 5(a)，当 S 等于 18 时，方法在 JUNYI 上取得最佳性能；固定 $\zeta = 10$ 时，图 5(b) 表明 κ 等于 0.001 时模型表现最佳；固定 $\kappa = 0.001$ 时，图 5(c) 表明 ζ 等于 10 时模型表现最优。

图 5：超参数敏感性分析。

6 结论

本文提出了一种基于哈希学习与不确定性削减的 CAT 方法，旨在平衡评估效果与时间效率。通过结合哈希表征生成模块与基于不确定性削减的习题选择算法，我们成功地将哈希表征融入 CAT，显著提升了时间效率。在四个真实数据集上的实验结果表明，本方法不仅在评估准确性上优于大多数现有方法，还实现了与随机选择策略相当的时间效率。

致谢。本工作部分受国家自然科学基金 (No. 62107001、62302010、62302009、62202006) 资助。

参考文献 (*References*) 按约定未翻译, 详见原文。