

KGCAT: 基于知识图谱推理的计算机自适应测试模型 精读笔记

原文: 2025.coling-main.354.pdf (A Knowledge Graph Reasoning-Based Model for Computerized Adaptive Testing, COLING 2025, 华东师大) 代码: 未发现开源代码 (全文未给出 GitHub/GitLab 等仓库地址) 笔记于 2026-06-27

一、解决什么问题

1.1 背景: CAT 的两大件

计算机自适应测试 (CAT) 就是“边考边出题”: 根据学生当前的知识状态, 自动挑下一道最合适的题。它由两个组件循环驱动:

1. **认知诊断模型 (CDM)**: 根据学生历史作答, 估计他的知识水平 (常用 IRT、NCD)。
2. **选择算法 (SA)**: 根据当前估计, 挑下一道题。

本文同时改进了“诊断表示”和“选题策略”两端。

1.2 痛点: 两个被忽视的问题

痛点 1: 一题多概念时, 概念相关性没处理好 (影响 CDM 端)。以前用 GNN 把“概念”和“题目”都当节点、题目连到它的概念上 (GIKT、Yang 2021 等)。但有两个毛病: - 没区分“概念”和“题目”本质上的不同; - 当一道题涉及多个概念时, 没考虑不同概念的相关性强弱。

论文的图 1(b) 例子很关键: - $q_1 = \{\text{三角形内角和, 圆心}\}$, $q_2 = \{\text{三角形内角和, 勾股定理}\}$, $q_3 = \{\text{勾股定理}\}$, $q_4 = \{\text{圆心}\}$ 。 - 要预测学生答对 q_2 的概率, 应该借用“和 q_2 相关的题”的历史作答。 - q_3 (只含勾股定理) 比 q_1 更该被优先采用——因为 q_1 还掺了“圆心/圆”这种和 q_2 无关的概念, 会引入噪声。

→ 所以需要一个机制: 聚合邻居时, 放大相关概念、淡化无关概念。本文用互信息解耦来做。

痛点 2: 选题目标太少 (影响 SA 端)。以前的强化学习选题 (NCAT、GMOCAT) 只关注质量/多样性/新颖性这类目标, 忽略了题目难度和学生相似度。太简单的题提升不了能力, 太难的题学生乱蒙, 都测不准。本文把“难度”和“相似度”作为两个新奖励加进多目标强化学习。

1.3 本文做法 (KGCAT) 一句话

把题目当节点、概念当边建知识图谱, 用相似度感知聚合 + 互信息解耦学出干净的题目/概念表示 (KGSE 模块); 再用带难度和相似度奖励的多目标 PPO 来选题 (DSMORL 模块)。

二、问题定义 (输入 / 输出)

2.1 符号与流程

CAT 是一个序列决策过程。在时刻 t : - 学生历史交互 $s_{t-1}^i = (q_{t-1}^i, c_{t-1}^i, y_{t-1}^i)$, 即 (做了哪道题、考哪些概念、对错)。 - KGSE 把历史编码成学生状态 $e_{s_t} \in \mathbb{R}^D$ 。 - DSMORL (强化学习策略 π) 根据状态选下一题 q_t 。 - 学生作答 $y_t \rightarrow$ 拼成新状态 $\rightarrow$ 进入 $t+1$ 。 - 重复 T 步 (实验取 $\text{step}=10, 20$)。

目标: 选出的题序列让模型对学生作答的预测 (对/错) 尽量准 (AUC/ACC 越高越好)。

2.2 小例子

学生 s 历史做过 3 题: $(q_5, \text{对}), (q_8, \text{错}), (q_2, \text{对})$ 。 - 输入: 这条交互序列 + 知识图谱 (题—概念—概念的连接)。 - KGSE 输出: 学生状态向量 e_{s_t} ($D = 3d = 48$ 维, 因为 $d = 16$)。 - DSMORL 输出: 从候选题里选一道 q_t (比如 q_{17}) 推给学生。 - 评价: 在测评集上预测他对各题的对错, 算 AUC。

三、模型结构

整体两大模块, 串成一个 RL 闭环 (图 2):

历史交互 s_{t-1}

|

[KGSE 知识图谱状态编码器]

- 1) 题目特征投影到 K 个潜在空间 (拆概念)
- 2) 相似度感知聚合: 图上按相似度聚合邻居 (放大相关概念)
- 3) 互信息解耦: 让 K 个分量彼此独立 (去噪)
- 4) 概念有向图 (GAT) 抓概念间先决关系 + 注意力融合直接/间接信息
- 5) 自注意力 + 平均池化 $\rightarrow$ 学生状态 e_{st}

|

$v_{e_{st}}$

[DSMORL 多目标强化学习选题]

奖励 = [质量, 多样性, 新颖性, 难度(新), 相似度(新)]

Actor-Critic + 多目标 PPO $\rightarrow$ 选题 q_t

|

$v_{q_t} \rightarrow$ 学生作答 $y_t \rightarrow$ 拼成 s_t , 进入下一步

KGSE 解决痛点 1 (表示去噪), DSMORL 解决痛点 2 (选题目标更全)。下面逐个公式讲。

四、关键公式详解 (核心)

公式 (1): 把题目特征拆到 K 个潜在空间

$$q_i = \{h_{i,1}, \dots, h_{i,K}\}, \quad h_{i,k} \in \mathbb{R}^{d_{embed}/K}, \quad h_{i,k}^0 = \sigma(W_k \bullet x_i)$$

- 一道题往往考多个概念, 混在一个向量里会“耦合”。这里把题目特征 x_i 用 K 个不同的投影矩阵 W_k 投到 K 个子空间, 每个子空间负责一种“概念语义”。
- 实验里 $K=3$, d_{embed} 是总维度, 每个分量维度 $= d_{embed}/K$ 。

举例。 $K=3$, 把题 q_2 (含“三角形内角和”+“勾股定理”) 拆成 $h_{2,1}, h_{2,2}, h_{2,3}$ 三个分量。理想情况下, $h_{2,1}$ 主要编码“三角形内角和”, $h_{2,2}$ 主要编码“勾股定理”, $h_{2,3}$ 编码别的/冗余。后面就能对每个分量单独判断相关性。

作用: 把“一题多概念”显式拆开, 为后面分概念地去噪打基础。

公式 (2)(3)(4): 相似度感知聚合 (在每个分量上分别聚合邻居)

$$h_{i,k}^{l+1} = \sigma \left(\sum_{(j,c) \in \hat{N}(i)} \alpha_{(i,j,c)}^k \phi(h_{j,k}^l, h_c^l, \theta_c) \right)$$

逐个看: - $\hat{N}(i)$: 题 i 的邻居 (在 KG 里通过共享概念相连的其他题) + 自己。 - $\theta_c = \text{diag}(w_c)$: 概念 c 的对角投影矩阵; $e_{i,c}^k = h_{i,k} \circ \theta_c$ 是题 i 在第 k 分量上“经过概念 c 过滤后”的关系感知表示。 - 注意力权重 (公式 3): $\alpha_{(i,j,c)}^k = \text{softmax}((e_{i,c}^k)^T e_{j,c}^k)$ ——两道题在概念 c 视角下越相似, 权重越大, 越该聚合。 - 消息函数 (公式 4, TransR 式): $\phi = (\theta_c \bullet h_e) - h_r$, 把邻居表示经概念投影后再减去关系向量, 得到这条边传过来的“消息”。

举例 (为什么能去噪)。聚合 q_2 的邻居时, q_3 (只含勾股定理) 和 q_2 在“勾股定理”这个分量 $k=2$ 上 $e_{q_2,c}^2 \cdot e_{q_3,c}^2$ 内积大 $\rightarrow \alpha$ 大 $\rightarrow$ 多聚合; q_1 (含圆心) 在该分量上和 q_2 不相关 $\rightarrow$ 内积小 $\rightarrow \alpha$ 小 $\rightarrow$ 少聚合。于是 q_1 带的“圆”噪声被自动压低。这正是痛点 1 的解药。

公式 (5) $h_c^{l+1} = W_c^l \bullet h_c^l$: 概念节点每层做个线性变换更新自己。

作用: 在图聚合时按“分概念的相似度”加权, 让相关邻居多贡献、无关邻居少贡献。

公式 (6)(7): 概念有向图——抓概念间的先决关系

概念之间也有关系，比如“概念 1 是概念 2 的先修知识”。用图注意力网络 (GAT) 建模：

$$E_c^{dir} = \sum_{c' \in N_c} \alpha_{c,c'} W_{dir} E_{c'}, \quad \alpha_{c,c'} = \text{Softmax}_{c'}(\text{att}_{dir}([W_{dir} E_c, W_{dir} E_{c'}]))$$

- E_c^{dir} : 概念 c 从直接的概念-概念有向边 (先决关系) 聚来的表示。
- 对比之下，公式 (2) 算出的 E_c^{ind} 是从题目间接学到的概念表示。

数据集里只有 Junyi 自带概念先决关系；Assist2009、Eedi 用 Gao 2021 (RCD) 的方法另外构造概念有向图。

公式 (8)(9): 融合“直接”和“间接”两种概念信息

$$\mu_{ind} = P_{ind}^T \bullet \tanh(W_{ind} E_c^{ind} + b_{ind}), \quad \mu_{dir} = P_{dir}^T \bullet \tanh(W_{dir} E_c^{dir} + b_{dir})$$

$$\tilde{E}_c = \mu_{ind} E_c^{ind} + \mu_{dir} E_c^{dir}$$

用注意力打分 μ 把两路概念表示加权合一，得到最终概念向量 $\tilde{E}_c$ 。

举例。某概念 c 的间接表示 (从相关题学的) 信息更靠谱，模型可能学到 $\mu_{ind} = 0.7, \mu_{dir} = 0.3$ ，于是 $\tilde{E}_c = 0.7 E_c^{ind} + 0.3 E_c^{dir}$ ，以间接信息为主、先决关系为辅。

公式 (10)(11): 互信息解耦 (让 K 个分量真正独立)

公式 (1) 只是“投影”出 K 个分量，它们之间其实还残留弱相关、且是非线性相关。要让它们真正解耦，用互信息度量并削弱这种依赖。互信息估计用 CLUB (contrastive log-ratio upper bound, Cheng 2020a) 这个上界估计器：

$$\mathcal{L}_{mi} = \sum_u \sum_v \mathbb{E}_{p(h_{i,u}, h_{i,v})} [\log q_\theta(h_{i,u} | h_{i,v})] - \mathbb{E}_{p(h_{i,u}) p(h_{i,v})} [\log q_\theta(h_{i,u} | h_{i,v})]$$

- $u \neq v$ 指同一题的两个不同分量。
- 因为真实条件概率 $p(h_{i,u} | h_{i,v})$ 拿不到，用一个变分网络 q_θ 去近似它 (公式 11: 交替优化，最小化两者 KL 散度)。
- 最小化 $\mathcal{L}_{mi} \approx$ 最小化分量间互信息 $\rightarrow$ 分量彼此独立。

直觉小例子。如果分量 1 (“三角形内角和”) 和分量 2 (“勾股定理”) 还纠缠在一起，那预测时这两类知识会互相干扰。互信息惩罚把它们“拉开”，于是聚合 q_2 时，“勾股定理”这条线索能干净地起作用，不被别的概念污染。CLUB 给的是互信息上界，把上界压低就保证真实互信息也低。

作用：在公式 (1) 的“形式拆分”之上，再做“统计独立”的硬约束，是 KGSE 去噪的第二把锁。

公式 (12)-(15): 状态编码器 (把交互序列编码成 RL 状态)

- 公式 (12): 作答 y (对/错, one-hot) 经 $W_y \in \mathbb{R}^{2 \times d}$ 映射成 $E_y \in \mathbb{R}^d$ 。
- 公式 (13): 把题目向量、概念向量、作答向量拼起来， $e_{t'} = \tilde{E}_{t'q} \oplus \tilde{E}_{t'c} \oplus E_{t'y} \in \mathbb{R}^D$ ， $D = 3d = 48$ 。
- 公式 (14): 堆成序列矩阵 $E_t \in \mathbb{R}^{(t-1) \times D}$ 。
- 公式 (15): **自注意力**——不同作答信息量不同 (答对比答错信息多)，让模型自己学哪些交互更重要：

$$\tilde{E}_t = \text{Softmax}\left(\frac{(E_t W^Q)(E_t W^K)^T}{\sqrt{d_k}}\right)(E_t W^V)$$

之后接 LayerNorm + 残差 + Dropout，再平均池化 $\rightarrow$ 学生状态 e_{s_t} 。

作用：把变长历史压成一个定长状态向量，喂给强化学习。

公式 (16): 多目标强化学习的总目标

$$\max_{\pi} J = \max_{\pi} \frac{1}{n} \sum_{i=1}^n \left[w^T \left(\sum_{t'=1}^T \gamma^{t'} r(s_t^i, q_t^i) \right) \right]$$

- 奖励是个向量 $r = [r_{qua}, r_{div}, r_{nov}, r_{dif}, r_{sim}]$ (质量、多样性、新颖性、难度、相似度)。
- w 是权重向量, 把向量奖励加权成标量。实验 $w = [1, 1, 1, 1, 1]$ (全开); 消融时把某位设 0 来关掉某目标。
- $\gamma = 0.5$ 是折扣因子。

前三个奖励沿用 GMOCAT, 后两个 r_{dif}, r_{sim} 是本文新增。

公式 (17)(18): 难度奖励——选“难度匹配学生能力”的题

$$D_i = \frac{1}{|Q_i|} \sum_{q \in Q_i} d_q, \quad d_q = \frac{1}{n} \sum_{j=1}^n r_{q,j}$$

$$r_{dif} = \begin{cases} 1, & |D_i - d_q| < x_{dif} \\ 0, & \text{其他} \end{cases}$$

- d_q = 题 q 的难度 = 所有做过它的学生的平均得分 (注意: 得分越高其实题越“容易”, 但论文把这个量直接叫难度并说“ d_q 越高题越难”, 此处按原文, 理解为一个难度代理量即可)。
- D_i = 学生 i 的能力 = 他做过的题的平均 d_q 。
- 只有当题难度和学生能力差距 < 0.25 时给奖励 1, 否则 0 $\rightarrow$ 鼓励选“难度适配”的题, 不太简单也不太难。

举例。学生能力 $D_i = 0.6$ 。候选题 q_a 难度 0.7 (差 $0.1 < 0.25 \rightarrow$ 奖励 1, 匹配), q_b 难度 0.2 (差 $0.4 > 0.25 \rightarrow$ 奖励 0, 太简单)。强化学习会更倾向选 q_a 。 $x_{dif} = 0.25$ 是实验调出的最优阈值 (图 6: 太小过滤掉有用题, 太大失去筛选作用)。

公式 (19)(20)(21): 相似度奖励——协同过滤式选题

$$\text{similarity}(s_i, s_j) = \frac{|Q_{s_i} \cap Q_{s_j}|}{|Q_{s_i} \cup Q_{s_j}|} \quad (\text{Jaccard 系数})$$

$$Q_i = (\bigcup_j Q_{s_j}) / Q_{s_i}, \quad \text{similarity}(s_i, s_j) > x_{sim}$$

$$r_{sim} = \begin{cases} 1, & q_t \in Q_i \\ 0, & \text{其他} \end{cases}$$

- 思路同推荐系统: 和你相似的学生 s_j 做过、而你没做过的题, 可能正适合你。
- Q_i = 所有与 s_i 相似度 $> x_{sim}$ 的学生做过、但 s_i 还没做的题集合。
- 选中的题若落在 Q_i 里就给奖励 1。

举例。 s_i 做过 $\{q1, q2, q3\}$, 相似学生 s_j 做过 $\{q2, q3, q9\}$ 。Jaccard = $|\{q2, q3\}| / |\{q1, q2, q3, q9\}| = 2/4 = 0.5 > x_{sim} = 0.1 \rightarrow s_j$ 算相似。 Q_i 收入 q_9 。若策略选了 q_9 , $r_{sim} = 1$ 。 x_{sim} 不能太大 (表 4: $x_{sim} > 0.4$ 后有候选集的学生数骤降), 实验取 0.1/0.2 最好。

公式 (22)-(25): 多目标 PPO 的更新

- 公式 (22) 优势函数 (向量): $A(s_t, q_t) = \sum_{t'} \gamma^{t'-t} r(s_{t'}, q_{t'}) - V(s_t)$, 实际回报减 critic 预测。
- 公式 (23) actor 的裁剪替代损失 (标准 PPO, 但乘 w^T 把向量优势变标量):

$$L_1 = -\mathbb{E}[\min\{\rho w^T A, \text{Clip}(\rho, 1 - \epsilon, 1 + \epsilon) w^T A\}], \quad \rho = \frac{\pi(q_t|s_t)}{\pi_{old}(q_t|s_t)}$$

$\epsilon = 0.2$ 限制策略一步别更新太猛。- 公式 (24) critic 损失: $L_2 = \frac{1}{2} w^T \|V(s_t) - \text{回报}\|^2$, 让价值预测逼近真实回报。- 公式 (25) 总损失: $L = L_1 + \alpha L_2$ 。

作用: 用 Actor-Critic + 多目标 PPO, 把“五个目标”的加权回报最大化, 学出选题策略。

举例。critic 预测某状态价值 $V = 2.0$, 实际折扣回报 $2.5 \rightarrow$ 优势 $A = +0.5 > 0$, 说明这步选题比预期好 $\rightarrow$ PPO 提高该动作概率 (在 clip 范围内)。

五、代码实现对照

未发现开源代码——全文 (含脚注、摘要、实验节) 未给出任何 GitHub/GitLab 仓库链接, 故无法做公式 $\leftrightarrow$ 代码对照。

可复现的关键超参 (来自 §4.1): $K = 3$ 、 $d = 16$ (故 $D = 48$)、 $x_{dif} = 0.25$ 、 $x_{sim} = 0.1$ 、 $\gamma = 0.5$ 、 $\epsilon = 0.2$ 、batch=128、Adam lr=0.02、self-attention dropout=0.1、 $w = [1, 1, 1, 1, 1]$ 、 $\alpha = 1$; 序列长度 < 40 的学生被剔除; 每生数据按 80/20 分候选集/元数据集。互信息估计器用 CLUB (Cheng 2020a), 概念有向图 (非 Junyi) 用 RCD (Gao 2021) 构造。

六、小结

实验结论 (Assist2009 / Junyi / Eedi, 对比 MAAT、BOBCAT、NCAT、GMOCAT, 基座 IRT/NCD, step=10/20, 指标 AUC/ACC): - KGCAT 整体最优 (多数格子加粗), GMOCAT 常为次优。- 用 RL 的方法 (NCAT/GMOCAT/KGCAT) 整体优于不用 RL 的 (MAAT/BOBCAT), 且步数越多 KGCAT 优势越明显 (RL 擅长期); 步数很少时偶尔不如基线。- 在 Assist2009/Junyi (每题约 1~1.2 概念) 提升比 Eedi (每题约 4 概念) 更大——因为 $K = 3$ 个投影空间装不下 4 个概念, 会丢信息。这其实暴露了“ K 固定”的设计短板。- 消融 (Eedi, 图 3): 去掉任一模块都掉点; 去掉难度 (KGCAT-H)、相似度 (KGCAT-S) 掉得最快 $\rightarrow$ 这两个新奖励最关键。换普通 GNN (KGCAT-KG) 掉得相对少 (作者推测是 K 太小没发挥出 KG 优势)。- $K = 3$ 最优 (图 4, 受算力限制只试到 3); $x_{dif} = 0.25$ 、 $x_{sim} = 0.1/0.2$ 最优。

优点: 1. 用知识图谱 + 分概念的相似度聚合, 对症解决“一题多概念时的噪声”; 2. 互信息解耦给概念分量加独立性约束, 去噪更彻底; 3. 多目标 RL 引入难度 + 相似度两个新奖励, 选题更贴合学生水平、更具协同性, 可解释性也更好。

局限 (作者自述 + 笔者补充): - 大规模 KG (概念/题目多) 计算开销大, 可扩展性受限; - 互信息 + 多目标 RL 让超参数调优很复杂 (学习率、奖励结构、MI 阈值都要调); - 投影数 K 固定为 3, 对每题概念数多的数据集 (如 Eedi) 会丢信息, 这是设计上可改进处; - 难度定义 d_q = 平均分, 与“得分高 = 题难”的表述略反直觉 (按原文理解为难度代理量); - 未开源, 复现需自行实现。