

# 一种基于知识图谱推理的计算机自适应测试模型 (A Knowledge Graph Reasoning-Based Model for Computerized Adaptive Testing)

原文: 2025.coling-main.354.pdf (COLING 2025) · 译者: Claude · 译于 2026-06-27 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT)、智能辅导系统 (Intelligent Tutoring System, ITS)、认知诊断模型 (Cognitive Diagnosis Model, CDM)、选择算法 (Selection Algorithm, SA)、项目反应理论 (Item Response Theory, IRT)、神经认知诊断 (Neural Cognitive Diagnosis, NCD)、知识图谱 (Knowledge Graph, KG)、图神经网络 (Graph Neural Network, GNN)、强化学习 (Reinforcement Learning, RL)、互信息 (Mutual Information, MI)、解耦 (disentanglement)

## 摘要

计算机自适应测试 (CAT) 在当代智能辅导系统 (ITS) 中的重要性不言而喻, 它旨在根据学生的知识状态为其推荐合适的题目。近年来, 图神经网络 (GNN) 与强化学习 (RL) 方法越来越多地被应用于 CAT。尽管这些方法取得了实证上的成功, 但它们仍面临一些局限, 例如当一道题目涉及多个知识概念时对概念相关性处理不足, 以及评价指标不完整。为解决这些问题, 我们提出一种基于知识图谱推理的 CAT 模型 (KGCAT), 它利用知识图谱 (KG) 的推理能力来捕捉概念与题目之间的语义与关系信息, 同时聚焦于利用互信息来降低低相关性概念所带来的噪声。此外, 我们采用一个多目标强化学习框架来纳入多个评价目标, 进一步优化题目选择并提升 CAT 的整体效果。在三个真实教育数据集上的实证评估表明, 所提出的模型在准确性与可解释性两方面都优于现有方法。

## 1 引言

近年来, 随着计算机技术的迅猛发展, 智能辅导系统 (ITS) 在教育领域得到了广泛应用。与传统的纸笔测试相比, CAT 凭借其自动化与个性化的显著优势, 已成为现代考试的一种常见手段。如图 1(a) 所示, CAT 主要由两个核心组件构成: 认知诊断模型 (CDM) 和选择算法 (SA)。CDM 利用统计或机器学习方法, 基于学生的历史交互数据来估计其当前的知识水平。最常用的 CDM 包括项目反应理论 (IRT) 和神经认知诊断 (NCD), 它们分别基于心理学和深度学习。

图 1: (a) CAT 的组成部分。(b) 题目与概念之间关系的一个示例。

近年来, GNN 在各个领域都展现出卓越的性能, 因而也被应用到 CAT 中。Nakagawa 等人 (2019) 用节点和边来表示概念及其关系, 但未能区分与同一概念相关联的不同题目。Yang 等人 (2021) 和 Wang 等人 (2023) 通过用节点同时表示概念和题目、并用一条边把每道题目与其对应概念相连, 将题目纳入图结构, 成功地解决了上述问题。然而, 这些方法忽略了概念与题目之间天然的区别。此外, 已有研究未能在训练过程中考虑——当一道题目涉及多个概念时——不同概念相关性可能带来的潜在影响。每个概念相对于该题目的不同重要程度, 可能会影响整体的学习效果, 而这一点在以往工作中尚未得到充分处理。图 1(b) 是一个例子:  $q_1$  包含“三角形内角和”与“圆心”两个概念,  $q_2$  包含“三角形内角和”与“勾股定理”,  $q_3$  包含“勾股定理”,  $q_4$  包含“圆心”。当预测一名学生答对题目  $q_2$  的概率时, 必须利用与  $q_2$  相关题目的历史作答数据。在这种情况下, 更恰当的做法是优先采用来自  $q_3$  的信息而非  $q_1$  的信息, 因为  $q_1$  涉及了额外的概念 (如“圆”), 可能给预测过程引入噪声。与此同时, 以往研究 (Bi 等, 2020; Zhuang 等, 2022; Wang 等, 2023) 只关注了有限的目标, 忽视了题目难度与学生相似度的重要影响。

为解决这些问题, 我们提出一个基于知识图谱推理的模型, 它将题目表示为节点、将概念表示为边, 从而更好地捕捉二者之间的语义与关系信息。为专门降低无关概念引入的噪声, 我们引入一个利用互信息的解耦模块。该模块增强了各个概念之间的独立性, 有助于减轻无关概念对预测过程的影响。此外, 鉴于现有选择算法对题目难度和学生相似度考虑不足, 我们集成了一个多目标强化学习框架。这一补充通过把这些因素纳入题目选择过程, 确保了更准确的推荐。

综上所述, 主要贡献如下:

- 我们提出一种基于知识图谱推理的计算机自适应测试模型 (KGCAT), 以更好地捕捉题目与概念之间的关系和语义信息, 同时聚焦于引入互信息来解耦多个概念, 并在聚合节点时减少不必要邻居带来的信息干扰。
- 我们采用一个多目标强化学习框架, 并纳入对题目难度和学生相似度的新考量, 以优化 CAT 模型的整体性能。
- 我们在公开数据集上进行了大量实验, 证明 KGCAT 在准确性与可解释性方面都优于现有方法。

## 2 相关工作

### 2.1 计算机自适应测试

近年来, 对 CAT 的改进主要可分为两类: 基于 CDM 的模型 (Tong 等, 2022; Yang 等, 2021; Nakagawa 等, 2019) 和基于 SA 的模型 (Zhuang 等, 2022; Wang 等, 2023; Bi 等, 2020; Ghosh 和 Lan, 2021)。Yang 等人 (2021) 和 Nakagawa 等人 (2019) 提出用 GNN 来捕捉概念与题目之间的关系, 引导模型的学习过程。另一方面, Tong 等人 (2022) 提出, 除了题目与概念之间的显式关系外, 从学生作答中导出的隐式联系也可以被利用, 以更好地构建这些关系。与这些方法不同, 我们的方法用知识图谱同时表示概念和题目, 同时捕捉它们的语义与关系信息。

对于基于 SA 的方法, Bi 等人 (2020) 提出了一个与模型无关的框架, 它兼顾质量与多样性, 以支持多种 CAT 场景。Zhuang 等人 (2022) 和 Wang 等人 (2023) 将 CAT 转化为一个强化学习问题, 并引入相似的指标来引导题目选择。在已有研究所确立的指标基础上, 我们引入新的评价标准, 以进一步引导题目选择过程。

## 2.2 知识图谱

知识图谱 (KG) 因其能有效捕捉和表示实体之间的关系, 已在推荐系统中被广泛采用。现有的基于 KG 的推荐模型大致可分为三类: 基于嵌入的 (Gao 等, 2022; Cao 等, 2019)、基于路径的 (Catherine 和 Cohen, 2016; Wang 等, 2019b) 和基于 GNN 的 (Wang 等, 2019a; Ai 等, 2018)。

基于嵌入的方法使用 KG 嵌入技术来构建知识图谱。基于路径的方法通过 KG 实体抽取从用户到物品的路径, 并输入到 RNN 和记忆网络中以引导推荐。基于 GNN 的方法使用 GNN 通过传播来学习长程信息。例如, Wang 等人 (2019a) 在 GNN 框架中显式地建模并捕捉用户与物品之间的高阶关系; Ai 等人 (2018) 在细粒度意图层面构建知识图谱, 并利用关系依赖来保留语义。然而, 知识图谱在 CAT 场景中的应用尚未被充分探索。因此, 我们的工作将聚焦于研究知识图谱在 CAT 语境下的潜力与应用。

## 3 方法

### 3.1 KGCAT 的结构

图 2 是 KGCAT 的整体结构框架, 它主要包括两个模块: KGSE (基于知识图谱的状态编码器, Knowledge Graph-Based State Encoder) 和 DSMORL (基于难度与相似度的多目标强化学习, Difficulty and Similarity-Based Multi-Objective Reinforcement Learning)。KGSE 将在时刻  $t$  输入的学生状态  $s_{t-1}$  编码为  $e_{s_t}$ , 并输出给 DSMORL。DSMORL 使用 RL 来选择题目  $q_t$ , 该题目将在  $t+1$  时刻与概念  $c_t$  和作答  $y_t$  结合, 作为下一时刻的输入  $s_t$ 。

图 2: KGCAT 的结构。

### 3.2 KGSE

一道题目可能涉及多个概念, 而这些概念之间有时存在一定的重叠。为了降低这些概念之间的耦合, 应当把一道题目分离成相互独立的变量。因此, 题目的特征被投影到  $K$  个潜在空间上:

$$q_i = \{h_{i,1}, h_{i,2}, \dots, h_{i,K}\}, \quad h_{i,K} \in \mathbb{R}^{\frac{d_{embed}}{K}} \quad (1)$$

其中  $h_{i,K}^0 = \sigma(W_K \bullet x_i)$  是初始嵌入,  $W_K$  是第  $K$  个投影矩阵,  $x_i$  是特征向量,  $\sigma$  是激活函数。

由于一个实体所携带的信息往往不完整, 因此有必要聚合邻居节点以学习更丰富的特征。然而, 并非邻居节点的所有信息都需要学习——模型应当学习与该节点相关的邻居节点, 并淡化无关的部分, 以学到更丰富的特征。为此, 我们提出一个解耦的知识图谱聚合模块, 它分为两部分: 1) 相似度感知聚合 (Similarity-Aware Aggregation), 2) 基于互信息的解耦 (Mutual Information-Based Disentanglement)。

**相似度感知聚合。**为了估计每个邻居节点在聚合中的重要性, 我们提出一种相似度感知的聚合策略。它在每个潜在空间分量上计算邻居节点的相似度。相似度越大, 两个节点之间越可能存在连接, 从而据此决定是否聚合这两个节点。节点与邻居节点之间的相关性由每个潜在空间分量来估计:

$$h_{i,k}^{l+1} = \sigma\left(\sum_{(i,c) \in \hat{N}(i)} \alpha_{(i,j,c)}^k \phi(h_{j,k}^l, h_c^l, \theta_c)\right) \quad (2)$$

$$\alpha_{(i,j,c)}^k = \text{softmax}((e_{i,c}^k)^T \cdot e_{j,c}^k) = \frac{\exp((e_{i,c}^k)^T \cdot e_{j,c}^k)}{\sum_{(j',r) \in \hat{N}(i)} \exp((e_{i,c}^k)^T \cdot e_{j',c}^k)} \quad (3)$$

$$\phi(h_e, h_c, \theta_c) = (\theta_c \bullet h_e) - h_r \quad (4)$$

其中  $h_{i,k}^{l+1}$  表示  $q_i$  在经过第  $l$  层后于第  $k$  个分量上的表示,  $\theta_c = \text{diag}(w_c)$  表示概念  $c$  的投影矩阵,  $e_{i,c}^k = h_{i,k} \circ \theta_c$  表示  $q_i$  在第  $k$  个分量上的关系感知权重,  $\hat{N}(i)$  表示  $q_i$  的邻居节点及其自身。类似地,  $h_c^l$  是概念  $c$  经过第  $l$  层后的表示。  $h_c^l$  通过带参数  $W_c^l$  的逐层线性变换来更新:

$$h_c^{l+1} = W_c^l \bullet h_c^l \quad (5)$$

通过在  $K$  个分量上计算邻居节点的相似度并聚合相似度大的节点, 可得到输出题目向量  $\tilde{E}_q = \{h_{q,1}^{l+1}, h_{q,2}^{l+1}, \dots, h_{q,K}^{l+1}\}$ , 以及从间接关系中学到的概念向量  $E_c^{ind} = h_c^{l+1}$ 。然而, 不仅概念与题目之间存在关系, 概念与概念之间也存在联系。例如, 概念之间可能存在先决 (prerequisite) 关系, 其中概念 1 是概念 2 的先验知识。为了捕捉这种关系, 我们使用一个图注意力网络:

$$E_c^{dir} = \sum_{c' \in N_c} \alpha_{c,c'} W_{dir} E_{c'} \quad (6)$$

$$\alpha_{c,c'} = \text{Softmax}_{c'}(\text{att}_{dir}([W_{dir} E_c, W_{dir} E_{c'}])) \quad (7)$$

其中  $E_c$  是概念  $c$  的输入向量,  $c' \in N_c$ ,  $N_c$  是概念  $c$  的邻居节点集合,  $W_{dir}$  是可训练参数,  $\alpha_{c,c'}$  是注意力权重,  $\text{att}_\bullet$  是一个带 LeakyReLU 激活函数的线性层,  $\bullet$  是连接 (join) 操作。

为了区分  $E_c^{dir}$  和  $E_c^{ind}$  中所包含的不同信息, 使用注意力向量  $P$  分别计算它们的权重:

$$\begin{aligned} \mu_{ind} &= P_{ind}^T \bullet \tanh(W_{ind} \bullet E_c^{ind} + b_{ind}) \\ \mu_{dir} &= P_{dir}^T \bullet \tanh(W_{dir} \bullet E_c^{dir} + b_{dir}) \end{aligned} \quad (8)$$

最后, 概念向量  $\tilde{E}_c$  可定义为:

$$\tilde{E}_c = \mu_{ind} E_c^{ind} + \mu_{dir} E_c^{dir} \quad (9)$$

**基于互信息的解耦。** 尽管每道题目被映射到  $K$  个不同的概念分量, 这些分量之间仍存在弱相关性, 且这些分量之间的关系不仅仅是线性的。受 Cheng 等人 (2020b) 和 Wu 等人 (2021) 的启发, 我们提出利用互信息来实现解耦。互信息可以度量两个随机变量之间非线性依赖的程度。这里, 分量之间的解耦通过使用对比对数上界 (contrastive log-ratio upper-bound, CLUB) 互信息估计器 (Cheng 等, 2020a) 来实现。由于同一题目在不同概念分量上的条件概率无法直接获得, 因此提出用一个带变分分布的简单神经网络  $Q$  来近似真实的条件神经网络。目标函数为:

$$\mathcal{L}_{mi} = \sum_u \sum_v \mathbb{E}_{(h_{i,u}, h_{i,v}) \sim p(h_{i,u}, h_{i,v})} [\log q_\theta(h_{i,u} | h_{i,v})] - \mathbb{E}_{(h_{i,u}, h_{i',v}) \sim p(h_{i,u}, h_{i,v})} [\log q_\theta(h_{i,u} | h_{i',v})] \quad (10)$$

注意,  $u \neq v$ , 且  $Q$  同时被训练以最小化  $p(h_{i,u} | h_{i,v})$  与  $q_\theta(h_{i,u} | h_{i,v})$  之间的 KL 散度。

$$\mathcal{L}(h_{i,u}, h_{i,v}) = D_{KL}[p(h_{i,u} | h_{i,v}) \| q_\theta(h_{i,u} | h_{i,v})] \quad (11)$$

这里,  $p(h_{i,u} | h_{i,v})$  是一个高斯分布, 并与  $\mathcal{L}_{mi}$  交替优化。通过用互信息来提出目标函数, 不同分量之间的依赖被削弱, 使得在聚合相邻节点时尽可能地聚合相关信息, 并降低无关分量的影响。

**状态编码器。** 我们将学生的历史交互序列定义为  $e_{s_i} = f(s_1^i, s_2^i, \dots, s_{t-1}^i)$ , 其中  $s_{t-1}^i = (q_{t-1}^i, c_{t-1}^i, y_{t-1}^i)$ , 用于强化学习。在相似度感知聚合中得到关系感知的题目向量  $\tilde{E}_q$  和概念向量  $\tilde{E}_c$  之后, 使用嵌入向量  $W_y = \mathbb{R}^{2 \times d}$  将学生的作答  $x_y$  转换为实值嵌入  $E_y \in \mathbb{R}^d$ :

$$E_y = x_y W_y \quad (12)$$

其中  $x_y$  是作答  $y$  的独热 (one-hot) 编码。因此, 时刻  $t'$  的  $e_{t'}$  可表示为:

$$e_{t'} = \tilde{E}_{t'q} \oplus \tilde{E}_{t'c} \oplus E_{t'y} \quad (13)$$

其中  $t' \in [1, t-1]$ ,  $e_{t'} \in \mathbb{R}^D$ ,  $D = 3d$ 。

$$E_t = [e_1, e_2, \dots, e_{t-1}]^T \in \mathbb{R}^{(t-1) \times D} \quad (14)$$

由于不同的作答所包含的信息量不同——例如, 答对一道题比答错一道题能产生更多信息——这里引入一个自注意力机制:

$$\tilde{E}_t = \text{Softmax}\left(\frac{(E_t W^Q)(E_t W^K)^T}{\sqrt{d_k}}\right)(E_t W^V) \quad (15)$$

其中  $W^Q, W^K, W^V$  是可训练参数,  $\sqrt{d_k}$  是缩放因子。在自注意力机制之后, 加入 LayerNorm 和跳跃连接 (skip-connection), 并使用 Dropout 来避免过拟合。自注意力的结果用平均池化层处理, 得到用于强化学习的学生状态  $e_{s_t} \in \mathbb{R}^D$ 。

### 3.3 DSMORL

基于 Wang 等人 (2023) 提出的、考虑准确性 (accuracy)、多样性 (diversity) 和新颖性 (novelty) 的多目标强化学习框架, 我们增加了另外两个目标: 难度 (difficulty) 和相似度 (similarity)。于是, 基于多目标强化学习的马尔可夫建模如下:

$$\max_{\pi} J = \max_{\pi} \frac{1}{n} \sum_{i=1}^n \left[ w^T \left( \sum_{t'=1}^T \gamma^{t'} r(s_t^i, q_t^i) \right) \right] = \max_{\pi} \mathbb{E}_{i \sim \pi} \left[ w^T \left( \sum_{t'=1}^T \gamma^{t'} r(s_t^i, q_t^i) \right) \right] \quad (16)$$

其中  $n$  是学生数量,  $q_t^i$  是在状态  $s_t^i$  下根据选择算法  $\pi$  所选的题目,  $r(s_t^i, q_t^i) = [r_{qua}, r_{div}, r_{nov}, r_{dif}, r_{sim}]$  是选择  $q_t^i$  所获得的奖励,  $w$  是用于计算各奖励分量重要性的权重向量。考量因素通过设定奖励值来引入, 其中  $r_{qua}$ 、 $r_{div}$  和  $r_{nov}$  与原始 MORL 相同; 此外, 这里还引入了题目难度  $r_{dif}$  和学生相似度  $r_{sim}$ 。

**难度。**人们普遍认为, 如果给学生很多非常简单的题目, 他们的能力无法得到提升; 如果给学生太多非常困难的题目, 他们可能因为题目超出自己的能力而随意作答。这两种情况都无法反映学生的真实水平。因此, 定义学生  $i$  的能力为  $D_i$ :

$$D_i = \frac{1}{|Q_i|} \sum_{q \in Q_i} d_q, \quad d_q = \frac{1}{n} \sum_{j=1}^n r_{q,j} \quad (17)$$

其中  $Q_i$  是学生  $i$  做过的题目集合,  $d_q$  是题目  $q$  的难度,  $d_q$  越高题目越难,  $n$  是题目  $q$  被所有学生练习的次数,  $r_{q,j}$  是学生  $j$  对题目  $q$  的作答。假设题目  $q$  在时刻  $t$  被选中, 难度奖励定义为:

$$r_{dif} = \begin{cases} 1, & \text{若 } |D_i - d_q| < x_{dif} \\ 0, & \text{其他} \end{cases} \quad (18)$$

其中  $x_{dif}$  是一个阈值, 这里设为 0.25。

**相似度。**利用用户相似度为用户推荐商品是推荐系统中常用的方法。具体来说, 如果用户  $u_i$  和用户  $u_j$  的购物习惯相似, 那么  $u_i$  很可能对  $u_j$  购买过的东西感兴趣, 且购买概率很高。这一思想可用于为学生推荐他可能感兴趣、或潜在需要练习的题目。这里使用 Jaccard 系数来度量学生  $s_i$  与学生  $s_j$  之间的相似度:

$$\text{similarity}(s_i, s_j) = \frac{|Q_{s_i} \cap Q_{s_j}|}{|Q_{s_i} \cup Q_{s_j}|} \quad (19)$$

$s_i$  的候选相似题目集  $Q_i$  由所有与  $s_i$  相似度高于  $x_{sim}$  的  $s_j$  所做的题目集合得到:

$$Q_i = \left( \bigcup_{j=1}^n Q_{s_j} \right) / Q_{s_i} \quad (i \neq j, \text{similarity}(s_i, s_j) > x_{sim}) \quad (20)$$

假设题目  $q_t$  在时刻  $t$  被选中, 相似度奖励定义为:

$$r_{sim} = \begin{cases} 1, & \text{若 } q_t \in Q_i \\ 0, & \text{其他} \end{cases} \quad (21)$$

然后, 定义奖励  $r(s_t^i, q_t^i) = [r_{qua}, r_{div}, r_{nov}, r_{dif}, r_{sim}]$ , 每个奖励分量的权重可由二值向量  $w$  设定。

我们使用 Actor-Critic 作为推荐器：策略网络是一个参数为  $\phi_\pi$  的全连接层，作为 actor，从分布  $\pi(q_t|s_t; \phi_\pi)$  中采样选择题目；一个参数为  $\phi_v$  的全连接价值网络作为 critic，用于评估状态。给定一个状态，critic 输出向量  $V(s_t; \phi_\pi) = [V(s_t)_{qua}, V(s_t)_{div}, V(s_t)_{nov}, V(s_t)_{dif}, V(s_t)_{sim}]$  用于预测期望回报。为了最大化式 (16) 中的加权和  $J$ ，这里使用多目标 PPO (Schulman 等, 2017)。

$q_t$  的优势值 (advantage) 定义为一个状态-动作对的实际回报减去该状态的预测值：

$$A(s_t, q_t) = \sum_{t'=t} \gamma^{t'-t} r(s_{t'}, q_{t'}) - V(s_t) \quad (22)$$

为了把  $A$  转换为标量，这里使用权重向量  $w$ ， $w$  中的每个分量分别对应质量、多样性、新颖性、难度和相似度目标。这里采用裁剪的替代损失 (clipped surrogate loss) 来更新动作参数：

$$L_1 = -\mathbb{E}_{\tau \sim \pi_{old}} \left[ \text{Min} \left\{ \frac{\pi(q_t|s_t)}{\pi_{old}(q_t|s_t)} w^T A(s_t, q_t), \text{Clip} \left( \frac{\pi(q_t|s_t)}{\pi_{old}(q_t|s_t)}, 1 - \epsilon, 1 + \epsilon \right) w^T A(s_t, q_t) \right\} \right] \quad (23)$$

critic 损失基于“期望回报尽可能接近实际回报”的期望来提出：

$$L_2 = \frac{1}{2} w^T \|V(s_t) - \gamma^{t'-t} r(s_{t'}, q_{t'})\|^2 \quad (24)$$

最终的多目标 PPO 损失函数为：

$$L = L_1 + \alpha L_2 \quad (25)$$

其中  $\alpha$  是平衡参数。

## 4 实验

### 4.1 数据集与设置

我们在三个公开数据集上进行实验 (Assist2009、Junyi、Eedi)。这些数据集记录了学生在在线教育平台上的作答数据。在去除学生交互序列长度小于 40 的数据后，三个数据集处理后的统计数据如表 1 所示。

表 1：实验所用数据集的统计信息。Assist2009：学生 1,360、题目 17,751、概念 123、交互 239,919、每题概念数 1.2、每概念题目数 172.7、正标签率 0.55；Junyi：学生 20,395、题目 2,835、概念 40、交互 2,537,898、每题概念数 1.0、每概念题目数 70.9、正标签率 0.62；Eedi：学生 4,918、题目 948、概念 86、交互 1,382,727、每题概念数 4.0、每概念题目数 44.28、正标签率 0.69。

实验按照 80%-10%-10% 的比例划分为训练集、测试集和验证集。同时，每个学生的数据按照 80%-20% 的比例划分为候选数据集 (candidate) 和元数据集 (metadata)。元数据集中的数据被视为学生的历史交互记录，候选数据集中的数据则可能根据选择算法被推荐给学生。这两个数据集在每个训练阶段都随机生成，以防止过拟合。实验中，权重因子  $w = [1, 1, 1, 1, 1]$ ，潜在空间投影数  $K = 3$ ，并展示 step=10、20 时的结果。设  $x_{dif} = 0.25$ 、 $x_{sim} = 0.1$ ，式 (22) 中  $\gamma = 0.5$ ，式 (23) 中  $\epsilon = 0.2$ ，批大小为 128，嵌入维度  $d = 16$ 。自注意力机制中的 dropout 因子为 0.1。优化器为 Adam，学习率为 0.02，损失平衡因子为 1。实验直接使用基线在原文中的参数，以确保其最佳效果。由于只有 Junyi 提供了先决 (premise) 关系，因此在另外两个数据集中使用 Gao 等人 (2021) 的方法来构建概念有向图。

### 4.2 性能比较

为验证 KGCAT 的有效性，实验将 KGCAT 与 MAAT (Bi 等, 2020)、BOBCAT (Ghosh 和 Lan, 2021)、NCAT (Zhuang 等, 2022) 和 GMOCAT (Wang 等, 2023) 进行比较，分别以 IRT 和 NCD 为基础。在本工作中，模型预测学生对题目作答的结果 (正确或错误)。表 2 和表 3 是 step=10 和 20 时、以 AUC (ROC 曲线下面积) 和 ACC (准确率) 为指标的结果。KGCAT 的整体性能优于基线。这表明，使用知识图谱来学习题目与概念的语义和关系信息、并考虑题目难度和学生相似度，对提升 CAT 的性能是有益的。KGCAT 有时在步数较少时表现不如基线，但随着步数增加，其 AUC 和 ACC 会持续上升并达到最优。这证明了强化学习在更长期场景中的优越性。同时，使用强化学习方法的 NCAT、GMOCAT、KGCAT 优于其他不使用强化学习的方法，这也证明了强化学习在选择算法应用中的有效性。

表 2：所有基线与所提模型在 3 个数据集上的 AUC 比较结果。最佳结果加粗，次佳结果下划线。(原文为大表，结构复杂，具体数值详见原文。)

表 3: 所有基线与所提模型在 3 个数据集上的 ACC 比较结果。最佳结果加粗, 次佳结果下划线。(原文为大表, 结构复杂, 具体数值详见原文。)

KGCAT 在 Assist2009 和 Junyi 上的提升高于在 Eedi 上的提升。这是因为在 Assist2009 和 Junyi 数据集上, 每道题目平均涉及 1.2 和 1 个概念; 当我们把每道题目投影到 3 个潜在空间时, 能捕捉到更多的概念信息。而在 Eedi 上, 每道题目平均涉及 4 个概念, 把题目投影到 3 个潜在空间可能造成信息损失。

### 4.3 消融与讨论

为证明 KGCAT 各模块的有效性, 在 Eedi 数据集上进行了消融实验。KGCAT-KG、KGCAT-H 和 KGCAT-S 分别表示将 KGCAT 中的知识图谱替换为普通 GNN、去除题目难度奖励、去除学生相似度奖励后的模型。通过在式 (16) 中设置  $w = [1, 1, 1, 0, 1]$  和  $w = [1, 1, 1, 1, 0]$ , 分别实现了 KGCAT-H 和 KGCAT-S。如图 3 所示, 在 step=20 时, 无论移除哪个模块, KGCAT 的性能都会下降, 这证明了每个模块都对提升模型性能起到了作用。其中, KGCAT-H 和 KGCAT-S 的性能下降迅速, 表明题目难度和学生相似度在题目选择中的重要性, 进一步证明了强化学习的优越性。为探索  $x_{dif}$  和  $s_{sim}$  的最优值, 我们在 Eedi 数据集上进行了额外实验。

图 3: 消融实验的结果。

**投影数  $K$  分析。**在 3.2 节中提到, 为了学习更丰富的特征, 把题目投影到  $K$  个潜在空间。为探索最合适的  $K$  值, 我们进行了实验。由于算力限制, 这里  $K$  只取 1 到 3 的值。结果如图 4 所示。当  $K = 3$  时结果最好, 这符合认知规律: 题目被投影到的空间越多, 能学到的不同语义就越多, 模型性能就越能提升。消融实验中 KGCAT-KG 对模型的影响不如 KGCAT-H 和 KGCAT-S, 也可能是因为  $K$  的取值不够大, 无法学到更丰富的语义信息。

图 4: 不同  $K$  值下的 AUC 与 ACC 性能比较。

**$x_{dif}$  分析。**图 5 展示了 Eedi 上题目难度的分布。大多数题目难度适中, 这与大多数教育平台上题目难度的分布一致。实验结果如图 6 所示。当  $x_{dif} = 0.25$  时 AUC 和 ACC 效果最好, 而随着取值向两端靠近, 效果逐渐变差。这是因为: 如果  $x_{dif}$  的值越小, 满足条件的题目就越少, 导致一部分实际上对模型有用的题目也被过滤掉, 使效果变差; 但如果  $x_{dif}$  的值太大, 会降低对题目的筛选效果, 这也会降低模型的性能。

图 5: 题目难度的概率密度分布。

表 4: 不同  $x_{sim}$  下的学生数量。  $x_{sim} = 0.1/0.2/0.3/0.4/0.5$  对应学生数 4,914/4,908/4,875/4,766/4,463。

图 6: 不同  $x_{dif}$  下的 AUC 与 ACC 性能比较。

图 7: 不同  $x_{sim}$  下的 AUC 与 ACC 性能比较。

**$x_{sim}$  分析。**表 4 是不同  $x_{sim}$  下, 候选相似题目集  $Q_i$  长度大于 0 的学生数量。当  $x_{sim} > 0.4$  时, 拥有候选相似题目集的学生数量开始迅速下降。为了让尽可能多的学生拥有自己的候选相似题目集, 使用  $x_{sim} \leq 0.5$  来计算模型的 AUC 和 ACC。如图 7 所示, 当  $x_{sim} = 0.1/0.2$  时整体性能更好。同时,  $x_{sim}$  的值不宜太大, 应让尽可能多的学生拥有自己的候选相似题目集。

## 5 结论

为提升个性化教育推荐的效果, 我们提出一种基于知识图谱推理的计算机自适应测试模型 (KGCAT)。该模型利用知识图谱的推理能力, 从而深入学习题目与概念之间的关系, 并引入一个使用互信息的解耦模块, 通过最小化低相关性邻居节点的影响来降低噪声。此外, 通过将强化学习纳入决策过程, 该模型以多目标的方式同时考虑题目难度和学生相似度, 从而实现更准确的题目推荐。最后, 一系列实验证明了该模型的有效性与改进的可解释性。

## 6 局限

虽然 KGCAT 有效地利用互信息来降低噪声、提升推荐准确性, 但处理包含大量概念和题目的大规模知识图谱可能带来计算上的挑战, 从而潜在地限制可扩展性。此外, 为概念解耦集成互信息以及多目标强化学习, 给超参数调优过程增加了额外的复杂性, 需要相当多的时间和精力来优化诸如学习率、奖励结构和互信息阈值等组件。

---

参考文献 (References) 按约定未翻译, 详见原文。