

受扩散模型启发、具备充分先验的计算机自适应测试冷启动 (Diffusion-Inspired Cold Start with Sufficient Prior in Computerized Adaptive Testing)

原文: dcsr-diffusion-cold-start-cat_12.pdf (KDD '25, Ma et al.) ·译者: Claude ·译于 2026-06-26 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT)、认知诊断模型 (Cognitive Diagnosis Model, CDM)、冷启动 (cold start)、先验不足冷启动 (Cold Start with Insufficient Prior, CSIP)、扩散模型 (Diffusion Model, DM)、领域迁移 (domain transfer)、后门准则 (backdoor criterion)、混淆变量 (confounding variable)

摘要

计算机自适应测试 (CAT) 旨在根据考生能力选择最合适的题目, 被广泛用于在线教育。然而, 现有 CAT 系统在测试初期往往缺乏对考生能力的认识, 需要随机投放试探性题目。这会导致题目匹配不佳、延长测试时长, 并对考生心态产生负面影响, 我们将这一现象称为**先验不足的冷启动 (Cold Start with Insufficient Prior, CSIP)** 任务。该问题之所以出现, 是因为 CAT 系统没有有效利用在线平台上其他课程所提供的、关于考生的丰富先验信息。由于不同知识领域之间认知状态的共性, 这些作答记录能为目标领域提供有价值的先验信息。然而, 此前没有工作探索过 CSIP 任务的解决方案。

针对这一空白, 我们提出**扩散认知状态迁移框架 (Diffusion Cognitive States Transfer Framework, DCSR)**, 一个基于扩散模型 (DM) 的新型领域迁移框架来解决 CSIP 任务。具体而言, 我们在领域之间构建一座**认知状态转移桥梁**, 由考生的共有认知状态来引导, 促使模型在目标领域中重建初始能力状态。为丰富生成数据的表达能力, 我们从因果视角分析生成过程中的因果关系。冗余和无关的认知状态会导致迁移受限以及负迁移效应。因此, 我们设计了**三种解耦策略**来控制混淆变量, 从而阻断妨碍因果发现的后门路径。鉴于过度的不确定性会影响生成结果对 CAT 系统的适用性, 我们提出**一致性约束 (consistency constraint)** 和**任务导向约束 (task-oriented constraint)**, 分别用于控制生成结果的随机性及其与 CAT 任务的相关性。我们的 DCSR 能将目标领域中生成的初始能力状态无缝应用于现有的题目选择算法, 从而提升 CAT 系统的冷启动性能。在五个真实数据集上的大量实验表明, DCSR 在解决 CSIP 任务上显著优于现有基线方法。代码已开源: <https://github.com/BIMK/Intelligent-Education/tree/main/DCSR>。

1 引言

随着人工智能赋能教育, 在线教育平台上的计算机自适应测试 (CAT) 受到了广泛关注。CAT 旨在用少量合适的题目, 逐步评估考生在特定领域的认知状态。通常, CAT 由两个迭代组件构成: 认知诊断模型 (CDM) 和题目选择算法。如图 1(a) 所示, CDM 根据考生在第 $t-1$ 步的作答估计其能力, 随后题目选择算法为下一步提供合适的题目, 从而实现对考生能力更精确的评估。

图 1: (a) 典型 CAT 流程的示意, 以及 (b) 冷启动下 CAT 的困境。

作为 CAT 关键组件的题目选择算法, 现有研究可分为**基于策略 (policy-based)** 与**基于学习 (learnable-based)** 两类。前者通常把题目选择过程转化为模型期望, 后者则把 CAT 过程定义为一个双层优化问题。

尽管各种题目选择算法取得了进展, 但它们在 CAT 过程中仍面临冷启动问题的挑战。如图 1(b) 所示, 在在线教育平台上, 系统初始时对考生能力一无所知, 导致 CAT 系统只能随机试探性地选题来确定测试的起点。题目的难度和内容可能与考生实际能力不符, 造成困惑或挫败, 并增加评估的时间成本。此外, 题目选择过程是一条迭代的马尔可夫链 (Markov chain), 这意味着如果初始阶段所选题目与考生能力不匹配, 可能导致后续阶段的选题出现偏差。大多数基于贪心策略的题目选择算法往往会放大这种偏差, 损害 CAT 系统的性能。这些算法虽然在某些场景下能快速找到局部最优, 但在多轮选题中容易陷入局部最优。在本文中, 我们将这一任务称为**先验不足的冷启动 (CSIP)**, 它源于测试初始阶段题目选择算法对考生认识不足, 导致选择起点不确定, 进而影响自适应测试过程。

随着教育平台的广泛应用, 大量考生数据被采集和存储, 为丰富 CAT 系统的先验信息提供了宝贵资源。值得注意的是, 考生在**其他课程**中的历史作答记录可以作为 CAT 系统初步了解考生能力的重要参考。不同课程的知识概念之间一定存在共性。例如, 许多物理题目 (如运动学和动力学) 需要求解代数方程, 而这是数学中的基础。因此, 考生在多门课程上的作答记录能反映其在多个交叉学科领域的基础能力和认知共性, 这些是**可迁移的属性**。这些预先诊断出的能力可以为目标 (冷启动) 课程提供丰富的先验信息, 让 CAT 系统提前把握考生的能力范围。例如, 如果一名考生在数学 (尤其是复杂代数和几何题) 上表现优异, CAT 系统就能推断他在物理上也具备较强的逻辑思维和解题能力, 从而赋予较高的初始能力。据我们所知, 尽管 CSIP 任务具有重要的实际意义, 目前还没有研究利用这些跨课程数据来解决它。

为充分利用这些跨课程作答记录、向 CAT 系统提供关于考生的先验信息, 我们基于扩散模型 (DM) 的思想, 将考生的预诊断结果整合并迁移到目标领域。DM 逐步加入噪声, 再分步反向重建被破坏的数据, 这不仅能处理源领域中的噪声作答记录, 也恰好契合 CSIP 任务的求解需求。这是因为 DM 在去噪过程中能逐步将复杂的多分布跨领域数据融合进一个统一的隐空间, 生成统一的隐表示, 从而从噪声中重建出带有特定迁移属性的目标领域初始能力。然而, 尽管用 DM 解决 CSIP 任务潜力巨大, 我们也发现了「是什么」与「怎么做」两方面的挑战: (1) 什么样的源领域信息可以作为引导输入反向去噪过程; (2) 如何约束输出以匹配 CAT 系统——这意味着生成结果中过度的不确定性会导致数据不适用于 CAT 任务。

为应对这些挑战, 我们为 CSIP 任务设计了一个新型领域迁移框架——**扩散认知状态迁移框架 (DCSR)**。在 DM 原理的引导下, 我们为考生在目标领域生成初始能力, 以增强 CAT 系统的冷启动性能。具体而言: 为防止扩散生成结果中个性化信息的丢失, 我们让去噪器以考生的先验认知能

力为条件，融入个性化的目标领域能力；为避免冗余信息和负迁移，我们从模型的因果视角分析不同变量之间的因果关系，设计三种解耦策略来调整后门路径中的混淆变量，阻断遮蔽真实因果关系的路径；为缓解 DM 的过度不确定性、增强对 CAT 任务的适应性，我们设计一致性约束和任务导向约束来控制随机性、匹配 CAT 系统的输入要求。DCSR 生成的结果可与现有题目选择算法无缝集成，提升 CAT 系统的冷启动性能。在五个真实数据集上的大量实验结果表明，DCSR 有效解决了 CSIP 任务，并显著优于各类基线。

2 相关工作

2.1 计算机自适应测试

CAT 旨在用较短的测试长度逐步评估考生能力。CAT 系统主要由两部分组成：(1) **认知诊断模型 (CDM)**，根据考生对所选题目的作答来诊断其能力。其中，项目反应理论 (Item Response Theory, IRT) 是一种广泛使用的 CDM，它假设单维独立性，用连续的隐变量来评估考生的潜在能力。随着深度神经网络的广泛应用，NCD、RCD、KaNCD 等神经网络 CDM 利用神经网络捕捉考生与题目之间的复杂交互，实现细粒度的诊断建模。(2) **题目选择算法**，旨在根据 CDM 的反馈自适应地选择下一道合适的题目。早期的题目选择算法是模型特定 (model-specific) 的，例如 IRT 专用的最大费舍尔信息量 (Maximum Fisher Information)、KL 信息指数 (Kullback-Leibler Information Index) 和最大熵 (Max Entropy)。然而，这些简单算法无法满足 CDM 不断演进的需求，导致性能受限。因此，模型无关 (model-agnostic) 的题目选择算法 MAAT 被提出，它利用主动学习把题目选择过程转化为「选取期望模型变化最大的题目」。类似地，BECAT 采用期望梯度差方法，在考生真实能力理论估计的指导下，把题目选择视为一个子集选择问题。另一个研究方向聚焦于数据驱动的题目选择算法，例如 BOBCAT、NCAT 和 GMOCAT 把 CAT 任务定义为双层优化问题，用强化学习从大规模作答数据中学习题目选择算法。然而，从模型角度看，当前 CAT 系统中关键的 CDM 组件在测试之初**随机初始化**考生能力，这种随机初始化使得贪心算法需要更多的选题步骤才能了解考生能力范围，从而加剧了 CAT 系统的冷启动问题。

2.2 扩散模型

扩散模型 (DM) 在图像生成等领域取得了令人瞩目的成果。为将这些成功迁移到其他领域，近期工作尝试架起图像领域与其他领域之间的桥梁。CODIGEM 首次将 DM 中的去噪模块扩展到推荐系统。DiffuRec、DreamRec 和 CF-Diff 对物品和用户偏好的隐表示建模，引导去噪模块生成个性化表示。DiffRec 和 DiffuASR 不仅降低了生成成本，还实现了对交互序列的时序建模。此外，更多研究利用 DM 的马尔可夫链建模特性来探索序列建模，而利用扩散特性研究跨领域问题的研究较少。尽管 DiffCDR 在这一方向做了初步探索，但它引入了冗余信息，且由于 CAT 系统中实体的多样性，在跨领域表示能力上存在局限。

3 预备知识

3.1 计算机自适应测试

3.1.1 任务介绍。在在线教育平台中，CAT 系统自适应地为考生选题，以准确揭示其认知能力。CAT 系统由两个组件构成：(1) 认知诊断模型 (CDM) $\mathcal{M}$ ，在考生作答所选题目后评估其能力状态；(2) 题目选择算法 Π ，根据考生当前能力状态选择下一道最有信息量的题目，以更精确地度量其能力。这两个组件交替迭代，直至满足终止条件。

具体而言，给定考生 e_i 及其候选题集 Q_i ，CAT 过程可表示为：

$$q_t \leftarrow \Pi(Q_i \mid \theta_i^{t-1}), \quad \theta_i^t \leftarrow \mathcal{M}(r_{iq_t} \mid q_t, \theta_i^{t-1}), \quad (1)$$

其中 q_t 表示 Π 在第 $t-1$ 时刻基于考生能力 θ_i^{t-1} ，从候选题集 Q_i 中所选的题目， Q_i 只包含考生 e_i 尚未作答的题目。变量 r_{iq_t} 表示考生 e_i 对题目 q_t 的作答结果。注意 T 是终止测试的最大步数。

3.1.2 先验不足的冷启动。在先验不足冷启动 (CSIP) 场景中，题目选择算法只考虑目标领域的信息，而忽略源领域的丰富数据。为缓解这种先验信息缺失，我们在 DCSR 中定义 M 个源领域 $\mathcal{S}_1, \mathcal{S}_2, \dots, \mathcal{S}_M$ 和一个目标领域 $\mathcal{T}$ 。每个领域包含三组实体。我们用 $E_{\mathcal{S}_m}$ 、 $Q_{\mathcal{S}_m}$ 、 $C_{\mathcal{S}_m}$ 分别表示第 $m \in M$ 个源领域中的考生集、题目集和知识概念集；类似地， $E_{\mathcal{T}}$ 、 $Q_{\mathcal{T}}$ 、 $C_{\mathcal{T}}$ 表示目标领域的三类实体。领域之间的重叠考生定义为 $E_O \ni E_{O_m} = E_{\mathcal{S}_m} \cap E_{\mathcal{T}}$ ，而另外两类实体一般在领域间没有重叠元素。

3.1.3 训练与测试阶段。在给定的 CAT 测试平台中，目标领域同时包含**热启动 (warm-start)** 和**冷启动 (cold-start)**，即 CAT 系统从未遇到过的考生。它们的作答记录可表示为：

$$R_{\mathcal{T}} = \{R_{\mathcal{T}}^{\text{warm}}, R_{\mathcal{T}}^{\text{cold}}\} = \{(e_i, q_j, r_{ij}) \mid e_i \in E_{\mathcal{T}}^{\text{warm}} \cup E_{\mathcal{T}}^{\text{cold}}\},$$

其中 $r_{ij} = 1$ 表示考生 e_i 正确作答题目 $q_j \in Q_{\mathcal{T}}$ ，否则 $r_{ij} = 0$ 。类似地，第 m 个源领域的作答记录表示为 $R_{\mathcal{S}_m} = \{(e_i, q_j, r_{ij}) \mid e_i \in E_{O_m}, q_j \in Q_{\mathcal{S}_m}\}$ ，所有源领域记录记为 $R_S = \{R_{\mathcal{S}_1}, R_{\mathcal{S}_2}, \dots, R_{\mathcal{S}_M}\}$ 。为防止数据泄露，上述作答集被统一划分为训练集 $D_{\text{train}} = \{R_{\mathcal{T}}^{\text{warm}}, R_S\}$ 和测试集 $D_{\text{test}} = R_{\mathcal{T}}^{\text{cold}}$ 。

我们的 DCSR 包含两个阶段：基于 D_{train} 训练考生在源领域的初始能力；以及基于 D_{test} 、在无需学习的情况下测试 CAT 系统中题目选择的性能。

3.1.4 预先建立认知状态。训练集 D_{train} 中的数据来自领域间重叠考生 E_O 的作答记录。我们对这些考生进行预训练，以建立他们在源领域和目标领域中的认知状态。预训练过程表示为：

$$\theta^* = \arg \min_{\theta \in \Theta} \sum_{(e_i, q_j, r_{ij}) \in D_{train}} \mathcal{L}(r_{ij}, \mathcal{M}_\Psi(q_j | \theta_i)), \quad (2)$$

其中 $\mathcal{M}_\Psi$ 是用于预训练的 CDM，不同领域数据对应不同的 CDM 参数，即 $\Psi = \{\psi_{S_1}, \psi_{S_2}, \dots, \psi_{S_M}, \psi_{\mathcal{T}}\}$ 。重叠考生的能力记为 $\Theta_S = \{\theta_i | i \in E_O\}$ ，类似地，目标领域的能力记为 $\Theta_{\mathcal{T}}$ 。

3.2 扩散模型

扩散模型 (DM) 在计算机视觉等领域展现出卓越性能。通常，DM 由两部分组成：前向过程和反向过程。

3.2.1 前向过程。给定从真实数据分布中采样的数据点 $x_0 \sim q(x)$ ，前向过程通过 T 步注入高斯噪声，逐步将 x_0 退化为标准高斯噪声 $x_T \sim \mathcal{N}(0, 1)$ 。具体而言，DM 中从 x_{t-1} 转换到 x_t 的过程表示为 $q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t \mathbf{I})$ ，其中 $t \in \{1, \dots, T\}$ 表示扩散步， $\beta_t \in (0, 1)$ 是预定义的噪声调度系数， $\mathcal{N}$ 表示高斯分布。

3.2.2 反向过程。在反向过程中，DM 学习去除所加的噪声，从而从纯噪声中恢复原始数据分布 x_0 ，并在生成过程中引入较小的不确定性。该过程学习一个参数化网络 $p_\delta(x_{t-1} | x_t)$ 来逼近反向过程，可形式化为 $p_\delta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\delta(x_t, t), \Sigma_\delta(x_t, t))$ ，其中 μ_δ 和 Σ_δ 是由参数为 δ 的神经网络预测的高斯分布的均值和方差。

4 方法

概述。本工作的核心思想是将源领域的先验诊断结果迁移到目标领域，从而为目标领域课程中的冷启动考生生成个性化的初始能力。如图 2 所示，DCSR 以**扩散模块 (Diffusion Module)** 为骨干，并由两个关键组件支撑：**认知状态统一模块 (Cognitive State Unification Module, CSUM)** 和**协调校准模块 (Harmonization and Calibration Module, HCM)**。具体而言，扩散模块利用源领域的先验能力，从噪声中重建考生在目标领域的认知状态。从因果模型视角看，生成的能力会受到冗余知识的影响，而领域特定的认知可能导致负迁移。因此，CSUM 用于控制后门路径中的混淆变量，从而揭示真实的因果关系。此外，为缓解扩散过程中的不确定性，我们在 HCM 中设计了一致性约束和任务导向约束，旨在保证生成结果既符合真实分布、又满足 CAT 任务的要求。值得注意的是，我们的框架具有显著的可扩展性，能将目标领域生成的初始能力无缝集成到现有 CAT 中，从而提升其冷启动性能。

图 2: DCSR 概览。左侧对应预训练；蓝色、黄色、绿色模块用于训练，橙色模块对应在 CAT 中的应用。右侧描绘了生成过程中的因果发现。

4.1 扩散模块

我们采用扩散思想作为模型骨干，在源领域与目标领域之间建立一座认知状态转换的桥梁。扩散模块的目的是将源领域的先验信息融入目标领域的初始能力估计过程。因此，它本质上包含两个不同的过程：前向加噪过程和反向去噪过程。

训练时，我们在 T 步内逐步向目标领域考生的能力向量 $\Theta_{\mathcal{T}}$ 注入高斯噪声。对特定考生 $e_i \in E_O$ ，其能力向量 $\theta_{i0}^{\mathcal{T}} = \theta_i^{\mathcal{T}} \in \Theta_{\mathcal{T}}$ 被破坏为 $\theta_{i1:T}^{\mathcal{T}}$ ，建模为一条高斯转移马尔可夫链：

$$q(\theta_{i1:T}^{\mathcal{T}} | \theta_{i0}^{\mathcal{T}}) = \prod_{t=1}^T \mathcal{N}(\theta_{it}^{\mathcal{T}}; \sqrt{1 - \beta_t} \theta_{it-1}^{\mathcal{T}}, \beta_t \mathbf{I}), \quad (3)$$

其中 $\beta_t \in (0, 1)$ 控制第 t 步所加噪声的尺度， $\mathcal{N}$ 表示高斯分布。

在反向去噪过程中，传统去噪方法（如 3.2.2 节所述）不足以实现有效迁移，因为所建模的去噪过程缺乏源领域信息的引导，导致生成能力丧失个性化。为生成个性化的能力向量，我们提出利用源领域的先验信息来引导去噪过程。具体而言，对考生 e_i ，我们用预训练得到的源领域能力 $\theta_i^S \in \Theta_S$ 作为引导：

$$p_\delta(\hat{\theta}_{it-1}^{\mathcal{T}} | \theta_{it}^{\mathcal{T}}, \theta_i^S) = \mathcal{N}(\hat{\theta}_{it-1}^{\mathcal{T}}; \mu_\delta(\theta_{it}^{\mathcal{T}}, \theta_i^S, t), \Sigma_\delta(\theta_{it}^{\mathcal{T}}, \theta_i^S, t)), \quad (4)$$

其中 μ_δ 和 Σ_δ 是由可学习参数为 δ 的神经网络输出的参数。

4.2 认知状态统一模块 (CSUM)

尽管用 CDM 得到的统一源领域能力来引导反向去噪是一种有前景的做法，但从模型的因果视角看（如图 2 右侧所示），在训练阶段，生成能力 Y 会受到领域共有认知 X 、领域特定认知 A_1 和目标领域能力 B 的影响。这是因为我们在训练时对时间步进行随机采样，即使引入了噪声，也会在目标领域能力向量中保留一些个性化信息。换言之， $\theta_{i1:T}^T$ 并不逼近标准高斯噪声，缺乏广泛的个性化特征。然而，引入领域特定认知 A_1 会增加模型复杂度、降低泛化能力，使模型容易过拟合。因此，我们提出探索生成结果 Y 与领域共有认知 X 、目标领域预训练能力 B 之间的因果关系，而 B 又可进一步解耦为领域特定认知 B_1 和领域共有认知 X 。接下来我们具体分析不同因素对生成结果的影响。

首先，领域共有认知 X 与生成结果 Y 之间存在三条路径： $X \rightarrow Y$ 、 $X \leftarrow \{A, A_1\} \rightarrow Y$ 、 $X \leftarrow \{B, B_1\} \rightarrow Y$ ，其中后两条是混淆路径。我们将应用后门准则 (**backdoor criterion**) 来探索 $X \rightarrow Y$ 的因果关系，即需要控制混淆变量 $C = \{A, A_1\} \cup \{B, B_1\}$ 来阻断后门路径：

$$P(Y | do(X)) = \sum_C P(Y | X, C = c)P(C = c), \quad (5)$$

其中第一项表示在控制混淆变量 C 的条件下 X 对 Y 的影响，第二项表示混淆变量的联合概率分布。为控制混淆变量，受相关工作启发，我们从源领域和目标领域的所有先验能力中解耦出领域共有认知 θ_i^{share} ：

$$\theta_i^{share} = f_{\varphi_2}(\sigma(f_{\varphi_1}(\theta_i^T \| \sum_{E_m \sim S_M} W_m \theta_i^{S_m}))), \quad (6)$$

其中 $W \in \mathbb{R}^{M \times d}$ 是把多个领域的预训练能力映射到同一特征空间的权重矩阵， d 是与 CDM 相关的特征维度， f_{φ_1} 和 f_{φ_2} 是参数不同的线性层， σ 表示激活函数， $(\cdot \| \cdot)$ 表示拼接操作。然后我们鼓励这个解耦出的领域共有认知去帮助预测所有领域的作答：

$$\mathcal{L}_1 = \sum_{(e_i, q_j^T, r_{ij}^T) \in R_{\mathcal{T}}^{warm}} \|r_{ij}^T - \mathcal{M}_{\phi_T}(\theta_i^{share}, q_j^T)\| + \sum_{S_m=1}^M \sum_{(e_i, q_j^{S_m}, r_{ij}^{S_m}) \in R_{S_m}} \|r_{ik}^{S_m} - \mathcal{M}_{\phi_{S_m}}(\theta_i^{share}, q_k^{S_m})\|, \quad (7)$$

其中 θ^{share} 被鼓励在所有场景下预测作答，包括第一项的目标领域和第二项的所有源领域作答数据。接下来，目标领域的特定认知 B_1 有两条路径影响生成结果： $B_1 \rightarrow Y$ 和 $B_1 \leftarrow \{X, B\} \rightarrow Y$ 。我们调整第二条混淆路径中的混淆变量 $\{X, B\}$ 来阻断后门路径。具体而言，我们抽取目标领域的特定认知（它将在 4.1 节中作为输入），同时获得目标领域的整体认知状态（对应因果图中的事件 B ）：

$$\theta_i^{\mathcal{T}specific} = f_{\varphi_4}(\sigma(f_{\varphi_3}(\theta_i^T))), \quad \theta_i^{concat} = f_{\varphi_5}(\sigma(f_{\varphi_6}(\theta_i^{\mathcal{T}specific} \| \theta_i^{share}))), \quad (8)$$

其中 $f_{\{\varphi_3, \varphi_4, \varphi_5, \varphi_6\}}$ 是四个参数不同的线性层。为学习目标领域的特定认知，我们提出一种新的解耦策略，它鼓励用领域特定认知预测领域内的作答结果，同时降低在其他领域的预测性能：

$$\begin{aligned} \mathcal{L}_2 = & \sum_{(e_i, q_j^T, r_{ij}^T) \in R_{\mathcal{T}}^{warm}} \left(\|r_{ij}^T - \mathcal{M}_{\phi_T}(\theta_i^{concat}, q_j^T)\| + \|r_{ij}^T - \mathcal{M}_{\phi_T}(\theta_i^{\mathcal{T}specific}, q_j^T)\| \right) \\ & - \sum_{S_m=1}^M \sum_{(e_i, q_j^{S_m}, r_{ij}^{S_m}) \in R_{S_m}} \left(\|r_{ik}^{S_m} - \mathcal{M}_{\phi_{S_m}}(\theta_i^{concat}, q_k^{S_m})\| + \|r_{ik}^{S_m} - \mathcal{M}_{\phi_{S_m}}(\theta_i^{\mathcal{T}specific}, q_k^{S_m})\| \right) \\ & + \mathbb{E}_{e_i \in E_{O_m}} \|\theta_i^T - \theta_i^{concat}\|. \end{aligned} \quad (9)$$

这里，第一项鼓励目标领域特定认知（无论是独立地还是与领域共有认知联合地）帮助预测目标领域的作答记录；第二项有意降低在源领域的预测性能，表明目标领域特定认知不适用于源领域；第三项约束预训练得到的诊断能力。此外，为进一步控制混淆变量对生成结果的影响，我们应用基于梯度的正交正则化来保证上述表示在特征空间中的独立性：

$$\mathcal{L}_3 = \left(\frac{\nabla_{\varphi_1, \varphi_2} \mathcal{L}_1}{\|\nabla_{\varphi_1, \varphi_2} \mathcal{L}_1\|} \cdot \frac{\nabla_{\varphi_3, \varphi_4} \mathcal{L}_2}{\|\nabla_{\varphi_3, \varphi_4} \mathcal{L}_2\|} \right)^2. \quad (10)$$

这种做法在学习领域共有认知时最小化领域特定认知的影响，反之亦然。

因此，前向与反向过程中的参数分别更新为 $q(\theta_{it}^{\mathcal{T}specific} | \theta_{it-1}^{\mathcal{T}specific})$ 和 $p_{\delta}(\hat{\theta}_{it-1}^{\mathcal{T}specific} | \theta_{it}^{\mathcal{T}specific}, \theta_i^{share})$ 。

4.3 协调校准模块 (HCM)

为学习去噪网络的参数 δ , DCSR 旨在最大化观测到的考生能力 $\theta_i^{\mathcal{T} specific}$ 的证据下界 (ELBO):

$$\begin{aligned} \log p(\theta_i^{\mathcal{T} specific}) &\geq \underbrace{\mathbb{E}_{q(\theta_{i0}^{\mathcal{T} specific} | \theta_{i1}^{\mathcal{T} specific})} [\log p_\delta(\theta_{i0}^{\mathcal{T} specific} | \theta_{i1}^{\mathcal{T} specific})]}_{:= \mathcal{L}_0} \\ &- \sum_{t=2}^T \underbrace{\mathbb{E}_{q(\theta_{it}^{\mathcal{T} specific} | \theta_{i0}^{\mathcal{T} specific})} [\text{KL}(q(\theta_{it-1}^{\mathcal{T} specific} | \theta_{it}^{\mathcal{T} specific}, \theta_{i0}^{\mathcal{T} specific}) \| p_\delta(\theta_{it-1}^{\mathcal{T} specific} | \theta_{it}^{\mathcal{T} specific}))]}_{:= \mathcal{L}_{t-1}}. \end{aligned} \quad (11)$$

这里, 第一项是**重建项**, 恢复 $\theta_{i0}^{\mathcal{T} specific}$ 的概率; 第二项是**去噪匹配项**, 把不可解的后验概率 $p_\delta(\cdot)$ 与可解分布 $q(\cdot)$ 对齐。为保持训练稳定、简化计算, 我们忽略对 $\Sigma_\delta(\cdot)$ 的学习, 将其设为与前向过程相同的固定值 β_t 。于是去噪匹配项可进一步计算为:

$$\mathcal{L}_{t-1} = \mathbb{E}_{q(\theta_{i0}^{\mathcal{T} specific} | \theta_{i1}^{\mathcal{T} specific})} \left[\frac{1}{2\beta_t} \left\| \mu_\delta(\theta_{it}^{\mathcal{T} specific}, \theta_{i0}^{\mathcal{T} specific}, t) - \tilde{\mu}(\theta_{it}^{\mathcal{T} specific}, \theta_{i0}^{\mathcal{T} specific}) \right\|^2 \right], \quad (12)$$

其中 $\tilde{\mu}(\cdot)$ 满足可解分布 $q(\theta_{it-1}^{\mathcal{T} specific} | \theta_{it}^{\mathcal{T} specific}, \theta_{i0}^{\mathcal{T} specific}) = \mathcal{N}(\theta_{it-1}^{\mathcal{T} specific}; \tilde{\mu}(\cdot), \beta_t \mathbf{I})$ 。

尽管上述训练目标保证了生成样本的多样性, 但 DM 在训练和推理阶段引入的过度随机性可能导致生成结果不符合 CAT 系统的要求。因此, 我们从两个方面约束生成的能力向量: 一致性约束和任务导向约束。

4.3.1 一致性约束。旨在最小化生成向量与真实数据样本在特征空间中的差异, 从而将不确定性限制在可控范围内。具体而言, 扩散模块将领域共有认知特征扩散为领域特定认知特征。首先, 生成目标领域的通用认知特征 $\hat{\theta}_i^{\mathcal{T}}$:

$$\hat{\theta}_i^{\mathcal{T}} = \mu_\delta(\theta_{iT:1}^{\mathcal{T} specific}, \theta_i^{share}, t_{T:1}) + \beta_t \epsilon, \quad \epsilon \in (0, 1). \quad (13)$$

由于固有的随机性, 生成的能力向量带有噪声, 不利于反映考生的真实能力。因此, 一致性约束旨在最小化 $\hat{\theta}_i^{\mathcal{T}}$ 与预训练得到的目标领域能力特征 $\theta_i^{\mathcal{T}}$ 之间的差异, 可建模为:

$$\mathcal{L}_{cc} = \mathbb{E}_{e_i \in E_O} (\theta_i^{\mathcal{T}} - \hat{\theta}_i^{\mathcal{T}})^2. \quad (14)$$

4.3.2 任务导向约束。保证生成的能力特征满足 CAT 任务的要求。具体而言, 我们从目标领域训练集 $R_{\mathcal{T}}^{warm}$ 中采样一些题目 q_j , 将生成的目标领域通用认知特征 $\hat{\theta}_i^{\mathcal{T}}$ 与 CDM 匹配:

$$\nabla_{\hat{\theta}_i^{\mathcal{T}}} \mathcal{L}_{tc} = - \sum_{(e_i, q_j, r_{ij}) \in R_{\mathcal{T}}^{warm}} \left[r_{ij} \log \mathcal{M}_{\psi_T}(\hat{\theta}_i^{\mathcal{T}}, q_j) + (1 - r_{ij}) \log (1 - \mathcal{M}_{\psi_T}(\hat{\theta}_i^{\mathcal{T}}, q_j)) \right], \quad (15)$$

其中 $\mathcal{M}_{\psi_T}(\cdot)$ 表示目标领域的预训练 CDM, 其参数被冻结, 只更新去噪模块的网络参数 $\mu_\delta(\cdot)$ 。

4.4 DCSR-CAT: DCSR 的实现

本节我们介绍 DCSR-CAT, 作为 DCSR 的一个实现, 以展示其对 CAT 的适用性。

在这一阶段, DCSR 不再涉及前向过程, 而是直接以纯噪声 $\epsilon_0 \sim \mathcal{N}(0, 1)$ 作为输入。对给定的、只在源领域有作答记录的冷启动考生 $e_i \in R_{\mathcal{T}}^{cold}$, 我们用预训练 CDM 获得其先验能力, 并计算其领域共有认知特征 θ_i^{share} 。值得注意的是, 由于原始的 $\theta_i^{\mathcal{T}}$ 未知, 我们用目标领域的平均认知状态作为替代:

$$\theta_i^{\mathcal{T} cold} = \mathbb{E}_{e_j \in R_{\mathcal{T}}^{warm}} \mathcal{M}_{\psi_T} \nabla_{\theta}(e_j), \quad (16)$$

这在一定程度上保留了领域信息。因此, 代回式 (6), 我们得到冷启动考生 e_i 的共有认知能力 θ_i^{share} 。为提升推理效率, 我们用 DPM-Solver 作为快速求解器, 高效地获得冷启动考生的初始能力:

$$\theta_i^0 = \text{Solver}(\mu_\delta(\cdot), \theta_i^{\text{share}}, \epsilon_0), \quad (17)$$

这对现实应用至关重要。我们的 DCSR 可与任何现有题目选择算法 Π 无缝集成。在测试之初，选择过程可表示为：

$$q_1 \leftarrow \Pi(Q_i \mid \theta_i^0), \quad (18)$$

这表示题目选择算法 Π 基于 DCSR 初始化的初始能力 θ_i^0 ，在第 $t = 1$ 步从候选题池 Q_i 中为考生 e_i 选出合适的题目 q_1 。后续步骤遵循一般的 CAT 系统流程。

5 实验

本节我们开展实验，旨在回答以下问题：

- **RQ1**: DCSR 能否利用单领域或多领域的先验信息来提升现有 CAT 系统的冷启动性能？
- **RQ2**: DCSR 框架的关键组件有多大效果？
- **RQ3**: DCSR 能否缓解题目选择算法陷入局部最优的问题？
- **RQ4**: DCSR 能否增强认知诊断模型的冷启动效果？
- **RQ5**: DCSR 赋予冷启动考生的初始能力是否合理？

5.1 实验设置

5.1.1 数据集描述。我们在从公开的 PTADisc 数据集中采集的五个真实数据集上开展实验，涵盖数据结构 (DS)、C、C++、Python、Java 编程语言课程。这些数据来自 PTA 平台，记录了考生在一系列课程上的学习表现。每个数据集提供考生的作答记录和题目-概念关系，每个数据集被视为一个独立领域。我们首先剔除每个数据集中作答记录少于 100 条的考生。处理后数据集的统计信息见表 1。为测试公平，我们将筛选后的考生记录按 80%:20% 随机划分为训练集和测试集。测试集中的考生被视为当前（目标）领域的冷启动考生，意味着他们在其他领域的作答记录被纳入训练集。训练集仅用于训练 DCSR 和基于学习的题目选择算法，以防止数据泄露。

表 1：数据集统计信息。

统计项	C	C++	DS	Java	Python
# 考生	3,856	3,856	3,856	3,856	3,856
# 题目	115,335	10,241	14,207	10,043	11,600
# 概念	654	472	560	541	480
# 作答日志	2,163,624	1,332,005	1,398,444	1,086,906	923,879

5.1.2 基线方法。为展示框架的有效性性与兼容性，我们将其应用于四个广泛使用的 CAT 系统，包括基于策略的 Fisher、MAAT、BECAT，以及数据驱动的 NCAT。我们选取跨领域基线进行对比，其中 Random 和 Oracle 方法分别代表 CAT 冷启动性能的下界和上界。

- **Random**: 从 $Uniform(0, 1)$ 分布中随机预测目标领域考生的初始能力，这是现有 CAT 系统中最常用的方法。
- **MLCCM**: 一种基于元学习 (meta-learning) 的跨课程方法，将元学习思想用于从训练集中学习跨领域映射函数。
- **Oracle**: 直接用 CDM 从目标领域考生（测试集）的作答记录中训练目标领域能力。

5.1.3 评价指标。DCSR 的性能将在 CAT 系统的测试阶段验证。我们通过预测考生对测试题集的二元作答来评估最终能力估计的准确性。为此，我们使用 ROC 曲线下面积 (AUC) 和准确率 (ACC) 作为评价指标。

5.1.4 参数设置。在预训练阶段，对 IRT，我们将考生和题目的隐特征维度都设为 1；对 NCD，设为对应领域的知识概念数量。此外，该阶段统一将批大小和学习率设为 32 和 0.002。在 DCSR 训练阶段，扩散模块的前向过程设为 1000 步加噪，并用 DPM-Solver 加速采样（采样在 30 步内完成）。该阶段批大小固定为 256。我们用 Xavier 初始化所有参数，并使用 Adam 优化器。在 CAT 测试阶段，题目选择算法遵循原文设置，测试长度设为 1 和 5，上述所有过程的随机种子设为 0。所有实验在一块 NVIDIA RTX4090 GPU 上进行。

5.2 整体性能 (RQ1)

为验证所提框架在解决 CSIP 挑战上的有效性，我们将 DCSR 与其他跨领域基线对比，分别用单领域和多领域作为先验知识，并将选题步数设为 1 和 5。首先，我们探索使用单个领域作为源领域，共涵盖六个跨领域场景。我们轮流让每个数据集充当目标领域，其他数据集作为源领域。表 2 的实验结果表明，所提出的 DCSR 不仅在全部六个场景中超越所有基线，还能很好地适配基于策略和基于学习的选择算法。此外，我们观察

到：(1) 相比常用的 Random 方法，DCSR 为冷启动考生提供了更准确的初始能力估计，尤其当源领域与目标领域之间存在显著相关性时（如 C 与 C++），DCSR 明显优于其他基线，并接近 Oracle 方法的性能。这证明了以考生领域共有认知作为迁移条件的有效性。(2) 相比 MLCCM，DCSR 不严重依赖监督训练，从而避免对标签过拟合。而且在大多数场景下，DCSR 在初始阶段赋予的能力，比其他方法经过多轮选择后诊断出的结果表现还要好。

表 2：六个场景下的 AUC/ACC 性能。最优结果加粗，* 表示上界 (Oracle)。(此处为原文表 2，结构复杂，按 CDM × CAT 算法 × 数据集场景交叉排布，未逐格转录，详见原文。)

接下来，我们探索使用多领域信息作为源领域，涵盖三个场景：分别以 C、C++、DS 为目标领域，其他课程作为源领域。如图 3 所示，相比单领域信息，多领域丰富了共有认知，课程之间的相关性显著有助于解决 CSIP。由于编程语言之间概念的重叠，前两个场景的性能尤为出色。

图 3：在 NCD-MAAT CAT 系统中，多领域与单领域所提供先验信息的对比。

5.3 消融实验 (RQ2)

本节深入分析 DCSR 中关键组件如何贡献于解决 CSIP 挑战。我们分别单独移除 4.2 节的认知状态统一模块 (CSUM，记为 w/o CSUM) 和 4.3 节的协调校准模块 (HCM，记为 w/o HCM)。CSUM 为扩散模块 (DM) 提供扩散引导，HCM 则约束 DM 的输出以匹配 CAT 任务。如图 4 所示，我们在 NCD-MAAT CAT 系统中验证不同组件对 DCSR 的影响，以 C 为目标领域、其他领域为源领域。具体而言，当从 DCSR 中移除 CSUM 时，性能显著下降，表明源领域的特定认知作为混淆变量，妨碍了真实因果效应，导致负迁移。类似地，移除 HCM 时也有一定程度的性能下降，说明过度的不确定性会影响生成结果与 CAT 任务的对齐。因此，所有组件都在不同程度上贡献于 DCSR。

图 4：关键组件的消融实验。

5.4 长测试步数下的性能 (RQ3)

为探索 DCSR 在贪心算法下对冷启动性能的影响，如图 5 所示，我们在 IRT-Fisher CAT 系统中延长测试长度，用单领域信息作为先验提供者，以常用的 Random 方法为基线。我们观察到，在测试早期，无论用哪个源领域，冷启动性能都显著提升。值得注意的是，当用 C++ 作为源领域时，由于课程之间的相关性，初始效果在 60 轮选题后已超越 Random 方法。这表明 DCSR 不仅缓解了选择算法陷入局部最优的问题，还通过提供准确的测试起点来引导选择算法。此外，即使用弱相关课程作为源领域，也能在更短的测试长度内达到传统 Random 方法的最优结果。

图 5：IRT-Fisher CAT 系统中延长测试流程下的结果。

5.5 认知诊断中的冷启动 (RQ4)

为探索 DCSR 在解决认知诊断任务冷启动问题上的表现，我们直接将 DCSR 应用于 CDM，包括单维的 IRT 和多维的 NCD。如图 6 所示，DCSR 在不同维度的 CDM 上都展现出更优的性能，在某些场景下接近 Oracle。而且在高维 CDM（即 NCD）上，DCSR 进一步增强了认知诊断任务的冷启动性能，显著优于常用的 Random 方法。此外，在相关性不明显的场景（如以 DS 为源领域、C++ 为目标领域）下，DCSR 表现优于 MLCCM，显著超越各类基线。

图 6：认知诊断冷启动任务上的性能。

5.6 初始化能力分析 (RQ5)

我们进一步探索 DCSR 赋予目标领域考生的能力是否合理，从两个方面分析。首先，以高维 NCD 为骨干，我们可视化不同方法在 12 个场景下赋予考生的初始能力分布。如图 7 所示，Random 方法赋予的能力分布明显呈球形，不利于区分考生能力。与 MLCCM 呈现的局部聚类相比，DCSR 更接近 Oracle 所展现的分布，呈现出清晰的区分度。这表明引入考生的跨领域共有认知能生成更个性化的初始能力。其次，我们随机选取一名考生，用 NCD 获得其诊断反馈，并随机选取十个知识概念，计算对应维度的诊断结果与 Oracle 结果之间的差异。如图 8 所示，DCSR 的波动显著更小，并且倾向于低估考生能力，而非像 MLCCM 那样高估。这种做法更好地服务于 CAT 系统，因为低估能力能引导选择算法选取相对简单的题目，避免过难题目带来的负面情绪。

图 7：目标领域能力的 T-SNE 可视化。图 8：单个考生的案例分析。

6 结论

本文提出扩散认知状态迁移框架 (DCSR)，以解决计算机自适应测试 (CAT) 中的先验不足冷启动 (CSIP) 问题。该挑战迫使 CAT 系统使用额外的选题步骤来缓解冷启动。为此，我们首先在扩散原理的引导下重建考生在目标领域的初始能力；同时，我们从基于模型的因果视角分析生成结果中的因果关系，提出三种解耦策略来阻断妨碍因果发现的两条后门路径；随后，我们从一致性和任务导向两个视角引入约束，强制生成结果与 CAT 系统对齐。因此，本框架可应用于现有主流 CAT 系统。最后，大量实验凸显了我们框架的有效性与适用性。

致谢与参考文献 (*References*) 按约定未翻译, 详见原文。