

MAMGE 精读笔记：基于元学习梯度嵌入、与模型无关的自适应测试

原文: Model-Agnostic Adaptive Testing_15.pdf (ACM TIST 2024, Haoyang Bi, Qi Liu, Enhong Chen 等, 中科大认知智能国家重点实验室 / 科大讯飞) · 代码: 论文未给出 MAMGE 专门的开源仓库; 其前作 MAAT 收录于中科大 bigdata-ustc 的 EduCAT / CAT 工具箱 (<https://github.com/bigdata-ustc/EduCAT>), 可作参照。本篇未发现 MAMGE 本身的开源代码。· 笔记于 2026-06-27

一、解决什么问题

先把 CAT 的两大件说清楚。计算机自适应测试 (CAT) = “边考边出题”的在线考试, 靠两个交替工作的模块:

- **题目选择模块 (item selection)**: 每一步挑下一道最该考的题。
- **认知状态估计模块 (cognitive state estimation)**: 拿到学生作答后, 更新对他能力 θ 的估计。

底层还需要一个**认知诊断模型 (CDM)**, 把“能力 θ + 题目特征 φ ”映射成“答对概率”, 最简单的就是 IRT: $\hat{r} = \sigma(\theta - \varphi)$ 。

痛点 (两条, 分别对应两个模块):

1. **题目选择“挑模型”**: 经典选题策略 (如 MFI 选 Fisher 信息最大的题) 都是为 IRT 这种特定 CDM 量身定做的, 换个结构不同的 CDM (尤其深度学习 CDM) 就失效, 得重新设计。→ 需要与**模型无关 (model-agnostic)** 的选题器。
2. **能力估计“不自适应”**: 现有估计器从随机初值出发、用固定步长梯度下降硬拟合当前考生那几条作答。CAT 本身很短 (就几道到十几道题), 这样做有两个毛病: (a) 在极少数数据上容易**过度自信**——第一题答对就把能力估到飞起; (b) 估计策略**不能随测试动态调整**——理想情况是前期大步快速逼近、后期小步精细微调。

作者怎么解决 (MAMGE = MAAT 的升级版):

- 前作 **MAAT** 只解决了问题 1 (用主动学习的 EMC + 知识覆盖做与模型无关的选题)。
- 本文 **MAMGE** 把两个问题**一起解决**, 而且让两个模块通过“梯度嵌入”巧妙咬合:
 - **GEIS** (选题): 把每道题用它的**梯度嵌入**表示——梯度的长度 = 信息量, 方向 = 代表性, 两阶段选出“既有用又有代表性”的题。
 - **MCSE** (估计): 用**元学习** (学会学习) 从历史考生身上学到一个好的**初始化 $\tilde{\theta}$** 和一个动态的**更新规则 $\alpha(t; \tilde{\mu})$** (同时管更新方向和步长, 还能随测试步动态变化)。
 - **咬合点**: MCSE 学到的“元学习梯度”反过来去精炼 GEIS 用的梯度嵌入, 两个模块用的是同一套梯度, 配合更好。

和已有工作比的好处: 比 MFI/KLI 灵活 (不挑 CDM); 比纯数据驱动的 BOBCAT 鲁棒 (BOBCAT 全靠数据学, 在 ECPE 这种小数据集上就拉胯); 是**启发式 + 数据驱动的混合物**, 即使元学习退化也至少能持平 MAAT。

二、问题定义 (输入 / 输出)

把“为一位考生做整场自适应测试”建模为一个元学习里的**任务 (task) $\mathcal{T}_e$** 。

符号: m 位考生 $\mathcal{E}$, n 道题 $\mathcal{J}$; 作答 $r_{ei} \in \{0, 1\}$; CDM 记 $\mathcal{M}(\theta, \varphi)$, 输出答对概率 $\hat{r}_{ei} = \mathcal{M}(\theta_e, \varphi_i) \in [0, 1]$ 。 θ_e 是考生能力 (IRT 里是 1 个标量; NN 里是高维向量), φ_i 是题目特征 (预先在历史数据上校准好、固定)。

一场测试的输入/输出 (测试阶段, 对新考生 e , 最大长度 T): - 每步 t : 题目选择模块根据当前估计 θ_e^{t-1} 选题 $i_t \rightarrow$ 考生作答 $r_{ei_t} \rightarrow$ 估计模块把 θ_e^{t-1} 更新成 θ_e^t 。- 最终输出: θ_e^T , 即对该考生能力的最终估计。

怎么算好坏: 真实能力 θ^* 拿不到, 于是用**替代任务**——拿 θ_e^T 去预测考生在一批评估题上的对错, 预测越准 (AUC/ACC 越高) 就认为 θ_e^T 越准。这个指标记 $\psi(\theta_e^T)$, 目标就是最大化它。

一个具体小例子 (IRT、ECPE 风格): 考生小红, 真实能力参考值 $\theta^* \approx 0.3$ (绿色虚线)。- $t = 0$: MCSE 不随机初始化, 而是给所有人一个元学习来的统一初值, 比如 $\theta^0 = 0.0$ (接近历史平均)。- $t = 1$: GEIS 选了一道题, 小红答对。朴素 MFI 估计器可能一下把 θ 顶到 1.5 (过拟合); MCSE 只温和地走到 0.4。- $t = 2..10$: MCSE 前期步子大、后期步子小, 曲线平滑收敛到 0.3 附近。- 输出 $\theta^{10} \approx 0.31$, 在评估题上预测 AUC 高。

三、模型结构

整体见算法 1: 先在训练考生上**元训练** MCSE (学 $\tilde{\theta}, \tilde{\mu}$); 再对每个测试考生跑 T 步“GEIS 选题 $\rightarrow$ MCSE 估计”。两个模块详解:

模块 A: GEIS (基于梯度嵌入的题目选择器)

核心 idea: 把 CAT 选题看成主动学习——题 = 无标注样本, 考生作答 = 标签, CDM = 预测模型。选哪道题最有价值? 看这道题如果被答了, 会让 CDM 的 θ 怎么变。这个“会怎么变”恰好就是**梯度**。

- 输入: 当前估计 θ_e^{t-1} 、所有未选题。
- 处理:
 1. 给每道未选题算一个**梯度嵌入** $\mathbf{g}_i$ (因为没真标签, 用 CDM 当前预测过 0.5 与否当伪标签, 公式 2)。
 2. **梯度长度** $\rightarrow$ **信息量** Info (公式 3): 长度大 = 答了它 θ 会大变 = 信息多。
 3. **梯度方向** $\rightarrow$ **代表性** Repr (公式 4): 方向和其他未选题越像 = 越能代表整个题库 = 越不“偏门”。
 4. **两阶段选** (公式 5): 先按 Info 取 top- K_C 候选, 再从候选里按 Repr 取第一。
- 输出: 下一题 i_t 。
- IRT 特例: θ 是一维标量, 梯度也是一维, 方向没意义 $\rightarrow K_C = 1$, 只用信息量。

模块 B: MCSE (元学习认知状态估计器)

核心 idea: 别只盯着当前考生那几条数据硬拟合, 而是从**海量历史考生**身上“学会怎么估计”。把每个历史考生当一个元训练任务。

- 输入: 考生到第 t 步的作答 $\mathcal{T}_e^t$ 、上一步估计 θ_e^{t-1} 。
- 处理: 用元学习的更新公式 (公式 8) 代替朴素梯度下降 (公式 6), 两处改动:
 - 初值用元学习的 $\tilde{\theta}$ (不再随机);
 - 更新量用 $\alpha(t; \tilde{\mu}) \circ \nabla \mathcal{L}$ (α 是一个会随步 t 动态变化的向量步长, 由 LSTM 吃梯度算出来, 公式 9-11)。
- 输出: 更新后的 θ_e^t 。
- 怎么训: 双层优化 (算法 2)。内层 (局部更新): 用 $\tilde{\theta}, \tilde{\mu}$ 在支持集上模拟跑完一场测试得到各步 θ_e^t ; 外层 (全局更新): 在查询集 (该考生全部作答) 上算损失, 对 $\tilde{\theta}, \tilde{\mu}$ 求梯度更新。

咬合: 元学习梯度把 A、B 连起来

MCSE 学到的 $\alpha(t; \tilde{\mu})$ 反过来塞进 GEIS 的梯度嵌入 (公式 14)。这样 GEIS 衡量“题目价值”用的梯度, 正好就是 MCSE 实际更新 θ 用的梯度——一致, 不再错配。

四、关键公式详解

公式 1: IRT (抽象 CDM 的最简实例)

$$\hat{r}_{ei} = \mathcal{M}(\theta_e, \varphi_i) = \sigma(\theta_e - \varphi_i)$$

- 符号: θ_e 考生能力 (标量), φ_i 题目难度 (标量), σ sigmoid。- 举例: $\theta = 0.5, \varphi = 0.2 \rightarrow \sigma(0.3) = 0.574$, 预测答对概率 57.4%。难度若升到 $\varphi = 1.5 \rightarrow \sigma(-1.0) = 0.27$, 答对概率掉到 27%。- 作用: 全文把 CDM 抽象成 $\mathcal{M}(\theta, \varphi)$, IRT 只是最简单的填法; 方法对任何可微 CDM 都成立, 这就是“与模型无关”。

公式 2 & 14: 梯度嵌入 (GEIS 的基石)

$$\mathbf{g}_{ei}^t = \nabla_{\theta} l(\mathcal{M}(\theta_e^{t-1}, \varphi_i), \mathbb{I}(\mathcal{M}(\theta_e^{t-1}, \varphi_i) > 0.5)) \quad (2); \quad \mathbf{g}_{ei}^t = \alpha(t; \tilde{\mu}) \circ \nabla_{\theta} \hat{\mathcal{L}}_i(\theta_e^{t-1}) \quad (14)$$

- 符号: l 是二元交叉熵; $\mathbb{I}(\cdot)$ 把当前预测二值化当**伪标签** (因为真标签——考生还没答——拿不到); ∇_{θ} 对能力参数求导。公式 14 在 2 的基础上左乘元学习步长 $\alpha(t; \tilde{\mu})$ 。- 举例 (IRT): $\theta^{t-1} = 0.5$, 某题 $\varphi = 0.2$, 预测 $\hat{r} = 0.574 > 0.5 \rightarrow$ 伪标签 = 1。BCE 对 θ 的梯度 $= \hat{r} - y = 0.574 - 1 = -0.426$ 。所以 $\mathbf{g}_i = -0.426$, 长度 0.426。另一道题预测 $\hat{r} = 0.95$ (很笃定) $\rightarrow$ 伪标签 1, 梯度 $= 0.95 - 1 = -0.05$, 长度仅 0.05 (答它几乎不改变 θ , 没信息量)。- 作用: 用一个“如果答了它, 模型会动多少/往哪动”的向量统一刻画每道题的价值。是 GEIS 选题、并与 MCSE 咬合的载体。

公式 3: 信息量启发式

$$\text{Info}(i) = \|\mathbf{g}_i\|$$

- 举例: 上面两道题, Info=0.426 vs 0.05 $\rightarrow$ 选第一道 (模型对它更“没把握”, 答了收获大)。- 作用: 选题第一优先级——挑能最大改变能力估计的题, 对应主动学习里的“不确定性/模型影响”。

公式 4: 代表性启发式

$$\text{Repr}(i; \mathcal{J}_U) = \frac{1}{|\mathcal{J}_U|} \sum_{j \in \mathcal{J}_U} \frac{\mathbf{g}_i \cdot \mathbf{g}_j}{\|\mathbf{g}_i\| \|\mathbf{g}_j\|}$$

- 符号: 就是题 i 的梯度方向与所有未选题梯度方向的平均余弦相似度。- 举例 (高维 NN): 题 i 梯度方向跟题库主流方向都挺像 $\rightarrow$ 平均余弦 0.6; 某偏门题 k 方向很独特 $\rightarrow$ 平均余弦 0.1。选 i 更稳 (它“代表”了一批相似题), 避开 k (分布外、偏题)。- 作用: 正则化, 防止只顾信息量而选出怪题/离群题, 让测试更鲁棒全面。

公式 5: 两阶段选题

$$i_t = \arg \max_{j \in \mathcal{J}_C} \text{Repr}(j; \mathcal{J}_U^{t-1}), \quad s.t. \mathcal{J}_C = \arg \max_{A \subset \mathcal{J}_U^{t-1}, |A| \leq K_C} \sum_{i \in A} \text{Info}(i)$$

- 举例: $K_C = 5$, 先按 Info 取前 5 道候选, 再从这 5 道里挑 Repr 最大的那道作为 i_t 。- 作用: 先信息量、后代表性, 分两步。比加权 and 更省算力 (只对 5 道算 Repr)、超参 K_C 更好调。

公式 6 vs 8: 朴素估计器 vs 元学习估计器 (MCSE 的核心对比)

$$\text{朴素: } \theta_e^0 \sim p(\theta), \quad \theta_e^t = \theta_e^{t-1} - \alpha \nabla \mathcal{L}_{\mathcal{T}_e^t}(\theta_e^{t-1}) \quad (6)$$

$$\text{MCSE: } \theta_e^0 = \tilde{\theta}, \quad \theta_e^t = \theta_e^{t-1} - \alpha(t; \tilde{\mu}) \circ \nabla \mathcal{L}_{\mathcal{T}_e^t}(\theta_e^{t-1}) \quad (8)$$

- 符号: $\circ$ 逐元素乘; $\tilde{\theta}, \tilde{\mu}$ 是元学习出来的参数 (带波浪号)。- 举例 (IRT, 第一题答对): 梯度 $\nabla \mathcal{L} = \hat{r} - 1 < 0$ 。朴素用固定 $\alpha = 1.0$ 可能把 θ 从随机的 -2.0 一下推到 +0.5 (既受烂初值拖累又过冲); MCSE 从 $\tilde{\theta} = 0.0$ 出发, $\alpha(1; \tilde{\mu})$ 这一步给个温和的 0.3, θ 走到 $0.3 \cdot$ (正方向) ≈ 0.13 , 稳。- 作用: 把“初始化、方向、步长”三件事全交给从历史数据学到的元参数, 且步长能随测试步变化。这是 MCSE 区别于所有现成估计器的关键。

公式 9-11: 动态步长 $\alpha(t; \tilde{\mu})$ (用 LSTM 实现)

$$\alpha(t; \tilde{\mu}) = \text{ReLU}(\alpha_{base} + \gamma \alpha_{dyna}^t), \quad \alpha_{dyna}^t = \tanh(W h_t), \quad [h_t, c_t] = \text{LSTM}(\nabla \mathcal{L}_{\mathcal{T}_e^t}, h_{t-1}, c_{t-1}; \Psi)$$

- 符号: α_{base} 全程不变的基础步长; α_{dyna}^t 随步动态变化的部分; LSTM 吃“每步梯度”产出隐状态 h_t ; γ 平衡两部分 (论文取 1); ReLU 保证步长非负。元参数 $\tilde{\mu} = \{\alpha_{base}, W, \Psi\}$ 。- 举例: $t = 1$ 时不确定性高, LSTM 看到大范数梯度 $\rightarrow \alpha_{dyna}^1$ 给较大值 $\rightarrow$ 总步长大、快逼近; $t = 8$ 时梯度小、信息趋稳 $\rightarrow \alpha_{dyna}^8$ 变小 $\rightarrow$ 步长小、精细微调。案例研究里图 7 红线/图 8 圆圈半径变小都印证了这一点。- 作用: 让估计策略“前期激进、后期保守”自动涌现, 而不用手调学习率衰减。

公式 12-13: 元优化目标 (双层)

$$\min_{\tilde{\theta}, \tilde{\mu}} \mathbb{E}_{\mathcal{T}_e \sim p(\mathcal{T})} \left[\sum_{t=1}^T \mathcal{L}_{\text{qry}(\mathcal{T}_e)}(\theta_e^t) \right], \quad \theta_e^t = \theta_e^{t-1} - \alpha(t; \tilde{\mu}) \circ \nabla \mathcal{L}_{\text{spt}(\mathcal{T}_e)^t}(\theta_e^{t-1})$$

- 符号: 内层用支持集 spt (模拟一场测试选出的题) 更新 θ ; 外层在查询集 qry (该考生全部作答) 上评估并对元参数求梯度。把各步损失求和 $\rightarrow$ 不只让最后一步准, 而是整场都准。- 举例: 拿一个历史考生, spt 取他 10 步的作答, 内层跑出 $\theta^1 \dots \theta^{10}$; qry 用他对题库全部题的真实作答, 算这 10 个 θ 的预测损失之和, 反传去更新 $\tilde{\theta}, \tilde{\mu}$ 。一个 batch 的考生平均一下做全局更新 (算法 2)。- 作用: 这就是“学会学习”——在历史考生上训练出通用的初始化 + 更新规则, 使新考生用极少几步就能估准。

五、代码实现对照

论文未发布 MAMGE 的官方代码。未发现 MAMGE 本身的开源代码。仅其前作 MAAT 收录在中科大 bigdata-ustc 的 EduCAT (<https://github.com/bigdata-ustc/EduCAT>, 又名 CAT 工具库) 中, 里面有 IRT/NCD 等 CDM、MFI/KLI/MAAT/BOBCAT 等选择算法的实现, 可作为复现 MAMGE 的手脚架参照:

论文部件/公式	在 EduCAT 中可参照的对应物 (非 MAMGE 原实现)
抽象 CDM $\mathcal{M}(\theta, \varphi)$ (公式 1)	CAT/model/ (IRT、NCD 等 CDM 实现)
MFI / KLI / MAAT / BOBCAT 基线	CAT/strategy/ (各选择策略)
GEIS 信息量 = 梯度长度 (公式 2-3)	可在 MAAT 的 EMC (期望模型变化) 思路上改造

论文部件/公式	在 EduCAT 中可参照的对应物 (非 MAMGE 原实现)
MCSE 元学习更新 (公式 8-11)	EduCAT 无现成实现, 需按算法 2 自行实现 LSTM 元学习器

若要完整复现 MAMGE, 需自行实现: 梯度嵌入计算 (autograd 对 θ 求导)、两阶段选题、以及双层元优化的 MCSE (含 LSTM 动态步长)。

六、小结

实验结论 (四数据集 ASSIST/Junyi/EXAM/ECPE $\times$ 两 CDM IRT/NN): - **总体**: MAMGE 在 AUC/ACC 上全面、显著超过 RANDOM、MFI、KLI、US、BOBCAT、MAAT。- **在 NN 上提升尤其大** (如 EXAM ACC 77.7% $\rightarrow$ 81.15%, ECPE 77.97% $\rightarrow$ 81.90%): 因为复杂 CDM 的能力是高维的, MCSE 的元学习估计 + GEIS 的方向代表性才有用武之地; IRT 一维, MCSE 帮助有限、GEIS 只剩信息量。- **比 BOBCAT 鲁棒**: BOBCAT 纯数据驱动, 在小数据 ECPE 上崩; MAMGE 是启发式 + 数据驱动混合, 更稳、更好调。- **消融**: 去掉 MCSE / Init / Dyna / GEIS / Info / Repr / 两阶段 任一部分都掉点。其中 Info 是选题核心 (去掉比随机还差), Init 对复杂 CDM 至关重要 (去掉甚至不如朴素估计器), Dyna 验证动态步长有效。- **测试长度**: 可以用与实测不同的长度元训练; Length-5 综合最好; 元训练越短 $\rightarrow$ 初期越好, 越长 $\rightarrow$ 适应越快、长程越好。- **案例**: 图 7 显示 MCSE 统一初始化 + 抗过拟合 + 前大步后小步; 图 8 显示 GEIS 不总选信息量最大的, 会用代表性避开离群题。

优点: (1) 真正与模型无关 (只要 CDM 对 θ 可微); (2) 第一个同时管选题 + 估计、并用梯度嵌入把两者咬合; (3) 启发式与数据驱动的混合, 鲁棒; (4) 把元学习的“初始化 + 方向 + 步长”全套用进 CAT 估计, 动态步长可解释。

局限: (1) IRT 这类简单一维 CDM 上 MCSE 收益有限; (2) 双层元优化训练成本和实现复杂度较高; (3) 论文未开源, 复现门槛高; (4) 作者自陈未来需进一步关注可扩展性与可解释性。