

面向智能教育系统、基于元学习梯度嵌入的与模型无关的自适应测试 (Model-Agnostic Adaptive Testing for Intelligent Education Systems via Meta-learned Gradient Embeddings)

原文: Model-Agnostic Adaptive Testing_15.pdf (ACM TIST, Vol. 15, No. 5, Article 95, 2024) ·译者: Claude ·译于 2026-06-27 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT); 认知诊断模型 (Cognitive Diagnosis Model, CDM); 项目反应理论 (Item Response Theory, IRT); 元学习 (meta-learning); 主动学习 (active learning); 题目选择 (item selection); 认知状态估计 (cognitive state estimation); 梯度嵌入 (gradient embedding); 信息量 (informativeness); 代表性 (representativeness)

摘要

随着智能系统与技术的出现,教育领域经历了一场重大变革,它们旨在个性化学习体验,满足每个学习者独特的需求与能力。在这一追求中,一个根本性的挑战是:设计恰当的测试,以准确、高效地评估学生在知识与技能上的认知状态。一种有前景的途径是**计算机自适应测试 (CAT)**,即由计算机自动施测、交替地为每位考生选择下一道题目,并根据其对所选题目的作答来估计其认知状态。然而,现有的 CAT 系统分别在题目选择上**缺乏灵活性**、在认知状态估计上**缺乏有效性**。

本文提出一种基于元学习梯度嵌入 (**Meta-learned Gradient Embeddings**) 的与模型无关 (**Model-Agnostic**) 的自适应测试框架,简称 **MAMGE**,同时改进题目选择与认知状态估计两方面。对于题目选择,我们设计了**基于梯度嵌入的题目选择器 (Gradient Embedding-based Item Selector, GEIS)**,引入梯度嵌入的概念来表示题目,并选出既有信息量又有代表性的最佳题目。对于认知状态估计,我们提出**元学习认知状态估计器 (Meta-learned Cognitive State Estimator, MCSE)**,通过“学会学习”来自动控制估计过程——学到一个合适的初始化和动态推断的更新。MCSE 与 GEIS 本质上都是与模型无关的,并且这两个模块通过元学习梯度嵌入有一种巧妙的连接。最后,大量实验评估了 MAMGE 的有效性 & 灵活性。

CCS 概念: 应用计算 → 在线学习、交互式学习环境; 计算方法 → 主动学习设定。

关键词: 自适应测试、智能辅导系统、主动学习、元学习。

1 引言

随着智能系统与技术的出现,教育领域经历了一场重大变革,它们旨在个性化学习体验,满足每个学习者独特的需求与能力。在这一追求中,一个根本性的挑战是准确、高效地评估学生在知识与技能上的认知状态。如图 1(a) 所示,传统的纸笔考试往往难以刻画学习者多样且不断演变的能力。具体而言,给所有考生提供相同的、非个性化的测试环境,难以保证所有所选题目的合理性与有效性。例如,如果整套题目的总体难度偏低,能力较强的考生会表现得相近,以致我们无法精确区分他们的状态。

鉴于这些考量,**计算机自适应测试 (CAT)** 已成为智能教育系统领域一种强有力的途径。如图 1(b) 所示, CAT 利用智能算法的能力,根据每位考生的作答与表现动态地裁定呈现给他们的测试题目。通过自适应地选择难度合适的题目, CAT 提供个性化且高效的评估体验,从而能更准确地估计学习者的水平。此外, CAT 还带来许多好处,包括缩短测试长度、提升考生参与度等,因而在标准化考试机构中有广泛应用,例如研究生管理科入学考试 (GMAT) 和研究生入学考试 (GRE)。

CAT 通常基于一个**认知诊断模型 (CDM)** 来从考生的作答中估计其认知状态。如图 1(b) 所示,一个 CAT 系统一般由两个在测试中交替工作的主要部件组成: (1) **题目选择模块**,在每个测试步从题库中推荐合适的题目; (2) **认知状态估计模块**,根据考生的作答更新其认知状态。这一过程持续进行,直到满足某个终止准则 (例如达到最大测试长度)。最终估计出的认知状态反映了考生对所需知识或技能 (例如数学中的“函数”) 的掌握程度,可支持进一步的分析,如用户画像和知识追踪。因此,根本性挑战在于:建立一个有效的 CAT 系统,为考生恰当地选择题目并准确地估计认知状态。

在 CAT 领域,大量研究集中在题目选择模块上,并依据底层 CDM 参数的解释开发了许多专门的 (ad hoc) 策略。例如,单参数 logistic 的项目反应理论 (IRT) 模型分别用一个标量参数表示考生能力和题目难度。基于这种参数化,一种流行的题目选择策略是选择难度最接近考生当前估计能力的题目。根据更新后的作答数据,考生的认知状态通过与 CDM 发展相绑定的参数优化方法 (例如极大似然估计) 来估计,而这一点在 CAT 领域较少被探索。

尽管近年来取得了重大进展, CAT 系统的有效性与灵活性仍受到一些主要挑战的限制,我们从两个方面来总结。**第一,现有的题目选择策略大多与特定模型绑定 (model-specific),导致 CAT 系统不灵活。**也就是说,它们深度绑定于底层认知诊断模型的细节,因而无法适用于其他模型。以上述难度匹配策略为例,如果底层 CDM 的结构以及参数含义与 IRT 模型不同,该方法就会失效;我们不得不为不同的 CDM 寻找专门设计的策略。更何况,如今基于各种先进技术的复杂模型层出不穷,为它们定制题目选择策略并不容易。因此,理想的 CAT 框架应当是与**模型无关的**,即 CAT 方案能适应不同的 CDM 同时保持有效。**第二,现有的认知状态估计器缺乏快速适应能力,限制了 CAT 的有效性。**一般而言,当前采用的估计器从随机初始化开始,然后通过优化方法 (例如每步梯度下降) 获得认知状态估计,僵硬地依赖当前考生的作答。这种不自适应的估计器有两个缺点。其一,仅在少量数据上拟合认知状态参数 (注意自适应测试通常很短) 容易导致过度自信和有偏的估计。例如,当考生在第一个测试步只有一次正确 (或错误) 作答时,理想的估计器应当把能力估计调整到一个合理偏高 (或偏低) 的水平,而不是一个极端值。其二,估计策略不能随测试进

行而动态调整,进一步限制了自适应测试的有效性。例如,在初始阶段为快速适应而激进地做粗略估计是合理的,而随着测试推进则应逐渐保守地做细致的更新以进行微调。图 1(b) 对比展示了两个玩具示例。在上面的例子中,估计器因考生第一次答对而严重高估,于是在后续交互中提供极难的题目,导致估计准确率 (ACC) 和考生体验都很差。在下面的例子中,理想的估计器以一个合适的估计开始,并平滑地调整到一个精细的结果。

在我们的前期工作中,我们用所提出的与模型无关的自适应测试 (MAAT) 框架解决了第一个挑战。通过引入主动学习的思想,我们基于期望模型变化 (Expected Model Change, EMC) 设计了一种新颖的题目选择启发式。具体来说,一道有较大期望梯度的题目被认为是具有信息量的,因为这意味着一旦知道考生对这题目的作答,底层 CDM 的认知状态估计可能发生较大变化。此外,为防止 CAT 选出分布外 (out-of-distribution) 的题目,我们为每道题目关联一个重要性加权知识覆盖 (Importance Weighted Knowledge Coverage, IWKC), 表示它对整个题库的代表程度。把 EMC 与 IWKC 结合起来, MAAT 选出既有信息量又有代表性的下一道题。注意上述过程隐藏了底层 CDM 的细节,因而是与模型无关的。

在本文中,我们进一步扩展前期工作,提出一个面向智能教育系统、基于元学习梯度嵌入的 MAAT 框架,简称 MAMGE,它在题目选择与认知状态估计两方面都有效且灵活。为解决题目选择中与特定模型绑定的问题,我们沿着 MAAT 的思路设计了基于梯度嵌入的题目选择器 (GEIS)。具体来说,我们用一个可在任意可微 CDM 上高效计算的梯度嵌入来表示每道题目;然后,我们分别用梯度嵌入的长度和方向来量化每道题目的信息量和代表性,并自然地设计一对与模型无关的题目选择启发式。为实现认知状态估计的快速适应能力,受元学习思想启发,我们提出元学习认知状态估计器 (MCSE),以数据驱动的方式智能地学习如何更好地估计。本质上,MCSE 借助来自历史考生的元经验,自动决定认知状态估计过程的所有要素 (包括初始化、更新方向和步长);而且,这些要素会随当前考生的测试过程动态推断。最后,通过用元学习得到的梯度来精炼 GEIS 中原本使用的梯度嵌入,我们表明认知状态估计模块 MCSE 与题目选择模块 GEIS 可以很好地连接起来,进一步提升 CAT 系统的有效性。

综上,通过把对 CAT 系统的考量从仅有题目选择策略扩展到完整的“选择—估计”过程,我们用所提出的框架 MAMGE (含一个 GEIS 和一个 MCSE) 进一步解决了实现有效的、与模型无关的 CAT 系统这一挑战。最后,我们在四个真实数据集、两个基础 CDM 上进行了大量评估,表明 MAMGE 超过了竞争基线,揭示了其有效性与灵活性。

本文余下部分组织如下。第 2 节介绍相关研究领域以及与本文相关的前期工作。第 3 节正式定义所研究的自适应测试问题。第 4 节介绍所提出的 MAMGE 框架的设计,先给出总览 (4.1 节),然后深入两个具体模块——GEIS (4.2 节) 和 MCSE (4.3 节) 的细节,最后对方法论给出讨论 (4.4 节)。第 5 节展示框架的实验分析。最后,第 6 节总结本文工作并展望未来工作。

图 1: (a) 两位考生的传统纸笔考试。(b) 由交替的题目选择和认知状态估计组成的计算机自适应测试。两位考生分别由一个朴素的不自适应估计器 (上) 和一个理想的恰当估计器 (下) 来评估。

2 背景与相关工作

2.1 自适应测试

由于在效率和准确率 (ACC) 上的出色表现,自适应测试已被公认为一种日益重要的评估方式。以往研究者主要聚焦于为不同的 CDM 设计专门的题目选择策略,其中具有代表性的是 IRT 模型。Lord 等人提出选择具有最大 Fisher 题目信息 (Maximum Fisher Item Information) 的题目,这是几十年来最流行的算法;Chang 等人则利用全局的 Kullback-Leibler 指数 (KLI) 而非逐点信息来提升鲁棒性。这些方法后来被扩展到多维 IRT (MIRT)。对于其他类型的 CDM,也开发了专门的策略。然而,这些与特定模型绑定的策略缺乏灵活性,难以扩展到新的 CDM,尤其是近来流行的深度学习模型。因此,一些研究者转而寻求与模型无关的自适应测试框架。从主动学习的视角看待该问题,Bi 等人提出了一种普遍适用的题目选择启发式。另一条路线是直接学习策略:Nurakhmetov 等人应用强化学习来训练一个智能体;Ghosh 等人尝试用双层优化来获得最优策略。相比之下,基于启发式的方法忽略了数据中的丰富信息,而数据驱动的方法难以训练,且容易受到偏差和数据稀缺的影响。尽管在选择恰当题目方面取得了很大进展,以往研究却很少关注 CAT 的认知状态估计部分。一旦收到考生的作答,现有 CAT 系统就用典型的优化方法 (如梯度下降) 来最小化损失函数 (如交叉熵损失)。然而,由于 CAT 固有的短长度,这种直白的估计容易过拟合。Ghosh 等人通过一种最先进的端到端 CAT 方案——基于双层优化的 CAT (BOBCAT) 缓解了一问题,它通过一种新颖的双层优化框架为认知状态参数产生一个合适的初始化。然而,BOBCAT 仍缺乏对恰当的参数更新策略的考量,无法实现快速适应能力并避免测试期间的过拟合。此外,还有近期工作处理 CAT 问题上的其他主题,如鲁棒性和搜索效率,这与我们的工作正交。

2.2 主动学习

主动学习是一种机器学习范式,旨在通过选择最少的有标注样本来最大化模型性能,已被很好地用于智能系统的发展。一般来说,主动学习中样本选择有两个主要视角,即信息量 (informativeness) 和代表性 (representativeness)。从样本信息量的视角看,建议选择那些对当前模型不确定的样本。不同的不确定性度量带来多种基于信息量的采样方法,如基于决策边界的方法和贝叶斯方法。信息量也可以用模型影响来度量,这与我们的工作更相关——在这类方法中,如果样本对模型参数有很大影响,就被认为是不确定的。这种影响可以通过影响函数或期望梯度长度来分析。从另一个视角看,与其关注每个样本中的信息,我们可以选择能很好代表整体样本分布的样本。直觉上,在少数代表性样本上训练可以近似在底层分布更多样本上训练的效果,也能阻止模型受到分布外样本的影响。常用的代表性度量包括数据的几何结构、邻居之间的关系等。例如,Sener 等人用核心集 (core-set) 寻找数据的全局代表,而 Yang 等人把代表性最大化表述为一个集合覆盖问题。由于这两个视角提供了不同种类的启发式,自然要同时考虑信息量和代表性。此外,还有一些数据驱动的方法可以从数据中自动学习启发式。在我们的前期工作中,我们在自适应测试与主动学习之

间建立了对应关系，设计了一种纯基于启发式的题目选择策略。然而，本文中我们扩展到一种同时利用元学习数据信息的混合方法，将在 4.4 节详细讨论。

2.3 元学习

元学习，也称“学会学习 (learning-to-learn)”，研究机器学习方法在各种学习任务上表现的差异，以及如何通过从这种元经验中学习来更快地学习新任务。根据编码元知识的方式，以往工作可分为三类：基于模型的、基于度量的和基于优化的。基于模型的元学习直接用一个黑箱元网络通过记忆增强架构来存储元知识并控制基学习器，但训练难度很大。基于度量的元学习把元知识嵌入到对象的度量空间中，使分类任务更高效，但应用场景相对有限。基于优化的元学习把元知识注入基学习器的优化算法中，以实现对少量样本的快速适应，由于梯度反向传播优化如今占主导地位，因此特别聚焦于此。最流行的方法是与模型无关的元学习框架 (MAML) 及其变体，它们通过元梯度下降为模型学习一个好的参数初始化。此外，近期研究揭示并探索了除初始化之外其他优化组件 (如学习率) 的重要性。我们所提出框架中的认知状态估计模块属于基于优化的类别。我们把为每位考生进行自适应测试视为一个独立的任务，并设计一个 MCSE，通过控制初始化、更新方向和步长的全部要素，来对新考生快速适应。

3 预备知识与问题定义

本节介绍必要的术语和定义。我们首先以一种抽象形式定义 CDM，以捕捉大多数 CDM 的共同特征，使我们的讨论本质上与模型无关。然后，我们基于抽象的 CDM 介绍一般的自适应测试系统，包括它由哪些部件组成、如何为考生施测。最后，我们正式定义本文研究的问题。

假设设有 m 位考生 $\mathcal{E} = \{1, \dots, m\}$ 和 n 道题目 $\mathcal{J} = \{1, \dots, n\}$ 。我们把考生 e 作答题目 i 的结果记为 $r_{ei} \in \{1, 0\}$ (即对或错)。一个 CDM $\mathcal{M}$ 被定义为一个参数化函数 $\mathcal{M}(\theta, \varphi; \omega)$ ，其中 θ 表示考生的认知状态 (如能力水平)， φ 表示题目特征 (如难度水平)， $\mathcal{M}(\cdot, \cdot; \omega)$ 是一个带有可能训练参数 ω (如神经网络) 的连接函数 (link function)。为简便起见，本文余下部分省略连接函数的参数，把 CDM 记为 $\mathcal{M}(\theta, \varphi)$ 。给定考生 $e \in \mathcal{E}$ 和题目 $i \in \mathcal{J}$ ，我们可以预测作答 $\hat{r}_{ei} = \mathcal{M}(\theta_e, \varphi_i)$ ， $\hat{r}_{ei} \in [0, 1]$ 。例如，最常用的 CDM——IRT，其最简单形式如下：

$$\hat{r}_{ei} = \mathcal{M}(\theta_e, \varphi_i) = \sigma(\theta_e - \varphi_i), \quad (1)$$

其中 $\theta_e \in \mathbb{R}$ 和 $\varphi_i \in \mathbb{R}$ 分别是表示考生能力水平和题目难度的标量认知状态参数， $\sigma(\cdot)$ 是 sigmoid 函数。通常，题目特征 φ_i ($i \in \mathcal{J}$) 和参数 ω 从海量历史数据中学得，然后对未来的新考生固定不变。

给定基础 CDM $\mathcal{M}(\theta, \varphi)$ ，一个自适应测试系统由两个基本模块组成：题目选择模块和认知状态估计模块。对于考生 $e \in \mathcal{E}$ ，这两个模块以迭代方式交替工作来进行自适应测试，每一步包含以下两部分：(1) **选择**：题目选择模块根据为考生估计的认知状态 θ_e^{t-1} 选出一道个性化题目 i_t ，然后从考生处获得作答 r_{ei_t} ；(2) **估计**：认知状态估计模块根据考生的作答 r_{ei_t} 把 θ_e^{t-1} 更新为 θ_e^t 。最终的认知状态估计 θ_e^T 作为测试结果输出。

算法 1: MAMGE (结构性伪代码，详见原文)。输入：CDM $\mathcal{M}(\theta, \varphi)$ ；考生集 $\mathcal{E} = \mathcal{E}_{train} \cup \mathcal{E}_{test}$ ；题目集 $\mathcal{J}$ ；测试长度 T 。输出：最终认知状态估计 θ_e^T 。先在 $\mathcal{E}_{train}$ 上对 MCSE 做元优化；然后对每个测试考生 e ，初始化 θ_e^0 、置已选/未选集合 $\mathcal{J}_S^0 = \emptyset, \mathcal{J}_U^0 = \mathcal{J}$ ，对 $t = 1, \dots, T$ ：用 GEIS 选题 i_t 、用 MCSE 更新 $\theta_e^{t-1} \rightarrow \theta_e^t$ 、更新已选/未选集合。

实践中，考生可分为 $\mathcal{E} = \mathcal{E}_{train} \cup \mathcal{E}_{test}$ 。 $\mathcal{E}_{train}$ 表示有作答记录的历史考生，用来训练基础 CDM (即校准题目特征和连接函数参数) 以及 (如有需要) 自适应测试系统。 $\mathcal{E}_{test}$ 表示那些被假定完全未知的新考生。基本上，本研究的目标是尽可能准确地估计认知状态。因此，对于考生 $e \in \mathcal{E}$ ，有必要定量评估输出 θ_e^T 有多准确。由于实际中无法获得 θ_e 的真值，我们寻求一个替代任务来评估 θ_e^T 。具体来说，我们基于 θ_e^T 预测考生未来的作答 (例如在一个验证题目集上)，并假设预测越准确， θ_e^T 也越准确。这样，我们就能利用预测任务的典型评估协议，如 AUC (5.1.1 节)。一般地，我们把这种协议称为**测试有效性 (testing effectiveness)**，记为 $\psi(\theta_e^T)$ 。因此，我们研究的自适应测试问题可形式化如下。

问题定义。给定一个基础 CDM $\mathcal{M}(\theta, \varphi)$ 和来自历史考生 $\mathcal{E}_{train}$ 的训练数据，我们的目标是实现一个有效的自适应测试系统，使得对于新考生 $e \in \mathcal{E}_{test}$ ，测试有效性 $\psi(\theta_e^T)$ 最大化。

4 MAMGE

4.1 框架总览

为实现一个有效的自适应测试系统，我们提出一个基于元学习梯度嵌入的 MAAT 框架，简称 MAMGE。如算法 1 所总结，对于任意考生 e ，在每个测试步 $t = 1, \dots, T$ ，底层 CDM 有一个来自上一步的临时认知状态估计 θ_e^{t-1} 。基于该估计，题目选择模块 GEIS 通过把候选题目与所谓的梯度嵌入相关联、并用精心设计的启发式对它们的优先级排序，为考生选出下一道题 i_t 。然后，考生收到题目 i_t 并给出作答 r_{ei_t} 。根据该作答，认知状态估计模块 MCSE 通过一种基于元学习的方法自动地把 θ_e^{t-1} 更新为 θ_e^t 。图 2 展示了整体流程图。本节余下部分将分别更详细地介绍这两个模块。

图 2: MAMGE 总览。考生的自适应测试工作流由题目选择和认知状态估计组成，分别由所提出的 GEIS 和 MCSE 承担。

4.2 GEIS (基于梯度嵌入的题目选择器)

在 CAT 系统中, 题目选择模块旨在为当前考生选出一道个性化题目, 以便在下一步更好地估计其认知状态。尽管已经提出了各种选择策略, 但其内在问题在于缺乏与模型无关的性质。为了让题目选择器对不同的 CDM 灵活、而非只为特定 CDM 定制, 我们借鉴主动学习的思想。具体来说, 我们把每道题目视为一个数据样本, 考生对它的作答对应于标签 (对或错); 类似地, CDM 扮演预测模型的角色。从这个视角看, CAT 中的题目选择可以转化为一个标准的主动学习问题, 其关键在于量化无标注样本的价值以最大化模型性能。有两个方面值得考虑。一方面, 每道题目的信息量是最重要的考量, 它确保所选题目的效用, 即为 CDM 提供关于考生认知状态的足够信息。另一方面, 每道题目相对于整个题库的代表性也应被考虑, 它确保测试是鲁棒和全面的。沿着这一思路, 我们提出一种新颖的 GEIS。如图 3 所示, 我们首先引入**梯度嵌入**的概念, 以统一的方式度量与每道题目相关的上述两种价值。然后, 我们基于一对精心设计的启发式来选出最佳题目。

4.2.1 梯度的力量 为度量一道题目的价值, 我们考虑它如何影响 CDM。本质上, 一旦获得考生对某题的作答, CDM 就会更新其认知状态估计, 通常是计算关于损失函数的梯度然后进行基于梯度的优化。从这个意义上说, 梯度可以被认作题目“测试相关特征”的一种表示。具体来说, 我们主张: **梯度的长度和方向分别传达了每道题目的信息量和代表性信息。**

一般地, 梯度的长度意味着: 如果知道考生对该题的作答, CDM 会把其认知状态估计 (即 θ) 更新多少。梯度长度大, θ 很可能发生很大变化, 因此该题传达了关于考生认知状态的相当多信息。反之, 梯度长度小, 该题对 θ 几乎没有影响, 就好像考生没答这道题一样, 难以帮助 CDM 更好地诊断考生。总之, 如果一道题对 CDM 有很大影响, 我们就认为它有信息量, 其信息量可由梯度长度表示。

图 3: GEIS 示意图。在自适应测试的每一步, 题库中的每道题都用一个梯度嵌入表示; 然后用这些嵌入计算两类量化题目价值的启发式; 最后根据启发式确定最终选择。

除长度外, 梯度的方向也捕捉了题目如何影响 CDM 估计的信息。对于认知状态用多维表示的 CDM, 不同维度通常有不同的内在效应。例如, MIRT 假设每个维度是考生在某个特定知识概念 (如几何、代数) 上的能力水平; 深度学习模型则从数据中学习复杂的融合特征。相应地, 如果两道题的梯度嵌入方向相似, 就认为它们对认知状态估计有相似的效应, 反之亦然。推而广之, 所有题目的梯度方向可以传达关于整个题库底层分布的信息。我们利用这种信息来优化所选题目的代表性, 即选择梯度方向与底层分布更相似的题目。一方面, 一道有代表性的题目对测试贡献更大, 因为从某种意义上说, 作答这道题等同于作答更多相似的题; 另一方面, 我们可以避免选出分布外的题目, 使测试更鲁棒。

因此, 一道题目的梯度可被用来在题目选择中度量其价值。然而, 实践中难以获得未选题目上的作答数据。于是, 我们用 CDM 对该题的当前预测作为**伪标签 (proxy labels)**来计算梯度。这样, 我们就能把每道未选题目与一个反映特定测试相关特征 (即信息量和代表性) 的梯度相关联, 因此把它称为**梯度嵌入**。

4.2.2 基于梯度嵌入的启发式 基于上述梯度嵌入的概念, 我们引入两类用于题目选择的启发式, 它们分别通过梯度长度和梯度方向考虑信息量和代表性。此刻, 我们正式记测试考生 $e \in \mathcal{E}$ 时题目 $i \in \mathcal{J}$ 在第 t 步的梯度嵌入为:

$$\mathbf{g}_{ei}^t = \nabla_{\theta} l(\mathcal{M}(\theta_e^{t-1}, \varphi_i), \mathbb{I}(\mathcal{M}(\theta_e^{t-1}, \varphi_i) > 0.5)), \quad (2)$$

这是一个关于损失函数 $l(\cdot, \cdot)$ (如二元交叉熵损失) 的伪梯度, 该损失用预测作答 $\mathcal{M}(\theta_e^t, \varphi_i; \omega)$ 和由指示函数 $\mathbb{I}(\cdot)$ 给出的伪标签计算。为简便起见, 在无歧义时我们省略上标 t (表示步) 和 e (表示考生), 用 $\mathbf{g}_i$ 表示题目 i 的梯度嵌入。在介绍 MCSE 模块后, 我们会用元学习的梯度精炼 g_i 的表述 (4.3.3 节), 而题目选择模块的其他部分保持不变。

为量化每道题目 $i \in \mathcal{J}$ 的信息量, 我们通过其梯度嵌入的长度定义如下**基于信息量的启发式**:

$$\text{Info}(i) = \|\mathbf{g}_i\|, \quad (3)$$

其中 $\|\cdot\|$ 表示欧几里得范数函数。

为捕捉关于代表性的信息 (即一道题在多大程度上能代表所有未选题目), 我们利用梯度嵌入的方向。具体来说, 我们用一道题与其他未选题目的余弦相似度来度量它的代表性, 并自然地定义如下**基于代表性的启发式**:

$$\text{Repr}(i; \mathcal{J}_U) = \frac{1}{|\mathcal{J}_U|} \sum_{j \in \mathcal{J}_U} \frac{\mathbf{g}_i \cdot \mathbf{g}_j}{\|\mathbf{g}_i\| \|\mathbf{g}_j\|}. \quad (4)$$

4.2.3 两阶段题目选择 给定上面定义的启发式, 我们现在介绍 GEIS 中使用的完整策略, 它以两阶段方式选择每道题目。具体来说, 在第 t 步, 从未选题目 $\mathcal{J}_U$ 中选出一个候选题目集 $\mathcal{J}_C$, 它由基于信息量启发式最大的 K_C 道题组成; 然后, 从 $\mathcal{J}_C$ 中选出基于代表性启发式最大的一道最终题目:

$$i_t = \arg \max_{j \in \mathcal{J}_C} \text{Repr}(j; \mathcal{J}_U^{t-1}), \quad s.t. \mathcal{J}_C = \arg \max_{A \subset \mathcal{J}_U^{t-1}, |A| \leq K_C} \sum_{i \in A} \text{Info}(i). \quad (5)$$

与直接组合两个启发式（如加权和或乘积）相比，如上进行两个顺序阶段有两个优点。第一，计算上更高效，因为我们只需在第二阶段为少量题目计算基于代表性的启发式。第二，我们凭经验发现超参数（即 K_C ）比其他组合方法的超参数更容易调。

4.3 MCSE (元学习认知状态估计器)

尽管所提出的 GEIS 实现了 CAT 中与模型无关的题目选择，但在考生作答我们精心选出的题目之后，我们仍缺乏恰当的认知状态估计。大多数现有 CDM，尤其是近来基于深度学习的模型，用基于梯度的优化方法（如随机梯度下降）进行认知状态估计。通常，定义一个估计器（即一个优化器）有三个关键要素：初始化、更新方向和步长。现有 CDM 通常以简单方式实现估计器：(1) 认知状态参数从某个预定义分布（如均匀分布）随机初始化；(2) 给定考生的作答，更新方向由某个代价函数（如交叉熵损失）的梯度决定；(3) 步长通常作为超参数手动设置，常带一个可选的衰减内循环以优化多次迭代直到收敛。

上述朴素的不自适应估计方法有以下两个缺点。第一，估计器容易对考生已有的作答过度自信，从而在估计中产生极端值。例如，如果考生第一题答对，估计器倾向于高估考生能力，导致在下一步选出一道远更难的问题；反过来，如果考生之后表现不佳，该考生的能力很可能被低估。总体而言，测试过程显得不稳定。第二，朴素估计器无法在测试期间调整其估计策略。例如，在测试初始阶段，急需快速找到考生认知状态的大致范围，因此需要粗粒度的估计策略（如相对较大的步长）；相反，随着测试推进、认知状态的不确定性逐渐降低，更好的做法是微调以获得更精确的估计。

图 4: MCSE 示意图。上半部分展示用历史考生进行的双层元优化过程（对应算法 2，只是为了视觉清晰，局部更新用单个考生而非一个批次来示意）。下半部分展示元学习估计器如何为新考生更新认知状态参数（对应公式 8）。

解决上述问题的关键在于：让估计不仅依赖来自在测考生的少量数据，还依赖来自所有历史考生的海量数据。在直接从当前考生学习认知状态之前，CAT 系统能否先通过历史考生学会“如何学习”？这一挑战可以自然地转化为一个“学会学习”（即元学习）的问题。因此，我们提出一个 MCSE，通过从海量历史记录中学会学习，仅用少量作答就恰当地更新考生的认知状态，如图 4 所示。具体来说，我们首先把认知状态估计表述为一个元学习问题并设计一个精巧的元学习器；然后，我们把每位历史考生识别为一个元训练任务，利用元优化在历史数据上训练元参数，以便利新任务的估计。本小节将更详细地讨论元学习器的结构和元优化过程。最后，我们用 MCSE 产生的元学习梯度嵌入精炼 GEIS，在统一框架内连接题目选择与认知状态估计。

4.3.1 元学习器 朴素估计器从随机初始化出发、用手动设计的步长通过梯度下降迭代更新认知状态参数；与之不同，MCSE 背后的基本思想是自动决定估计器的所有要素（即初始化、更新方向和步长）并在测试期间自适应地调整它们。在数学上，对考生 e 测试的第 t 步 ($t = 1, \dots, T$)，一个典型的朴素估计器的估计步骤可表述如下：

$$\theta_e^0 \sim p(\theta), \quad \theta_e^t = \theta_e^{t-1} - \alpha \nabla \mathcal{L}_{\mathcal{T}_e}(\theta_e^{t-1}). \quad (6)$$

测试开始时，初始认知状态参数 θ_e^0 从先验分布 $p(\theta)$ 中采样。然后在第 t 步，参数 θ_e^{t-1} 通过步长为标量 α 的梯度下降更新。 $\mathcal{T}_e^t = \{(i_{t'}, r_{ei_{t'}})\}_{t'=1}^t$ 表示考生到目前为止的作答， $\mathcal{L}_{\mathcal{T}_e}(\theta_e^{t-1})$ 是经验损失：

$$\mathcal{L}_{\mathcal{T}_e}(\theta_e^{t-1}) = \frac{1}{t} \sum_{t'=1}^t l(\mathcal{M}(\theta_e^{t-1}, \varphi_{i_{t'}}), r_{ei_{t'}}), \quad (7)$$

其中损失函数 $l(\cdot, \cdot)$ 如二元交叉熵损失。相应地， $\nabla \mathcal{L}_{\mathcal{T}_e}(\theta_e^{t-1})$ 是 $\mathcal{L}_{\mathcal{T}_e}(\theta_e^{t-1})$ 关于认知状态参数的梯度。

与之相对，我们给出形式相似但带有两个元学习项的如下元学习器：

$$\theta_e^0 = \tilde{\theta}, \quad \theta_e^t = \theta_e^{t-1} - \alpha(t; \tilde{\mu}) \circ \nabla \mathcal{L}_{\mathcal{T}_e}(\theta_e^{t-1}), \quad (8)$$

它对公式 6 做了两处关键改动：(1) 不再随机抽取初始参数，而是用一个初始化项 $\tilde{\theta}$ 为每位新考生初始化估计器；(2) 不再用手动设置的步长沿原始梯度走，而是在每个测试步 t 通过一个适应项 $\alpha(t; \tilde{\mu})$ 修改梯度，动态地决定更新方向和步长，其中 $\circ$ 表示逐元素乘积。我们用波浪号标记表示 $\tilde{\theta}$ 和 $\tilde{\mu}$ 是待训练的元参数。本小节余下部分先讨论元参数的基本结构与动机，然后介绍详细的元优化过程；此外，4.4 节给出一个基于隐喻的元参数直观解释。

(1) 初始化项。 $\tilde{\theta}$ 与 CDM 的认知状态参数有完全相同的结构。其背后的思想是：通过考虑整体任务分布，为任务特定的微调找到最优初始化。以 IRT 模型为例，每位考生用一个标量能力水平表示。我们可以直观地把参数估计视为一个搜索问题。如果想快速找到真值，类似于高效的二分查找，

最好从相对整体能力分布的一个中间值开始，而非极端值。这样，项 $\tilde{\theta}$ 通过一个从历史数据元学习得到的合适初始化，帮助对新考生的认知状态快速适应。

(2) 适应项。与 $\tilde{\theta}$ 不同， $\tilde{\mu}$ 包含一组背后结构更复杂的元参数：

$$\alpha(t; \tilde{\mu}) = \text{ReLU}(\alpha_{base} + \gamma \alpha_{dyna}^t), \quad (9)$$

$$\alpha_{dyna}^t = \tanh(W h_t), \quad (10)$$

$$[h_t, c_t] = \text{LSTM}(\nabla \mathcal{L}_{\mathcal{T}_e^t}(\theta_e^{t-1}), h_{t-1}, c_{t-1}; \Psi). \quad (11)$$

如上所示， $\alpha(t; \tilde{\mu})$ 由 (1) 在整个测试期间保持不变的基础部分 α_{base} ，和 (2) 在测试期间动态推断的动态部分 α_{dyna}^t 组成。 $\text{ReLU}(\cdot)$ 把 $\alpha(t; \tilde{\mu})$ 正则化为非负， $\gamma \in (0, +\infty)$ 是一个为 α_{dyna}^t 提供可选权重的超参数。这样，元学习器可以随测试的进行动态调整策略。为推断动态部分，我们利用一个由 Ψ 参数化的长短期记忆 (LSTM) 网络 (公式 11)。每一步的普通梯度 $\nabla \mathcal{L}_{\mathcal{T}_e^t}$ 被认为包含关于参数估计的信息，因此作为网络的输入。例如，范数更大的梯度可能意味着当前步有更大的不确定性。 h_t 和 c_t 分别是隐藏状态和单元状态，二者都零初始化。最终输出由当前隐藏状态经一个双曲正切激活函数变换而来 (公式 10)。总之，元学习的适应项 $\tilde{\mu}$ 由三部分元参数组成： α_{base} (公式 9)、 W (公式 10) 和 Ψ (公式 11)。

总之，对于考生 e ，我们的元学习器首先用 $\tilde{\theta}$ 初始化认知状态参数 θ_e^0 。然后在测试第 t 步，给定少量测试作答 $\mathcal{T}_e^t = \{(i_{t'}, r_{ei_{t'}})\}_{t'=1}^t$ ，元学习器用自适应推断的步长和更新方向 (隐式实现于 $\alpha(t; \tilde{\mu}) \circ \nabla \mathcal{L}_{\mathcal{T}_e^t}(\theta_e^{t-1})$ 中) 把 θ_e^{t-1} 更新为 θ_e^t 。还值得注意的是，在每个测试步 t ，我们严格用单次梯度下降优化认知状态参数，而非朴素估计器中可能的多轮。如后文 (4.4 节) 所讨论，这在连接题目选择与认知状态估计中起作用。

4.3.2 元优化 我们现在转向元学习器的元优化过程，即学习初始化项 $\tilde{\theta}$ 和适应项 $\tilde{\mu}$ (公式 8)，使得对任意新考生 e 都能很好地估计认知状态 θ_e^t 。从元学习的视角，我们把为任意考生 e 进行自适应测试视为一个任务 $\mathcal{T}_e$ ，并考虑历史和即将到来的考生都从中抽取的任务分布 $p(\mathcal{T})$ 。沿着这一思路，我们可以在历史数据上训练元参数，以使元学习器在新数据上快速适应。如图 4 所示，每个元训练任务 $\mathcal{T}_e$ 由一个支持集 $\text{spt}(\mathcal{T}_e)$ 和一个查询集 $\text{qry}(\mathcal{T}_e)$ 组成。在我们的语境中， $\text{spt}(\mathcal{T}_e)$ 由考生对整个自适应测试中所选全部题目的作答组成，带上标 t 的 $\text{spt}(\mathcal{T}_e)^t$ 包含测试前 t 步所选的那些题目；相应地， $\text{qry}(\mathcal{T}_e)$ 包含考生对一组事先预留用于元验证的目标题目的作答。在数学上，我们元学习器的训练目标可表述如下：

$$\min_{\tilde{\theta}, \tilde{\mu}} \mathbb{E}_{\mathcal{T}_e \sim p(\mathcal{T})} \left[\sum_{t=1}^T \mathcal{L}_{\text{qry}(\mathcal{T}_e)}(\theta_e^t) \right], \quad (12)$$

其中 θ_e^t 依赖元参数 $\tilde{\theta}$ 和 $\tilde{\mu}$ 迭代计算，类似于公式 8：

$$\theta_e^0 = \tilde{\theta}, \quad \theta_e^t = \theta_e^{t-1} - \alpha(t; \tilde{\mu}) \circ \nabla \mathcal{L}_{\text{spt}(\mathcal{T}_e)^t}(\theta_e^{t-1}). \quad (13)$$

注意，我们把每一步 t 累积的损失加起来，以优化整个自适应测试的认知状态估计。算法 2 展示了我们元学习器的详细训练过程。本质上，我们通过从历史考生 $e \in \mathcal{E}_{train}$ 中抽样，等价地从分布 $\mathcal{T}_e \sim p(\mathcal{T})$ 中迭代抽样一个小批量任务。对每个元训练任务 $\mathcal{T}_e$ ，我们通过随机选取一段日志序列 $\text{spt}(\mathcal{T}_e) = \{(i_t, r_{ei_t})\}_{t=1}^T$ 来构成支持集，其中 T 是自适应测试长度。对于查询集，我们发现与其预留少量目标题目，不如使用考生在整个题库上的全部作答记录更鲁棒，即 $\text{qry}(\mathcal{T}_e) = \{(i, r_{ei})\}_{i \in \mathcal{I}}$ 。从随机的初始元参数 $\tilde{\theta}$ 和 $\tilde{\mu}$ 开始，算法通过在每个支持集上计算训练损失并调整参数来执行局部更新，然后通过用适应后的元参数在查询集上最小化测试损失来执行全局更新。这种双层迭代重复进行，直到元参数收敛。

算法 2: MCSE 的元优化过程 (伪代码，详见原文)。输入：元参数学习率 β 。输出：元参数 $\tilde{\theta}, \tilde{\mu}$ 。随机初始化 $\tilde{\theta}, \tilde{\mu}$ ；未收敛时：从 $\mathcal{E}_{train}$ 抽样一个小批量考生 B ，对每个 $e \in B$ 置 $\theta_e^0 = \tilde{\theta}$ 并对 $t = 1, \dots, T$ 做局部更新 $\theta_e^t \leftarrow \theta_e^{t-1} - \alpha(t; \mu) \circ \mathcal{L}_{\text{spt}(\mathcal{T}_e)^t}(\theta_e^{t-1})$ ；然后全局更新 $\tilde{\theta} \leftarrow \tilde{\theta} - \beta \sum_{e \in B} \nabla_{\tilde{\theta}} \sum_{t=1}^T \mathcal{L}_{\text{qry}(\mathcal{T}_e)}(\theta_e^t)$ ， $\tilde{\mu}$ 同理。

4.3.3 用元学习梯度精炼题目选择 有了所提出的 MCSE 模块，我们可以用一次单步元学习梯度恰当地更新认知状态估计。值得回顾的是，GEIS 中题目选择的基本思想是通过题目的梯度嵌入度量其价值。沿着这一思路，我们可以把 GEIS 中的梯度嵌入 (公式 2) 精炼如下：

$$\mathbf{g}_{ei}^t = \alpha(t; \tilde{\mu}) \circ \nabla_{\theta} \hat{\mathcal{L}}_i(\theta_e^{t-1}), \quad \hat{\mathcal{L}}_i(\theta_e^{t-1}) = l\left(\mathcal{M}(\theta_e^{t-1}, \varphi_i), \mathbb{I}(\mathcal{M}(\theta_e^{t-1}, \varphi_i) > 0.5)\right), \quad (14)$$

其中 $\alpha(t; \tilde{\mu})$ 如公式 9 所定义， $\hat{\mathcal{L}}_i(\theta_e^{t-1})$ 是用预测作答 $\mathcal{M}(\theta_e^{t-1}, \varphi_i; \omega)$ 和伪标签 $\mathbb{I}(\mathcal{M}(\theta_e^{t-1}, \varphi_i) > 0.5)$ 计算的损失函数。元学习梯度通过适应项 $\alpha(t; \tilde{\mu})$ 可能比原始梯度更好地度量题目的价值，因为前者通过在海量历史数据上的元优化包含了更丰富的信息。从这个意义上说，元学习梯度嵌入为题目选择与认知状态估计提供了一个合适的连接。具体来说，当 CAT 系统采用执行多步梯度下降的朴素估计器时，由于与实际更

新不匹配,原始梯度只是对模型影响的粗略近似;相反,如果我们应用执行单步优化的 MCSE,元学习梯度嵌入(公式 14)就与更新过程(公式 8)很好地匹配。这种不匹配的消除促成了两个模块之间更好的协作。

4.4 讨论

在介绍完整体方法论后,我们对所提出的框架做进一步阐释。首先,我们给出 MAMGE 中建模的元参数的直观解释。其次,我们总结与前期工作 MAAT 的主要区别和扩展。第三,我们强调 MAMGE 主要的新颖性质。

4.4.1 元知识的解释 一般来说,MCSE 中建模的元参数(即 $\tilde{\theta}$ 和 $\tilde{\mu}$)编码了历史数据中包含的元知识,从而把公式 6 中 CDM 的原始优化过程精炼为公式 8。这里我们讨论在自适应测试语境下这种元知识究竟是什么。作为一个直观的隐喻,我们设想这样一个情境:一位熟练的家庭教师通过一系列测试来判断学生的状态,以个性化下一步的学习计划。除了该特定学生的单独表现外,这位教师自然会利用她的先验经验,即她教过的学生和出过的测试。然后我们在家庭教师拥有的先验经验和元参数中编码的元知识之间建立对应关系。

(1) **初始化项。**公式 8 中用作初始化项的元参数 $\tilde{\theta}$ 可直观地对应学生还没参加任何测试的情形。教师不会为学生把初始学习计划设在随机的难度水平,而很可能会指定一个适中的水平,这某种程度上符合她历史学生的整体能力分布(如平均能力)。类似地, $\tilde{\theta}$ 学到的元知识也可以被认作关于历史学生的某种分布信息。从这个意义上说,在新学生服从相同分布的假设下,元知识增强的初始化能优于随机初始化。

(2) **适应项。**公式 8 中用作适应项的元参数 $\tilde{\mu}$ 可对应教师通过先验经验修正她判断的情形。设想学生第一次测试就得满分的情况:若不考虑任何先验知识,学生的能力可能被极度高估,随后为他制定的个性化学习计划会难得离谱。然而实践中,除了该特定学生的单独表现,教师可以参考所有参加过同一测试的历史学生,从而给出适中的判断和合理的计划。相应地, $\tilde{\mu}$ 学到的元知识也是这样一种防止参数更新期间过拟合的修正能力。

此外,我们在 5.2.4 节给出案例研究,展示 MCSE 在上述元参数影响下一致的行为模式。

4.4.2 与前期工作的比较 MAMGE 是我们前期 MAAT 框架在以下两个不同层面上自然而又非平凡(nontrivial)的扩展。

(1) **研究范围的扩展。**在更高层面上,MAMGE 把自适应测试视为题目选择与认知状态估计的系统性结合,而 MAAT 只聚焦于题目选择部分。从这个意义上说,MAMGE 扩展了对自适应测试问题的研究范围,更贴近实际因而更有效(实验比较见第 5 节)。

(2) **策略设计的扩展。**即便在题目选择部分的范围内,MAMGE 也通过进一步探索梯度在 MAMGE 中的作用扩展了方法论设计。一般来说,MAMGE 和 MAAT 都用梯度长度表示信息量,主要区别在于代表性启发式。具体来说,为获得题目相似度,MAMGE 利用梯度嵌入的方向,而 MAAT 使用关联的知识点。我们指出 MAMGE 这一设计选择的两个优点。第一,MAMGE 对数据外部信息的依赖极小,因此比需要专家标注题目知识的 MAAT 更普遍适用。第二,由于梯度嵌入是关于底层 CDM 计算的,基于梯度的启发式可以内在地利用 CDM 的表达能力。例如,一些近来由深度学习技术驱动的 CDM 能够从知识图谱中提取知识点之间的复杂关系。尽管如此,这两种设计是内在一致而非冲突的。设想一个认知状态参数与知识强相关的 CDM(例如一个表示在每个知识点上能力水平的向量),那么对于一道关联特定知识点的题目,其梯度嵌入的方向被认为与关联的知识标注传达一致的信息。

4.4.3 突出的性质 MAMGE 的关键性质可从以下三个方面总结。

(1) **一个与模型无关的框架。**在前面的讨论中,底层 CDM $\mathcal{M}(\theta, \varphi)$ 的细节被隐藏,这表明所提出的 MAMGE 框架可应用于广泛的 CDM。更具体地说,对 MCSE 和 GEIS 而言,唯一的假设是损失函数在 θ 上足够光滑以支持基于梯度的运算。这一假设对大多数现有模型、尤其是近来基于深度学习的模型都成立。因此,MAMGE 是一个灵活的、与模型无关的 CAT 框架。

(2) **基于启发式与数据驱动方法的混合。**以往 CAT 方法要么基于启发式,要么数据驱动。然而,前者缺乏对数据的有效利用,后者受数据偏差之苦;实践中很难在应用前判断哪种更好。我们认为 MAMGE 有更鲁棒的性能,因为它可被视为基于启发式与数据驱动方案的混合。一方面,MCSE 模块通过元学习梯度嵌入有效利用历史数据;另一方面,GEIS 模块由精心设计的启发式组成,使 MAMGE 在元学习梯度嵌入退化为朴素梯度时也能表现得与 MAAT 相近。

(3) **估计与选择的良好连接。**在现有 CAT 系统中,题目选择模块与认知状态估计模块是独立设计的,这从根本上限制了测试有效性。一方面,题目选择中的主要考量是如何量化每道题目所含的潜在信息;另一方面,认知状态估计正是题目把其信息传达给底层 CDM 的方式。从这个意义上说,存在统一连接这两个模块的内在动机。MAMGE 用元学习梯度嵌入实现了一种巧妙的连接,它同时作为 GEIS 的选择指标和 MCSE 的估计更新。

5 实验

5.1 实验设置

5.1.1 数据描述与评估协议 我们用四个由真实学生交互组成的数据集评估框架的有效性,它们来自不同来源、规模不同:

- **ASSIST:** ASSISTments 2017 是一个广泛使用的教育数据集,包含学生用 ASSISTments 系统做的数学练习。**Junyi:** Junyi Academy 数学练习日志是由 Junyi 在线学习平台收集的、最大的公开学生交互数据集之一。

- **EXAM**: EXAM 数据集由科大讯飞 (iFLYTEK) 提供, 收集自一个智能辅导系统。与 ASSIST 和 Junyi 不同, EXAM 中的交互数据是学生参加真实数学考试 (而非练习) 时收集的。
- **ECPE** (Examination for the Certificate of Proficiency in English): ECPE 数据集来自密歇根大学英语语言研究所开发并评分的一项标准化英语测试。

为保证实验结果的可靠性, 我们对所有数据集做如下预处理。首先, 如果一名学生在同一道题上有多条记录, 我们只保留最早的一条以去重。然后, 我们过滤掉被少于 10 名学生作答的题目, 以及作答了少于 20 道题的学生。

表 1 给出的分析统计表明, 所选的四个数据集涵盖了多种属性。第一, 数据集规模跨度很大。例如, Junyi 从数千名在线学生收集了超过一百万条日志, 而 ECPE 是规模小得多的线下收集。第二, 数据集有不同的数据密度 (以每学生/每题目平均日志数衡量)。在实验中, 更高的每题密度 (如 Junyi 和 ECPE) 意味着题目校准 (即题目表示能有多准确) 的方差更小; 更高的每学生密度 (如 ASSIST) 意味着题目选择验证的自由度更大, 因为实验上我们只能选那些有真值的题目。特别地, 对 ECPE, 每名学生都有作答每道题的记录 (即每学生平均日志数 = 题目数), 从而完全消除了题目真值的限制, 这也是我们在案例研究中选择 ECPE 的原因。最后但同样重要的是, 数据集有各不相同的标签分布 (即正确作答数与总日志数之比), 从 43.18% 到 76.67% 不等。数据集属性的广泛性有助于支持更全面、更有说服力的实验验证。

对每个数据集, 我们按 60%、20%、20% 随机划分学生用于训练、验证和测试。训练划分扮演第 3 节介绍的历史考生 (即 $\mathcal{E}_{train}$) 的角色, 假定为 CAT 系统所知; 相应地, 测试划分作为新考生 (即 $\mathcal{E}_{test}$) 来评估自适应测试方法的有效性; 此外, 与测试划分类似的验证划分用于执行早停和为每种方法调超参数。

测试时, 我们用不同方法为每位考生选出一套个性化题目, 测试长度相同 (即题目数相同)。此外, 实践中我们把选择限制在那些在测试数据中已记录实际作答的题目上。此后, 如第 3 节所讨论, 我们通过预测考生在一个评估题目集上的表现来比较不同方法的测试有效性 (即 $\psi(\theta^T)$)。本文中, 我们用所有已记录实际作答的题目作为评估集。具体来说, 我们采用两个常用指标——ACC 和 ROC 曲线下面积 (AUC)——来量化 $\psi(\theta^T)$ 。

表 1: 预处理后数据集的统计信息

数据集	ASSIST	Junyi	EXAM	ECPE
学生数	1,670	29,301	3,750	2,922
题目数	1,960	701	1,179	28
日志数	355,376	1,423,438	158,178	81,816
平均日志/学生	212.80	48.58	42.18	28.00
平均日志/题目	181.31	2030.58	143.41	2922.00
标签分布	43.18%	76.67%	66.87%	71.46%

5.1.2 基线方法 为证明 MAMGE 的有效性, 我们将它与以下所选基线方法比较, 包括作为起点线的基础随机方法、CAT 文献中两种经典的基于 IRT 的方法、一种常用的主动学习方法, 以及两种近来开发的最先进方法:

- **RANDOM**: 基础随机方法, 为所有考生任意选择下一道题, 用于量化其他方法的提升。
- **最大 Fisher 信息 (MFI)**: 最流行的选择策略, 用 Fisher 信息函数度量题目信息, 专为 IRT 模型设计。
- **KLI**: 一种全局信息启发式, 借助 Kullback-Leibler 散度量信息量, 同样专为 IRT 模型设计。
- **不确定性采样 (Uncertainty Sampling, US)**: 一种常用的主动学习方法, 选择对当前模型最不确定的样本以加速模型学习过程。实验中我们用广泛采用的熵函数作为不确定性度量。
- **BOBCAT**: 在双层优化框架内从训练数据自动学习一个数据驱动的题目选择算法。
- **MAAT**: 迈向与模型无关 CAT 系统的第一步, 通过主动学习技术保证所选题目兼具质量和多样性。

5.1.3 底层 CDM 为评估所提框架的“与模型无关”性质, 我们在两个不同的底层 CDM 上 (如果可能) 应用上述所有基线以及 MAMGE (注意经典的 MFI 和 KLI 方法只能用于 IRT)。一个是公式 1 所示的 IRT 模型, 它是 CAT 中最常用的 CDM。另一个是 [16] 中使用的基于神经网络的模型, 我们称之为 NN。具体来说, NN 实现为一个带 ReLU 激活和 20% dropout 率的两层全连接网络, 由一个 8 维输入层、64 个隐藏节点和一个直接输出每道题表现预测的最终 sigmoid 输出层组成。

5.1.4 参数设置 对所有基线方法, 超参数在验证数据集上调到最佳性能。对我们的 MAMGE 框架, 超参数设置如下。在 MCSE 模块中, 我们设 $\gamma = 1$ 来平衡元学习适应项的基础部分和动态部分 (公式 9); 动态部分的 LSTM 用两个循环层实现。元训练期间, 题目特征参数和元参数的学习率都设为 0.001。在 GEIS 模块中, 两阶段题目选择 (公式 5) 的平衡参数 K_C 在配合 IRT 模型时设为 1, 配合 NN 模型时设为 5。也就是说, 对 IRT 模型我们只用基于信息量的启发式, 因为 IRT 中认知状态参数及其梯度都是一维的, 使得基于代表性的启发式无用。我们把最大测试长度设为 10, 这对典型 CAT 足够有代表性; 关于测试长度的进一步讨论将在后面进行。所有实验在一台 Linux 服务器上进行, 配两块 2.30 GHz 的 Intel Xeon Gold 5118 CPU 和一块 11G GTX 1080ti GPU。

5.2 结果与分析

5.2.1 总体性能 表 2 展示完成整个测试后（即达到最大测试长度时）在 ACC 指标上的平均总体性能比较；表 3 用 AUC 指标做同样的事。每个表中表现更优的结果加粗。可以清楚看到，尽管底层模型和评估指标不同，MAMGE 始终比所有最先进基线取得显著提升。四个数据集都呈现相似结果，证明 MAMGE 能有效实现一个 MAAT 系统。此外，还有一些值得讨论的进一步观察。

第一，我们注意到 NN 模型在大多数情况下优于 IRT 模型，但也有例外。这表明两点：一方面，确实存在某些 CDM 比其他更“强大”的情况；另一方面，仅仅不断为那些更强大的 CDM 设计新算法并不能完全解决问题，因为不可能完全断定一个 CDM 在某数据集上的表现。因此，鉴于不同 CDM 在不同数据集上的表现各异，CAT 框架有必要做到与模型无关。从这个意义上说，MFI 和 KLI 虽然被证明是经典高效的基于 IRT 的方法，却难以扩展到更广泛的 CDM（包括 NN 这类更强大的模型）。相比之下，MAMGE 在两个底层 CDM 上都表现一贯良好。同时，我们发现 MAMGE 在 NN 模型上的提升幅度比在 IRT 模型上更大，这表明 MAMGE 相当适合更复杂、更强大的 CDM。

第二，观察几乎适用于所有模型的简单策略 US 的结果，我们发现一个与模型无关的方法要同时取得出色性能并非易事。事实上，由于无法获得底层模型的细节，自适应测试框架对精巧设计有额外需求。相比之下，MAMGE 通过为题目选择和认知状态估计精心设计的模块，同时保持了灵活性和有效性。

第三，与最先进工作 BOBCAT 相比，我们的方法表现出更强的鲁棒性和稳定性。特别地，我们观察到 BOBCAT 在 ECPE 上表现平平，因为该数据集相比其他数据集缺乏大量交互数据。背后的关键在于 BOBCAT 是彻底数据驱动的，它从历史数据自动学习整个题目选择模块以及参数初始化，因此容易受历史数据中偏差或稀缺的影响（其原文也提到了这一点）。此外，我们在实验中凭经验认识到 BOBCAT 在训练和调参上难度更高。相比之下，如 4.4 节所讨论，MAMGE 在数据驱动和基于启发式的思想之间有更好的折中。

最后但同样重要的是，看 MAMGE 所扩展的 MAAT 的结果，我们可以注意到，与本文的基本思想一致，为 CAT 提供更好的认知状态估计能带来很大提升。如 4.4 节所讨论，我们认为优势不仅来自估计器本身，还来自认知状态估计与题目选择的合理结合。

表 2：MAMGE 在四个真实数据集上 ACC 指标的总体性能（结构复杂，仅说明：加粗为更优结果。MAMGE 在 IRT 和 NN 两种 CDM、四个数据集上均取得最佳 ACC；NN 上提升尤为明显，如 EXAM 从约 77.7% 提升到 81.15%、ECPE 从约 77.97% 提升到 81.90%。完整数值见原文表 2）。

表 3：MAMGE 在四个真实数据集上 AUC 指标的总体性能（结构复杂，仅说明：加粗为更优结果。MAMGE 同样全面领先，NN 上 Junyi 从约 81.28% 提升到 84.19%、EXAM 提升到 84.85%。完整数值见原文表 3）。

5.2.2 消融研究 为进一步验证不同部分的有效性，我们把 MAMGE 与其变体比较。除了整体验证 MCSE 和 GEIS 外，我们还对两个模块内部的细节部分做更细粒度的验证。所比较的变体如下：

- **MAMGE w/o MCSE**：为验证 MCSE 的有效性，认知状态估计只用公式 6 的朴素估计器。
- **MAMGE w/o Init**：在 MCSE 模块内，为验证元学习初始化项 $\tilde{\theta}$ （公式 8）的有效性，认知状态估计只用随机初始化。
- **MAMGE w/o Dyna**：为验证 MCSE 模块中元学习适应项动态部分 α_{dyna}^t 的有效性，通过在公式 9 中设 $\gamma = 0$ 来禁用它。
- **MAMGE w/o GEIS**：为验证 GEIS 的有效性，题目选择用随机策略。
- **MAMGE w/o Info**：在 GEIS 模块内，为验证基于信息量启发式的有效性，在两阶段题目选择中设 $K_C = |J_U|$ ，从而只用基于代表性的启发式。
- **MAMGE w/o Repr**：为验证 GEIS 模块中基于代表性启发式的合理性，在两阶段题目选择中设 $K_C = 1$ ，从而只用基于信息量的启发式。
- **MAMGE w/o Two-stage**：为验证两阶段题目选择的有效性，用加权之和来组合两个启发式以替代它。形式上，把公式 5 替换为 $i_t = \arg \max_{ACJ_U^{t-1}} \text{Info}(i) + w * \text{Repr}(i)$ ，其中 $w \in (0, +\infty)$ 是加和权重；消融研究中我们在验证集上调到 $w = 0.1$ 。

图 5 描绘了四个数据集、两个底层 CDM 上的比较结果。注意对 IRT，由于基于代表性的启发式被禁用，三个变体（w/o Info、w/o Repr、w/o Two-stage）被忽略。总体结果清楚显示了 MAMGE 中所研究各部分的有效性。特别有几个观察值得注意。

第一，从 IRT 模型上 MAMGE w/o MCSE 与 MAMGE w/o GEIS 的比较结果可以发现，认知状态估计模块（MCSE）比题目选择模块（GEIS）起的作用更小。原因是 IRT 中认知状态估计因其一维表示而简单得多，这种情形下元学习估计器无法充分发挥优势。相反，对 NN 模型，由于其用神经层的复杂表示，MCSE 模块对性能有关键影响。这也很好地解释了为什么 MAMGE 在 NN 模型上的提升幅度比 IRT 模型更大。

第二，看 NN 模型上 MAMGE w/o MCSE、w/o Init 和 w/o Dyna 的结果，我们观察到：（1）在估计复杂认知状态参数时，初始化项对 MCSE 相当重要，没有它元学习估计器甚至会比朴素估计器更差；（2）对认知状态估计中动态性的建模是有效的，因为没有适应项的动态部分时 MCSE 的性能显著下降。

第三，MAMGE w/o GEIS、w/o Info 和 w/o Repr 的结果很好地印证了我们对题目选择启发式的理解。一方面，基于信息量的启发式是题目选择中的核心考量，没有它策略甚至比随机选择更差；另一方面，基于代表性的启发式起到正则化作用，防止 GEIS 模块选出题库中的分布外题目。

最后，MAMGE w/o 2-stage 展示了用加和而非两阶段顺序选择来组合两个启发式的另一种方式。注意组合方法更多是一种设计选择而非我们的贡献，MAMGE 框架完全可以灵活地使用其他方法。尽管如此，结果显示基于加和的选择性能有竞争力但略低于两阶段选择，这验证了后者

是一个合理的选择。

5.2.3 关于测试长度的分析 本小节讨论测试长度，即自适应测试中的步数。在 MAMGE 中，测试长度的影响是双重的：(1) 元训练采样任务的测试长度（算法 2）和 (2) 对真实新考生进行 CAT 的测试长度（算法 1）。在前面的实验中，这两个概念被同等对待。此外，自适应测试的长度被假定为固定，这有时不切实际——例如，测试可能采用导致长度可变的停止规则。沿着这一思路，自然产生三个问题：(1) 我们能否用与进行自适应测试时不同的测试长度做元训练？(2) 我们能否用训练好的框架进行可变长度的自适应测试？(3) 元训练长度如何影响框架的性能？

为回答这些问题，我们用各种长度的支持集（3、5、10、15）对 MCSE 模块做元训练，然后用各种步数（从 1 到 15）进行自适应测试。图 6 展示四个数据集上用 NN 模型的结果，图中每条线描绘用某个长度元训练的 MAMGE 的 AUC 指标，US 方法（黑线）作为基线。比较结果后，我们有以下观察。第一，每条线并非只在与元训练长度相同的测试步取得好性能，而是有正常的上升趋势，即性能随测试步保持健康增长，这验证了用与自适应测试不同的灵活测试长度来元训练 MAMGE 的可行性。第二，几乎所有线都显著高于基线（ECPE 上 Length-15 的初始几步除外），表明我们的框架鲁棒、在各种测试长度下一贯表现良好。最后但同样重要的是，仔细比较图 6 中不同的线可以发现，元训练长度实际上影响 MAMGE 在初始化与适应之间的权衡。元训练长度越短，初始几步的性能越好。例如，在所有数据集的第一个测试步，Length-3 性能最好而 Length-15 最差。然而，元训练长度越长，MAMGE 能适应得越快，可能在长程上带来更好性能。例如在 ECPE 上，3 个测试步后 Length-5 超过 Length-3。总体上，在图 6 中，用 Length-5 元训练的框架在四个数据集上跨测试步的总体性能最好。理解这种权衡有助于在实践中实现高鲁棒性和高性能。

5.2.4 案例研究 为说明 MAMGE 中 MCSE 模块如何工作，我们在一些代表性案例上可视化认知状态估计过程。具体来说，图 7 展示用 IRT 模型表示的三位考生的认知状态，它们是反映其能力水平的标量值。红线描绘 MAMGE 估计的值，蓝线描绘有朴素估计器的 MFI 方法。为更直观地解释，绿色虚线表示每位考生的参考能力水平，由考生的全部记录计算得到。首先，我们可以看到 MAMGE 把所有考生的能力水平初始化到相同的值，该值从历史数据元学习而来，使后续估计能快速适应；相反，基线随机抽样一个初始值，有时导致次优估计。在考生 1 的案例中，基线从一个极低的水平开始，而该考生恰好第一题答错，尽管考生在后面的题上表现更好，这种低估却几乎无法被纠正。除初始化外，MAMGE 还表现出抗过拟合的鲁棒性。在考生 2 的案例中，基线的初始值比 MAMGE 更接近参考值，但在第一个测试步，基线过拟合并把能力水平高估到极高，而 MAMGE 不同——它迈出温和的一步，使其在后续步骤中适应良好。最后，看这三个案例中的曲线，我们发现 MAMGE 倾向于在较早阶段用较大步长快速适应、在较晚阶段用较小步长微调。这一观察验证了 MCSE 中适应项动态部分（公式 10）的有效性——实际上，步长可以随自适应测试的进行由循环层动态调整。MCSE 上述行为模式恰好对应 4.4 节讨论的元参数直观解释。

为说明 MAMGE 中 GEIS 模块如何工作，我们也可可视化题目选择过程。图 8 展示 ECPE 数据集上用 NN 模型为某位考生的部分题目选择过程（测试步 $t = 3, 5, 10$ ）。图中每个圆圈表示一道未选题目的梯度嵌入，通过主成分分析投影到二维空间；圆圈半径与梯度嵌入的范数（降维前）成正比；红色和蓝色圆圈是基于信息量选出的 K_C 道题，其中红色圆圈是基于代表性启发式做出的最终选择。该图验证了 MAMGE 除信息量外还考虑了题目的代表性。我们注意到 MAMGE 的最终选择并不总是信息量最大的那个（即圆圈尺寸最大的）；相反，基于代表性的启发式有效地远离那些分布外题目，更偏好能更好代表底层分布的题目。另一个有趣的观察是，图中圆圈的平均半径从左（测试步 = 3）到右（测试步 = 10）变小，意味着步长变小。这一事实再次验证了 MAMGE 倾向于动态降低其步长以进行微调。

6 结论与未来工作

本文针对智能教育系统的 CAT 进行了聚焦研究，即通过为考生施行自动化的题目选择和认知状态估计来提升测试的个性化和效率。具体来说，我们提出一个通过 MAMGE 的 MAAT 框架，以统一的方式解决题目选择和认知状态估计中的挑战。首先，我们设计了一个 MCSE，通过学会学习一个合适的初始化、更新方向以及步长来自动控制估计过程；然后，我们设计了一个 GEIS，用 MCSE 提供的伪元学习梯度作为嵌入来表示题目，并选出同时有信息量和代表性的最佳题目。MCSE 和 GEIS 本质上都与模型无关，并通过梯度嵌入的概念有一种内在连接。最后，我们在四个真实数据集、不同底层 CDM 上进行了大量实验，验证了 MAMGE 的有效性以及与模型无关的性质。

在未来工作中，我们将继续探索自适应测试方法，聚焦于可扩展性和可解释性。此外，我们也注意到扩展 CAT 应用范围的新兴机会。除教育领域外，还有更多智能系统需要高效有效的用户认知建模组件，例如知识追踪系统、心理学启发或跨域推荐系统，以及社会行为分析。我们希望本工作能为未来研究提供一些启示。

参考文献 (References) 按约定未翻译，详见原文。