

基于协同排序的计算机自适应测试 (Computerized Adaptive Testing via Collaborative Ranking)

原文: ccat-collaborative-ranking-cat_14.pdf (NeurIPS 2024, Zirui Liu, Yan Zhuang, Qi Liu 等, USTC & 科大讯飞) · 译者: Claude · 译于 2026-06-26 术语对照: Computerized Adaptive Testing 计算机自适应测试 (CAT); Item Response Theory 项目反应理论 (IRT); ability 能力; ranking consistency 排序一致性; collaborative students 协同学生; anchor 锚点; question selection 选题; Kendall coefficient Kendall 系数。

摘要

随着机器学习与智能教育的深度融合, 计算机自适应测试 (Computerized Adaptive Testing, CAT) 受到越来越多的研究关注。与传统纸笔测试相比, CAT 能在测试过程中根据学生表现自动调整测试题目, 从而提供既个性化又交互式的评估。因此, CAT 被认为是一种高效的测试方法, 能用最少的题目准确估计学生能力, 被广泛应用于 GMAT、GRE 等主流选拔性考试。然而, 在真实场景中, 仅仅提升能力估计的准确性远远不够, 因为对学生进行准确的排序通常更重要 (例如在高利害考试中)。考虑到现有 CAT 方案在学生排序上的不足, 本文强调将测试结果 (学生排名) 与学生真实潜在能力对齐的重要性。沿此思路, 与传统的学生间独立测试范式不同, 我们提出一个新颖的协同框架——协同计算机自适应测试 (Collaborative Computerized Adaptive Testing, CCAT), 利用学生间信息来增强学生排序。通过把协同学生 (collaborative students) 作为锚点来辅助对考生排序, CCAT 能为确保排序一致性提供理论保证和实验验证。

1 引言

随着计算机科学的飞速发展, 在线教育经历了重大变革, 重塑并取代了传统线下教育评估技术。在这一演进格局中, 计算机自适应测试 (CAT) [1, 2] 已成为标准化测试的一种主流方法, 被广泛应用于 GMAT [3]、GRE [4]、TOEFL [5] 等选拔性考试。与传统纸笔测试不同, CAT 提供个性化、交互式的评估, 题目的难度和特性会根据实时作答持续调整。通过让题目与学生当前能力估计相匹配, CAT 在每一迭代步精化估计过程 [6]。测试结束后, 图 1(a) 所示的最终能力分数作为成绩报告提供给学生。这个分数对其教育和职业前景起着关键作用。

图 1: (a) GRE 提供的成绩报告, 以及一个示例, 说明低 MSE 不能保证学生测试结果的正确排序。(b) 折线图展示了以往 CAT 方法在排序上的表现, 可以看到在准确性上达到最先进 (BECAT) 的方法在排序上可能只能达到随机选择的效果。

然而, 尽管人们已投入大量精力, 通过改进选题算法 [7, 8, 9, 10, 11, 12] 来优化能力估计的准确性, 但必须强调: 准确的能力估计本身并不能保证正确的学生排序。如图 1(a) 所示, 最小化能力分数的均方误差 (MSE) 并不总能转化为学生的准确排序。事实上, 即便是准确性表现优越的最先进 (SOTA) 选题算法, 在排序表现上也可能出现不一致, 有时甚至比随机选择方法还差, 如图 1(b) 所示。同时, CAT 测试过程中不同学生之间的异步性与独立性 [13, 14] 是实现准确能力排序的一大技术难点。这个问题阻碍了把所有学生的测试信息一起用于选题来提升学生间排序精度, 从而使 CAT 中排序一致性问题的求解更加复杂。

为应对这一挑战, 我们提出一个新颖的框架——协同计算机自适应测试 (CCAT), 它引入一种协同学习 [15, 16] 方法, 利用协同学生的数据作为排序锚点。该框架促进考生之间的交互, 从而获得更鲁棒的排序结果。重要的是, 我们还给出了理论分析, 证明在协同学生数量足够时, 排序一致性误差能被显著降低到可接受水平。总之, 我们的贡献是:

- 据我们所知, 这是首个揭示 CAT 内在排序一致性困境的研究, 给出了它的形式化定义与近似。这一发现使我们能显著精化 CAT 的目标, 对其在高利害考试场景中的部署是一项关键进展。
- 我们提出一种新颖的、基于协同的方法, 同时增强选题与能力估计以最小化排序不一致, 即便题目数量有限也能为排序一致性提供理论保证。
- 我们的方法足够通用, 可与现有选题算法集成。在大量真实世界教育数据集上的实验证明了 CCAT 的有效性, 相比其他方法排序一致性平均提升 5%, 并且在短测试场景下这一改进更显著。

2 相关工作

CAT 旨在高效、准确地估计学生能力 [2], 被广泛用于包括 GRE 在内的各类竞争性考试。CAT 本质上分两个阶段运作: 首先, 它用项目反应理论 (IRT) [17] 等方法估计学生能力; 随后, 用这些估计为每位学生选择下一题。下面分别概述 CAT 中使用的项目反应理论和常见选题算法。

项目反应理论 (IRT)。 IRT 是一种心理测量理论, 主要用于教育领域估计学生能力 [17, 18, 19]。它假设考生能力在整个测试中保持不变, 其表现仅取决于自身能力和题目提供的信息。标准模型是双参数 logistic (2PL) 模型: $P_j(\theta) = P(y_j = 1) = \sigma(a_j(\theta - b_j))$, 其中 $\sigma(x) = \frac{1}{1+e^{-x}}$ 是 sigmoid 函数, $y_j = 1$ 表示对题目 j 答对。参数 $a_j, b_j \in \mathbb{R}$ 分别表示题目 j 的区分度和难度。这些参数在测试前用马尔可夫链蒙特卡洛 (MCMC) [20, 21] 和梯度下降 (GD) [22, 23] 等算法估计。 $\theta \in \mathbb{R}$ 表示学生能力, 在每一步 t 用最大似然法估计:

$$\theta^t = \arg \max_{\theta \in \Theta} \sum_{j=1}^t y_j \ln P_j(\theta) + (1 - y_j) \ln(1 - P_j(\theta)). \quad (1)$$

近年来,越来越多的研究 [24, 25, 26, 27, 28] 借助深度学习技术 (如神经网络) 的飞速发展, 显著提升了学生能力估计的准确性。例如, NeuralCD [24] 利用一个非负全连接神经网络来捕捉复杂的学生-题目交互, 以实现更准确的估计。

选题算法。选题算法研究可分为两大路线: 传统的基于规则的算法和数据驱动的算法。首先, 传统选题算法 [29, 30, 31] 把 CAT 看作一个参数估计问题。它们基于学生当前熟练度计算每道题的信息值, 选择信息值最大的题目 [32], 通常用 Fisher 信息 (FSI) [32] 和 Kullback-Leibler 信息 (KLI) [33] 等指标。随后, 为了直接优化测试结果的准确性, 研究者提出了 MAAT [34]、BOBCAT [35] 和 NCAT [36] 等方法, 分别基于主动学习 [37]、元学习 [38] 和强化学习 [39]。最近, BECAT [40] 提出用学生在整个题库上的完整作答估计出的能力作为真值, 并用一种数据高效方法 [41] 求解 CAT 问题。

事实上, 在许多考试尤其是选拔性考试中, 成绩排名往往是录用的最重要依据之一。因此我们认为, 学生在 CAT 中的需求不一定是对其能力在测试集上更精确的估计, 相反, CAT 应当确保能力更强的学生获得更好的排名。因此, 我们把 CAT 的排序一致性确立为首要目标。

3 CAT 的排序一致性

我们首先假设 CAT 中的测试步数统一为 T 步, 所有选出的题目都来自题库 Q 。每位学生作答的题目构成一个子集 $S \subseteq Q$ 。在每一步 t , IRT 估计出的学生能力为 θ^t , 测试停止时学生的最终结果为 θ^T 。对传统 CAT 方法而言, 目标是用更少的题目让测试结果 θ^T 尽可能接近学生真实能力 θ^* [40, 42]:

$$\min_{|S|=T} \|\theta^T - \theta^*\|, \quad (2)$$

其中 θ^* 用学生在整个题库 Q 上完整作答估计出的能力来近似 [40]。然而如前所述, CAT 常常更看重学生间的排序问题, 而非仅仅提升 θ^T 的准确性。例如, 如果学生得知一个真实能力更低的同伴在 CAT 中表现得比自己好, 他们可能会质疑考试的公平性 [43]。因此, 我们如下定义 CAT 排序的一致性:

定义 1 (CAT 的排序一致性)。在计算机自适应测试中, 两个学生的真实能力分别记为 θ_1^* 和 θ_2^* 。这两位学生在题库 Q 的子集 S_1 、 S_2 上的测试结果记为 θ_1^T 和 θ_2^T 。测试的排序一致性要求: 真实能力更高的学生也应当表现出更高的测试结果:

$$\max_{|S_1|=|S_2|=T} P(\theta_1^T > \theta_2^T \mid \theta_1^* > \theta_2^*). \quad (3)$$

图 2: CCAT 框架结构。CCAT 由两部分组成: 选题和能力估计。选题部分利用协同学生在作答各类题目上的表现, 为被测学生选择合适的题目; 能力估计部分把被测学生与协同学生进行排序, 并用该排序作为测试结果。

考虑到接受测试的学生在表现、所答题目和进度上各不相同, 他们在 CAT 过程中保持独立。因此, 根据彼此在测试中的表现来选题以干预排序一致性是不切实际的。这使该问题难以直接优化。

4 CCAT 框架

为解决排序一致性问题, 本节我们首先引入“协同学生作为被测学生锚点”的概念, 然后阐明它们在选题和能力估计中的应用。最后, 我们对协同学生方法进行理论分析, 证明: 尽管被测学生在协同学生中的排名未必完全准确, 但当有足够多的协同学生时, CAT 实现排序一致性的概率至少能达到 $1 - \delta$ 。

定义 2 (协同学生)。协同学生指一组 M 名学生, 被用作锚点来辅助对考生排序 [44, 45]。可以假设协同学生已完成题库 Q 中所有题目的作答, 他们在题库 Q 或子集 S ($|S| = T$) 上的能力为 θ_c^* 和 θ_c^T , 这些都很容易获得。

由于测试过程中任意两位学生之间不存在信息披露, 我们无法直接干预他们的排序关系。尽管如此, 由于协同学生回答了题库中的每一道题, 我们可以假设: 在测试中, 每位协同学生都会“陪”被测学生回答相同的题目。这有助于在被测学生之间建立关系。

具体地, 当两个学生 A 和 B 回答不同的题目集 (比如 A 答 q_1, q_2, q_3 , B 答 q_4, q_5, q_6) 时, 由于题目不同可能产生不一致。然而, 每位协同学生都能把自己的表现与 A、B 两人比较。例如, 一位协同学生可以在 q_1, q_2, q_3 上与 A 比、在 q_4, q_5, q_6 上与 B 比。如果该协同学生发现自己的能力超过 A 但不及 B, 她就为准确排序 A、B 提供了有价值的信息。

4.1 问题近似 (Problem Approximation)

如前所述, 我们的目标是通过与协同学生比较来建立被测学生之间的排序关系。显然, 确保被测学生间排序一致性的第一步, 是在协同学生和被测学生之间建立排序一致性:

$$\max_{|S|=T} P(\theta^T > \theta_c^T \mid \theta^* > \theta_c^*, S). \quad (4)$$

第 2 节中我们概述了 IRT 中 θ 的估计方法 (式 (1))。利用该公式, 我们可以导出下面的引理, 它有助于简化优化目标。

引理 1。 给定两个学生, 他们在 S ($|S| = T$) 上的作答为 $y_1, y_2, \dots, y_T$ 和 $\tilde{y}_1, \tilde{y}_2, \dots, \tilde{y}_T$, 他们在 S 上由 IRT (参数 a_i, b_i) 估计出的测试能力为 $\theta^T, \tilde{\theta}^T$ 。我们可以证明: 若 $(\theta^T - \tilde{\theta}^T) > 0$, 则 $\sum_{i=1}^T a_i(y_i - \tilde{y}_i) > 0$, 反之亦然。

引理 1 表明: 若两个学生在相同的题目子集上接受测试, 则项 $\sum_{i=1}^T a_i(y_i - y_i^c)$ 可用来替代 $\theta^T - \theta_c^T$, 因为它们符号相同 (同正或同负)。这一替换让目标更精简:

$$P(\theta^T > \theta_c^T \mid \theta^* > \theta_c^*, S) = P\left(\sum_{q_i \in S} a_i(y_i - y_i^c) > 0 \mid S, \theta^* > \theta_c^*\right) \Rightarrow \sum_{q_i \in S} a_i P(y_i > y_i^c \mid \theta^* > \theta_c^*) = \sum_{q_i \in S} R(q_i \mid \theta^* > \theta_c^*), \quad (5)$$

其中 $R(q_i \mid \theta^* > \theta_c^*) = a_i P(y_i = 1 \mid \theta^*) P(y_i^c = 0 \mid \theta^* > \theta_c^*)$, y_j^c 和 y_j 分别表示协同学生和被测学生对题目 j 的作答。上述推导假设题库 Q 中所有题目相互独立, 且高能力学生在每道题上都应表现良好。这个公式表明: 对每位被测学生而言, 回答那些能力更弱的学生答不对的题目, 能增强排序一致性。

考虑到协同学生与被测学生之间的不对称性, 我们还需考虑协同学生能力强于被测学生的情形:

$$P(\theta^T < \theta_c^T \mid \theta^* < \theta_c^*, S) \Rightarrow \sum_{q_i \in S} R(q_i \mid \theta^* < \theta_c^*), \quad (6)$$

其中 $R(q_i \mid \theta^* < \theta_c^*) = a_i P(y_i = 0 \mid \theta^*) P(y_i^c = 1 \mid \theta^* < \theta_c^*)$ 。与式 (5) 类似, 我们的目标是避免让学生在那些“能力更高的学生都可能答不准”的题目上接受评估。利用式 (5) 和式 (6) 的约束, 我们可以基于协同学生为被测学生选择特定题目:

$$q_t = \arg \max_{q \in Q \setminus S_{t-1}} P(\theta^* < \theta_c^*) R(q \mid \theta^* < \theta_c^*) + P(\theta^* > \theta_c^*) R(q \mid \theta^* > \theta_c^*). \quad (7)$$

这里 S_{t-1} 表示截至第 t 步已选出的题目子集, $S_t = S_{t-1} \cup \{q_t\}$, q_t 是第 t 步选出的题目。该公式旨在找到那些能力更高的协同学生很可能答对、而被测学生可能答不出的题目; 同时也找出那些能力更低的协同学生不太可能答对、而被测学生可能答对的题目。这种选择方法增强原本强的学生的表现、削弱较弱学生的表现, 帮助被测学生确定自己在协同学生中的排名。

测试后, 被测学生收到他们在 S 上的表现, 以及与每位协同学生的排序关系。在本研究中, 我们用被测学生在协同学生中的平均排序关系作为其测试结果:

$$\hat{\theta}^T = \mathbb{E}[\mathbb{I}(\theta^T > \theta_c^T)] = \mathbb{E}\left[\mathbb{I}\left(\sum_{i \in S} a_i(y_i - y_i^c) > 0\right)\right], \quad (8)$$

其中 $\mathbb{I}(\cdot)$ 是指示函数。由于被测学生能力的不确定性、以及测试过程中协同学生作答的不完整, 我们在附录 C 中进一步对该优化问题做近似和阐述。

算法 1: CCAT 框架 > 输入: 题库 Q 、IRT 估计方法。> 初始化: 随机初始化被测学生能力 θ^0 , 初始化题目子集 $S_t \leftarrow \emptyset$ 、被测学生记录 $Y \leftarrow \emptyset$ 、协同学生记录 $Y^c \leftarrow \emptyset$ 。> **for** $t = 1$ **to** T **do** > 1. 选题: $q_t \leftarrow \arg \max_{q \in Q \setminus S_{t-1}} P(\theta^* < \theta_c^*) R(q \mid \theta^* < \theta_c^*) + P(\theta^* > \theta_c^*) R(q \mid \theta^* > \theta_c^*)$, $S_t \leftarrow S_{t-1} \cup \{q_t\}$ 。> 2. 获取被测学生和协同学生的作答: $Y \leftarrow Y \cup \{y_t\}$, $Y^c \leftarrow Y^c \cup \{\{y_{1t}^c, \dots, y_{Mt}^c\}\}$ 。> 3. 更新学生能力估计 θ : $\theta^t = \arg \min_{\theta \in \Theta} -\log p_{\theta}(q_i, y_i)$ 。> 计算被测学生在协同学生中的排名: $\hat{\theta}^T \leftarrow \frac{1}{M} \sum_{i=1}^M \sigma\left(\sum_{t=1}^T a_i(y_{it}^c - y_t)\right)$ 。> 输出: 学生最终的估计排序能力 $\hat{\theta}^T$ 。

4.2 CCAT 的理论分析

通过上述推导与近似, 我们给出了 CCAT 的选题算法和估计方法, 它能确保协同学生与被测学生之间高度的排序一致性。这一排序随后被用来为被测学生提供测试结果, 记为 $\hat{\theta}^T$ 。关于能力估计中的测试结果 $\hat{\theta}^T$, 我们有如下结论:

定理 1. 给定两个学生 A 和 B，他们与协同学生的关系为 $r_1, r_2, \dots, r_M$ 和 $\tilde{r}_1, \tilde{r}_2, \dots, \tilde{r}_M$, $r_i \in \{0, 1\}$ 表示在给定测试中学生 A 是否胜过协同学生 i 。假设学生 A 胜过协同学生 i 的概率为 $P(r_i = 1) = \zeta_1$ ，学生 B 胜过协同学生 i 的概率为 $P(\tilde{r}_i = 1) = \zeta_2$ 。则可得出如下结论：

(1) 若提供 $M > \frac{\ln \frac{1}{\delta}}{2(\zeta_1 - \zeta_2)^2}$ 名协同学生，则排序一致性的预测至少为 $1 - \delta$ 。

(2) 当测试题目数 T 较小时，对被测学生与协同学生之间排序关系的评估可能产生不准确的结果。假设错误概率为 $\rho \in (0, 0.5)$ ，我们仍可推出：若提供 $M > \frac{\ln \frac{1}{\delta}}{2(1-2\rho)^2(\zeta_1 - \zeta_2)^2}$ 名协同学生，则排序一致性的预测至少为 $1 - \delta$ 。

由定理 1 可推断：拥有足够数量的协同学生，即便被测学生与协同学生之间存在排名误差，也能确保所有被测学生之间能力排序的一致。同时，我们的选题算法实际上通过最大化协同学生与被测学生之间的排序一致性来降低排名误差 ρ ，从而在理论上提升排序一致性。

算法 1 给出了 CCAT 框架的伪代码。在选题阶段，我们提出的选题算法复杂度为 $O(|Q|TMN)$ ，因为它需要为每位被测学生以 $O(|Q|M)$ 的复杂度从题库 Q 中选出最合适的题目。这里 T 是测试总题数， M 是协同学生数， N 是被测学生数。可以看到，CCAT 的时间复杂度与数据驱动 CAT 方法的推理速度相当。然而 CCAT 通过存储协同学生规避了耗时的训练过程。尽管这确实增加了空间复杂度，但它显著减少了训练所需时间，并消除了因系统变化而反复训练模型的需要。

5 实验

本节中，为证明 CCAT 在排序一致性上的有效性，我们在两个真实世界数据集上将 CCAT 在排序一致性指标上的表现与其他基线方法比较。此外，我们进行了一个案例研究，比较 IRT 与协同能力估计，更深入地洞察协同能力估计如何带来排序一致性。

5.1 实验设置

评估方法。 目标是确保被测学生在子集 S 上的测试结果排序与他们在题库 Q 全部题目上的能力排序一致。本研究中，我们使用被测学生在子集 S 上的能力与在题库 Q 上的能力之间的 Kendall 系数 [46]，称之为**类内排序一致性 (intra-class ranking consistency)**：

$$K = \frac{2}{N(N-1)} \sum_{1 \leq i < j \leq N} U_{ij}, \quad U_{ij} = \begin{cases} 1 & (\theta_i^* - \theta_j^*)(\theta_i^T - \theta_j^T) \geq 0 \\ 0 & (\theta_i^* - \theta_j^*)(\theta_i^T - \theta_j^T) < 0 \end{cases}. \quad (9)$$

对任意两个学生，若其测试结果排序与真实能力一致，则该指标记为 1；反之若测试结果排序与真实能力相悖，则记为 0。

类似地，我们也可以考察被测学生与协同学生之间的排序一致性，称之为**类间排序一致性 (inter-class ranking consistency)**：

$$K = \frac{1}{MN} \sum_{i=1}^N \sum_{j=1}^M U_{ij}, \quad (10)$$

其中 M 、 N 分别是协同学生和被测学生的数量。此外，我们在正文中还讨论 AUC、ACC 指标，NDCG 指标在附录 D.2 中作为参考指标 [47, 48, 49]。

数据集。 我们分别在两个教育基准数据集 NIPS-EDU 和 JUNYI 上做实验。NIPS-EDU [50] 是从 Eedi 收集的学生答题交互数据集，用于 NeurIPS 2020 教育挑战赛。JUNYI [51] 源自 junyiacademy.org，提供 2018—2019 年间某课程注册学生的数百万条作答数据。选这两个数据集是因为其学生群体庞大、每位学生作答量大，便于构建协同学生集。在接下来的实验中，我们过滤掉作答少于 50 次的学生和作答少于 50 次的题目，然后按 4:1 把数据集划分为训练集（协同学生）和测试集（被测学生）。代码见 github: <https://github.com/bigdata-ustc/CCAT>。

对比方法。 本文主要讨论测试中的排序一致性，因此我们采用能给出有实际意义结果 θ 的 IRT。如我们所知，蒙特卡洛采样 (MCMC) 和梯度下降 (GD) 方法都能估计 IRT 参数 a_i, b_i 。本实验中，我们分别用 GD 和 MCMC 估计的 IRT 模型来进行选题和学生估计。在选题算法方面，我们选取以下 SOTA 算法作为基线：**Random** 每步为学生随机选一题，作为评估其他算法改进的基准。**FSI** [32] 和 **KLI** [33] 选择 Fisher/KL 信息最高的题目，该信息衡量回答一题能获得多少学生能力 θ 的信息。**MAAT** [34] 用主动学习方法衡量每道题给测试带来的信息。**BECA** [40] 把 CAT 选题看作核心集 (coreset) 选择问题，并给出近似求解策略。**BOBCAT** [35] 提出基于双层优化的框架，同步优化选题算法和估计模型。**NCAT** [36] 利用强化学习思想，用数据驱动方法直接优化 CAT 测试结果的准确性。

5.2 结果与讨论

为证明 CCAT 框架的优越性，我们分别在用 GD 和 MCMC 估计的 IRT 上比较各种 CAT 选题算法。得到如下结论：

类内排序一致性表现。表 1 表明：在采用协同能力估计 (X-C) 后，方法 X 在每一步都一致地增强了排序一致性。这一发现与定理 1 相符，证实了 CCAT 中协同能力估计的有效性。此外，比较方法 X-C 时，无论用 MCMC 还是 GD 估计 IRT 模型参数，我们的 CCAT 算法在两个公开数据集上都展现出更优的排序一致性。特别地，CCAT 在测试题目更少时改进更显著，优于其他方法。随着测试步数增加，FSI-C 方法提升排序一致性的速度更快，最终达到高度一致——这归功于 FSI 方法能选出区分度更高、作答更不确定的题目，使 FSI-C 能及时调整排序不一致的学生。然而由于 FSI 方法对当前能力敏感，在题目较少时表现不佳。这些结果证实，无论从测试时长还是估计模型来看，CCAT 框架对 CAT 排序普遍有效。

类间排序一致性表现。在每个基线选题算法完成后，我们用协同能力估计得到的排序结果替换原先直接用 IRT 做参数估计得到的结果。从表 1 和表 2 可见，被测学生在协同学生中的排序一致性（表 2）与被测学生间的排序一致性（表 1）之间存在正相关，尤其在使用协同能力估计方法时，CCAT 方法在两张表中都处于领先地位，FSI 方法仅次于 CCAT。这也解释了我们为何要在上文优化协同学生间的排序一致性。

表 1 / 表 2：不同选题算法在类内/类间排序一致性上的表现 (NIPS-EDU、JUNYI 两数据集 $\times$ GD/MCMC $\times$ 5/10/15/20 步)。（此处为原文表格，结构复杂，未逐一转录数值。要点：X-C 普遍优于 X；CCAT 在绝大多数设置下最优，例如 JUNYI/GD 上 CCAT 在第 20 步达 0.9066，高于所有基线；题目少时 CCAT 优势最明显。）

ACC & AUC。图 3 展示了不同选题算法在用不同方法估计的 IRT 上得到的 ACC、AUC 指标。可见 CCAT 相比其他 CAT 选题算法在 ACC、AUC 指标上并无显著差异，这说明 CCAT 在增强排序一致性的同时保持了 CAT 测试结果的准确性。此外，用 MCMC 估计的 IRT 显著优于用 GD 和 BOBCAT 估计的——这也解释了为何表 1 中同一选题算法在 MCMC 得到的 IRT 模型上表现更好。另外，在 GD 上提出的选题算法（尤其是 NCAT 这类数据驱动方法）对 MCMC 估计的 IRT 效率不高。这意味着这些方法或许并不有效，而只是能弥补用 GD 估计 IRT 的缺陷。然而像 BOBCAT 这种同时训练 IRT 模型和选题算法的方法，可能给 IRT 模型引入偏差。如图 3 所示，尽管它在特定优化目标 (ACC@20) 上优于所有梯度下降方法，但在其他时刻可能损害准确性，并破坏 IRT 模型在能力估计上的稳定性，从而在排序问题上表现欠佳。综合上述分析以及 MCMC 方法的稳定性，我们认为：在 IRT 参数估计上，MCMC 比 GD 方法更合适，尤其在考虑 CAT 排序一致性时。

图 3：不同选题算法在 NIPS-EDU 上、对用 MCMC 和 GD 估计的 IRT 模型的 ACC 和 AUC 表现。

案例研究。为展示 CCAT 的优越性及其机制，我们从每个数据集中选取 10 对学生，进行如图 4 所示的两个可视化实验。该图比较了 IRT 与 CCAT 方法估计出的学生对之间的能力差距。具体地，对每对学生，我们在每一时刻用真实能力较低者的估计能力减去真实能力较高者的估计能力。差距越大表明估计方法的区分能力越好。当数值小于 0（红色）时，表示该时刻出现排序不一致。我们发现，尽管选题算法不变，CCAT 产生更大的区分度和更准确的排序，尤其在测试步数较少时。

图 4：IRT 方法与 CCAT 方法在能力估计差异上的可视化。

我们还分析了这 20 对学生上协同学生的估计结果，揭示出协同能力估计方法本质上相当于协同学生对被测学生的一个投票过程。此外，我们可视化了随着测试题目增多，每位协同学生对两位学生的判断如何逐渐变得清晰。更多细节请参阅附录 D.2。

6 结论

本文从学生的视角探讨了计算机自适应测试 (CAT) 的目标，把 CAT 的挑战重新表述为排序任务，并为这些任务提出了具体目标。为应对“学生独立作答导致在测试过程中难以影响排名”的挑战，我们引入了协同计算机自适应测试 (CCAT) 框架。该方法利用协同学生交互来辅助测试中的选题和估计。在两个真实世界数据集上的实验表明，CCAT 提升了排序一致性。尽管结果可喜，我们的方法仍有固有局限，尤其在更长的测试序列上。未来工作中，我们希望改进模型以解决这些局限，并增强 CCAT 框架在多样测试场景中的鲁棒性与有效性。

致谢

本研究受国家重点研发计划 (No. 2021YFF0901003)、安徽省重点研发计划等资助 (详见原文)。

参考文献 (References) 按约定未翻译，详见原文。