

由分层结构搜索驱动的统一自适应测试系统 (A Unified Adaptive Testing System Enabled by Hierarchical Structure Search)

原文: uats-unified-adaptive-testing-structure-search_15.pdf · 译者: Claude · 译于 2026-06-27 术语对照: 自适应测试系统 (Adaptive Testing System, ATS)、计算机化自适应测试 (Computerized Adaptive Testing, CAT)、多阶段测试 (Multistage Testing, MST)、项目反应理论 (Item Response Theory, IRT)、认知诊断模型 (Cognitive Diagnosis Model)、能力估计 (ability estimation)、题目选择 (item/question selection)、双层优化 (bilevel optimization)、结构搜索 (structure search)

摘要

自适应测试系统 (Adaptive Testing System, ATS) 是一种很有前景的测试模式, 在 GRE 等标准化考试中得到了广泛使用。它通过根据个体能力水平动态调整题目, 提供个性化的能力评估。与传统考试相比, ATS 能在提升能力估计精度的同时, 减少所需作答的题目数量。尽管 ATS 存在多种测试形式, 分别面向不同测试场景下的适应性需求, 但目前明显缺少一个统一的框架来对它们进行建模。本文提出一个统一的、数据驱动的 ATS 框架, 把各种测试形式概念化为一个分层的测试结构搜索 (hierarchical test structure search) 问题。该框架可以直接从数据中学习, 为每个学生求解最优题目, 无需人工设计测试方案。我们提出的求解算法在估计误差与收敛性上都带有理论保证。实验结果表明, 本框架在保持评估精度的同时, 平均减少 20% 的题量, 并提升了训练的稳定性。

1. 引言

自适应测试系统 (ATS) 是智能教育领域的一项开创性应用, 提供个性化、高效的评估体验 (Chen 等, 2015; Vie 等, 2017)。与传统的纸笔考试 (对所有考生统一给出相同题目) 不同, ATS 会根据个体能力水平动态调整题目。这种方式不仅提升了评估精度, 同时也减少了所需题量, 从而提高了测试效率。如今 ATS 已被多邻国测试 (Duolingo Test)、GRE、TOEFL、GMAT 等高利害考试所采用。

ATS 是学生与系统之间的交互式过程。如图 1 所示, 在每一个测试步骤, 认知诊断模型 (Wang 等, 2023a) ——例如以心理测量学为基础的用户模型项目反应理论 (IRT) (Embretson & Reise, 2013) ——首先通过分析之前的作答记录估计学生当前的能力, 随后选择算法 (Selection Algorithm) 基于强化学习 (Zhuang 等, 2022) 或某些信息量指标 (Chang & Ying, 1996; Bi 等, 2020) 从题库中选出下一批题目, 这些指标通常致力于让题目难度与学生估计能力相匹配 (Lord, 2012)。这一迭代循环一直进行, 直到满足停止规则为止。ATS 的核心, 就是用尽可能少的题目尽可能精确地估计学生能力。

图 1: 传统 ATS 流程——在第 t 步, IRT 基于此前 t 步的作答记录估计当前能力 θ_t ; 随后选择算法基于当前估计能力 θ_t 选出一批题目 Q_{t+1} 。

当前的 ATS 按测试形式可分为两个研究方向: 计算机化自适应测试 (CAT) 与多阶段测试 (MST)。一篇近期的综述 (Liu 等, 2024) 详尽讨论了这两类方法: CAT 在每一步只选一道题, 要求学生答完一题后才能进入下一题 (Van der Linden & Pashley, 2009); 而 MST 在每一步选一组题目 (一个题组 testlet)。这些题组由专家预先设定, 通常包含难度相近、内容多样的题目 (Sari 等, 2016)。CAT 以其细粒度的方式而以估计精确著称, MST 则能融入专家见解、提供更全面的测试体验 (Magis 等, 2017)。尽管二者都服务于自适应评估这一核心目标, 但由于其适应性粒度不同——CAT 在题目级别、MST 在题组级别——目前二者各自独立运作。

因此, 显然需要一个统一框架, 能灵活地同时建模 CAT 与 MST, 将这两套方法论协调进单一的 ATS 方案之中。这样一个统一框架既能受益于 CAT 的高适应性, 又能纳入 MST 题组内部的组合效应, 更关键的是, 它能避免专家设计题组那一耗时耗力的过程。然而, 开发这样一个统一框架并非易事。例如: 用什么机制来确定每一步该选多少道题, 又无需人工干预? 如何直接从可用数据中自动优化所需的测试形式/结构? 又该如何刻画自动生成的题组内题目之间的相似性与组合效应? 这些挑战凸显了所面对决策问题的复杂性。

本文提出一个数据驱动的框架, 将 ATS 视为一个结构搜索 (structure search) 问题。我们把每一道潜在题目设想为一张网络图中的一个节点, 目标是为每个学生在图中搜索出最有效的路径——也就是边 (edge)。它实现了对题目选择或题组构建的系统化、自动化处理。我们的贡献如下:

- 我们首次将各种形式的 ATS 重新定义为一个统一的测试结构搜索问题。它是数据驱动的, 能动态地引导题目选择, 无需人工专家设计。
- 我们设计了一个可微分、分层的优化算法来选取合适的题目。该方法能高效、精确地优化, 并在收敛性与梯度估计误差上带有理论保证。
- 该框架在多个真实数据集上展现出优越性能, 在精度与效率上都超越其他 ATS 方法。值得注意的是, 与其他数据驱动方法相比, 它在训练中表现出更稳定的收敛性。

2. 背景与相关工作

自适应测试系统 (ATS) 是一个迭代过程, 主要由两部分组成: 项目反应理论与题目选择算法。下面分别介绍:

(1) 项目反应理论 (IRT)。IRT 植根于心理测量学与认知科学 (Ackerman 等, 2003; Huang 等, 2020), 它利用题目与学生的特征来预测作答结果 (对或错)。最简单的形式是单参数逻辑斯蒂 (1PL) 模型:

$$\Pr(\text{学生答对题目 } j) = \sigma(\theta - \beta_j),$$

其中 $\sigma(\cdot)$ 是逻辑斯蒂函数, $\beta \in \mathbb{R}$ 表示每道题预先标定的参数, 称为**难度 (difficulty)**, $\theta \in \mathbb{R}$ 是待估计的学生潜在能力。近期已有许多研究引入神经网络来建模学生与题目的交互 (Cheng 等, 2019; Gao 等, 2022; Wang 等, 2023a; Shen 等, 2024)。

(2) 选择算法。 ATS 的目的是在保持精度的前提下用尽量少的题目估计学生能力, 因此选择算法是关键一步。传统 ATS 从两个视角看待这一问题: **适应性 (adaptability)** 与 **灵活性 (flexibility)**。CAT 更看重适应性, 旨在得到一份最优测试 (Meijer & Nering, 1999), 它每一步只选一道题。围绕基于信息量的选择 (Lord, 2012; Chang & Ying, 1996; Rudner, 2002; van der Linden, 1998; Veerkamp & Berger, 1997; Kang 等, 2017; Ma 等, 2023)、数据驱动的方法 (Nurakhmetov, 2019; Zhuang 等, 2022; Ghosh & Lan, 2021; Wang 等, 2023b; Li 等, 2023; Yu 等, 2023) 以及其他方法 (Veldkamp & Verschoor, 2019; Gilavert & Freire, 2022; Feng 等, 2023; Mujtaba & Mahapatra, 2021) 已有大量提出。然而这类算法对学生施加了限制: 一次只选一道题, 约束了学生的解题习惯 (Mead, 2006)。在这一点上, MST 能通过一次推荐一组题目来解决该问题, 大大增强了灵活性 (Sari 等, 2016), 学生在一步内可以自由选择作答题目。然而该方式也有缺点: 它要求作答更多题目, 并且需要专家设计题组 (Magis 等, 2017)。目前缺少一个能统一地解决适应性与灵活性问题的综合方法。

本文提出一个统一的 ATS 框架, 称为 **UATS**, 它解决了 CAT 与 MST 各自面对的挑战。该框架同时涵盖 CAT 与 MST, 能在测试过程中自动组合题目包 (question package)。我们的研究发现, UATS 框架在理论分析与实验评估中都表现卓越, 超越了 CAT 与 MST 方法的能力。

3. 任务形式化

自适应测试系统 (ATS) 的目标, 是依次向学生呈现一段最优定制的题目或题组序列。本质上, 在每一步过程中, 都会为学生选出最合适的一组题目 $Q_t = \{q_t^1, q_t^2, \dots, q_t^m\}$ 用于施测。对于 CAT, 集合大小 $m = 1$, 即一次选一道题 q ; 对于 MST, 则选出一组大小为 m 的题目 (题组)。ATS 的终极目标有两点: (1) 为每个学生选出有价值、最贴合的题目, 最小化测试长度; (2) 利用学生的作答结果, 在测试结束时精确估计其真实能力¹。

为达成这些目标, ATS 包含两个关键组件: 项目反应理论 (IRT) 与选择算法。如图 1 所示, 在每个测试步骤, ATS 首先用 IRT 基于此前 t 个题目集合的作答来估计学生当前能力 θ_t 。这里常用二元交叉熵损失: 给定此前 t 个集合的作答 $D_t = \{(Q_1, Y_1), \dots, (Q_t, Y_t)\}$, 经验损失为

$$L(\theta, D_t) = \sum_{i=1}^t -\log p_\theta(Q_i, Y_i), \quad (1)$$

其中 $Y_i = \{y_i^1, y_i^2, \dots, y_i^m\}$ 表示学生对 Q_i 的作答标签, $y_i^m = 1$ 表示答对题目 q^m , 否则为 0; $p_\theta(Q, Y)$ 表示能力为 θ 的学生作答出 (Q, Y) 的概率, 其具体形式由 IRT 决定。于是, 当前的能力估计 θ_t 通过最小化损失函数 $L(\theta, D_t)$ 得到: $\theta_t = \arg \min_\theta L(\theta, D_t)$ 。

随后, 选择算法以学生当前能力估计 θ_t 为引导, 从题库中挑选下一题目集合 Q_{t+1} : $Q_{t+1} \sim \pi(\theta_t)$, 其中 π 可以是各种衡量“该题目集合能提供多少关于学生能力的信息”的准则 (Lord, 2012; Chang & Ying, 1996), 也可以是由数据驱动方法 (例如强化学习) 训练出的策略的输出 (Zhuang 等, 2022; Ghosh & Lan, 2021)。

评估方法: 数据集中无法获得学生真实能力的真值 (ground truth), 这给能力估计的评估带来挑战。为此, 一种常见做法是把每个学生的数据随机划分为**查询集 (query set)** D_u 与**支撑集 (support set)** D_t (Ghosh & Lan, 2021)。支撑集 D_t 用于模拟题目选择过程并估计最终能力值 θ_T , 而查询集 D_u 用于评估这一估计的准确性。可用交叉熵 $L(\theta_T, D_u)$ 或诸如预测准确率 (accuracy) 之类的分类指标进行评估。细节见第 5 节。

¹ ATS 的一个重要假设 (Chang, 2015) 是: 学生的真实能力水平 θ^* 在整个测试过程中保持不变。

4. 测试结构搜索

在上述传统 ATS 中, 题目选择算法基于学生当前能力估计 θ_t , 在每一步 t 确定最合适的题目集合 Q_t 供学生作答。然而, 由于测试场景的多样性, 每一步选出的题目数量可能不同。这种可变性带来了挑战: 它要求考虑影响测试的各种因素, 例如题目相似性与组合效应。这显著增加了选择算法的复杂度, 难以单纯靠专家干预 (即预先定义候选题组 testlet) 来实现。这种人工方式耗时耗力, 且无法适应更复杂的测试场景。

为解决这一问题, 本文提出一种数据驱动的方法, 将不同测试形式建模为一个统一的**结构搜索问题**。具体来说, 从全局视角看, 自适应测试可被视为一个从初始节点到终止节点的测试结构搜索问题。图 2 左侧展示了这一概念。题目节点数量 M 决定了每一步选出题目的最大数量, 节点之间不同颜色的边代表不同的题目。图 2 右侧的 CAT 情形中, 每步只选一道题, 于是相邻测试步骤之间只有一条边; 另一种是 MST 情形, 每步选出 M 道题, 于是测试节点之间有 M 条边。

图 2: 左侧结构展示了我们的 UATS 框架——每一层从 M 个题目池中选題, 每条边对应来自某个题目节点的题目, 题目选择被转化为一个结构搜索问题。右侧示意展示了在本场景下 CAT 与 MST 的实现: CAT 每次只选一道题, MST 每次选一组題。

4.1 问题定义

从测试节点 t 到题目节点 m 的每条有向边由 $\{x_q^{(t,m)}\}_{q \in V}$ 表示, 且 $x_q^{(t,m)} \in \{0, 1\}$, 其中 1 表示该边被选入最终测试结构, 0 表示未选。对每一对节点 (t, m) , 一共有 $|V| + 1$ 条边, 包括题库 V 中所有题目, 外加一条额外的零边 (**zero edge**) (表示不选)。最终结构中每对节点只选一条边。

为了直接从大规模学生作答数据中优化测试结构, 每个学生的作答数据进一步被随机划分为查询集 D_u 与支撑集 D_t 。用能力估计损失函数基于查询集 D_u 来优化测试结构, 而支撑集 D_t 则用于在给定结构参数下优化最优能力估计:

$$\min_x L(\theta_t^*(x), D_u) \quad (2)$$

$$\text{s.t. } \theta_t^*(x) = \arg \min_{\theta} L(\theta, D_t(x)). \quad (3)$$

其中 $\theta_t(x)$ 表示学生基于“结构参数 x 所对应题目”上的作答而得到的最终能力估计。因此, 在每一步 t , 所选题目 q_t^m 由下式确定:

$$q_t^m = \arg \max_{q \in V} x_q^{(t,m)} \quad (4)$$

最终, 结构参数 x 等于 1 所对应的题目被选出, 组成最终的题目集合 $Q_t = \{q_t^1, q_t^2, \dots, q_t^M\}$ 。

显然, 结构参数 x 是离散且不可微的。我们进一步对离散结构参数做一个**松弛 (relaxation)**: 在节点 t 与节点 m 之间定义一组权重参数, 记为 $\{\alpha_q^{(t,m)}\}_{q \in V}$ 。由此得到 ATS 的统一定义, 即**测试结构搜索问题**:

定义 4.1 (ATS 的统一定义)。不同形式的自适应测试系统都可统一为一个测试结构搜索问题。为实现可微优化, 定义一组与结构相关的权重参数 $\{\alpha_q^{(t,m)}\}_{q \in V}$:

$$\min_{\alpha} L(\theta_t^*(\alpha), D_u) \quad (5)$$

$$\text{s.t. } \theta_t^*(\alpha) = \arg \min_{\theta} L(\theta, D_t(\alpha)). \quad (6)$$

最终目标是找到最优权重参数 α^* , 而最优题目的具体选取可用 Softmax 函数确定:

$$q_t^m = \sum_{q \in V} \frac{\exp(\alpha_q^{(t,m)})}{\sum_{q' \in V} \exp(\alpha_{q'}^{(t,m)})} q.$$

这里 q 指题目的参数, 例如难度与区分度。

这样, 通过直接从大规模数据中优化这个可扩展、灵活的 ATS 框架, 就避免了人工设计的需要, 并能适应复杂的测试场景。当我们用 IRT 作为认知诊断模型时, 可以利用 IRT 的强凸 (strongly convex) 性质 (Lord, 2012), 得到该优化问题的一些理想性质, 如下所示:

引理 4.2. 当使用 IRT 作为学生作答函数时, 内层函数 (式 6) 与外层函数 (式 5) 具有以下性质:

1. 内层函数关于 θ 是强凸的, 且其关于 θ 与 α 的导数都是 L -Lipschitz 连续的; 其二阶导数同样 Lipschitz。具体地, $\nabla_{\alpha} \nabla_{\theta} L(\theta, D_t(\alpha))$ 是 τ -Lipschitz 连续的, $\nabla_{\theta}^2 L(\theta, D_t(\alpha))$ 是 ρ -Lipschitz 连续的。
2. 外层函数是 M -Lipschitz 连续的, 其关于 θ 的导数是 L -Lipschitz 连续的, 关于 α 的导数是 W -Lipschitz 连续的。

引理的所有证明见附录。引理 4.2.1 描述了内层函数的性质, 内层函数代表评估过程中对学生能力的建模。强凸性保证了函数在局部范围内的单调性与收敛性, 这对优化算法的收敛速度至关重要; 此外, 关于参数的 Lipschitz 连续性保证了函数的光滑与稳定, 使优化算法能在参数空间中高效搜索最优解。引理 4.2.2 描述了外层函数的性质, 外层函数代表评估过程中的整体优化目标, 其 Lipschitz 连续性保证了优化过程的稳定与可行, 而其关于参数的导数的连续性, 则保证了梯度下降算法在参数空间中的有效性。这些优良性质为我们的优化理论提供了保障。

4.2 近似与优化

定义 4.1 的搜索过程同时考虑了参数选择的全局问题与学生的能力。它致力于优化最终结果，而这是在已知全局信息的条件下建立的。然而，直接求解上述问题是不可行的，因为 ATS 是序贯的 (sequential)：第 $t+1$ 题的作答依赖于第 t 题的作答。在实际应用中无法获得未来的作答数据，这意味着无法直接求解整个结构。

为解决这一问题，我们用贪心的分层结构搜索 (greedy hierarchical structure search) 来近似全局结构搜索问题。全局搜索是同时获得测试每一步的最优解，而贪心分层结构搜索旨在找出当前时刻最合适的题目。具体来说，在测试的第 t 步 ($t \in [1, 2, \dots, T]$)，学生能力估计为 θ_t ，题目选择参数为 α_t 。首先，基于学生此前各步的作答更新当前学生能力，直到收敛：

$$\theta_t^k = \theta_t^{k-1} - \gamma \nabla_{\theta} L(\theta, D_t(\alpha_t)) \quad (7)$$

这里 k 是迭代标识。给定学习率 γ ，式 (7) 将一直执行直到收敛到 θ_t^* 。这是在第 t 步得到学生能力估计的最优解。基于收敛后的最优结果 θ_t^* ，更新当前的题目选择参数。值得注意的是，把内层函数训练到收敛会带来巨大开销。因此，我们不训练到收敛的最优解，而是用 K 次梯度更新作为近似，用 θ_t^K 代替 θ_t^* ，从而大大降低开销。

题目选择参数同样采用梯度下降形式，如式 (8) 所示：

$$\alpha_{t+1} = \alpha_t - \beta \nabla_{\alpha} L(\theta_t^K(\alpha_t), D_u) \quad (8)$$

这里 β 是 α 的学习率。经过梯度下降更新后，我们得到新参数 α_t 。下一题将基于 α_t 选出并加入 D_t ，从而实现贪心分层搜索过程。重复这些步骤进行训练，便是一个可行的优化方案。然而，用 θ_t^K 替代 θ_t^* 会引入一些误差 (Ji 等, 2021)。我们在下文给出该近似算法的误差上界。

定理 4.3 (梯度估计误差界)。假设学生作答函数是 μ -强凸的 (例如 IRT)。在测试第 t 步，设 B 是 $\|\theta_t^0(\alpha_t) - \theta_t^*(\alpha_t)\|$ 的上界，取学习率 $\gamma \leq \frac{1}{L}$ 。则有

$$\|\nabla_{\alpha} L(\theta_t^K(\alpha_t), D_u) - \nabla_{\alpha} L(\theta_t^*(\alpha_t), D_u)\| \leq \frac{B}{\mu} \left(L^2(1 - \gamma\mu)^K - \frac{M(\tau\mu + L\rho)}{\mu} (1 - \gamma\mu)^{\frac{K+1}{2}} \right) + \frac{ML(1 - \gamma\mu)^K}{\mu} + \frac{BM(\tau\mu + L\rho)}{\mu^2} \quad (9)$$

定理 4.3 表明，梯度的估计误差随内层循环迭代次数 K 呈指数衰减。定理 4.3 的证明直接刻画了梯度序列沿梯度下降路径收敛到 $\nabla_{\alpha} L(\theta_t^*(\alpha_t), D_u)$ 的速率，并表明随着 K 增大，误差趋于减小。

算法 1 描述了 UATS 框架的完整训练过程。它结合了上述动态题目选择算法与贪心分层结构搜索，目标是优化定义 4.1。在测试第 t 步，已有序列 D_t 。首先基于当前 α_t 选出题目 Q 并获得对应反馈 Y_t ，加入 D_t 后，基于 D_t 更新当前学生估计能力 θ_t ；随后用 θ_t 更新选择参数 α_{t+1} ，下一题将基于 α_{t+1} 选出。这便是整个训练过程。

算法 1: UATS 框架训练过程 输入：学习率 γ, β ，初始化参数 θ_0, α_0 1: while 未收敛 do 2: 随机采样一个小批量 (mini-batch) 学生，含查询集 D_u ，并初始化支撑集 $D_t = \{\}$ 3: for $t = 1, 2, \dots, T$ do 4: 基于 α_t 选出题目 Q_t : $Q_t \sim \pi(\alpha_t)$ 5: 学生对 Q_t 的作答为 Y_t 6: $D_t = D_t \cup \{Q_t, Y_t\}$ 7: 令 $\theta_t^0 = \theta_{t-1}^K$ 8: for $k = 1, 2, \dots, K$ do 9: $\theta_t^k \leftarrow \theta_t^{k-1} - \gamma \nabla_{\theta} L(\theta_t^{k-1}, D_t(\alpha_t))$ 10: end for 11: $\alpha_{t+1} \leftarrow \alpha_t - \beta \nabla_{\alpha} L(\theta_t^K(\alpha_t), D_u)$ 12: end for 13: end while

为进一步保证贪心逐层搜索算法的性质，我们提出以下理论，确保算法在训练过程中的梯度收敛。

定理 4.4 (收敛性分析)。取 $\gamma \leq \frac{1}{L}$ ， $\beta = \frac{1}{4W}$ 。则外层函数梯度的平均值满足以下定理：

$$\frac{1}{T} \sum_{t=0}^{T-1} \|\nabla L(\theta_t^*(\alpha_t), D_u)\|^2 \leq \frac{16W}{T} (L(\theta_0^*(\alpha_0), D_u) - L(\theta_T^*(\alpha_T), D_u)) + C \quad (10)$$

基于定理 4.4，我们证明了外层函数 T 个梯度的平均值存在一个上界，从而保证了收敛性。

5. 实验

本节对 UATS 框架进行定性分析与定量分析。该评估在三个真实数据集上展开，以考察我们方法的有效性。具体代码见：<https://github.com/bigdata-ustc/UATS>，我们将持续维护。

5.1 实验设置

数据集。我们使用了三组不同的教育数据：ASSIST 数据集 (Pardos 等, 2013)，包含来自 ASSISTments 在线辅导系统、与数学及知识概念题目相关的学生练习日志；NIPS-EDU 数据集 (Wang 等, 2021)，源自 NeurIPS 2020 教育挑战赛，包含学生在 NIPS-EDU 教育平台上对题目的作答；EXAM 数据集，由科大讯飞 (iFLYTEK Co., Ltd.) 提供，收集了初中生在数学考试上的记录。三个数据集的具体细节见表 1。

表 1：数据集统计

数据集	ASSISTments	NIPS-EDU	EXAM
学生数	2.3k	22.0k	9.2K
题目数	26.7k	27.6k	1.6k
交互数	325k	15M	133K

数据划分与评估方法。我们在所有数据集上进行 5 折交叉验证。每一折中，60% 的学生用于训练，20% 用于验证，20% 用于测试。每一折里，我们用验证集做早停 (early stopping) 以微调各方法参数。为缓解过拟合，我们在每个训练 epoch 开始时随机打乱这些划分。评估的性能指标包括准确率 (Accuracy) (Gao 等, 2021) 与受试者工作特征曲线下面积 (Area Under the ROC Curve, AUC) (Bradley, 1997)。所有实验在一块 NVIDIA V100 GPU 上运行。

对比方法。在评估 CAT 中的题目选择算法时，关键在于将其与合适的认知诊断模型配对。本研究比较两种模型的效果：项目反应理论 (IRT) 与神经认知诊断模型 (NeuralCDM) (Wang 等, 2023a)。NeuralCDM 可涵盖许多认知诊断模型，例如 MIRT (Reckase, 2009) 与矩阵分解 MF (Toscher & Jahrer, 2010; Desmarais, 2012)。用于比较的选择算法如下：

- **Random**：随机选题，作为相对若干基线衡量改进的参照。
- **FSI** (Lord, 2012)：利用最大 Fisher 信息量选题，仅当认知诊断模型为 IRT 时有效。
- **KLI** (Chang & Ying, 1996)：利用 Kullback-Leibler 信息量选题，同样依赖 IRT。
- **MAAT** (Bi 等, 2020)：采用主动学习 (active learning) (Krishnakumar, 2007) 方法衡量题目信息量来选题。
- **BECAT** (Zhuang 等, 2023)：将题目选择转化为最优子集的选择。
- **NCAT** (Zhuang 等, 2022)：采用强化学习方法训练一个 DQN 架构进行题目选择。
- **BOBCAT** (Ghosh & Lan, 2021)：采用元学习 (meta learning) 来学习题目选择算法。

图 3：(a) 与 (b) 分析了测试阶段数为 2、3、5 (每阶段最多选 2、3、5 道题) 时的 AUC 与 ACC 曲线。例如 MST-5 表示每阶段选 5 道题。

5.2 结果与讨论

本节比较两类经典自适应测试任务的性能，以评估所提 UATS 框架的有效性 & 效率。

5.2.1 学生成绩预测 (1) 与 CAT 基线比较。表 2 展示了 UATS 算法与其他模型设计在自适应测试场景下的比较。我们以测试长度 $T = 5, 10, 20$ 时的准确率 (ACC) 与曲线下面积 (AUC) 作为评估度量。UATS 框架在这三个数据集上取得了最佳的整体性能。在使用 IRT 模型时，EXAM 数据集表现最佳。相比原先的 SOTA 算法，AUC@20 的相对提升平均为 1.31%，ACC@20 为 0.71%。这一结果表明 UATS 框架能在考试结束时提供准确的能力估计。

(2) 与 MST 基线比较。MST 数据集严格保密，我们无从获取。因此我们参考自动化测试组卷 (Automated Test Assembly, ATA) (Breithaupt & Hare, 2007) 的自动出题方法来构建 MST 的测试模块。基于 NIPS-EDU 数据集，我们给出阶段总数为 2、3、5 的测试结果，每阶段的模块数为 2，每模块的题数为 2、3、5。图 3 用 ACC 与 AUC 比较了 UATS 与 MST。结果表明 UATS 框架在这些数据集上取得最佳整体性能，超越所有其他 MST 方法，ACC 平均提升 2.7%，AUC 平均提升 3.1%。这说明 UATS 框架能完美地纳入 MST，在提供灵活性的同时给出更准确的能力估计。

表 2：不同方法在学生成绩预测上的 ACC 与 AUC 指标。“—”表示基于信息量的选择算法无法应用于 NeuralCDM 模型。加粗文字表示相对最佳基线具有统计显著优势 (p 值 ≤ 0.01)。

(a) ASSIST 上的表现

方法	IRT ACC/AUC@5	@10	@20	NeuralCDM ACC/AUC@5	@10	@20
Random	65.54/66.37	65.72/66.51	66.13/66.80	64.99/66.20	65.18/66.37	65.60/66.66
FSI	65.76/66.51	66.16/66.78	66.74/67.23	—	—	—
KLI	65.76/66.48	66.13/66.76	66.75/67.21	—	—	—

方法	IRT ACC/AUC@5	@10	@20	NeuralCDM ACC/AUC@5	@10	@20
MAAT	65.65/66.46	65.90/66.77	66.18/67.07	65.15/66.12	65.34/66.41	65.64/66.59
BECAT	65.69/66.44	66.12/66.67	66.67/67.19	65.08/66.35	65.54/66.53	65.89/66.85
BOBCAT	65.99/67.45	66.12/67.83	66.63/67.87	66.76/67.03	67.52/67.87	68.20/68.05
NCAT	66.07/67.33	66.23/67.63	66.42/67.88	66.54/66.98	67.21/67.75	68.18/67.32
UATS	66.13/67.62	66.47/67.91	67.07/68.00	67.16/67.95	67.61/68.58	68.32/68.92

(b) NIPS-EDU 上的表现

方法	IRT ACC/AUC@5	@10	@20	NeuralCDM ACC/AUC@5	@10	@20
Random	63.17/68.49	64.24/69.88	65.66/72.19	63.57/68.12	64.46/69.83	66.28/72.16
FSI	63.70/69.26	64.74/71.08	66.19/73.48	—	—	—
KLI	63.67/69.22	64.72/71.06	66.26/73.57	—	—	—
MAAT	62.86/68.15	63.01/69.33	63.11/71.39	62.79/67.92	62.97/69.33	64.04/71.02
BECAT	63.40/68.52	64.66/69.90	65.85/72.73	62.81/67.98	64.13/69.56	66.52/73.23
BOBCAT	64.71/70.04	66.07/71.61	67.51/73.36	63.97/68.80	69.02/75.47	69.46/76.02
NCAT	64.37/69.36	65.55/71.33	66.20/72.88	63.27/67.81	66.87/72.76	68.95/76.34
UATS	63.37/71.79	65.98/73.46	68.17/74.85	64.43/69.79	68.94/75.65	70.15/76.86

(c) EXAM 上的表现

方法	IRT ACC/AUC@5	@10	@20	NeuralCDM ACC/AUC@5	@10	@20
Random	67.72/74.31	68.42/74.92	69.01/75.47	69.53/74.04	70.12/74.92	70.39/75.38
FSI	68.69/75.08	69.52/75.71	70.40/76.75	—	—	—
KLI	68.75/75.07	69.55/75.73	70.63/76.81	—	—	—
MAAT	68.35/74.72	69.79/75.32	69.98/76.24	70.17/74.84	70.51/75.24	71.37/76.26
BECAT	68.49/74.94	69.22/75.59	70.37/76.66	70.15/74.91	70.82/75.52	71.76/76.54
BOBCAT	72.28/76.03	72.57/76.55	73.80/77.32	72.39/76.19	73.62/76.55	74.08/77.58
NCAT	71.89/76.13	72.41/76.67	73.18/77.19	72.18/76.28	73.69/76.73	74.21/77.20
UATS	72.74/77.81	72.96/78.15	74.51/78.63	73.51/76.78	74.12/77.16	74.53/77.98

5.2.2 能力估计的模拟 能力估计的模拟是 ATS 中一项基础的评估技术 (Vie 等, 2017)。自适应测试的目标是准确估计学生能力。我们在 NIPS-EDU 数据集上做了能力估计的模拟实验。具体地, 我们用学生真实能力 θ_0 与第 t 步能力 θ_t 之间的均方误差 $E[\|\theta_t - \theta_0\|^2]$ 来衡量。由于真实能力 θ_0 未知, 我们用学生作答题库中全部题目的反馈来近似它。

图 4(a) 展示了基于 IRT 模型在 NIPS-EDU 数据集上、第 1 到 20 步各方法的指标。随着所选题目增多, 我们发现 UATS 方法始终取得更低的估计误差。一些不以估计精度为优先的隐式方法 (如 NCAT) 在初始阶段表现更好, 但 4 步之后仍落后于 UATS 框架。相比 SOTA 算法, UATS 能用更少题目达到相同估计误差——平均而言, 它能用少 20% 的题目达到相同估计精度, 体现出其在能力估计上的高效, 即缩短了测试长度。

我们还发现, UATS 框架中题目包 (question pack) 的数量会影响能力估计。从图 4(b) 可见, 随着题目包数量增加, 相同步数下的均方误差变高。这是因为更多的题目包意味着更接近 MST, 需要作答更多题目; 当题目包数量较少时, 则更接近 CAT, 意味着一个阶段内作答更少题目、适应性更强。因此, 有效控制题目包数量可以在 MST 与 CAT 之间取得平衡。

图 4: (a) 在 NIPS 数据集上不同基线方法与 UATS 的比较; (b) 单层中不同题目池数量对学生能力估计的影响; (c) UATS 框架与其他数据驱动方法在前 500 个 epoch 的比较。

5.2.3 收敛性质分析 为评估所提方法的收敛性, 我们将其训练曲线与几种流行的数据驱动方法进行比较。图 4(c) 展示了在 ASSISTment 数据集上前 500 个 epoch 的训练曲线。可以看到, 我们的方法不仅取得最佳结果, 而且在训练中稳步提升。相比其他方法, 它减小了波动, 实现了更稳定的收敛。结果表明, 我们的方法收敛更平滑、稳定性更高, 同时在训练中性能指标的变化也相对可控。

6. 结论

本文提出了 UATS 框架，为从真实世界在线教育数据中学习选择算法提供了一种统一方法。该框架涵盖了现有的自适应测试框架，包括计算机化自适应测试 (CAT) 与多阶段测试 (MST)。具体来说，为克服 CAT 对学生作答的限制以及 MST 对专家预设的要求，我们将它们建模为一个结构搜索问题，并在有效的深度学习环境中解决了这些限制。此外，我们提出了一种动态、可微的选择算法，将全局搜索转化为贪心搜索问题，并给出了收敛性证明。大量实验表明，UATS 框架兼顾了适应性与灵活性，能准确测量学生熟练度并缩短测试长度。而且，与其他数据驱动框架相比，我们的方法在训练中表现出更强的稳定性。

影响声明

在自适应测试系统中，不同学生可能被推荐不同题目，这引发了对公平性的担忧。本文聚焦于提出一种新颖的自适应测试方法，而公平性是另一个独立的研究领域 (Lord, 2012; Zhang 等, 2024)，因此不在本文讨论范围之内。

致谢

本研究部分受以下项目资助：国家重点研发计划 (Grant No.2021YFF0901003)、国家自然科学基金 (Grants No.62106244、No.U20A20229、No.62172320)、安徽省高校协同创新计划 (No.GXXT-2022-042)。

附录

A. 引理 4.2 的证明

引理 4.2 当使用 IRT 作为学生作答函数时，内层函数 (式 6) 与外层函数 (式 5) 具有以下性质：(1) 内层函数关于 θ 强凸，其关于 θ 与 α 的导数都是 L -Lipschitz 连续的，二阶导数也 Lipschitz: $\nabla_{\alpha} \nabla_{\theta} L$ 是 τ -Lipschitz, $\nabla_{\theta}^2 L$ 是 ρ -Lipschitz; (2) 外层函数 M -Lipschitz, 其关于 θ 的导数 L -Lipschitz, 关于 α 的导数 W -Lipschitz。

引理 4.2.1 的证明. 首先证明内层函数关于 θ 强凸。展开内层函数并代入定义 4.1 的损失函数，得

$$L(\theta, D_t(\alpha)) = - \sum_{i=1}^t (y_i \log(\sigma(\theta - b_i)) + (1 - y_i) \log(1 - \sigma(\theta - b_i))) \quad (11)$$

由于我们用 IRT 作为作答函数，即 $\sigma(\theta - b_i)$ ，易知 IRT 是强凸函数。又因为交叉熵损失是强凸的，当我们用 IRT 模型计算损失并求和时，内层函数关于 θ 也保证是强凸的。

其次，证明内层函数关于 θ 与 α 的导数都是 L -Lipschitz 连续的：

$$\nabla_{\theta} L(\theta, D_t(\alpha)) = - \sum_{i=1}^t \nabla_{\theta} (y_i \log(\sigma(\theta - b_i)) + (1 - y_i) \log(1 - \sigma(\theta - b_i))) = - \sum_{i=1}^t (y_i - \sigma(\theta(\alpha) - b_i)) \quad (12)$$

$$\nabla_{\alpha} L(\theta, D_t(\alpha)) = - \left(\sum_{i=1}^{t-1} \frac{\partial \theta(\alpha)}{\partial \alpha} (y_i - \sigma(\theta(\alpha) - b_i)) + \left(\frac{\partial \theta(\alpha)}{\partial \alpha} - \frac{\partial b_t}{\partial \alpha} \right) (y_t - \sigma(\theta(\alpha) - b_t)) \right) \quad (13)$$

θ 的导数显然有界，因此 L -Lipschitz 连续。 α 的导数中存在变量 $\frac{\partial \theta(\alpha)}{\partial \alpha}$ 与 $\frac{\partial b_t}{\partial \alpha}$ ： $\frac{\partial \theta(\alpha)}{\partial \alpha}$ 是更新内层函数的梯度，总有明确上界； $\frac{\partial b_t}{\partial \alpha}$ 是动态选题算法所选题目关于选题参数的梯度，同样保证有界。因此它是 L -Lipschitz。

最后，证明内层函数的二阶导数也 Lipschitz。式 (12) 是内层函数关于 θ 的一阶导数，据此有：

$$\nabla_{\alpha} \nabla_{\theta} L(\theta, D_t(\alpha)) = \sum_{i=1}^{t-1} \left[\frac{\partial \theta(\alpha)}{\partial \alpha} \sigma(\theta(\alpha) - b_i) (1 - \sigma(\theta(\alpha) - b_i)) + \left(\frac{\partial \theta(\alpha)}{\partial \alpha} - \frac{\partial b_t}{\partial \alpha} \right) \sigma(\theta(\alpha) - b_t) (1 - \sigma(\theta(\alpha) - b_t)) \right] \quad (14)$$

$\frac{\partial \theta}{\partial \alpha}$ 与 $\frac{\partial b_t}{\partial \alpha}$ 保证有界，因此可证整体函数有界，满足 τ -Lipschitz。

接下来证明 $\nabla_{\theta}^2 L(\theta, D_t(\alpha))$ 是 ρ -Lipschitz 连续的:

$$\nabla_{\theta}^2 L(\theta, D_t(\alpha)) = - \sum_{i=1}^t \nabla_{\theta} (y_i - \sigma(\theta(\alpha) - b_i)) = \sum_{i=1}^t (1 - \sigma(\theta(\alpha) - b_i)) \sigma(\theta(\alpha) - b_i) \quad (15-16)$$

显然这是有界的, 证毕。

引理 4.2.2 的证明. 首先证明外层函数 M -Lipschitz. 结合定义 4.1, 外层函数表示学生对查询集中题目作答的损失之和, 记为 $L(\theta(\alpha), D_u)$:

$$L(\theta(\alpha), D_u) = - \sum_{i=1}^U (y_i \log(\sigma(\theta - b_i)) + (1 - y_i) \log(1 - \sigma(\theta - b_i))) \quad (17)$$

显然它有界, 意味着我们总能找到满足 Lipschitz 的 M 。

接下来证明外层函数 $L(\theta(\alpha), D_u)$ 关于 θ 的导数 L -Lipschitz:

$$\nabla_{\theta} L(\theta(\alpha), D_u) = - \sum_{i=1}^U (y_i - \sigma(\theta(\alpha) - b_i)) \quad (18)$$

式 (18) 必然有界, 故 L -Lipschitz 当然满足。

最后证明外层函数关于 α 的导数 W -Lipschitz. 损失函数导数的展开如下:

$$\nabla_{\alpha} L(\theta^*(\alpha), D_u) = \frac{\partial \theta^*(\alpha)}{\partial \alpha} \sum_{i=1}^U (y_i - \sigma(\theta^*(\alpha) - b_i)) \quad (19)$$

式 (19) 有界, 可证其关于 α_t 的导数有界, 证毕。

B. 定理 4.3 的证明

定理 4.3 (梯度估计误差界). 假设学生作答函数 μ -强凸 (例如 IRT)。在测试第 t 步, 设 B 为 $\|\theta_t^0(\alpha_t) - \theta_t^*(\alpha_t)\|$ 的上界, 取学习率 $\gamma \leq \frac{1}{L}$, 有式 (9) (同正文)。

证明. 利用

$$\nabla_{\alpha} L(\theta_t^*(\alpha), D_u) = \frac{\partial \theta_t^*(\alpha_t)}{\partial \alpha_t} \nabla_{\theta} L(\theta_t^*(\alpha_t), D_u), \quad \nabla_{\alpha} L(\theta_t^K(\alpha_t), D_u) = \frac{\partial \theta_t^K(\alpha_t)}{\partial \alpha_t} \nabla_{\theta} L(\theta_t^K(\alpha_t), D_u) \quad (21-22)$$

将二者之差通过加减同一项拆开 (式 23), 并用三角不等式得:

$$\|\nabla_{\alpha} L(\theta_t^K) - \nabla_{\alpha} L(\theta_t^*)\| \leq \left\| \frac{\partial \theta_t^K}{\partial \alpha_t} - \frac{\partial \theta_t^*}{\partial \alpha_t} \right\| \|\nabla_{\theta} L(\theta_t^K)\| + \left\| \frac{\partial \theta_t^*}{\partial \alpha_t} \right\| \|\nabla_{\theta} L(\theta_t^K) - \nabla_{\theta} L(\theta_t^*)\| \quad (24)$$

根据引理 4.2.2 有

$$\leq M \left\| \frac{\partial \theta_t^K(\alpha_t)}{\partial \alpha_t} - \frac{\partial \theta_t^*(\alpha_t)}{\partial \alpha_t} \right\| + L \left\| \frac{\partial \theta_t^*(\alpha_t)}{\partial \alpha_t} \right\| \|\theta_t^K(\alpha_t) - \theta_t^*(\alpha_t)\| \quad (25)$$

接着求 $\left\| \frac{\partial \theta_t^K}{\partial \alpha_t} - \frac{\partial \theta_t^*}{\partial \alpha_t} \right\|$ 的上界。根据梯度下降 $\theta_t^k = \theta_t^{k-1} - \gamma \nabla_{\theta} L(\theta_t^{k-1}, D_t(\alpha_t))$ 并用链式法则 (式 26), 再结合 $\theta^*(\alpha_t)$ 的最优性条件

$$\nabla_{\alpha} \nabla_{\theta} L(\theta_t^*, D_t(\alpha_t)) + \frac{\partial \theta_t^*(\alpha_t)}{\partial \alpha_t} \nabla_{\theta}^2 L(\theta_t^*, D_t(\alpha_t)) = 0 \quad (27)$$

将式 (27) 代入式 (26), 得到一阶差分的递推 (式 28)。由式 (27) 与引理 4.2.1 可得

$$\left\| \frac{\partial \theta_t^*(\alpha_t)}{\partial \alpha_t} \right\| = \|\nabla_\alpha \nabla_\theta L(\theta_t^*, D_t(\alpha_t))\| \|\nabla_\theta^2 L(\theta_t^*, D_t(\alpha_t))^{-1}\| \leq \frac{L}{\mu}. \quad (29)$$

进而 (式 30)

$$\left\| \frac{\partial \theta_t^k}{\partial \alpha_t} - \frac{\partial \theta^*}{\partial \alpha_t} \right\| \leq (1 - \gamma\mu) \left\| \frac{\partial \theta_t^{k-1}}{\partial \alpha_t} - \frac{\partial \theta^*}{\partial \alpha_t} \right\| + \gamma \frac{\tau + L\rho}{\mu} \|\theta_t^{k-1} - \theta^*(\alpha_t)\| \quad (30)$$

再由强凸下层函数的性质 (式 31) $\|\theta_t^{k-1}(\alpha_t) - \theta^*(\alpha_t)\| \leq (1 - \gamma\mu)^{\frac{k-1}{2}} \|\theta_t^0(\alpha_t) - \theta^*(\alpha_t)\|$, 将 k 从 1 累加到 K (式 32), 最终设 B 为 $\|\theta_t^0(\alpha_t) - \theta^*(\alpha_t)\|$ 的上界, 得到式 (33), 即式 (9)。证毕。

C. 定理 4.4 的证明

定理 4.4 (收敛性分析) . 取 $\gamma \leq \frac{1}{L}$, $\beta = \frac{1}{4W}$, 则外层函数梯度的平均值满足式 (10) (同正文)。

证明. 根据引理 4.2.2, 外层函数关于 α 的导数 W -Lipschitz。由光滑性的下降引理有

$$L(\theta_{t+1}^*(\alpha_{t+1}), D_u) \leq L(\theta_t^*(\alpha_t), D_u) + \langle \nabla_\alpha L(\theta_t^*(\alpha_t), D_u), \alpha_{t+1} - \alpha_t \rangle + \frac{W}{2} \|\alpha_{t+1} - \alpha_t\|^2$$

代入更新式 $\alpha_{t+1} = \alpha_t - \beta \nabla_\alpha L(\theta_t^K(\alpha_t), D_u)$, 整理得 (式 35)

$$\leq L(\theta_t^*(\alpha_t), D_u) - \left(\frac{\beta}{2} - \beta^2 W \right) \|\nabla L(\theta_t^*(\alpha_t), D_u)\|^2 + \left(\frac{\beta}{2} + \beta^2 W \right) \|\nabla L(\theta_t^*) - \nabla L(\theta_t^K)\|^2 \quad (35)$$

将定理 4.3 代入式 (35) 得式 (36), 对 t 从 0 到 $T - 1$ 做望远镜求和 (telescoping) 得式 (37)。最后代入 $\beta = \frac{1}{4W}$ 以及

$$K = \log \left(\max \left\{ \frac{BL^2}{\mu}, \frac{(1-\gamma\mu)M^2(\tau\mu+L\rho)^2 B^2}{\mu^4}, \frac{ML}{\mu} \right\} \frac{9}{4\epsilon} \right) / \log \frac{1}{1-\gamma\mu}, \quad C = \frac{3B^2 M^2 (\tau\mu+L\rho)^2 (1-\gamma\mu)^2}{4\mu^4} + \epsilon$$

代入式 (37), 最终得到式 (10) (式 38)。证毕。

参考文献 (References) 按约定未翻译, 详见原文。