

迈向可解释的计算机自适应测试：基于大语言模型的方法 (Towards Explainable Computerized Adaptive Testing with Large Language Model)

原文: lacat-explainable-cat-with-llm_16.pdf (EMNLP 2024 Findings, pp. 2655–2672) ·译者: Claude ·译于 2026-06-26 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT)、认知诊断模型 (Cognitive Diagnostic Model, CDM)、项目反应理论 (Item Response Theory, IRT)、大语言模型 (Large Language Model, LLM)、能力估计 (ability estimate, θ)、题目选择 (item/question selection)、支持集 (support set)、查询集 (query set)

摘要

随着智能教育的发展，它将基于学生各自的能力为其提供多种个性化的学习服务。计算机自适应测试 (CAT) 旨在用最少的题目准确测量学生的能力，提供一种高效且个性化的测试方法。然而，现有方法主要聚焦于「最小化评估能力所需的题目数量」，往往无法对题目选择过程给出清晰可靠的解释。如果教育者和学生不理解题目选择背后的依据，他们很难信任并接受 CAT 系统。为解决这一问题，我们提出了**基于 LLM 智能体的 CAT (LLM-Agent-Based CAT, LACAT)**，这是一种由大语言模型驱动的新型智能体，能够为 CAT 赋予类人的可解释性与解释能力。LACAT 由三个关键模块组成：**Summarizer (总结器)**，生成可解释的学生画像；**Reasoner (推理器)**，个性化地选题并给出人类可读的解释；以及**Critic (评判器)**，从过去的选择中学习以优化未来的选题。我们在三个真实教育数据集上进行了大量实验。结果表明，LACAT 在准确率上能够与传统 CAT 方法相当甚至更优，并显著提升了测试过程的透明度与可接受性。人工评估进一步证实，LACAT 能够生成高质量、易理解的解释，从而增强学生的信任与满意度。¹

1 引言

随着智能教育的显著演进，计算机自适应测试 (CAT) ——其目标是用尽可能少的题目准确测量学生的能力——为下游教育服务（如学习资源推荐、学习状态报告）提供了一种高效、个性化的测试方法 (Van der Linden and Glas, 2000)。一般而言，CAT 会选择与每位学生个人表现相匹配的合适题目，从而以更少的测试项达到与传统纸笔考试同等的测试准确度 (Cheng, 2009)。

图 1: CAT 工作流程概览。

图 1 展示了一个典型 CAT 的玩具示例。在实践中，CAT 包含两个核心组件：**认知诊断模型 (CDM)**，用于估计学生能力；以及**选择策略**，根据学生以往表现挑选最合适的题目 (Embretson and Reise, 2013; Zhao et al., 2023)。CAT 系统的工作流程如下：给定一名学生，在第 $t - 1$ 步，选择算法基于 CDM 对该学生当前能力的估计 θ_{t-1} 选出一道题。随后学生接受并作答该题。收到答案后，CDM 根据新的作答把估计更新为 θ_t 。

传统上，人们使用启发式规则进行题目选择，如最大化 Fisher 信息量 (Chang et al., 2015)、KLI (Chang and Ying, 1996)。然而，这些方法在泛化性以及对学生与题目之间复杂交互的建模上存在困难。近年来，研究重点已转向深度学习方法，如 NCAT (Zhuang et al., 2022)、BOBCAT (Ghosh and Lan, 2021) 和 GMOCAT (Wang et al., 2023b)，它们从大规模学生作答数据中学习选择算法，并提升了测试准确度。尽管成效显著，这些黑箱系统缺乏透明度，无法给出合理的解释 (Liu et al., 2024a)，可能导致师生的不信任。因此，开发可解释、透明的自适应测试模型，对于其广泛采用与获得信任至关重要 (Wainer et al., 2000)。

如今，大语言模型 (Achiam et al., 2023) 的出现为解决这一问题提供了新视角。近期研究已证明其在文本推理上的能力 (Zhang et al., 2024a)，在文本摘要 (Luo et al., 2023)、情感分析 (Zhang et al., 2023a) 等任务上取得了显著成果。此外，这些模型具备强大的语言生成能力，能够为其决策过程产出人类可读的解释性文本。然而，尽管大语言模型在语言处理任务上表现出色，将 LLM 集成进计算机自适应测试的框架仍然极具挑战。

用大语言模型 (LLM) 解决可解释的计算机自适应测试任务，可归纳出三个主要挑战：**第一**，认知诊断模型 (CDM) 通常用一个单维或多维向量来表示对学生能力的估计。然而，仅依赖一个向量不足以指导 LLM 进行题目选择。**第二**，虽然计算机自适应测试的首要目标是准确评估学生能力，但缺乏精确的选题标准、难以判定「最优题目」是一大挑战。对于还必须解释自己选题的 LLM 而言，这一点尤为突出。**第三**，缺乏有效的反馈机制来优化题目选择是一大挑战。在计算机自适应测试中，决策是连续进行的，过去的选择与经验对当前决策至关重要。确保过去的决策能改进未来的选题，是维持准确评估的关键。

为应对这些挑战，我们提出了**基于 LLM 智能体的 CAT (LACAT)**。LACAT 包含三个核心组件：(1) **Summarizer (总结器)**，从学生作答数据中准确刻画用户画像，进一步增进对学生能力的理解，解决了「仅靠学生能力估计向量提供的选题指导不足」的挑战。(2) **Reasoner (推理器)**，选出最合适的题目并给出清晰、人类可读的解释，应对了「缺乏精确选题与解释标准」的挑战。(3) **Critic (评判器)**，反思过去的选题并汲取经验以改进未来决策，解决了「缺乏有效反馈机制来优化选题」的挑战。综上，我们的贡献是：

- 据我们所知，本方法是**首个**将大语言模型 (LLM) 引入计算机自适应测试 (CAT) 以实现可解释题目选择的工作，提出了新的视角与方法论。
- 我们提出了 LACAT 框架，包含三个利用 LLM 的模块，用以理解学生的认知能力、选出最合适的题目，并给出清晰易懂的解释。
- 在三个真实公开数据集上的大量实验证明了 LACAT 的有效性。人工评估进一步证实了其生成解释的高质量。

¹ 代码与数据公开于 <https://github.com/doublecheng12/LACAT>

2 相关工作

2.1 计算机自适应测试

在经典的计算机自适应测试 (CAT) 系统中, 项目反应理论 (IRT) 通常被用作认知诊断模型 (CDM) 来预测学生对题目的作答。近来, 基于神经网络的 CDM 也相继出现, 如 NCDM (Wang et al., 2020)、ICDM (Liu et al., 2024b)。选择算法在 CAT 系统中扮演关键角色。最初, 选择算法基于信息量度量, 如 MFI (Chang et al., 2015) 和 KLI (Chang and Ying, 1996)。随后出现了基于规则的方法, 如使用主动学习的 MAAT (Bi et al., 2020)。近期工作转向数据驱动方法。例如, BOBCAT (Ghosh and Lan, 2021) 和 NCAT (Zhuang et al., 2022) 将 CAT 视为强化学习 (RL) (Kaelbling et al., 1996) 问题, 直接从大规模学生作答数据中训练选择算法。此外, 为实现更通用、可扩展的框架, 研究者提出了有界估计 CAT 框架 (BECAT) (Zhuang et al., 2024), 用数据摘要 (data summary) 的思路重新定义了选择问题。然而, 这些方法主要旨在缩短测试长度, 并未涉及 CAT 选择的可解释性。据我们所知, 目前还没有工作聚焦于 CAT 选择算法的透明度与可解释性。

2.2 基于 LLM 的智能体

随着大语言模型的快速发展, 越来越多的工作尝试将这些模型用作决策智能体 (Yang et al., 2024; Zhao et al., 2024a)。这些模型通常具备反思 (Wang et al., 2023c; Pan et al., 2023; Li et al., 2023)、记忆 (Zhong et al., 2024; Sun et al., 2023; Li and Qiu, 2023) 和工具使用 (Zhao et al., 2024b) 的能力, 并已应用于诸多领域, 如游戏决策 (Ma et al., 2023; Zhu et al., 2023; Wang et al., 2023a)、金融 (Li et al., 2024b; Koa et al., 2024) 和推荐系统 (Shi et al., 2024; Zhou et al., 2024; Zhang et al., 2023b)。在教育领域, 基于 LLM 的智能体已被应用于学生状态建模任务, 如知识追踪 (Li et al., 2024a) 和模拟学生行为 (Xu et al., 2024)。然而, 现有研究通常只解决智能教育的某个单一方面 (如学生能力建模), 缺乏整合恰当的模块来完成复杂的多步任务。因此, 它们并不适合处理 CAT 任务中的解释问题。在本文中, 我们提出了一个多模块框架 LACAT (基于 LLM 智能体的 CAT), 通过 Summarizer、Reasoner 和 Critic 三个模块的协同工作, 增强计算机自适应测试 (CAT) 中多步决策的可解释性与透明度。

3 预备知识

3.1 计算机自适应测试 (CAT)

在计算机自适应测试 (CAT) 中, 如图 2(a) 所示, 两个核心组件——认知诊断模型和选择算法——通过一系列步骤 $t \in [1, T]$ 协同工作。首先, 候选题库被随机划分为支持集 (support set) 和查询集 (query set)。选择算法从支持集中为学生挑出最合适的题目作答。学生作答后, 认知诊断模型根据其作答记录 (q_t, a_t, c_t) 估计学生的真实能力 θ_t , 其中 q_t 是学生在第 t 步作答的题目, a_t 是作答结果 (答对为 1, 否则为 0), c_t 是该题的文本内容。结合 θ_t , 查询集可用来计算反馈, 以评估能力估计的准确度, 如图 2(a) 所示。该反馈随后用于指导下一题的选择, 使过程不断优化, 更好地匹配学生展现出的能力。

图 2: (a) 典型 CAT 流程 (左) 与 (b) LACAT 流程 (右) 示意图, 后者整合了 Summarizer、Reasoner 和 Critic 三个组件。支持集与查询集从候选题库中随机选取。

3.2 问题陈述

如上所述, 计算机自适应测试系统在每一步 t 都要基于学生的历史记录以及认知诊断模型 (CDM) 的反馈, 为学生 u_i 从支持集中选出一道题 q 。在收到学生对题目 q 的作答 a 后, CDM 更新并估计新的能力水平 θ_t 。该过程重复 T 次, 以准确估计学生能力, 目标是让 θ_T 逼近 θ_0 , 其中 θ_0 表示学生 u_i 的真实 (通常未知) 能力。

此外, 我们旨在将大语言模型 (LLM) 集成进计算机自适应测试 (CAT) 的题目选择过程, 以增强用户建模, 并提升能力估计的透明度、可解释性与效率。这一集成将能为题目选择生成清晰透明的解释, 从而让该过程对学生和教育者更易理解、更易获取。借助 LLM, 我们能够提供更个性化、更准确的评估, 最终促成对学生能力更有效、更具洞见的评价。

4 方法

4.1 整体工作流程

如图 2(b) 所示, **Summarizer** 负责构建学生画像, 它由两部分组成: 从学生全部作答记录中得到的**长期画像 (long-term profile)**, 以及从其近期作答记录中得到的**短期画像 (short-term profile)**。该画像作为后续选题的依据, 解决了传统能力估计向量提供的选题指导不足的问题。随后, **Reasoner** 基于 Summarizer 构建的详细用户画像, 以及 Critic 对上一轮选题的评估所得到的洞见, 从支持集中选出最合适的题目。重要的是, Reasoner 为每次选择都给出清晰合理的解释, 确保透明度与可解释性。**Critic** 的评估基于环境提供的奖励 (reward)。若奖励较低, Critic 会分析上一轮选题中的问题, 以避免在未来的选择中重蹈覆辙, 从而优化选题质量、实现更精确的能力评估。

具体来说, 鉴于一名新学生还没有任何作答记录, 系统会首先从支持集中为其选出一道有代表性的题目, 例如一道区分度高、难度中等的题。随后, Summarizer 获取该学生的记录并分析其画像。Reasoner 基于画像为学生选出最合适的练习题, 并给出选择的理由。如果选题质量不令人满意, Critic 会分析原因以防止同样的错误, 并为下一轮选择提供提示。这三个组件循环工作, 直到测试结束。

4.2 Summarizer (总结器)

Summarizer 模块同时包含长期画像系统和短期画像系统。如图 2(b) 所示，长期画像库会细致地分析并归档从学生整个作答历史中抽取的、学生特有的特征。它系统性地识别并记录学生随时间表现出的强项、弱项和持续存在的难点，从而提供对每位学生独特学习历程的全面视图。与此同时，短期画像系统聚焦于对学生最近一次作答的即时评估，进行实时分析以综合出一条有据可依的「指导性想法 (guiding thought)」。这一认知过程对于后续题目的自适应选择至关重要，能确保题目在挑战难度上恰当、并与学生即时的学习需求相契合。

4.2.1 长期画像 学生在考试表现上可能随时间呈现出一致的能力。例如，一名空间想象能力欠缺的学生通常在立体几何题上表现不佳 (Chen et al., 2023b; Zhao et al., 2021)。因此，我们提出学习学生的长期画像来刻画这种一致的能力。具体而言，对于时间步 t 的学生 u_i ，画像利用其历史作答记录以及当前能力估计 θ_t (该估计由抽象 CDM 的参数导出，以前所有步骤的作答记录作为输入)。

注意，长期画像的输入包含此前所有步骤的作答记录。因此，对于此前的每一步 $t' \in [1, t-1]$ ，三元组 $(q_{t'}, a_{t'}, c_{t'})$ 可用 $e_{t'}$ 表示。学生当前的能力估计 θ_t 正是利用这些以往作答计算得到的。

$$L_t = \text{LLM}_{\text{long-term}}([e_1, e_2, \dots, e_{t-1}], \theta_{t-1}, \text{prompt}_{\text{long-term}}). \quad (1)$$

长期画像主要刻画学生在每一类知识上的状态，是为其个人需求量身选题的宝贵资源。

表 1: Critic 示例。

(Critic 案例) 所选的三角函数题对该学生而言太难，导致结果不甚理想。这种不匹配可能让学生感到沮丧，阻碍其进步。为改善这一情况，我们应当调整题目难度，使之与学生当前的技能水平相匹配。通过提供与学生能力相符的题目，我们可以帮助他们逐步建立信心，有效地促进学习。

4.2.2 短期画像 除了长期能力之外，在构建学生画像时，还必须考虑其近期的学业表现。例如，如果学生在上一题中正确作答了三角函数相关的知识，那么与该知识点相关题目的难度水平就应提高，以便对其能力做出更精确的评估。我们把短期画像表示为一条「想法 (thought)」，它基于学生的长期画像及其近期作答历史来指导下一题的选择。具体而言，对于时间步 t 的学生 u_i ，Summarizer 利用最近一次作答记录 e_{t-1} 作为输入来生成短期画像。

$$S_t = \text{LLM}_{\text{short-term}}([e_{t-1}], L_t, \text{prompt}_{\text{short-term}}). \quad (2)$$

鉴于这些全面的画像机制，学生画像由长期和短期两部分共同构成。因此，Reasoner 可以利用这一多层面的学生画像，做出明智的决策来选出最合适的下一题。

4.3 Critic (评判器)

在计算机自适应测试 (CAT) 的选择过程中，决策是连续进行的，过去的选择与经验在当前选择中起着关键作用 (Zhao et al., 2024a; Li et al., 2024c; He et al., 2024)。有鉴于此，我们设计了 Critic 模块，从过去的选择中提取指导原则。当所选题目的质量较低时，Critic 模块分析原因并为下一次选择提供指导。题目的质量由其「能否准确预测学生真实能力」来定义。尽管学生的真实能力通常未知，我们仍可用其查询集 (Zhuang et al., 2022) 来度量能力估计 θ_t 的误差。在测试阶段 t ，我们用 θ_t 计算查询集上的预测准确率，记为 $\text{ACC}(\theta_t)$ 。 $\text{ACC}(\theta_t)$ 越高，估计出的 θ_t 就越接近真实能力。因此，一道题的质量可形式化定义如下：

$$r_{\text{qua}} = \begin{cases} 1, & \text{若 } \text{ACC}(\theta_t) > \text{ACC}(\theta_{t-1}) \\ 0, & \text{否则。} \end{cases} \quad (3)$$

$\text{ACC}(\theta_t)$ 的详细计算过程见附录 C。

当题目能够提升能力评估的准确度时，便被认定为高质量。Critic 模块旨在模拟这一质量评估过程，并随时间最大化 r_{qua} 。如果所选题目未能提升准确度，Critic 会评估输出质量，并通过下式给出策略性指导：

$$C_t = \text{LLM}_{\text{critic}}([e_1, \dots, e_{t-1}], \theta_{t-1}, \text{prompt}_{\text{critic}}). \quad (4)$$

为便于更清晰地理解，我们在表 1 中给出了一个示例。在该实例中，选题质量差是由于所选题目与学生能力之间不匹配。具体来说，选中了一道远超学生当前能力的三角函数题。因此，接下来的选择应考虑降低该知识点题目的难度。显然，Critic 模块帮助智能体充分感知学生过去的的能力，并相应调整策略以维持高质量的选题。

4.4 Reasoner (推理器)

Reasoner 的目标是基于学生的历史作答记录，为不同能力的学生选出最合适的题目，并给出合理、透明、人类可读的解释。为此，Reasoner 同时考虑学生的长期和短期表现，并在选题过程中综合这些洞见。在 Critic 的指导下，Reasoner 可以及时调整选择策略。此外，我们采用思维链 (chain of thought) 提示 (Wei et al., 2022) 来增强选题的效果与可解释性。具体而言，Reasoner 首先识别出应为每位学生选择何种特征的题目，尤其关注每道题如何影响学生的能力画像。这一做法确保每次选择背后的推理都清晰易懂，从而提升过程的透明度与可信度。

表 2: Reasoner 示例。

(Reasoner 案例) 我之所以选择第 1 题，是因为它涉及解一元二次方程，而该学生近期在这一领域有显著进步。这将有助于巩固其代数技能、建立信心。中等的难度水平能够有效评估其理解程度，并区分其在代数上的能力。此外，聚焦代数可以避开他们在几何上的弱项，使他们能专注于自己的强项，提升整体学习体验。

例如，表 2 展示了一名学生在解一元二次方程上有显著进步，在该领域展现出强项，而在几何上仍有困难、几何仍是其弱项。基于这些信息，Reasoner 从候选题列表中选出一道涉及一元二次方程的题目，以巩固学生的代数技能、建立信心。这一选择利用了学生的强项，并提供了恰当的挑战来准确评估其理解。在此阶段避开几何题，使学生能专注于自己擅长的领域，从而提升学习体验。

对于测试阶段 t ，最终过程可形式化为：

$$(r_t, q_t) = \text{LLM}_{\text{Reasoner}}(L_{t-1}, S_{t-1}, C_{t-1}, [\text{support set}], \text{prompt}_{\text{Reasoner}}). \quad (5)$$

此处， r_t 表示选择 q_t 的理由， q_t 是选出的题目。

5 实验

在本节中，我们在三个真实数据集上进行大量实验，以评估 LACAT 的性能。我们的实验聚焦于回答以下研究问题：

- **RQ1**: 在通用 CAT 设置下，LACAT 与现有题目选择算法相比表现如何？
- **RQ2**: LACAT 各组件（即 Summarizer、Reasoner）生成的解释质量如何？
- **RQ3**: LACAT 在题目曝光 (Question Exposure) 和上下文重叠 (Context Overlap) 方面表现如何？
- **RQ4**: 不同组件（即 Summarizer、Critic）如何影响 LACAT？

此外，我们还进行了若干定量实验，以进一步证明 LACAT 的有效性。更多细节见附录 B。

5.1 实验设置

5.1.1 数据划分与实验流程 我们使用三个真实教育数据集评估 LACAT 方法：Junyi、MOOCRadar 和 EXAM。Junyi 数据集 (Chang et al., 2015) 包含在线学习平台 Junyi Academy 2018–2019 学年的答题日志。MOOCRadar (Yu et al., 2023) 包含来自各类 MOOC 的学生学习记录。EXAM 数据集由智学网 (Zhixue.com) 提供，包含初中生数学考试表现的记录。对于所有数据集，我们移除测试记录少于 30 条的学生。然后，我们将 80%、10%、10% 的学生分别分配给训练、验证和测试。此外，我们把包含学生测试记录的样本划分为支持题集（占 80% 样本）和查询题集（占剩余 20%）。我们使用 AUC（曲线下面积）和 ACC（准确率）来评估每种 CAT 方法的性能。

5.1.2 对比方法 在实验中，我们使用项目反应理论 (IRT) (Embretson and Reise, 2013)，它是计算机自适应测试 (CAT) 中最常用的认知诊断模型 (CDM)。为衡量 LACAT 的有效性，我们首先将其与无需训练的传统 CAT 方法对比，包括 MFI (Chang et al., 2015)、KLI (Chang and Ying, 1996)、MAAT (Bi et al., 2020) 和 BECAT (Zhuang et al., 2024)。此外，为评估 LACAT 的优越性，我们将其与其他数据驱动的 CAT 算法对比，具体为 BOBCAT (Ghosh and Lan, 2021) 和 NCAT (Zhuang et al., 2022)。基线方法的详细实现见附录 A。

5.1.3 实现细节 我们使用 OpenAI API 提供的 GPT-3.5-turbo-16k 作为 LLM 主干，因其具有强大的长上下文建模能力，模型温度设为 0。此外，我们使用公开的 EduCAT 库复现了所有基线模型，并采用各原文推荐超参数。

5.2 学生表现预测 (RQ1)

表 3: 不同方法在「学生成绩预测」任务上以 ACC 和 AUC 指标衡量的性能。加粗表示相较最佳基线有统计显著的提升 (p 值 < 0.05)。

为验证选择算法的有效性，我们在 CAT 的学生成绩预测任务上进行测试。评估方法详见附录 D。如表 3 所示，我们以学生在测试集查询集题目上作答的 AUC 和 ACC 作为评估指标，并给出第 1、5、10 个测试步骤的结果。

下表给出三个数据集 (MoocRadar、Junyi、Exam) 在第 1/5/10 步的 AUC 与 ACC (百分数)：

AUC (%)

方法	Mooc@1	Mooc@5	Mooc@10	Junyi@1	Junyi@5	Junyi@10	Exam@1	Exam@5	Exam@10
MFI	65.03	70.12	74.67	68.14	68.57	69.03	74.12	74.50	74.59
KLI	65.11	69.59	73.95	68.12	68.48	69.01	74.14	74.47	74.56
MAAT	65.45	69.71	74.17	68.18	68.70	69.54	74.17	74.53	74.64
BECAT	65.72	70.54	75.13	68.17	68.91	69.66	74.29	74.61	74.74
BOBCAT	65.97	71.34	75.78	68.23	69.07	69.73	74.49	74.73	74.97
NCAT	65.93	71.42	76.01	68.19	68.95	69.69	74.45	74.85	75.08
LACAT (Zero-shot)	66.08	71.66	76.32	68.37	69.15	69.79	74.22	74.60	74.71

ACC (%)

方法	Mooc@1	Mooc@5	Mooc@10	Junyi@1	Junyi@5	Junyi@10	Exam@1	Exam@5	Exam@10
MFI	74.67	83.14	86.67	71.20	71.93	72.08	64.44	65.35	66.47
KLI	74.76	83.28	86.66	71.23	71.99	72.13	64.39	65.27	66.40
MAAT	75.19	83.42	86.92	71.26	72.05	72.17	64.48	65.46	66.52
BECAT	75.36	83.54	87.06	71.39	72.07	72.20	64.55	65.50	66.61
BOBCAT	75.49	83.58	87.14	71.51	72.09	72.39	64.77	65.96	66.84
NCAT	75.58	83.97	87.36	71.43	72.07	72.22	64.83	66.12	67.10
LACAT (Zero-shot)	75.70	84.35	87.48	71.75	72.13	72.42	64.48	65.44	66.50

我们的观察如下：

- LACAT 在 Junyi 和 MoocRadar 两个数据集上均表现优异，超越了所有基线模型。值得注意的是，尽管 LACAT 无需任何数据训练，它仍优于数据驱动的方法，验证了我们框架的有效性。这一成果凸显了 LACAT 有能力有效地建模学生与练习题之间错综复杂的关系，彰显了它在教育评估中的潜力。
- LACAT 在 Exam 数据集上表现欠佳。我们将其归因于大语言模型难以识别需要复杂推理的数学题的属性。尽管在众多数据集上训练过，大语言模型在复杂推理上仍有困难。相比 Junyi 简单的小学数学题和 MoocRadar 的测验题，大语言模型在需要复杂推理的题目上可能犯更多错误。

5.3 可解释性评估结果 (RQ2)

由于此前没有关于 CAT 可解释性的现成参照，受先前文本质量评估实验 (Yang et al., 2023; Chen et al., 2023a) 的启发，我们设计了四项指标来评估 LACAT 生成的文本，包括 Summarizer 生成的学生画像和 Reasoner 给出的选题理由。这些指标是：1) **流畅度 (Fluency)**：文本的流畅性与可读性；2) **全面性 (Comprehensiveness)**：生成文本是否覆盖了学生的所有问题；3) **相关性 (Relevancy)**：生成文本是否与学生的解题情况相关；4) **总体 (Overall)**：生成解释的总体有效性。

每个方面按 0 到 2 的尺度评分，分数越高表示表现越令人满意。我们从 MoocRadar 和 Exam 数据集中各抽取 50 个样本，共 100 个样本。这些样本被分发给 5 位评估者，包括教育领域的教师和研究生。具体而言，我们向评估者提供了学生的答题记录、Summarizer 总结的学生画像，以及 Reasoner 为每道题选择给出的解释。此外，大语言模型 (LLM) 的出现激发了人们对其在评估自然语言生成 (NLG) 任务上潜在应用的兴趣。为利用这些进展，我们使用了最先进的模型，具体为 GPT-4 和 Deepseek-v2，作为自动评估方法来评估生成文本的质量。评估标准的细节见附录 E。

表 4：对 LACAT 解释进行人工评估的 Fleiss’Kappa 统计量与平均分。

模块	Kappa-流畅	Kappa-相关	Kappa-全面	Kappa-总体	均分-流畅	均分-相关	均分-全面	均分-总体
Summarizer	0.94	0.51	0.46	0.66	1.92	1.63	1.72	1.78
Reasoner	0.98	0.63	0.59	0.60	1.97	1.57	1.60	1.52

5.3.1 人工评估 首先，我们通过为每个方面计算评估者间一致性（用 Fleiss’Kappa 统计量，Falotico and Quatto, 2015）来评估人工评估结果中标注的质量。Fleiss’Kappa 结果展示在表 4 的左侧。评估者的意见高度一致，按 Fleiss’Kappa 统计量超过了「中等一致」的标准 (>0.41)。特别是流畅度指标，几乎达到了完全一致，反映出人工标注的高质量。

如表 4 右侧所示，在流畅度方面，Summarizer 生成的用户画像和 Reasoner 选出的题目都是人类可读且高度流畅的，与人类撰写的文本极为相近，平均分接近 2.0。Summarizer 和 Reasoner 生成的文本在相关性和完整性上的平均分均超过 1.5，表明对学生能力有清晰、全面的理解。然而，Reasoner 在这两项指标上都略逊于 Summarizer，这可能是由于题目选择需要对学生状态有更深入的理解，是一项更复杂的任务。总体而言，两个模块的平均分都超过 1.5，表明 LACAT 能在流畅度、相关性和完整性上为正确分类生成人类可读、清晰的解释，达成了让 CAT 过程透明化的目标。

5.3.2 自动评估 我们要求 LLM 在以下选项中选择：1) **全面 (Comprehensive)** (正确且详尽)；2) **部分良好 (Partially good)** (合理但不全面)；3) **无效 (Invalid)**。表 5 给出了 LACAT 解释的自动评估结果，结果取两个模型评估的平均值。两个模块生成的解释表现良好，超过 90% 的内容是有效的，反映出解释的高质量。

表 5: LACAT 解释的自动评估结果。

质量	Summarizer	Reasoner
Comprehensive	72.5%	64.5%
Partially good	18.5%	25.5%
Invalid	9.0%	10.0%

5.4 题目曝光与上下文重叠 (RQ3)

为更深入地洞察 LACAT，我们仔细考察了算法所选题目的特征。我们用两个主要指标评估不同算法的新颖性：题目曝光率 (question exposure rate) 和文本重叠率 (text overlap rate)。题目曝光率指在一次考试中遇到相同题目的频率，文本重叠率则表示两次或多次测试之间的相似度。曝光率和重叠率越低，算法越好。我们采用 Chang (Chang and Ying, 1999) 和 Chen (Chen et al., 2003) 提出的方法来度量这些率。如表 6 所示 (列出在 MoocRadar 数据集上第 10 步的曝光率 Exp. 和平均重叠率 Over.)，LACAT 表现出低题目曝光率和低文本重叠率。

表 6: 在 MoocRadar 数据集上第 10 步的曝光率 (Exp.) 与平均重叠率 (Over.)。最佳结果加粗。

方法	Exp.% (mid)	Over.%
MFI	0.13	8.73
KLI	0.19	8.27
MAAT	0.20	11.71
BOBCAT	0.65	16.32
BECAT	0.21	6.09
NCAT	0.17	5.67
LACAT	0.18	3.69

5.5 消融研究 (RQ4)

在本小节中，我们进行消融研究以进一步考察各模块对 LACAT 的贡献。我们在 MoocRadar 数据集、IRT 上测试第 3、5、10 步的 AUC 指标。设置如下：

- **LACAT-S**: 移除 Summarizer 模块，意味着我们只使用 IRT 模型提供的学生能力估计，忽略从学生作答序列构建的学生画像。
- **LACAT-C**: 移除 Critic 模块，意味着没有机制来识别和纠正推理过程中的缺陷。

表 7: 消融研究结果。我们在 MoocRadar 数据集上测试时间步 $t = 3, 5, 10$ 的 AUC 指标。最佳结果加粗。

指标	AUC@3	AUC@5	AUC@10
LACAT	69.24	71.66	76.32
LACAT-S	68.19	70.17	74.20
LACAT-C	68.73	70.88	75.17

结果展示在表 7 中。我们观察到，移除任何一个模块都会导致 LACAT 性能下降。分析如下：

- LACAT-S 不使用 Summarizer 模块提供的学生画像，导致缺乏关键的学生信息，进而性能下降。这表明从学生作答序列中抽取信息以构建准确学生画像的重要性。
- 没有 Critic 模块，LACAT-C 无法及时纠正错误，导致性能下降。这凸显了及时纠错的关键作用。

6 结论

我们提出了 LACAT，一个将大语言模型与计算机自适应测试相集成的框架。它由用于学生画像的 Summarizer、用于题目选择与解释的 Reasoner，以及用于过程优化的 Critic 组成，在真实教育场景中增强自适应测试。与传统的基于规则和数据驱动的方法相比，LACAT 能够生成更清晰、更透明、更合理的题目（选择）。这种将大语言模型与计算机自适应测试相结合的方式，为提升教育评估展现了一条充满希望的路径。

局限性

我们的实验仅基于一种 IRT（项目反应理论），它在 CDM（认知诊断模型）中提供单维的能力估计。虽然许多其他 CDM 模型用复杂的向量来评估学生能力（Wang et al., 2020; Gao et al., 2021; Zhang et al., 2024b），但将这些向量翻译成可供大语言模型使用的文本仍然具有挑战性。此外，由于本文是首篇探索 CAT 可解释性的工作，还需要进一步研究来更好地定义和完善评估指标。

致谢

本研究得到以下项目资助：国家科技重大专项（No. 2022ZD0117103）、国家自然科学基金（Grants No. 62337001, 62106246）、安徽省重点研发计划（No. 202423k09020039）以及安徽省高校协同创新项目（GXXT-2022-042）。

附录 A 基线方法

- **MFI** (Chang et al., 2015)：基于最大 Fisher 信息量选择题目。
- **KLI** (Chang and Ying, 1996)：选择 Kullback-Leibler 信息量移动平均最大的题目。
- **MAAT** (Bi et al., 2020)：提出一种基于主动学习的方法，通过计算每道题引起的期望模型变化 (Expected Model Change, EMC) 来衡量题目的信息量。
- **BECAT** (Zhuang et al., 2024)：提出一种有效的、基于期望梯度的选择算法，最小化 CAT 系统中的估计误差项。
- **BOBCAT** (Ghosh and Lan, 2021)：首个用于 CAT 的双层优化 (Franceschi et al., 2018) 框架，采用近似梯度估计方法来学习数据驱动的选择算法。
- **NCAT** (Zhuang et al., 2022)：一种基于强化学习的方法，设计了一个基于注意力的 DQN (Van Hasselt et al., 2016)。

附录 B 补充结果

成本与效率分析实验。我们在 MoocRadar 和 Exam 数据集上，使用四个大语言模型（GPT-3.5-turbo-16k、DeepSeek、GPT-4、GPT-4o-mini）进行了全面的成本与效率实验。表 8 给出了 100 名学生完成一次 10 步计算机自适应测试（CAT）的平均成本与耗时。结果表明成本相对可负担；即便是最贵的模型（GPT-3.5-turbo-16k）每轮测试也不超过 0.2 美元，而 DeepSeek 和 GPT-4o-mini 每次测试低于 0.01 美元。

然而，效率构成了挑战，最慢的模型 DeepSeek 平均约需八秒来选出一道题。为解决这一问题，我们设计了一种减少耗时的策略：当学生在做练习题时，系统会基于其答对/答错两种情况并发性地进行选题。这样在学生提交结果后即可立即推荐后续练习，显著减少了总体耗时。

表 8：在 MoocRadar 和 Exam 数据集上，100 名学生完成 10 步 CAT 测试的成本与耗时。最佳结果加粗。

模型	Mooc 成本 (USD)	Mooc 耗时 (s)	Exam 成本 (USD)	Exam 耗时 (s)
GPT-3.5-turbo-16k	0.1334	65.62	0.0923	68.13
DeepSeek	0.0076	79.96	0.0056	80.58
GPT-4	0.1873	49.28	0.1617	55.77
GPT-4o-mini	0.0083	34.51	0.0051	36.88

LLM 对学生成绩预测性能的影响。遵循 5.2 节描述的实验设置，我们将基础 LLM 替换为两个备选 LLM：由阿里巴巴开发的 Qwen-1.5-7B (Bai et al., 2023)，以及由幻方 (Magic Square) 开发的 Deepseek-v2 (Bi et al., 2024)，二者均为开源模型。这些模型在某些方面表现良好，Deepseek-v2 甚至在性能上超越了 GPT-3.5。如图 3 所示，可得出以下观察：

- 首先，Qwen-1.5-7B 在 MoocRadar 和 Exam 数据集上预测学生表现较差。尽管使用了与 ChatGPT 相同的提示模板，其输出常常无法满足规定的性能指标，即便多次尝试也是如此。这一问题可能归因于该模型对长上下文的处理，导致其默认随机选择练习题。

- 相比之下，Deepseek-v2 表现更优，这可能得益于其先进的推理能力。具体来说，在 MoocRadar 数据集上，Deepseek-v2 超越了 NCAT，尽管 ChatGPT 取得了最高成绩。此外，在 ChatGPT 表现欠佳的 Exam 数据集上，Deepseek-v2 仍超过了最佳基线的表现。

这些发现表明，框架的性能与所选模型的推理能力密切相关。因此，选择合适的 LLM 作为框架的核心组件，对于实现最优性能至关重要。

图 3：不同 LLM 上的学生成绩预测性能 ((a) MoocRadar; (b) Exam)。

附录 C $ACC(\theta_t)$ 的计算过程

如图 4 所示，在第 t 步，选择算法从支持集中选出题目，并用 CDM 估计学生能力 θ_t 。然后基于估计的 θ_t 估计学生在查询集上的表现，并与实际表现对比以计算准确率 (Wang et al., 2023b)。

图 4： $ACC(\theta_t)$ 的计算过程。

附录 D 详细评估方法

计算机自适应测试 (CAT) 的首要目标是用最少的测试项准确评估学生的真实能力。然而，真实能力是一个抽象概念，无法被直接测量。为评估 CAT 系统能力估计的有效性，我们采用一种间接方法。该方法利用保留的作答数据中已作答题目的得分（答对或答错）。通过分析这些得分，我们可以推断 CAT 系统估计学生能力的强项与弱项。这种间接评估作为评估 CAT 系统总体性能与准确度的代理，用以衡量其达成「高效、精确地评估能力」目标的程度。

附录 E 人工评估标准

评估者将获得 Summarizer 和 Reasoner 生成的解释，需要从以下方面对生成的解释进行评分和标注：

流畅度 (Fluency)。评估解释的连贯性与可读性。评估者应判断生成的解释是否结构良好、易于阅读、无语法或句法错误。

- 0：不连贯、难以阅读、含大量错误
- 1：基本流畅、易读、仅有少量小错误
- 2：完全流畅、连贯、无错误

相关性 (Relevance)。衡量生成的选题理由或用户画像与学生知识状态的契合程度，以及所选练习题的恰当性。评估者应判断解释是否切题、连贯，并充分反映学生的学习需求。主要判断标准（按关键程度排序）：

- 0：信息无关，或与学生知识状态完全不符
- 1：信息有一定相关性，但存在若干不符或离题之处
- 2：信息基本相关、仅有轻微不符，总体上与学生知识状态和学习需求契合

全面性 (Comprehensiveness)。衡量生成的解释对学生知识状态及所选练习题恰当性的覆盖程度。评估者应判断解释是否充分涵盖学生学习需求的所有相关方面。主要判断标准（按关键程度排序）：

- 0：信息不完整，遗漏了学生知识状态的许多关键方面
- 1：信息部分完整，覆盖了部分但非全部关键方面
- 2：信息全面，充分覆盖学生的知识状态与学习需求

总体分 (Overall Score)。通过评估流畅度、相关性和全面性来评价生成解释的质量。评估者应考虑解释表述是否清晰、与学生知识状态契合程度如何、对其学习需求覆盖是否充分。主要判断标准（按关键程度排序）：

- 0：解释表述差、基本无关，未能充分覆盖学生知识状态
- 1：解释较清晰、相关性中等、覆盖学生知识状态的部分方面
- 2：解释表述良好、高度相关，对学生知识状态与学习需求提供了透彻的理解

附录 F 提示模板

本节给出 LACAT 使用的部分提示模板（原文为英文，此处译出要点，变量名保留）。

提示模板 (Summarizer, 长期画像)。你是一名教育评估专家。你正基于一名学生对一组题目的对错作答，以及由 IRT 生成的能力估计，分析其表现。你的目标是对学生的强项与弱项做全面分析以帮助其改进。输入：Correct: {right response records}; Incorrect: {wrong response records}; Ability Estimation: {ability estimation}。请逐步仔细分析学生表现，推理过程应详尽。先基于答对记录总结强项（聚焦其擅长之处、已掌握的技能或知识领域），再基于答错记录总结弱项。要点包括：答对中的模式（反复出现的主题/技能、持续表现好的题型）、答错中的模式（常见错误或误解、经常出错的题型）、对比分析。严格按格式输出：Strength: <...>、Weakness: <...>。

提示模板 (Summarizer, 短期画像)。你是一名教育评估专家，正基于学生的画像及其在自适应测试中最近一次作答记录分析其近期表现。输入：Profile: {student profile}; Last record: {last response record}。请基于近期表现理解学生需求，分析其在最近一题上的表现，聚焦最近一答中表现出的强弱项。要点包括：理解学生画像、分析最近作答记录、给出可操作的反馈。严格按格式输出：Thought: < 对最近一题表现的分析 >。

提示模板 (Critic)。你是一名教育评估专家，职责是检查给学生的推荐是否恰当、有无基本错误。典型错误类型及示例：(1) 推荐题目过难、超出学生能力（如给挣扎于基础代数的学生推荐高等微积分）；(2) 推荐题目过易、低于学生实际能力；(3) 推荐题目知识饱和、覆盖学生已掌握的内容（如反复给已掌握几何的学生推荐同一组几何题）。输入：student_profile: {profile}; last_recommended_exercise: {exercise}。请检查推荐是否存在上述错误并给出判断（明确指出错误及类型）。严格按格式输出：Hint: < 一些简短提醒 >。

提示模板 (Reasoner)。通过逐步思考学生的强弱项，从候选题中选出最合适的一道，兼顾难度、区分度和知识覆盖。运用 CAT 原则，使学生答完此题后其能力能被更准确地测量。输入：Long-term profile: {strength}; candidate questions: {candidate_questions}; Short-term profile: {thought}; hint: {hint}。先分析长期表现（识别长期强弱项、已掌握/待提高的知识点）和短期表现（近期作答记录反映的即时学习需求）；再从难度、区分度、知识覆盖三方面评估候选题；并结合 CAT 的动态调整、精确测量原则；最后清晰解释选择理由。严格按格式输出：Reason: < 为何选此题、如何用此题探测认知状态 >、Selected question with index: < 仅一个题目索引 >。

参考文献 (References) 按约定未翻译，详见原文。