

面向计算机自适应测试的有界能力估计 (A Bounded Ability Estimation for Computerized Adaptive Testing)

原文: NeurIPS-2023-a-bounded-ability-estimation-...-Paper-Conference_17.pdf (NeurIPS 2023, Yan Zhuang, Qi Liu 等, USTC & UC Berkeley & 科大讯飞) · 译者: Claude · 译于 2026-06-26 术语对照: Computerized Adaptive Testing 计算机自适应测试 (CAT); Item Response Theory 项目反应理论 (IRT); ability estimation 能力估计; question selection 选题; Coreset 核心集; data summary 数据摘要; submodular 次模; facility location function 设施选址函数; gradient difference 梯度差。

摘要

计算机自适应测试 (Computerized Adaptive Testing, CAT) 作为一种能高效测量学生能力的工具, 已被广泛用于各类标准化考试 (如 GMAT 和 GRE)。CAT 的自适应性指的是为每位学生选择最具信息量的题目, 从而缩短测试长度。现有 CAT 方法并未显式地以能力估计的准确性为目标, 因为没有学生的真实能力作为真值 (ground truth); 因此, 这些方法无法保证在如此有限的作答下让估计收敛到真值。本文分析了估计的统计性质, 找到了真实能力的一个理论近似: 用学生对整个题库的完整作答所估计出的能力。在此基础上, 我们以数据摘要 (data-summary) 的方式提出一个面向 CAT 的有界能力估计框架 (Bounded Ability Estimation framework for CAT, BECAT), 它选择一个能紧密匹配完整作答梯度的题目子集。为此, 我们提出一种期望梯度差近似 (expected gradient difference approximation), 设计了一个简单的贪心选题算法, 并给出其能力估计的严格理论保证和误差上界保证。在真实世界数据集和合成数据集上的实验表明, 它平均能用少 15% 的题目达到相同的估计准确性, 显著缩短了测试长度。

1 引言

随着教育格局的快速变化 (尤其在新冠疫情之后), 许多学校和机构从课堂转向在线平台, 提供教育测量和推荐等个性化教育服务。他们希望根据学生的能力水平来“量体裁衣”地安排学习体验 [1, 2]。为此, 计算机自适应测试 (CAT) [3] 成为在标准化测试、计算机辅导和在线课程领域高效测量学生能力的不可或缺的工具, 它通过自动为每位学生选择最合适的题目来实现这一点。与耗时繁重的纸笔测试相比, CAT 已被证明能用更少的题目达到相同的测量准确性 [4, 2]。

一个典型的 CAT 系统如图 1 所示: 在测试步 t , 认知诊断模型 (如基于心理学的用户模型项目反应理论 IRT) 首先用学生此前 t 道题的作答来估计其当前能力 θ^t 。IRT 家族已被用于若干州级评估中的能力估计, 如 OECD/PISA 项目 [5, 6]。接着, 选题算法根据某些准则从整个题库中选出下一题 [7, 8, 9]。其中大多数是信息量度量, 例如选择难度最接近其当前能力估计 θ^t 的题目, 即学生答对它的概率最接近 50% [7]。显然, 选题算法是实现 CAT 自适应性的核心组件, 它试图回答下面这个关于准确性与效率的问题: **我们能否用尽可能少的题目、以可忽略的估计误差, 估计出学生的真实能力?**

图 1: CAT 系统示意图。在测试步 $t \in [1, \dots, T]$, 选题算法用当前能力估计 θ^t 从题库中选下一题 q^{t+1} 。测试停止时输出 θ^T (即对其真实能力 θ^0 的最终估计)。

从机器学习的视角看, CAT 可被视为一个代价最小的参数估计问题: 本质上是从整批未标注数据 (题库) 中顺序选出最少的数据样本 (待作答的题目), 使得在获得它们的标签 (对/错作答) 后, 能准确估计出模型的隐参数 (学生真实能力 θ^0)。遗憾的是, 学生的确切真实能力即便对学生自己也是未知的, 因此不可能在数据集中找到这样的真值来设计/训练选题算法。结果是, 大多数选题算法并未显式地以准确、高效的估计为目标设计。现有方法要么仅从题目特征空间选择有代表性/多样化的题目 [9] (偏离了能力估计的目标), 要么需要额外的训练开销 (如基于强化学习的方法 [10, 11, 12, 13])。尽管这些隐式方法在实验中取得了不错的结果, 但对于可靠的 CAT 系统 (尤其在标准化考试中), 逼近学生真实能力的理论保证同样至关重要。

显然, 设计可靠的显式方法的最大挑战是: 学生的真实能力 θ^0 未知。因此, 本文提出一个通用的 (上) 有界能力估计 CAT 框架 (BECAT), 它显式地以能力估计的准确性和效率为目标。由于 θ^0 未知, 我们首先找到它的理论近似 θ^* 作为替代: 用学生对整个题库的完整作答所估计出的能力。因此, 我们的关键思想是选择题目, 使得估计能最好地逼近“完整作答所估计出的能力”。具体地, 我们基于近期的数据高效/摘要技术 [14, 15, 16] 提出一种期望梯度差近似方法, 并在次模函数 (submodular function) 中设计了一个实用的贪心选题算法, 它本质上是寻找有代表性的题目来逼近完整作答的梯度。我们进一步给出关于其能力估计误差上界的理论分析。

为验证 BECAT 的有效性, 我们在来自不同教育平台的三个真实世界数据集上做实验。实验结果表明, 这个简单的贪心选题相比其他隐式方法达到了最先进的性能。主要贡献是:

- 为了更好地估计未知的 θ^0 , 我们找到它的理论近似作为设计显式选题算法的新目标。基于此, 我们首次以数据摘要的方式将 CAT 形式化地重新定义并转化为一个自适应子集选择问题。
- 提出一种有效的、基于期望梯度的选题算法来选取合适的题目, 它恰好最小化了估计误差项, 从而为 CAT 系统中的能力估计提供理论保证。
- 我们展示了 BECAT 的通用性——它可应用于任何基于梯度的方法, 包括 IRT 和神经网络方法。我们观察到 BECAT 在缩短测试长度上优于现有 CAT 方法, 达到相同估计准确性所需的题目少 10%–20%。

2 CAT 的问题定义

为了准确、高效地评估，CAT 需要从题库 Q 中为每位学生顺序选出最契合的题目，再用对应作答进行能力估计。当测试停止时，最终估计作为本次测试的结果/分数输出。CAT 的目标是准确估计考生的真实能力 θ^0 ，同时最小化所问题目数 [17]。

2.1 预备知识

具体地，在测试步 $t \in [1, 2, \dots, T]$ ，给定学生此前 t 个作答 $S_t = \{(q_1, y_1), \dots, (q_t, y_t)\}$ (其中 $\{q_i\}_{i=1}^t \subseteq Q$ 由选题算法顺序选出， y 是对/错的二值结果)，学生的当前能力可通过在整个能力空间 Θ 上最小化经验风险（如二元交叉熵）来估计：

$$\theta^t = \arg \min_{\theta \in \Theta} \sum_{i \in S_t} l_i(\theta) = \arg \min_{\theta \in \Theta} \sum_{i \in S_t} -\log p_\theta(q_i, y_i), \quad (1)$$

其中 $p_\theta(q_i, y_i)$ 表示能力为 θ 的学生作答 (q_i, y_i) 的概率， p_θ 的具体形式由 IRT 决定。由于 S_t 的规模很小，标准梯度下降 [18, 19] 足以最小化式 (1)，它需要计算 $\sum_{i \in S_t} \nabla l_i(\theta)$ ——此前 t 个作答数据上梯度的和。它沿梯度反方向反复迭代，从而得到式 (1) 经验风险的极小值。

接着，选题算法根据各种准则从题库 Q 中选出下一题 q_{t+1} [7, 8, 12, 13]。上述过程重复 T 次，即 $|S| = T$ (多数测试中 $T \leq 20$ [13])，确保最终步估计 θ^T 接近真实 θ^0 ，即：

定义 1 (CAT 的传统定义)。在每一步 t ，根据学生当前能力 θ^t 选出最合适/最具信息量的题目。测试结束时 ($t = T$)，最终能力估计 $\theta^T = \arg \min_{\theta \in \Theta} \sum_{i \in S} l_i(\theta)$ 能逼近真实能力：

$$\min_{|S|=T} \|\theta^T - \theta^0\|. \quad (2)$$

遗憾的是，直接求解上述优化问题是不可行的。因为真值能力 θ^0 无法获得，连学生自己也不知道确切值。结果是，传统的基于信息量的方法 [7, 8] 利用最大似然估计的渐近统计性质来降低估计不确定性，例如选择难度最接近学生当前能力 θ^t 的题目；但它们都是 IRT 特定的 (IRT-specific)，无法应用到近期的神经网络方法中。尽管近期基于主动学习 [9] 和基于强化学习 [12, 13] 的方法取得了不错的实验结果，但没有证据表明它们能在理论上保证估计高效逼近 θ^0 ，这对应用于标准化考试的 CAT 系统是不可接受的。测试可靠性不仅要求令人满意的实验结果，也要求良好的理论保证 [3]。

2.2 CAT 的新定义

鉴于数据集中没有真值 θ^0 ，为了设计显式选题算法，我们找到它的近似作为新目标。

命题 1。用学生对整个题库 Q 的完整作答所估计出的能力 θ^* ，是其真实能力 θ^0 的一个近似，即：

$$\theta^* \approx \theta^0. \quad (3)$$

证明。当我们使用一致估计 (consistent estimation) 方法 (如式 (1) 中的最大似然估计/交叉熵损失) 时，有 $\lim_{t \rightarrow \infty} p(|\theta^t - \theta^0| \geq \epsilon) = 0$ ，其中 t 是用于能力估计的作答数 (步数)。CAT 题库规模有限 (即 $t \in [0, |Q|]$)，且 $\theta^* = \lim_{t \rightarrow |Q|} \theta^t$ ，因此 $\theta^* \approx \lim_{t \rightarrow \infty} \theta^t \approx \theta^0$ ，即 θ^* 可被视为 θ^0 的近似。□

由于该命题利用了估计量的渐近性质，可能使近似不完美。例如，题库规模 $|Q|$ 和学生作答中的各种扰动都会影响该命题。因此，我们还做了仿真实验进一步验证：从 Θ 中随机采样 100 个 θ^0 作为真值，使用第 4 节中最小的 EXAM 数据集 ($|Q| = 1650$)；再用带这些 θ^0 的 IRT 模拟 100 个学生的作答行为 (对/错)。图 2(a) 显示，当题库规模超过 300 ($\approx |Q|/5$) 时，估计的 $\theta^* \approx \theta^0$ (蓝色)。即便加入一些极端扰动 (如猜测和失误因子 [13])，其 MSE 也不会超过 0.1。因此，在优化中用 θ^* 替代 θ^0 作为真值是合理的。

图 2: (a) 关于命题 1 的仿真实验，用 $\text{MSE } \mathbb{E}[\|\theta^* - \theta^0\|^2]$ 衡量。除正常情形 (蓝) 外，还展示不同扰动下的 MSE，例如 Slip5% 表示标签有 5% 概率从 1 变 0；Guess25% 表示标签有 25% 概率从 0 变 1。(b) 优化问题示意：选择子集 S 覆盖 Q 上的全部作答数据。矩形代表学生对题库 Q 的完整作答， $w(i, j)$ 衡量作答对 (i, j) 的相似度。

这样，选题算法就能以逼近 θ^* 为目标，而非未知的 θ^0 。我们可以设计显式选题算法：从题库 Q 中选出一个题目子集 S ，使得仅在子集 S 上估计的学生能力仍能 (近似) 收敛到最优解 θ^* (即“若在对 Q 的完整作答上优化所能得到的估计”)。如预备知识所述，能力估计通常采用带梯度计算的交叉熵损失，把损失关于能力参数的完整梯度记为 $\sum_{i \in Q} \nabla l_i(\theta)$ ——完整作答上梯度的和。因此：

定义 2 (CAT 的新定义)。自适应地找到一个规模为 T 的子集 S 及对应权重 $\{\gamma_j\}_j$ ，使其逼近完整梯度：对优化参数 $\theta \in \Theta$ 的所有可能能力值，最小化它们的差：

$$\min_{|S|=T} \|\theta^T - \theta^*\| \Rightarrow \min_{|S|=T} \max_{\theta \in \Theta} \left\| \sum_{j \in S} \gamma_j \nabla l_j(\theta) - \sum_{i \in Q} \nabla l_i(\theta) \right\|. \quad (4)$$

由于优化时我们对学生能力的范围一无所知，我们考虑最坏情况下的近似误差 ($\max_{\theta \in \Theta}$)，而非某个特定 θ 。在找到这样的 S 及相应权重 $\{\gamma_j\}_j$ 后，无论 θ 取值如何，在 S 上的梯度更新都将与在 Q 上的梯度相似，从而使估计接近目标 θ^* 。这样，CAT 就能以数据高效的方式被视为一个子集选择优化问题。同时，我们发现它与近期的核心集 (Coreset) 技术 [20, 15, 21] 一致——后者逼近完整数据的梯度，使模型仅在子集上训练却仍能 (近似) 收敛到最优解。

然而，与传统 Coreset 问题相比，最大的技术挑战是：没有标签就无法计算题库上的梯度 $\sum_{i \in Q} \nabla l_i(\theta)$ 。只有此前几步已作答的少数题目 (即 S_t) 才有对应标签。因此，为简化问题，我们暂时假设学生的完整作答可得。在第 3.1 节，我们将进一步提出一种期望近似方法来解决这一点。

3 BECAT 框架

本节中，为求解上述优化问题式 (4)，我们在次模函数中设计一个简单的贪心算法。更重要的是，我们给出使用本方法时能力估计期望误差的上界。

优化。上述子集选择问题是 NP 难的，因此我们基于近期的 Coreset 方法对其进行变换。可以证明，最小化“估计完整梯度误差”的子集 S 被一个次模设施选址函数 (submodular facility location function) 上界约束，该函数已用于各种摘要应用 [22, 23]。于是：

$$\min_{|S|=T} \max_{\theta \in \Theta} \left\| \sum_{j \in S} \gamma_j \nabla l_j(\theta) - \sum_{i \in Q} \nabla l_i(\theta) \right\| \Rightarrow \min_{|S|=T} \max_{\theta \in \Theta} \sum_{i \in Q} \min_{j \in S} \|\nabla l_i(\theta) - \nabla l_j(\theta)\| \Rightarrow \max_{|S|=T} \sum_{i \in Q} \max_{j \in S} w(i, j), \quad (5)$$

其中 $w(i, j) \triangleq d - \max_{\theta \in \Theta} \|\nabla l_i(\theta) - \nabla l_j(\theta)\|$ 是该学生作答对 $i = (q_i, y_i)$ 与 $j = (q_j, y_j)$ 之间的梯度相似度。作答 j 的相关权重 $\gamma_j = \sum_{i \in Q} \mathbb{1}[j = \arg \max_{s \in S} w(i, s)]$ ，即 Q 中与 $j \in S$ 最相似的作答个数。

给定子集 S ，式 (5) 中的 $\sum_{i \in Q} \max_{j \in S} w(i, j)$ 通过把每个 $i \in Q$ 与其最近的 $j \in S$ 之间的相似度 w 求和，量化了对 Q 上全部作答数据的覆盖度。该优化问题的语义见图 2(b)。 $w(i, j)$ 越大，它们在所有可能能力 $\theta \in \Theta$ 下的能力估计梯度差越小，意味着这两个作答 i 和 j 对学生能力估计有相似的重要性/影响。因此，式 (5) 变换后的问题等价于选择最有代表性的作答构成子集 S ，这与以往选题算法 [12, 9]、主动学习方法 [24, 25] 和无监督学习 [26, 27] “选择代表性题目”的思想一致。

定义一个单调非减的次模函数——设施选址函数 $F: 2^Q \rightarrow \mathbb{R}$: $F(S) = \sum_{i \in Q} \max_{j \in S} w(i, j)$ 。次模优化用简单的贪心算法即可提供具有 $(1 - 1/e)$ 近似界的近最优解 [28]，选第 t 题：

$$q_t = \arg \max_{(q, y) \in Q \setminus S_{t-1}} \Delta((q, y) | S_{t-1}). \quad (6)$$

其中 $\Delta((q, y) | S_{t-1}) = F(\{(q, y)\} \cup S_{t-1}) - F(S_{t-1})$ ， S_{t-1} 是该学生在 CAT 中此前 $t - 1$ 个作答的集合。

3.1 期望梯度差近似

然而，上述选题算法在 CAT 中不切实际。因为我们无法获得学生对题库 Q 的完整作答，于是没有相关作答对错标签就无法计算 $w(i, j)$ 中的梯度差 $\|\nabla l_i(\theta) - \nabla l_j(\theta)\|$ 。实际上，在步 t ，只能获得此前 $t - 1$ 步的作答 (即 S_{t-1})。因此，我们提出一种期望梯度差近似方法来替代原方法度量相似度，新的相似度函数 $\tilde{w}(i, j)$ 为：

$$\tilde{w}(i, j) \triangleq d - \max_{\theta \in \Theta} \mathbb{E}_{y \sim p_{\theta^t}} [\|\nabla l_i(\theta) - \nabla l_j(\theta)\|], \quad (7)$$

其中带范数的梯度差被计算为对所有可能标注 y 的期望 $\mathbb{E}_{y \sim p_{\theta^t}}$ ，因为在选题步中学生对候选题的作答标签 y 未知。此外，为了更准确地近似、并充分利用已有的此前 $t - 1$ 个作答，式 (7) 中的期望由当前估计 θ^t 决定。该方法可视为基于“软伪标签 (soft pseudo-labels)”的梯度差近似。于是，选下一题 q_t 不再需要学生真实的作答对错标签：

$$q_t = \arg \max_{q \in Q \setminus S_{t-1}} \Delta(q | S_{t-1}). \quad (8)$$

其中 $\Delta(q|S_{t-1}) = \tilde{F}(\{q\} \cup S_{t-1}) - \tilde{F}(S_{t-1})$, $\tilde{F}(S) = \sum_{i \in Q} \max_{j \in S} \tilde{w}(i, j)$ 。此外，我们还揭示了关于这个简单期望近似的一些重要结论：

算法 1: BECAT 框架 > 输入：题库 Q , f —IRT 或神经网络方法。> 初始化：作答数据 $S_0 \leftarrow \emptyset$ 。> **for** $t = 1$ **to** T **do** > 1. 基于 $\tilde{w}(i, j)$ 选题： $q_t \leftarrow \arg \max_{q \in Q \setminus S_{t-1}} \Delta(q|S_{t-1})$ 。> 2. 获取学生对应作答对/错标签 y_t ： $S_t \leftarrow S_{t-1} \cup \{(q_t, y_t)\}$ 。> 3. 更新权重 $\{\gamma_j\}_{j=1}^t$ ： $\gamma_j \leftarrow \sum_{i \in Q} \mathbb{1}[j = \arg \max_{s \in S_t} \tilde{w}(i, s)]$ 。> 4. 更新学生能力估计： $\theta^t \leftarrow \arg \min_{\theta \in \Theta} \sum_{i \in S_t} \gamma_i l_i(\theta)$ 。> 输出：学生最终能力估计 θ^T 。

引理 1. 当我们用 $\tilde{w}(i, j)$ 替换 $w(i, j)$ 中原始的梯度差时，相应设计的、使用次模函数 $\tilde{F}$ 的选题算法，实际上近似求解了如下优化问题：

$$\min_{|S|=T} \max_{\theta \in \Theta} \mathbb{E}_y \left\| \sum_{j \in S} \gamma_j \nabla l_j(\theta) - \sum_{i \in Q} \nabla l_i(\theta) \right\|. \quad (9)$$

基于引理 1 的结论，我们可以假设：优化后，预条件期望梯度可被一个至多为 ϵ 的误差近似： $\mathbb{E}_y[\|\sum_{i \in S} \gamma_j \nabla l_j(\theta) - \sum_{i \in Q} \nabla l_i(\theta)\|] \leq \epsilon$ 。然后我们找到把基于梯度的估计方法应用于它所找子集 S 时的能力估计理论保证：

定理 1 (期望估计误差界)。假设能力估计的损失函数是 α -强凸的（如 IRT）。设 S 是本方法得到的带权子集。则在学习率 $\frac{1}{\alpha}$ 下，对子集应用梯度下降进行能力估计具有如下期望估计误差界：

$$\mathbb{E} [\|\theta^{t+1} - \theta^*\|^2] \leq \frac{2\epsilon D\alpha + \sigma_l^2 + 2\sigma_f D\alpha H_p(\theta^t, \theta^*)}{\alpha^2}, \quad (10)$$

其中

$$H_p(\theta^t, \theta^*) = \mathbb{E}_{(q, y) \sim p_{\theta^t}} \left[\frac{1}{p_{\theta^*}(q, y)} \right], \quad (11)$$

θ^* 是用完整作答的最优估计， σ 是梯度范数的上界， $D = \max_{\theta} \|\theta - \theta^*\|$ 。

所有证明见附录。上述定理表明：尽管无法获得学生的完整作答，这种简单的期望梯度差近似也能让每一步的估计误差有上界。该定理对损失强凸的情形可达，如经典 L2 正则化 IRT [29] 的交叉熵损失。我们将在实验中进一步验证其他情形（如基于神经网络的方法）的性能。

定理 1 还提示：为最小化期望误差界，CAT 系统应尽量最小化 $H_p(\theta^t, \theta^*)$ ，它可被视为一种统计距离：衡量概率分布 p_{θ^t} 与 p_{θ^*} 的差异。此外，我们发现借助每一步的一致性估计（即二元交叉熵）， $H_p(\theta^t, \theta^*)$ 能达到其理论最小值：

定理 2. 假设由式 (1) 交叉熵损失估计的 θ^t 能最小化经验风险，即 $\sum_{i \in S_t} l_i(\theta^t) = 0$ 。则当 $\theta = \theta^t$ 时 $H_p(\theta, \theta^*)$ 取最小值，即

$$H_p(\theta^t, \theta^*) \leq H_p(\theta, \theta^*), \quad \forall \theta \in \Theta. \quad (12)$$

因此，CAT 中常用的能力估计方法实际上有助于最小化这一上界。证明和相关实验见附录 C 和 E.4。

BECAT 的复杂度分析。 算法 1 给出了 BECAT 框架的伪代码。式 (8) 选题算法的朴素实现复杂度为 $O(|Q|^2|\Theta|)$ ，因为每一步都要：(1) 从题库中找题 ($O(|Q|)$)，(2) 最大化边际增益 $\Delta(q|S_{t-1}) = \tilde{F}(\{q\} \cup S_{t-1}) - \tilde{F}(S_{t-1})$ （复杂度 $O(|Q||\Theta|)$ ）。为从上述两方面让 BECAT 更快、更可扩展，我们采用两个加速技巧：惰性求值 (lazy evaluations) [30, 31] 和多面估计 (multifaceted estimation) [32]（实现细节见附录 D）。我们还在附录 E 中比较了不同方法的选题耗时（秒）。

4 实验

评估方法。 CAT 的目标是用最少的步数准确估计学生能力。因此，遵循以往工作 [9, 12]，通常有两个任务来验证不同 CAT 方法的性能：(1) **学生成绩预测 (Student Score Prediction)**：为评估 CAT 输出的能力估计，可用该估计预测学生在留出作答数据中已答题目上的二值作答（对/错）。因此用预测准确率 (ACC) 和 AUC 评估 [33]；(2) **能力估计仿真 (Simulation of Ability Estimation)**：这是 CAT 的传统评估方法。由于学生能力真值 θ^0 不可得，我们人工生成 θ^0 并进一步仿真学生一题目交互过程，从而可用均方误差 (MSE) 指标。两种评估方法的细节见附录 E。

数据集。 我们在三个教育基准数据集 ASSIST、NIPS-EDU、EXAM 上做实验。ASSIST [34] 采集自在线教育系统 ASSISTments，包含学生数学练习日志。NIPS-EDU [35] 指 NeurIPS 2020 教育挑战赛中的大规模数据集，采集自学生对 Eedi（一个教育平台）题目的作答。EXAM 数据集由科大讯飞提供，收集了初中生数学考试记录。数据集统计见附录。代码见 github: <https://github.com/bigdata-ustc/EduCAT>。

对比方法。为验证 BECAT 的通用性,除传统 IRT 外,我们还比较基于神经网络的模型 NeuralCDM [36]: 它能涵盖许多 IRT 和认知诊断模型,如 MIRT [37] 和 MF [38, 39]。选题算法方面,我们主要用以下 SOTA 算法作基线: **Random**: 随机选题策略,作为量化其他方法改进的基准; **FSI** [7] 和 **KLI** [8] 选择 Fisher/Kullback-Leibler 信息最大的题目,该信息衡量一道题携带的关于未知参数 θ 的信息量,二者专为 IRT 设计; **MAAT** [9] 用主动学习 [40] 衡量每道候选题带来的不确定性; **BOBCAT** [12] 和 **NCAT** [13] 分别把 CAT 重塑为双层优化和强化学习问题,从学生作答数据中训练数据驱动的选题算法。

4.1 结果与讨论

本节我们在上述两个经典 CAT 任务上比较性能,评估 BECAT 框架的有效性跟效率。我们还对所选题目的特性做了定性考察,更深入地洞察 BECAT 为何能带来更准确的能力估计。

任务 1: 学生成绩预测。遵循以往工作 [13],我们同样固定最大长度 $T = 20$,在三个数据集上计算第 5、10、20 步的 ACC 和 AUC,结果见表 1 (原文表 3)。我们发现:

- (1) 显式的 BECAT 框架在三个数据集上取得了最佳的整体性能,显著优于所有其他方法。在 ASSIST 上,相对性能改进在 ACC@20 上平均至少 1.5%、AUC@20 上至少 1.1%。这表明 BECAT 能在考试结束时提供准确的能力估计。它甚至超过了基于深度学习的隐式选题算法 (如 NCAT 和 BOBCAT)。这一现象说明: 相比专注于建模复杂的学生-题目交互,直接以估计准确性为目标确实能取得惊人的效果。
- (2) BECAT 在大规模数据集 (如 NIPS-EDU) 上表现更好。从表 1 看,在 NIPS-EDU (题库规模 27613) 上, BECAT 相比著名的 FSI 基线平均取得 2.48% 的 AUC 提升。在另两个数据集 ASSIST 和 EXAM 上,平均提升仅 0.32%。这一发现启示我们: BECAT 更适应实际的大规模测试场景,能从海量候选题中检索出最合适的题目。然而不可忽视的是, BECAT 在考试开始阶段无法超过所有其他方法。例如在 NIPS-EDU 上,它在 ACC@5 上落后 BOBCAT 约 2.53%。这是因为考试初期可用的学生作答数据有限,而数据驱动方法 (如 BOBCAT 和 NCAT) 能在大规模学生作答数据集上预训练以学习交互模式,从而解决这一冷启动问题 [41]。因此,把所提显式算法适配到数据驱动框架是很有前景的未来工作。

表 1: 不同方法在学生成绩预测上的 ACC 与 AUC 表现 (ASSIST/NIPS-EDU/EXAM 三数据集 $\times$ IRT/NeuralCDM $\times$ 5/10/20 步)。“—”表示基于信息/不确定性的选题算法 (如 FSI) 无法用于深度学习方法。加粗表示相对最佳基线的统计显著改进 ($p < 0.01$)。(此处为原文表格,结构复杂未逐一转录。要点: BECAT 在 @20 上几乎全部最优,如 ASSIST/IRT ACC@20=73.96、NIPS-EDU/NeuralCDM AUC@20=79.36; 初期 @5 偶尔落后 BOBCAT/NCAT。)

任务 2: 能力估计仿真。实用 CAT 系统的目标是准确估计学生能力。我们在 EXAM 数据集上做能力估计仿真实验,用每一步能力估计 θ^t 与真实能力 θ^0 之间的均方误差 $\mathbb{E}[\|\theta^t - \theta^0\|^2]$ 衡量。图 3(a) 报告了不同方法在 IRT 上的结果。随着所选题目数增加,我们发现 BECAT 方法总能取得低得多的估计误差,尤其在中间阶段。一些不以估计准确性为目标的隐式方法在初期表现更好 (如 NCAT),但最终准确性仍落后于 BECAT 框架。同时,与广泛使用的 FSI 相比, BECAT 最多能用少 20% 的题目达到相同估计误差。平均而言,它能用少 15% 的题目达到相同估计准确性,这证明了它在能力估计上的效率,即缩短测试长度。

所选题目的特性。为深入洞察 BECAT 为何带来更准确的估计,我们仔细考察所选题目的特性。首先,对 IRT,我们输出所选题目的难度和区分度参数,画成图 3(b) 的散点图。我们发现它倾向于选择高区分度的题目,且其难度分散、大致集中在中等难度区域,这可能是由于大多数学生是中等能力 [42]。其次,对 NeuralCDM,为更好地洞察所选题目覆盖的知识概念 (如数学中的几何) 以及 BECAT 与其他方法的关联,图 3(c) 展示了题目概念的 Jaccard 相似系数。同类方法选的题目在知识概念上重叠度高,如 FSI 与 KLI、BOBCAT 与 NCAT。MAAT 和 FSI 与 BECAT 的相似度最高: 1) 尽管 BECAT 在选题时不直接采用概念特征,但它与直接以知识概念覆盖/多样性为目标的 MAAT 得分高,从而使测量更全面; 2) 与 FSI 的高相似度证明 BECAT 不仅通用,也能选出有信息量的题目。

图 3: (a) EXAM 数据集上的能力估计误差。(b) IRT 中为 10 名学生所选题目的特性 (区分度与难度),灰点是题库全部题目,“□”是 BECAT 所选。(c) 所选题目的 Jaccard 相似系数。

5 相关工作

计算机自适应测试。CAT 技术已被广泛用于许多标准化考试 (如 GMAT), GRE 中的多阶段测试也是 CAT 的特例 [17]。它是一个迭代过程,主要包括项目反应理论和选题算法。下面分别回顾这两个组件:

- (1) **项目反应理论 (IRT)**。它建立在心理测量理论之上,已在教育评估中流行,用于提供关于学生潜在能力的更个性化反馈 [43, 44]。它假设考生能力在整个测试中保持不变,因此能力可用其此前作答以基于梯度的优化来估计 [32]。经典形式是双参数 logistic (2PL): $p(\text{对题目 } j \text{ 答对}) = \text{sigmoid}(a_j(\theta - b_j))$, 其中 $a_j, b_j \in \mathbb{R}$ 分别表示每道题的区分度和难度 (考前预先标定 [29]), $\theta \in \mathbb{R}$ 是待估计的学生能力。近期许多研究 [36, 45, 46] 结合认知诊断、用神经网络来建模这种学生-题目交互 (如 NeuralCDM [36])。
- (2) **选题算法**。选题算法是实现 CAT 自适应性的核心组件——用最少测试步准确估计学生能力。传统算法基于某些不确定性或信息量度量,如著名的 Fisher 信息 (FSI)。在此基础上,许多方法 [8, 47, 48, 49] 被提出以在选题中引入额外信息。由于它们不通用、不适用于近期的神经网络方法, MAAT [9] 用主动学习在题目特征空间选择多样且有代表性的题目。近期, BOBCAT [12] 和 NCAT [13] 把 CAT

视为强化学习 (RL) 问题, 直接从大规模学生作答数据训练选题算法。由于 θ^0 未知, 它们的目标是最小化估计在留出作答数据上的学生成绩预测损失, 这也是隐式的、容易受训练数据偏差影响。本文的 BECAT 是通用的, 并显式地以能力估计的准确性和效率为目标。与以往隐式方法相比, 我们发现它在理论和实验上都表现更优。然而, 各种偏差 (如测试题目设计和受试群体选择中引入的偏差) 会影响估计学生真实能力的有效性 [50]。虽然我们的方法力求提升估计学生能力的效率, 但并不减轻测试设计者缓解模型拟合之外引入的偏差源的必要性。

数据高效。另一类密切相关的文献是数据高效 (或数据摘要) [51, 15, 52]。为缓解各种代价 (计算 [53, 54] 或标注 [40] 代价), 数据高效被用于从数据集中精心选择或生成一些与完整数据相当的样本。其具体实现方法包括核心集 (Coreset) [15, 21, 16, 20]、主动学习 [40, 55, 56]、数据蒸馏 [57] 等。例如, 近期的 Coreset 方法 [15, 21, 20] 试图找到一个紧密逼近完整梯度 (即全部训练样本梯度之和) 的子集。本文中, Coreset 帮助我们在第 2.2 节变换优化问题, 但梯度计算需要标签, 这显然不适用于 CAT 场景 (选题前无法获得学生作答标签)。因此, 我们对其加以改进, 设计了一种期望梯度差近似方法, 并给出对最优解的良好上界保证, 这是本文的主要贡献之一。

6 结论

本文聚焦于准确、高效估计学生真实能力 θ^0 的显式方法。鉴于真值 θ^0 不可得, 我们找到它的理论近似——用对题库完整作答估计出的能力, 并以它为优化目标, 设计了有界能力估计 CAT 框架 (BECAT)。为在 CAT 场景中实用, 我们在贪心选题算法中提出一种简单但有效的期望梯度差近似。我们进一步分析其理论性质, 并证明了 BECAT 所找题目上能力估计的误差上界。通过在三个真实世界教育数据集上的大量实验, 我们证明 BECAT 能取得最佳估计准确性, 并在缩短测试长度上优于现有 CAT 方法。

致谢

本研究部分受国家重点研发计划 (No. 2021YFF0901003)、国家自然科学基金 (No. U20A20229, No. 62106244) 以及 UC Berkeley 资助。

参考文献 (References) 按约定未翻译, 详见原文。