

SACAT: 学生自适应的计算机自适应测试 (SACAT: Student-Adaptive Computerized Adaptive Testing)

原文: 3627676.3627679.pdf (DAI '23, 上海交通大学 & 华为诺亚方舟实验室 & 吉林大学) ·译者: Claude ·译于 2026-06-27 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT)、认知诊断模块 (Cognitive Diagnosis Module, CDM)、选题算法 (Selection Algorithm)、元学习 (meta-learning)、协同检索 (Collaborative Retrieval)、快速自适应 (Fast Adaptation)、能力 (ability, θ)、项目反应理论 (Item Response Theory, IRT)

摘要

计算机自适应测试 (CAT) 指的是一种在线学生能力测试系统, 它由选题算法 (Selection Algorithm) 和认知诊断模块 (CDM) 组成。选题算法旨在为新到来的学生精心挑选一小批题目作答, CDM 则旨在根据该学生对所选题目的作答来推断其能力。CDM 面临的挑战是: 如何基于很短的“题目—作答”序列来推断学生能力。目前最先进的方法采用元学习框架来解决这一挑战。具体而言, 在元学习框架的外层, 它从所有学生中学到一个平均学生能力, 作为新到来学生的初始能力; 在内层, 它再从这条短序列中推断新到来学生的能力。然而, 这种方法存在两大局限: 第一, 没有利用新到来学生与全体学生之间的协同信息; 第二, 元学习框架收敛缓慢。本文提出学生自适应的计算机自适应测试 (SACAT), 通过以下两点解决上述问题: 第一, 用新到来学生的短序列从全体学生中检索出相似学生; 第二, 设计一个快速自适应函数, 能够从相似学生的能力中自适应地生成一个适合新到来学生的能力表征。通过在三个真实学生作答数据集上的大量实验, 我们验证了 SACAT 能够超越现有 CAT 方法。此外, 借助快速自适应, 我们证明 SACAT 实现了快速的模型收敛。

CCS 概念: 以人为中心的计算 → 协同与社会计算中的实证研究; 应用计算 → 协作学习。

关键词: 小样本学习 (few-shot learning)、快速自适应、计算机自适应测试。

1 引言

在线测试平台 (如 GRE、GMAT、SAT) 中, 计算机自适应测试 (CAT) 系统被广泛用于评估学生的能力。CAT 系统之所以实用, 是因为它能用合理数量的、精心挑选的题目准确估计学生能力。如图 1(a) 所示, 一个 CAT 系统由两部分组成: (1) 选题算法, 旨在为新到来的学生挑选一小批最具信息量的题目以估计其能力; (2) 认知诊断模块 (CDM), 旨在从学生很短的“题目—作答”序列中准确推断其能力。这两部分以“选题—能力推断”的方式迭代协作。当前 CAT 研究主要聚焦两方面: 一方面, 一些工作研究选题算法如何挑出最有效的题目; 另一方面, 一些工作研究 CDM 如何通过短序列推断学生能力, 其中最有效的方法采用了元学习的双层结构。具体而言, 如图 1(b) 所示, 在外层确定所有学生的平均能力; 在内层, 把平均能力作为新到来学生的初始能力, 再从其短序列推断出新到来学生的最终能力。

图 1: (a) 在 CAT 系统中, 选题算法与认知诊断模块 (CDM) 协同工作。 (b) 现有工作从历史学生中学到初始学生能力, 并基于短的“题目—作答”序列推断最终学生能力。 (c) SACAT 用短序列检索相似学生, 并设计一个快速自适应函数来引导对新到来学生的能力推断。

当把 CAT 套进元学习框架时 (如 BOBCAT 和 NCAT), 一种直接的做法是把外层从全体学生学到的学生能力, 复制为内层中每个新到来学生的初始能力, 然后内层的能力推断从这个初始化开始。然而, 这类做法有两个弱点。第一, 学生各不相同、能力各异, 这些方法没有利用被测的新到来学生与全体学生之间的协同信息。直观地说, 在全体学生中, 那些“题目—作答”序列与被测新到来学生的短序列相似的学生, 其能力应当最接近被测的新到来学生。以协同的方式使用相似学生、而不是使用全体学生, 将能增强学生能力评估。例如, 用图 1(c) 所示的检索过程来检索与被测新到来学生相似的学生, 替换掉图 1(b) 中的“全体学生”。这样就利用了协同信息, 消除了“全体学生”中不相似学生的干扰, 从而为被测新到来学生得到更准确的初始能力估计。第二, 如图 1(b) 所示, 双层结构在“外层优化全体学生平均能力”与“内层优化单个学生能力”之间交替进行。在外层每一轮优化平均学生能力时, 都会引入一定程度的不相似学生干扰, 导致学生能力推断的收敛效率低下。基于这一考虑, 利用协同信息、并为不同学生自适应地推断能力, 是至关重要的。

本文提出学生自适应的计算机自适应测试 (SACAT), 它通过利用协同信息来帮助 CDM 更准确地推断学生能力, 并设计了一种快速自适应机制来加速学生能力推断的收敛。具体而言, 如图 1(c) 所示, SACAT 由两个过程组成: 协同检索过程与快速自适应过程。它先进行协同检索, 再进行快速自适应。在协同检索过程中, SACAT 用新到来学生的短序列从全体学生中检索相似学生, 并计算这些相似学生的能力。在快速自适应过程中, SACAT 利用相似学生的能力来推断目标学生的能力。通过在三个真实学生作答数据集 (Assist09、Eedi-2、EdNet) 上的大量实验, 我们证明所提出的 SACAT 在预测准确率指标上显著优于其他对比方法。为进一步分析其有效性, 我们做了一个案例研究, 表明 SACAT 能把不同类型的学生映射到彼此分离的能力域中。此外, 我们还证明 SACAT 实现了快速的模型收敛。作为一个 CAT 系统, 我们也证明 SACAT 带来了可接受的题目曝光率 (question exposure) 与上下文重叠率 (context overlap)。

本文的贡献总结如下:

- 引入协同信息, 以增强 CDM 在处理短序列时推断学生能力的准确性。据我们所知, SACAT 是首个在 CAT 系统中显式利用协同信息的工作。
- 设计了一种学生能力快速自适应机制, 以在利用协同信息时加速 CDM 的收敛。
- 通过实验验证了最先进的性能与改善的收敛性。

2 相关工作

2.1 计算机自适应测试

计算机自适应测试 (CAT) 指的是一种在线学生能力测试系统, 其中选题算法旨在为不同能力的学生挑选最具信息量的题目, CDM 旨在准确测量每个学生的能力。长期以来, 经典 CAT 系统使用项目反应理论 (IRT) 模型作为 CDM。大多数选题算法, 如最大 Fisher 信息量 (Maximum Fisher Information, MFI) 和 Kullback-Leibler 信息指数 (KLI), 都是专为 IRT 模型设计的。

近年来, 深度学习已成为设计 CAT 系统的有力工具。一批富有成效的选题算法蓬勃发展, 如使用主动学习的 MAAT。与此同时, CDM 从 IRT 演进到 MIRT、神经网络 (NN) 和 NCDM。从短序列推断学生能力是一个小样本学习问题, 近来一些工作聚焦于解决类似问题。最先进的方法 (如 NCAT 和 BOBCAT) 利用元学习来增强 CDM。元学习采用双层优化框架, 即外层优化和内层优化。在外层确定所有学生的平均能力; 在内层, 把平均能力作为新到来学生的初始能力, 再从其短序列推断最终能力。然而, 仅仅学一个平均能力作为初始学生能力是次优的。从协作学习的视角看, 进一步为被测新到来学生检索相似学生、并为不同学生自适应地推断能力, 可能对 CAT 系统更有帮助。所提出的 SACAT 利用了协同信息, 此外还引入一个能力自适应函数来为不同学生推断能力。

3 预备知识

CAT 过程与问题陈述。如前所述, 一个 CAT 系统由选题算法与 CDM 两部分组成。在基于元学习的方法以及 SACAT 的设定中, 每个学生的数据被切分为两部分: (1) 选题集 A , 供选题算法选题使用; (2) 查询集 Q , 用于验证 CDM 推断出的学生能力的准确性。

如图 1(a) 所示, CAT 的典型过程如下: 对于新到来的学生 u_i , 在时间步 t , 选题算法 (记为 $q_t \sim \pi(s_{t-1}^i)$) 根据学生在时间步 $t-1$ 的短“题目—作答”序列 s_{t-1}^i , 为学生 u_i 选出题目 $q_t \in A$ 。其中 $s_{t-1}^i = \{(q_1, a_1), \dots, (q_k, a_k), \dots, (q_{t-1}, a_{t-1})\}$, (q_k, a_k) 表示在时间步 k 的题目 q_k 及其对应的作答结果 a_k 。学生 u_i 作答题目 q_t 后, 我们得到“题目—作答”对 (q_t, a_t) , 并把序列 s_{t-1}^i 更新为 s_t^i 。然后短序列 s_t^i 被送入 CDM (记为 $\theta_i^t \sim M(s_t^i)$), 以推断学生 u_i 在时间步 t 的能力 θ_i^t 。

我们把学生 u_i 的真实能力记为 θ_i^* 。给定最终时间步 T , CAT 系统的目标是让推断出的 $\hat{\theta}_i^T$ 尽可能接近真实学生能力 θ_i^* 。我们的工作聚焦于增强 CDM, 使其在时间步 T 从短序列 s_T^i 推断出的 $\hat{\theta}_i^T$ 尽可能接近真实学生能力 θ_i^* 。为衡量 $\hat{\theta}_i^T$ 与真实学生能力 θ_i^* 之间的差异, 我们对查询集中所有对应题目 $q_l \in Q$, 计算作答结果预测 $\hat{a}_l$ 与真实标签 a_l 的 AUC。该预测过程表述为 $\hat{a}_l = G(\hat{\theta}_i^T, q_l)$ 。

4 方法

我们提出 SACAT, 它由协同检索过程与快速自适应过程组成, 帮助 CDM 利用协同信息, 从而更准确地从短题目序列推断能力, 并获得更快的收敛。首先, 我们介绍协同检索过程, 它用新到来学生的短序列从全体学生中检索相似学生, 并计算这些相似学生的能力。其次, 我们介绍快速自适应过程, 它利用相似学生的能力来推断新到来学生的能力。最后, 我们讨论快速自适应过程中使用的自适应函数。

协同检索 (Collaborative Retrieval)。受其他领域检索方法的启发, 我们设计了协同检索方法。对于任意学生 u_i , 其在时间步 t 的“题目—作答”序列记为 $s_t^i = \{(q_1, a_1), \dots, (q_k, a_k), \dots, (q_t, a_t)\}$ 。其中 $(q_k, a_k) \in s_t^i$ 满足 $q_k \in A$ 且 $a_k \in \{-1, 1\}$ 。 $a_k = 1$ 表示学生 u_i 答对 q_k , $a_k = -1$ 表示答错。令 $s^i \in \{-1, 0, 1\}^{|A|}$ 为其状态向量。对所有 $(q_k, a_k) \in s_t^i$, s^i 的第 q_k 维取值为 $s^i[q_k] = a_k$ 。对于 $q_l \in A$ 且 $(q_l, a_l) \notin s_t^i$, $s^i[q_l]$ 取值为 0; 这里 $s^i[q_l] = 0$ 表示题目 q_l 未被学生 u_i 作答。当学生 u_i 是待测能力的学生时, 我们按如下方式检索与他相似的学生:

定义 4.1 (相似学生): 给定状态为 s^i 的学生 u_i 与状态为 s^m 的学生 u_m , 若 $|\cos(s^i, s^m)| \leq \alpha$, 则学生 u_m 与学生 u_i 互为相似学生。其中 α 是一个作为超参数的正标量。

对于与学生 u_i 相似的每个学生 u_m , 我们按如下方式计算其能力 $\hat{\theta}_m$:

$$\hat{\theta}_m = M_{\gamma^*}(s^m) \quad (1)$$

$$s.t. \quad \gamma^* = \arg \min_{\gamma} \sum_{q_k \in A_m} \ell(a_k, G(M_{\gamma}(s^m), q_k)), \quad (2)$$

其中 γ 是 CDM $M(\cdot)$ 的参数, $G(\cdot)$ 是预测函数, ℓ 是 BCE 损失 (二元交叉熵), A_m 是学生 u_m 的选题集。

快速自适应 (Fast Adaptation)。从学生 u_i 的状态 s^i 出发, 假设我们得到 n 个相似学生 $u_{m_1}, u_{m_2}, \dots, u_{m_n}$, 并用式 (1)、(2) 计算出他们对应的能力 $\hat{\theta}_{m_1}, \hat{\theta}_{m_2}, \dots, \hat{\theta}_{m_n}$ 。我们引入一个带参数 ϕ 的能力快速自适应函数 $f_{\phi}(\cdot)$, 从相似学生计算学生 u_i 的能力:

$$\hat{\theta}_i = f_{\phi^*}(\hat{\theta}_{m_1}, \hat{\theta}_{m_2}, \dots, \hat{\theta}_{m_n}) \quad (3)$$

$$s.t. \quad \phi^* = \arg \min_{\phi} \sum_{q_k \in Q_i} \ell(a_k, G(f_{\phi}(\hat{\theta}_{m_1}, \hat{\theta}_{m_2}, \dots, \hat{\theta}_{m_n}), q_k)), \quad (4)$$

其中 Q_i 是学生 u_i 的查询集。经过快速自适应后，我们得到 $\hat{\theta}_i$ 作为学生 u_i 用于推断的初始能力。从学生 u_i 的短序列 $s_t^i = \{(q_1, a_1), \dots, (q_k, a_k), \dots, (q_t, a_t)\}$ 出发，我们得到最终学生能力：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \sum_{(q_k, a_k) \in s_t^i} \ell(a_k, G(\theta, q_k)). \quad (5)$$

自适应函数 (Adaptive Function)。第 4 节引入的能力快速自适应函数可以采用广泛的函数族。本节描述我们如何设计它。

能力快速自适应函数（简称自适应函数） $f_{\phi}(\cdot)$ 以相似学生的能力为输入，生成适合每个学生的初始学生能力作为输出。当自适应函数采用线性神经网络（即不含激活的单层 MLP）时，我们将该方法命名为 **f-linear**。当自适应函数采用带激活的多层 MLP 网络时，我们命名为 **f-nn**。我们采用的架构是带 Sigmoid 激活的两层 MLP 网络。我们曾尝试把 f-nn 模块加深、加宽，但性能变化不大。

5 实验

本节详细介绍实验设置与相应结果。实现将公开提供。我们用以下研究问题（RQs）来引导实验与讨论：

- **RQ1**: SACAT 在学生表现预测上是否优于基线方法？
- **RQ2**: SACAT 是否比其他方法更准确地捕捉学生能力？
- **RQ3**: 自适应函数如何有效地把不同类型的学生映射到学生能力分布的分离域中？
- **RQ4**: SACAT 是否比基于元学习的方法收敛得更好？
- **RQ5**: 快速自适应是否比元学习基线方法的内层优化表现更好？
- **RQ6**: SACAT 在题目曝光与测试重叠方面表现如何？

5.1 实验设置

5.1.1 数据集 我们使用三个公开基准数据集：ASSIST09、Eedi-2、EdNet。如表 2 所示，我们列出了学生数、题目数和交互数。我们在补充材料中提供每个数据集的预处理细节与额外背景。对所有数据集，我们进行 5 折交叉验证；每一折中，分配 60% 的学生用于训练、20% 用于验证、20% 用于测试。对于 SACAT，我们把每个学生 u_i 作答的题目划分为选题集 (A_i , 80%) 与查询集 (Q_i , 20%)。

表 2: 数据集统计信息。

数据集	学生数	题目数	交互数
ASSIST09	2.3K	26.7K	325K
Eedi-2	5K	1K	1.4M
EdNet	312K	13K	76M

5.1.2 评估方法 我们在查询集 Q_i 上同时使用准确率 (ACC) 与 ROC 曲线下面积 (AUC) 作为指标，评估所有方法在预测二值学生作答上的表现。

5.1.3 对比方法 如前所述，CAT 由选题算法与 CDM 组成。我们的实验主要涉及两个经典 CDM 模型：传统的多维项目反应理论 MIRT 和近来兴起的神经网络 (NN)。我们将 SACAT 与以下 CAT 系统对比：

- **Random**: 随机选题策略。
- **MAAT**: 一种基于主动学习的方法，通过计算每道题引起的期望模型变化 (EMC) 来衡量题目的信息量。
- **NCAT**: 一种基于强化学习的方法，设计了基于注意力的 DQN 来选题。
- **BOBCAT**: 首个双层优化框架，把 MAML 引入 CAT 系统，并为 CAT 采用一种近似梯度估计方法，以学习数据驱动的选题算法。

5.1.4 超参数 我们用带 L2 正则的逻辑回归训练 MIRT 模型。对于 NN，我们使用一个两层全连接网络 (256 个隐藏节点、ReLU 非线性、20% dropout、最终 sigmoid 输出层) 作为作答模型，输入是每个学生特有的 256 维能力向量。所有方法均用 PyTorch 实现。

5.2 性能比较 (RQ1)

学生表现预测任务通常用于评估 CAT 系统的有效性。表 1 报告了不同方法在第 t 步选题后查询集上的平均 AUC 与 ACC 指标，我们分别在选题数（或测试长度）为 1、5、10 时给出结果。

我们有如下观察：SACAT 在三个基准数据集、所有测试长度下，都取得了最佳的 AUC 与 ACC，显著优于 SOTA 方法。这暗示我们提出的 SACAT 框架捕捉到了更准确的学生能力状态 θ_i ，从而使查询集上的学生表现预测更准确。

** 表 1：三个公开数据集上的 AUC 与 ACC 表现。最佳加粗，次佳下划线，”*”表示用 t-检验衡量、p 值低于 0.05 的统计显著提升。**（此处为原文表 1，结构为 3 数据集 $\times$ 2 种 CDM $\times$ {1,5,10} 步，仅转录关键结论：以 ASSIST09 + MIRT 为例，AUC 在 step=1/5/10 时 SACAT 取得 73.39/76.68/77.26，相比次佳 BOBCAT 的 70.22/73.36/73.76 全面领先；SACAT 在几乎所有 18 个 AUC 列和 18 个 ACC 列上均为最佳且多数带显著性标记 *。）

5.3 能力估计 (RQ2)

CAT 系统旨在用尽可能少的题目获得关于学生能力尽可能准确的信息。因此，估计出的学生能力 $\hat{\theta}_i$ 可用来给 CAT 系统打分。我们在 Eedi-2 数据集上进行实验，用当前能力参数估计 $\hat{\theta}_i^{(n)}$ 与真实能力 θ_i^* 之间的平方误差作为评估指标。这里 n 表示能力 $\hat{\theta}_i^{(n)}$ 是在选题算法选出 n 道题之后估计的。由于真实学生作答数据集中的真实学生能力是未知的，我们用每个学生对所有作答题目所估计出的能力值作为替代。以 NN 为 CDM，我们比较以下 CAT 方法：Random、MAAT、BOBCAT、NCAT、带线性自适应函数的 SACAT (SACAT-linear)、带 nn 自适应函数的 SACAT (SACAT-nn)。图 2 展示了不同选题数下的能力估计误差（五折平均）。我们看到，模型估计能力与真实能力之间的 MSE 随测试步数增加而下降，且 SACAT-linear 与 SACAT-nn 相比其他方法都有更低 MSE。一方面，SACAT 在相同题目数下实现了更准确的估计；另一方面，SACAT 用更少的题目就能达到相同的准确度，这意味着 SACAT 能显著缩短测试长度。

图 2：在 Eedi-2 数据集上 MSE 随测试步数增加的变化。

5.4 自适应函数的映射有效性 (RQ3)

为深入理解能力自适应函数如何带来更准确的题目预测，我们仔细观察映射后的学生能力分布。我们在 Eedi-2 数据集上实验，在 SACAT 框架下使用 nn 作为能力自适应函数。

首先，我们把答题数排名前 5% 的学生标为绿色，把答题数排名后 5% 的学生标为红色，“绿色”与“红色”合计约 150 名学生。不同类型的学生被映射到能力高维空间的分离区域。由于学生能力是高维向量，我们用 tSNE 在 2D 与 3D 维度上刻画学生能力。经能力自适应函数映射后，绿色类型与红色类型的学生能力分别聚集（图 3(a) 与 3(b)）。

其次，为进一步观察能力自适应函数是否把不同能力的学生映射到不同区域，我们选取两类不同的学生：把从第 1 题到第 4 题都答对的学生标为绿色，把所有题都答错的学生标为红色。经能力自适应函数映射后，如图 3(c)(d) 所示，可以看到绿色类型与红色类型比图 3(a)(b) 聚集得更分离。

结果表明，具有不同学生能力的不同类型学生能够被映射到不同区域（图 3(a)(b)）。

图 3：在 Eedi-2 数据集上经能力函数映射后的学生能力分布。(a) 前 5% 与后 5% 学生的 3D 图。(b) 前 5% 与后 5% 学生的 2D 图。(c) 两类学生的 3D 图。(d) 两类学生的 2D 图。

5.5 快速自适应 (RQ4)

我们用训练 epoch 数来评估模型收敛。在表 3 中，我们报告 BOBCAT、SACAT-linear、SACAT-nn 在 ASSIST09 数据集上模型收敛时的 epoch 数。我们在每对数据集与查询上随机生成 20 次种子。SACAT-linear 与 SACAT-nn 的 epoch 数都小于 BOBCAT，可见两者都比 BOBCAT 收敛更快。

表 3：不同方法在不同选题数下于 ASSIST09 数据集上收敛所需的 epoch 数。

n_query	1	3	5	10
BOBCAT	276 $\pm$ 54	527 $\pm$ 51	542 $\pm$ 44	448 $\pm$ 45
SACAT-linear	257 $\pm$ 43	276 $\pm$ 23	534 $\pm$ 33	352 $\pm$ 17
SACAT-nn	254 $\pm$ 41	273 $\pm$ 41	439 $\pm$ 51	224 $\pm$ 36

5.6 内层效率 (RQ5)

我们通过改变更新步数, 进一步分析快速自适应的有效性。我们比较 SACAT-linear 的快速自适应优化与 BOBCAT 的内层优化, 各训练指定的步数。这里用 NN 作为 CDM。AUC 结果见表 4。无论步数多少, SACAT-linear 始终优于 BOBCAT。我们可以看到, 即使 SACAT-linear 只用 1 步, 其 AUC 也高于 BOBCAT 用 4 步的结果, 这表明 SACAT 具备快速自适应的能力。

表 4: 在 ASSIST09 数据集上不同方法在不同内层步数下的 AUC。

方法	步数	AUC
BOBCAT	step 4	71.78
SACAT-linear	step 1	73.57
SACAT-linear	step 2	74.88
SACAT-linear	step 3	74.93
SACAT-linear	step 4	75.08

5.7 题目曝光与上下文重叠 (RQ6)

我们沿用衡量曝光率分布的方法 (Chang 1999, stratified) 以及衡量上下文重叠的方法 (Chen 等)。曝光率与重叠率越小, 方法越好。具体方法如下: Chang 与 Ying 提出用 χ^2 统计量衡量曝光率分布的偏斜度: $\chi^2 = \sum_{k=1}^n \frac{(er_k - L/n)^2}{L/n}$, 其中 er_k 是第 k 题的观测曝光率, L 是测试长度, n 是题库中题目总数。Chen 等引入一种衡量上下文重叠的方法: $\hat{T} = \frac{L}{n} er_k^2 + \frac{n}{L}$ 。

在表 5 中, 我们给出 Eedi-2 数据集上题目曝光率与测试重叠率的汇总统计。我们看到, SACAT-nn 带来的题目曝光率低于现有 CAT 方法, 且过曝题目 (超过推荐上限 20%) 的占比可接受。另一方面, SACAT-nn 带来的测试重叠率介于 BOBCAT 与 NCAT 之间, 也是可接受的。

表 5: 在 Eedi-2 数据集上以 NN 为 CDM 时不同方法的题目曝光率与测试重叠率。

方法	曝光率 (中位数)	曝光率 (> 20%)	重叠率 (均值)
Random	1.02%	0.00%	1.61%
MAAT	0.61%	0.11%	4.90%
BOBCAT	0.10%	0.42%	8.54%
NCAT	0.00%	1.79%	30.00%
SACAT-nn	0.00%	0.62%	12.67%

6 结论与未来工作

本文提出了 SACAT (学生自适应 CAT), 它检索相似学生并执行快速自适应过程。通过在三个真实学生作答数据集上的大量实验, 我们验证了: 协同信息是 BOBCAT 与 NCAT 方法所忽视的重要要素, 利用它能在缩短测试长度方面超越现有 CAT 方法。未来, 我们致力于设计依赖于 CDM 与数据集的、更有效的能力自适应函数。至于如何选择能力自适应函数, 我们将其留作未来工作。

致谢。本团队部分受国家自然科学基金 (62177033) 支持, 本工作亦受华为创新研究计划资助。感谢 MindSpore、CANN (神经网络计算架构) 与昇腾 AI 处理器对本研究的支持。

参考文献 (References) 按约定未翻译, 详见原文。