

搜索高效的计算机化自适应测试 (Search-Efficient Computerized Adaptive Testing)

原文: 3583780.3615049.pdf (CIKM '23) · 译者: Claude · 译于 2026-06-27 术语对照: Computerized Adaptive Testing (CAT, 计算机化自适应测试)、item pool (题库)、selection strategy (选题策略)、score function (打分函数 / 信息量函数)、Cognitive Diagnosis Model (CDM, 认知诊断模型)、Item Response Theory (IRT, 项目反应理论)、Fisher information (FSI, Fisher 信息量)、Ball Tree (球树)、space partitioning (空间划分)、asymptotic theory (渐近理论)

摘要

计算机化自适应测试 (Computerized Adaptive Testing, CAT) 作为在线教育中一种很有前景的个性化测试方式而出现, 其目标是通过自适应地选择测试题目来揭示学生潜在的知识状态。**选题策略**是 CAT 的核心组件, 它在每个测试步根据学生当前估计的能力, 搜索最合适的测试题目。然而, 现有的选题策略以“暴力穷举”的方式运作, 导致时间复杂度与题库中题目数量 N 成线性关系, 即 $O(N)$ 。因此, 在现实中, 当题库规模很大时, 搜索延迟就成了 CAT 的瓶颈。为此, 我们提出**搜索高效的计算机化自适应测试框架 (SECAT)**, 旨在用一个高效的选题策略来增强 CAT。具体而言, SECAT 包含两个主要阶段: **题库索引**和**题目搜索**。在题库索引阶段, 我们在题库上应用一种**学生感知的空间划分 (student-aware spatial partition)**方法, 把测试题目划分到许多子空间中, 并在划分时考虑题目的适配性。在题目搜索阶段, 我们用渐近理论优化传统的单轮搜索策略, 提出一种**多轮搜索策略**, 进一步提升时间效率。与现有策略相比, SECAT 的时间复杂度从 $O(N)$ 降到 $O(\log N)$ 。在两个真实世界数据集上, SECAT 实现了 200 倍以上的加速, 且精度损失可以忽略。

CCS 概念

- 信息系统 → 用户与交互式检索;
- 社会与专业话题 → 计算教育。

关键词

计算机化自适应测试; 教育资源搜索; 教育测量; 认知诊断

1 引言

随着智能教育系统的普及, 计算机化自适应测试 (CAT) 已成为许多真实场景中的关键问题, 例如教育测量、游戏和招聘 [23, 36, 40]。CAT 旨在通过自适应地选择题目来揭示学生 / 应试者的知识状态, 它已被应用于许多标准化测试机构, 例如研究生管理科入学考试 (GMAT) [34] 和研究生入学考试 (GRE) [31]。与纸笔测试相比, CAT 用更少的题目就能达到相同的测量精度 [16]。

如图 1 所示, CAT 由三个组件构成:

- (1) **题库 (item pool)**: 在测试开始前预加载。它包含带有校准好的题目参数的题目, 这些参数用于选题和能力估计。
- (2) **选题策略 (selection strategy)**: 在每个测试步根据当前诊断出的状态, 从题库中确定最合适的测试题目。
- (3) **认知诊断模型 (CDM)**: 根据此前的作答揭示学生的知识状态。

CAT 系统的工作流程如下: 给定一个学生, 在第 t 步, 选题策略首先基于当前状态 $\hat{\theta}_t$ 选出一道题 q_t^* 。然后学生阅读并作答。收到作答 r_t 后, CDM 根据作答序列 $\{r_1, r_2, r_3, \dots, r_t\}$ 把当前状态更新为 $\hat{\theta}_{t+1}$ 。该过程不断重复, 直到满足终止条件 (如达到最大测试长度)。最终诊断出的能力将作为测试结果输出。

图 1: CAT 工作流程概览。

作为测试流程中的关键组件, 选题策略受到研究者的大量关注。以往工作把重点放在如何通过优化分数来提升**效果**上, 却忽视了**延迟**问题, 这导致搜索延迟成了大题库下的障碍。具体来说, 当代的选题策略只是用一个打分函数来计算每道题的信息量分数, 这导致穷举搜索的时间复杂度与题库规模成线性关系, 即 $O(N)$ 。举例来说, 假设一个 10 万规模的题库 (这在在线智能教育系统中很常见), 用 Fisher 信息量 [26] (一种经典的信息量打分函数) 以暴力方式选出最具信息量的题目, 在 2.20 GHz 的 Intel CPU 上每一步要花 10 秒以上, 这在现实场景中是无法接受的。因此在实践中, GMAT [34]、GRE [31] 等知名机构要求专家通过人工制定筛选规则来缩减候选题目, 这既耗费人力, 又在一定程度上限制了 CAT 的效果。为应对这一问题, 提升选题策略的时间效率成为 CAT 中的一个紧迫课题。

受其他领域 (如推荐 [39]、信息检索 [11, 28]) 中解决选项检索效率问题的成功方法启发, 一种潜在方案是把题目划分到子空间中, 再从受限的子空间里高效搜索合适的题目, 这就是所谓的**空间划分 (Space partitioning)** [8]。然而, 在 CAT 中设计一个高效的选题策略并不容易, 原因有以下几点挑战:

第一, 在 CAT 中题目划分应当是**学生感知的**。例如, 给定某个特定学生, 适合他 / 她的题目应当被划分到同一个子空间中。仅依据相似度距离构建索引会忽略题目与学生的相关性。因此, 在题库的索引阶段, 应当考虑题目对不同学生的适配性。

第二，打分函数应当是一个有效的度量（如点积）。然而信息量函数在欧几里得空间中是无效的，这成了把题目划分到子空间的障碍。如何处理打分函数的复杂形式成为一个关键问题。

第三，选题是多轮相互依赖的。为得到准确的估计，CAT 根据当前估计逐步选题。CAT 中基于递归估计的多轮选题，可能因为估计相似而对子空间产生冗余检查。

为此，我们提出搜索高效的计算机化自适应测试框架（SECAT）。具体而言：

- 首先，我们通过考虑题目的适配性来优化空间划分方法。这样整个选择空间 ($O(N)$) 被递归地划分成许多对数规模 ($O(\log N)$) 的子空间，且具有相似选择可能性的题目能被划分到同一个子空间。
- 其次，为处理选题策略中打分函数的复杂形式，我们通过从现有策略中蒸馏知识，构造出一个通用打分函数。这使我们能在一个有效的度量上把题目划分到子空间。
- 第三，我们利用渐近理论来减少冗余查找，进一步限制候选子空间。当当前估计与此前某个估计相似时，我们就从此前若干步产生最合适题目的对应子空间中选题。

我们的方法把穷举搜索的线性时间复杂度 ($O(N)$) 降低到对数时间复杂度 ($O(\log N)$)。例如，要从 10 万规模的题库中选出最具信息量的题目，SECAT 平均每步只需计算 83 道题的信息量分数，耗时不到 0.1 秒。我们的方法在达到与暴力搜索相近精度的同时实现了 200 倍以上的加速。为验证 SECAT 的有效性与高效性，我们在两个来自教育系统的真实数据集上进行了实验。

2 相关工作

2.1 计算机化自适应测试

CAT 由题库、认知诊断模型和选题策略构成。题库作为测试内容在 CAT 系统中预加载，题目的数量会很大程度上影响测试的公平性和质量 [14]。在测试过程中，认知诊断模型 (CDM) [9, 13] 与选题策略交替工作，直到满足选题终止准则。代表性的 CDM 包括传统的项目反应理论 (Item Response Theory, IRT) [7] 和近年来的深度学习模型（如 NCD [41]）。选题策略是 CAT 的核心组件，它由两部分组成：衡量题目信息量的打分函数，以及找出最具信息量题目的搜索策略。以往工作聚焦于打分函数的设计，并以暴力方式搜索。

现有的打分函数可分为两类：最大信息量打分函数和数据驱动打分函数。最大信息量打分函数是人工设计的，用于量化信息量。Lord [26] 提出用 Fisher 信息量 (FSI) 来量化题目信息量的打分函数。Chang 和 Ying [4] 则用 Kullback-Leibler (KL) 信息量作为 CAT 中的打分函数。FSI 和 KLI 都是基于 IRT 族模型设计的。Bi [2] 提出一个模型无关 (Model-Agnostic) 框架，根据期望模型变化 (expected model change) 来设计打分函数，它与底层 CDM 无关。数据驱动打分函数则是从数据中学到的，受强化学习 [24] 启发。BOBCAT [10] 把 CAT 重新表述为元学习中的双层优化问题，从训练数据中直接学习一个数据驱动的打分函数。NCAT [44] 正式地把 CAT 重新定义为一个强化学习问题，直接从真实数据中学习打分函数。然而，数据驱动打分函数由强化学习训练，在大数据集上比在小数据集上要计算密集得多。由于学习开销太大，很难把它们应用于大题库。此外，学到的打分函数容易在历史数据上产生偏差 [10]。因此，本文聚焦于如何降低基于最大信息量打分函数的策略的时间复杂度。

2.2 高效搜索

高效搜索方法 [17] 一直被研究用于准确、高效地检索候选项，可分为以下几类。第一类是基于哈希的方法 [27, 37]，把数据从原始空间投影到汉明 (Hamming) 空间。一些基于哈希的方法（如语义哈希 [12]）从数据中学习编码。几乎所有基于哈希的方法都存在严重的信息损失，导致推荐精度偏低。第二类是基于量化的方法 [18, 20, 30]。乘积量化 (Product quantization) [19] 把空间分解为子空间，适用于高维场景。乘积量化通常用于基于欧氏距离的相似度搜索，而 LightRec [25] 利用乘积量化提出了一个基于点积的、内存和搜索都高效的框架。第三类是基于图的方法，通过搜索邻近节点来提升检索效率，如 HNSW [29]。第四类是使用空间划分结构的基于树的方法，如 KD-Tree [1] 和 Ball-tree (球树) [21, 33, 43]。Koenigstein [22] 从题目表示构建度量树 (metric tree)，基于点积提供精确的 top-k 推荐。SECAT 属于这一类。与仅基于题目相似度构建度量树不同，我们在空间划分时考虑了题目对不同学生的适配性；在搜索阶段，我们利用 CAT 中多轮搜索的依赖性进一步提升时间效率。

3 预备知识

3.1 CAT 组件

具体来说，CAT 由三个组件构成：

(1) 题库 Q ：由带校准参数（如难度和区分度）的题目组成。在测试前，题目被分配给专业测试者来收集作答，从而对题目进行校准，同时作为副产品得到一组用户能力。题库的规模需要考虑，原因有三：其一，大题库因为精度更高，已被证明更可靠 [14]。自适应测试的一个重要要求是提供足够多、难度参数各异的题目，使不同能力水平的学生都能被准确诊断。其二，大题库通过控制曝光率 (exposure rate)，有利于测试的公平性和安全性。其三，由于有大量可用题目，大题库在在线智能教育系统中更为常见。由于在现有选题策略中搜索延迟与题库规模成线性增长，因此在大规模题库下降低搜索延迟成为一个紧迫问题。

(2) **认知诊断模型 M** : 用于根据学生作答揭示其知识状态。使用最广泛的 CDM 是项目反应理论 (IRT)。IRT 用一个一维的值 θ_i 表示学生 i 的潜在特征, 并计算学生 i 正确作答题目 j 的概率:

$$P(r_{i,j} | \theta_i, a_j, b_j) = \frac{1}{1 + e^{-1.7a_j(\theta_i - b_j)}}, \quad (1)$$

其中 $r_{i,j}$ 是学生 i 对题目 j 的作答 (1 表示作答正确)。每道题用两个参数表示: a_j 是题目 j 的区分度, b_j 是题目 j 的难度。最近, 神经认知诊断模型 (Neural Cognitive Diagnosis Model, NCD) [41] 被提出, 它利用深度神经网络来建模学生的多维潜在特质。

(3) **选题策略**: 是最重要的组件, 它根据第 t 步当前估计的学生能力 $\hat{\theta}_t$, 从题库中选出下一道题。选题策略由衡量题目信息量的打分函数 S 和找出最具信息量题目 q_t^* 的搜索策略组成:

$$q_t^* = \arg \max_{q_j \in Q} S(\hat{\theta}_t, q_j). \quad (2)$$

由于打分函数形式复杂, 搜索效率很难提升。打分函数是人工设计的, 它以复杂的方式刻画学生与题目之间的交互。例如, FSI [26] 把打分函数定义为:

$$S(\hat{\theta}) = \frac{[P'(\hat{\theta})]^2}{P(\hat{\theta})(1 - P(\hat{\theta}))}, \quad (3)$$

其中 $P(\hat{\theta})$ 表示在给定估计 $\hat{\theta}$ 下正确作答的概率, $P'(\hat{\theta})$ 是 $P(\hat{\theta})$ 的导数。总之, 选题策略中打分函数的形式与相似度函数 (点积、余弦相似度) 相当不同, 它们在欧氏空间中是无效的, 这成了搜索阶段提升时间效率的障碍。

3.2 问题定义

如上所述, CAT 系统包含一个 N 规模的题库 $Q = \{q_1, q_2, \dots, q_N\}$ 。给定一个新学生 s_i , 在第 t 步, 由认知诊断模型 M 根据此前的作答估计该学生的水平:

$$P(r_{i,j} = 1 | \theta_i, q_j), \quad (4)$$

其中 θ_i 是学生的能力, $r_{i,j}$ 是学生 i 对题目 j 的作答 (1 表示作答正确)。我们用 $M, q_j, r_{i,j}$ 得到估计 $\hat{\theta}$ 。之后, 选题策略按式 (2) 在当前估计水平 $\hat{\theta}$ 上选出信息量最大的题目。

假设计算打分函数 $S(\hat{\theta})$ 的时间复杂度为 D , 传统策略以暴力方式计算 N 规模题库中每道题的信息量并选出信息量最大的题, 所以每一步选题的时间复杂度是 $O(ND)$ 。我们的目标是通过缩小选择规模 N 来降低搜索延迟, 且测试精度损失可忽略。

4 方法

图 2: SECAT 工作流程概览。(在每个测试步, CDM 根据作答更新学生状态估计; 若当前估计是“渐近的” (asymptotic), 则从前几轮所选题目所在的叶子中搜索, 否则从整棵树搜索。)

4.1 概览

SECAT 包含两个主要阶段: **题库索引**和**题目搜索**。在索引阶段, 我们在题库上构建一棵空间划分树, 结合题目的适配性把题目递归地划分成二叉子空间。在题目搜索阶段, 我们提出一种高效的多轮搜索策略来增强现有的选题策略。如图 2 所示, 如果当前估计是渐近的, 我们就从前几轮所选题目的叶子开始搜索, 否则从整棵树搜索。我们的框架 SECAT 可以应用于选题策略的所有打分函数, 但 NCAT [44] 和 BOBCAT [10] 除外, 因为它们改变了 CAT 的范式。在第 4 节中, 我们将首先介绍如何在题库上构建空间划分树, 然后在已索引题库的前提下阐述高效的搜索策略, 最后对所提出的选题策略进行时间复杂度分析。

4.2 题库索引

在传统 CAT 设定中, 题库是一堆无结构的题目集合。为了降低搜索延迟, 我们需要在测试前用某种数据结构对题库建立索引。

4.2.1 学生感知的空间划分 我们首先把题目划分到子空间中以限制选择空间。选题策略中复杂的打分函数是高效搜索的一个重要难题，我们将在随后的 4.2.2 节解决它；在本节中，我们基于欧氏距离来划分空间。受以往工作 [6, 22] 启发，我们通过空间划分为题库构建一棵度量树。根节点包含题库中的所有题目，题目被一个超平面划分成二叉超球 (balls)。通过递归划分，所有题目被分割到最小的子空间中，记为**叶子 (leaves)**。

在 Andrew Moore [32] 提出的传统划分方法中，每个节点 x 按以下步骤分裂：1) 选取彼此距离最远的两个点 A, B 作为两个质心。2) 由两个子划分的质心定义一个超平面：

$$y(x) = w * x + b, \quad (5)$$

图 3：学生感知空间划分示意图。

其中，

$$w = B - A, \quad b = -\frac{1}{2}(\|B\|^2 - \|A\|^2). \quad (6)$$

3) 用该超平面把所有点分到两个子划分中。然而，由两个随机的最远点确定的超平面忽视了题目与学生的相关性。把题目划分成两个子空间的目的，是减少在两个子空间中的额外查找。例如，如图 3 所示，蓝色的学生擅长技能，绿色的学生不擅长。适合擅长学生和不擅长学生的题目应当分别被划分到不同的子空间。通过递归划分，适合相似水平的题目能被划分到同一个子空间。

我们在算法 1 中提出学生感知的空间划分方法。我们首先在校准阶段获得一组学生能力 Ω ——校准阶段中，题目被分配给专业测试者收集作答 [38]。在每次划分时，我们不挑选距离最远的两道题，而是选择**最适合集合中能力最高者和能力最低者的两道题**作为两个质心。之后， Ω 中的用户能力被划分成两个集合，分别用于下一次划分。这样，超平面就由适合不同学生的两道最佳题目确定。结果就是，我们能得到一个更合理的超平面，并通过递归划分构建出组织良好的题库。

算法 1：学生感知空间划分方法 输入：题库 $Q = \{q_1, q_2, \dots, q_N\}$ ，学生 $\Omega = \{\theta_0, \theta_1, \dots, \theta_M\}$ ，打分函数 S

```
function MakeTree(学生  $\Omega$ , 题目  $Q$ )
    T.Q  $\leftarrow Q$ 
    T.center  $\leftarrow \text{mean}(Q)$ 
    T.radius  $\leftarrow \max_{q_i \in Q} \|T.\text{center} - q_i\|$ 
    // N0 是叶子中题目数量的上限
    if  $|Q| \leq N0$  then
        return T
    else
        (w, b)  $\leftarrow \text{MakeHyperplane}(\Omega, Q)$ 
        Q_l  $\leftarrow \{q_i \in Q : w^T q_i + b \leq 0\}$ 
        Q_r  $\leftarrow Q - Q_l$ 
         $\theta_m = \text{median}_{\{\theta_i \in \Omega\}} \|\theta_i\|$ 
        Q_l  $\leftarrow \{\theta \in \Omega : \|\theta\| < \|\theta_m\|\}$ 
        Q_r  $\leftarrow \Omega - Q_l$ 
        T.left  $\leftarrow \text{MakeTree}(Q_l, Q_l)$ 
        T.right  $\leftarrow \text{MakeTree}(Q_r, Q_r)$ 
    end if
    return T
end function
```

```
function MakeHyperplane(学生  $\Omega$ , 题目  $Q$ )
     $\theta_l \leftarrow \min_{\{\theta_i \in \Omega\}} \|\theta_i\|$ 
     $\theta_r \leftarrow \max_{\{\theta_i \in \Omega\}} \|\theta_i\|$ 
    A  $\leftarrow \text{argmax}_{\{q_i \in Q\}} S(\theta_l, q_i)$ 
    B  $\leftarrow \text{argmax}_{\{q_i \in Q\}} S(\theta_r, q_i)$ 
    w  $\leftarrow B - A$ 
    b  $\leftarrow -1/2 (\|B\|^2 - \|A\|^2)$ 
    return (w, b)
end function
```

4.2.2 打分函数蒸馏 现有选题策略的打分函数在欧氏空间中是无效的。借助空间划分方法，我们把所有题目划分到了叶子中，但由于打分函数与度量树不兼容，找出可能的候选叶子会很有挑战性。因此，提出一个能用于有效划分空间的有效打分函数尤为紧迫。考虑到打分函数作用在学生和题目上的形式，我们采用点积距离，通过**双塔网络 (double-tower network)** 来近似现有策略：

$$S(\theta, q) \leftarrow f(\theta)^\top g(q), \quad (7)$$

其中 f 表示用户塔编码器， g 表示题目塔编码器， S 表示 Fisher、KL 信息量这样的信息量。我们用双塔 [5, 15] 结构从复杂的信息量计算中蒸馏知识。具体来说，把学生的信息（估计的能力和歷史作答）喂入用户塔得到学生表示，把题目的信息（校准好的难度和区分度参数）喂入题目塔得到题目表示。两个编码塔都可以是嵌入模块，或者是用于建模附加信息的最先进模块。蒸馏损失为：

$$Loss = \sum_{j=0}^N \|f(\theta)^\top g(q_j) - S(\theta, q_j)\|^2. \quad (8)$$

借助双塔网络，我们用点积来近似信息量分数。

4.3 题目搜索

按照 4.2.2 节中的通用打分函数，我们用点积函数来近似打分函数。在本节中，我们采用深度优先的分支定界 (**branch-and-bound**) 算法来搜索最具信息量的题目，且性能退化可忽略。

4.3.1 单轮搜索策略 在图 3 中划分好的题库中，我们记 B 为题目所在的球（子空间），每个球以 q_c 为中心、半径为 r 。根据 Noam Koenigstein [22]，球 B 中最大可能点积存在一个上界：

$$\max_{q_i \in B} f(\theta)^\top g(q_j) \leq f(\theta)^\top q_c + r \|f(\theta)\|. \quad (9)$$

结合打分函数蒸馏中的式 (7)(8)，我们有

$$S(\theta, q_i) \approx f(\theta)^\top g(q_j). \quad (10)$$

因此，

$$\max_{q_i \in B} S(\theta, q_i) \lesssim f(\theta)^\top q_c + r \|f(\theta)\|. \quad (11)$$

这样，球 B 中题目的信息量就有了一个近似上界： $f(\theta)^\top q_c + r \|f(\theta)\|$ 。我们在算法 2 中以深度优先的方式搜索信息量最大的题目。在测试前，所有题目都已被题目塔编码器 g 变换过。测试时，我们用用户塔编码器 f 计算用户表示 $f(\theta)$ 。遵循度量树中的搜索算法 [22]，如果某个子空间中题目的上界大于当前的最大信息量，我们就递归遍历该子空间的子节点；否则该子空间被剪枝，其中题目的计算可以省去。事实上，只有 L 个上界更大的叶子会被检查。遍历子空间的顺序由节点的上界决定，目的是尽快找到可能的叶子。因此，基于子空间中题目的上界，单轮搜索策略通过把题目限制在 L 个叶子中，减少了信息量的计算。

算法 2：单轮搜索策略 输入：估计的学生能力 $\hat{\theta}$ ，用户塔编码器 f ，题目塔编码器 g ，题目树节点 T ，打分函数 S 。输出：所选题目 $T.M$

```
T.M ← None
SearchTree(θ; T)
return T.M
```

```
function SearchTree(查询 θ, 题目树节点 T)
    if T.M < f(θ)·TT.center + T.radius·||f(θ)|| then
        if isLeaf(T) then
            q ← argmax_{g(q_j) ∈ T.Q} S(θ, q_i)
            if S(θ, q) > S(θ, T.M) then
                T.M ← q
        end if
```

```

else
  l_l ← f(θ)^TT.left.center + T.left.radius||f(θ)||
  l_r ← f(θ)^TT.right.center + T.right.radius||f(θ)||
  if l_l ≤ l_r then
    SearchTree(θ, T.right)
    SearchTree(θ, T.left)
  else
    SearchTree(θ, T.left)
    SearchTree(θ, T.right)
  end if
end if
end if
end function

```

4.3.2 多轮搜索策略 尽管我们提出了高效的单轮搜索策略来降低每一步的延迟，但多轮搜索之间的依赖性尚未被利用。CAT 系统根据当前估计自适应地从题库中给出最合适的题目，第 t 道题是根据此前的 $t - 1$ 个作答 $\{r_1, r_2, \dots, r_{t-1}\}$ 选出的。相应地，Chang 和 Ying [42] 已证明，递归估计序列 $\{\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_{t-1}\}$ 与真值 θ_0 是渐近一致的：

$$\lim_{n \rightarrow \infty} \Pr \left\{ |\hat{\theta}_n - \theta_0| \geq \epsilon \right\} = 0, \quad (12)$$

其中 ϵ 是任意小的正量。渐近理论说明，估计能力 $\hat{\theta}$ 在测试过程中逐渐逼近真值。因此，当前估计有可能与此前查询的估计相似。在这种情况下，相似的估计可能导致冗余的选题。

因此，我们提出一种新颖的多轮搜索选题策略，利用此前各轮的搜索结果。当当前估计能力 $\hat{\theta}$ 与历史查询相当相似时，我们从此前选题的候选叶子中选题；反之，当 θ 与所有历史查询都不相似时，我们用算法 2 从整棵度量树中选题。因此，如何量化查询相似度成为多轮搜索问题的关键。

如 4.2.2 节所述，借助蒸馏打分函数，估计能力 $\hat{\theta}$ 被用户编码器 f 变换为 $f(\hat{\theta})$ ，题目 q 被题目编码器 g 变换为 $g(q)$ 。我们用点积形式来近似打分函数 S ：

$$S \approx f(\hat{\theta})^\top g(q) = \|f(\hat{\theta})\| \|g(q)\| \cos \alpha, \quad (13)$$

其中 α 是变换后的学生向量与变换后的题目向量之间的夹角。在式 (13) 中，查询向量的长度不影响搜索结果，结果取决于夹角 α 和题目向量长度 $\|g(q)\|$ 。换言之，两个用户向量之间的小夹角意味着两个估计能力有相近的值。因此，我们首先用查询的余弦函数来量化查询相似度（定义 1），并进一步用定义 2 来定义渐近查询，用于从历史候选叶子中搜索。

定义 1 (查询相似度)： 给定能力为 θ_i 的学生 i 和能力为 θ_j 的学生 j ，学生能力的相似度为：

$$Sim(\theta_i, \theta_j) = \cos(f(\theta_i), f(\theta_j)). \quad (14)$$

定义 2 (渐近查询)： 给定第 t 步估计能力为 $\hat{\theta}_t$ 的学生 i 、相似度阈值 δ ，以及该学生历史估计能力集合 $\Theta = \{\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_{t-1}\}$ ，若满足

$$\min_{\hat{\theta}_{t'} \in \Theta} Sim(\hat{\theta}_t, \hat{\theta}_{t'}) > \delta, \quad (15)$$

则当前选题具有一个渐近查询。

如算法 3 所示，我们用相似度阈值 δ 来决定是从此前的候选叶子中搜索，还是从整棵度量树中搜索。首先，估计的学生水平会与历史估计作比较。如果最大相似度大于阈值 δ ，意味着该次选题具有渐近查询，我们就搜索历史候选叶子，而不使用单轮搜索策略。借助高效的多轮搜索策略，从整个题库中进行的冗余搜索可被进一步减少。

算法 3：多轮搜索策略 输入：估计的学生能力 $\hat{\theta}_t$ ，用户塔编码器 f ，题目树节点 T ，历史查询 $\Theta = \{\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_{t-1}\}$ ，历史候选 C ，阈值 δ ，打分函数 S 。输出：所选题目 $T.M$

```

C_t ← 空集
if max_{θ_{t'} ∈ Θ} Sim(θ_t, θ_{t'}) > δ then
    // 对于渐近查询，选择空间被限制在此前选过的叶子中
    for each θ_{t'} ∈ Θ do
        if Sim(θ_t, θ_{t'}) > δ then
            C_t ← C_t ∪ C.θ_{t'}
        end if
    end for
    T.M ← argmax_{q_i ∈ C_t} S(θ, q_i)
else
    SearchTree(θ, T)
    // 所选叶子中的题目记为 M_leaf
    C.θ_t ← T.M_leaf
end if
return T.M

```

4.4 时间复杂度分析

假设打分函数 $S(\hat{\theta}, q)$ 的时间复杂度为 D ，题库规模为 N ，则每一步穷举搜索的时间复杂度为 $O(ND)$ 。在 SECAT 中，我们在题库上构建了一棵度量树。由于度量树把 N 个题目递归地划分成二叉子空间，最小的子空间（叶子）含有 $O(\log N)$ 规模的题目。通过剪掉上界较小的子空间，我们假设选课时遍历了 L 个叶子。因此，单轮搜索下度量树的时间复杂度降为 $O(DL \log N)$ 。借助多轮搜索策略，当当前估计相比此前估计变化很小时，选择空间被限制在此前各轮所选的叶子里，于是 L 在多轮搜索策略中进一步减小，这将在第 5.5 节通过实验验证。

4.5 与 ANN 方法的关系

由于我们用点积来近似信息量分数，从技术上讲，针对最大点积的近似最近邻（approximate nearest neighbor, ANN）搜索也可以应用于 CAT。ANN 方法旨在从数百万候选项中搜索近似项，在其他任务（如 CV [35] 和 RS [25]）中表现出色。然而，CAT 对精度的要求更高，因为它用比纸笔测试更少的题目。SECAT 能从两个方面减少精度退化：1) SECAT 的骨干是球树（Ball Tree），它为查询搜索精确的题目；2) 在叶子中搜索时，SECAT 利用近似上界，用原版打分函数 S (FSI、KL、EMC) 来计算信息量。这个近似上界只在球树中有效，因此无法应用于其他 ANN 方法。所以 ANN 会带来额外的精度退化。总之，SECAT 能更好地保证测试在题目搜索中的精度。

5 实验

5.1 实验设置

数据集。本实验使用两个真实世界数据集，即 Eedi 和 EXAM。Eedi 指 NeurIPS 2020 教育挑战赛的数据集。EXAM 数据集由科大讯飞 (iFLYTEK) 提供，包含数学练习题和高中考试的作答日志。我们选择了大题库的数据集来评估所提方法。

表 1：数据集统计

数据集	Eedi	Exam
学生数	118,971	1,897,707
题目数	27,613	122,950
作答日志数	15,867,850	89,106,879
每个学生的作答日志数	133	47
每道题的作答日志数	575	725

数据划分。我们把学生-题目交互划分为历史数据和测试数据以服务不同目标。历史数据在测试前收集，用于校准题目参数（如难度和区分度）。我们在历史数据中分别过滤掉 Eedi 和 Exam 中作答日志少于 30 条的学习者，以保证校准题目的质量。测试数据用于在实验中模拟自适应测试过程。

评估任务。遵循以往工作 [2, 44]，我们在一个模拟研究（simulation study）和一个学生表现预测（student performance prediction）任务上进行实验。

1) **模拟研究：**传统 CAT 研究有一个称为模拟研究的评估过程，先初始化学生能力，再用一个 CDM 在整个题库上生成作答记录。测试时，CAT 通过自适应地选择记录来估计学生能力。由于模拟研究中 CAT 从整个题库选题，其搜索延迟接近真实世界。

2) **学生表现预测：**我们在学生表现预测任务上做实验以检验 CAT 的表现。评估时，我们把选择限制在测试数据中已记录作答的那些题目上。

评估指标。我们用以下两类指标评估实验结果。

1) **效率指标：**直观地，我们用选题所花的时间（秒）来衡量搜索时间效率。为进一步分析时间复杂度，我们用度量树中遍历的叶子数 L 来估计每一步的计算开销。

2) **效果指标：**在模拟研究中，我们计算估计参数与模拟参数之间的均方误差（MSE）。在学生表现预测任务中，我们预测学生在已记录作答的题目上的表现。从二分类角度，我们用准确率（ACC）和 ROC 曲线下面积（AUC）[3] 来评估不同的选题策略。

基线方法。如上所述，CAT 中选题策略的打分函数依赖于认知诊断模型（CDM）。我们用项目反应理论（IRT）[7] 和一个基于深度学习的模型（NCD）[41] 作为底层 CDM。我们用以下几种最先进的选题策略打分函数作为基线：

- **Random：**随机搜索方法，作为展示其他方法改进的基准。
- **FSI [26]：**Fisher 信息量，是为 IRT 设计的最流行的打分函数。
- **KLI [4]：**KL 信息量，旨在提升测试初期的精度。它利用 Kullback-Leibler 信息量来衡量两个相邻水平后验之间的散度。它是为基于 IRT 的模型设计的。
- **MAAT [2]：**MAAT 受主动学习方法启发，用期望模型变化（EMC）来量化信息量。它与底层 CDM 无关。

我们用 $X + \text{SECAT}$ 表示带额外学生感知超平面和多轮选题策略的 SECAT。我们的框架 SECAT 可以应用于所有打分函数，但数据驱动算法（NCAT 和 BOBCAT）除外，因为它们改变了 CAT 的范式且难以应用于大题库。例如，在 Exam 数据集上，用 BOBCAT 训练选题算法一个 epoch 在 GPU 上要花 18 小时以上，而整个训练需要数十到数百个 epoch。而且，随着题库规模增大，周转时间会迅速增长。因此，数据驱动算法不适合大题库。

实现细节。叶子中题目数量的上限阈值在 Eedi 中为 50，在 Exam 中为 100（因为 Exam 题目更多）。在通用打分函数中，学生向量和题目向量的维度为 15，以降低内积计算成本。对于多轮搜索策略，查询相似度阈值为 0.95，相关分析见 5.6 节。所有方法在两块 2.20 GHz Intel Xeon E5-2650 v4 CPU 和一块 TITAN Xp GPU 上开发和训练。

5.2 模拟研究

CAT 的终极目标是得到学生能力 θ 的估计。由于真值 θ_0 未知，我们进行水平估计的模拟实验。具体来说，我们人为初始化学生能力，并在整个题库上生成作答。由于模拟研究只适用于参数简单、可解释的 CDM，我们只用 IRT 进行模拟研究。

我们的代码可在 <https://github.com/bigdata-ustc/SECAT> 获取。

图 4：模拟研究的搜索延迟。

图 5：模拟研究的 MSE。

5.2.1 效率分析 图 4 展示了暴力方法和 SECAT 在一步上的平均搜索延迟。我们用双 Y 轴来衡量两个数据集上的延迟，因为暴力搜索方法比高效搜索方法耗时多得多。具体来说，所提 SECAT 对应左轴，暴力搜索方法对应右轴。首先，可以看到 SECAT 在两个数据集上都优于暴力方法。在最温和的情况下，用 FSI 打分函数的暴力搜索累积延迟超过 20 秒，而 SECAT 的累积延迟不到 0.1 秒。因此，SECAT 在模拟研究中实现了对暴力方法 200 倍以上的加速。其次，尽管暴力方法在不同打分函数上的搜索延迟各异，SECAT 把所有打分函数的搜索延迟显著降低到随机搜索方法的数量级。对暴力方法而言，MAAT 中信息量的计算比 FSI 和 KLI 更耗时。对 SECAT 而言，它通过限制题目数量减少了信息量的计算。通过降低搜索延迟，SECAT 使得从一个巨大的题库中选题成为可能。

5.2.2 效果分析 如图 5 所示，我们把不同打分函数上的高效搜索方法记为 $X + \text{SECAT}$ 。首先，可以看到 $X + \text{SECAT}$ 在 MSE 指标上能近似暴力方法的选题，这意味着高效策略在测试中保持了精度。其次，Random 选择在 Exam 数据集上的效果不如在 Eedi 上，而设计好的打分函数（MFI、KLI、MAAT）在 Exam 上比在 Eedi 上表现更好。原因可能是 Exam 提供了更大的题库，覆盖了更多潜在的可能能力。总之，SECAT 在大题库中起着关键作用，因为设计好的打分函数的相对提升在更大的题库中更明显。

表 2：学生表现预测的结果。（在第 10 步、IRT/NCD 两种 CDM、FSI/KLI/MAAT 几种打分函数下，分别报告 Random、Brute-force、SECAT 的累积延迟（秒）、ACC(%)、AUC(%)。结构复杂，详见原文表 2；关键结论是 SECAT 在大幅降低延迟的同时，ACC/AUC 与 Brute-force 几乎持平。例如 Eedi-IRT-MAAT: Brute-force 累积延迟 7.192s、SECAT 0.704s; ACC 70.35 vs 70.23; AUC 72.53 vs 72.52。Exam-NCD-MAAT: Brute-force 14.952s、SECAT 0.769s; ACC 80.89 vs 80.37; AUC 87.61 vs 87.56。）

表 3：在 eedi 数据集上用 NCD 在第 10 步与 ANN 方法的对比。

指标	ACC	AUC	MSE
Brute-Force	72.55	73.11	0.17
SECAT	72.38	72.92	0.178
ANNOY	71.94	72.21	0.695

指标	ACC	AUC	MSE
HNSW	72.03	72.67	0.313

5.3 学生表现预测

我们也在学生表现预测任务上做实验，以验证选题策略的效率和效果。表 2 报告了测试中第 10 步的累积搜索延迟、ACC 和 AUC。首先，SECAT 在两个数据集上都能显著降低搜索延迟。特别地，依赖 NCD-MAAT 的暴力搜索方法在 Eedi 上花将近 7 秒、在 Exam 上花 14 秒。在两个数据集上，SECAT 都把 MAAT 的搜索延迟降低到随机搜索方法的数量级。其次，如表 2 所示，所提 SECAT 对 ACC/AUC 的负面影响可忽略，SECAT 取得了有竞争力的预测表现。例如，基于 NCD-MAAT 的 SECAT 几乎达到与暴力方法相同的表现。这意味着 SECAT 中受限的选题空间妥善保留了可能的题目。此外，我们注意到暴力方法在 FSI 和 KLI 上的搜索延迟与 SECAT 没有显著差异。我们认为主要原因如下：就累积延迟而言，CAT 从测试数据中已记录作答的题目里选题，这只是题库的一小部分。因此，有限的选择空间规模导致了相近的累积延迟。

5.4 SECAT 对比 ANN 方法

如 4.5 节所述，ANN 在打分函数蒸馏后也可应用于 CAT。因此，我们在表 3 中比较 SECAT 与两种强大的 ANN 方法：ANNOY 和 HNSW [29] 的效果。可以看到，SECAT 在所有效果指标上的退化都可忽略，而 ANNOY 和 HNSW 在 ACC 和 AUC 上带来额外退化。尤其在 MSE 上，ANN 方法的估计存在显著偏差。由于 CAT 的目标是准确的参数估计，ANN 方法不适合 CAT。原因可能是 ANN 方法是高维题目搜索设计的，且以牺牲精度为代价。简言之，与 ANN 方法相比，SECAT 保持了测试精度，更适合测试场景。

5.5 消融研究

我们通过在 IRT 模拟研究上做消融研究，比较遍历的叶子数，来分析学生感知空间划分和多轮搜索策略的有效性。结果如图 6 所示。我们把没有多轮搜索策略的 SECAT 记为 SECAT-m，没有学生感知空间划分方法的 SECAT 记为 SECAT-s。首先，对 SECAT-s 而言，遍历的叶子数随着步数增加而增加，意味着后面的步需要探索更多叶子。原因是 CAT 不允许在不同步重复选题，于是它在后面的轮次中探索树里更多可能的叶子。其次，SECAT 遍历的叶子数在后面的轮次中减少，意味着带渐近查询的多轮选题策略在后续步骤中对缩减选择空间起着更关键的作用。第三，可以看到 SECAT-s 为找到最合适的题目搜索了更多叶子，意味着学生感知超平面在测试初期就限制了选择空间。

图 6：每一步平均遍历的叶子数。

我们把遍历的叶子数记为 L ，在 SECAT 中 L 减小到一个常数值。总之，SECAT-m 的时间复杂度是 $O(DL \log N)$ ，遍历 L 个叶子。SECAT 在大多数轮次中把平均 L 减小到接近常数值。因此，SECAT 的时间复杂度约为 $O(D \log N)$ 。

图 7： δ 在预测精度与搜索延迟之间的平衡影响。

5.6 模型参数分析

在 SECAT 中，多轮搜索策略里的权衡参数 δ 在平衡效果与效率方面起着重要作用，它决定是从此前的叶子中选还是从整个题库中选。我们用 NCD-MAAT 打分函数在学生表现预测任务上做参数敏感性实验，以观察 δ 的影响。 δ 取值范围为 0 到 1。 δ 越小，从某个叶子中选题的可能性越高；反之， δ 越大，SECAT 越倾向于从整个空间中选。当 δ 等于 1 时，模型用单轮搜索策略选题。

如图 7 所示，当 δ 增大时，ACC 增大。这表明适当探索未被选过的叶子中的题目有利于效果。当 δ 太大时，平均遍历的叶子数迅速增长，导致长搜索延迟。这些结果表明，选择一个合适的阈值 δ 来平衡效果与效率至关重要。

6 结论

本文为智能教育系统提出了一个新颖的搜索高效计算机化自适应测试框架。为尽快找到可能的候选题，我们提出了一种考虑题目适配性的学生感知空间划分方法。此外，我们在 CAT 中运用渐近理论，利用此前的作答来帮助下一次选题。作为一项通用工作，SECAT 可应用于许多打分函数。大量实验证明了 SECAT 的高效性和有效性。在未来工作中，我们将探索 CAT 中更现实的约束，如曝光控制 (exposure control)。

致谢。本研究部分受国家重点研发计划 (编号 2021YFF0901003) 和国家自然科学基金 (编号 U20A20229) 资助。

参考文献 (References) 按约定未翻译，详见原文。