

应对计算机自适应测验中的选择偏差：一种用户级聚合影响函数方法 (Addressing Selection Bias in Computerized Adaptive Testing: A User-Wise Aggregate Influence Function Approach)

原文：3583780.3615455.pdf (CIKM '23) ·译者：Claude ·译于 2026-06-27 术语对照：Computerized Adaptive Testing = 计算机自适应测验 (CAT)；Influence Function = 影响函数 (IF)；Aggregate Influence Function = 聚合影响函数 (AIF)；item profile = 题目画像 (题目参数)；selection bias = 选择偏差；Item Response Theory = 项目反应理论 (IRT)；diagnostic model = 诊断模型；Inverse Propensity Score = 逆倾向得分 (IPS)

摘要

计算机自适应测验 (Computerized Adaptive Testing, CAT) 是一种被广泛使用、效率很高的测验模式，它根据考生在测验领域内的能力水平进行自适应。CAT 需要预先训练好的**题目画像 (item profile)**，因为 CAT 会基于已登记题目的画像实时评估学生，并利用候选题目的画像来选择下一道要施测的题目。然而，获取这些题目画像是一个代价高昂的过程：需要先收集大量、稠密的题目—作答数据，再在这些数据上训练一个诊断模型。本文中，我们探索一种可能性——直接利用 CAT 服务过程中收集到的作答数据。我们首先指出，这样做会带来一个独特的挑战，因为 CAT 本身会引入**选择偏差 (selection bias)**：即能力更强的学生会收到更难的题目。事实上，当我们朴素地用 CAT 作答数据去训练诊断模型时，会观察到题目画像与真实值产生显著偏离。为了解决选择偏差问题，我们提出了**用户级聚合影响函数 (user-wise aggregate influence function)** 方法。我们的核心直觉是：以聚合的方式过滤掉那些作答数据偏差严重的用户——判断依据是这些新增数据在参数估计过程中会引入多大的扰动。这样，我们就在尽量少地给题目画像引入偏差的同时，提升 CAT 的性能。我们通过在三个公开数据集和一个包含真实世界 CAT 作答数据的数据集上的大量实验，证明了所提方法的优越性。

CCS 概念

·应用计算 → 在线学习 (E-learning)；·社会与专业议题 → 学生评估 (Student assessment)。

关键词

计算机自适应测验 (CAT)；影响函数 (Influence Function)；偏差消减 (Bias Reduction)

1 引言

计算机自适应测验 (CAT) 在传统测评和数字化学习中都有着重要意义。CAT 会自适应地选择与考生能力相匹配的题目，在保证测量精度的同时，最大限度地减少冗余题目和无关题目。因此，CAT 被广泛用于 GMAT、GRE、MCAT、PISA 等标准化测评。这种高效性不仅惠及大规模考试，也延伸到了形成性评价 (formative assessment) 实践中。随着数字化学习系统 (包括 COVID-19 时期的远程学习) 的普及，CAT 可以在整个学习过程中提供每日个性化的自适应测验，从而促进频繁的形成性评价。

为了根据用户估计出的能力水平自适应地呈现题目，CAT 关键性地依赖于**题目 (即问题 (1)) 画像**。CAT 基于已施测题目的画像来实时评估用户，并据此基于未施测题目的画像来选择下一题。获取这些题目画像是一个代价高昂的过程：它需要收集一个完整的作答数据集——也就是说，对于较多的考生，我们必须对每一道考虑中的题目都进行登记 (即让足够多人作答)。这促使我们去考虑一种更**数据高效**的方案：从一个较小的作答数据集出发，持续地利用 CAT 服务收集到的数据来更新题目画像。

然而，我们观察到，利用 CAT 作答数据会因为**选择偏差**而带来挑战。在 CAT 中，这种偏差自然产生，因为所施测题目的难度与学生的能力水平相对应。在线推荐系统等领域也存在类似形式的选择偏差，那里的用户反馈更多地由系统算法塑造，而非用户真实偏好。我们在图 1 (中间部分) 中更深入地剖析了 CAT 作答数据的这一特性。图中，题目和用户分别按难度和能力水平排序。注意，CAT 作答数据呈现出一个明显的模式：能力更强的用户倾向于收到更难的题目，而能力较弱的用户收到较容易的题目。这种选择偏差会扭曲题目画像；例如，高水平用户对难题的正确作答，可能会错误地告诉诊断模型「这些题目其实没那么难」。

(1)「题目 (item)」与「问题 (question)」这两个词可互换使用，均指一次测验中的单道题。

为了最大限度地利用 CAT 作答数据，我们提出了**用户级聚合影响函数 (user-wise Aggregate Influence Function, AIF)** 方法，它在题目画像建模之前先筛选出偏差最小的 CAT 作答数据 (见图 1 的示意)。具体而言，我们的方法受影响函数 (**Influence Function, IF**) 思路启发，IF 用于识别每一个有偏数据点对估计得到的题目画像参数偏离程度的贡献。不同于只关注每个作答数据点单独的 IF，用户级 AIF 考虑某一用户**全部作答数据**的聚合效应，进而过滤掉那些作答严重有偏的用户。

在实验中，我们基于三个公开数据集和一个额外包含真实世界 CAT 作答数据的数据集，验证了用户级 AIF 方法的有效性。在所考虑的所有情形中，我们的方法在评估准确率 (以 AUC 衡量) 方面均优于基线方法，同时给题目画像引入的偏差也最小 (以真实难度与估计难度之间的秩相关衡量)。(2)

综上，我们的贡献是：

- **观察到 CAT 作答数据中的选择偏差：**我们识别出由 CAT 自适应特性所固有引入的选择偏差。具体而言，据我们所知，这是首个使用真实世界 CAT 服务数据来研究 CAT 作答数据中选择偏差的工作。
- **用户级聚合 IF 方法：**我们提出了一种新颖的去偏方法，称为用户级聚合 IF 方法。这个简单的方法有效地缓解了 CAT 作答数据中存在的选择偏差，并克服了传统 IF 方法的局限性。
- **实验结果：**我们基于模拟的和真实世界的 CAT 作答数据进行的实验表明，即使在无偏初始数据有限的情况下，用 AIF 引入 CAT 作答数据也能提升 CAT 性能。

(2) 代码与部分数据集可在 <https://github.com/rriid/UserAIF> 获取。

本文结构如下：第 2 节中，我们借助一个真实世界数据集讨论 CAT 中的选择偏差；第 3 节介绍我们的用户级 AIF 方法；第 4 节给出实验结果。

2 CAT 与选择偏差

计算机自适应测验。CAT 由两个关键组件构成：实时用户评估与题目选择。首先，给定用户的能力水平会基于预训练的题目画像被实时估计。对于二分 (dichotomous, 即对/错) 题目，常用于题目画像建模的诊断模型包括一参数到四参数的逻辑斯蒂项目反应模型 (Item Response Models, IRT)。CAT 的第二个关键组件是题目选择算法。该算法在考虑考生能力水平和候选题目画像的前提下，推荐下一道要呈现给考生的题目。多年来，各种题目选择算法已被广泛研究。最近，一些研究还探索了把 CAT 任务表述为双层优化 (bi-level optimization) 问题或强化学习问题，从而训练题目选择算法。

预备知识。如上所述，CAT 关键性地依赖在 CAT 之前通过诊断建模得到的题目画像。我们首先描述题目画像是如何基于诊断建模和初始收集的稠密数据学习出来的。

设对于一组用户 $\mathcal{U}$ 和一组题目 $\mathcal{Q}$ ，我们有一份题目-作答数据 $\{x_{ij} \mid i \in \mathcal{U}, j \in \mathcal{Q}\}$ ，其中若用户 i 正确作答题目 j 则 $x_{ij} = 1$ ，否则为 0。诊断建模的目标是准确预测给定用户正确作答给定题目的概率：

$$p_{ij} = \mathbb{P}(x_{ij} = 1 \mid d_j, \theta_i),$$

其中 $\theta_i \in \mathbb{R}^{1 \times m}$ 表示用户 $i \in \mathcal{U}$ 的可训练 m 维用户嵌入 (能力参数)， $d_j \in \mathbb{R}^{1 \times n}$ 表示题目 $j \in \mathcal{Q}$ 的 n 维题目嵌入。

为了训练模型，在给定相应参数的条件下，给每个数据点分配如下的单点损失：

$$l(x_{ij} \mid d_j, \theta_i) = -x_{ij} \log p_{ij} - (1 - x_{ij}) \log(1 - p_{ij}). \quad (1)$$

最后，给定初始收集的稠密、无偏数据集，我们最小化如下损失函数：

$$L(x \mid \beta) = \frac{1}{\sum_{i \in \mathcal{U}_{unbiased}} |\mathcal{Q}_i|} \sum_{i \in \mathcal{U}_{unbiased}} \sum_{j \in \mathcal{Q}_i} l(x_{ij} \mid d_j, \theta_i), \quad (2)$$

其中 $\mathcal{U}_{unbiased}$ 表示稠密无偏数据集集中的用户集合， $\beta = (d_1, \dots, d_{|\mathcal{Q}|}, \theta_1, \dots, \theta_{|\mathcal{U}_{unbiased}|})$ 表示用诊断模型对无偏训练集 x 所要估计的全部参数。因此，我们把 $\mathcal{U}_{unbiased}$ 称为**无偏用户**。

选择偏差。假定题目嵌入已经准备好、且已建立合适的题目选择算法，我们就可以启动 CAT 服务了。设 CAT 服务上线后，我们从被服务的用户那里收集到作答数据，记为

$$z = \{z_k\}_{k \in \mathcal{U}_{biased}} = \{z_{kj}, j \in \mathcal{Q}_k\}_{k \in \mathcal{U}_{biased}}.$$

与 x 类似， z_{kj} 表示新用户 k 对题目 $j \in \mathcal{Q}_k$ 作答的对错。集合 $\mathcal{U}_{biased}$ 表示接受过 CAT 服务的用户群体，我们称之为**有偏用户**。无偏用户 i 的题目集合 $\mathcal{Q}_i$ 与 $\mathcal{Q}$ 相同，而 $\mathcal{Q}_k$ 则是为每个用户 k 个性化施测的题目集合。

CAT 的个性化特性给 CAT 作答数据集 z 引入了偏差。例如，对于一维单参数 IRT 模型，基于费舍尔信息 (Fisher Information, FI) 的题目选择算法会选择能使 FI 最大化的题目：

$$I_j(\theta_k) = p_{kj}(1 - p_{kj}).$$

这意味着该算法倾向于偏好预测正确概率接近 0.5 的题目。结果是，题目参数与用户能力之间被显式地引入了一种强关联，这正是数据集 z 中选择偏差的来源。

真实世界数据集中的选择偏差。我们现在基于从 R.test(3) 收集的 CAT 作答数据集证明：CAT 中的选择偏差确实会在现实中发生。R.test 是一个由 AI 驱动的诊断测验平台，使用 CAT 来评估学生的应试准备程度。图 2 下半部分展示了 SAT 阅读部分（共 52 道题）的用户—题目作答情况。该 CAT 服务数据集包含 125 名被服务用户的作答，每名用户做了 10 道题。与图 1 类似，题目和用户按其正确率排序。由于一些内容上的约束，图 2 中的用户—题目模式与图 1 略有不同。尽管如此，它仍然展现出「用户所收到题目的难度与其能力水平相关」的趋势。

图 2 上半部分进一步说明了这一现象：它分别用无偏作答数据和 CAT 服务数据，展示了所有题目的正确率。可以明显看到，CAT 服务数据的正确率与原始正确率有显著偏离。为了进一步分析偏差程度，我们计算了「从大规模无偏数据集得到的题目参数」与「从有偏 CAT 服务数据得到的题目参数」之间的秩相关。观测到的秩相关仅为 0.0881。这一发现证实了 CAT 服务数据中存在偏差，凸显出我们需要有效的方法来缓解这种偏差，从而提升 CAT 中题目参数估计的准确性。

(3)<https://www.rtest.ai/>

图 2：在 R.test 平台上 SAT 阅读部分的用户—题目作答情况及题目级正确率的可视化。

3 聚合影响函数

本节描述我们提出的方法——用户级聚合影响函数 (AIF)，用于缓解 CAT 作答数据中的选择偏差。我们首先介绍影响函数 (IF) 思路；接着，通过按用户考虑聚合 IF，把 IF 改造得更适合 CAT 作答数据。

3.1 影响函数

简单来说，IF 衡量的是：当把一个数据点加入现有训练集后，估计参数会被引入多大的扰动。更形式化地说，回顾我们已通过优化式 (2) 从无偏数据 x 得到参数 $\hat{\beta} \in \mathbb{R}^{1 \times (n|Q|+m|U_{unbiased}|)}$ ，即

$$\hat{\beta} = \arg \min_{\beta} L(x | \beta).$$

现在假设把来自 z 的单个新数据点 z_{kj} （有偏用户 $k \in \mathcal{U}_{biased}$ 对题目 j 的作答）加入训练集 x 。我们令 θ_k^{biased} 为有偏用户 k 的用户嵌入。

为了研究它对原参数 $\hat{\beta}$ 的影响，考虑如下被扰动的参数估计器：

$$\hat{\beta}_{\epsilon, z_{kj}} = \arg \min_{\beta} (1 - \epsilon)L(x | \beta) + \epsilon l(z_{kj} | d_j, \theta_k^{biased}).$$

这里，我们并不为有偏用户引入一个新参数，而是使用从 CAT 估计得到的固定值 θ_k^{biased} 。注意，当 CAT 测验长度足够大时，这个估计是相当准确的。同时，这种做法使我们能够只考虑原参数 β ，从而简化问题。

利用 Hampel 的 IF，我们评估「在无偏集 x 的经验分布上、在新数据点 z_{kj} 处施加无穷小量污染」对 β 估计的影响：

$$\text{IF}_{\beta}(z_{kj}, x) = \lim_{\epsilon \rightarrow 0} \frac{\hat{\beta}_{\epsilon, z_{kj}} - \hat{\beta}}{\epsilon}. \quad (3)$$

这个 IF (3) 可以计算为

$$\text{IF}_{\beta}(z_{kj}, x) = -H_x^{-1} [\nabla_{\hat{\beta}} l(z_{kj})]^T, \quad (4)$$

其中 $H_x = \nabla_{\beta}^2 L(x | \beta) \big|_{\beta=\hat{\beta}}$ 是海森矩阵 (Hessian matrix)， $\nabla_{\hat{\beta}} l(z_{kj})$ 是 $\nabla_{\beta} l(z_{kj} | d_j, \theta_k^{biased}) \big|_{\beta=\hat{\beta}}$ 的简写。对于 IRT 模型，梯度和海森矩阵都可以解析地定义和计算。(4)

虽然 IF (4) 在去偏问题上的应用各式各样 (5)，但被最广泛采用的方案出自 [7]。在那项工作中，作者引入了「在一个新的无偏测试点上计算损失」的 IF。这通过链式法则推导得到，在我们的语境下表示为

$$\text{IF}_{loss}(z_{kj}, y_{pq}) = -\nabla_{\hat{\beta}} l(y_{pq}) H_x^{-1} [\nabla_{\hat{\beta}} l(z_{kj})]^T$$

这里, y_{pq} 表示来自 $\mathcal{U}_{unbiased}^{val}$ 的无偏用户 p 的作答, $\mathcal{U}_{unbiased}^{val}$ 是一组与 $\mathcal{U}_{unbiased}$ 不重叠的无偏验证用户。当考虑由 y_{pq} 组成的整个集合 y 时, 我们滥用记号写作

$$\text{IF}_{loss}(z_{kj}, y) = \sum_{p \in \mathcal{U}_{unbiased}^{val}} \sum_{q \in \mathcal{Q}_p} \text{IF}_{loss}(z_{kj}, y_{pq}). \quad (5)$$

参数上的 IF (4) 和损失上的 IF (5), 分别给出了每个有偏数据点对参数偏离、对损失偏离的贡献的近似。

(4) 实现这些公式的代码及其说明可在 <https://github.com/riid/UserAIF> 找到。(5) 第 4 节的基线方法给出了一份相关可用方法的清单。

然而, 正如先前研究 [8] 所强调的, 当处理一大组数据点时, 有必要考虑组内的交叉效应 (cross-effects)。因此, 我们不再只关注单个数据点的 IF, 而是提出一种考虑「数据组」的数据选择方法, 这一思路由我们研究中观察到的选择偏差特性所驱动。

3.2 用户级聚合影响函数

接下来, 我们提出一种数据选择方法, 它兼顾两个关键考量。第一, 我们希望最小化所选数据点对原参数变化的影响; 第二, 我们力图在所选组内保留题目之间的相对难度排序。为实现这一点, 我们的方法采用按用户 (user-wise) 的视角: 纳入每个用户的完整作答数据, 以维持其数据集内部的秩信息。此外, 我们对该用户所有数据点上的全部参数, 利用其聚合的 IF 值。

我们首先把估计器 $\hat{\beta}$ 对每个有偏用户的用户级 AIF 定义如下:

$$\text{AIF}_{\beta}(k, x) = \sum_{j \in \mathcal{Q}_k} \sum_c (\text{IF}_{\beta}(z_{kj}, x))_c \quad (6)$$

对于用户 $k \in \mathcal{U}_{biased}$, 这里, 下标 c 从 1 取到向量 β 的总长度, $(\text{IF}_{\beta}(z_{kj}, x))_c$ 表示 $\text{IF}_{\beta}(z_{kj}, x)$ 的第 c 个元素。

基于 AIF, 我们提出如下选择方法, 记为「UserAIF」:

1. 对每个有偏用户 k 计算 $\text{AIF}_{\beta}(k, x)$ 。
2. 选出一组被选中的有偏用户 $\mathcal{U}_{biased}^s$, 其 $|\text{AIF}_{\beta}(k, x)|$ 小于某个阈值 η , 即

$$\mathcal{U}_{biased}^s = \{k \in \mathcal{U}_{biased} : |\text{AIF}_{\beta}(k, x)| \leq \eta\}.$$

3. 用 $x \cup \{z_k\}_{k \in \mathcal{U}_{biased}^s}$ 重新训练模型。

在实验中, 阈值 η 取集合 $\{|\text{AIF}_{\beta}(k, x)|\}_{k \in \mathcal{U}_{biased}}$ 的第一分位数 (即下四分位数, 25%), 但数值结果对该阈值的选取是鲁棒的。

4 实验

本节给出在三个公开数据集和一个真实世界 CAT 作答数据集上的实验结果。我们先描述对比的基线方法; 随后, 用两个公开稠密数据集对我们的方法做对比分析; 进一步, 我们探究将方法应用于一个近期提出的 CAT 神经模型, 以及应用于从 R.test 收集的真实世界 CAT 作答数据时的有效性。

4.1 基线方法

在以下基线描述中, 我们用 x 、 y 、 z 分别表示无偏训练集、验证集和有偏集。

4.1.1 重训练 (Retraining) 最简单的基线是用变更后的数据集重新训练题目反应模型。我们使用三种数据集: 有偏 (z)、无偏 (x)、以及有偏加无偏 ($z \cup x$)。

4.1.2 IPS 逆倾向得分加权 (Inverse of Propensity Score, IPS) 是推荐系统去偏中最流行的方法之一。然而, 在稀疏数据集上很难估计倾向得分, 因此我们采用 [23] 中基于朴素频率的 IPS 方法, 记为 IPS-NB 与 IPS-NB-IW。

4.1.3 IF 我们用 IF 实验多种基线。基于 IF 的基线有两类：一类是加权方法，另一类是用 IF 从有偏集中做选择。

- **IF4URec [23]**: 这是最相关的工作，它提出一种交互级 (interaction-wise) 加权方法，并在推荐中证明能有效去偏。某次交互的建议权重值用式 (5) 计算如下：

$$\pi_{k,j} = \frac{1}{1 + e^{\frac{\text{IF}_{\text{loss}}(z_{kj}, y)}{\alpha \max_{k,j} \{\text{IF}_{\text{loss}}(z_{kj}, y)\} - \min_{k,j} \{\text{IF}_{\text{loss}}(z_{kj}, y)\}}}},$$

其中 α 为某常数。

- **IFloss**: 我们选出 z 中满足 $\text{IF}_{\text{loss}}(z_{kj}, y) < 0$ 的数据 z_{kj} ，其中 $\text{IF}_{\text{loss}}(z_{kj}, y)$ 用式 (5) 计算。所选的点被期望能最小化验证损失。然后用无偏集与所选数据训练最终模型，即 $x \cup \{z_{kj} : \text{IF}_{\text{loss}}(z_{kj}, y) < 0\}$ 。
- **IFparam**: 我们用式 (4) 选出 z 中满足 $\text{IF}_{\beta}(z_{kj}, x) < \eta$ 的数据 z_{kj} (η 为某阈值)。所选交互被期望产生「与在无偏集上训练得到的原参数相近」的扰动参数。用于重训练的数据是 $x \cup \{z_{kj} : \text{IF}_{\beta}(z_{kj}, x) < \eta\}$ 。
- **GreedyAIF**: 我们以贪心方式，逐个寻找能使聚合效应最大化的一组数据点。从初始点 $z_{kj}^1 \in z$ 出发，第 S 个被选中的数据 z_{pq}^S 取为

$$\arg \min_{p,q} \left\{ \sum_c [\text{IF}_{\beta}(z_{pq}, x)]_c + \sum_{s=1}^{S-1} \sum_c [\text{IF}_{\beta}(z_{p_s q_s}^s, x)]_c \right\}.$$

4.2 主对比实验

本节通篇使用一维双参数 IRT 模型，搭配基于 Kullback-Leibler 信息 (KLI) 的题目选择方法。这被公认为 CAT 文献中最流行的方案，并在所考虑的数据集上被证明能带来最佳性能。

4.2.1 数据集 由于缺乏带有 CAT 偏差的公开数据集，我们通过两个真实世界稠密数据集 ENEM 与 NIPS-EDU 上模拟 CAT，来制造有偏数据。ENEM 来自 2019 年的巴西全国高中考试 (Exame Nacional do Ensino Medio)。我们使用稠密化后的 NIPS-EDU [18]，它由 Eedi 在 NeurIPS 2020 教育挑战赛上发布。对于每个数据集，无偏用户被划分为训练用户与验证用户，分别记为 $\mathcal{U}_{\text{unbiased}}$ 与 $\mathcal{U}_{\text{unbiased}}^{\text{val}}$ 。我们得到 ENEM 与 NIPS-EDU 的 CAT 数据集，即由 KLI 方法生成、含有 CAT 偏差的有偏集。考虑到题目总数 $|Q|$ ，我们为 $\mathcal{U}_{\text{biased}}$ 中的每个有偏用户在 ENEM 上选 30 道题、在 NIPS-EDU 上选 40 道题。各数据集的统计信息见表 1。注意，我们模拟的是无偏用户数量有限的现实场景。

4.2.2 实验设置 评价指标方面，我们使用受试者工作特征曲线下面积 (AUC，以% 表示)、秩相关 (Rank Corr.) 和准确率 (ACC，以% 表示)。表格中给出的 $\pm$ 值表示由五次实验得到的标准差，说明结果在不同运行间的一致性。首先，我们检视 CAT AUC 以评估 CAT 的性能。为观测 CAT AUC，我们把题目划分为题池题 (pool-items) 和评测题 (eval-items)：用题池题执行 CAT，然后在评测题上评估性能。验证我们方法对题目表征质量的影响也很重要。因此，我们额外检视两个指标——Random AUC 与 Rank Corr.。为观测 Random AUC，我们冻结训练好的题目表征，对每个用户随机提供 80% 的交互用于更新用户表征，然后在剩余 20% 的交互上评估 AUC。我们还观测「重训练后的题目表征」与「从大规模无偏数据得到的题目表征（我们视其为真实值）」之间难度参数的 Rank Corr.。

对于早停 (early stopping)，我们使用专门针对 CAT 场景的验证方法。CAT 的目标是用训练好的题目表征评估新用户的能力，因此我们在 y 上做验证。每个验证步骤中，我们冻结训练得到的题目表征，提供 y 的 80% 交互，并基于在剩余 20% 交互上的预测计算验证损失。

表 1: 真实世界数据集的统计信息 (含 $|Q|$ 、 $|\mathcal{U}_{\text{unbiased}}|$ 、 $|\mathcal{U}_{\text{unbiased}}^{\text{val}}|$ 、 $|\mathcal{U}_{\text{biased}}|$ 、测试用户数)。

数据集	$ Q $	$ \mathcal{U}_{\text{unbiased}} $	$ \mathcal{U}_{\text{unbiased}}^{\text{val}} $	$ \mathcal{U}_{\text{biased}} $	测试用户数
ENEM	185	40	10	1,000	2,000
NIPS-EDU	200	40	10	638	200
Assist2009	26,700	266	66	334	166

4.2.3 结果 首先，我们指出选择偏差在所考虑的 CAT 数据集集中的影响。表 2 给出了基线与我们方法的评价指标。值得注意的是，用有偏集重训练 IRT 时，两个数据集上的所有指标都明显欠佳。难度参数的低秩相关凸显出，如前所述，CAT 偏差导致了题目难度排序的扭曲。

其次，在表 2 中，UserAIF 通过考虑 IF 的聚合效应以及保留每个用户所收题目秩信息的「按用户」选择，在「题目表征质量」和「CAT 性能」两方面的评估上都优于其他基线。

基于 IPS 的方法（表中第二部分）可能有前景。然而，由于计算 IPS 用到的是交互频率，它们在像 NIPS-EDU 这样数据稀缺的场景下往往不够精确。在 NIPS-EDU 上，基于 IPS 的方法在 CAT AUC 上甚至不如重训练 IRT 的基线。

基于 IF 的基线方法（它们只考虑单个数据点上的 IF）并不能提供完整的解决方案。IF4URec 与 IFloss 依赖额外的无偏验证集，由于该集合规模很小，这可能成为劣势。我们还观察到，考虑了所选数据点间 IFparam 聚合效应的 GreedyAIF，在 ENEM 数据集上导致整体相对欠佳，并使 Rank Corr. 下降。

第三，我们考察 UserAIF 的性能如何随不同题目选择算法所引入的选择偏差程度而变化。图 3 给出了在 ENEM 数据集上由 FI 与 KLI 方法生成的两个有偏集的结果。FI 题目选择算法被用于双参数 IRT。左侧面板展示 AUC 与 Rank Corr.，右侧面板展示有偏用户的 AIF (6) 绝对值之和。我们观察到，由 KLI 生成的有偏集表现出更差的性能指标和更大的 $\sum |AIF_{\beta}(k, x)|$ ，表明 KLI 方法引入了更强的偏差。UserAIF 在 KLI 有偏集上的所有指标改进都更大。从 FI 与 KLI 的结果来看，我们预期我们的方法对其他题目选择算法也会有良好表现。

图 3：题目选择算法的消融实验。

4.3 对神经模型的适用性

尽管基于 IRT 的反应模型和基于信息量的题目选择方法在 CAT 中仍被广泛使用，最近一些基于神经网络的方法已被提出并展现出卓越性能。BOBCAT [5] 是 SOTA 方法之一，它利用双层优化同时训练诊断模型和题目选择模型。具体地，我们使用在原论文中表现最佳的 BiNN-Approx 模型。

数据集。实验中我们使用 Assist2009 数据集，它是原论文使用的基准数据集之一。Assist2009 数据采集自 2009–2010 学年一个面向 7 至 12 年级学生的网络数学辅导系统。与之前的数据集不同，Assist2009 数据集呈现稀疏性——事实上其填充率仅为 0.0128。因此，在做 CAT 时，我们只能选择数据集中已有交互的题目，这限制了 CAT 过程中的可选项。鉴于深度模型对充足训练数据的需求，我们在 Assist2009 上比之前的实验纳入了更多无偏用户。Assist2009 的更详细统计信息见表 1。使用训练好的 BiNN-Approx 模型，我们通过在 CAT 过程中共施测 30 道题，生成模拟的有偏 CAT 作答数据。

模型。BiNN-Approx 模型以一个神经网络作为反应诊断模型（带全局反应模型参数），并以题目选择参数上的近似梯度学习题目选择算法。为应用我们提出的方法，我们在 AIF 计算 (6) 中用全局反应模型参数作为 β 。相应地，式 (6) 中 β 的维度被缩减为「全局反应模型参数个数」乘以「参数维度」。

结果。我们首先考察使用 BiNN-Approx 模型时是否会出现选择偏差。先前工作 [5] 提到，学习到的题目选择模型倾向于提供多样性较低的一组题目。然而，我们仍然观察到生成的 CAT 数据中存在选择偏差。图 4 通过比较「在无偏数据和 CAT 作答数据中均被施测超过 75% 的题目」的正确率来说明这一点。有偏 CAT 数据（红色所示）的题目正确率出现波动，与无偏数据中观察到的单调有序形成对比，这与图 2 类似。此外，表 3 表明，当把有偏数据加入无偏数据时，CAT AUC 会下降。

图 4：Assist2009 中正确率的可视化。

其次，我们在表 3 中展示我们方法在 BiNN-Approx 模型上、步数为 20 时的性能。尽管相比之前的实验拥有更多无偏数据，UserAIF 方法仅用无偏数据集就在 AUC 和 ACC 上都取得了改进。而且，与之前实验中最强去偏基线 IPS-NB 相比，所提方法依然胜出。

表 2：两个模拟真实世界数据集上各方法的性能（ENEM 与 NIPS-EDU，指标含 CAT AUC-Pool/Eval、Random AUC、Rank Corr.，步数 10/20）。此处为原文表 2，结构复杂，仅转录关键结论：UserAIF 在两个数据集上多数指标取得最佳，例如 ENEM 步数 20 的 CAT AUC-Pool 为 70.13、Rank Corr. 为 0.8600；NIPS-EDU 步数 20 的 CAT AUC-Pool 为 78.33、Rank Corr. 为 0.9030。

表 3：与 BOBCAT 搭配使用时各方法的性能（Assist2009）。

方法	CAT AUC-Eval	CAT ACC-Eval
unbiased	70.98±0.53	68.99±0.28
biased $\cup$ unbiased	70.93±0.68	69.22±0.52
IPS-NB	71.02±0.96	68.65±0.68
UserAIF	71.07±0.62	69.26±0.41

4.4 用 R.test CAT 作答数据的实验

本节中，我们利用自己在 R.test 平台收集的 CAT 服务数据来验证所提方法的有效性。R.test 是一个由 AI 驱动的诊断测验平台，使用 CAT 评估学生的应试准备程度。

部署在 R.test 的 CAT 模型，是用大量初始作答数据训练的，目标是在考生作答 52 道题中的 10 道后，预测其 SAT 阅读分数。随后，我们收集了 125 名在一个月使用该服务的用户的交互，作为我们分析的有偏数据。题目选择算法中还存在额外约束，例如某些题型（如「行证据题」line evidence）需要前置题目，以及同一篇阅读文章相关题目的顺序施测。这些现实服务中固有的约束引入了额外的偏差来源。

表 4 给出评价指标结果，包括步数 $t = 3, 5$ 时的分数平均绝对误差 (Score Mean Absolute Error, MAE)，它衡量对测试用户的预测分数与实际分数之间的差异。CAT 越精确地预测学生能力，我们就能越准确地预测学生分数，即 MAE 越低。unbiased $\cup$ biased 的表现在多个评价指标上劣于 unbiased。相比之下，IPS-NB 和我们提出的方法在所有指标上都有改进。UserAIF 在较小步数下表现尤为出色——它能用更少的题目准确诊断用户，从而提升用户体验。

我们承认，观察到的性能提升相对较小，因为初始数据集显著大于有偏集。然而，我们预期随着服务被更广泛地使用，会有进一步的性能增益。对这些潜在改进的考察与分析留作未来工作。

表 4：在收集的 R.test 数据 (SAT-reading) 上各方法的性能。

方法	CAT AUC-Pool $\uparrow$ (step 3 / 5)	MAE $\downarrow$ (step 3 / 5)	Random AUC $\uparrow$	Rank Corr. $\uparrow$
unbiased	66.65 / 69.10	36.60 / 29.43	72.48	0.9100
biased $\cup$ unbiased	66.62 / 69.04	36.17 / 29.01	72.40	0.9101
IPS-NB	67.06 / 69.23	35.77 / 28.35	72.51	0.9115
UserAIF	67.31 / 69.28	35.63 / 28.66	72.51	0.9119

5 结论

我们观察到 CAT 作答数据中存在选择偏差，它源于 CAT 的自适应特性。为缓解这种偏差，我们引入了用户级 AIF 方法，它相比基线方法展现出更优的性能，同时给题目画像引入的偏差也最小。该方法在不同设置下（包括初始数据、诊断模型、选择算法的变化）始终保持领先，无论是在模拟的还是真实世界的 CAT 作答数据上。未来工作包括：设计自适应的数据选择策略，以及探索应用二阶 IF 来考察组效应。本研究凸显了一种数据高效方案在启动 CAT 服务中的可行性——通过利用 CAT 服务自身的作答数据来持续更新 CAT 性能，从而降低数据收集的成本和时间。

参考文献 (References) 按约定未翻译，详见原文。