

一种带解耦学习选择器的新型计算机化自适应测试框架 (A novel computerized adaptive testing framework with decoupled learning selector)

原文: s40747-023-01019-1.pdf ·译者: Claude ·译于 2026-06-27 术语对照: Computerized Adaptive Testing (CAT, 计算机化自适应测试) · Question Selector (选题器/题目选择器) · Cognitive Diagnosis Model (CDM, 认知诊断模型) · Item Response Theory (IRT, 项目反应理论) · Maximum Fisher Information (MFI, 最大费雪信息量) · Bilevel Optimization (双层优化) · Decoupled Learning (解耦学习)

摘要

计算机化自适应测试 (Computerized Adaptive Testing, CAT) 的目标是准确评估学生在所需学科/领域的能力水平。其核心问题在于: 如何设计一个选题器, 使其能够根据学生此前的作答表现, 一步步地、自适应地为每位学生挑选最合适的题目。现有的大多数选题器通过贪心式的度量函数 (例如题目信息量与不确定性) 来执行, 无法有效捕捉数据特征。也有一些基于学习的选题器, 它们把 CAT 问题重新定义为一个双层优化 (bilevel optimization) 问题, 但其中选题器的参数学习与学生能力估计模型是耦合在一起的, 因而不够灵活。为此, 本文提出了一种带解耦学习选择器 (Decoupled Learning selector) 的新型 CAT 框架, 记为 DL-CAT。具体来说, 我们首先以当前估计的学生能力和题目特征作为输入, 设计了一个基于深度学习的选题器来预测题目的选择分数; 接着, 为了解决「没有真值 (ground truth) 来衡量所选题目质量」这一难题, 我们专门设计了一个近似真值 (approximate ground-truth) 模块和一个成对排序损失 (pairwise rank loss) 函数, 从而独立地更新选题器的参数。在两个真实数据集上的大量实验表明, 本文提出的 DL-CAT 在有效性上有一定优势, 在效率上有显著优势。

关键词 计算机化自适应测试 · 选题器 · 学生评估 · 学习型选择器

引言

计算机化自适应测试 (CAT) 是一种新型的个性化测试模式, 其目标是通过自适应地挑选最合适的题目来准确估计学生的能力水平。为达成这一目标, CAT 会交替地、一步步地执行两个模块 (即学生能力估计模块与选题器模块), 如图 1 所示。具体来说, 在每一步 n , 学生能力估计模块基于此前 (第 1 步到第 $n-1$ 步) 的作答情况, 输出当前估计的学生能力 θ_n ; 选题器随后根据给定的 θ_n 与题目特征, 为学生挑选下一道要作答的题目。由于具有降低成本、提升效率、保障安全等特点, CAT 已被许多标准化考试机构广泛使用, 例如 GRE 和研究生管理科入学考试 (Graduate Management Admission Test, GMAT)。

图 1: CAT 流程的一个示意性例子

在过去几十年里, 人们为 CAT 任务付出了大量努力。其中最典型的工作之一, 使用双参数项目反应理论 (Item Response Theory, IRT) 根据此前作答来估计学生能力, 并使用最大费雪信息量 (Maximum Fisher Information, MFI) 作为选题器。式 (1) 给出了 IRT 函数, 其中 $P_k(\theta_i)$ 是能力为 θ_i 的学生正确作答题目 e_k 的概率, 该题目有两个预训练参数 (即难度 α_k 与区分度 β_k), $\sigma[\cdot]$ 是逻辑斯谛 (logistic) 函数。给定学生此前 (第 1 步到第 n 步) 的作答, IRT 模型可以估计出学生能力 $\hat{\theta}_i^{(n)}$ 。式 (2) 给出了在当前学生能力估计 $\hat{\theta}_i^{(n)}$ 下题目 e_k 的费雪信息量, $P'_k(\hat{\theta}) = \partial P_k(\hat{\theta}) / \partial \hat{\theta}$ 是其求导过程。信息量最大的题目被选中。也就是说, 区分度高、且难度接近当前学生能力估计值的题目, 是每一步最合适的那一道。此后, 人们又发展出许多类似方法, 例如使用多维项目反应理论 (MIRT) 作为学生能力估计模块、用 Kullback-Leibler 信息量 (KLI) 作为选题器的 CAT 系统; 以及使用贝叶斯网络模型作为学生能力估计模块、用期望信息增益最大化作为选题器的 CAT 系统。

$$P_k(\theta_i) = P(Y = 1 | \theta_i, e_k) = \sigma[\alpha_k(\theta_i - \beta_k)] \quad (1)$$

$$I_k(\hat{\theta}_i^{(n)}) = \frac{P'_k(\hat{\theta}_i^{(n)})}{P_k(\hat{\theta}_i^{(n)}) [1 - P_k(\hat{\theta}_i^{(n)})]} \quad (2)$$

尽管这些传统的选题方法具有一定的有效性, 但它们仍有很大的局限。具体来说, 大多数选题算法基于预定义的准则, 这些准则带有一定的偏好, 无法有效捕捉复杂的数据特征。为克服这些启发式选题器的局限, 一些研究者也尝试探索基于学习式选择策略的选题器, 把 CAT 问题重新定义为双层优化问题以及强化学习问题。这些基于学习的选题器相比基于准则的选题器已显示出优势。然而, 这些现有的基于学习的 CAT 框架不够灵活, 因为它们的两个模块 (即学生能力估计模型与选题器) 在训练时是耦合的。例如, 基于双层优化的 CAT 框架在训练过程中通过耦合的内层与外层优化来获得两个模块 (学生能力估计与选题器) 的参数, 即外层优化模型的结果被用来衡量内层优化的质量。

为此, 我们提出了一种带解耦学习选择器的新型 CAT 框架 (DL-CAT)。具体来说, 本文的主要贡献可以总结如下:

- 我们提出了一种新型的基于深度学习的选题器, 它通过给定当前估计的学生能力和题目特征, 直接输出下一道题目。与现有 CAT 系统相比, 其优势体现在两方面。一方面, 它使用深度神经网络更智能地直接选取下一题, 而不是依赖预定义的准则; 另一方面, 该选题器与学生能力估计模块的模型和训练过程都是无关 (agnostic) 的。

- 我们是首个在基于学习的 CAT 框架中将选题器与学生能力估计模型的参数学习解耦的工作。为实现这一目标，我们专门设计了一个近似真值模块和一个损失学习模块，从而独立地更新选题器的参数。
- 在两个真实世界数据集上的实验结果证明了所提出的 DL-CAT 的有效性 & 高效性。尤其是，与传统选题器和新型的基于学习的选题器相比，DL-CAT 在有效性上有一定优势，在效率上有显著优势。

相关工作

本文聚焦于 CAT 的选题器部分。现有的 CAT 选题器主要分为以下两类：基于启发式的选题器，以及基于学习的选题器。

基于启发式的选题器

这一类中的大多数选题器是**模型相关 (model-specific)** 的，由专家根据不同学生能力估计模型（即 CAT 的另一组成部分）的特点专门设计，例如最大费雪信息量 (MFI)、Kullback–Leibler 信息量 (KLI)、香农熵 (Shannon entropy)、互信息 (mutual information)、误差最小化，以及它们针对 IRT 模型专门设计的扩展选题方法。其中，最大费雪信息量 (MFI) 的选题策略核心，是利用当前学生能力的估计值来计算题库中剩余题目的信息量，然后选取信息量最大的题目作为下一道测试题。由于 MFI 函数只与能力估计值有关，因此 Chang 与 Ying 提出了一种基于 KL 全局信息的选题方法，所选题目即 KL 值最大的题目。KL 值越大，说明当前学生能力估计值相对于合理波动范围内的其他能力值越好。此后，当学生能力估计模块从单维 IRT 扩展到多维 IRT (MIRT) 时，人们又提出了多种通过对 MFI 与 KLI 进行多维扩展和优化的选题策略。基于 KLI 的多维扩展主要包括加权 KL 策略 (PWKL) 和能力后验分布 KL 策略。这些模型相关选题器的灵活性是受限的，因为很难针对基于神经网络的学生能力估计模型专门设计一个选题器。

为克服模型相关选题器的局限，人们提出了一种**模型无关 (model-agnostic)** 的选题器，即 MAAT，它基于不确定性来选题。受主动学习 (active learning) 思想的启发，该模型从模型变化的角度进行设计，即计算每道题目所引起的期望模型变化 (expected model change, EMC)，以衡量题目的信息量。最终，期望模型变化 (EMC) 最大的题目被选中，且这一选题器独立于学生能力估计模型。

总之，这些基于启发式的算法只是基于某些先验知识或经验设计的，其缺点是没有充分考虑数据本身的特征。

基于学习的选题器

为解决启发式选题算法无法捕捉数据特征的问题，数据驱动的学习型选题器逐渐受到重视。这一类尝试从大规模行为数据中学习并持续优化一个选题器，而不是使用静态的选题算法，以尽可能减小能力估计的误差。这一类的代表性工作包括基于双层优化的计算机化自适应测试 (BOBCAT) 和神经计算机化自适应测试 (NCAT)。这两个模型都把 CAT 问题重新定义为一个双层优化问题。在双层优化框架中，外层优化问题是通过显式地最大化学生在留出的元题目集 (meta question set) 上作答的预测似然，来学习作答模型参数和数据驱动的选题算法；内层优化问题则是通过最大化学生在已观测训练题目集上作答的预测似然，将外层的作答模型适配到每位学生。为求解 CAT 的双层优化问题，BOBCAT 在双层优化问题中采用了关于选题算法参数梯度的一个有偏近似估计，而 NCAT 则将其形式化地转化为一个等价的强化学习问题。

尽管上述基于学习的选题器取得了很大成功，但基于双层优化框架的不灵活这一缺点仍然明显，因为内层和外层优化（即两个组件的参数学习）在训练过程中相互耦合，即内层（外层）优化被用来衡量外层（内层）优化的质量。这种耦合的训练过程要求：当题库中新增题目时，选题器必须从头重新训练。

因此，本文一方面尝试设计一个基于深度学习的选题器来自动预测题目的选择概率，从而更全面地捕捉数据特征；另一方面，为解决「选题器参数学习与学生能力估计模型耦合」所导致的训练不灵活问题，我们专门设计了一个真值构造模块，以独立地训练选题器。借助这些特殊设计，当题库中新增题目时，选题器可以直接用于在新题库上得到题目选择分数，而无需重新训练（我们只需重新训练学生能力估计模型来获得新题目的参数），这更适用于真实的 CAT 教育场景。

预备知识与问题形式化

本节包含两部分：预备知识与问题形式化。预备知识部分着重介绍传统计算机化自适应测试 (CAT) 的术语、目标与组成结构。问题形式化部分则描述本文 CAT 任务中问题的定义与扩展。本文用到的主要符号列于表 1。

预备知识

在一个智能教育系统中，假设有 L 名学生和 M 道题目，分别可以用学生集合 $S = \{s_1, s_2, \dots, s_L\}$ 和题库 $E = \{e_1, e_2, \dots, e_M\}$ 表示。作答日志 R 中的每个元素可以用一个三元组 (s, e, r) 表示，其中 $s \in S$, $e \in E$, $r \in \{0, 1\}$ 表示学生 s 在题目 e 上的作答得分。这里 $r = 1$ 表示作答正确， $r = 0$ 表示作答错误。一个典型的 CAT 系统有两个组件，即能力估计模型 $\mathcal{M}$ 和选题器 π ：前者基于学生的作答日志 R 来训练能力估计模型 $\mathcal{M}$ ；后者则根据学生的行为记录 R 和能力估计值 θ 动态地选取下一道题目 e 。经过基于学生交互数据的多轮选题后，当测试结束时，便形成了一个适配学生 s 的测试序列。我们的目标是设计一个策略 π ，根据学生 s_i 的表现一步步地选出一个大小为 N 的题目集合，记为 $E_i = \{e_1^*, e_2^*, \dots, e_N^*\}$ ，从而更准确地测评考生。

表 1: 本文用到的主要符号 | 符号 | 描述 | L | 学生数 | N | 题目数 | S | 学生集合 | E | 题库 | s_i | S 中第 i 名学生 | e_j | E 中第 j 道题目 | r_{ij} | 学生 s_i 在题目 e_j 上的作答得分 | R | 作答日志, 由三元组 (s, e, r) 集合表示 | $\mathcal{M}$ | 能力估计模型, 根据此前作答估计学生当前能力 | π | 选题器 | n | CAT 中所选题目的总数 | $\hat{\theta}_i^{(k-1)}$ | 选完第 $k-1$ 题后对 s_i 的能力估计 | θ_i^0 | 学生 s_i 的真实能力 (通常未知) | α_j, β_j | 题目 e_j 的难度与区分度参数 | X_{ij} | 拼接后用作输入的特征 | p_{ij} | s_i 选择 e_j 的预测分数 |

如相关工作一节所述, 一些最新的数据驱动方法在元学习 (meta-learning) 配置下把 CAT 问题形式化为双层优化问题, 其中能力估计模型 $\mathcal{M}$ 与选题器 π 的参数学习耦合在一起。具体而言, 在外层优化中, 两个模块的参数通过最大化元集上的预测准确率来学习; 在内层优化中, 外层学到的两个模块参数被应用于学生的能力评估, 以最大化其在训练集上的预测准确率。

问题形式化

本文的目标是把能力估计模型 $\mathcal{M}$ 与选题器 π 的训练过程解耦。因此, 我们着重于设计一个可学习的选题器 π , 用于在每一步 k , 通过给定当前估计的学生能力 $\hat{\theta}_i^{(k-1)}$ 和题目参数, 从 E 中为学生 s_i 选取一道题目 e 。在收到学生 s_i 在题目 e 上的作答 r 后, 模型 $\mathcal{M}$ 更新并估计出新的能力 $\hat{\theta}_i^{(k)}$ 。值得注意的是, 学生能力 $\hat{\theta}_i$ 的更新只基于此前所选的题目和作答结果, 而与选题器本身无关。这一过程重复 n 次, 从而准确地估计学生能力, 即 $\theta_i^{(n)} \rightarrow \theta_i^0$, 其中 θ_i^0 是学生 s_i 的真实能力 (通常未知)。

所提出的方法

整体框架

所提出方法的主要思想是: 在每一步, 通过选题器, 根据学生当前对各个知识概念的知识掌握程度 (或称知识能力), 为学生选取一道最合适的题目。显然, 有两个组件对所选题目的质量有很大影响: 一是用于诊断学生当前知识掌握程度的学生能力估计模型, 二是用于推荐合适题目的选题器。由于本文的重点是设计一个有效的选题器, 我们将直接采用现有的学生能力估计模型 (例如 IRT 或 MIRT) 来获得学生在各知识概念上的知识能力。然而, 由于任务的特殊性, 没有真值来衡量所选题目的质量, 因此一般的训练流程无法直接套用。为解决这一问题, 我们设计了一个真值构造模块, 为选题器生成合理的标签, 使其训练过程能够良好地执行。此外, 我们还进一步提出了一个成对排序损失函数, 使模型的训练更稳定, 从而带来更好的最终性能。

为便于理解, 所提出方法 DL-CAT 的整体框架已总结于图 2, 主要由四个步骤组成。首先, 基于所有学生的作答日志训练一个经典的认知诊断模型, 其中学生能力估计模型通过对学生作答得分建模来获得学生的知识能力。第二, 在学生能力估计模型中得到的学生能力参数与题目隐参数被组合起来作为选题器的输入, 然后选题器预测学生在所有候选题目上的分数。接着, 真值模块被用来为给定学生生成对应的标签。第四, 基于预测输出和生成的标签计算损失函数来更新选题器的权重参数, 其中采用了所建议的成对排序损失。上述过程将对所有学生重复执行, 直到选题器收敛才结束。此后, 选题器将分别向每位学生推荐分数最佳的题目。

图 2: 选题器及其训练方法

选题器

选题器 π 通过挖掘学生与题目之间的关系, 根据学生当前的知识能力状态, 为学生选取一个合适的题目序列。直观上, 对学生当前知识能力的诊断越准确, 选题器为该学生选出的题目就越合适。因此, 在挖掘学生与那些他从未做过的新题目之间的潜在关系之前, 先用一个认知诊断模型 $\mathcal{M}_C$ 为每位学生获得准确的诊断结果是很重要的。为此, 我们首先在训练数据集 D 上基于所有学生的作答日志, 通过最小化下面的损失来训练一个认知诊断模型 $\mathcal{M}_C$:

$$\text{loss} = -\frac{1}{n} \sum_{(s_i, e_j, r_{ij}) \in D} r_{ij} \log \hat{r}_{ij} + (1 - r_{ij}) \log(1 - \hat{r}_{ij}), \quad (3)$$

其中 $\hat{r}_{ij} = \mathcal{M}_C(s_i, e_j)$ 表示模型 $\mathcal{M}_C$ 预测学生 s_i 正确作答题目 e_j 的概率。然后, 我们直接从训练好的模型 $\mathcal{M}_C$ 中提取与学生相关的参数, 作为学生当前的知识能力。此外, 为得到学生从未做过的新题目 e_j 的表示, 我们也从模型 $\mathcal{M}_C$ 中提取了与题目相关的参数。注意, 在下文中, e_j 表示题库中学生 s_i 从未做过的题目。

以项目反应理论 (IRT) 模型为例, 其前向传播过程可记为:

$$\begin{cases} h_S = X_i^S \times W_S, & W_S \in \mathbb{R}^{L \times D} \\ h_E = X_j^E \times W_E, & W_E \in \mathbb{R}^{M \times D} \\ \theta_i = h_S \times W_\theta, & W_\theta \in \mathbb{R}^{D \times 1} \\ \alpha_j = h_E \times W_\alpha, & W_\alpha \in \mathbb{R}^{D \times 1} \\ \beta_j = h_E \times W_\beta, & W_\beta \in \mathbb{R}^{D \times 1} \\ \hat{r}_{ij} = \text{Sigmoid}(\alpha_j \cdot (\theta_i - \beta_j)) \end{cases} \quad (4)$$

其中 D 是嵌入维度, $x_i^S \in \{0, 1\}^{1 \times L}$ 是 s_i 的学生独热 (one-hot) 向量, $x_j^E \in \{0, 1\}^{1 \times M}$ 是 e_j 的题目独热向量, $W_S, W_E, W_\theta, W_\alpha, W_\beta$ 是嵌入层中的可训练矩阵。于是 $\hat{r}_{ij} = \mathcal{M}_C(s_i, e_j \mid \hat{\theta}_i, \alpha_j, \beta_j)$ 。这里, 我们可以为学生 s_i 提取一个学生相关参数 θ_i , 并为新题目 e_j 提取两个题目相关参数, 即题目区分度 α_j 与题目难度 β_j 。

此后, 所提出的选题器 π 以学生当前的知识能力和题目参数作为其输入。为整合这两类输入特征, 使用一个简单却有效的拼接 (concatenation) 操作得到 π 的正式输入:

$$X_{ij} = [\theta_i, \alpha_j, \beta_j]. \quad (5)$$

于是, 对于新题目 e_j , 所提出的选题器 π 将通过一个 h 层的多层感知机 (MLP) 来预测学生 s_i 在题目 e_j 上的分数 p_{ij} , 其基本前向传播过程如下:

$$\begin{cases} y_1 = \sigma(W_1 \times X_{ij} + b_1) \\ \dots, \\ y_i = \sigma(W_i \times y_{i-1} + b_i), \quad 2 \leq i \leq h-1 \\ p_{ij} = \sigma(W_h \times y_{h-1} + b_h) \end{cases} \quad (6)$$

其中 $\sigma(\cdot)$ 是激活函数, y_i 是第 i 层的输出, W_i 与 b_i 是第 i 层的权重与偏置。

真值构造

由于选题器 π 独立于模型 $\mathcal{M}_C$, 因此无法直接利用模型 $\mathcal{M}_C$ 来判断某次选题对学生是否合适。为衡量所选题目的质量, 我们提出一个近似真值构造模块来获得有效的真值。

具体来说, 该模块将生成一个真值, 用以衡量 π 所选题目的有效性。为此, 使用 RMSE (均方根误差) 来计算「学生真实能力 θ_i^0 」与「为学生 s_i 选定一题后更新的能力 $\hat{\theta}_i$ 」之间的差异。这里, 学生的 θ_i^0 是基于学生元集作答日志获得的。首先, 我们初始化学生 s_i 的知识能力 θ_i , 选取一组题目 $\{e_1, e_2, \dots, e_q\}$ 作为支持集 D_T^i , 并基于 $\mathcal{M}_C$ 和 D_T^i 得到更新后的学生能力 $\hat{\theta}_i$ 。然后, 我们通过下式计算 $\hat{\theta}_i$ 的 Rmse_{ij} :

$$\text{Rmse}_{ij} = \sqrt{\frac{1}{|D_V^i|} \sum_{f=1}^{|D_V^i|} (r_{if} - \mathcal{M}(s_i, e_f \mid \hat{\theta}_i, \alpha_f, \beta_f))^2}, \quad (7)$$

其中 D_V^i 表示元集, $|D_V^i|$ 是 D_V^i 中的题目数, r_{if} 是题目 e_f 上的真实作答得分, $\mathcal{M}(s_i, e_f \mid \hat{\theta}_i, \alpha_f, \beta_f)$ 是模型 $\mathcal{M}_C$ 在更新后的学生能力 $\hat{\theta}_i$ 下对题目 e_f 预测的概率。真值构造模块通过用验证集上的结果进一步衡量所选题目的质量, 从而模拟真实的 CAT 估计过程。本文将这一模拟过程生成的近似值用作预测分数的标签, 从而克服「无法直接反映所选题目对学生是否合适」的难题。

算法 1: 选题器的训练过程 (输入: 训练集 D 中的所有学生 S , $\mathcal{M}$ ——基础认知诊断模型 CDM(IRT), $f(\phi)$ ——选题器, $\text{step} = 0$.) 1. $\theta = \{\theta_1, \dots, \theta_n\} \leftarrow$ 初始化 S 中每位用户的能力 2. $\alpha = \{\alpha_1, \dots, \alpha_m\}$, $\beta = \{\beta_1, \dots, \beta_m\} \leftarrow$ 在历史数据上预训练 $\mathcal{M}$ 3. **while** 选题器训练未收敛 **do** 4. **for** $\text{step} \in 0 \dots n$ **do** 5. **if** $\text{step} > 0$ **then** 6. $\theta = \{\hat{\theta}_1, \dots, \hat{\theta}_n\} \leftarrow$ 更新学生能力 7. **for** each $i \in S$ **do** 8. $D_i \leftarrow$ 学生 i 的记录数据 9. $D_T^i, D_V^i \leftarrow$ 将 D_i 划分为训练集与元集 10. **for** each $(e_j, r_j) \in D_T^i$ **do** 11. $X_i^j \leftarrow (\theta_i, \alpha_j, \beta_j)$ // 拼接特征 12. $p_{ij} \leftarrow f(X_i^j \mid \phi)$ // 预测分数 13. $\hat{\theta}_i \leftarrow \mathcal{M}(\theta_i, e_j)$ // 更新学生能力 14. $\text{rmse}_{ij} \leftarrow \mathcal{M}(\hat{\theta}_i, D_V^i)$ // 在 D_V^i 上验证 $\hat{\theta}_i$ 15. $P_i = (p_{i1}, \dots, p_{it})$, $\text{RMSE}_i = (\text{rmse}_{i1}, \dots, \text{rmse}_{it})$ 16. 用式 (8) 计算成对损失 L_i 17. 更新 $f(\phi)$ 18. **return** $f(\phi)$

用成对排序损失进行训练

由于真值构造模块生成的真值之间数值差异很小，无法准确反映学生选题之间的顺序关系，因此传统的损失函数难以很好地解决这一问题。为解决该问题，我们受 Learning to rank 和 learning loss 的启发，设计了一种适合当前问题的损失方法，提出了一种新型的成对排序损失 (pairwise rank loss)，它能很好地以偏序对 (partial sequence pairs) 关系反映所选题目的次序。给定排序后的预测分数序列 $P_i = \{p_{i1}, \dots, p_{iq}\}$ 与计算得到的 RMSE 序列 $\text{RMSE}_i = \{\text{rmse}_{i1}, \dots, \text{rmse}_{iq}\}$ ，我们可以通过下式计算学生 s_i 在 q 道题目上的成对排序损失 L_i ：

$$L_i = \sum_{j=1}^q \sum_{k=1}^{q-1} \max(0, A(\text{rmse}_{ij}, \text{rmse}_{ik}) \cdot (p_{ij} - p_{ik}))$$

$$A(\text{rmse}_{ij}, \text{rmse}_{ik}) = \begin{cases} -a, & \text{if } \text{rmse}_{ij} < \text{rmse}_{ik} \\ +a, & \text{otherwise} \end{cases} \quad (8)$$

其中参数 a 被用作一个惩罚系数，表示位置的权重——位置越靠前， a 的值越大。

借助这一量身定制的损失函数，所提出的选题器可以被很好地训练，其训练过程的更多细节已总结于算法 1。首先，初始化 S 中每位学生的知识能力，并在历史数据上预训练基础认知诊断模型 $\mathcal{M}$ 直到收敛，从模型 $\mathcal{M}$ 中可以提取题目相关参数 (第 1–2 行)。第二，当 $\text{step} = 0$ 时，直接获得初始化的当前知识能力参数；若 $\text{step} > 0$ ，则更新知识能力参数 (第 4–6 行)。之后，我们把学生 s 的记录数据 D_s 划分为训练数据集 D_T^s 和元集 D_V^s (第 8–9 行)。接着，根据拼接特征计算数据集 D_T^s 中题目的预测分数，并在 D_V^s 数据集上用 RMSE 指标验证更新后的 $\hat{\theta}$ (第 10–15 行)。第五，用式 (8) 计算 P_i 与 RMSE_i 的损失，更新选题器参数 $f(\phi)$ 以进入下一轮迭代 (第 16–17 行)。

实验

在实验部分，我们主要聚焦于回答以下问题：

- (RQ1) 与最先进的方法相比，所提出的 DL-CAT 性能如何？
- (RQ2) DL-CAT 在仿真实验中的性能如何？
- (RQ3) 本文设计的成对排序损失函数与传统的列表式 (listwise) 损失方法相比是否更有效？
- (RQ4) 不同的惩罚系数设置在影响上是否有差异？
- (RQ5) DL-CAT 在效率方面有何优势？

实验设置

数据集。为验证所提出的 DL-CAT 在计算机化自适应测试上的有效性，下面的实验使用了两个真实世界的教育数据集，包括一个公开数据集 ASSIST 和一个私有数据集 Math，其统计信息总结于表 2，描述如下：

- **ASSISTments** (ASSISTments 2009–2010 skill builder) 是 ASSISTments 在线辅导服务系统于 2009 年创建的一个公开可用数据集。这里我们采用了不含重复数据的公开修正版。可以看到，该数据集集中有 4 千多名学生、近 1.8 万道题目、超过 30 万条作答日志。
- **Math** 是一个私有数据集，基于教育平台上学生在数学科目上的真实行为记录。该数据集主要包含 1 至 6 年级学生的行为数据，共有 1 万多名学生、100 多万条作答记录。

表 2：数据集统计信息 | 数据集 | Assistment2009 | Math | |—|—|—| 学生数 | 1505 | 6618 | | 题目数 | 932 | 326 | | 概念数 | 22 | 56 | | 作答日志 | 59,500 | 245,155 | | 人均作答日志 | 39.5 | 37 | | 每题作答日志 | 63.8 | 752 | | 每概念题目数 | 44.4 | 5.8 |

数据处理。为使实验结果可靠，对 ASSIST 和 Math，我们首先过滤掉相关题目少于 10 道的知识概念。此外，在 ASSIST 中，我们还过滤掉作答次数少于 50 次的题目，以及作答少于 10 道题的学生。

对比方法 (基准方法)。为公平比较，我们采用了两个能力评估模型 IRT 和 MIRT 作为能力评估模型，描述如下：

- **IRT**：IRT 是最典型的认知诊断模型，它用简单的逻辑斯谛函数整合输入向量，将学生掌握程度表示为一个单维连续向量，以预测学生正确作答题目的概率；
- **MIRT**：作为 IRT 的后继者，MIRT 将 IRT 单维的学生与题目隐特质扩展到多维空间，以增强所学表示，从而满足多维数据的需求。

此外，我们将 DL-CAT 与五种最先进的选题算法进行了比较，其中基于启发式的选题器包括 MFI、MAAT 及其变体 MAAT Cov，基于学习的选题器包括 BOBCAT，以及一个名为 Random 的随机选题器。这些对比算法的更多细节如下：

- **Random**：从题库中随机选题，用于量化其他方法。
- **MFI**：最经典也最广泛使用的选题算法，选取费雪信息量最大的题目，该方法仅适用于 IRT 模型。

- **MAAT**: 基于主动学习的思想, 从模型变化的角度深入研究。计算每道题目所引起的期望模型变化 (EMC), 以衡量题目的信息量, 最终选取 EMC 最大的题目, 该方法独立于认知诊断模型 (CDM)。
- **MAAT Cov**: MAAT 的完整版本, 质量模块 (quality Module) 首先量化题目的信息量并生成质量最高的候选子集, 多样性模块 (diversity Module) 在每一步选取能最大化概念覆盖度的题目, 即考虑了知识概念的覆盖指标来选题;
- **BOBCAT**: 利用双层优化框架直接从训练数据中学习数据驱动的选题算法, 它与底层的学生作答模型无关, 且在自适应测试过程中计算高效。

评价指标。我们用不同的选题器 π 在题库 E 中为学生选取题目 e_j^* , 并用模型 $\mathcal{M}$ 更新学生能力 $\hat{\theta}$ 。最后, 我们在测试集上评估 $\hat{\theta}$ 的准确率 (ACC) 和曲线下面积 (AUC)。ACC (AUC) 值越高, 表示为学生选出的题目越合适。

训练细节。在选题器模块中, 使用一个 3 层 (即 $h = 3$) 的 MLP, 其隐藏层大小设为 8。在真值构造模块中, 训练集按 50% 与 50% 随机划分为支持集 (D_T^s) 和元集 (D_V^s)。训练过程中, 我们采用 Adam 优化器, 学习率为 0.001。为减少计算开销, 我们选取选题器预测的前 40% 的题目来计算 RMSE 值。

实验结果

整体性能 (RQ1) 为验证所提出算法的有效性, 表 3 总结了所提出的 DL-CAT 与对比方法在 ACC 和 AUC 值上的比较结果, 其中选题步数分别设为 5 和 10。由此我们从表中得到三个观察。第一, 当步数从 5 增加到 10 时, 所提出的 DL-CAT 比其他方法有更大的性能提升, 且在 ASSIST 数据集上的性能提升显著。第二, 当采用 IRT 模型进行认知诊断时, 所有方法在 AUC 和 ACC 值上都有更好的表现, 且在 ASSIST 数据集上的性能差距显著。第三, 无论采用哪种认知诊断模型, 所提出的 DL-CAT 在 ASSIST 和 Math 数据集上都展现出比所有对比方法更好的 AUC 和 ACC 值, 其中在 ASSIST 的第 10 步, 所提出的方法相比第二好的算法有超过 0.7% 的提升。

表 3: 所提出的 DL-CAT 与对比方法在 ASSIST 和 Math 数据集上 AUC 与 ACC 值的性能比较 (两种步数设置: 5 与 10)。(此处为原文表 3, 包含 IRT/MIRT $\times$ AUC/ACC $\times$ 步数 5/10 的多组数值, 结构复杂; 关键结论是 DL-CAT 在各设置下均取得最佳值, 例如 ASSIST 上 IRT-AUC 第 10 步 DL-CAT 为 0.6751, 优于第二好的 BOBCAT 0.6690。)

为深入洞察结果, 图 3a 展示了所提出方法与所有对比方法在 ASSIST 数据集上从第 0 步到第 20 步的 AUC 值, 其中我们用真值构造模块获得最小 RMSE 值, 以展示选题算法的上界。我们可以观察到, 由「real」(真值) 表示的曲线始终保持最佳性能, 这表明所提出的 DL-CAT 始终优于其他对比方法。此外, 显然, 除 BOBCAT 外, 所提出方法与其他对比方法之间的 AUC 值差距随步数增加而逐渐增大, 这意味着所提出方法在选题步数较大时更有效。总之, 所提出的真值模块和 DL-CAT 的有效性得到了验证。

图 3: 所有方法随步数增加的 AUC 与 RMSE 值曲线示意图

能力 (θ) 估计的性能 (RQ2) 由于 CAT 的目标是估计学生能力 θ , 除了上述对学生得分预测的评价外, 我们设计了一个仿真实验来衡量「学生真实能力 θ 」与「基于 t 步选题及学生 s_i 相应作答而诊断出的能力 $\hat{\theta}_i^t$ 」之间的差距。具体来说, 我们人工构造学生能力 θ^0 , 并为能力估计生成相应的作答。图 3b 展示了所有方法的 RMSE 曲线, 可由 $\text{RMSE} = |\hat{\theta}_i^T - \theta^0|$ 计算。我们可以观察到, 所提出的 DL-CAT 在学生能力估计上取得了最佳性能, 尤其是步数大于 10 时, DL-CAT 收敛速度更快、最终 RMSE 值更好。

成对排序损失的有效性 (RQ3) 为验证所设计的成对排序损失的有效性, 我们进一步用一些传统损失函数构造了所提出方法的若干变体来比较它们的性能, 其中对比的损失函数包括 ListMLE loss、ListNet loss 和 SetRank。图 4a 展示了所提出方法与三个构造变体方法在 ASSIST 数据集上的 AUC 值, 其中采用了四种步数设置 (即 5、10、15、20) 进行全面比较。显然, 无论步数为多少, 所设计的成对排序损失都使所提出方法保持最佳性能。此外, 成对排序损失在不同步数下相对其他损失函数的性能领先没有显著变化, 这表明所提出的损失更鲁棒, 尤其是相比 ListMLE loss 和 SetRank。因此, 我们可以得出结论: 所提出的成对排序损失设计在提升 DL-CAT 整体性能上是有效的。

图 4: 所提出的成对排序损失的有效性验证, 以及参数 a 的设置

不同惩罚参数 a 的影响 (RQ4) 可以观察到, 式 (8) 中的 a 值作为所设计损失函数中的惩罚项, 可能对选题器的训练产生影响。为研究 a 的不同设置对所提出方法最终性能的影响, 我们考虑了四种不同而经典的 a 设置, 包括 $a = 1$ 、 $a = (q - j)$ 、 $a = k$ 、 $a = (q - j) * k$ 。值得注意的是, $a = 1$ 意味着不考虑位置关系, $a = (q - j)$ 意味着位置越靠前惩罚系数越大, $a = k$ 表示考虑了比较位置, 而 $a = (q - j) * k$ 表示两种情况都考虑。然后, 图 4b 总结了所提出方法在 ASSIST 数据集上用上述四种 a 设置得到的 AUC 值。我们可以观察到, 采用 $a = (q - j) * k$ 的所提出方法比其他设置有更高的 AUC 值, 且相比 $a = 1$ 、 $a = (q - j) * k$ 的性能领先是显著的。因此, 可以证明惩罚系数应充分考虑位置关系。

效率评价 (RQ5) 上述实验已证明了所提出方法以及一些所设计策略的有效性。为进一步展示所提出方法的优越性, 这里我们通过比较训练、测试和新增题目的运行时间, 来比较所提出方法与对比方法的效率。表 4 总结了不同模型在 ASSIST 数据集上训练和测试阶段的时间开销。可以看到, 所提出的 DL-CAT 在测试阶段比 BOBCAT、MAAT 和 MAAT Cov 高效得多。然而, 为验证所提出的 DL-CAT 在训练阶段是解耦

的，我们模拟了一个会向题库 E 新增题目的 CAT 系统场景，向题库 E 新增了 50 道题目。可以看到，所提出的 DL-CAT 在新增题目场景下的训练效率远优于 BOBCAT。

表 4: ASSIST 上的效率实验 | 方法 | 总训练时间 | 测试 (10 步) | 新增题目 | |---|---|---| Random | 0 | 0.246 (s) | 0 | MFI | 16 (s) | 0.289 (s) | 18 (s) | MAAT | 16 (s) | 385 (s) | 18 (s) | MAAT Cov | 16 (s) | 420 (s) | 18 (s) | BOBCAT | 4.5 (h) | 20.4 (s) | 5.8 (h) | DL-CAT | 30 (min) | 2.31 (s) | 18 (s) |

结论与未来工作

本文提出了一种带解耦学习选择器的新型 CAT 框架 (DL-CAT)，它使用神经网络在给定当前估计的学生能力时选取下一道题目。为实现「将选题器与学生能力估计模块的参数学习解耦」这一目标，我们设计了一个真值构造策略，并提出了一个成对损失函数，使选题器能够被独立训练。大量实验表明，DL-CAT 框架在性能和效率上都有显著优势。此外，真值构造策略和成对损失函数的有效性也在实验部分得到了验证。

未来，一方面，我们将进一步尝试受元学习启发设计学生能力初始化策略，以提升 DL-CAT 框架的性能与效率；另一方面，我们希望将所提出的模型应用于其他领域（例如心理评估），并提炼新的问题。

数据可用性。本文使用的 Assistment2009 数据集可从网站 <https://sites.google.com/site/assistentmentsdata/home/2009-2010-assistment-data> 获得。而 Math 数据集是私有数据集，因（法律/商业）限制不能公开分享。

参考文献 (References) 按约定未翻译，详见原文。