

GMOCAT: 一种用于计算机自适应测试的图增强多目标方法 (GMOCAT: A Graph-Enhanced Multi-Objective Method for Computerized Adaptive Testing)

原文: 3580305.3599367.pdf (KDD '23) · 译者: Claude · 译于 2026-06-26 术语对照: 计算机自适应测试 (Computerized Adaptive Testing, CAT); 认知诊断模型 (Cognitive Diagnosis Model, CDM); 项目反应理论 (Item Response Theory, IRT); 多目标强化学习 (Multi-Objective Reinforcement Learning, MORL); 图注意力网络 (Graph Attention Network, GAT); 题目曝光 (question exposure); 概念覆盖 (concept coverage)

摘要

计算机自适应测试 (Computerized Adaptive Testing, CAT) 是一种在线系统, 它能够根据学生的历史作答记录, 为不同能力水平的学生自适应地选择最合适的题目。与基于启发式规则的传统 CAT 方法相比, 近期的数据驱动型 CAT 方法通过从大规模数据集中学习取得了更高的性能。然而, 大多数 CAT 方法只关注“准确预测学生能力”这一**质量 (quality)** 目标, 而忽视了**概念多样性 (concept diversity)** 与**题目曝光控制 (question exposure control)**, 这两点对于保证 CAT 的性能与有效性都很重要。此外, 学生的作答记录中蕴含着题目与知识概念之间宝贵的关系信息 (relational information), 以往方法忽略了这种关系信息, 从而导致选出的测试题目并非最优。

为了解决这些挑战, 我们提出了一种用于 CAT 的图增强多目标方法 (Graph-Enhanced Multi-Objective method for CAT, GMOCAT)。首先, 我们把三个目标——**质量 (quality)**、**多样性 (diversity)** 和**新颖性 (novelty)**——引入到 CAT 的标量化多目标强化学习 (Scalarized Multi-Objective Reinforcement Learning, Scalarized MORL) 框架中, 它们分别对应于提升预测准确率、增加概念多样性、降低题目曝光。我们使用一个 Actor-Critic 推荐器 (Actor-Critic Recommender) 来选择题目, 并通过标量化函数 (scalarization function) 同时优化这三个目标。其次, 我们利用图神经网络 (graph neural network) 学习题目和概念的关系感知嵌入 (relation-aware embeddings), 这些嵌入能够在题目与概念的关系图上聚合邻域信息。我们在三个真实教育数据集上进行了实验。实验结果表明, GMOCAT 不仅在能力预测上超过了当前最先进 (state-of-the-art) 的方法, 而且在提升概念多样性、缓解题目曝光方面也取得了更优的表现。

CCS 概念: 应用计算 → 在线学习 (E-learning)。

关键词: 计算机自适应测试、认知诊断、强化学习、教育测量。

1 引言

随着互联网技术的快速发展, 计算机自适应测试 (CAT) 逐渐把纸笔测验中的重复劳动解放了出来。CAT 是一种在线测试, 它能够通过不断地把最合适的题目推送给学生, 从而准确地测量学生的能力。CAT 已被应用于许多大规模教育考试场景, 例如 GMAT 和 GRE, 以提升学生的参与度。

图 1(a) 展示了一个 CAT 流程的例子。一个 CAT 系统通常由两个迭代协同工作的主要部件组成: (1) **认知诊断模型 (Cognitive Diagnosis Model, CDM)**, 它利用学生对题目的作答来刻画其能力。最简单的 CDM 是项目反应理论 (Item Response Theory, IRT), 它用一个项目反应函数 (item response function) 来逼近学生的真实能力。基于深度学习的 CDM, 例如 NeuralCDM (NCD), 则用神经网络来建模学生与题目之间的交互。(2) **选择算法 (Selection Algorithm)**, 它根据学生的历史作答记录为其选择最合适的题目。传统的静态算法通常用启发式规则来选择“信息量最大”的题目, 或者“期望模型变化最大”的题目。这些算法往往在单步上很贪心, 却缺乏长期视角。近年来, 从大规模数据集中学习选题规则的数据驱动方法也开始涌现。选择算法通过挑选最合适的题目, 帮助 CDM 更高效地评估学生能力。

作为题目选择器, 选择算法在上述 CAT 流程中扮演着关键角色, 因此本文聚焦于设计一种有效的数据驱动选择算法。近年来, 人们从元学习 (meta learning) 或强化学习 (Reinforcement Learning, RL) 的角度提出了数据驱动的选择算法。然而, 这些研究只关注“准确预测学生能力”的质量目标, 这在真实场景中是不够的。我们认为, 单目标方法存在两大局限:

(1) **缺乏概念多样性。**一场好的考试应当在相关但多样的知识概念上评估学生的能力。例如, 每个学期末的数学期末考试通常会涵盖代数、几何等多个概念。遗憾的是, 以往算法由于忽视多样性问题而并非最优, 导致涉及的概念非常有限。

(2) **缺乏新颖性。**CAT 会针对不同的学生反复重用题库中的题目, 导致某些题目被选得过于频繁。测试题目的过度曝光会降低其新颖性, 并改变学生的应试行为。例如, 过度曝光的题目会被很多学生知晓, 从而抬高后续学生的分数。更糟糕的是, Ghosh 和 Lan 发现, 大多数选择算法都偏好一部分题目, 导致曝光率过高, 这在真实的 CAT 系统中是不切实际的。

总之, 质量、多样性和新颖性在 CAT 中都很重要、都值得关注。尽管以往一些研究已经注意到这些问题, 但它们只关注其中的一部分, 没有人从统一的视角来解决这些问题。

为了解决上述不足, 我们提出了一种用于 CAT 的图增强多目标方法 (GMOCAT)。首先, 我们把 CAT 流程形式化为一个多目标马尔可夫决策过程 (Multi-Objective Markov Decision Process, MOMDP), 然后把标量化多目标强化学习 (Scalarized MORL) 框架引入到 CAT 设定中。与 CAT 的贪心方法相比, RL 框架已被证明能从长期视角为学生探索更合适的题目。

在统一框架下, 我们的 GMOCAT 考虑以下三个目标: i) **质量**——准确预测学生能力; ii) **多样性**——使推荐题目所涉及的知识概念多样化; iii) **新颖性**——控制题目曝光。针对这三个目标, 我们设计了三种奖励, 即质量奖励、多样性奖励和新颖性奖励。我们设计了一个 Actor-Critic 推荐器

来选择题目，它通过标量化函数同时优化三个目标。MORL 中一种朴素且被广泛使用的做法是：简单地修改环境，使其返回一个标量化的加权奖励，再用单目标方法来优化策略。与此不同，我们对单目标算法进行了改进，把价值函数和奖励函数都扩展为**向量化 (vectorized)** 的形式。借助这种更细粒度的向量化反馈，Actor-Critic 推荐器不会混淆各个目标，从而取得更好的性能。

为进一步提升 CAT 的有效性，题目与知识概念之间的关系信息可以被利用，因为这种信息与 CAT 中的各个目标密切相关。例如，多样性目标要求选出包含多种知识概念的题目。在我们的工作中，主要考虑两类关系：**相关关系 (correlation)** 和**先修关系 (prerequisite)**，如图 1(b) 所示。相关关系存在于一道题目与其相关概念之间；先修关系涉及一对概念，意味着逻辑上应当先学会其中一个概念才能学另一个（例如，乘法是加法的后继）。这种关系信息对于选择合适的题目至关重要，但在以往工作中被忽视了。因此，我们在框架中利用关系信息进行题目选择。具体来说，我们使用图注意力网络 (graph attention networks) 从多个关系图中提取并聚合邻域信息。

综上，我们的主要贡献如下：

- 我们在 CAT 中考虑三个重要目标：质量、多样性和新颖性，并把它们整合到一个统一的 MORL 框架中。我们还提出了三种奖励来量化三个目标的反馈。据我们所知，这是首个把 MORL 应用于 CAT 的工作。
- 我们把关系图引入 CAT，并学习关系感知嵌入，以帮助选出更合适的题目。这也是首次尝试用关系图来辅助题目选择。
- 我们在三个真实教育数据集上进行了大量实验。实验结果表明，我们的方法比当前最先进的方法获得了更准确的能力估计。同时，我们提出的方法还显著提升了概念多样性、降低了题目曝光。

图 1: (a) CAT 的工作流程：在第 t 步，选择算法根据历史作答记录选出下一道题目 q_t 。(b) 相关图与先修图的玩具示例。

2 相关工作

2.1 计算机自适应测试

计算机自适应测试 (CAT) 有两个主要部件：认知诊断模型 (CDM) 和选择算法。在传统 CAT 系统中，一个被广泛使用的 CDM 是项目反应理论 (IRT)，它通过预测学生对题目的作答来估计学生能力。近期出现的神经认知诊断模型 (Neural Cognitive Diagnosis Model, NCD) 则利用神经网络来建模学生一题目之间的交互。

本文聚焦于选择算法。最广泛使用的算法利用**最大 Fisher 信息 (Maximum Fisher Information, MFI)** 来选题。另一种做法是**Kullback-Leibler 信息 (KLI)**，它在一个能力区间上做积分来挑选题目。这些启发式算法是为特定的 CDM (如 IRT) 设计的。为缓解这一问题，Bi 等人提出了一种与模型无关 (model-agnostic) 的算法 MAAT，它利用主动学习 (active learning) 来选题，并额外设计了一个模块来强化概念多样性。RAT 通过捕获学生能力的多个方面来改进选择算法。在此之后，更多基于深度学习、数据驱动的算法被开发出来。例如，BOBCAT 是一种基于元学习的方法，它把 CDM 与选择算法耦合到一个双层优化 (bilevel optimization) 问题中。NCAT 是一种基于强化学习的方法，它利用基于注意力的 DQN 来选题；NCAT 还通过从玻尔兹曼分布 (Boltzmann distribution) 中采样来控制题目曝光。上述方法只考虑了多样性或新颖性中的一项，没有把这两部分结合起来。据我们所知，鲜有现有工作为 CAT 很好地建立起多目标框架。

2.2 多目标优化

多目标优化 (Multi-Objective Optimization) 旨在同时优化多个目标的同时达到帕累托最优 (Pareto Optimality)。多目标问题可以用多种方法求解，例如遗传算法、演化算法或多目标强化学习算法。在 CAT 领域，Mujtaba 和 Mahapatra 提出用一种多目标演化算法来优化测试长度和准确率，但该方法尚未在真实数据集上得到验证。据我们所知，与我们最相似的方法是自适应学习领域的 DRE，它把三种奖励整合成一种，并使用 DQN 策略。与之相反，我们采用标量化多目标策略梯度方法，以保持各目标之间的相互独立性。

2.3 知识图谱

知识图谱 (Knowledge Graph) 以节点 (实体，例如题目或概念) 和边 (关系，例如先修) 的形式包含大量信息。关系图作为一种知识图谱，已经借助各种图表示学习被用于许多领域。例如，GKT 用图神经网络 (GNN) 结合类图的知识结构来做知识追踪；RCD 用图注意力网络 (GAT) 聚合多层次信息来做认知诊断；CSEAL 为自适应学习设计了一种基于图的认知导航。据我们所知，我们是首个把关系图引入 CAT 设定的工作。

3 预备知识

3.1 术语

定义 3.1 (作答记录, Response Record)。在 CAT 流程中，对于学生 i ，她在测试第 t 步的作答记录记为 (q_t^i, c_t^i, y_t^i) ，其中 q_t^i 表示学生在第 t 步所作答的题目， c_t^i 表示这道题目涵盖的概念， y_t^i 表示学生的作答结果。若作答正确则 y_t^i 为 1，否则为 0。

我们定义两类图来表示题目和概念之间的关系。以图 1(b) 为例，我们定义相关图和先修图：

定义 3.2 (相关图, $\mathcal{G}_{qc}$)：是一个无向二部图，用来表示题目与其相关知识概念之间的关系。 $\mathcal{G}_{qc}$ 的节点集合由题目和概念组成；边集合中的任意一条边连接一道题目与其某个相关概念。

定义 3.3 (先修图, $\mathcal{G}_{cc}$): 是一个有向图, 用来表示概念之间的先修关系。 $\mathcal{G}_{cc}$ 的节点集合由知识概念组成; 边集合中的任意一条边连接一个概念与它的先修概念。

3.2 CAT 流程与问题设定

CAT 由 CDM 和选择算法组成, 前者旨在估计学生能力, 后者旨在选出最合适的题目。数据驱动的选择算法已被证明优于手工设计的算法。因此, 本文聚焦于设计一种有效的数据驱动选择算法。

带有数据驱动选择算法的 CAT 流程包含训练阶段和测试阶段。为了训练/测试选择算法, 一种常规设定是把包含学生 i 测试记录的样本划分为**候选题目集 (Candidate Question Set, $\mathcal{D}_c^i$)** 和**元题目集 (Meta Question Set, $\mathcal{D}_m^i$)**, 如附录 A 所示。下面, 我们以单目标选择算法为例来分析 CAT 流程中的训练/测试阶段:

训练阶段。 对训练集中的每个学生 i : (1) 在测试第 $t \in [1, T]$ 步, 选择算法根据她的历史作答记录从候选题目集 $\mathcal{D}_c^i$ 中选出 q_t^i ; (2) 学生给出作答 y_t^i , CDM 更新当前能力估计 θ_t^i ; (3) 用 θ_t^i 和元题目集 $\mathcal{D}_m^i$ 计算一个反馈 (例如奖励), 用来衡量能力估计的准确程度; (4) 经过上述过程的 T 次迭代后, 我们训练选择算法以最大化该反馈。

测试阶段。 对测试集中的一个新学生 j , 阶段 (1) 和 (2) 与训练阶段相同。阶段 (3) 是在她的元题目集 $\mathcal{D}_m^j$ 上评估 θ_t^j 的准确程度。在测试阶段, 选择算法不被训练。

在 CAT 流程中, 假设学生的真实能力 θ^{i*} 保持不变。从上述阶段可以看出, 单目标方法 (即所谓的质量目标) 的目标是: 通过最大化反馈, 使最终估计 θ_T^i 尽可能接近真实能力 θ^{i*} 。在我们的工作中, 我们不仅考虑上述质量目标, 还考虑多样性和新颖性目标, 从而在多个方面优化和评估 CAT。总体而言, 本文的目标是设计一种选择算法, 使其在每一步选出最合适的题目以实现三个目标。

4 方法

4.1 形式化与总览

如引言所述, CAT 流程是一个复杂且相互依赖的系统。我们把 CAT 任务建模为一个序贯决策问题, 并将其形式化为一个多目标马尔可夫决策过程 (MOMDP)。RL 框架可以从长期视角探索更合适的题目, 而非贪心式的近似。这个 MOMDP 可以由元组 $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$ 定义, 其中:

- $\mathcal{S}$: 表示选择算法用来选题的状态集合。给定测试第 t 步, 状态可以定义为 $s_t^i = f_{se}(\{(q_1^i, c_1^i, y_1^i), \dots, (q_{t-1}^i, c_{t-1}^i, y_{t-1}^i)\}) \in \mathcal{S}$, 其中 f_{se} 是一个状态编码器 (state encoder), 将在 4.3 节讨论。状态编码器以学生 i 的历史作答记录为输入, 输出状态 s_t^i 。
- $\mathcal{A}$: 是一个有限的动作集合。在给定的第 t 步, 从动作空间 (即候选题目集) 中选取一个动作, 由选择算法 π 选出题目 q_t^i 。
- $\mathcal{P}$: 表示在状态 s_t^i 上选择题目 q_t^i 后到达下一状态 s_{t+1}^i 的转移概率, 即 $\mathcal{P}(s_{t+1}^i | s_t^i, q_t^i)$ 。
- $\mathcal{R}$: $\mathcal{S} \times \mathcal{A} \mapsto \mathbb{R}^m$, 表示选择算法在状态 s_t^i 上选择 q_t^i 的即时奖励函数。与以往工作不同, 我们的奖励是向量值的。在我们的设定中, $r(s_t^i, q_t^i) = [r_{qua}, r_{div}, r_{nov}]$, 分别对应质量、多样性和新颖性奖励。这一奖励将在 4.2 节解释。
- $\gamma \in [0, 1]$: 是折扣因子, 用于权衡即时奖励和未来奖励。

至此, 我们已从 MORL 的视角重构了 CAT 流程。

CAT 流程的 MORL 形式化: 令 n 表示学生数量。对于学生 i , 在测试第 t 步, 选择算法 π 根据状态 s_t^i 从她的候选题目集中选出题目 q_t^i , 即 $\pi(q_t^i | s_t^i)$ 。然后, 它把 q_t^i 推送给学生 i , 并收到多目标奖励 $r(s_t^i, q_t^i)$ 。最终, 我们的多目标目标是最大化加权和回报 J :

$$\max_{\pi} J = \max_{\pi} \frac{1}{n} \sum_{i=1}^n \left[w^T \left(\sum_{t'=1}^T \gamma^{t'} r(s_{t'}^i, q_{t'}^i) \right) \right] \quad (1)$$

$$= \max_{\pi} \mathbb{E}_{i \sim \pi} \left[w^T \left(\sum_{t'=1}^T \gamma^{t'} r(s_{t'}^i, q_{t'}^i) \right) \right] \quad (2)$$

其中 w 是标量化函数, 可以看作一个权重向量, 其每个元素代表对应目标的重要程度。

在这一目标下, 我们的 GMOCAT 由四个部件组成: 多目标奖励、关系聚合器 (relation aggregator)、自注意力状态编码器 (self-attentive state encoder) 和 Actor-Critic 推荐器。如图 2 所示, 关系聚合器利用关系图来学习题目和概念的关系感知嵌入; 随后, 状态编码器利用这些嵌入对学生的历史作答记录进行编码, 生成 GMOCAT 的状态; 接着, 这个状态被送入 Actor-Critic 推荐器, 在多目标奖励的指导下选择题目。

为充分说明 GMOCAT 的细节, 我们将先介绍多目标奖励、自注意力状态编码器和 Actor-Critic 推荐器; 最后, 我们讨论如何用关系聚合器来学习关系感知嵌入。请注意, 在以下各节中, 由于我们讨论的是为单个学生选题, 因此省略上标 i 。

图 2: GMOCAT 的整体框架。关系聚合器学习题目和概念的关系感知嵌入; 状态编码器把历史作答记录转换为一个低维状态; Actor-Critic 推荐器选出下一道题目, 然后收到多目标奖励。

4.2 多目标奖励

本部分讨论如何设计多目标奖励，它在学习最优选择算法中扮演着重要角色。如前所述，以往工作只关注质量目标，但这种单目标方法在实践中无法满足 CAT 的需求。本文将三个领域特定的目标——质量、多样性和新颖性——纳入奖励设计，以支持自适应的题目选择。

4.2.1 质量 一个优秀的选择算法应当选出最合适的题目来准确预测学生的能力。对任意一名学生，由于其真实能力未知，我们可以用她的元题目集来衡量能力估计 θ_t 的误差。具体而言，在测试第 t 步，我们用 θ_t 计算在她元题目集上的预测准确率，记为 $ACC(\theta_t)$ 。 $ACC(\theta_t)$ 越高，说明能力估计 θ_t 越准确、越接近真实能力。

直觉上，如果选择算法选出的题目有助于提升能力估计的准确率，就应给予正向激励；相反，如果选出的题目降低了这一准确率，就应给予惩罚。形式化地，我们把质量奖励设计为：

$$r_{qua} = ACC(\theta_t) - ACC(\theta_{t-1}) \quad (3)$$

元题目集用于计算质量奖励，不会被选给学生。

4.2.2 多样性 在大型综合考试中，测试题目应包含丰富的知识概念。多样性目标要求覆盖多种知识概念。这意味着，如果选择算法选出一道包含新概念的题目，就应给予正向激励。这里为简单起见，我们对奖励值进行离散化。形式化地，如果选出的题目涉及一个新概念，则多样性奖励为 1，否则为 0：

$$r_{div} = \begin{cases} 1, & \text{if } c_t \setminus \{c_1 \cup c_2 \dots \cup c_{t-1}\} \neq \emptyset \\ 0, & \text{otherwise} \end{cases} \quad (4)$$

其中 c_t 是第 t 步题目 q_t 涵盖的概念。这种二值奖励设定在 RL 中很常见。

4.2.3 新颖性 如前所述，一个恰当的选择算法应当把新颖性考虑在内，因为缺乏新颖性会导致题目过度曝光，并可能影响学生的应试行为。例如，学生可以把过度曝光题目的答案告诉后来的同学。

因此，我们设计新颖性奖励来控制题目曝光。令 $\mathcal{T}$ 表示训练集中最热门（最常被选）的前 $x\%$ 题目的集合。我们鼓励选择不太热门的题目，因为这些题目在未来更可能是新颖的，并能带来更均衡的题目曝光分布。沿着这一思路，如果选出的题目 q_t 不在 $\mathcal{T}$ 中，则新颖性奖励为 1，否则为 0：

$$r_{nov} = \begin{cases} 1, & \text{if } q_t \notin \mathcal{T} \\ 0, & \text{otherwise} \end{cases} \quad (5)$$

请注意，在确定训练集之后， $\mathcal{T}$ 即被计算并固定，在整个 CAT 流程中不会改变。本文按照 Stamenkovic 等人的做法，设 $x = 10$ 。

至此，我们已定义了向量值奖励 $r(s_t, q_t) = [r_{qua}, r_{div}, r_{nov}]$ ，分别对应质量、多样性和新颖性奖励。从公式 2 的优化函数可知，奖励向量被标量化函数 w 加权。 w 的每个元素可看作对应目标的重要程度，我们将在 5.7 节讨论其作用。

4.3 状态编码器

一般来说，状态编码器以历史作答记录为输入，生成 GMOCAT 的状态： $s_t = f_{se}(\{(q_1, c_1, y_1), \dots, (q_{t-1}, c_{t-1}, y_{t-1})\})$ 。下面我们详细说明状态编码器 f_{se} 是如何实现的。

假设题目数量为 Q ，我们用嵌入矩阵 $W_q \in \mathbb{R}^{Q \times d}$ 把每道题目 q 映射为实值嵌入 $E_q \in \mathbb{R}^d$ ： $E_q = x_q W_q$ ，其中 x_q 是 q 的独热 (one-hot) 向量， d 是嵌入维度。 E_q 刻画了题目的信息。我们用相同的操作得到概念 c 的概念嵌入 $E_c \in \mathbb{R}^d$ 和作答 y 的作答嵌入 $E_y \in \mathbb{R}^d$ 。

关系聚合器用于提取关系信息并学习关系感知嵌入。借助图神经网络，聚合器以原始题目嵌入 E_q 和原始概念嵌入 E_c 为输入，输出对应的关系感知嵌入 $\tilde{E}_q$ 和 $\tilde{E}_c$ (详见 4.5 节)。当然，我们也可以像以往工作那样直接使用题目和概念的原始嵌入，但我们发现在大多数数据集上关系感知表示的效果更好。关系感知表示的性能将在 5.6 节进一步讨论。

给定第 t 步，状态编码器用关系感知题目嵌入 $\{\tilde{E}_q^{1:t-1}\}$ 来表示历史题目序列 $\{q_{1:t-1}\}$ ，用关系感知概念嵌入 $\{\tilde{E}_c^{1:t-1}\}$ 来表示历史概念序列 $\{c_{1:t-1}\}$ ；历史作答序列 $\{y_{1:t-1}\}$ 则用原始作答嵌入 $\{E_y^{1:t-1}\}$ 来表示。

注意，状态编码器的输入 $\{(q_{t'}, c_{t'}, y_{t'}) | t' \in [1, t-1]\}$ 是此前所有步的作答记录。因此，对每个之前的步 $t' \in [1, t-1]$ ，三元组 $(q_{t'}, c_{t'}, y_{t'})$ 可以用 $e_{t'}$ 表示，即关系感知题目嵌入 $\tilde{E}_q^{t'}$ 、关系感知概念嵌入 $\tilde{E}_c^{t'}$ 和作答嵌入 $E_y^{t'}$ 的拼接。 $e_{t'} \in \mathbb{R}^D$ 的表达式为：

$$e_{t'} = \tilde{E}_q^{t'} \oplus \tilde{E}_c^{t'} \oplus E_y^{t'} \quad (6)$$

其中 $D = 3d$ 。如果一道题目包含多个概念，我们取其相关概念的关系感知嵌入的均值作为 $\tilde{E}_c^{t'}$ 。

于是历史作答记录 $\{(q_{t'}, c_{t'}, y_{t'}) | t' \in [1, t-1]\}$ 可以用一个嵌入矩阵 $E_t = [e_1, e_2, \dots, e_{t-1}]^T \in \mathbb{R}^{(t-1) \times D}$ 来表示。我们注意到，不同的作答记录包含的信息量不同。例如，答对一道难题比答对一道简单题包含更多信息。为了捕捉作答记录之间的差异，我们在 E_t 上应用自注意力机制 (self-attention mechanism)，定义为缩放点积函数 (scaled dot-product function)：

$$\tilde{E}_t = \text{Softmax} \left(\frac{(E_t W^Q)(E_t W^K)^T}{\sqrt{d_k}} \right) (E_t W^V) \quad (7)$$

其中 $W^Q, W^K, W^V \in \mathbb{R}^{D \times D}$ 是可训练矩阵， $\sqrt{d_k}$ 是缩放因子。我们在自注意力机制之后加入层归一化 (LayerNorm) 和跳跃连接 (skip-connection)，并使用 Dropout 来避免过拟合。

注意到学生的真实能力在 CAT 流程中保持不变，因此每条记录的顺序并不重要。我们把 $\tilde{E}_t$ (自注意力之后的嵌入) 输入到平均池化 (average-pooling) 中，生成状态 $s_t \in \mathbb{R}^D$ 。Actor-Critic 推荐器利用这个状态来选择下一道题目。

4.4 Actor-Critic 推荐器

Actor-Critic 推荐器以状态 s_t 为输入。我们用一个策略网络作为 **actor**，通过从分布 $\pi(q_t | s_t; \phi_\pi)$ 中采样来生成动作。actor 是一个带参数 ϕ_π 的全连接层。此外，我们用一个价值网络作为 **critic** 来评估状态。给定状态 s_t ，critic 的输出 $V(s_t)$ 是一个向量，用来预测期望回报，其每个元素对应一个目标，定义为 $V(s_t; \phi_v) = [V(s_t)_{qua}, V(s_t)_{div}, V(s_t)_{nov}]$ 。下标 $\{qua, div, nov\}$ 分别表示质量、多样性和新颖性目标。critic 同样是一个带参数 ϕ_v 的全连接层。

为最大化公式 2 中的加权和回报 J ，我们把 PPO (Proximal Policy Optimization) 方法改造成多目标形式。具体而言，选择 q_t 的优势值 (advantage value) 定义为某个状态一动作对的实际回报减去该状态的期望回报：

$$A(s_t, q_t) = \sum_{t'=t} \gamma^{t'-t} r(s_{t'}, q_{t'}) - V(s_t) \quad (8)$$

我们用标量化函数 f_w 把向量化的优势 A 转换为标量。如前所述，我们选择线性函数 $f_w = w$ ，其中重要性权重 w_i 对应于单个目标。我们应用裁剪的代理损失 (clipped surrogate loss) 来更新 actor 参数：

$$L_1 = -\mathbb{E}_{\tau \sim \pi_{old}} \left[\text{Min} \left\{ \frac{\pi(q_t | s_t)}{\pi_{old}(q_t | s_t)} w^T A(s_t, q_t), \text{Clip} \left(\frac{\pi(q_t | s_t)}{\pi_{old}(q_t | s_t)}, 1 - \epsilon, 1 + \epsilon \right) w^T A(s_t, q_t) \right\} \right] \quad (9)$$

critic 损失基于“期望回报尽可能接近实际回报”这一目的：

$$L_2 = \frac{1}{2} w^T \left\| V(s_t) - \sum_{t'=t} \gamma^{t'-t} r(s_{t'}, q_{t'}) \right\|^2 \quad (10)$$

最后，多目标 PPO (Multi-Objective PPO, MOPPO) 损失是两个损失的加权和，权衡超参数为 $\alpha \in \mathbb{R}^+$ ：

$$L = L_1 + \alpha L_2 \quad (11)$$

4.5 关系聚合器

如前所述，题目和概念中所包含的关系信息与我们的三个目标密切相关，但被现有 CAT 方法所忽视。我们用关系聚合器来聚合关系信息。本部分从概念和题目两个角度描述关系信息的聚合。

4.5.1 概念关系 由于概念同时出现在先修图和相关图中，因此概念嵌入受到两种关系的影响。我们应用图注意力网络（GAT）来聚合这两个图中的邻居嵌入。对每个原始嵌入为 E_c 的概念 c ，令 N_c^{pre} 、 N_c^{cor} 分别为它在先修图和相关图中的邻域。我们用注意力权重聚合邻居嵌入，得到先修感知嵌入（prerequisite-aware embedding） g_{pre} 和相关感知嵌入（correlation-aware embedding） g_{cor} ：

$$g_{pre} = \sum_{c' \in N_c^{pre}} \alpha_{c,c'} W_{pre} E_{c'}, \quad g_{cor} = \sum_{q' \in N_c^{cor}} \beta_{c,q'} W_{cor} E_{q'} \quad (12)$$

直觉上，注意力权重（ $\alpha_{c,c'}$ 或 $\beta_{c,q'}$ ）与邻居嵌入和概念 c 嵌入之间的相似度相关，定义为：

$$\alpha_{c,c'} = \text{Softmax}_{c'} \left(\text{att}_{pre} ([W_{pre} E_c, W_{pre} E_{c'}]) \right), \quad c' \in N_c^{pre} \quad (13)$$

$$\beta_{c,q'} = \text{Softmax}_{q'} \left(\text{att}_{cor} ([W_{cor} E_c, W_{cor} E_{q'}]) \right), \quad q' \in N_c^{cor} \quad (14)$$

其中 $\text{att}_\bullet$ 表示一个带 LeakyReLU 激活函数的线性层， $[\cdot]$ 是拼接操作， W_{pre}, W_{cor} 是可训练矩阵。

先修感知嵌入和相关感知嵌入包含不同的关系信息。为了区分它们各自不同的重要程度，我们采用如下处理。先修感知嵌入的权重 μ_{pre} 与注意力向量 P 和先修感知嵌入之间的相似度相关，定义为：

$$\mu_{pre} = P^T \cdot \tanh(W \cdot g_{pre} + b) \quad (15)$$

权重 μ_{cor} 可以类似地建模。这两个权重通过一个 softmax 操作进行归一化。最后，概念 c 的关系感知嵌入（记为 $\tilde{E}_c$ ）是先修感知嵌入和相关感知嵌入的加权和：

$$\tilde{E}_c = \mu_{pre} g_{pre} + \mu_{cor} g_{cor} \quad (16)$$

4.5.2 题目关系 与概念类似，我们再次通过 GAT 进行题目的邻居聚合。对每个原始嵌入为 E_q 的题目 q ，令 N_q^{cor} 为它在相关图中的邻居集合。由于题目只包含相关关系，所以题目的关系感知嵌入 $\tilde{E}_q$ 就是相关感知嵌入 h_{cor} 。题目 q 的关系感知嵌入 $\tilde{E}_q$ 给定为：

$$h_{cor} = \sum_{c' \in N_q^{cor}} \xi_{q,c'} W_{cor} E_{c'}, \quad \tilde{E}_q = h_{cor} \quad (17)$$

权重 $\xi_{q,c'}$ 可以用类似公式 14 的形式来建模。

5 实验

本节我们在三个真实教育数据集上进行了大量实验，以评估所提出的 GMOCAT 方法的有效性。

5.1 数据划分与实验流程

我们在三个真实教育数据集上评估 GMOCAT 方法：Eedi、ASSIST 和 Junyi。Eedi 来自教育平台 Eedi 在 2018—2020 年间的作答日志。ASSIST 来自 ASSISTments 在线辅导平台。Junyi 采集自在线学习网站 Junyi Academy 在 2018—2019 年间的练习日志。

对所有数据集，我们移除测试记录少于 40 条的学生。处理后数据集的统计信息列于表 1。我们按 80%-10%-10% 的比例划分学生用于训练、验证和测试。训练集中的学生不会出现在验证/测试集中。训练集用于获取校准后的题目参数、用于新颖性奖励的最热门题目，以及优化选择算法。此外，我们把包含学生 i 测试记录的样本划分为候选题目集（ $\mathcal{D}_c^i$, 80%）和元题目集（ $\mathcal{D}_m^i$, 20%）。这两个集合对每个学生都不同，并且在每个训练轮次中随机生成，以防止过拟合。

实验结果对五次运行取平均。我们所有的实验结果都在测试集上取得。对测试集中的每个学生 j ：(1) 我们用选择算法从 $\mathcal{D}_c^j$ 中选出一道题目；(2) CDM 用相应的作答更新能力估计；(3) 我们用不同的指标评估选择算法并报告其数值。

表 1：数据集统计信息

数据集	Eedi	ASSIST	Junyi
学生数	4,918	1,360	20,395
题目数	948	17,751	2,835
概念数	86	123	40
记录数	1,382,727	239,919	2,537,898
先修边数	334	1,166	306
每题概念数	4.0	1.2	1.0
正标签率	0.55	0.62	0.69

5.2 评估方法

5.2.1 质量指标 我们通过预测学生 i 在其元题目集 $\mathcal{D}_m^i$ 上的二值作答，来评估其最终能力估计的准确程度。因此，我们采用 ROC 曲线下面积 (Area Under ROC Curve, AUC) 和准确率 (Accuracy, ACC) 作为质量指标，以衡量不同的选择算法。

5.2.2 多样性指标 我们用概念覆盖率 (concept coverage, Cov) 来衡量多样性。具体而言，令 K 为概念集合， $\mathcal{K}_t$ 为第 t 步之前所有已选题目所覆盖的概念集合。 Cov 定义为所有已选题目所覆盖概念的比例：

$$Cov = \frac{1}{|K|} \sum_{k \in K} \mathbb{1}(k \in \mathcal{K}_t) \quad (18)$$

5.2.3 新颖性指标 我们用题目曝光率 (question exposure rate, 一道题目被选中次数的比例) 和平均重叠率 (mean overlap rate, 学生集合中任意两名学生所选题目之间的平均重叠) 来衡量新颖性：

$$\text{Exposure}_q = \frac{N_q}{|\mathcal{U}|} \quad (19)$$

$$\text{Overlap} = \frac{\sum_i \sum_{j \in \mathcal{U}, j \neq i} |Q_i \cap Q_j|}{|\mathcal{U}| * (|\mathcal{U}| - 1) / 2} \quad (20)$$

其中 N_q 是题目 q 被选中的次数， $\mathcal{U}$ 是学生集合， Q_i 是学生 i 测试过的题目集合。

5.3 基线方法

我们在两种 CDM 上应用我们的方法：传统的项目反应理论 (IRT) 和近期基于深度学习的模型 NeuralCDM (NCD)，并与两组选择算法进行比较。我们使用以下最先进的选择算法作为基线：

静态方法 (基于启发式、不可学习的规则)。

- **Random**: 随机选择算法。
- **MFI**: 选择具有最大 Fisher 信息的题目。仅为 IRT 设计。
- **KLI**: 选择具有最大 Kullback-Leibler 信息移动平均的题目。仅为 IRT 设计。
- **MAAT**: 一种基于主动学习的方法，利用 CDM 的期望模型变化 (Expected Model Change, EMC) 来选题。它还设计了一个额外的模块来增强概念多样性。

可学习方法 (数据驱动，可从大规模数据集中学习)。

- **BOBCAT**: 一种基于元学习的方法，把 CAT 重构为一个双层优化问题。
- **NCAT**: 一种基于强化学习的方法，设计了一个基于注意力的 DQN。它通过从 Q 值的玻尔兹曼分布中采样来选题，以控制题目曝光。

5.4 实现细节

对于所有实验结果，除 5.7 节外，我们始终保持标量化函数 $w = [1, 1, 1]$ 。我们模型的实现已公开。我们按照以往工作设置最大测试长度 $T = 20$ 。在公式 8 中设 $\gamma = 0.5$ ，在公式 9 中设 $\epsilon = 0.2$ 。批量大小为 128，嵌入维度 $d = 128$ 。自注意力机制中的 dropout 率为 0.1。优化器为 Adam，学习率为 0.001。损失权衡参数 $\alpha = 1.0$ 。所有基线的参数均遵循其原始论文的设置，以确保其最佳性能。在三个数据集中，只有 Junyi 提供了知识概念之间的先修关系。因此，我们使用 Gao 等人的实现为另外两个数据集构建先修图，详见附录 B。

5.5 性能比较

这里我们分析 GMOCAT 在不同指标上的性能。标量化函数 w 固定为 $[1, 1, 1]$ 。

5.5.1 质量比较 表 2 报告了不同方法在测试步 $t = 5, 10, 20$ 时的 AUC 和 ACC 指标。从中我们观察到：

- (1) 我们的方法在三个公开数据集的两种不同 CDM 上都超过了所有基线。在 Eedi 上, GMOCAT 相比最佳基线取得了最高 2% 的 AUC 提升 (例如 NCD 上的第 5 步)。在 ASSIST 上, GMOCAT 相比最佳基线取得了最高 1% 的 ACC 提升 (例如 IRT 上的第 10 步)。在 Junyi 上, GMOCAT 比最佳基线高出 1% 的 AUC (例如 IRT 上的第 20 步)。这些结果表明, 关系信息和多目标策略可以提升能力估计的准确率。
- (2) NCAT 同样作为基于 RL 的方法, 在大多数数据集上排名第二, 这也证明了 RL 框架的有效性。例如, 在测试开始时 (第 5 步), MAAT 并不弱, 但在测试末尾 (第 20 步), 其 AUC/ACC 总是被基于 RL 的方法击败。这是因为 MAAT 基于贪心而非长期视角来选题。

表 2: 三个公开数据集上的 AUC 和 ACC 性能 (结构复杂, 此处仅说明: 最优值加粗, 次优值加下划线, “-”表示该方法无法应用于 NCD, “”表示通过 t 检验衡量、 p 值 < 0.05 的统计显著提升。完整数值见原文表 2。GMOCAT 在所有列上均取得带 “” 的最优结果)。

5.5.2 多样性比较 我们在图 3 中展示了整个 CAT 流程中的 Cov 曲线。GMOCAT 在所有数据集、两种 CDM 上都大幅领先, 因为它在 MORL 框架中有一个显式的多样性目标, 并有一个关系感知的选择算法, 而其他方法都没有。与其他基线相比, GMOCAT 的 Cov 曲线增长最快。在大多数情况下, 第二快的方法是 MAAT, 因为它也有一个内在的多样性目标, 但其贪心策略导致性能下降。

5.5.3 新颖性比较 表 3 列出了在 Junyi 数据集上第 20 步的曝光率 (Exp.) 和平均重叠率 (Over.), 其中 Exp.(>0.2) 表示曝光率 > 0.2 的题目所占比例。我们发现：

- (1) 尽管 Random 方法的曝光率最低, 但这并不意味着它是最好的方法。因为随机选出的题目完全没有个性化, 这违背了 CAT 的初衷。我们在此列出 Random 方法, 主要是为了说明曝光率的实际下界。
- (2) 在除 Random 之外的所有方法中, GMOCAT 取得了最小的曝光率和重叠率, 这证明了新颖性奖励的有效性。NCAT 也获得了较低的题目曝光, 因为它从玻尔兹曼分布中采样动作。相比之下, 我们的方法通过直接把曝光作为优化目标, 取得了更低的题目曝光。

从上述三个方面可以看出, 使用 GMOCAT 方法, 我们不仅能在准确率、多样性和新颖性之间取得平衡, 还能显著提升所有定量指标。强化多样性和新颖性目标在 Cov 和曝光率指标上带来了显著提升。

表 3: 在 Junyi 数据集上第 20 步的曝光率 (Exp.) 和平均重叠率 (Over.)

		IRT Exp.%(>0.2)	IRT Over.%	NCD Exp.%(>0.2)	NCD Over.%
静态	Random ^a	0.04	4.6	0.04	4.6
	MFI	0.18	6.62	-	-
	KLI	0.21	6.73	-	-
	MAAT	0.63	17.66	0.67	15.22
可学习	BOBCAT	0.74	17.36	0.88	17.64
	NCAT	0.21	7.62	0.14	7.03
	GMOCAT	0.11*	5.13*	0.07*	4.86*

^a 此处列出 Random 方法只是为了说明曝光率的实际下界。

5.6 消融研究

我们进行消融研究, 以进一步考察 GMOCAT 中各模块的贡献。我们在 Junyi 数据集、IRT 上测试第 20 步的所有指标。我们仍设标量化函数 $w = [1, 1, 1]$ 。设定讨论如下：

- **GMOCAT-R**: 移除关系感知嵌入。即忽略关系图, 把关系感知嵌入 $\tilde{E}_q, \tilde{E}_c$ 替换为原始嵌入 E_q, E_c 。
- **GMOCAT-S**: 移除标量化函数。即奖励从向量变为标量, 由三种奖励加权而成; 相应地, critic 的输出也变成标量。

结果如表 4 所示。我们可以观察到, 无论移除哪个模块, GMOCAT 的性能都会下降。这意味着两个模块都对 GMOCAT 的性能有所贡献。我们分析认为: (1) GMOCAT-R 丢失了题目与知识概念之间至关重要的关系信息, 从而显著降低了性能。这让我们可以稳妥地得出结论: 为了选出更合适的题目, 捕获关系信息是明智之举。(2) 移除标量化函数后, GMOCAT-S 的性能下降也证明了把单目标方法转换为带向量量化奖励的多目标方法的必要性。

表 4: 消融研究结果 (Junyi 数据集、IRT、第 20 步)

指标	AUC@20	Cov@20	Overlap@20
GMOCAT	0.8024*	0.8185*	0.0513*
GMOCAT-R	0.7999	0.7380	0.0599
GMOCAT-S	0.7983	0.7310	0.0586

5.7 目标比较

为了考察不同目标的作用，本部分探讨当 GMOCAT 聚焦于三个目标的不同子集时的差异。在我们的设定中， w 的第一、第二、第三项分别对应质量、多样性和新颖性目标。我们用以下 w 的配置进行实验：

$$w \in \{[1, 1, 1], [1, 0, 0], [0, 1, 0], [0, 0, 1], [1, 1, 0], [1, 0, 1], [0, 1, 1]\}$$

这里我们主要考虑每个目标存在/缺失的影响，因此 w 的取值要么为 1（存在），要么为 0（缺失）。

图 4 展示了在 Eedi+IRT 设定、测试第 20 步、不同 w 配置下 GMOCAT 的性能比较。从结果中我们发现一些有趣的现象：

- (1) 仅聚焦于单个目标会导致其他指标性能下降。例如， $[1, 0, 0]$ 得到较低的覆盖率（Cov）； $[0, 1, 0]$ 和 $[0, 0, 1]$ 得到较低的 AUC/ACC。这证明了同时利用多个目标的重要性和必要性。
- (2) 从图 4(a) 和 4(b) 可以发现，加入多样性目标会提升 AUC/ACC 的值（例如 $[1, 1, 0]$ 在 AUC/ACC 上优于 $[1, 0, 0]$ ）。这一现象与我们的直觉一致，因为学生的能力是多方面的。如果测试题目包含多样的知识概念，我们就能更准确地预测学生的能力。
- (3) 从图 4(a) 和 4(b) 我们还发现，加入新颖性目标会略微损害质量性能（例如 $[1, 1, 0]$ 在 AUC/ACC 上优于 $[1, 1, 1]$ ）。这一现象暗示了质量目标与新颖性目标之间存在潜在冲突。新颖性目标试图实现测试题目的均衡分布，这导致低质量的题目被更频繁地选中，从而妨碍我们准确预测学生的能力。

从上述观察可以得出结论：三个目标之间既有促进也有矛盾。GMOCAT 提供了一种灵活的方式，以适应不同的实际需求来调整 CAT。例如，如果我们想更关注测试题目的曝光率，可以在保证质量性能不至于下降太多的前提下，提升新颖性目标的重要程度。我们把定量分析多目标之间的权衡、并自动化地平衡它们以满足各种实际应用，留作未来工作。

图 3：用 Cov 指标进行的多样性比较。图 4：GMOCAT 在不同 w 配置（使其聚焦于目标的某个子集）下的性能比较，结果为 Eedi 数据集、IRT、第 20 步。 w 的第一、第二、第三项分别对应质量、多样性和新颖性目标的重要程度。

6 结论

在这项工作中，我们提出了 GMOCAT，一种用于 CAT 的图增强多目标方法，它为学习选择算法提供了一种多目标途径。我们强调了 CAT 中的三个目标——质量、多样性和新颖性，并应用标量化多目标 RL 从长期视角优化这些目标。此外，我们的方法通过构建题目和概念的关系感知表示来总结其关系信息，从而改进了现有的 CAT 方法。大量实验证明，我们的方法在三个教育数据集上超过了最先进的方法，显著提升了能力估计的准确率、使测试题目多样化，并缓解了题目曝光。

致谢

（致谢内容从略，详见原文。）

附录

A 单目标选择算法的流程

图 5：单目标选择算法的训练/测试流程。

B 先修图构建

在三个数据集中，只有 Junyi 提供了知识概念之间的先修关系。因此，我们需要为另外两个数据集构建先修图。这里我们采用 Gao 等人的实现。首先，我们计算正确矩阵（correct matrix） C ，其中 C_{ij} 当 $i \neq j$ 时为 $\frac{n_{ij}}{\sum_k n_{ik}}$ ，否则为 0。 n_{ij} 表示“在概念 i 被答对之后，紧接着概念 j 也被答对”的次数。接下来，我们计算转移矩阵（transition matrix） T ，其中当 $\frac{C_{ij} - \min(C)}{\max(C) - \min(C)} > threshold$ 时 $T_{i,j} = 1$ ，表示概念 i 有一条指向 j 的边。如果 $T_{ij} = 1$ 但 $T_{ji} \neq 1$ ，则概念 i 和 j 之间的关系是先修关系，即 i 是 j 的先修概念。我们把 $threshold$ 设为矩阵 T 的平均值。

参考文献 (*References*) 按约定未翻译, 详见原文。