

《一种用于教育题目检索的鲁棒 CAT 方法》(RAT) 精读笔记

原文: 3477495.3531928.pdf (Zhuang et al., SIGIR '22) · 代码: 未发现 RAT 方法本身的开源仓库 (作者仅给出配套的数
据集工具包 [EduData](#) 与认知诊断工具包 [EduCDM](#), RAT 算法本身未单独开源) · 笔记于 2026-06-26

这篇论文出自中科大 USTC 大数据组 (陈恩红、刘淇团队), 是 CAT 方向里一篇思路很「轻」但理论很「重」的工作。核心一句话能讲完: 别再纠结于设计更复杂的选题算法, 而是把喂给选题算法的那个「能力估计 $\hat{\theta}$ 」做得更鲁棒——做法是每一步同时估计出 m 个彼此有差异的能力值, 再取平均当作查询。下面按规范展开。

一、解决什么问题

先回顾 CAT (计算机自适应测验) 每一步在干嘛。它是一个「估计 → 选题」交替循环:

1. **CDM (认知诊断模型)**: 用学生已答的 t 道题, 估出他当前能力 $\hat{\theta}_t$ 。
2. **选题算法**: 拿 $\hat{\theta}_t$ 当查询, 从题库里挑一道「最有信息量」的题给学生答 (比如 FSI 会挑难度最贴近 $\hat{\theta}_t$ 的题)。

痛点在于: 选题算法的唯一输入就是 $\hat{\theta}_t$ 。如果这个 $\hat{\theta}_t$ 估歪了 (离真实能力 θ_0 远), 那后面挑的题全是错的方向, 整条链路就废了。而 $\hat{\theta}_t$ 估歪几乎是必然的——初期作答太少、学生蒙对 (guess)、粗心答错 (slip)、优化过拟合, 都会让 $\|\hat{\theta}_t - \theta_0\|$ 偏大。

已有方案的不足: - 一类 (KLI、贝叶斯准则、权重准则) 还是围着「单个 $\hat{\theta}_t$ 」打转, 引入点额外信息, 治标不治本。- 另一类 (BOBCAT 等强化学习/元学习方法) 干脆推翻范式, 用神经网络直接学选题策略。但缺点是: 题库一加新题就得整个重训, 真实教育系统每天上传海量新题, 根本扛不住; 还会继承历史数据的偏差。

这篇的切入点 (很巧): 作者发现一个被忽视的事实——学生是「多面的 (multi-facet)」。同一份作答记录, 本就对应多个合理的能力值, 而不是一个。- 例 1: 答对难度 0.3 的题、答错难度 0.8 的题 → 能力可能在 $[0.3, 0.8]$ 这一整段区间里, 而非某个点。- 例 2: 一道题有多种解法 (代数解 / 几何解 / 蒙的)。答对它, 可能说明代数强、也可能几何强、也可能纯蒙 → 对应好几个不同的 $\hat{\theta}$ 。

所以与其赌一个 $\hat{\theta}_t$, 不如生成一组 $\{\hat{\theta}_1, \dots, \hat{\theta}_m\}$ 再融合 (取平均)。难点是这组估计要同时满足: **准确** (每个都得拟合已有作答) + **多样** (彼此要有差异, 否则等于没多生成)。而它们都是在同一份数据上估的, 天然容易高度相关甚至完全一样。RAT 就是来解决「如何造出又准又多样的一组估计」。

二、问题定义 (输入 / 输出)

符号与维度: - 题库 $\mathcal{Q} = \{q_1, \dots, q_{|\mathcal{Q}|}\}$ 。- 学生真实能力 $\theta_0 \in \mathbb{R}^d$, **整场测验中恒定不变** (这是 CAT 区别于知识追踪 KT 的关键假设——KT 里能力是随学习动态变化的, CAT 里假设它固定, 只是我们不知道而已)。- d 是知识概念数 (一维 IRT 时 $d = 1$)。- CDM 是个函数 $f(q, \theta) = \Pr(y = 1 | q, \theta)$, 输出答对概率。- 第 t 步的作答历史 $R = \{(q_1, y_1), \dots, (q_t, y_t)\}$, $y = 1$ 答对、0 答错。

一次 CAT 的输入输出: - 输入: 一个新学生 + 题库 + 选定的 CDM + 选定的信息度量 $\mathcal{J}$ 。- 过程: 循环 T 步 (论文设 $T = 20$), 每步选 1 题、学生作答、更新能力估计。- 输出: 测验结束时学生的最终能力估计 θ^* , 以及 (隐含地) 一条用尽量少的题、把能力估准的作答路径。

评测时的小例子 (理解评测口径很重要): 测试集里每个学生 i 的历史作答被切成两份——候选集 $\mathcal{Q}_i$ (供选题算法挑題、CDM 更新用) 和元集 $\mathcal{M}_i$ (留出来当考卷)。流程是: 从 $\mathcal{Q}_i$ 选题 → CDM 用其作答更新 $\hat{\theta}$ → 拿这个 $\hat{\theta}$ 去预测元集 $\mathcal{M}_i$ 上每道题答对与否 → 算 ACC/AUC。选题算法越好, 选出的题越能把 $\hat{\theta}$ 估准, 元集上的预测就越准。所以 ACC/AUC 高 = 选题好。

三、模型结构 (RAT 怎么嵌进 CAT)

RAT 不改 CAT 的两段式骨架, 只是把「估 1 个 $\hat{\theta}$ 」换成「估 m 个再平均」。看算法 1 的一个循环步 (第 t 步):

输入 → 处理 → 输出 逐行说: 1. **算查询** (line 2): 把上一步生成的 m 个估计取平均 $\theta^* = \frac{1}{m} \sum_i \hat{\theta}_i^{t-1}$ 。这就是这一步要用的「鲁棒查询」。2. **选题** (line 3): $q_t = \arg \max_q \mathcal{J}_q(\theta^*)$ 。注意 $\mathcal{J}$ 可以是任何现成度量 (FSI、KLI、MAAT 的 EMC.....), RAT 只换了输入的 θ , 不碰选题算法本身——这就是它「通用、即插即用」的来源。3. **学生作答**, 记录进 R , 把这题从题库移走 (line 4-5)。4. **顺序生成 m 个新估计** (line 6-8): 对 $i = 1, \dots, m$, - 先算「前 $i-1$ 个估计的临时平均」 $\theta_i^* = \frac{1}{i-1} \sum_{k=1}^{i-1} \hat{\theta}_k^t$; - 再解 $\hat{\theta}_i^t = \arg \min_{\theta_i} [\mathcal{L}_{MLE}(\theta_i) - \frac{\lambda}{2} \|\theta_i - \theta_i^*\|^2]$ 。- **关键设计**: 第 i 个估计被一个「推离前面已生成估计平均值」的正则项往外推, 所以它会和前面那些不一样 → 制造多样性。同时 $\mathcal{L}_{MLE}$ 把它拉回来拟合数据 → 保证准确。一推一拉, 平衡出又准又散的一组。

输出: 测验结束的 $\theta^* = \frac{1}{m} \sum_i \hat{\theta}_i^T$ 即学生最终能力。

为什么用「前 $i-1$ 个的平均」而不是「全部 m 个的平均」当推离目标? 因为 m 个是顺序生成的, 造第 i 个时后面的还没生出来, 拿不到全局平均, 只能用已有的临时平均代替。这是个工程上的因果顺序考量。

四、关键公式详解（重点）

公式 1 (式 1): IRT 的答对概率

$$\Pr(\text{学生答对题}j) = \sigma(\theta - b_j)$$

- σ 是 sigmoid, θ 学生能力, b_j 题目难度。
- 举例: 学生能力 $\theta = 1.0$, 题难 $b_j = 0.5$, 则 $\sigma(1.0 - 0.5) = \sigma(0.5) = \frac{1}{1+e^{-0.5}} \approx 0.62$, 即约 62% 概率答对。若换难题 $b_j = 2.0$, $\sigma(-1.0) \approx 0.27$, 只剩 27%。
- 作用: CDM 的最简形式, 把「能力 vs 难度」的差转成概率, 是后面 MLE 和 FSI 的基础。

公式 2 (式 2): MLE 损失 (怎么估 $\hat{\theta}$)

$$\mathcal{L}_{MLE}(\theta) = -\frac{1}{t} \sum_{(q,y) \in R} [y \log f(q, \theta) + (1-y) \log(1-f(q, \theta))]$$

- 就是二元交叉熵。固定题目参数, 只优化 θ , 让模型预测概率尽量贴近真实对错。 $\hat{\theta}_t = \arg \min_{\theta} \mathcal{L}_{MLE}$ 。
- 举例: 学生答了 2 题。题 A ($b = 0.5$) 答对 ($y = 1$), 题 B ($b = 1.5$) 答错 ($y = 0$)。若试探 $\theta = 1.0$: 题 A $f = \sigma(0.5) = 0.62$, 贡献 $-\log 0.62 = 0.48$; 题 B $f = \sigma(-0.5) = 0.38$, 答错贡献 $-\log(1-0.38) = -\log 0.62 = 0.48$ 。平均损失 0.48。若试 $\theta = 0.5$: 题 A $f = \sigma(0) = 0.5$ 贡献 0.69; 题 B $f = \sigma(-1.0) = 0.27$ 贡献 $-\log 0.73 = 0.31$, 平均 0.50。比较下来 $\theta = 1.0$ 损失更小 $\rightarrow$ 更可能是它。这就是 MLE 在「挑能力值」。
- 作用: 传统 CAT 每步就靠它估出唯一的 $\hat{\theta}_t$ 。RAT 在它基础上做文章。

公式 5 (式 5): 误差分解 = 准确性 - 多样性 (全文的灵魂)

$$\underbrace{\|\theta^* - \theta_0\|^2}_{\text{平均估计的误差}} = \underbrace{\frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta_0\|^2}_{\text{【1】 准确性 (越小越准)}} - \underbrace{\frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta^*\|^2}_{\text{【2】 多样性 (越大越散)}}$$

这是借自集成学习的「误差-歧义分解」。它说: 平均值 θ^* 的误差 = 各估计的平均误差 - 各估计的发散度。因为【2】非负, 所以 θ^* 的误差永远 $\leq$ 单个估计的平均误差 (取平均稳赚不赔); 而且想让 θ^* 更准, 要么【1】更小 (每个都准), 要么【2】更大 (彼此更散)。

- 数值举例 (一维): 设真实 $\theta_0 = 1.0$, 造了 3 个估计 $\hat{\theta} = \{0.7, 1.0, 1.6\}$ 。
 - 平均 $\theta^* = (0.7 + 1.0 + 1.6)/3 = 1.1$ 。左边 $\|\theta^* - \theta_0\|^2 = (1.1 - 1.0)^2 = 0.01$ 。
 - 【1】准确性 = $\frac{1}{3}[(0.7-1)^2 + (1.0-1)^2 + (1.6-1)^2] = \frac{1}{3}[0.09 + 0 + 0.36] = 0.15$ 。
 - 【2】多样性 = $\frac{1}{3}[(0.7-1.1)^2 + (1.0-1.1)^2 + (1.6-1.1)^2] = \frac{1}{3}[0.16 + 0.01 + 0.25] = 0.14$ 。
 - 验证: $0.15 - 0.14 = 0.01$ (对), 正好等于左边。
 - 直观感受: 单个估计平均误差 0.15, 但一平均后误差降到 0.01! 这 0.14 的降幅完全来自「多样性」——几个估计有的偏高有的偏低, 平均时互相抵消了。这就是为什么要刻意制造多样性。
- 作用: 它把「为什么取平均会更准」量化了, 并指明优化方向 = 保准确 (压【1】) + 促多样 (抬【2】)。直接催生了公式 6 的设计。

公式 6 (式 6): 带多样性正则的新估计目标

$$\hat{\theta}_i^t = \arg \min_{\theta_i} \mathcal{L}_{MLE}(\theta_i) - \lambda \psi(\theta_i), \quad \psi(\theta_i) = \frac{1}{2} \|\theta_i - \theta_i^*\|^2, \quad \theta_i^* = \frac{1}{i-1} \sum_{k=1}^{i-1} \hat{\theta}_k^t$$

- $\mathcal{L}_{MLE}$ 管准确 (对应【1】), $-\lambda\psi$ 管多样 (对应【2】)。注意是减 $\lambda\psi$: 最小化「负的距离」= 最大化 θ_i 离 θ_i^* 的距离 = 把第 i 个估计往「远离前面估计平均」的方向推。 $\lambda \geq 0$ 控制推力大小。
- 三种极端:
 - $\lambda = 0$: 退化成纯 MLE, m 个估计全一样 ($\theta^* = \hat{\theta}_1 = \dots = \hat{\theta}_m$), 白做。
 - λ 适中: 又准又散 (论文最优 $\lambda = 0.1$)。
 - $\lambda = \infty$: 只顾散不顾准, 等于在无穷范围乱采样, 没意义。
- 举例: 第 t 步, 前 2 个估计已生成 $\hat{\theta}_1^t = 0.8$, $\hat{\theta}_2^t = 1.2$, 现在造第 3 个。临时平均 $\theta_3^* = (0.8 + 1.2)/2 = 1.0$ 。若纯 MLE 最优解本来是 $\theta = 1.05$, 加上 $-\frac{\lambda}{2}(\theta - 1.0)^2$ ($\lambda = 0.1$) 这个把它推离 1.0 的力后, 解会被往远离 1.0 的一侧稍微推开, 比如变成 1.15。这样第 3 个估计就和前两个拉开了差距, 多样性上来了, 但因为 MLE 还在拽, 也没跑太远谱。
- 作用: 这是 RAT 的「引擎」, 顺序地造出一组又准又散的估计。

公式 8 + 定理 1/2: 为什么 θ^* 是个「好」估计量

作者把式 6 的最优条件 $\nabla \mathcal{L} = 0$ 在 θ_0 处泰勒展开, 解出 θ^* 的近似闭式 (式 7、8), 再推出三条统计性质:

- 定理 1 渐近无偏 + 有效: 当 $\lambda < I(\theta_0)$ (正则别太猛, 否则破坏无偏性——这也解释了实验里 λ 太大反而变差) 且 $m \rightarrow \infty$ 时, $\mathbb{E}[\theta^*] = \theta_0$ (平均意义上不偏), 且方差 $\text{Var}[\theta^*] = \frac{1}{tI(\theta_0)}$ 达到克拉默-拉奥下界 (理论上方差能压到的最低点, 没有更准的无偏估计了)。- 数值感受: $I(\theta_0)$ 是费舍尔信息。设 $I = 1$, 则第 $t = 5$ 步方差 = $1/5 = 0.2$, $t = 20$ 步方差 = $1/20 = 0.05$ 。步数越多, 方差越小, 估计越聚拢到真值。
- 定理 2 一致性: $\lim_{t \rightarrow \infty} \Pr(\|\theta^* - \theta_0\| \geq \epsilon) = 0$ 。用切比雪夫不等式 $\Pr(|\theta^* - \theta_0| \geq \epsilon) \leq \frac{\text{Var}}{\epsilon^2} = \frac{1}{tI(\theta_0)\epsilon^2} \rightarrow 0$ 一步推出。意思是题答得够多, θ^* 几乎必然落在真值附近任意小邻域内。
 - 配合图 3 理解: 无偏性 (图 3a) 保证打靶「不系统偏向某侧」, 但单次可能散得远; 有效性 (图 3b) 保证随 t 增大弹着点越缩越紧, 最终密集环绕靶心。

这三条性质就是论文敢说「用 θ^* 当查询和最终能力都靠谱」的理论底气。

五、代码实现对照

未发现 RAT 方法本身的开源代码。论文只放出了两个配套工具包: - 数据集: <https://github.com/bigdata-ustc/EduData> (Junyi/Eedi 等的下载与预处理)。- 认知诊断: <https://github.com/bigdata-ustc/EduCDM> (IRT、NCDM、DINA 等 CDM 的实现)。

若要复现, 核心改动其实很小, 可基于 EduCDM 的 IRT/NCDM 实现, 把 CAT 主循环按算法 1 改造, 伪代码骨架如下 (对照公式 6 与算法 1):

```
# 第 t 步: 生成 m 个估计 (对应算法 1 line 6-8 / 公式 6)
thetas = [] # 本步的 m 个估计
for i in range(m):
    theta_star_i = mean(thetas) if thetas else theta_init # *_i = 前 i-1 个的平均
    theta_i = clone(theta_star_i).requires_grad_()
    for _ in range(inner_steps): # 在 mini-batch 作答 R 上优化
        loss = bce(f(R.q, theta_i), R.y) # L_MLE, 公式 2
        loss = loss - (lam / 2) * ((theta_i - theta_star_i)**2).sum() # 减去多样性正则, 公式 6
        loss.backward(); opt.step(); opt.zero_grad()
    thetas.append(theta_i.detach())
theta_query = mean(thetas) # *, 当查询 (算法 1 line 2-3 / 公式 4)
q_next = argmax_q( information_metric(q, theta_query) ) # FSI/KLI/MAAT 原样调用
```

关键对应关系: $\text{loss} = \text{bce} - (\text{lam}/2) * \text{dist}^2$ 这一行就是公式 6 的全部; 外层 `for i in range(m)` 顺序生成对应算法 1 的内循环; `theta_query = mean(thetas)` 对应公式 4 把平均值当查询。注意正则项前是减号 (推离), 别写成加号 (那会变成互相吸引、彻底失去多样性)。

六、小结

实验结论要点: - 在 Junyi/Eedi/Math 三数据集上, 把 RAT 套到 FSI、KLI、MAAT 上 (X+RAT), ACC/AUC 普遍涨 1~2 个点; 越弱的基线 (如 FSI) 涨得越多 (平均 +2.07 ACC), 最后几个传统方法被拉到几乎同一水平, 说明「以前是估计方法拖了后腿, 不是选题算法本身不行」。- 甚至能在 Eedi 上超过需要大规模训练的深度方法 BOBCAT, 而 RAT 零额外训练开销。- 抗噪实验 (猜测 25%/50%、失误 5%/10%) 下 MSE 仍稳步下降, 且与基线差距随步数拉大, 鲁棒性得到验证。- 超参: $m = 5$ 就够 (再大不敏感), $\lambda = 0.1$ 最佳 (太大破坏无偏性, 呼应定理 1 的 $\lambda < I(\theta_0)$ 条件)。- 对比 Bagging/AdaBoost: 传统集成在 CAT 上几乎没用 (数据太少易过拟合, 且目标是「预测准」而非「参数估准」), RAT 在 MSE 上至少领先 14.29%。

优点: - 即插即用, 不改 CAT 范式、不改选题算法, 只换查询输入, 通用性强。- 有完整理论保证 (无偏/有效/一致), 不是纯 trick。- 几乎零额外训练成本, 比深度方法实用 (题库天天更新也不怕)。

局限 / 可改进: - 估计开销变 m 倍 (mT_e), 虽然作者论证 $mT_e \ll T_s$ 可忽略, 但在 CDM 很重、题库不大时未必成立。- 理论建立在 $m \rightarrow \infty$, 实践用 $m = 5$, 二者间的 gap 只有经验支撑。- 「学生能力测验中恒定」是 CAT 的硬假设, 对学习过程中能力变化的场景 (更接近 KT) 不适用。- 用「前 $i - 1$ 个平均」作推离目标是顺序近似, 不同生成顺序可能影响结果 (论文未深究)。

对 KT/CAT 研究者的启发: 这篇提供了一个很好的「正交于选题算法」的改进维度——能力估计的鲁棒性。它和你做 CAT 选题策略的工作不冲突, 反而可叠加; 其「多估计 + 多样性正则 + 误差分解」的框架也可借鉴到 KT 里对学生状态的不确定性建模上。