

一种用于教育题目检索的鲁棒计算机自适应测验方法 (A Robust Computerized Adaptive Testing Approach in Educational Question Retrieval)

原文: 3477495.3531928.pdf (SIGIR '22) ·译者: Claude ·译于 2026-06-26 术语对照: Computerized Adaptive Testing 计算机自适应测验 (CAT) ·Cognitive Diagnosis Model 认知诊断模型 (CDM) ·Item Response Theory 项目反应理论 (IRT) ·Fisher Information 费舍尔信息 (FSI) ·proficiency 能力/水平 θ ·multi-facet 多面性

摘要

计算机自适应测验 (Computerized Adaptive Testing, CAT) 是个性化在线教育 (如 GRE) 中一种很有前景的测验模式, 其目标是准确测量学生的能力水平并缩短测验长度。它的「自适应」体现在选题算法上: 该算法能在每一步根据学生当前被估计出的能力, 检索出最适合他/她的题目。尽管已有许多精巧的选题算法来提升 CAT 的效果, 但这些算法都受制于、并被「当前能力估计的准确性」所扰动, 因而缺乏鲁棒性。为此, 我们研究了一种通用方法, 借助测验过程中学生的「多面性 (multi-facet)」本质来增强已有算法的鲁棒性。具体来说, 我们提出了一个通用的优化准则——鲁棒自适应测验 (Robust Adaptive Testing, RAT), 它通过在每一步融合多个能力估计来完成能力估计, 从而维持对学生潜在能力的一种多面描述。我们进一步从理论上分析了这种估计量所具有的良好统计性质: 渐近无偏性、有效性与一致性。在带扰动的合成数据以及三个真实世界数据集上的大量实验表明, RAT 框架下的选题算法具有鲁棒性, 并能带来显著提升。

CCS 概念: 应用计算 → 在线学习 (E-learning)。

关键词: 计算机自适应测验, 教育资源检索, 教育测量, 认知诊断。

1 引言

在信息爆炸的时代, 计算机自适应测验 (CAT) 是教育资源检索与教育测量中的一个关键问题。由于能够为学生自适应地检索最适合的题目, CAT 已经成为标准化考试 (如 GMAT 和 GRE) 中测量学生能力水平的一种越来越流行的方式。Lan 等人已经证明, 这类自适应测验要达到与纸笔测验相同的测量精度, 所需的题目数量更少。同时, 更短的测验能降低系统负载, 对学生也更友好——如果需要回答太多题目, 学生可能会感到沮丧或厌烦。

在真实场景中, CAT 由两个核心组件交替工作直到测验结束组成 (见图 1): 在第 t 个测验步:

1. **认知诊断模型 (Cognitive Diagnosis Model, CDM)**, 作为「用户模型」, 首先利用学生对前 t 道题目的作答来估计其当前能力 $\hat{\theta}_t$ 。最著名的模型是项目反应理论 (Item Response Theory, IRT), 它通过对齐并比较学生的整体能力 $\theta \in \mathbb{R}$ 与题目难度, 来定义答对的概率。更一般地, θ 是多维的, 每个维度代表对应知识概念 (如数学中的「代数」概念) 的掌握程度。
2. 接着, **选题算法 (selection algorithm)** 根据某种「下一题准则 (next item criteria)」检索题目, 挑出最有信息量的那一道, 例如难度最接近 CDM 所估计的学生能力的题目; 因此大多数算法都采用当前估计 $\hat{\theta}_t$ 作为选题时的查询 (query)。已被证明, 提出更有信息量、更恰当的题目能显著缩短测验长度。

虽然上述范式已取得巨大成功, 但其缺陷也很明显: 如果查询 (即当前估计 $\hat{\theta}_t$) 不接近学生的真实能力 θ_0 , 选题算法就会失效。不幸的是, 这种偏差 $\|\hat{\theta}_t - \theta_0\|$ 在各种扰动下是不可避免的, 例如优化困境 (如过拟合)、初始几步用于估计的作答数太少、学生的猜测 (guess) 和失误 (slip) 因素等。为缓解 CAT 这种较差的鲁棒性, 已有一系列准则被提出, 在选题中引入额外信息, 但它们仍然围绕当前估计来检索, 因而带来的改进有限。近来, 许多研究试图改变这一传统范式——用强化学习训练数据驱动的选题算法; 然而, 这些方法一旦动作空间中加入新题目就必须从头重新训练, 这在每天有海量新题上传或更新的真实教育系统中并不现实; 它们也容易受历史数据偏差的影响。因此, 一种更现实的增强 CAT 鲁棒性的方案仍待深入探索。

幸运的是, 我们发现了一个此前被忽视的事实: 学生在测验中是「多面的 (multi-facet)」, 即他/她以往的作答往往对应着多个能力估计, 而非单一的 $\hat{\theta}_t$:

- **例 1:** 测验中, 如果一个学生答对了一道较简单的题 (如难度 = 0.3), 却答错了一道较难的题 (如难度 = 0.8), 那么他/她的能力可能落在区间 $[0.3, 0.8]$ 内, 而不是某个确定的值。
- **例 2:** 通常, 一道题有多种解法 (见图 2)。对一道关于「代数」概念的题目答对, 可以推断出他/她可能确实在「代数」上能力更高, 或在「几何」上能力更高, 或两者都不是 (即猜对, guess 因素), 又或者两者都高。

图 1: CAT 的工作流程: 在第 t 步, 选题算法基于 CDM 估计出的学生当前能力 $\hat{\theta}_t$, 自适应地选出一道题 q_{t+1} 。

上述发现似乎为 CAT 的鲁棒性问题提供了一个概念上简单而直观的解法: 「三个臭皮匠胜过诸葛亮」——在每一步融合一组多样的能力估计来选题。然而, 引入多个估计并保证它们的准确性与多样性并不容易: 1) **准确性:** 为了更好地刻画学生上述的多面本质 (如例 1、例 2), 所有生成的估计都应当与他/她以往的作答相符; 2) **多样性:** 这些估计彼此当然应当有差异, 才能全面描述学生的潜在能力, 否则就没必要引入多个。然而, 它们是在同一份作答数据下估计出来的, 这可能导致这些估计高度相关, 甚至完全相同。

基于这些考虑，我们提出了一种在已有 CAT 方法内部增强鲁棒性的通用方法，称为鲁棒自适应测验框架 (Robust Adaptive Testing framework, RAT)。具体来说，我们在传统极大似然估计 (Maximum Likelihood Estimation, MLE) 基础上，为 CAT 过程中的能力估计设计了一种新的优化形式。它在每一步生成多个估计，并维持它们的多样性与准确性，从而让 CAT 能在更鲁棒的设定下运行。更重要的是，我们揭示了由这些多个估计所确定的估计量具有的渐近无偏性、有效性与一致性，并给出了理论证明。这种新估计量所具备的良好统计性质，保证了把它既用作选题查询、又用作学生最终能力估计的有效性。值得注意的是，RAT 简单却更可靠，它不需要对 CAT 范式施加额外约束，也不需要修改已有的选题算法。

为验证所提 RAT 框架的有效性，我们在合成数据集和来自不同教育系统的三个真实世界数据集上进行了大量实验。实验结果表明，即使在高噪声率下 RAT 也能取得当前最优 (state-of-the-art) 的表现。令人惊讶的是，当与强大的深度学习选题算法相比时，RAT 框架中基于传统不确定性信息的准则取得了极具竞争力的表现，且不需要对选题算法增加任何额外的训练开销。

图 2: 通常一道题有多种解法，每一种解法都对应一种可能的能力，即 $\{\hat{\theta}_1^t, \hat{\theta}_2^t, \dots, \hat{\theta}_m^t\}$ ，而非单一的 $\hat{\theta}_t$ 。

2 背景与相关工作

计算机自适应测验 (CAT) 是一个迭代且动态的过程，包括一个认知诊断模型 (CDM) 和一个选题算法。这两个组件交替工作，直到满足终止准则，最后输出学生被估计出的能力，并以可视化的方式反馈给学生本人或教师，以促进个性化学习。CAT 的目标是：在尽量减少所问题目数量的同时，准确估计即将到来的学生的能力。下面分别回顾 CAT 的这两个组件。

2.1 认知诊断模型

认知诊断 (Cognitive Diagnosis) 意味着学生的认知状态或能力在一次测验中是稳定的，因而可以通过其交互行为 (即历史作答) 推断出来。因此，认知诊断模型 (CDM) (或称心理测量模型) 采用题目和学生的特征来预测作答 (答对或答错)。最著名的模型是项目反应理论 (IRT)，其最简单的形式 (1PL) 为：

$$\Pr(\text{学生答对题目 } j) = \sigma(\theta - b_j), \quad (1)$$

其中 $\sigma(\cdot)$ 是逻辑斯蒂 (logistic) 函数， $b_j \in \mathbb{R}$ 表示每道题预先标定好的参数，称为难度， $\theta \in \mathbb{R}$ 是待估计的学生潜在能力。其他有代表性的模型包括矩阵分解 (Matrix Factorization, MF)、确定性输入、噪声与门模型 (Deterministic Inputs, Noisy-And gate, DINA)，以及最近提出的、利用神经网络建模学生-题目交互的神经认知诊断模型 (如 NCDM 和 CDGK)。给定具体的 CDM 与作答数据，通常用极大似然估计 (二元交叉熵损失) 来估计 θ ，供后续选题使用。

2.2 选题算法

传统算法基于某种不确定性或信息度量，针对不同的 CDM 专门设计。例如，使用最广泛的是费舍尔信息 (Fisher Information, FSI) 度量，它是为 IRT 设计的，会选出能在当前估计处最大化费舍尔信息的下一题；然而，如果当前能力估计 θ 不接近真实值，它就会失效，从而影响 CAT 系统的鲁棒性。为缓解这一点，已有一系列基于 FSI 的方法被提出，包括 KL 信息 (Kullback-Leibler Information, KLI)、贝叶斯准则 (Bayesian criterion) 和权重准则 (weight criterion)，它们分别引入了额外的积分、概率和权重分配。不幸的是，这些方法仍然以当前估计为中心，忽视了「学生以往表现所对应的能力本身就不唯一」这一事实。近来，许多研究者转而改变 CAT 范式，把它视为一个强化学习问题，直接从大规模学生作答数据中训练选题算法，如 BOBCAT；尽管深度神经网络带来了强劲的表现，但如第 1 节所述，它们在实际应用中计算上不可行，且容易受训练数据偏差影响。本文提出一种更现实的方法，在不修改 CAT 范式的前提下增强已有算法 (如 FSI) 的鲁棒性。

3 预备知识

计算机自适应测验 (CAT) 的任务是为学生提供一份最契合的题目列表。CAT 的一个重要假设是：学生的真实能力水平 $\theta_0 \in \mathbb{R}^d$ 在整个测验过程中保持恒定 (脚注 1: 这一假设使 CAT 从根本上区别于其他智能教育系统，如知识追踪 Knowledge Tracing)，其中 d 指能力的维度 (如待测的知识概念数量)。CAT 的最终目标是：(1) 为每个学生选出有价值且最契合的题目，缩短测验长度；(2) 利用以往作答来估计学生能力 θ ，并保证测验结束时它接近真实的 θ_0 。

3.1 任务形式化

在 CAT 的第 $t \in [1, 2, \dots, T]$ 个测验步，先用前 t 次作答估计学生当前能力 $\hat{\theta}_t$ ；然后利用 $\hat{\theta}_t$ 从题库 $\mathcal{Q}$ 中检索下一题 q_{t+1} 提问学生，并接收作答 y_{t+1} 。这些交互构成一个序列 $\{(q_1, y_1), (q_2, y_2), \dots, (q_T, y_T)\}$ ，其中若对 q_t 答对则 $y_t = 1$ ，否则为 0。具体来说，给定题库 $\mathcal{Q} = \{q_1, q_2, \dots, q_{|\mathcal{Q}|}\}$ ，一个完整的 CAT 系统包含两个组件，它们交替重复工作 T 步：

(1) 用 CDM 进行能力估计。一个 CDM 类 f (如 IRT、NCDM) 预测能力为 θ 的学生答对题目的概率, 记为 $f(q, \theta) = \Pr(y = 1|q, \theta)$ 。为在每一步准确估计其能力, CAT 中采用著名的极大似然估计 (MLE), 确保估计出的 $\hat{\theta}$ 接近真实值, 即 $\|\hat{\theta} - \theta_0\| \rightarrow 0$ 。在第 t 步, 给定以往作答 $R = \{(q_1, y_1), (q_2, y_2), \dots, (q_t, y_t)\}$, 对应的 MLE 损失如下, 于是估计更新为 $\hat{\theta}_t = \arg \min_{\theta} \mathcal{L}_{MLE}(\theta)$:

$$\mathcal{L}_{MLE}(\theta) = -\frac{1}{t} \sum_{(q,y) \in R} y \log f(q, \theta) + (1 - y) \log(1 - f(q, \theta)). \quad (2)$$

(2) 题目选择。选题算法基于学生当前估计 $\hat{\theta}_t$ 从 $\mathcal{Q}$ 中选题。更具体地, 它按下式检索下一题 q_{t+1} :

$$q_{t+1} = \arg \max_{q \in \mathcal{Q}} \mathcal{J}_q(\hat{\theta}_t), \quad (3)$$

其中 $\mathcal{J}_q(\cdot)$ 是题目 q 的信息量。接收到新作答 y_{t+1} 后, CDM 更新并估计能力 $\hat{\theta}_{t+1}$ 。

3.2 问题分析

从上述 CAT 的整个过程不难发现, 总结了学生以往表现/作答的能力估计 $\hat{\theta}_t$, 是各种选题算法唯一的依据/输入。因此, 如果当前估计 $\hat{\theta}_t$ 不接近 θ_0 , 选题算法就会失效, 从而干扰后续流程。正如我们前面所指出的, 这种偏差是不可避免且客观存在的 (如学生的猜测和失误)。我们能做的是尽量缩小它。

因此, 本文不去设计新的选题算法, 而是聚焦于查询本身 (即能力估计 $\hat{\theta}$)。我们的方法在概念上很简单: 融合一组潜在估计 $\{\hat{\theta}_i^t\}_{i=1}^m$ 以提升其准确性与鲁棒性。主要原因在于: 从以往作答推断出的能力并不唯一。例如如图 2 中, 对第五题答对, 可推断出由于该题有多种解法, 他/她可能有多种潜在能力。 $\{\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m\}$ 的语义是: 由于不确定性, 学生以往的作答对应多个估计而非单一估计。这种做法有两个优点:

- 用一组估计从多个视角描述学生能力, 抵抗扰动。进一步整合它们, 可以提升每一步估计的准确性 (见下一节)。
- 这种方法是通用的, 且基于学生-题目之间客观存在的模式, 对 CAT 本身不含任何额外限制和假设。

4 所提方法

在我们的鲁棒自适应测验框架 (RAT) 中, 如前所述, 每一步都会生成多个估计 $\{\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m\}$ 作为学生的多面视角。为保持典型的 CAT 范式不变并确保方法的通用性, 我们利用它们的平均值 $\theta^* = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i^t$ 作为新的查询 (替换式 (3) 中的 $\hat{\theta}_t$) 来选题:

$$q_{t+1} = \arg \max_{q \in \mathcal{Q}} \mathcal{J}_q(\theta^*), \quad (4)$$

其中 $\mathcal{J}_q(\cdot)$ 可以是题目 q 的任意已有信息度量, 如 FSI 和 KLI。

4.1 动机: 准确性与多样性

类似地, 作为选题算法效率的保证, θ^* 的误差在每一步也应被限制到最小, 即 $\|\theta^* - \theta_0\| \rightarrow 0$ 。进一步, 我们发现:

引理 1. 假设 $\{\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m\}$ 是真实值 θ_0 的 m 个估计。令 $\theta^* = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i$ 。那么 RAT 在每一步试图最小化的误差 $\|\theta^* - \theta_0\|^2$ 可分解为:

$$\|\theta^* - \theta_0\|^2 = \underbrace{\frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta_0\|^2}_{\text{【1】 准确性}} - \underbrace{\frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta^*\|^2}_{\text{【2】 多样性}}. \quad (5)$$

证明. 展开 【2】 多样性项: $\frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta^*\|^2 = \frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta_0 + \theta_0 - \theta^*\|^2 = \frac{1}{m} \sum_{i=1}^m \{\|\hat{\theta}_i - \theta_0\|^2 + 2(\hat{\theta}_i - \theta_0)^\top (\theta_0 - \theta^*) + \|\theta_0 - \theta^*\|^2\} = \frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta_0\|^2 + 2(\theta_0 - \theta^*)^\top \frac{1}{m} \sum_{i=1}^m (\hat{\theta}_i - \theta_0) + \|\theta_0 - \theta^*\|^2 = \frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta_0\|^2 - 2\|\theta_0 - \theta^*\|^2 + \|\theta_0 - \theta^*\|^2 = \frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta_0\|^2 - \|\theta^* - \theta_0\|^2$ 。证毕。□

在第 t 步, 这些估计的平均误差 $\frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta_0\|^2$ 衡量它们的准确性。同时, 每个估计与其平均值之差 $\frac{1}{m} \sum_{i=1}^m \|\hat{\theta}_i - \theta^*\|^2$ 用于衡量它们的多样性。这一分解揭示: (1) θ^* 的误差永远不会大于 【1】 $\{\hat{\theta}_i\}_{i=1}^m$ 的平均误差 (上界), 因为 【1】 和 【2】 都非负。(2) 更小的 【1】 (更准确)

和更大的【2】(更多样)会带来更准确的 θ^* 。因此,引理 1 启发了一种改进能力估计量的直观方式:对 $\{\hat{\theta}_i\}_{i=1}^m$ 取平均得到 θ^* ,关键是保持它们的准确性与多样性。这一分解可视为误差-歧义分解 (error-ambiguity decomposition) 的一个推广。

4.2 能力估计的新形式

基于上述发现,我们现在引入估计学生能力的新形式。在第 t 步,我们通过在常用的 MLE 目标上加入多样性正则项 $\psi(\theta_i)$,来调整 θ_i ($1 \leq i \leq m$) 的优化函数:

$$\hat{\theta}_i^t = \arg \min_{\theta_i} \mathcal{L}_{MLE}(\theta_i) - \lambda \psi(\theta_i), \quad i = 1, \dots, m. \quad (6)$$

$$\psi(\theta_i) = \frac{1}{2} \|\theta_i - \theta_i^*\|^2, \quad \theta_i^* = \frac{1}{i-1} \sum_{k=1}^{i-1} \hat{\theta}_k^t,$$

其中 $\mathcal{L}_{MLE}(\theta_i)$ 是 MLE 损失 (式 (2)), 确保估计的准确性 (即式 (5) 中的【1】)。 $\lambda \geq 0$ 是控制多样性正则项 (即式 (5) 中的【2】) 的权重系数。由于在优化 θ_i 时,所有 m 个估计尚未全部生成、无法得到平均值,所以用前 $i-1$ 个估计的临时平均 θ_i^* 作为式 (5) 中 θ^* 的替代。所有估计 $\{\hat{\theta}_1^t, \hat{\theta}_2^t, \dots, \hat{\theta}_m^t\}$ 依次顺序生成,平衡它们的准确性与多样性。

我们现在解释这个新形式背后的原理:

- **传统 MLE** ($\lambda = 0$)。此时,该优化可视为用 MLE 重复估计 m 次。也就是说,所有估计 $\{\hat{\theta}_1^t, \hat{\theta}_2^t, \dots, \hat{\theta}_m^t\}$ 可能高度相关,甚至彼此相同,即 $\theta^* = \hat{\theta}_1^t = \dots = \hat{\theta}_m^t$, 于是式 (6) 退化为传统 MLE。
- **混合估计** ($\lambda \in (0, \infty)$)。随着 λ 增大,多样性正则项 $\lambda \psi(\theta_i)$ 的作用越来越强,确保所有估计彼此多样,否则惩罚 $\lambda \psi(\theta_i)$ 会太小。
- **盲目估计** ($\lambda = \infty$)。直观上,这一极限情况会强迫所有估计彼此多样,而完全不顾准确性和对数据的拟合,类似于在无限范围内随机采样所有估计。

经过鲁棒优化的 CAT 流程见算法 1,我们在其中详述了每个测验步内部发生的交互。显然:(1) RAT 是通用的,可直接应用于已有选题算法和 CDM。(2) 学生多面能力估计的平均值 (即 θ^*) 既用作选题的新查询 (第 3 行),也用作学生的最终能力估计。

算法 1: RAT 流程 输入: 题库 $\mathcal{Q}$, 一个具体 CDM f , 一个具体信息度量 $\mathcal{J}$; 初始化: 初始化 m 个估计 $\{\hat{\theta}_1^0, \hat{\theta}_2^0, \dots, \hat{\theta}_m^0\}$; 作答数据 $R \leftarrow \emptyset$; 1: **for** $t = 1$ **to** T **do** 2: $\theta^* \leftarrow \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i^{t-1}$; 3: $q_t \leftarrow \arg \max_{q \in \mathcal{Q}} \mathcal{J}_q(\theta^*)$; 4: $R \leftarrow R \cup \{(q_t, y_t)\}$; # 学生作答 5: $\mathcal{Q} \leftarrow \mathcal{Q} - \{q_t\}$; 6: **for** $i = 1$ **to** m **do** # 生成 m 个估计 7: $\theta_i^* \leftarrow \frac{1}{i-1} \sum_{k=1}^{i-1} \hat{\theta}_k^t$; 8: $\hat{\theta}_i^t \leftarrow \arg \min_{\theta_i} \mathcal{L}_{MLE}(\theta_i) - \frac{\lambda}{2} \|\theta_i - \theta_i^*\|^2$ 输出: 学生最终能力估计 $\theta^* := \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i^T$

时间复杂度。每一步, CAT 的时间开销分为两部分: 能力估计 (T_e) 和为选题计算每道题的信息量 (T_s)。显然,引入 m 个估计会带来 m 倍的估计开销 mT_e 。但与计算题目信息量相比,用迷你批 (mini-batch) 中少量作答做估计的额外时间可以忽略,尤其在真实应用中面对海量候选题目时,即 $mT_e \ll T_s$ 。此外,第 6.4 节的实验结果表明 $m = 5$ 已足以取得令人满意的表现。因此,时间复杂度是可接受的,这一新优化准则可应用于实际部署。我们把进一步的探索与优化留作未来工作。

5 估计量的性质刻画

新的能力估计方法利用 θ^* 作为 CAT 的鲁棒增强估计量。本节深入刻画其性质,证明它作为「检索题目的查询」以及「学生最终能力估计」的合理性。

5.1 理论分析: 无偏性、有效性与一致性

在统计学中,估计量之所以被采用,通常是因为其统计性质,最显著的是无偏性、有效性与一致性。为此,首先需要解析由式 (6) 所确定的 θ^* 的表达式。我们对 $\nabla_{\theta_i} [\mathcal{L}_{MLE}(\theta_i) - \lambda \psi(\theta_i)] := \nabla_{\theta_i} \mathcal{L}(\theta_i)$ 的每一维在点 θ_0 处做泰勒展开,得到:

$$\nabla_{\theta_i} \mathcal{L}(\theta_i) \approx \nabla_{\theta_i} \mathcal{L}_{MLE}(\theta_0) - \lambda(\theta_0 - \theta_i^*) + (\theta_i - \theta_0)(H_D(\theta_0) - \lambda), \quad (7)$$

其中 $H_D = \text{diag}[\nabla_{\theta_i}^2 \mathcal{L}_{MLE}]$ 是 $\mathcal{L}_{MLE}$ 的海森 (Hessian) 矩阵的对角线。 $\hat{\theta}_i$ 是 $\nabla_{\theta_i} \mathcal{L}(\theta_i) = 0$ 的解,代入式 (7) 可得 $\hat{\theta}_i \approx \frac{\theta_0 H_D(\theta_0) - \lambda \theta_i^* - \nabla \mathcal{L}_{MLE}(\theta_0)}{H_D(\theta_0) - \lambda}$ 。于是,我们得到想要的估计量 θ^* 的表达式:

$$\theta^* = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i \approx \frac{\theta_0 H_D(\theta_0) - \frac{\lambda}{m} \sum_i \theta_i^* - \nabla \mathcal{L}_{MLE}(\theta_0)}{H_D(\theta_0) - \lambda}. \quad (8)$$

基于上述结果，可详细推导估计量 θ^* 的每个性质。为更直观地说明，我们只展示一维情形，多维情形类似。

定理 1 (渐近无偏性与有效性)。把 CDM 在 θ_0 处的费舍尔信息记为 $I(\theta_0)$ 。当 $\lambda < I(\theta_0)$ 且 $m \rightarrow \infty$ 时，估计量 θ^* 是渐近无偏的，即

$$\mathbb{E}[\theta^*] = \theta_0. \quad (9)$$

进一步，它是渐近有效的，其渐近方差为 $\text{Var}[\theta^*] = \frac{1}{tI(\theta_0)}$ ，恰好等于克拉默-拉奥下界 (Cramér–Rao lower bound)。

证明。详细证明见附录 A。□

无偏性这一统计性质指的是： θ^* 的抽样分布的期望值等于学生的真实能力 θ_0 。然而，仅知道这个估计量无偏并不很有用——如果 θ^* 的取值在不同样本间波动很大、偏离真实值 (图 3(a))。所幸，上面的第二个论断表明，方差 $\frac{1}{tI(\theta_0)}$ 会随测验步 t 增大而减小到零，因而估计 θ^* 随 t 增大越来越准确 (图 3(b))。

定理 2 (一致性)。给定任意小的正数 ϵ ，当 $\lambda < I(\theta_0)$ 且 $m \rightarrow \infty$ 时，估计量 θ^* 是一致的，即

$$\lim_{t \rightarrow \infty} \Pr(\|\theta^* - \theta_0\| \geq \epsilon) = 0. \quad (10)$$

证明。结合定理 1 的结论 $\mathbb{E}[\theta^*] = \theta_0$ 与 $\text{Var} = \frac{1}{tI(\theta_0)}$ ，对所有 $\epsilon > 0$ ，有 $\lim_{t \rightarrow \infty} \Pr\{|\theta^* - \theta_0| \geq \epsilon\} = \lim_{t \rightarrow \infty} \Pr\{|\theta^* - \mathbb{E}[\theta^*]| \geq \epsilon\} \leq \lim_{t \rightarrow \infty} \frac{\text{Var}[\theta^*]}{\epsilon^2}$ (切比雪夫不等式) $\approx \lim_{t \rightarrow \infty} \frac{1}{tI(\theta_0)\epsilon^2} = 0$ 。证毕。□

图 3: (a) 新能力估计方法的无偏性。可惜，估计 θ^* 仍可能远离真实值。(b) 估计量 θ^* 的方差随测验步 t 增大而不断收缩 (即有效性)，并环绕真实值 (即无偏性)。

这一致性性质直观地意味着：步数 t 越大， θ^* 与 θ_0 之差超过任何固定值的机会就越小。因此， θ^* 的分布越来越集中在真实能力 θ_0 周围。

5.2 与其他方法的关系

我们讨论所提 RAT 与另两种相关方法——集成学习 (Ensemble Learning) 与蒙特卡洛方法 (Monte Carlo Method) ——的关系。

5.2.1 集成学习 长期以来，集成学习在广泛任务上被公认为比单一模型更鲁棒、更准确。其经典技术包括装袋 (Bagging) 和提升 (Boosting)。一般认为，要得到好的集成，基模型应当既准确又多样，这与我们所提方法的思想相似。差异体现在两方面。(1) 准确性：集成学习关注的是准确的预测 (即模型输出)，而我们的方法关注的是参数估计的准确性。(2) 多样性：集成学习中的多样性以隐式方式维持 (如实例采样、实例加权、不同的参数初始化)，而我们的方法在优化式 (6) 中加入多样性正则项以显式控制其多样性。

5.2.2 蒙特卡洛方法 蒙特卡洛方法 (或采样方法) 是一类用于近似求解问题的技术，其根本在于使用独立随机采样。从这一视角看，在第 t 步，CAT 中的能力估计可被视为在「由用于估计的前 t 次作答所确定的区域」内采样 $\hat{\theta}_t$ 。如果我们在第 t 步改为用 m 份互不重叠的作答数据采样 $\{\hat{\theta}_1^t, \hat{\theta}_2^t, \dots, \hat{\theta}_m^t\}$ ，且 $m \rightarrow \infty$ ，那么由大数定律，真实值 θ_0 可用它们的平均 $\frac{1}{m} \sum_{i=1}^m \hat{\theta}_i^t \approx \theta_0$ 来近似。然而，有限的作答数据会导致这些估计高度相关/相似 (并非独立采样)，从而导致近似很差。因此，借助 RAT 中的多样性正则， m 个估计被强迫彼此多样，努力逼近理想的蒙特卡洛方法。

表 1: 数据集统计信息。

数据集	Math	Junyi	Eedi
学生数	4,211	61,027	263,568
题目数	472	22,726	27,613
作答记录数	100,833	13,578,787	19,752,063
人均作答记录数	24.0	222.5	74.9
题均作答记录数	213.6	597.5	715.3

6 实验

本节在三个真实世界数据集和带扰动的合成数据上进行定量与定性实验，以评估我们通用方法 RAT 的有效性。

6.1 实验设置

6.1.1 数据集 我们在三个教育基准数据集 Junyi、Eedi、Math 上进行实验。Junyi 来自 junyiacademy.org，包含其平台上一学年（2018-2019）内数百万次练习作答日志。Eedi 指 NeurIPS 2020 教育挑战赛中的数据，采集自 Eedi 平台两个学年（2018-2020）学生对题目的作答，该平台每天有全球数百万学生互动。Math（原文中也称 EXAM 数据集）由科大讯飞（iFLYTEK Co., Ltd.）提供，包含数学练习与高中考试日志。完整统计信息见表 1。数据集可在 <https://github.com/bigdata-ustc/EduData> 找到。

6.1.2 评测方法 遵循通用策略，我们按学生以 7:2:1 的比例把学生-题目交互划分为训练、验证、测试集。验证/测试集中的学生不会出现在训练集中，符合标准 CAT 设定。训练集主要用于初步学习 CDM 中题目的某些预固定参数（如难度），以及某些数据驱动的选题算法基线（如 BOBCAT）。

在验证/测试中，每个学生 i 的作答进一步划分为候选集 ($\mathcal{Q}_i$) 和元集 (meta, $\mathcal{M}_i$) 以模拟 CAT 过程。具体来说：(1) 不同选题算法先从 $\mathcal{Q}_i$ 中选一题；(2) CDM 随后用对应作答更新能力估计；(3) 在留出的元集 $\mathcal{M}_i$ 上预测二值作答来评估该估计的准确性。换言之，选题算法越好，越可能选出最契合的题目来提升估计准确性。因此，从这一二分类视角，我们使用预测准确率 (Prediction Accuracy, ACC) 和 ROC 曲线下面积 (Area Under ROC Curve, AUC) 来评测不同选题算法。所有方法在两块 2.20 GHz Intel Xeon E5-2650 v4 CPU 和一块 TITAN Xp GPU 上开发与训练。

6.1.3 对比方法 由于如上所述选题算法必须依赖 CDM，我们选用两个经典 CDM：项目反应理论 (IRT) 和基于深度学习的模型 (如 NCDM)。不同 CDM 的代码可在 <https://github.com/bigdata-ustc/EduCDM> 获取。我们采用以下当前最优选题算法作为基线：

- **Random**: 随机选题策略，作为衡量其他方法改进幅度的基准。
- **FSI**: 选出费舍尔信息最大的题目，是使用最广泛的选题算法之一。专为 IRT 设计。
- **KLI**: 利用 KL 信息度量能力两个连续后验之间的散度。也专为 IRT 设计。
- **MAAT**: 一种基于主动学习的方法，通过计算每道候选题对 CDM 造成的「期望模型变化 (Expected Model Change, EMC)」来度量对个体学生的不确定性。它与底层 CDM 无关 (agnostic)。
- **BOBCAT**: 最近提出的方法，把 CAT 重构为一个双层优化 (bilevel optimization) 问题，并通过元/强化学习优化。因此它直接从大规模学生作答数据中学习一个数据驱动的选题算法。遵循其设定，我们使用一个全连接网络 (2×256 隐藏层、Tanh 非线性、softmax 输出层) 作为选题算法。它也与底层 CDM 无关。

注意，我们的通用方法 RAT 可应用于除 BOBCAT 之外的所有选题算法 (记为 X+RAT)，因为 BOBCAT 改变了 CAT 的原始范式。同时，BOBCAT 是相关工作中最近提出的唯一基于深度学习的基线，相关工作中的其他强化学习方法无法在真实世界数据集上验证。此外，为进一步验证 RAT 的有效性，我们还与强大且通用的集成方法 (即 Bagging 和 AdaBoost) 做了对比。

6.1.4 实现细节 我们用 PyTorch 实现所有方法，并用 Adam 算法优化。批大小固定为 128，学习率在整个过程中固定为 0.001。由于 20 步足以满足标准 CAT，我们设最大测验长度 $T = 20$ 。每步估计数 m 设为 5，估计形式中的超参数 λ 设为 0.1。关于 m 和 λ 的更详细分析见第 6.4 节。

6.2 与基线的比较

我们在三个数据集上计算 ACC 和 AUC 分数进行评测，表现见表 2。由此得到以下关键发现。

表 2: 不同方法在「学生表现预测 (Student Performance Prediction)」上以 ACC 和 AUC 度量的表现。「-」表示基于信息/不确定性的选题算法 (如 FSI) 无法应用于深度学习 CDM (NCDM)。(此处为原文表 2，含 Junyi/Eedi/Math 三数据集、IRT/NCDM 两 CDM、step 5/10/20 三测验步下各方法的 ACC 与 AUC，结构复杂，详见原文。要点: X+RAT 普遍优于不加 RAT 的基线约 1.0~2.0 个百分点。)

- **发现 1**——应用了我们方法的选题算法 (X+RAT) 在三个数据集上几乎优于所有基线。表 2 显示，X+RAT 相比不加 RAT 的基线取得 1.0~2.0 的 ACC/AUC 提升。例如 MAAT+RAT 相比基线 MAAT 平均提升 1.61 个 AUC 点，清楚展示了 RAT 的有效性与通用性。特别是，我们的 MAAT+RAT 在 Eedi 上还超过了需要在大规模学生作答数据上额外训练的强模型 BOBCAT。
- **发现 2**——深度学习方法 (BOBCAT) 的实力不可小觑。X+RAT 和 BOBCAT 谁也无法稳定压制对方，二者各有所长。BOBCAT 在测验初期 (即 step 5) 表现与 RAT 方法相近，甚至在 Junyi 数据集上用 NCDM 时超过了所有 RAT 方法。这可能是因为它在元学习框架中利用了神经网络，善于缓解冷启动问题。此外，测验初期作答缺乏，会因更大的不确定性而限制包括 RAT 在内的所有算法。尽管基于深度学习的模型在真实 CAT 场景 (即每天有海量题目上传) 中不实用，但把所提 RAT 改造来增强它们是很有前景的未来工作。

- **发现 3**——传统方法有相近的潜力与容量，此前可能被传统估计方法所束缚。从表 2 看，我们的 RAT 框架提升了所有类型选题算法基线的表现，例如在 Math 上 (step 20, IRT) 相比 KLI 和 MAAT 两个基线分别提升 1.43 和 1.34 个 ACC 点。有趣的是，当基线模型不那么强时能取得更多提升，例如相比非常经典且广泛使用的 FSI 基线，平均取得 2.07 的 ACC 增益。结果是，(FSI, KLI, MAAT)+RAT 把各自基线提升到几乎相同的水平，从它们旗鼓相当的表现就能看出。这些发现启发我们：1) 传统能力估计方法生成的查询束缚了这些算法，而它们本质上有相近的容量与潜力；2) 我们可用 RAT 强化这些较弱的方法，尤其当它们必须部署在数据有限、有时延的场景中时。

6.3 进一步研究

在与基线比较之后，我们将进一步介绍能力估计的模拟实验（定量）、估计的可视化（定性），以及与强大集成方法的比较。

6.3.1 猜测与失误下的能力估计模拟 遵循 CAT 的传统评测方法，由于学生能力 θ_0 的真值不可得，我们人为生成 θ_0 并用简单 IRT 模拟学生-题目交互过程。为进一步验证 RAT 的鲁棒性，我们让这个模拟 CAT 暴露在各种扰动下：

- **猜测 (Guess) 因素**：面对一道有 4 个选项的选择题时，即便学生没掌握，也有 25% 的机会答对。（标签以 25% 概率从 0 改为 1。）
- **失误 (Slip) 因素**：可能有小概率（如 5%）意外或粗心地答错本可解出的题。（标签以 5% 概率从 1 改为 0。）

我们用在真实数据集 Eedi 上训练得到的题目和学生参数作为真值，而非凭空生成。两种噪声水平下的结果见图 4。当步数增加时，所有方法 MSE 度量 $\mathbb{E}\|\hat{\theta} - \theta_0\|^2$ 稳步下降，且 RAT 取得明显更优的表现。基线与 RAT 之间的性能差距也呈增长趋势。在更高噪声水平下（图 4(b)），所有方法 MSE 在最初几步略有上升，但最终都获得了一致改善。这些观察表明，即使在各种扰动下我们的 RAT 仍能让选题表现获益。它也促使我们更关注学生-题目之间的复杂关系，这可能是提升 CAT 效率的关键。总之，它清楚表明 RAT 通过在每步融合 m 个估计，提供了对学生能力的鲁棒估计。

图 4：模拟 CAT 过程中两个不同噪声水平下的 MSE 曲线：(a) 猜测 25% (4 选 1)、失误 5%；(b) 猜测 50% (判断题)、失误 10%。

6.3.2 估计分析 为深入分析学生的多面能力估计，我们把模拟过程中每一步生成的所有估计可视化。为直观观察它们的相关性和 RAT 中的动态过程，我们采用二维 IRT，随机选 50 名学生输出其在该过程中的估计 ($m = 5$)。如图 5 所示，我们用不同颜色表示每个学生：不透明色表示其真实能力 θ_0 ，半透明色表示 m 个估计。一方面，借助式 (6) 中的多样性正则项，每一步的多个估计是多样的，分布相对均匀。另一方面，初始阶段所有可能能力的范围很大；随着步数增加，它们的范围逐渐收缩并逼近真实 θ_0 。因此，这些观察进一步证明了 RAT 中新能力估计方法的有效性。

图 5：用 RAT 在第 5、10、15、20 步对 50 名学生能力估计的可视化。不同颜色代表不同学生：不透明色代表其真实能力 θ_0 ，半透明色代表 m 个估计 ($m = 5$)。

6.3.3 RAT 与集成方法的对比 如第 5.2 节所述，我们所提方法与集成学习在形式上有相似之处。因此，表 3 展示了与两种通用且强大的集成方法——Bagging 和 AdaBoost——的比较。RAT 中的基线算法 (MAAT) 持续超过另两种集成方法。相对于 MAAT+Bagging 的相对提升在 ACC 上为 2.08%，相对于 MAAT+AdaBoost 的相对提升可达 2.58%。在 MSE 上的优势更为突出，MAAT+RAT 取得当前最优的 MSE 分数，性能提升至少 14.29%。令人意外的是，在其他任务（如计算机视觉 CV、推荐系统 RS）中表现出色的集成方法在 CAT 上效果甚微。这可能有两个原因：1) 作答/训练数据稀缺：集成学习的优势建立在大规模训练样本上；面对 CAT 中每个学生的作答（至多 20 条），它们容易过拟合。2) 目标不同：传统集成学习的目标是预测的准确性，而 CAT 追求的是准确的参数估计（详见第 5.2 节）；这一点从表 3 的 MSE 对比中可清楚验证。简而言之，与集成方法相比，RAT 更不易过拟合，更适合 CAT 应用场景。

表 3：在 Math 数据集上用 NCDM、step 20 时与集成方法的比较。

度量	ACC	IMP(%)	AUC	IMP(%)	MSE	IMP(%)
MAAT	82.81	2.70	78.90	2.19	0.47	23.40
MAAT+AdaBoost	82.91	2.58	79.23	1.77	0.42	14.29
MAAT+Bagging	83.32	2.08	79.55	1.36	0.42	14.29
MAAT+RAT	85.05	—	80.63	—	0.36	—

6.4 参数敏感性

这里我们探讨方法中两个重要超参数的敏感性：多样性正则权重 λ 和每步估计数 m 。

6.4.1 权重 λ 的影响 我们在 $\{0.001, 0.01, 0.1, 0.5, 1, 10\}$ 中变化 λ 进行实验。如图 6(a) 所示，小 λ （如 0.001）的表现不如大 λ （如 0.1），这意味着估计时应更重视多样性正则。然而，当 λ 持续增大时，表现反而下降。原因是过大的多样性正则则会引入更多随机性、降低准确性，验证了定理 1 中关于 λ 的条件。最佳的平衡选择是 $\lambda = 0.1$ 。

6.4.2 估计数 m 的影响 图 6(b) 报告了估计数的影响。我们在集合 $\{1, 3, 5, 10, 20, 50\}$ 中变化 m 。我们发现当 m 大于 5 时 RAT 对该超参数不敏感。这一观察确保了 m 不需要很大就能取得较好表现，尽管理论是建立在 $m \rightarrow \infty$ 上的。此外，这一结论还揭示 RAT 可通过使用相对较小的 m 在性能与计算开销之间取得进一步平衡。

图 6: 关于权重 λ 和估计数 m 的参数敏感性。

7 结论

本文聚焦于个性化在线教育的基础，提出了一个用于教育测量的通用优化准则 RAT。它是一种简单却非常有效的方法，通过为个体学生融合多个能力估计，缓解了 CAT 缺乏鲁棒性的问题。理论上，我们证明了 RAT 中的新估计量具备高度理想的统计性质：渐近无偏性、有效性与一致性。实验结果表明，即使在高噪声率下，RAT 在缩短测验长度方面仍保持强劲表现。此外，详尽的比较证明：与设计另一个精巧的选题算法相比，增强选题中的查询同样能取得有竞争力的表现。在未来工作中，我们将把方法应用到其他数据集与应用上。

致谢

本研究部分受到以下资助：国家重点研发计划（项目号 2021YFF0901003）、国家自然科学基金（项目号 61922073、U20A20229、62106244）、中央高校基本科研业务费（项目号 WK2150110021）。

参考文献 (*References*) 按约定未翻译，详见原文。