

全自适应框架：面向在线教育的神经计算机自适应测试 (Fully Adaptive Framework: Neural Computerized Adaptive Testing for Online Education)

原文: 03296-ZhuangY.pdf (AAAI-22, Yan Zhuang 等, 中国科学技术大学) ·译者: Claude ·译于 2026-06-26
语对照: Computerized Adaptive Testing 计算机自适应测试 (CAT) ; Cognitive Diagnosis Model 认知诊断模型 (CDM) ; Selection Algorithm 选题算法; Item Response Theory 项目反应理论 (IRT) ; proficiency 能力/熟练度; bilevel optimization 双层优化; Reinforcement Learning 强化学习 (RL); Performance Learning 表现学习 (PL); Contradiction Learning 矛盾学习 (CL)。

摘要

计算机自适应测试 (Computerized Adaptive Testing, CAT) 是在线教育中一种高效、个性化的测试模式，目标是在所需的学科/领域上准确测量学生的能力水平。CAT 的核心组件是“自适应”的选题算法 (question selection algorithm)，它根据学生当前估计出的能力，自动为其挑选最合适的题目，从而缩短测试长度。现有算法依赖一些人工设计且预先固定的题目“信息量/不确定性”度量来选题，这既费人力，也不足以刻画学生与题目之间复杂的关系。本文提出一个全自适应框架，命名为神经计算机自适应测试 (Neural Computerized Adaptive Testing, NCAT)，它把 CAT 形式化地重新定义为一个强化学习 (reinforcement learning) 问题，直接从真实世界数据中学习选题算法。具体而言，我们定义了一个双层优化 (bilevel optimization)，并在 CAT 的应用场景下对其加以简化，使算法可学习。进一步地，为了有效地求解 CAT 任务，我们把它当作一个等价的强化学习问题来处理，并提出一种注意力神经策略 (attentive neural policy) 来建模复杂的非线性交互。在真实世界数据集上的大量实验，证明了 NCAT 相比若干最先进方法的有效性与鲁棒性。

引言

计算机自适应测试 (CAT) 是一种新颖且有前景的测试模式，它提供了一种高效的方式，仅用很少的题目就能准确测量学生在某一特定领域（例如数学）的能力/熟练度水平。与传统的纸笔测试相比，CAT 通过为每位考生量身定制一套个性化的测试流程，效率高得多 (Cheng 2009; Wang et al. 2016)。因此，它被广泛用于各种标准化考试，例如 GRE。CAT 中的“自适应”指的是：根据每位学生当前估计出的能力，为其选择最合适的题目。

为实现这种自适应性，CAT 通常需要两个交替工作的核心组件：(1) 认知诊断模型 (Cognitive Diagnosis Model, CDM) 和 (2) 选题算法 (Selection Algorithm)。图 1 给出了一个典型 CAT 的示意例子。在测试的每一步（用 t 索引），(1) CDM 首先根据此前的作答估计学生当前的能力。其中最著名的是项目反应理论 (item response theory, IRT)：

$$P(a_{i,j} = 1) = \sigma [\alpha_j(\theta_i - \beta_j)], \quad (1)$$

其中 $\sigma[\cdot]$ 是 logistic 函数， $a_{i,j}$ 是学生 i 对题目 j 的作答 (1 表示答对)。每道题用两个预先标定好的参数 $\alpha, \beta \in \mathbb{R}$ 表示，分别称为区分度 (discrimination) 和难度 (difficulty) (Embretson and Reise 2013)。IRT 用一个潜在能力 $\theta \in \mathbb{R}$ (称为 ability) 来表示学生的作答。最近，基于深度学习的 CDM (Wang et al. 2020a) 用信息更丰富的多维向量来表示这一能力 θ 。(2) 选题算法随后根据 CDM 给出的当前能力估计 $\hat{\theta}_i^t$ 来选择下一题。大多数算法是“模型相关 (model-specific)”的，由专家根据不同 CDM 的特性专门设计。例如，(Chang 2015) 提出了专门为 IRT 设计的最大 Fisher 信息量法 (Maximum Fisher Information, MFI)，它倾向于选择高分度、且难度接近学生能力估计的题目（即式 (1) 中更高的 α 以及 $\beta = \theta$ ）。

图 1：典型 CAT 流程示意图。

然而，这类选题算法的自适应性在三个方面受到限制：

- **对学生而言**：选题算法的效率严重依赖当前估计 $\hat{\theta}$ 的准确性。因此它缺乏鲁棒性，用单一的 θ 去概括学生与题目之间的复杂交互，可能造成严重的信息损失 (DiBello, Roussos, and Stout 2007)。
- **对 CDM 而言**：我们必须详细了解某个具体 CDM 的工作机制，才能设计出与之匹配的选题算法（即模型相关）。尽管许多主动学习 (active learning) 方法 (Bi et al. 2020) 利用 CDM 的输出不确定性来实现模型无关 (model-agnostic)，但各个 CDM 的不同特性也被忽略了。
- **对题目而言**：这类预定义算法在选题时通常有各自的“偏好”（例如用 MFI 时高分度的题目被选中的频率相对较高），这不可避免地会影响曝光控制 (exposure control)，降低测试的安全性 (Segall 2005)。

我们没有去手工设计另一套复杂的选题算法，而是提出一个全自适应框架，命名为神经计算机自适应测试 (NCAT)。它把 CAT 看作一个强化学习问题，试图从大规模学生作答数据中学习出一套神经算法。在我们的框架中，为了让选题算法可学习，并直接捕捉学生交互与给定 CDM 的特性，我们仿照元学习 (meta-learning) 方法 (Ghosh and Lan 2021)，把它重新定义为一个双层优化的目标。随后，为了模拟 CAT 中的动态交互并有效求解该优化问题，我们将其形式化地转化为一个等价的强化学习问题，进一步控制题目曝光率。接着，我们提出一种神经选题算法来建模学生与题目之间复杂的非线性交互，其中设计了两个注意力模块：1) 双通道表现学习 (Double-channel Performance Learning, PL) 模块，分

别捕捉学生多样化表现的信息；2) 矛盾学习 (Contradiction Learning, CL) 模块，进一步识别并提取学生表现中的扰动（例如猜测因子和失误因子）。最后，我们用高效的 Q-learning 来优化该算法，以选择下一题。

在三个真实世界数据集上的大量实验，证明了 NCAT 的有效性，即用最少的题目准确测量学生能力。此外，即便在高噪声率下它仍然鲁棒，并且在 CAT 设定下实现了曝光控制。

相关工作

计算机自适应测试。 CAT 由两个组件构成：认知诊断模型 (CDM) 和选题算法。两者交替工作，直到测试结束（依据特定停止规则），然后输出最后一步估计出的学生能力水平，以可视化的方式反馈给学生本人或老师，以改进未来的学习。CAT 的目标是用尽可能少的题目准确测量学生的能力 (Chang 2015)。因此，CAT 也是一个参数估计过程。选题算法是 CAT 的核心组件。长期以来，大多数算法都是专门为 IRT 模型设计的，例如最大 Fisher 信息量法 (MFI) (Lord 2012)、Kullback-Leibler 信息指数 (KLI) (Chang and Ying 1996)，以及它们的多元扩展 (Hooker, Finkelman, and Schwartzman 2009; Rudner 2002)。最近，MAAT (Bi et al. 2020) 和 BOBCAT (Ghosh and Lan 2021) 分别利用主动学习和元学习中的双层优化来设计算法，它们在基于深度神经网络的 CDM (Wang et al. 2020a) 上表现出良好的性能与自适应性。然而，这些方法无法适应真实的 CAT 场景，例如 BOBCAT 没有考虑学生一题目交互中的复杂性，也无法在应用中保持曝光均衡。

强化学习。 强化学习 (RL) 训练模型去做出一系列决策。为了让模型做我们想要的事，模型会因其执行的动作而获得任务相关的奖励 (reward)。RL 智能体的目标是学到一个策略 π ，使轨迹的期望累积奖励最大化。深度强化学习作为最先进的技术之一 (Arulkumaran et al. 2017)，已在许多领域展现出卓越能力，如游戏 (Hessel et al. 2018; Rajeswaran, Mordatch, and Kumar 2020)、机器人 (Hu et al. 2020; Haarnoja et al. 2018) 和推荐系统 (Chen et al. 2019; Zhao et al. 2021)。把 RL 应用到 CAT 的最大困难在于奖励的定义，它要能促使选题算法从数据中学习并适应给定的 CDM。例如，尽管 (Nurakhmetov 2019; Li et al. 2020) 提出了用强化学习来学习选题算法/策略的方法，但它们无法在真实世界数据集上得到验证。

神经计算机自适应测试框架

本节我们首先从双层优化的视角形式化 NCAT 中可学习的选题算法，然后将其转化为一个等价的强化学习问题以便高效求解。

问题陈述 (Problem Statement)

对每位学生而言，能力水平记为 $\theta \in \mathbb{R}^d$ ， θ_0 是她的真实值（未知），其中 d 指能力水平的维度（例如待测知识概念的数量）。在测试过程中，她已作答的题目 q 记为一个二元组 (q, a) ，若答对则 $a = 1$ ，否则 $a = 0$ 。接下来给出如下定义：

典型 CAT 流程。 给定题库 $\mathcal{J} = \{q_1, q_2, \dots, q_{|\mathcal{J}|}\}$ ，一个完整的 CAT 系统包含两个组件：(1) 一个 CDM $\mathcal{M}$ ，通过预测学生答对题目 q 的概率（二分类）来建模她的能力，记为 $\mathcal{M}(q|\theta) \in [0, 1]$ ；(2) 一个选题算法 π ，根据 $\mathcal{M}$ 中当前的估计 $\hat{\theta}$ 从 $\mathcal{J}$ 中选题。更具体地，在第 $t \in [1, T]$ 步，CAT 为学生选出一题 $q_t \sim \pi(\hat{\theta}^{t-1})$ 。收到作答 a_t 后， $\mathcal{M}$ 更新并估计出新的能力 $\hat{\theta}^t$ 。上述过程重复 T 步。在定长 (fixed-length) 设计中 T 对所有学生相同，变长 (variable-length) 设计中则不然。CAT 的目标是当测试结束时让估计能力接近 θ_0 ，即 $\hat{\theta}^T \rightarrow \theta_0$ 。

可学习的选题算法 (The Learnable Selection Algorithm)

我们不去手工设计选题算法，而是把它定义为一个优化目标，直接从大规模作答数据中学习，并应用到新学生身上。具体而言，可学习的选题算法在元学习设定下定义 (Finn, Abbeel, and Levine 2017; Lee et al. 2019)：设 n 为我们用于训练该算法 π 的作答数据集中的学生数量。学生 i 的作答进一步被随机划分为支持集 (support set) D_s^i 和查询集 (query set) D_u^i ，其中 π 顺序地选出共 t 道题 $\{q_1, \dots, q_t\}$ 及对应的作答（即 D_s^i ）来估计能力，并用它在查询集 D_u^i 上优化 π 。遵循元学习中的双层范式 (Franceschi et al. 2018; Ghosh and Lan 2021)，NCAT 中的选题算法 π 被重新定义为双层优化的目标：

$$\pi^* = \arg \min_{\pi} \frac{1}{n} \sum_{i=1}^n \sum_{t=1}^T \frac{1}{|D_u^i|} \sum_{(q,a) \in D_u^i} l(a, \mathcal{M}(q|\hat{\theta}_i^t)), \quad (2)$$

$$\text{s.t. } \hat{\theta}_i^t = \arg \min_{\theta_i} \sum_{(q,a) \in D_s^{i(t)}} l(a, \mathcal{M}(q|\theta_i)), \quad (3)$$

其中 $D_s^{i(t)} = \{q_1, a_i(1), \dots, q_t, a_i(t)\}$ 且 $q_t \sim \pi(q_1, a_i(1), \dots, q_{t-1}, a_i(t-1))$ 。

在内层优化（式 (3)）中，学生 i 的支持集 $D_s^{i(t)}$ 由算法 π 根据她此前的作答顺序选出；我们随后在 $D_s^{i(t)}$ 上最小化二元交叉熵损失 $l(\cdot)$ ，为外层估计出能力 $\hat{\theta}_i^t$ 。在外层优化（式 (2)）中，我们在学生的查询集 D_u^i 上最小化二元交叉熵损失，从而在给定当前 $\hat{\theta}$ （由内层估计）的情况下学习目标选题算法 π 。

这一双层优化具有以下理想特性：(1) 能力估计的误差主要由所选题目的差异造成，这进一步引导 π 的优化。由于真实 θ_0 未知，我们用估计 $\hat{\theta}_i^t$ 在查询集上的拟合程度来在外层度量这种误差（Chen, de la Torre, and Zhang 2013）。(2) 由于测试可能根据不同停止规则在任意时刻/步停止，我们对目标进行了简化，把所有测试步求和来最小化损失，这些解法与之前基于双层优化的方法 BOBCAT（Ghosh and Lan 2021）不同。(3) 算法 π 也是模型无关的。更重要的是，通过求解该问题，它能自动适应给定的 CDM $\mathcal{M}$ 以实现高效选题。一旦选题算法学好，它在 CAT 过程中无需再更新，并能根据此前的作答自适应地选择下一题。

强化学习形式化 (Reinforcement Learning Formulation)

在上述形式化中，我们注意到选题算法 π 可以通过求解一个优化问题来学习。形式上，目标式 (2) 可以转化为：

$$\min_{\pi} \frac{1}{n} \sum_{i=1}^n \sum_{t=1}^T \frac{1}{|D_u^i|} \sum_{(q,a) \in D_u^i} l(a, \mathcal{M}(q|\hat{\theta}_i^t)) \triangleq \max_{\pi} \mathbb{E}_{i \sim \pi} \left[\sum_{t=1}^T \frac{-1}{|D_u^i|} \sum_{(q,a) \in D_u^i} l(a, \mathcal{M}(q|\hat{\theta}_i^t)) \right] = \max_{\pi} \mathbb{E}_{i \sim \pi} \left[\sum_{t=1}^T -L_{\mathcal{M}}(D_u^i, \hat{\theta}_i^t) \right], \quad (4)$$

其中 $L_{\mathcal{M}}(\cdot)$ 是给定预测器 $\mathcal{M}$ 时在查询集上的平均二元交叉熵损失。于是，双层优化被转化为在强化学习设定下最大化期望累积奖励（即 $-L_{\mathcal{M}}(D_u^i, \hat{\theta}_i^t)$ ）。

具体地，作为一个 RL 问题，马尔可夫决策过程 (MDP) 中的 $\langle S, A, P, R, \gamma \rangle$ 定义如下：(1) 状态集 S 是状态的集合， $s_t \in S$ 是 CAT 在第 t 步对学生 i 所拥有的可用信息/作答，即 $s_t = \{q_1, a_i(1), \dots, q_{t-1}, a_i(t-1)\}$ 。(2) 动作集 A 是题库 $\mathcal{J}$ 。每道题/动作对每位学生/每条轨迹至多被选一次。(3) 转移 P 是转移函数， $P(s_{t+1}|s_t, q_t)$ 表示在 s_t 处采取动作 q_t 后到达状态 s_{t+1} 的概率。在 CAT 中，不确定性来自学生第 t 步作答的对错 $a_i(t)$ 。(4) 奖励 R 是第 t 步学生 i 在查询集上估计能力的负损失，即 $r_i^t = -L_{\mathcal{M}}(D_u^i, \hat{\theta}_i^t)$ ，由式 (4) 导出。图 2(a) 给出了 NCAT 框架的总览。

如此一来，CAT 被当作一个决策过程：给定学生此前的作答和一个具体的 CDM，哪道题最适合用来准确测量她的能力。实际上，学生作答的转移、能力估计、以及选题算法的决策过程彼此影响、相互依赖，演变成一个复杂的系统。因此，相比把 CAT 的动态视为一个整体优化过程，RL 框架能以长远眼光为不同学生探索更多可能的“最契合”题目。例如，相比基于学生此前作答的贪心选择，充分且多样的题目组合通常能更全面、更准确地测量学生能力（Bi et al. 2020; Liu et al. 2019），这一点将在实验中验证。

注意力神经选题算法 (Attentive Neural Selection Algorithm)

基于上述强化学习中的 NCAT 框架，我们用一个分层注意力神经网络 (hierarchical attentive neural network) 来实现其中的选题算法，以建模学生与题目之间复杂的交互。图 2(b) 展示了它的结构，主要由一个双通道表现学习 (PL) 组件、一个矛盾学习 (CL) 组件和一个策略层 (policy layer) 构成。首先，PL 分别捕捉学生多样化表现的信息，因为学生答对和答错的作答通常是不均衡的（即答错的通常远少于答对的）（Zhou et al. 2021）。其次，CL 识别并提取学生表现中的矛盾，试图缓解扰动（即猜测因子和失误因子）的影响。最后，策略层做出下一步选择，并用著名的 Q-learning 算法来优化策略。

题目嵌入 (Question Embedding)：给定学生 i 的当前状态 $s_t = \{q_1, a_i(1), \dots, q_{t-1}, a_i(t-1)\}$ ，整个题目集合 $\{q_j\}$ 通过把每个 $q_j \in \mathcal{J}$ 嵌入到连续空间，被转换为维度为 d 的嵌入向量 $\{\mathbf{q}_j\}$ ，这是一个嵌入矩阵 $E \in \mathbb{R}^{|\mathcal{J}| \times d}$ 。由于学生在同一题上的不同作答（答对和答错）提供不同信息，每道题有各自独立的表示： E_1 和 E_0 分别是答对与答错的嵌入矩阵。

双通道表现学习 (Double-Channel Performance Learning)

为了更好地建模学生表现（即观测 s_t ），我们首先用双通道自注意力 (self-attention) 块来独立处理答对和答错的作答，如图 2(b) 所示。设 k_1 和 k_0 分别表示第 t 步答对和答错的题目数量。把已作答的题目记为两个嵌入矩阵 $E_t^z = [\mathbf{q}_1^z, \mathbf{q}_2^z, \dots, \mathbf{q}_{k_z}^z]^\top$ ， $z \in \{0, 1\}$ （1 表示答对，0 表示答错）。 E_t^z 输入到自注意力块，该块一般由两个子层构成，即一个自注意力层和一个逐位置前馈网络 (point-wise feed-forward network)。具体地，自注意力定义为：

$$S_t^z = \text{Attention}(E_t^z W_1^{z,c}, E_t^z W_1^{z,k}, E_t^z W_1^{z,v}),$$

其中投影矩阵 $W_1^{z,c}, W_1^{z,k}, W_1^{z,v} \in \mathbb{R}^{d \times d}$ 是对应的可学习参数。注意力函数由缩放点积 (scaled dot-product) 运算实现：

$$\text{Attention}(C, K, V) = \text{softmax} \left(\frac{CK^\top}{\sqrt{d}} \right) V,$$

其中 C, K, V 分别代表查询 (queries)、键 (keys)、值 (values) (Vaswani et al. 2017)。 $\frac{1}{\sqrt{d}}$ 是缩放因子，用于避免内积出现过大的值 (Zou et al. 2020)。

为了赋予该组件非线性、并考虑不同潜在维度之间的交互，我们对 S_t^z 施加一个逐位置前馈网络。计算定义为：

$$F_t^z = \text{FFN}(S_t^z) = \sigma(S_t^z W^{(1)} + b^{(1)}) W^{(2)} + b^{(2)},$$

其中 σ 是激活函数，这里我们使用 ReLU 函数；权重矩阵 $W^{(1)}, W^{(2)}$ 的形状为 $\mathbb{R}^{d \times d}$ ， $b^{(1)}, b^{(2)}$ 是偏置项。于是 $\{F_t^0, F_t^1\}$ 就是这个双通道表现学习组件的输出。

矛盾学习 (Contradiction Learning)

学生在 CAT 中行为的复杂性主要体现在猜测因子和失误因子上 (Vie et al. 2017; Liu et al. 2018; Gao et al. 2021)：例如，面对一道有 4 个选项的选择题，即便学生没掌握，也有 25% 的概率答对（即猜测因子）；面对一道简单题时，也可能有很小的概率（例如 5%）答错（即失误因子）。为了实现 CAT 的终极目标——测量学生真实的能力水平，选题算法应当识别并消除她表现中的这些扰动，以便更好地选题。

当猜测或失误因子发生时，答对与答错的作答之间可能存在某些矛盾。例如，学生答对了一道乘法题（较难），却答错了一道加法题（较简单）。那么可能的矛盾是：乘法题可能是猜中的，或加法题是失误，或两者皆有。我们设计了一种新颖的双注意力（dual-attention）操作来捕捉答对与答错作答之间的矛盾：

$$\alpha_{ij} = \frac{W_2^{0,c} \mathbf{q}_i^0 \cdot (W_2^{1,k} \mathbf{q}_j^1)^\top}{\sqrt{d}}, \quad (5)$$

其中 α_{ij} 是题目 $\mathbf{q}_i^0$ （答错）与 $\mathbf{q}_j^1$ （答对）的矛盾分数，权重矩阵 $W_2^{0,c}, W_2^{1,k}$ 的形状为 $\mathbb{R}^{d \times d}$ 。所有 α_{ij} 构成分数矩阵 $A \in \mathbb{R}^{k_0 \times k_1}$ 。接着，矛盾分数 A 分别从行和列两个维度用 softmax 函数归一化： $\tilde{\alpha}_{ij}^0 = \frac{\exp(\alpha_{ij})}{\sum_{j=1}^{k_1} \exp(\alpha_{ij})}$ 和 $\tilde{\alpha}_{ij}^1 = \frac{\exp(\alpha_{ij})}{\sum_{i=1}^{k_0} \exp(\alpha_{ij})}$ ，分别构成 $\tilde{A}^0, \tilde{A}^1 \in \mathbb{R}^{k_0 \times k_1}$ 。

为了进一步提取存在矛盾的题目对的信息，我们用表现学习中生成的矩阵 F_t^1 和 F_t^0 （即图 2(c) 中的 V_1 和 V_2 ）与分数矩阵 $\tilde{A}^0, \tilde{A}^1$ 分别做双注意力和前馈运算：

$$F_t^{10} = \text{FFN}(\tilde{A}^0 F_t^1), \quad F_t^{01} = \text{FFN}(\tilde{A}^1 F_t^0),$$

其中 $F_t^{10} \in \mathbb{R}^{k_0 \times d}$ 和 $F_t^{01} \in \mathbb{R}^{k_1 \times d}$ 分别是两个通道中题目的矛盾特征矩阵。

策略层 (Policy Layer)

最后，选题算法基于四个矩阵 $\{F_t^0, F_t^1, F_t^{01}, F_t^{10}\}$ 预测下一次选择的分数，这些矩阵经过多个注意力块自适应地提取了此前作答的信息。基于“学生能力在 CAT 过程中保持不变”的假设 (Wainer et al. 2000)，每条作答的顺序并不重要，于是我们对每个矩阵做平均池化 (average-pooling)，并把它们拼接成一个向量 $u_t \in \mathbb{R}^{4d}$ 。近似动作价值函数 (action-value function) 记为 $Q_\pi(s_t, \cdot) = (Q_\pi(s_t, q_1), \dots, Q_\pi(s_t, q_{|\mathcal{J}|}))$ ，可用一个前馈层表示：

$$Q_\pi(s_t, \cdot) = \sigma(u_t W^{(1)} + b^{(1)}) W^{(2)} + b^{(2)},$$

其中 $W^{(1)} \in \mathbb{R}^{4d \times d}$ ， $W^{(2)} \in \mathbb{R}^{d \times |\mathcal{J}|}$ 是权重矩阵， $b^{(1)} \in \mathbb{R}^d$ 和 $b^{(2)} \in \mathbb{R}^{|\mathcal{J}|}$ 是偏置项。一旦有了 $Q_\pi(s_t, \cdot)$ ，最优学习策略便随手可得，即 $\pi^*(s_t) = \arg \max_{q \in \mathcal{J}} Q_\pi(s_t, q)$ 。

题目选择 (Question Selection)。由于 CAT 的测试长度通常很短，使用确定性策略（即 $\arg \max_q Q_\pi(s_t, q)$ ）会限制所选题目的多样性。这不可避免地会影响曝光控制，损害测试安全性 (Segall 2005)。例如，当测试长度为 10、且所有学生的候选题与第一题都相同时，由于作答是二值的，所有测试中最多只会出现 $2^{10} - 1 = 1023$ 种不同的题目（路径）。因此，给定当前状态（即此前的作答），选择题目 q 的概率与其 Q 值成正比：

$$P(q|s_t) = \frac{e^{Q_\pi(s_t, q)/\nu}}{\sum_{q \in \mathcal{J}} e^{Q_\pi(s_t, q)/\nu}}, \quad (6)$$

其中 ν 是温度参数 (temperature parameter), 在测试过程中缓慢减小, 使选择在临近结束时更贪心。通过在测试开始时引入随机性, 不同的起点能丰富所选题目与测试路径。随着测试推进, 选择的确定性持续增加。当 $\nu \rightarrow 0$ 时, 式 (6) 等价于 $\arg \max Q_\pi$ 。显然, 完全随机化是最简单的曝光控制方法, 会带来相同的曝光率。然而, 它与“选择最契合题目以加速测量过程”的思想相冲突。测量准确性与曝光率之间的平衡将在消融实验中进一步研究。

策略学习 (Policy Learning)

我们用 Q-Learning (Mnih et al. 2013) 来学习策略 π (即上述网络中的所有参数)。为了得到良好的近似动作价值函数, 状态—动作空间需要被充分探索 (Li et al. 2020)。深度 Q-learning 算法采用所谓的 ϵ -贪心探索。具体地, 在第 t 步以概率 ϵ 选择一个随机动作, 以概率 $1 - \epsilon$ 选择贪心动作 q_t 。选题算法 π (由 φ 参数化) 可通过最小化如下均方损失函数来训练:

$$L(\varphi) = \mathbb{E}_{(s_t, q_t, r_i(t), s_{t+1}) \sim B} [(y_t - Q_\pi(s_t, q_t))^2],$$

$$y_t = r_i(s_t, q_t) + \gamma \max_{q_{t+1} \in \mathcal{J}} Q_\pi(s_{t+1}, q_{t+1}),$$

其中 γ 是折扣因子, y_t 是基于最优 Bellman 方程 (Sutton and Barto 2018) 的目标值。 $B = \{(s_t, q_t, r_i(t), s_{t+1})\}$ 是一个大的回放缓冲区 (replay buffer), 存储过去的经验, 样本以小批量 (mini-batch) 方式抽取用于训练。对损失函数关于 π 求导, 梯度为:

$$\nabla_\varphi L(\varphi) = \mathbb{E} [(y_t - Q_\pi(s_t, q_t)) \nabla_\varphi Q_\pi(s_t, q_t)].$$

实验

本节我们在三个真实世界数据集上进行大量实验, 以评估 NCAT 的有效性。我们主要聚焦回答以下研究问题: (RQ1) 在 CAT 设定下, NCAT 如何超越现有选题算法? (RQ2) NCAT 会选出什么样的题目? (RQ3) NCAT 是否很好地捕捉了学生与题目之间的复杂关系? (RQ4) NCAT 中各组件的影响如何?

实验设置

数据集。我们使用三个真实世界教育数据集, 即 ASSIST、EXAM 和 NIPS-EDU。ASSIST (Pardos et al. 2013) 采集自在线辅导系统 ASSISTments, 记录了学生在数学练习上的日志以及题目相关的知识概念。EXAM 采集自一个为学生提供作业、考试和评估的在线教育系统, 收集的是初中生在数学练习上的记录。NIPS-EDU (Wang et al. 2020b) 指 NeurIPS 2020 教育挑战赛中的数据, 采集自学生在 Eedi (一个教育平台) 上对题目的作答, 数据集可在 <https://github.com/bigdata-ustc/EduData> 找到。

数据划分与评估方法。我们对所有数据集进行 5 折交叉验证; 对每一折, 我们用 60%-20%-20% 的学生分别作训练、验证和测试。此外, 我们把每位学生作答的题目划分为支持集 (D_s^i , 70%) 和查询集 (D_u^i , 30%)。这些划分在每个训练 epoch 中也随机重新生成, 以防止过拟合。在测试中: 1) 我们用不同方法在 $\mathcal{J}_i$ 中选题; 2) CDM 用对应的作答更新估计; 3) 在查询集 D_u^i 上评估 CDM 预测二值学生作答的性能。因此, 我们同时用准确率 (ACC) 和 ROC 曲线下面积 (AUC) 作为指标来评估不同选题算法的性能。所有方法都在一块 Tesla K20m GPU 上开发和训练。

对比方法。如前所述, CAT 中的选题算法需要依赖认知诊断模型 (CDM)。我们的实验主要涉及两类经典 CDM: 传统的项目反应理论 IRT (Embretson and Reise 2013) 和近期提出的深度学习模型 (如 NCDM, Wang et al. 2020a)。不同 CDM 的代码可在 <https://github.com/bigdata-ustc/EduCDM> 获取。我们将 NCAT 与以下选题算法比较:

- **MFI** (Lord 2012): 最广泛使用的选题策略之一, 选择 Fisher 信息量最大的题目。该方法只依赖 IRT。
- **KLI** (Chang and Ying 1996): 用 Kullback-Leibler 信息量度量能力的两个相邻后验之间的散度。也依赖 IRT。
- **BOBCAT** (Ghosh and Lan 2021): 第一个用于 CAT 的双层优化框架, 采用一种近似梯度估计方法来学习数据驱动的选题算法。它与底层 CDM 无关。
- **MAAT** (Bi et al. 2020): 提出一种基于主动学习的方法, 通过计算每道题引起的期望模型变化 (Expected Model Change, EMC) 来度量题目的信息量。它也与底层 CDM 无关。
- **RAND**: 随机选题策略, 作为衡量其他方法改进幅度的基准。

图 3: 用覆盖率指标进行的多样性比较。左图是 IRT 上的结果, 右图是 NCDM 上的结果。

参数设置。由于 20 道题对一次典型测试已足够, 我们设最大长度 $T = 20$ 。CDM 中所有关于题目的参数 (如 IRT 中的难度和区分度) 都会用训练集提前估计好作为真值 (ground-truth), 如 (Chen, de la Torre, and Zhang 2013)。我们报告每个方法在验证集上最优超参数设置下的结果。我们设嵌入维度 $d = 128$, RL 算法的学习率为 0.001。式 (6) 中的温度参数 ν 设为 $2^{-0.1t}$, 在测试过程中缓慢减小。Q-learning 的回放缓冲区容量在实验中设为 10000。探索因子 ϵ 在训练过程中从 1 衰减到 0。

性能比较 (RQ1)

为验证选题算法的效率, CAT 中通常使用学生表现预测 (Student Performance Prediction) 任务。表 1 报告了不同方法在第 t 步选题后查询集上的平均准确率和 AUC 指标, 我们展示了测试第 5、10、20 步的结果。结果与我们的直觉相当一致, 有如下观察:

(1) 可以看到, NCAT 在三个基准数据集、所有步数上的准确率和 AUC 都取得最佳性能, 显著超越了最先进方法。这意味着我们提出的方法能快速捕捉学生的作答模式, 为他们选出最契合的题目, 并把这一策略迁移到新学生身上。

(2) NCAT 和 BOBCAT 都显著优于其他预先固定的选题算法 (如 MAAT)。这表明显式地从数据中学习选题算法能提升 CAT 的效率。与 BOBCAT 相比, 强化学习中的 NCAT 框架利用我们提出的注意力机制, 进一步提升了选题效率。

表 1: 不同方法在学生表现预测任务上的 ACC 与 AUC 指标性能。加粗表示相对最佳基线的统计显著改进 (即双侧 t 检验, $p < 0.01$)。 (此处为原文表 1, 含三数据集 $\times$ 两 CDM $\times$ 三步数的完整数值, 结构复杂, 正文未逐一转录; 要点见上文 (1)(2): NCAT 在所有设置下均最优, 例如 ASSIST/IRT 上 ACC@20 达 0.756、AUC@20 达 0.755, 均高于 BOBCAT。)

知识概念覆盖率 (RQ2)

为了更深入理解 NCAT, 我们仔细考察算法所选题目的特性。我们度量不同算法的概念覆盖率 (concept coverage), 即在每个测试步所选题目中覆盖的知识概念 (如数学中的代数与几何) 的比例 (Bi et al. 2020)。具体地, 设 $K = \{k_1, k_2, \dots, k_{|K|}\}$ 为与所有题目相关的知识概念集合。在第 t 步, 若与知识概念 k 相关的题目在所有已选题目 $\mathcal{J}_t$ 之中, 则记为 $k \in \mathcal{J}_t$ 。概念覆盖率指标为:

$$\text{Cov}(\pi) = \frac{1}{|K|} \sum_{k \in K} \mathbb{1}[k \in \mathcal{J}_t].$$

在图 3 中, NCAT 的覆盖率在测试过程中增长相对较快, 并逼近极限 1。直觉上, 最大化所选题目中的概念覆盖率, 能让对学生的测量和诊断更全面。结果验证了: 在 RL 框架中探索、并提升选题中的概念多样性, 能增强 CAT 的准确性, 而这正是 NCAT 所要做的。

复杂的练习交互 (RQ3)

作答中的矛盾。为了进一步说明对学生表现中矛盾的学习, 我们把式 (5) 中矛盾分数 A 的中间结果可视化。图 4(a) 展示了 EXAM 数据集上某学生在下一次选题前的 7 条作答 (4 对 3 错)。我们还展示了这些题目的相关信息, 包括其编号、难度 (由 IRT 估计) 和相关知识概念。 q_{2335} (答对) 与 q_{2348} (答错) 之间的矛盾分数高于其他对, 且答对的题比答错的题更难。这揭示出 q_{2335} 可能存在猜测因子、或 q_{2348} 存在失误因子、或两者皆有。同时, 尽管 q_{2335} 与 q_{4804} 在难度上的对比与上述类似, 但分数却低得多。这很直观: 它们之间知识概念的相关性低于 q_{2335} 与 q_{2348} , 因此忽略了它们的矛盾。这些观察表明, 我们提出的 NCAT 提供了一种很好的方式来捕捉题目与学生之间的复杂关系, 以便更好地选题。

带猜测与失误的能力估计。CAT 的终极目标是估计学生的能力 θ 。由于真实 θ_0 未知, 除了 RQ1 中的预测任务, 我们还采用仿真研究: 人为构造学生的能力 θ_0 并生成相应作答, 用于能力估计 (Linden, van der Linden, and Glas 2000)。于是我们用所有构造学生上的均方误差 (MSE) 来评估它, 即 $\mathbb{E} \|\hat{\theta} - \theta_0\|^2$ 。为了模拟真实测试场景、验证 NCAT 在猜测与失误因子下的鲁棒性: 当生成的作答为 0 时, 有 25% 概率被改为 1 (即猜测因子); 当作答为 1 时, 有 5% 概率被改为 0 (即失误因子)。我们在图 4(b) 展示 EXAM 上的 MSE。我们用简单的 IRT 进行此实验, 并用在整个数据集上学到的能力参数作为真值, 而非生成它们。可以看到, 即便存在多种扰动, NCAT 框架在 MSE 指标上仍表现良好, 进一步证实了它在能力估计上的高准确性与鲁棒性。

图 4: (a) 学生表现中矛盾分数矩阵的可视化及题目信息; (b) EXAM 数据集上随测试步增加、带猜测与失误因子的 MSE 比较。

消融实验 (RQ4)

由于我们的框架中有许多组件, 我们通过消融实验分析它们的影响。表 2 展示了默认方法及其 3 个变体在三个数据集上的性能。我们介绍这些变体并分析其作用:

(1) **NCAT-C 和 NCAT-P:** 它们是 NCAT 的变体, 分别只使用矛盾学习模块和表现学习模块。NCAT-C 只捕捉学生观测表现中的矛盾, 但禁用了表现学习生成的矩阵, 这显著降低了它的准确率。NCAT-P 表现比默认版差, 因为它忽略了学生表现中的扰动 (即猜测与失误因子)。这让我们可以稳妥地得出结论: 考虑矛盾方面来建模学生与题目之间的复杂交互是明智的。

(2) $\nu \rightarrow 0$: $\nu \rightarrow 0$ 意味着策略是确定性的, 即选择 Q 值最大的题目。换言之, 只考虑了测量准确性, 而不考虑曝光率。不出所料, 尽管其结果略好于默认设置, 但结合表 3 的结果, NCAT 在准确性与曝光控制之间取得了平衡。整体偏低的曝光率能有效保障测试的安全性与公平性。

表 2: 三个数据集上在 IRT 下的消融分析 (准确率 $T@20$)。‘↑’和‘↓’分别表示相对默认版的性能上升和下降。(默认版 ACC: ASSIST 0.7562、NIPS-EDU 0.7321、EXAM 0.8516; NCAT-C、NCAT-P 均下降, $\nu \rightarrow 0$ 略升。)

表 3: 用仿真研究 (ASSIST 数据集) 得到的不同方法题目曝光率 (均值)。MFI 14.4%、MAAT 13.9%、BOBCAT 16.3%、NCAT 5.2%、NCAT($\nu \rightarrow 0$) 15.1%。默认 NCAT 加粗, $\nu = 2^{-0.1t}$ 。可见默认 NCAT 的曝光率 (5.2%) 远低于其他方法。

结论

本文提出了一个全自适应的 CAT 框架 NCAT, 它提供了一种通用方式, 从真实世界数据中为在线教育学习选题算法。具体而言, 为了克服人工设计选题算法的局限, NCAT 被重新表述并在有效的强化学习设定下求解。此外, 我们提出一种注意力神经选题算法作为实现, 来建模测试中复杂的非线性交互。大量实验表明, NCAT 能成功捕捉学生与题目之间的复杂关系 (如猜测与失误因子), 并准确测量学生能力, 缩短测试长度。

致谢

本研究部分受国家自然科学基金 (No. 61922073, U20A20229)、中央高校基本科研业务费 (No. WK2150110021)、安徽省教育厅自然科学基金重点项目 (No. KJ2020A0036) 以及安徽省自然科学基金 (No. 2108085QF272) 资助。

参考文献 (References) 按约定未翻译, 详见原文。