

BOBCAT: 基于双层优化的计算机化自适应测验 (BOBCAT: Bilevel Optimization-Based Computerized Adaptive Testing)

原文: 2108.07386v1.pdf (arXiv:2108.07386, Aritra Ghosh & Andrew Lan, University of Massachusetts Amherst) · 译者: Claude · 译于 2026-06-25 术语对照: 计算机化自适应测验 (Computerized Adaptive Testing, CAT); 项目反应理论 (Item Response Theory, IRT); 知识追踪 (Knowledge Tracing, KT); 题目选择算法 (question/item selection); 双层优化 (bilevel optimization); 元学习 (meta learning); 影响函数 (influence function)

摘要

计算机化自适应测验 (CAT) 指的是一类针对每位学生/考生进行个性化定制的测验。CAT 方法会根据学生对此前题目的作答情况, 自适应地为其选择下一道信息量最大的题目, 从而有效缩短测验长度。现有 CAT 方法使用项目反应理论 (IRT) 模型来刻画学生能力与其作答之间的关系, 并使用静态的题目选择算法——这些算法被设计为尽可能快地降低能力估计误差; 因此, 它们无法通过从大规模学生作答数据中学习而得到改进。本文提出 BOBCAT, 一个面向 CAT 的、基于双层优化 (Bilevel Optimization-Based) 的框架, 能够直接从训练数据中学习一个数据驱动的题目选择算法。**BOBCAT 不依赖于具体的学生作答模型**, 且在自适应测验过程中计算高效。通过在五个真实世界学生作答数据集上的大量实验, 我们表明 BOBCAT 在缩短测验长度方面优于 (有时显著优于) 现有 CAT 方法。

1 引言

计算机化/在线学习平台的一项重要功能是计算机化自适应测验 (CAT), 它指的是这样一类测验: 通过使用一个算法, 根据学生对此前题目的作答自适应地为其选择下一道题目, 从而只用很少的题目就能准确测量一名学生/考生的能力/知识水平 [van der Linden and Glas, 2000; Luecht and Sireci, 2011]。对学生知识水平准确而高效的估计, 有助于计算机化学习平台为每位学习者提供个性化的学习体验。

一个 CAT 系统通常由以下部分组成: 一个底层的心理测量模型, 用于将题目特征与学生特征关联到学生对题目的作答; 一个题库, 其中题目的特征已从先前数据中学得; 以及一个算法, 用于从题库中为每位学生选择下一道题目并决定何时停止测验; 综述参见 [Han, 2018]。CAT 系统中最常用的作答模型是项目反应理论 (IRT) 模型, 其最简单的形式 (IPL) 为:

$$p(Y_{i,j} = 1) = \sigma(\theta_i - b_j), \quad (1)$$

其中 $Y_{i,j}$ 是学生 i 对题目 j 的二值作答, 1 表示答对, $\sigma(\cdot)$ 是 sigmoid/logistic 函数, $\theta_i \in \mathbb{R}$ 和 $b_j \in \mathbb{R}$ 分别是对应学生能力和题目难度的标量 [Lord, 1980; Rasch, 1993]。更复杂的 IRT 模型会使用额外的题目特征, 例如区分度 (scale) 和猜测参数 (guessing), 或者使用多维的学生特征, 即学生在多个技能上的知识水平 [Reckase, 2009]。

CAT 系统中最常用的题目选择算法会选择那道能最小化学生特征测量误差、信息量最大的题目; 综述参见 [van der Linden and Pashley, 2009]。具体而言, 在为学生 i 进行自适应测验过程的每一步 (以 t 为索引) 中, 它们按如下方式选择下一道题目:

$$j_i^{(t)} = \arg \max_{j \in \Omega_i^{(t)}} I_j(\hat{\theta}_i^{(t-1)}), \quad (2)$$

其中 $\Omega_i^{(t)}$ 是在时间步 t 可供该学生选择的题目集合 (每一步被选中的题目随后会被移除), $\hat{\theta}_i^{(t-1)}$ 是根据此前作答 $Y_{i,j_i^{(1)}}, \dots, Y_{i,j_i^{(t-1)}}$ 得到的对其能力参数的当前估计, $I_j(\cdot)$ 是题目 j 的信息量。在 **IPL IRT 模型下, 大多数信息量度量会选择难度最接近当前学生能力估计值的题目, 即选择那道使学生答对概率最接近 50% 的题目**。这一准则与二分类中的不确定性采样 (uncertainty sampling) [Lewis and Gale, 1994] 相吻合, 后者是主动学习 (active learning) [Settles, 2012] 中一种常用方法, 并已部署于真实世界的 CAT 系统中 [Settles et al., 2020]。

尽管现有 CAT 方法行之有效, 但有两个局限阻碍了它们的进一步改进。第一, 大多数题目选择算法是专门为 IRT 模型 (1) 设计的。IRT 模型高度结构化的特性使得对题目信息量进行理论刻画成为可能, 但相比更灵活的、基于深度神经网络的模型 [Cheng et al., 2019; Wang et al., 2020a], 它捕捉复杂的学生一题目交互的能力受到限制。这一局限在已经公开的大规模学生作答数据集 (往往含有数百万条作答) 上尤为明显 [Choi et al., 2020; Wang et al., 2020b]。第二, 大多数现有题目选择算法是静态的, 因为它们需要一个预先定义的信息量度量 (2); 它们只能利用大规模学生作答数据来改进底层的 IRT 模型 (例如校准题目难度参数), 却无法改进题目选择算法本身。因此, 随着越来越多学生参加测验, 它们不会有显著提升。近来已有一些将强化学习用于学习题目选择算法的想法 [Nurakhmetov, 2019; Li et al., 2020]; 然而, 这些方法尚未在真实数据上得到验证。

1.1 贡献

本文提出 BOBCAT，一个面向计算机化自适应测验的、基于双层优化 (Bilevel Optimization-Based) 的框架。BOBCAT 基于一个关键观察：CAT 的最终目标是缩短测验长度。因此，估计学生能力参数只是真正目标的一个代理——真正的目标是预测学生在一份长到无法实际施测的测验上对所有题目的作答。我们做出三项关键贡献：

第一，我们在元学习 (meta learning) [Finn et al., 2017] 的框架下，把 CAT 重新表述为一个双层优化 (bilevel optimization) 问题 [Franceschi et al., 2018]：在外层优化问题中，我们通过显式地最大化对一个留出的元题目集 (meta question set) 上学生作答的预测似然，来同时学习作答模型参数和一个数据驱动的题目选择算法。在内层优化问题中，我们通过最大化对一个已观测的训练题目集 (training question set) 上学生作答的预测似然，将外层作答模型适配到每位学生。这一双层优化框架通过“训练—元” (training-meta) 的设置，直接学得一个有效且高效的题目选择算法。此外，BOBCAT 不依赖于具体的作答模型，既兼容 IRT 模型，也兼容基于深度神经网络的模型；一旦学得，题目选择算法便能直接根据过去的作答来选择下一道题目，而无需在 CAT 过程中实时反复估计学生参数。

第二，我们在双层优化问题中，对题目选择算法参数的梯度采用了一个有偏的近似估计量。该近似利用了每道题目对算法参数的影响 (influence) [Koh and Liang, 2017]，以降低梯度估计的方差，并由此得到比无偏梯度估计量更好的题目选择算法。

第三，我们通过在五个大规模真实世界学生作答数据集上的大量定量与定性实验，验证了 BOBCAT 的有效性。我们观察到，所学得的数据驱动题目选择算法在缩短测验长度方面优于现有 CAT 算法，在某些情况下要在元题目集上达到相同的预测准确率，所需题目可减少 50%；这一改进在更大的数据集上通常更为显著。我们的实现将公开于 <https://github.com/arghosh/BOBCAT>。

说明。我们强调，本文的目标是学习数据驱动的题目选择算法，而非开发最优的底层学生作答模型。我们也承认，BOBCAT 未必能直接应用于真实世界的 CAT 场景，因为其数据驱动的特性使其 i) 难以进行理论分析，且 ii) 容易受到历史数据中偏差的影响。尽管如此，我们令人鼓舞的结果表明，借助大规模学生作答数据来提升 CAT 的效率是可能的。此外，诸如题目曝光控制 (question exposure control) [Veldkamp and van der Linden, 2008] 等其他重要的 CAT 议题还需进一步研究；我们在第 3.1 节中提供了初步的定性分析。

图 1: BOBCAT 框架总览。(图中展示了外层与内层两部分：内层根据式 (5) 选择题目、并用式 (4) 将全局作答模型适配为学生专属模型；外层在元题目集上计算损失、并用式 (3) 更新全局模型。左侧为训练题目按学生索引与时间步 t 排布，右侧为元题目集，中间红框为题目选择算法。)

2 BOBCAT 框架

下面我们详细介绍 BOBCAT 框架，如图 1 所示。令 N 和 Q 分别表示我们用于训练 BOBCAT 的学生作答数据集中学生和题目的数量。对于单个学生 i ，我们顺序地选取共 n ($\ll |\Omega_i^{(1)}|$) 道题目¹，记为 $\{j_i^{(1)}, \dots, j_i^{(n)}\}$ ，观察其作答，并预测其在一个留出的元题目集 Γ_i 上的作答； $\Omega_i^{(1)}$ 表示初始可选题目集，且 $\Omega_i^{(1)} \cap \Gamma_i = \emptyset$ 。训练题目集与元题目集是随机选取的，对数据集中每位学生而言并不相同。我们求解以下双层优化问题 [Franceschi et al., 2018; Rajeswaran et al., 2019]：

$$\underset{\gamma, \phi}{\text{minimize}} \quad \frac{1}{N} \sum_{i=1}^N \sum_{j \in \Gamma_i} \ell(Y_{i,j}, g(j; \theta_i^*)) := \frac{1}{N} \sum_{i=1}^N L(\theta_i^*, \Gamma_i) \quad (3)$$

$$\text{s.t.} \quad \theta_i^* = \arg \min_{\theta_i} \sum_{t=1}^n \ell(Y_{i,j_i^{(t)}}, g(j_i^{(t)}; \theta_i)) + R(\gamma, \theta_i) := L'(\theta_i) \quad (4)$$

$$\text{其中} \quad j_i^{(t)} \sim \Pi(Y_{i,j_i^{(1)}}, \dots, Y_{i,j_i^{(t-1)}}; \phi) \in \Omega_i^{(t)}. \quad (5)$$

这里， γ 和 ϕ 分别是全局作答模型参数和题目选择算法参数。 $g(\cdot)$ 是作答模型，它以目标题目的索引 j 为输入，并使用学生 i 专属的局部参数 θ_i^* ，输出对该学生答对该题概率的预测。 $\Pi(\cdot)$ 是题目选择算法 (图 1 中的红框)，它以学生对此前所选题目的作答为输入，输出下一道所选题目的索引。

¹ BOBCAT 既适用于定长 (fixed-length) 也适用于变长 (variable-length) CAT 设计 [Choi et al., 2011]；本文研究前者。

外层优化问题 (图 1 中的蓝框) 最小化所有学生在元题目集上的二元交叉熵损失 $\ell(\cdot)$ ，以同时学习全局作答模型和题目选择算法； $L(\cdot)$ 对应于每位学生在元题目集中所作答题目上该损失之和。内层优化问题 (图 1 中的绿框) 最小化 $L'(\cdot)$ ，即在训练题目集上为每位学生所选的少量题目上的交叉熵损失，从而把全局作答模型适配到每位局部学生，得到学生专属参数 θ_i^* ； $R(\gamma, \theta_i)$ 是一个正则项，惩罚局部参数对其全局值的过大偏离。注意 θ_i^* 是全局参数 γ 和 ϕ 的函数，这既通过式 (4) 中的正则项体现，也通过式 (5) 中题目选择算法为该学生所选的题目体现。

作答模型。作答模型 $g(\cdot)$ 既可取 IRT 模型，也可取基于神经网络的模型。在 IRT 模型的情形下，全局参数 γ 对应于题目难度和学生能力先验的组合。我们通过学生在内层优化问题中对所选题目的作答，将这些参数适配到每位局部学生。在我们的实验中，我们只把全局学生能力用作每位局部学生能力估计的先验均值，并在内层优化问题中保持题目难度固定，这与真实世界 CAT 系统的典型设置一致。在基于神经网络的模型情形下，参数

通常并不对应任何特定含义；遵循元学习中的标准做法 [Lee et al., 2019]，我们固定网络的一部分（例如所有权重和偏置，可将其视为题目难度的非线性版本），而在内层优化问题中优化网络的其余部分（例如输入向量，可将其视为学生能力）。

题目选择算法。题目选择算法 $\Pi(\cdot)$ 既可以是确定性的，也可以是概率性的，即它要么输出单个被选题目，要么输出可选题目上的一个概率分布。我们将第 t 步题目选择算法的输入状态向量定义为 $x_i^{(t)} \in \{-1, 0, 1\}^Q$ ，其中 -1 表示对一道此前所选题目的错误作答， 1 表示正确作答， 0 表示尚未被选择的题目。我们没有在状态向量中加入题目被选中的时间步，因为在 CAT 设置中，学生的真实能力在测验过程中被假定为静态，只是其估计值在不断更新。尽管任何可微的模型架构都可用于题目选择算法，我们采用对题目顺序保持不变的多层感知机（MLP）模型。对于概率性的题目选择算法，我们通过从输出分布中采样来选择题目： $j_i^{(t)} \sim \Pi(x_i^{(t)}, \Omega_i^{(t)}; \phi)$ 。

2.1 优化

我们使用梯度下降（GD）来求解关于局部作答模型参数 θ_i^* 的内层优化问题，这遵循模型无关元学习（model-agnostic meta learning, MAML）[Finn et al., 2017]。具体而言，我们让学生专属的局部参数从全局作答模型参数 γ 出发偏离，做 K 步 GD，每一步为：

$$\theta_i \leftarrow \theta_i - \alpha \nabla_{\theta} \sum_{t=1}^n \ell(Y_{i,j_i^{(t)}}, g(j_i^{(t)}; \theta)) \Big|_{\theta_i}, \quad (6)$$

其中 α 是学习率。我们没有为 GD 步显式使用正则化，因为早停（只做少数几步 GD）等价于一种正则化形式 [Rajeswaran et al., 2019]。计算关于全局参数 γ 的梯度，需要我们对式 (6) 内层优化中的梯度再求梯度（也称为元梯度，meta-gradient），这可以用自动微分 [Paszke et al., 2017] 来计算。计算精确的元梯度需要二阶导数；然而我们发现，一阶近似在实践中效果良好，且计算复杂度低。类似地，为了学习选择算法参数 ϕ ，我们需要通过学生专属参数 $\theta_i^*(\gamma, \phi)$ （即内层优化问题的解）计算外层目标 (3) 关于 ϕ 的梯度。对于单个学生 i （完整梯度对所有学生和），该梯度为：

$$\nabla_{\phi} L(\theta_i^*(\gamma, \phi), \Gamma_i) = \nabla_{\phi} \mathbb{E}_{j_i^{(1:n)} \sim \Pi(\cdot; \phi)} [L(\theta_i^*(\gamma, \{j_i^{(1:n)}\}), \Gamma_i)], \quad (7)$$

其中我们把 θ_i^* 对题目选择算法参数 ϕ 的依赖，替换为对所选题目索引 $j_i^{(1:n)}$ 的依赖——我们需要反向传播穿过这些索引。这些变量的离散特性使它们不可微，因此我们无法计算精确梯度。接下来，我们详述估计该梯度的两种方法。

无偏梯度估计 我们可以利用基于得分函数（score function）的恒等式（对任意概率分布 $f(X; \phi)$ ，有 $\frac{\partial \log f(X; \phi)}{\partial \phi} = \frac{\partial f(X; \phi) / \partial \phi}{f(X; \phi)}$ ）来估计式 (7) 中的无偏梯度 [Williams, 1992]：

$$\begin{aligned} & \nabla_{\phi} \mathbb{E}_{j_i^{(1:n)} \sim \Pi(\cdot; \phi)} [L(\theta_i^*(\gamma, \{j_i^{(1:n)}\}), \Gamma_i)] \\ &= \mathbb{E}_{j_i^{(1:n)} \sim \Pi(\cdot; \phi)} \left[(L(\theta_i^*, \Gamma_i) - b_i) \nabla_{\phi} \log \prod_{t=1}^n \Pi(j_i^{(t)} | x_i^{(t)}; \phi) \right] \\ &= \mathbb{E}_{j_i^{(1:n)} \sim \Pi(\cdot; \phi)} \left[(L(\theta_i^*, \Gamma_i) - b_i) \sum_{t=1}^n \nabla_{\phi} \log \Pi(j_i^{(t)} | x_i^{(t)}; \phi) \right], \end{aligned} \quad (8)$$

其中 b_i 是用于降低梯度估计方差的控制变量（基线）。这一无偏梯度与用于 CAT 的强化学习类算法相似，这一思路在 [Nurakhmetov, 2019] 中已有讨论。我们采用近端策略优化（proximal policy optimization, PPO）以获得训练稳定性，使用一个策略网络（actor）和一个价值网络（critic）[Schulman et al., 2017]；这些网络的细节我们在论文完整版将随附的补充材料中给出。

我们观察到，这一无偏梯度估计仅通过被选中的题目来更新题目选择算法参数，而未纳入对那些可选但未被选中的题目的观测，导致在实践中经验收敛较慢。然而，将未被选中题目的信息纳入梯度计算，可能会降低梯度方差并稳定训练过程。接下来，我们详述一个利用所有可用训练题目的有偏梯度近似。

近似梯度估计 我们可以把式 (7) 中的梯度改写为:

$$\nabla_{\phi} L(\theta_i^*(\gamma, \phi), \Gamma_i) = \nabla_{\theta_i^*} L(\theta_i^*, \Gamma_i) \nabla_{\phi} \theta_i^*(\gamma, \phi). \quad (9)$$

关于 θ_i^* 的梯度可以精确计算; 接下来, 我们针对单个时间步 t , 详细讨论 $\nabla_{\phi} \theta_i^*(\gamma, \phi)$ 的计算。我们可以把式 (4) 中的内层优化改写——将当前题目索引 $j_i^{(t)}$ 与此前所选题目索引 $j_i^{(1)}, \dots, j_i^{(t-1)}$ 分离:

$$\theta_i^* = \arg \min_{\theta_i} \sum_{\tau=1}^{t-1} \ell(Y_{i,j_i^{(\tau)}}, g(j_i^{(\tau)}; \theta_i)) + R(\gamma, \theta_i) + \sum_{j \in \Omega_i^{(t)}} w_j(\phi) \ell(Y_{i,j}, g(j; \theta_i)), \quad (10)$$

其中 $w_j(\phi) = 1$ 当 $j = j_i^{(t)}$, 而对所有其他可选题目 $w_j(\phi) = 0$ 。在式 (10) 中, 我们可以利用隐函数定理 (implicit function theorem) [Cook and Weisberg, 1982], 对 $\Omega_i^{(t)}$ 中所有可选题目索引 (无论它们在时间步 t 是否被选中) 计算导数 $\frac{d\theta_i^*}{dw_j(\phi)}$:

$$\frac{d\theta_i^*}{dw_j(\phi)} = -(\nabla_{\theta_i}^2 L'_i)^{-1} \nabla_{\theta_i} \ell(Y_{i,j}, g(j; \theta_i)) \Big|_{\theta_i^*}.$$

这一梯度可以用自动微分计算, 而无需显式计算逆 Hessian 矩阵, 方式与计算全局作答模型参数 γ 的梯度类似。然而, 我们仍需计算 $\frac{\partial w_j(\phi)}{\partial \Pi(j|x_i^{(t)}; \phi)}$, 它是不可微的; 由于当选择算法网络把全部概率质量都放在单道题目上时 $w_j(\phi) = \Pi(j|x_i^{(t)}; \phi)$ 成立, 我们可以采用近似 $w_j(\phi) \approx \Pi(j|x_i^{(t)}; \phi)$ 。由式 (9) 和式 (10) 可知, 在此近似下, 关于单道题目的完整梯度 $\frac{\partial L(\theta_i^*, \Gamma_i)}{\partial \Pi(j|x_i^{(t)}; \phi)}$ 正是广为使用的影响函数得分 (influence function score) [Koh and Liang, 2017]:

$$-\nabla_{\theta_i} L(\theta_i, \Gamma_i) (\nabla_{\theta_i}^2 L'_i)^{-1} \nabla_{\theta_i} \ell(Y_{i,j}, g(j; \theta_i)) \Big|_{\theta_i^*} := I_i(j), \quad (11)$$

其中 $I_i(j)$ 是题目 j 的影响函数得分, 它度量当式 (10) 中该题目的权重 $w_j(\phi)$ 受到微小扰动时, 元题目集上损失的变化。直观地, 我们希望选择那些梯度与元题目集上梯度相似的可用训练题目, 即那些对元题目最具信息量的题目; 这一近似使我们能够通过把影响得分作为梯度反向传播到训练题目集中所有可用题目上, 从而学得这样一个题目选择算法。相比之下, 对于式 (8) 中的无偏梯度, $\frac{\partial L(\theta_i^*, \Gamma_i)}{\partial \Pi(j|x_i^{(t)}; \phi)}$ 对所有未选中题目等于零, 而

对被选中题目 $j_i^{(t)}$ 等于 $-(L(\theta_i^*, \Gamma_i) - b_i) \log \Pi(j_i^{(t)}|x_i^{(t)}; \phi)$ 。这种有偏近似 (通常称为直通估计量, straight-through estimator) 已在以往关于神经网络量化的研究中被成功应用, 并能带来更低的经验方差 [Bengio et al., 2013]。算法 1 总结了 BOBCAT 的训练过程。

算法 1: BOBCAT 训练过程

1. 初始化全局参数 γ, ϕ , 学习率 η_1, η_2, α , 以及内层 GD 步数 K 。
2. **while** 未收敛 **do**
3. 随机采样一个学生小批量 B , 连同其训练题目集与元题目集 $\{\Omega_i^{(1)}, \Gamma_i\}_{i \in B}$ 。
4. **for** $t \in 1 \dots n$ **do**
5. 根据学生对此前所选题目的作答, 编码其当前状态 $x_i^{(t)}$ 。
6. 为每位学生选择题目 $j_i^{(t)} \sim \Pi(x_i^{(t)}; \phi)$ 。
7. 在已观测作答 $\{Y_{i,j_i^{(1:t)}}\}$ 上, 用学习率 α 和 K 步 GD (式 6) 优化 θ_i^* 。
8. 用式 (8) (或式 11) 估计无偏 (或近似) 梯度 $\nabla_{\phi} L(\theta_i^*, \Gamma_i)$ 。
9. 更新 ϕ : $\phi \leftarrow \phi - \frac{\eta_2}{|B|} \sum_{i \in B} \nabla_{\phi} L(\theta_i^*, \Gamma_i)$ 。
10. **end for**
11. 更新 γ : $\gamma \leftarrow \gamma - \frac{\eta_1}{|B|} \sum_{i \in B} \nabla_{\gamma} L(\theta_i^*(\gamma, \phi), \Gamma_i)$ 。
12. **end while**

计算复杂度。在训练时, 我们需要求解完整的 BOBCAT 双层优化问题, 这在大数据集上计算开销很大。然而在测试时, 当我们需要为每位学生选择下一道题目时, 只需把其过去的作答作为输入送入已学得的目标选择算法 $\Pi(\cdot; \phi)$, 即可得到被选题目作为输出; 这一操作比现有 CAT 方法 (每答一题后都需更新学生能力估计) 在计算上更高效。

3 实验

下面我们详述我们在五个真实世界学生作答数据集上开展的定量与定性实验，以验证 BOBCAT 的有效性。

数据集、训练、测试与评测指标。我们使用五个公开的基准数据集：EdNet、Junyi、Eedi-1、Eedi-2 和 ASSISTments。表 3 列出了学生数、题目数和交互数。我们在补充材料中提供了预处理细节以及每个数据集的更多背景信息。我们对所有数据集执行 5 折交叉验证；每一折中，我们分别用 60%-20%-20% 的学生作训练、验证和测试。对每一折，我们使用验证集学生进行早停并为每种方法调参。对于 BOBCAT，我们将每位学生所作答的题目划分为训练题目集 ($\Omega_i^{(1)}$, 80%) 和元题目集 (Γ_i , 20%)。为防止过拟合，我们在每个训练 epoch 中随机重新生成这些划分。我们同时使用准确率 (accuracy) 和受试者工作特征曲线下面积 (AUC) 作为指标，评测所有方法在元集 Γ_i 上预测二值学生作答的表现。我们用 PyTorch 实现所有方法，并在一块 NVIDIA TitanX/1080Ti GPU 上运行实验。

方法与基线。对于现有 CAT 方法，我们使用 IRT-Active 作为基线，即基于不确定性采样 [Lewis and Gale, 1994] 的主动学习题目选择算法，它选择难度最接近学生当前能力估计的下一道题目 [Settles et al., 2020]。该方法在 1PL IRT 模型下与基于题目信息量的 CAT 方法相吻合。我们还使用一个额外的基线，它随机选择下一道题目，我们称之为 IRT-Random。对于 BOBCAT，我们考虑使用 IRT 模型 (记为 BiIRT) 和使用神经网络 (记为 BiNN) 作为作答模型两种情形。对 BiIRT 和 BiNN，我们都使用四种题目选择算法：除上述 -Active 和 -Random 算法外，我们还使用以无偏梯度 (8) 和近似 (-Approx) 梯度 (11) 作用于题目选择算法参数 ϕ 而学得算法 (-Unbiased)。

网络与超参数。我们使用带 l_2 范数正则化的逻辑回归训练 IRT 模型。对 IRT-Active，我们计算学生当前能力估计时加入 l_2 范数正则化，以惩罚对平均学生能力参数的偏离。对 BiNN，我们使用一个两层全连接网络 (256 个隐藏节点、ReLU 非线性、20% dropout、最后接 sigmoid 输出层) [Goodfellow et al., 2016] 作为作答模型，以一个学生专属的 256 维能力向量作为输入。我们使用另一个全连接网络 (两个隐藏层、256 个隐藏节点、Tanh 非线性、最后接 softmax 输出层) [Goodfellow et al., 2016] 作为题目选择算法。对 BiNN/IRT-Unbiased，除题目选择策略网络 (actor) 外，我们还使用另一个全连接价值网络 (critic，两个隐藏层、256 个隐藏节点、Tanh 非线性)。对 BiIRT 和 BiNN，我们用 Adam 优化器 [Kingma and Ba, 2015] 学习全局作答模型参数 γ 和题目选择算法参数 ϕ ，并用 SGD 优化器 [Goodfellow et al., 2016] 学习适配到每位学生的作答参数 (在内层优化问题中)。我们在补充材料中为每个数据集提供具体的超参数选择和批量大小。对所有方法，我们为每位学生选取 $n \in \{1, 3, 5, 10\}$ 道题目。

表 1: 所有数据集上、跨折在元题目集上的平均预测准确率 (%)。最优方法以粗体显示。标准差以及所有方法的结果，参见图 2 及补充材料中的表格。

数据集	n	IRT-Active	BiIRT-Active	BiIRT-Unbiased	BiIRT-Approx	BiNN-Approx
EdNet	1	70.08	70.92	71.12	71.22	71.22
	3	70.63	71.16	71.3	71.72	71.82
	5	71.03	71.37	71.45	71.95	72.17
	10	71.62	71.75	71.79	72.33	72.55
Junyi	1	74.52	74.93	74.97	75.11	75.1
	3	75.19	75.48	75.53	75.76	75.83
	5	75.64	75.79	75.75	76.11	76.19
	10	76.27	76.28	76.19	76.49	76.62
Eedi-1	1	66.92	68.22	68.61	68.82	68.78
	3	68.79	69.45	69.81	70.3	70.45
	5	70.15	70.28	70.47	70.93	71.37
	10	71.72	71.45	71.57	72.0	72.33
Eedi-2	1	63.75	64.83	65.22	65.3	65.65
	3	65.25	66.42	67.09	67.23	67.79
	5	66.41	67.35	67.91	68.23	68.82
	10	68.04	68.99	68.84	69.47	70.04
ASSISTments	1	66.19	68.69	69.03	69.17	68.0
	3	68.75	69.54	69.78	70.21	68.73
	5	69.87	69.79	70.3	70.41	69.03
	10	71.04	70.66	71.17	71.14	69.75

表 2: 所有数据集上、跨折在元题目集上的平均 AUC (%)。标准差以及所有方法的结果，参见补充材料中的图和表。

数据集	n	IRT-Active	BiIRT-Active	BiIRT-Unbiased	BiIRT-Approx	BiNN-Approx
EdNet	1	73.58	73.82	74.14	74.34	74.41

数据集	n	IRT-Active	BiIRT-Active	BiIRT-Unbiased	BiIRT-Approx	BiNN-Approx
Junyi	3	74.14	74.21	74.49	75.26	75.43
	5	74.6	74.56	74.77	75.68	76.07
	10	75.35	75.21	75.39	76.35	76.74
	1	74.92	75.53	75.67	75.91	75.9
	3	76.06	76.52	76.71	77.11	77.16
	5	76.82	77.07	77.07	77.69	77.8
Eedi-1	10	77.95	77.95	77.86	78.45	78.6
	1	68.02	70.22	70.95	71.34	71.33
	3	71.63	72.47	73.26	74.21	74.44
	5	73.69	73.97	74.54	75.47	76.0
Eedi-2	10	76.12	75.9	76.34	77.07	77.51
	1	69.0	70.15	70.64	70.81	71.24
	3	71.11	72.18	73.11	73.37	73.88
	5	72.42	73.21	74.19	74.55	75.2
ASSISTments	10	74.36	75.17	75.37	75.96	76.63
	1	69.14	70.55	71.0	71.33	70.12
	3	71.17	71.6	72.35	73.16	71.57
	5	72.26	71.65	73.1	73.71	72.14
	10	73.62	72.52	74.38	74.66	73.59

表 3: 数据集统计。

数据集	EdNet	Junyi	Eedi-1	Eedi-2	ASSISTments
学生数	312K	52K	119K	5K	2.3K
题目数	13K	25.8K	27.6K	1K	26.7K
交互数	76M	13M	15M	1.4M	325K

3.1 结果与讨论

在表 1 中, 我们列出选定的 BOBCAT 变体和 IRT-Active 在所有数据集上、跨所有折的平均准确率; 在表 2 中, 我们用 AUC 指标做同样的事。在补充材料中, 我们提供上述所有方法的结果, 并列出跨折的标准差。使用基于神经网络的作答模型时, BiNN-Approx 在大多数情况下优于其他方法。使用 IRT 作答模型时, BiIRT-Approx 的表现与 BiNN-Approx 相当, 并优于其他方法。所有 BOBCAT 变体都显著优于使用静态题目选择算法的 IRT-Active。在五个数据集中最小的 ASSISTments 上, BiIRT-Approx 优于会过拟合的 BiNN-Approx。这些结果表明: i) BOBCAT 通过显式地从数据中学习题目选择算法, 改进了现有 CAT 方法, 且这一改进在更大的数据集上更为明显; ii) 由于 BOBCAT 不依赖于具体作答模型, 当训练数据有限时可自由选择 IRT 模型, 当训练数据充足时可选择基于神经网络的模型。

图 2: 所有数据集上的平均准确率 (深色线) 和 5 折标准差 (浅色填充线)。第一列比较 IRT 与 BiIRT 模型; 第二列比较所有 BiNN 模型。

在图 2 中, 我们用一系列图作为消融研究, 对不同方法进行更细致的比较; 这里我们把随机题目选择作为下限基准。在第一列中, 我们绘制 IRT-Random、IRT-Active、BiIRT-Random 和 BiIRT-Active 的准确率均值与标准差随所选题目数的变化。在 Eedi-1 数据集上, BiIRT-Active 在较小的 n 上优于 IRT-Active, 但在 $n = 10$ 时略差。在 ASSISTments 数据集上, 我们观察到较大 n 时标准差很高; 尽管如此, BiIRT 变体仍优于对应的 IRT 方法。在所有其他数据集上, BiIRT 方法显著优于对应的 IRT 方法。要达到相同准确率, 在 EdNet、Eedi-2 和 Junyi 数据集上, BiIRT-Active 相比 IRT-Active 所需题目约少 30%。这一以 IRT 为底层作答模型的正面对比, 展示了双层优化的威力; 即便使用静态题目选择算法, 显式地在元题目集上最大化预测准确率也能带来更好的表现, 尽管这种性能提升未必显著。

在第二列中, 我们使用同一个底层的基于神经网络的作答模型, 比较不同的 BOBCAT 变体。我们观察到, 在所有数据集上, BiNN-Approx 显著优于其他方法, 达到与 BiNN-Active 相同的准确率所需题目减少 50%–75%。这一性能提升在更大的数据集上更显著。它也显著优于无偏梯度估计, 达到相同准确率所需题目减少 10%–70%。BiNN-Unbiased 在较小 n 时显著优于 BiNN-Active, 但在较大 n 时则不然; 我们认为无偏梯度的高方差可能是这一现象的原因。这一正面对比表明, 我们的近似梯度估计稳定了模型训练过程并带来更好的模型拟合。此外, 通过双层优化学得的数据驱动题目选择算法, 远优于标准的静态 CAT 题目选择算法, 并且随着训练数据增多而变得更好。

研究: 能力估计。 现有真实世界 CAT 系统的目标是在 IRT 模型下准确估计学生能力参数, 该参数随后用于评分。因此, 我们在 Eedi-2 数据集上开展一个额外实验, 以当前能力参数估计 $\hat{\theta}_i^{(n)}$ 与真实能力 θ_i 之间的平方误差作为评测指标。由于真实学生能力在真实学生作答数据集中是未知的, 我们用根据每位学生所作答全部题目估计出的能力值作为替代。我们比较两种方法: IRT-Active, 其底层 1PL IRT 模型在数据上训练; 以及

BiIRT-Approx, 其中我们仅在现有 CAT 方法的设置下使用所学习的模型无关题目选择算法进行评测。图 3 (左) 展示了不同所选题目数 n 下的能力估计误差 (在五折上平均)。我们看到, 尽管 BiIRT-Approx 的目标并非能力参数估计, 它仍比 IRT-Active 更有效, 能用最多少 30% 的题目达到相同精度, 显著缩短了测验长度。图 3 (右) 展示了在 25% 和 50% 训练数据上训练的模型的同一对比。我们看到, BOBCAT 能随着可用训练数据增多而显著提升, 而现有 CAT 方法则不能。

图 3: Eedi-2 数据集上的能力估计精度。

表 4: IRT-Active 与 BiNN-Approx 方法在 Eedi-2 数据集上的题目曝光率与测验重叠率。

方法	曝光率 (中位数)	曝光率 (>20%)	重叠率 (均值)
IRT-Active	0.51%	0.25%	6.03%
BiNN-Approx	0%	1.54%	28.64%

研究: 题目曝光与内容重叠。在表 4 中, 我们给出 Eedi-2 数据集上题目曝光率 (一道题目被选中的次数比例) 和测验重叠率 (为两名学生所选题目之间的重叠) 的汇总统计。我们看到, BOBCAT 导致的题目曝光率略高于现有 CAT 方法, 但仍能维持可接受比例的过曝光题目 (超过推荐上限 20% [Veldkamp and van der Linden, 2008] 的部分)。然而, BOBCAT 导致的测验重叠率远高于现有 CAT 方法 [Stocking, 1994]。这一现象的原因在于, BOBCAT 偏好一小部分对预测学生在其他题目上作答高度有用的题目, 下文我们将对此详细解释。因此, 对未来工作而言, 在部署前开发受约束版本的 BOBCAT 以最小化其题目曝光率和测验重叠率, 是很重要的。

研究: 题目选择。为了更深入地理解为何 BOBCAT 能带来更准确的作答预测、却导致更高的题目曝光率和测验重叠率, 我们开展一项定性考察。一个可能的解释是, 式 (11) 的梯度更新会为那些与元集 (从所有题目中随机选出) 中题目更相似的题目赋予更高权重。因此, BiIRT/NN-Approx 方法偏好那些对整个题目集合高度有代表性的题目, 从而导致表 4 中更高的测验重叠率。我们考察 IRT-Active、BiIRT-Approx 和 BiNN-Approx 方法在 Eedi-2 数据集上所选的题目。我们计算每道题目与所有其他题目之间的加权互信息 (mutual information, MI)。然后用该得分把每道题目按其 MI 分配到一个有序的箱 (从 1 到 10) 中, 使每个箱含有等量的题目。具体而言 (以下记号仅适用于本研究), 令 $i_1, \dots, i_m$ 为同时作答了题目 j 和 k 的 m 名学生的集合。对题目 j 和 k 的作答记为 $Y_{i_1,j}, \dots, Y_{i_m,j}$ 和 $Y_{i_1,k}, \dots, Y_{i_m,k}$ 。题目 j 与 k 之间的互信息 $MI(j, k)$ 计算为:

$$\sum_{x \in \{0,1\}} \sum_{y \in \{0,1\}} \frac{|Y_{i,j} = x, Y_{i,k} = y|}{m} \log \frac{m |Y_{i,j} = x, Y_{i,k} = y|}{|Y_{i,j} = x| |Y_{i,k} = y|}.$$

我们还计算数据集中每道题目的经验频率 p_j , 即作答过该题目的学生比例。单道题目 j 的加权 MI 则为 $\sum_{k, k \neq j} p_k MI(j, k)$ 。直观地, 如果一道题目与数据集中其他题目之间的 MI 较高, 即处于更高的 MI 箱中, 那么该题目相比其他题目能提供关于每位学生的更多信息。在图 4 中, 我们绘制 IRT-Active、BiIRT-Approx 和 BiNN-Approx 方法为测试集学生从每个箱中所选题目的比例。这些结果证实了我们的直觉: BiIRT-Approx 和 BiNN-Approx 方法偏好那些能为每位学生提供关于所有其他题目更多信息的题目。相反, 我们没有在 IRT-Active 方法上观察到此类趋势; 其所选题目在各箱中均匀分布。这些趋势解释了为何我们在表 4 中观察到 IRT-Active 方法具有更低的题目曝光率和测验重叠率。因此, 准确预测学生在一份长测验上对题目的作答, 与选择多样化题目以最小化题目曝光率和测验重叠率, 是需要加以平衡的相互冲突的目标。这一观察进一步凸显了开发能平衡这些目标的受约束版本 BOBCAT 的必要性。

图 4: 每种方法所选题目与它们和 Eedi-2 数据集中所有其他题目之间互信息的关系。BOBCAT 倾向于选择信息量更大的题目。

4 结论与未来工作

本文提出了 BOBCAT, 一个面向 CAT 的双层优化框架, 它不依赖于底层学生作答模型, 并从训练数据中学习一个题目选择算法。通过在五个真实世界学生作答数据集上的大量实验, 我们证明 BOBCAT 在缩短测验长度方面能显著优于现有 CAT 方法。未来工作的方向包括: i) 将题目曝光与内容平衡约束 [Kingsbury and Zara, 1991] 纳入 BOBCAT, 使其可部署于真实世界测验; ii) 研究 BOBCAT 因训练数据中潜在偏差而带来的公平性问题。

致谢

我们感谢美国国家科学基金会 (National Science Foundation) 在 IIS-1917713 项目下的支持, 并感谢 Stephen Sireci 的有益讨论。

补充材料

5 无偏梯度的完整目标

我们用“奖励”(reward)一词表示负的损失值 $-L$ 。在式 (8) 中, 梯度是基于元题目集上的损失和被选题目概率计算的。在实践中, 我们可以使用一个 actor-critic 网络, 其中 actor 网络计算题目选择概率 $\Pi(\cdot|x_i^{(t)}; \phi)$, critic 网络预测一个标量的期望奖励值 $V(x_i^{(t)})$ 。被选题目 $j_i^{(t)}$ 的优势值 (advantage value) 定义为:

$$A(x_i^{(t)}, j_i^{(t)}) = -(L(\theta_i^*, \Gamma_i) - b_i) - V(x_i^{(t)}).$$

actor 网络更新参数 ϕ 以提升奖励 (或等价地提升优势值)。我们使用近端策略优化 (PPO) 来学习无偏模型。PPO 模型是一种离策略 (off-policy) 的策略梯度方法, 它在参数 ϕ 上做多步梯度。由于第一步之后, 更新后的模型 ϕ 已不同于用于计算奖励的模型 ϕ_{old} , 我们需要调整重要性权重以得到无偏梯度 [Schulman et al., 2017]。actor 网络在时间步 t 的近端策略优化目标为:

$$L_1 = -\mathbb{E}_{j_i^{(t)} \sim \Pi(\phi_{old})} \left[\min \left\{ \frac{\Pi(j_i^{(t)}|x_i^{(t)}; \phi)}{\Pi(j_i^{(t)}|x_i^{(t)}; \phi_{old})} A(x_i^{(t)}, j_i^{(t)}), \text{Clip} \left(\frac{\Pi(j_i^{(t)}|x_i^{(t)}; \phi)}{\Pi(j_i^{(t)}|x_i^{(t)}; \phi_{old})}, 1 - \epsilon, 1 + \epsilon \right) A(x_i^{(t)}, j_i^{(t)}) \right\} \right], \quad (12)$$

其中函数 $\text{Clip}(r, 1 - \epsilon, 1 + \epsilon)$ 返回 $\min\{1 + \epsilon, \max\{r, 1 - \epsilon\}\}$; 这一约束通过不让网络做过大的梯度步来稳定训练。此外, 为鼓励探索, PPO 基于 actor 输出概率分布加入一个熵目标:

$$L_2 = \sum_{j \in \Omega_i^{(t)}} \left[\Pi(j|x, \phi) \log \Pi(j|x_i^{(t)}, \phi) \right]. \quad (13)$$

critic 网络根据期望奖励与真实奖励之间的 MSE 损失更新参数:

$$L_3 = \|V(x_i^{(t)}) + (L(\theta_i^*, \Gamma_i) - b_i)\|^2. \quad (14)$$

我们基于元题目集上的准确率为每位学生计算奖励。此外, 我们观察到每位学生的表现差异相当大, 而广为使用的单一移动平均基线表现不佳; 因此我们决定为每位学生使用不同的基线。我们以基于随机选择算法得到的元集表现作为每位学生的基线。这一基线计算增加了计算复杂度; 不过, critic 网络的输出 $V(x_i^{(t)})$ 只需预测 actor 网络相比随机选择算法好多少。这一基线选择在我们所有实验中都表现良好。PPO 的最终目标使用这些各项损失的加权组合 ($L_1 + 0.01L_2 + 0.5L_3$)。

表 5: 完整数据集细节。交互数少于 20 的学生被移除。括号中列出预处理/过滤前的数值。 R 是为降低方差而进行的“训练一元”划分的重复次数。

数据集	学生数	题目数	交互数	R
EdNet	312,372 ($\square$ 0.8M)	13,169	76,489,425 ($\square$ 95M)	1
Junyi	52,224 (72,758)	25,785	13,603,481 ($\square$ 16M)	2
Eedi-1	118,971	27,613	15,867,850	2
Eedi-2	4,918	948	1,382,727	5
ASSISTments	2,313 (4,217)	26,688	325,359 (346,860)	10

6 数据集与预处理细节

我们在五个公开基准数据集上比较我们的模型: EdNet、Junyi、Eedi-1、Eedi-2 和 ASSISTments; 其中 Eedi-2 数据集曾用于 [Wang et al., 2020b]。我们移除交互数少于 20 的学生; 此外, 对于重复出现的题目, 我们只保留首次交互。表 5 列出学生数、题目数和交互数。我们还在括号中列出每个数据集 (过滤前) 的总学生数和总交互数; 我们无需对 Eedi-1 和 Eedi-2 数据集做预处理, 因为它们对每道题目只含单次交互, 且每位学生保有 50 次以上的总交互。遵循 [Wang et al., 2020b], 对较小的数据集, 我们为验证集和测试集中的每位学生创建多个 (R 个) 训练集 ($\Omega_i^{(1)}$, 80%) 和元集 (Γ_i , 20%) 的划分, 以降低最终估计的方差; 每个数据集的重复次数 R 列于表 5。验证集和测试集学生的 (训练一元题目集) 划分对所有模型完全相同。

7 网络与超参数

训练 IRT-Active 和 IRT-Random 时, 我们使用 l_2 范数正则化 $\lambda_1 \in \{10^{-3}, 10^{-6}, 10^{-10}\}$ 。对 IRT-Active, 我们用作答和 l_2 范数正则化 $\lambda_2 \in \{10, 1, 10^{-1}, 10^{-2}, 10^{-4}, 0\}$ 计算学生能力参数, 以惩罚对训练数据集中平均学生能力参数的偏离。对 BiNN 模型, 全局作答模型 γ 由一个输入向量 $w \in \mathbb{R}^{256}$ 、一个含 256 节点单隐藏层 (权重 $W^1 \in \mathbb{R}^{256 \times 256}$) 的网络, 以及一个输出层 (权重 $W^2 \in \mathbb{R}^{Q \times 256}$) 组成 (为简洁起见我们忽略偏置)。该作答模型用学生专属参数 $\theta_i := \{w_i, W_i^1, W_i^2\}$ 计算题目 j 答对概率: $g(j, \theta_i) = \sigma(W_i^2 \text{Dropout}(\text{ReLU}(W_i^1 w_i)))[j]$, 其中 $x[j]$ 表示向量 x 的第 j 维, sigmoid 函数 $\sigma(\cdot)$ 逐元素作用。我们在内层保持网络的一部分 (W^1 、 W^2) 固定, 仅适配学生专属参数 w 。我们对 BiIRT 和 BiMLP 模型中所有与题目相关的参数使用 Adam 优化, 学习率设为 10^{-3} 。对 γ 的其余参数 (学生专属、在内层适配的部分), 我们用 SGD 优化全局值, 学习率设为 10^{-4} 、动量设为 0.9。我们用固定的 $K = 5$ 步 GD 优化内层目标; 我们发现学生专属参数在略高的学习率 $\alpha \in \{0.05, 0.1, 0.2\}$ 下能在几步内迅速收敛。题目选择网络参数用 Adam 优化器优化, 学习率 $\eta_2 \in \{0.002, 0.0002\}$ 。对无偏梯度, 我们在选择过程结束时做 4 步离策略梯度, 并在所有实验中将裁剪参数 ϵ 设为 0.2, 遵循 [Schulman et al., 2017]。我们根据 GPU 显存为每个数据集中的所有模型固定批量大小, 并训练所有模型直到验证表现在若干 epoch 内不再提升。所需 GPU 显存与题目数成正比。我们将 Eedi-1、Junyi 和 ASSISTments 数据集的批量大小固定为 128, EdNet 数据集固定为 200, Eedi-2 数据集固定为 512。

对 BiIRT/BiNN-Active 方法, 我们需要在推断时做 $K = 5$ 步 GD, 而 -Approx 和 -Unbiased 则用神经网络 ϕ 摊销了这一开销。因此, 我们观察到 -Active 方法相比 -Approx 和 -Unbiased 方法有更高的推断时间。在较大数据集 (Eedi-1、Junyi 和 EdNet) 上, 平均而言, 训练 -Approx 和 -Unbiased 模型需 10–20 小时, 训练 BiIRT/BiNN-Active 模型需 15–30 小时, 训练 BiIRT/BiNN-Random 模型需 5–10 小时。

8 额外实验结果

在表 7 中, 我们列出所有模型在所有数据集上的 5 折准确率均值与标准差。此外, 在表 6 中, 我们列出所有模型在所有数据集上的 5 折 AUC 均值与标准差。我们观察到两个指标呈现相似趋势。在图 5 中, 我们提供使用 AUC 指标的消融实验图。

图 5: 所有数据集上的平均 AUC (深色线) 和 5 折标准差 (浅色填充线)。第一列比较 IRT 与 BiIRT 模型; 第二列比较所有 BiNN 模型。

表 6 (此处为原文表 6, 含全部 10 种方法在 5 个数据集、4 种题目数下的 5 折 AUC 均值 $\pm$ 标准差, 结构复杂, 完整数值详见原文)。其趋势与正文表 2 一致: BiNN-Approx 与 BiIRT-Approx 总体最优, 所有 Bi- (双层) 变体显著优于对应的 IRT 静态基线。

表 7 (此处为原文表 7, 含全部 10 种方法在 5 个数据集、4 种题目数下的 5 折准确率均值 $\pm$ 标准差, 结构复杂, 完整数值详见原文)。其趋势与正文表 1 一致。

参考文献 (References) 按约定未翻译, 详见原文。