

精读笔记:Quality meets Diversity: A Model-Agnostic Framework for Computerized Adaptive Testing (MAAT)

Bi, Ma, Huang, Yin, Liu, Chen, Su, Wang — USTC / 安徽大学 / 讯飞研究院, ICDM 2020(arXiv:2101.05986) 本文件夹内代码:官方开源实现(<https://github.com/bigdata-ustc/MAAT>)的核心部分,配 ASSISTments 数据

1. 论文解决了什么问题?

一句话:让 CAT(计算机自适应测试)的选题策略不再依赖某个具体的认知诊断模型(CDM),同时兼顾"题目质量(信息量)"和"知识点多样性(覆盖度)"。

CAT 系统 = 认知诊断模型 M (估计学生知识状态) + 选题策略 S (每步挑下一题)。论文把 CAT 形式化为:给定新考生 e 、题库 Q 和知识点集 K ,设计策略 S 逐步选出长度为 N 的测试序列 Q_T ,使得:

1. **Quality(质量)**:选出的题信息量最大,能最快降低对学生知识状态估计的不确定性;
2. **Diversity(多样性)**:选出的题尽可能覆盖所有知识点,给学生一个全面的诊断。

且整个策略不依赖 CDM 的内部机制(model-agnostic),换 CDM 不用重新设计策略。

2. 这个问题是由什么引发的?

- 传统 CAT 策略都是 **model-specific** 的:MFI(最大 Fisher 信息量)必须知道 IRT 的参数形式才能算 Fisher 信息;D-Optimality、MKLI 绑定 MIRT。换一个 CDM 就要重新推导整个选题策略,系统非常不灵活。
- 深度学习 CDM(如 NCDM)出现后问题更尖锐:神经网络参数没有 IRT 那样可解释的解析形式,Fisher 信息根本没法推,导致这些强大的新模型接不进现有 CAT 系统。论文实验里 NCDM 只能和随机选题比,就是因为没有任何现存策略能配它。
- 另外,现有策略只顾信息量、忽略知识点覆盖:比如一直选"函数"相关的高信息题,导致"几何"完全没测过,诊断结果片面。测试通常很短(几十题),覆盖不均衡的问题很实际。

3. 目前有哪些其他解决方法?

论文对比的基线(都绑定具体 CDM):

策略	绑定的 CDM	思路
RAND	任意	随机选题(唯一的 model-agnostic 基线)
MFI (Lord, 1980)	IRT	最大 Fisher 信息,最经典
KLI (Chang & Ying, 1996)	IRT	KL 散度衡量全局信息量
D-Opt	MIRT	MFI 的多维推广(D-最优设计)
MKLI	MIRT	KLI 的多维推广

它们的共同缺陷:① 必须懂 CDM 内部细节;② 基本不管知识点多样性。

思想来源:主动学习(Active Learning)。AL 中"不看模型细节、只看模型输出/数据特征来挑样本"的做法(如 Expected Model Change、representativeness)启发了本文;知识覆盖的 **submodular(次模)**优化则借鉴自文档摘要、推荐系统里的 coverage 建模。论文自称是第一个显式把"知识点覆盖"作为 CAT 优化目标并给出次模优化算法的工作。

4. 作者怎么解决的?—— MAAT 框架三模块

每一步 t 的选题分两阶段,外加一个测前预计算模块:

4.1 Quality Module:Expected Model Change(EMC)—— 质量

不看 CDM 内部,只看"如果把这道题的作答加进去,模型参数 θ 会变多少":

- $\Delta M(r_{ij}) = |\theta(R_i \cup \{r_{ij}\}) - \theta(R_i)|$,即加入一条作答记录后参数的变化量;
- 考前不知道学生答对答错,所以按模型预测的答对概率 $p = M(e_i, q_j | \theta)$ 取期望: $EMC(q_j) = p \cdot \Delta M(\text{答对}) + (1-p) \cdot \Delta M(\text{答错})$ (式 1-2)
- θ 变化大 $\rightarrow$ 这题信息量大。任何梯度可训练的 CDM 都适用(用梯度近似 ΔM 提效),这就是 model-agnostic 的关键。
- 对所有未测题算 EMC,取 **top-K_C** 构成候选集 Q_C (实验里 $K_C=10$)。

4.2 Diversity Module:IWKC 覆盖分 —— 多样性

从候选集 Q_C 里挑一道让"知识覆盖分"边际增益最大的题。朴素覆盖 NKC(覆盖知识点数/总知识点数)有两个毛病:① 所有知识点同等重要;② 0/1 覆盖太硬(某知识点测 1 题和测 9 题没区别)。改进为 **Importance Weighted Knowledge Coverage(IWKC)**(式 5-7):

- $IWKC(Q_T) = \sum_k w_k \cdot \text{IncCov}(k, Q_T) / \sum_k w_k$
- $\text{IncCov}(k, Q_T) = \text{cnt} / (\text{cnt} + 1)$, cnt 是 Q_T 中关联知识点 k 的题数 —— 软覆盖, $0 \rightarrow 0.5 \rightarrow 0.67 \rightarrow 0.75 \dots$, 收益递减;
- w_k 是知识点重要性权重(由 Importance Module 给)。

选题规则(式 8-9): $q^* = \operatorname{argmax}_{\{q \in Q_C\}} [IWKC(Q_T \cup \{q\}) - IWKC(Q_T)]$,即贪心最大边际增益。

理论保证:证明了 IWKC 最大化问题是 **NP-hard**(规约到加权最大覆盖问题),但 IWKC 是非负单调次模函数,因此贪心算法有经典的 $(1 - 1/e)$ 近似比保证。

4.3 Importance Module:知识点重要性 w_k (测前用历史数据预计算)

思想:一个知识点重要 $\Leftrightarrow$ 它关联的题更有"代表性"。

1. **Test-Effect Embedding**(式 10-12):仿 Item2Vec,把每条历史记录编码成 $2|Q|$ 维 one-hot(答对/答错拼接),用 Skip-Gram 负采样(SGNS)训练题目向量——历史上被学生们表现相似的题,向量相近;
2. **Test-Effect Density**(式 13-14):题目 q 的密度 = 它与 K_N 个近邻的平均相似度 $\text{Sim} = \exp(-\gamma ||q_i - q_j||)$,密度越大越有代表性;
3. w_k (式 15)= 关联知识点 k 的所有题的密度平均值。

4.4 整体流程(Algorithm 1)

测前:用历史数据 H 训练 CDM 初始参数(题目侧参数固定)、训练 Test-Effect embedding、算 w_k 。测中每步:算全部未测题 EMC $\rightarrow$ 取 top- K_C $\rightarrow$ 按 IWKC 边际增益选 1 题 $\rightarrow$ 学生作答 $\rightarrow$ 用新记录更新 θ $\rightarrow$ 重复 N 步。超参 K_C 调节质量-多样性的平衡: $K_C=1$ 退化成纯 Quality, $K_C=|Q_U|$ 退化成纯 Diversity。

5. 在代码中是怎么体现的?

代码是简化版官方实现,只含 IRT 模型 + Random/MAAT 两种策略(models/ 下有 ncd checkpoint 但没有 NCD 模型代码;Importance Module 没有实现,详见局限)。

目录结构

```
pyat/
  model/irt_model.py          # IRT CDM + EMC 的实现
  strategy/maat_strategy.py  # MAAT 选题策略(Quality-Diversity 两阶段)
  utils/data/                 # TrainDataset / AdapTestDataset(tested/untested 集合管理)
  driver.py                   # 自适应测试模拟主循环
scripts/train.py              # 测前:训练 IRT
scripts/test.py               # 测中:模拟 CAT,对比 Random vs MAAT
datasets/assistent/          # ASSISTments 2009-2010 数据
```

论文-代码对照

论文概念	代码位置	说明
抽象 CDM M(θ)	<code>irt_model.py:16</code> <code>IRT</code> 类	θ =学生能力 embedding, α =区分度, β =难度;预测 $p = \sigma(\alpha \cdot \theta + \beta)$
EMC(式 1-2)	<code>irt_model.py:174</code> <code>expected_model_change()</code>	冻结 α 、 β ,克隆当前 θ ;分别假设"答对"/"答错"各做几轮梯度更新,得 <code>pos_weights</code> / <code>neg_weights</code> ;返回 <code>p</code> .
Quality Module 取 top-K_C	<code>maat_strategy.py:35-37</code>	对每个未测题算 EMC, <code>np.argsort</code> 降序取前 <code>n_candidates</code> (默认 10,即论文 $K_C=10$)
Diversity Module / IWKC	<code>maat_strategy.py:18-27</code> <code>_compute_coverage_gain()</code>	对候选题算"加入后"的覆盖分: $\sum cnt/(cnt+1)$ / 知识点 数,正是式 6 的 IncCov 软覆盖; <code>maat_strategy.py:38</code> 用 <code>max(candidates, key=...)</code> 贪心选边际增益最大 者(直接比"加入后的总分"等价于比边际增益)
Importance Module w_k	未实现	代码里所有知识点等权(相当于 $w_k \equiv 1$),即论文的 WKC 退化 版,没有 Item2Vec/SGNS 部分
更新 θ (观察 作答后)	<code>irt_model.py:96</code> <code>adaptest_update()</code>	只对 <code>model.theta</code> 建 optimizer(α 、 β 不动),用刚测的那 道题(<code>get_tested_dataset(last=True)</code>)训练 8 个 epoch
Algorithm 1 主循环	<code>driver.py:23-36</code>	每轮:策略选题 $\rightarrow$ <code>apply_selection</code> (untested $\rightarrow$ tested) $\rightarrow$ 更新 $\theta \rightarrow$ 评估 AUC/Coverage 并写 tensorboard
$\text{Inf}(S) =$ AUC(式 17)、 $\text{Cov}(S)$ (式 18)	<code>irt_model.py:133</code> <code>adaptest_evaluate()</code>	用当前 θ 预测该生全部有真实标签的题算 AUC;覆盖率 = 已 测题涉及知识点 / 该生做过的题涉及的全部知识点

输入数据格式

- `train_triplets.csv` / `test_triplets.csv`:三元组 `student_id, question_id, correct` (0/1),就是论文的作答记录 $r = \langle e_i, q_j, a_{ij} \rangle$ 。按学生划分:1426 个学生做历史数据(训练),47 个学生模拟考生(测试),学生 ID 各自重新编号(`data_prep.py:split_data_by_student`);
- `concept_map.json`: {题目id: [知识点id,...]} ,即论文的 Q-K 二元关系 G;
- `metadata.json`:1473 学生 / 903 题 / 22 知识点 / 58427 条记录。

训练了什么、怎么测的

1. `scripts/train.py` (测前): 用 1426 个历史学生的全部三元组训练 IRT($\text{lr}=0.002$, $\text{batch}=2048$, 100 epochs, 1 维 θ), 交叉熵损失。 `adaptest_save` 只保存 α 、 β (题目参数), 学生 θ 不保存 —— 因为测试时面对的是全新考生;
2. `scripts/test.py` (模拟 CAT): 加载 α 、 β , 47 个测试学生的 θ 随机初始化; 他们的真实作答记录当作 "标准答案库", 系统每选一题就 "揭晓" 该题对错 (`data[sid][qid]`), 模拟真实考试。测 50 步, 每步后评估。对比 `RandomStrategy` 和 `MAATStrategy`。

最后得到什么

`results/<时间戳>/` 下的 tensorboard 日志, 记录每一步 (0~50) 的两条曲线: AUC (诊断准确度, 质量指标) 和 cov (知识点覆盖率, 多样性指标), 可直观看到 MAAT 两条曲线都压过 Random。

6. 实验结果如何?

数据集: EXAM (讯飞私有, 4307 生/527 题/31 知识点) 和 ASSIST (公开 ASSISTments 2009-2010)。测长 $N=50$, 评估第 25/50 步。

- 质量 (AUC@25/@50, Table III): MAAT 在 IRT、MIRT、NCDM 三种 CDM 上全部胜过对应的 model-specific 基线。如 EXAM+IRT@50: MAAT 0.7319 > KLI 0.7257 > MFI 0.7207; NCDM 上 (无基线可用) 也明显超过 RAND (0.7868 vs 0.7566)。而且 CDM 越复杂整体 AUC 越高, 印证 model-agnostic 的价值: 换更强的 CDM 不用改策略, 直接受益;
- 多样性 (Coverage, Fig. 3): MAAT 覆盖率在测试前期快速逼近 1, 大幅领先所有基线; 同时发现 MFI/KLI 也顺带提升覆盖 —— 说明质量与多样性是相关而非对立的目标;
- 一致性验证 (SEE, Fig. 4): 在传统模拟研究 (IRT 模拟参数) 下, MAAT 的参数估计误差下降速度也与 MFI/KLI 相当且远快于 RAND, 说明新评估方式与传统结论一致;
- 消融 (K_C , Fig. 5): K_C 越大覆盖涨越快; $K_C=10$ 时多样性已接近上限, 而质量最好的反而不是 $K_C=1$ (因为覆盖/重要性也间接帮助质量) —— 小的 $K_C(10)$ 即可取得最佳平衡;
- 案例 (Table IV): 同一考生前 10 题, MAAT 覆盖 9 个知识点, D-Opt 只有 5 个、MKLI 6 个, 且 AUC 还略高; 基线反复选 "Function" 相关题, MAAT 不会。

7. 局限性

论文自身的局限:

1. EMC 计算开销大: 每步要对每道未测题分别模拟 "答对/答错" 两次参数更新。虽然论文说可用单步梯度近似, 但对大题库、深度 CDM 仍是 $O(|Q_U|)$ 次前向+反向, 比 MFI 的解析式贵得多; 论文没有报告运行时间;

2. w_k 是静态的:知识点重要性由历史数据测前算好,对所有考生一样、测试中不变,没有个性化(不同学生薄弱点不同,重要性理应自适应);
3. 贪心只有 $(1-1/e)$ 近似,且质量-多样性平衡靠单一超参 K_C 硬切换(先质量后多样性的两阶段串联),不是真正的联合多目标优化;
4. 评估依赖真实数据回放:只能从"该生历史上做过的题"里选(否则没有标签),题库被人为缩小,与真实 CAT 场景有偏差;AUC 也是用"全量作答"训练出的参数当近似真值;
5. 未考虑曝光控制、题目使用均衡、作答时间等实际 CAT 运营约束;实验只有数学学科的两个数据集。

这份代码相对论文的缺口(读代码时要注意):

1. Importance Module 完全缺失:没有 Test-Effect Embedding/SGNS/密度估计, w_k 等权 —— 实现的其实是 WKC 而非 IWKC;
2. 只实现了 IRT(1 维,近似 2PL);NCDM/MIRT 模型代码不在此 repo(仅留了一个 ncd checkpoint);
3. EMC 用多轮真实重训而非论文提到的梯度近似, `num_epochs=8` 意味着每题 16 次小训练,慢;
4. `expected_model_change` 里 optimizer 是 Adam 且每次新建,冻结非 θ 参数的方式 (`requires_grad=False` 后又全部置 True)与 `adaptest_update` 的注释代码有些不一致,属工程简化;
5. 基线里只有 Random,没有 MFI/KLI 的实现,复现 Table III 需自行补。

8. 一句话总结

MAAT 把主动学习的"期望模型变化"和次模覆盖优化引入 CAT;用 EMC 把选题策略与 CDM 解耦(黑盒也能测信息量),用 IWKC+贪心保证知识点覆盖有 $(1-1/e)$ 理论下界,在 IRT/MIRT/NCDM 上同时赢得质量与多样性 —— 代价是每步对全题库做两次假设更新的计算开销,以及开源代码只落地了框架的一半(缺 Importance Module)。