

MAAT 多样性模块公式详解

逐个拆解 MAAT(ICDM 2020) Diversity Module 的式 (3)–(9), 配一个贯穿始终的数值例子。

先固定一个玩具场景: 知识点集合 $K = \{\text{代数}, \text{几何}, \text{概率}\}$, 当前已选题集 $Q_T = \{q_1, q_2\}$, 其中 q_1 考代数, q_2 考代数 + 几何。符号 G 是“题目—知识点”关联表, $(q, k) \in G$ 就是“题 q 考了知识点 k ”。

1. 式 (4):Cov ——一个知识点被覆盖了没有?

$$Cov(k, Q_T) = \mathbb{1}[\exists q \in Q_T, (q, k) \in G]$$

符号读法: $\mathbb{1}[\cdot]$ 是指示函数, 条件成立等于 1, 否则等于 0; $\exists$ 读作“存在”。

整句话: 已选的题里, 只要有任何一道考到了知识点 k , 就记 1 分, 一道都没有就记 0 分。

代入例子: 代数被 q_1, q_2 考过 $\rightarrow Cov(\text{代数}) = 1$; 几何被 q_2 考过 $\rightarrow Cov(\text{几何}) = 1$; 概率没人考 $\rightarrow Cov(\text{概率}) = 0$ 。

2. 式 (3):NKC ——朴素覆盖率

$$NKC(Q_T) = \frac{\sum_{k \in K} Cov(k, Q_T)}{|K|}$$

把每个知识点的 0/1 加起来, 除以知识点总数 $|K|$, 即“覆盖了几成知识点”。

代入例子: $NKC = \frac{1+1+0}{3} = 0.667$ 。

它的两个毛病:(1) 代数被考 1 次还是 9 次都只记 1 分 (0/1 太硬);(2) 代数和几何谁重要, 它不管 (等权)。下面的公式就是修这两个毛病的。

3. 式 (7):cnt ——数数

$$cnt(k, Q_T) = \sum_{q \in Q_T} \mathbb{1}[(q, k) \in G]$$

对已选的第每道题问一句“你考 k 了吗”, 考了记 1, 全部加起来, 即“已选中有几道题考了知识点 k ”。它是从 0/1 走向“软覆盖”的原材料——先把“有没有”升级成“有几道”。

代入例子: $cnt(\text{代数}) = 2, cnt(\text{几何}) = 1, cnt(\text{概率}) = 0$ 。

4. 式 (6):IncCov ——把“几道”压成 0 到 1 的软分数

$$IncCov(k, Q_T) = \frac{cnt(k, Q_T)}{cnt(k, Q_T) + 1}$$

cnt (考了几道)	0	1	2	3	4	...
$IncCov$ (覆盖分)	0	0.5	0.667	0.75	0.8	$\rightarrow 1$
这一道新题涨了多少	—	+0.5	+0.167	+0.083	+0.05	递减

看第三行, 这是整个设计的灵魂: 第 1 道题最值钱 (+0.5), 之后每加一道涨幅骤减, 永远到不了 1。

“后期平滑”是怎么做到的？

把公式换个写法：

$$\frac{cnt}{cnt+1} = 1 - \frac{1}{cnt+1}$$

也就是“距离满分 1，永远还差 $\frac{1}{cnt+1}$ ”。 $cnt = 0, 1, 2, 3$ 时，差距分别是 $1, \frac{1}{2}, \frac{1}{3}, \frac{1}{4}, \dots$ 。每多测一道题，差距从 $\frac{1}{n+1}$ 缩到 $\frac{1}{n+2}$ ，缩小的量为：

$$\Delta = \frac{1}{n+1} - \frac{1}{n+2} = \frac{1}{(n+1)(n+2)}$$

分母平方级增长，所以涨幅按 $1/n^2$ 的速度衰减： $+\frac{1}{2}, +\frac{1}{6}, +\frac{1}{12}, +\frac{1}{20}, \dots$

这就是“后期平滑”的全部机制：不是设计了什么复杂函数，而是选了双曲线这个天生“够不着渐近线”的形状——无限逼近 1 但永远差一点，越靠近爬得越慢。任何“单调递增 + 增量递减 + 饱和于 1”的凹函数（比如 $1 - e^{-cnt}$ ）都能达到同样效果，作者选 $\frac{cnt}{cnt+1}$ 只因为它是其中最简单的有理式。而“增量递减”正是次模性的来源，后面贪心算法的 $1 - \frac{1}{e}$ 保证全靠它。

效果：“9 道代数 + 1 道几何”得 $0.9 + 0.5 = 1.4$ ，输给“5 道代数 + 5 道几何”的 $0.833 \times 2 = 1.667$ ——不平衡终于会被扣分了。

5. 式 (5):IWKC ——加权汇总

$$IWKC(Q_T) = \frac{\sum_{k \in K} w_k \times IncCov(k, Q_T)}{\sum_{k \in K} w_k}$$

每个知识点的软覆盖分乘上重要性权重 w_k （重要性模块预先算好的正数）加起来；分母除以权重总和，把结果归一化回 $[0, 1]$ （相当于加权平均）。重要的知识点，覆盖它涨分多；不重要的，少花题量也亏不了多少。

代入例子：设 $w = \{\text{代数} : 3, \text{几何} : 2, \text{概率} : 1\}$ （代数最重要）：

$$IWKC(\{q_1, q_2\}) = \frac{3 \times 0.667 + 2 \times 0.5 + 1 \times 0}{3 + 2 + 1} = \frac{3.0}{6} = 0.5$$

6. 式 (9): 边际增益——一道候选题能涨多少分

$$\Delta_{q_j} IWKC(Q_T) = IWKC(Q_T \cup \{q_j\}) - IWKC(Q_T)$$

把候选题 q_j 假装放进已选集，算一下新 IWKC，减去旧 IWKC——差值就是这道题的“边际增益”。纯粹是“试放一下、量一量涨幅”。

7. 式 (8):argmax ——挑涨分最多的那道

$$q_t^* = \arg \max_{q_j \in Q_C} \Delta_{q_j} IWKC(Q_T)$$

arg max 读作“取使后面式子最大的那个自变量”。对候选集 Q_C 里的每道题（只在质量模块筛出的 10 道里挑，不是全题库）都算一遍式 (9)，谁涨分最多，谁就是本步最终选中的题 q^* 。

8. 用例子把式 (8)(9) 走一遍

接着上面的局面 ($IWKC = 0.5$)，假设候选集里有两道题：

候选 q_3 考代数： cnt (代数) 从 2 变 3, $IncCov$ 从 0.667 变 0.75：

$$IWKC_{\text{新}} = \frac{3 \times 0.75 + 2 \times 0.5 + 0}{6} = 0.542, \quad \Delta = +0.042$$

候选 q_4 考概率： cnt (概率) 从 0 变 1, $IncCov$ 从 0 变 0.5：

$$IWK C_{\text{新}} = \frac{3 \times 0.667 + 2 \times 0.5 + 1 \times 0.5}{6} = 0.583, \quad \Delta = +0.083$$

尽管代数权重 (3) 是概率 (1) 的三倍, q_4 还是赢了——因为概率一片空白, 第一道题的 +0.5 涨幅太大, 盖过了权重劣势。这正是设计者想要的行为: 权重决定“该多测谁”, 软覆盖决定“别落下谁”, 两股力量在同一个分数里自动讨价还价。

反过来, 如果概率已经测过一道, q_4 的增益会掉到 $\frac{1 \times 0.167}{6} \approx 0.028$, q_3 就会反超——不会无脑地在冷门知识点上堆题。

9. 总结: 七个公式其实是一条流水线

数数 (7) $\rightarrow$ 压成软分 (6) $\rightarrow$ 加权平均 (5) $\rightarrow$ 试放量涨幅 (9) $\rightarrow$ 挑涨幅最大 (8)

而式 (3)(4) 只是被批判的旧方案。所有复杂记号剥掉后, 每一步都是小学算术——真正的巧思只有一处: $\frac{cnt}{cnt+1}$ 这个“越测越不值钱”的形状。