

MAAT 重要性模块公式详解

逐个拆解 MAAT(ICDM 2020)Importance Module 的式 (10)–(15), 配数值例子。式 (11)(12) 前专门补一节 Skip-Gram 基础, 零 NLP 背景可读。

这个模块只回答一个问题: IWKC(式 5) 里的权重 w_k ——每个知识点多重要——从哪来? 它在考试开始前用历史作答数据一次性算好, 考试中直接查表。

整体逻辑链 (先记住这个, 公式只是逐环的实现):

1. 知识点重不重要, 看它名下的题目有没有代表性;
2. 有代表性的题 = 和很多其他题相似的题 (考了它, 等于间接摸了一批相似题, 一题顶多题);
3. 要衡量“题与题相似”, 得先把每道题变成向量 (空间中的点), 距离近 = 相似;
4. 向量从哪来? 从历史学生的作答记录里学: 被学生们“表现得很像”的题, 向量就该靠得近。

对应的流水线: 学题目向量 (式 10–12) → 算每道题的密度 (式 13–14) → 知识点权重 = 名下题目密度的平均 (式 15)。

1. 式 (10): 把“一条作答记录”编码成向量

$$x_{ij} = \begin{cases} \mathbb{1}_{|Q|}(j) \oplus \mathbb{1}_{|Q|}(j), & \text{若 } a_{ij} = 1 (\text{答对}) \\ \mathbb{1}_{|Q|}(j) \oplus \mathbf{0}_{|Q|}, & \text{若 } a_{ij} = 0 (\text{答错}) \end{cases}$$

符号读法: $\mathbb{1}_{|Q|}(j)$ 是长度为题库大小 $|Q|$ 、只有第 j 位是 1 的独热向量; $\mathbf{0}_{|Q|}$ 是全零向量; $\oplus$ 是拼接 (不是加法), 拼完长度 $2|Q|$ 。

在干什么: 一条记录要同时说清两件事——“做的是哪道题”和“对了没有”。前半段永远在第 j 位标 1 (做的是第 j 题); 后半段答对时也在第 j 位标 1, 答错时全零。同一道题, 答对和答错是两个不同的“词”——这是后面 word2vec 类比的伏笔。

代入例子: 题库 $|Q| = 4$, 学生做了 q_2 :

- 答对: $x = [0, 1, 0, 0 \mid 0, 1, 0, 0]$ (8 维)
- 答错: $x = [0, 1, 0, 0 \mid 0, 0, 0, 0]$

2. 补课: Skip-Gram 到底是什么?

式 (11)(12) 看不懂, 几乎一定是因为它默认读者熟悉 word2vec。这一节从零讲起, 讲完再回去看那两个式子, 它们就只是“换了符号的抄写”。

2.1 目标: 把“词”变成向量, 且意思相近的词向量要靠近

计算机怎么表示一个词? 最朴素的是独热向量: 词表 1 万个词, 就用 1 万维、只有一位是 1 的向量。它有个致命缺点: 任何两个独热向量都互相垂直、两两等距, “猫”和“狗”的距离等于“猫”和“微积分”的距离, 语义完全体现不出来。

我们想要的是: 每个词一个低维稠密向量 (比如 100 维), 并且意思相近的词, 向量自动靠近。word2vec(2013) 就是做这件事的工具, Skip-Gram 是它的训练方式之一。

2.2 核心思想: 一个词的意思, 由它的“邻居”定义

语言学里有个分布假设 (distributional hypothesis): 经常出现在相似上下文里的词, 意思相近。看例子:

- “我家的猫在睡觉”/“我家的狗在睡觉”
- “喂猫吃罐头”/“喂狗吃罐头”

“猫”和“狗”本身几乎从不挨着出现, 但它们的邻居 (我家的、睡觉、喂、罐头) 高度重合。Skip-Gram 利用这一点, 设计了一个“假任务”: 给模型句子中间的一个词 (中心词), 让它预测周围会出现哪些词 (上下文词)。

关键在于: 为了预测得准, 模型被迫给“邻居相似”的词分配相似的向量——“猫”和“狗”都要预测出同一批邻居, 向量不靠近就做不到。词向量是这个预测任务的副产品; 任务本身 (预测邻居) 训练完就没人关心了, 大家要的只是练出来的向量。

2.3 预测概率怎么算? 点积打分

给中心词 c 和候选词 o , Skip-Gram 用两个向量的点积打分: 点积越大, 表示“ o 越可能出现在 c 旁边”。原始版本再用 softmax 把整个词表的分数归一化成概率:

$$p(o | c) = \frac{\exp(u_o \cdot v_c)}{\sum_{w \in \text{词表}} \exp(u_w \cdot v_c)}$$

这里有个后面要用的细节: 每个词其实有两套向量——它当中心词时用 v , 当“被预测的邻居”时用 u 。两套分开学, 训练完通常只保留一套。

2.4 负采样: softmax 太贵, 改成“真假判别”

上式的分母要对整个词表 (几十万词) 求和, 每步训练都算一遍, 太慢。负采样 (Negative Sampling) 换个提法: 不做“从几十万词里挑一个”的多分类, 改做几个二分类——给一对词, 判断它是“真实共现的对”还是“随机拼凑的假对”:

- 正样本: 语料里真实挨着出现的 (c, o) , 要求模型判“真”: $\sigma(u_o \cdot v_c) \rightarrow 1$, 即点积越大越好;
- 负样本: 保持 c 不动, 从词表随机抽 N_{neg} 个词 n (大概率与 c 无关) 拼成假对 (c, n) , 要求模型判“假”: $\sigma(-u_n \cdot v_c) \rightarrow 1$, 等价于点积 $u_n \cdot v_c$ 越小越好。

$\sigma(x) = \frac{1}{1+e^{-x}}$ 是 Sigmoid, 把任意实数压到 $(0, 1)$, 当作“这一对是真的”的概率。

为什么必须有负样本? 若只有正样本 (只要求真的点积大), 模型有个作弊解: 把所有词向量调成同一方向、模长拉到无穷大, 则任何两词点积都是无穷大、所有 σ 都是 1, 目标“完美”达成, 但向量什么也没学到。负样本提供反向的力 (“无关的词要推远”), 两股力平衡后, 空间里的远近才有含义: 共现过的拉近, 没共现的推远。

每一步训练的几何图像: v_c 被朝正样本 u_o 的方向拉近一点, 同时被朝远离各负样本 u_n 的方向推开一点。

2.5 从“句子”到“做题记录”: Item2Vec 的一步改造

MAAT 论文引用的其实是 Item2Vec——把 word2vec 从 NLP 搬到推荐系统的经典做法, 改动只有一处:

- 句子里的词有顺序, Skip-Gram 只把窗口内 (如前后 5 个词) 算作邻居;

- 一个用户买过的商品集合没有顺序,Item2Vec 干脆规定: 同一集合里任意两个元素都算共现 (相当于窗口无限大)。

MAAT 照搬到教育场景, 对照表:

word2vec	Item2Vec	MAAT
一句话	一个用户的购物篮	一个学生的全部做题记录
一个词	一件商品	一条记录 (题号 + 对错)
窗口内相邻 = 共现	同一购物篮 = 共现	同一学生名下 = 共现
练出词向量	练出商品向量	练出题目“测试效应”向量

补课结束。带着 2.4 的两条 (“正样本 $\sigma(u_o \cdot v_c)$ 、负样本 $\sigma(-u_n \cdot v_c)$ ”) 回去看式 (11)(12)。

3. 式 (11): 训练目标——“两两配对, 互相预测”

$$\max \frac{1}{|R_k^H|} \sum_{r_{ki} \in R_k^H} \sum_{r_{kj} \in R_k^H, j \neq i} \log p(r_{kj} | r_{ki})$$

R_k^H 是历史学生 e_k 的全部做题记录。按 2.5 的规定, 同一学生名下任意两条记录都算共现, 所以: 外层求和遍历他的每条记录 r_{ki} (充当“中心词”), 内层遍历他其余每条记录 r_{kj} (充当“邻居”), 把每一对的 $\log p$ 加起来, 除以记录条数, 越大越好。双重求和只是“两两配对”的书面写法。

代入例子: 学生 e_k 做过 3 条记录 A, B, C , 则有序配对共 6 个, 目标就是:

$$\frac{1}{3} \left[\log p(B|A) + \log p(C|A) + \log p(A|B) + \log p(C|B) + \log p(A|C) + \log p(B|C) \right]$$

所有历史学生的这个量加总, 一起最大化。翻译成入话: 训练模型做到“看见一个学生做过记录 **A**, 就能猜出他历史里还有记录 **B**”。和 2.2 节同理, 猜得准的唯一途径, 是给“总出现在同一批学生名下”的记录分配相近的向量——向量是副产品, 预测是手段。

4. 式 (12): 一对记录的“共现概率”= 1 个正样本项 $\times N_{neg}$ 个负样本项

$$p(r_{kj} | r_{ki}) = \underbrace{\sigma((Wx_{ki})^T v_j)}_{\text{正样本: 拉近}} \underbrace{\prod_{l=1}^{N_{neg}} \sigma(-(Wx_{kn_l})^T v_{n_l})}_{N_{neg} \text{ 个负样本: 推远}}$$

先对照 2.4 节逐项“认领”:

Skip-Gram 负采样 (2.4 节)	式 (12)
中心词向量 v_c	Wx_{ki} (当前记录的向量)
邻居词向量 u_o	v_j (题 q_j 的嵌入)
正样本项 $\sigma(u_o \cdot v_c)$	$\sigma((Wx_{ki})^T v_j)$
负样本项 $\sigma(-u_n \cdot v_c)$	$\sigma(-(Wx_{kn_l})^T v_{n_l})$

把式 (12) 代回式 (11) 取对数, 连乘变连加: $\log \sigma(\text{正}) + \sum_i \log \sigma(-\text{负})$ ——这正是标准 SGNS 损失。所以式 (12) 并不是一个严格归一化的概率 (各项加起来不等于 1), 它只是沿用 word2vec 原论文的记法, 把“一正多负”的判别目标写成了乘积形式, 不必纠结它“是不是真概率”。

还剩三个符号, 逐个拆:

(a) Wx_{ki} 在干嘛?——“两套向量”里的第一套。2.3 节说过每个“词”有两套向量。这里中心词的向量不是直接查表, 而是用矩阵 $W(d \times 2|Q|)$ 乘式 (10) 的独热拼接 x_{ki} 得到。因为 x 里只有一两个位置是 1, 矩阵乘法实际是从 W 的 $2|Q|$ 列里挑列相加:

- 记录 = 答对第 j 题: x 的第 j 位和第 $|Q| + j$ 位是 1 $\rightarrow Wx = W$ 第 j 列 + 第 $|Q| + j$ 列;
- 记录 = 答错第 j 题: 只有第 j 位是 1 $\rightarrow Wx = W$ 第 j 列。

可以把 W 的前 $|Q|$ 列理解为每道题的“基础向量”, 后 $|Q|$ 列是“答对加成向量”: 答对/答错同一道题的两种记录共享基础列、只差一个加成列——既区分了对错 (2.2 节的类比里它们是两个不同的“词”, 能有不同的邻居分布), 又不至于把同一道题的两种结果学成毫无关系的东西。

(b) v_j ——“两套向量”里的第二套, 也是我们最终要的东西。每道题 q_j 配一个 d 维向量 v_j , 充当“被预测的邻居”角色。注意: x (式 10) 区分对错, 但 v 按题编号、不分对错——每道题最终只有一个嵌入。训练完, W 功成身退丢掉, 保留 v_j 作“测试效应嵌入” (论文记作 q_j^{TE}), 供式 (13)–(15) 算距离用。

(c) 负样本 n_l : 随机抽 N_{neg} 条别的记录当“假邻居”, 通过 $\sigma(-\cdot)$ 要求点积小, 即把无关记录的向量推远。作用同 2.4 节: 没有它, 一切向量会坍塌到“全都无穷相似”的作弊解。

细心的话会发现一处不严格: 按 word2vec 原版, 负样本项应是中心记录和负样本嵌入的点积 $\sigma(-(Wx_{ki})^T v_{n_l})$, 而论文写成 Wx_{kn_l} (负样本自己配自己)。一般认为这是论文记法上的笔误/简写, 按标准 SGNS 理解即可, 不影响任何结论。

代入例子: $d = 2, N_{neg} = 1$ 。设当前记录 (中心) 的向量 $Wx_{ki} = (1, 0.5)$, 正样本 $v_j = (0.8, 0.4)$, 负样本 $v_n = (-0.5, 1)$:

- 正样本点积: $1 \times 0.8 + 0.5 \times 0.4 = 1.0, \sigma(1.0) = 0.731$;
- 负样本点积: $1 \times (-0.5) + 0.5 \times 1 = 0, \sigma(-0) = 0.5$;
- $p = 0.731 \times 0.5 = 0.366$ 。

训练就是不断微调 W 和所有 v 让 p 变大: 这一步会把 v_j 朝 $(1, 0.5)$ 方向拉近一点、把 v_n 推远一点。

为什么训练完, “考察效果相似”的题会聚在一起? 设想两道题 q_a, q_b : 会做 q_a 的学生大多也会做 q_b , 它们总是共同出现在同一批学生的记录里、周围的“邻居记录”也高度重合。那么训练中 v_a 和 v_b 会被同一批中心向量反复朝同一方向拉——被同一批力拉的两个点, 最后自然停在相近的位置 (正如“猫”和“狗”因邻居相同而向量靠近)。这种“近”衡量的不是题面文字像不像, 而是学生做起来的表现像不像——难度、区分度、考察的能力相近——所以叫“测试效应”嵌入。

5. 式 (13): 两道题的相似度——距离换算成 0 到 1 的分数

$$\text{Sim}^{TE}(q_i, q_j) = e^{-\gamma \|q_i^{TE} - q_j^{TE}\|}$$

$\|\cdot\|$ 是欧氏距离 (两点间直线距离), γ 是控制衰减快慢的正数旋钮。距离 $0 \rightarrow$ 相似度 1; 距离越远, 指数衰减到 0。没有更多内容, 就是“把距离翻译成相似度”。

代入例子 ($\gamma = 1$): 两题嵌入相距 0.3, $\text{Sim} = e^{-0.3} = 0.741$; 相距 2, $\text{Sim} = e^{-2} = 0.135$ 。

6. 式 (14): 密度——这道题周围挤不挤?

$$Den^{TE}(q_j) = \frac{1}{K_N} \sum_{q_i \in N(q_j)} Sim^{TE}(q_i, q_j)$$

$N(q_j)$ 是 q_j 在嵌入空间里的 K_N 个最近邻。密度 = 和这几个最近邻的平均相似度。

直觉: 一道题若处在密集题目簇的中心 (周围一堆测试效应相似的题), 密度高——考它一道, 等于把整簇题间接摸了一遍, 代表性强; 孤零零在角落的题, 只能代表它自己, 密度低。

7. 式 (15): 知识点重要性——名下题目密度取平均

$$w_k = \frac{1}{\sum_{(q,k) \in G} 1} \sum_{(q,k) \in G} Den^{TE}(q)$$

式子看着绕, 其实分母 $\sum 1$ 就是“数一数知识点 k 名下有几道题”, 整个式子就是求平均: w_k = 关联 k 的所有题的密度平均值。名下的题普遍有代表性 $\rightarrow k$ 是题库的“主干考点” $\rightarrow$ 权重大, IWKC 里覆盖它更值钱。

8. 一个完整的数值例子: 从嵌入一路算到 w_k

设训练完成后 5 道题的嵌入 ($d = 2$) 如下, 取 $\gamma = 1, K_N = 2$:

题目	嵌入坐标	关联知识点
q_1	(0, 0)	代数
q_2	(0.3, 0)	代数
q_3	(0, 0.4)	代数
q_4	(3, 3)	几何
q_5	(3.2, 3)	几何

q_1, q_2, q_3 挤成一簇, q_4, q_5 是远处的一小撮。

算密度 (式 13 + 14), 以 q_1 为例: 它的 2 个最近邻是 q_2 (距离 0.3) 和 q_3 (距离 0.4):

$$Den(q_1) = \frac{e^{-0.3} + e^{-0.4}}{2} = \frac{0.741 + 0.670}{2} = 0.706$$

同法算出全部:

题目	最近邻 (距离)	密度
q_1	$q_2(0.3), q_3(0.4)$	0.706
q_2	$q_1(0.3), q_3(0.5)$	$(0.741 + 0.607)/2 = 0.674$
q_3	$q_1(0.4), q_2(0.5)$	$(0.670 + 0.607)/2 = 0.639$
q_4	$q_5(0.2), q_1(4.24)$	$(0.819 + 0.014)/2 = 0.417$
q_5	$q_4(0.2), q_1(4.53)$	$(0.819 + 0.011)/2 = 0.415$

注意 q_4, q_5 : 虽然彼此很近 (相似度 0.819), 但第二个最近邻已经要跨到远处的簇 (相似度几乎为 0), 密度被拉低——小孤岛的代表性天然弱于大陆。

算权重 (式 15):

$$w_{\text{代数}} = \frac{0.706 + 0.674 + 0.639}{3} = 0.673, \quad w_{\text{几何}} = \frac{0.417 + 0.415}{2} = 0.416$$

代数名下的题聚成大簇 → 权重 0.673; 几何是边缘小簇 → 权重 0.416。代回 IWKC(式 5), 多样性模块就会优先保证代数的覆盖, 而不为几何浪费太多宝贵题量。

9. 总结

六个公式 = 三步流水线:

$$\underbrace{\text{式 (10)-(12)}}_{\text{word2vec 学题目向量}} \rightarrow \underbrace{\text{式 (13)(14)}}_{\text{距离} \rightarrow \text{相似度} \rightarrow \text{密度}} \rightarrow \underbrace{\text{式 (15)}}_{\text{密度取平均得 } w_k}$$

核心思想一句话: 被学生们“表现得相似”的题会在向量空间里聚簇; 处在大簇中心的题最有代表性; 名下题目普遍有代表性的知识点, 就是值得优先覆盖的“主干考点”。

提醒: 本文件夹的开源代码没有实现这个模块 (所有知识点等权, $w_k \equiv 1$), 所以代码里找不到式 (10)-(15) 的对应实现, 属正常现象。