

质量遇见多样性：一个模型无关的计算机自适应测试框架 (Quality meets Diversity: A Model-Agnostic Framework for Computerized Adaptive Testing)

原文: 2101.05986v1.pdf (arXiv:2101.05986, 2021-01-15) ·译者: Claude ·译于 2026-06-25 作者: Haoyang Bi, Haiping Ma, Zhenya Huang, Yu Yin, Qi Liu, Enhong Chen, Yu Su, Shijin Wang (中国科学技术大学、安徽大学、科大讯飞研究院) 术语对照: Computerized Adaptive Testing (CAT, 计算机自适应测试); Cognitive Diagnosis Model (CDM, 认知诊断模型); Item Response Theory (IRT, 项目反应理论); Active Learning (AL, 主动学习); Expected Model Change (EMC, 期望模型变化); Importance Weighted Knowledge Coverage (IWKC, 重要性加权知识覆盖); submodular (次模/子模)。

摘要

计算机自适应测试 (Computerized Adaptive Testing, CAT) 正在教育、游戏、招聘等众多场景中成为一种有前景的测试应用, 其目标是诊断被试在所需知识概念上的掌握水平。CAT 的优势在于为每位被试量身定制个性化的测试流程——根据被试的作答表现, 逐步地选择题目。尽管已有大量工作致力于开发 CAT 系统, 但现有方案普遍遵循一种不灵活的、**模型特定 (model-specific)** 的范式: 它们需要观察某个具体的认知模型 (cognitive model), 由该模型估计被试的知识水平, 再依据模型的估计结果来设计选题策略。本文研究一个新颖的**模型无关 (model-agnostic)** CAT 问题, 目标是提出一个灵活的框架, 能够适配不同的认知模型。同时, 本工作还探究了如何同时生成既高质量又多样的题目, 从而为每位被试提供全面的知识诊断。受主动学习 (Active Learning) 启发, 我们提出一个新框架, 即**模型无关自适应测试 (Model-Agnostic Adaptive Testing, MAAT)**, 其中设计了三个精巧的模块: 质量模块 (Quality Module)、多样性模块 (Diversity Module) 和重要性模块 (Importance Module)。具体而言, 在一个 CAT 选题步骤中, 质量模块首先量化题目的信息量, 生成质量最高的候选子集; 随后多样性模块在每一步选出一道使概念覆盖最大化的题目; 此外, 我们提出重要性模块来估计各概念的重要性, 以优化 CAT 选题。在 MAAT 框架下, 我们证明同时最大化质量与多样性的目标是 NP-hard 的, 但我们利用其内在的次模 (submodular) 性质提供了高效算法。在两个真实数据集上的大量实验清晰地表明, MAAT 能够在保证质量与多样性两个层面的前提下支撑 CAT。

关键词——计算机自适应测试 (Computerized Adaptive Testing)、模型无关 (Model-Agnostic)、质量 (Quality)、多样性 (Diversity)

一、引言

设计合适的测试来评估被试在所需概念上的知识状态, 是教育、游戏、招聘等众多现实场景中的一项基础任务。传统上, 教师可以组织一次纸笔测试, 一次性为被试精心挑选一组题目, 然后我们便能从他们的作答表现中评估其状态。这种简单方式虽然有效, 但它只为所有被试提供相同的环境, 因而难以保证所有选题对每个人都合理。为此, 近来的努力转向另一种测试形式——**计算机自适应测试 (CAT)**, 它旨在构建对每位被试个性化适配的测试, 依据被试的作答表现逐步定制题目。事实上, CAT 具有诸多优势, 包括提高准确性、保障安全性、增强被试参与度, 并已应用于许多标准测试机构, 如研究生管理科入学考试 (GMAT) 和研究生入学考试 (GRE)。

在实践中, 一个典型的 CAT 系统通常由两个关键部件构成: **(1) 一个认知诊断模型 (CDM)**, 根据被试的作答表现估计其知识状态; **(2) 一个选择策略 (selection strategy)**, 从题库中挑选题目以支撑测试流程。如图 1(a) 所示, 当一位被试 e_1 到来时, 该 CAT 系统可为其建立一个交互式测试流程。在第 t 步, 系统先发布一道题 (例如 q_t); 随后被试阅读并作答; 在收到回答 (即对或错) 之后, 带有 CDM 的系统估计其当前状态, 并在此基础上为下一轮精心选出新题 q_{t+1} 。该流程重复若干次, 直到满足终止条件 (如达到最大测试长度), 从而我们可以了解被试对所需概念 (如数学中的“函数”) 的掌握程度。如此一来, 即便从同一道题开始, 不同被试 (如图 1(b) 中的 e_1 与 e_2) 仍可获得个性化的定制。因此, 关键问题在于如何建立一个最优的 CAT 系统, 为被试选择合适的题目。

图 1: (a) 一个典型 CAT 系统及其单步测试流程的示意。(b) 被试 e_1 与 e_2 所经历的 CAT 流程的两个示意例子。我们用不同颜色表示不同题目。

在已有文献中, 关于 CAT 设计的努力很多, 且已支撑了许多标准测试。一般而言, 现有方案深入挖掘底层的 CDM, 例如项目反应理论 (IRT) 及其多维版本 (MIRT), 然后通过观察与被试知识状态相关的对应模型参数来产生题目。例如, Lord 等人建立了一个 CAT 系统, 其中提出了一种最大费舍尔信息 (maximum Fisher information) 策略, 贪心地选择能使被试参数 (由具体 IRT 模型估得) 方差最小化的题目。尽管这些工作取得了巨大成功, 但它们都是**模型特定的**, 即 CAT 方案只适用于其指定的 CDM。换言之, 在设计 CAT 选题策略时, 我们必须详细理解某个具体 CDM (如 IRT 或 MIRT) 的工作机理。因此, 现有 CAT 系统通常变得不灵活, 因为一旦替换背后的 CDM, 就必须重新设计选择策略。然而, 如上所述, CAT 主要的目标是在测试过程中选出合适的题目, 这给了我们一个直觉: 无论我们探究哪种 CDM 模型, 我们只需关心被试状态的结果即可。为此, 我们主张一个理想的 CAT 框架应当是**模型无关的**, 即 CAT 方案能够适配不同的 CDM。

据我们所知, 此前尚无 CAT 工作尝试实现模型无关框架。幸运的是, 我们注意到主动学习 (Active Learning, AL) 中有一个类似的思想——AL 是一个流行的框架, 用于缓解图像分类、推荐等众多任务中的数据匮乏问题。原则上, AL 框架旨在设计一种策略, 逐步把有价值的数据挑选给专家进行标注, 从而使机器学习模型能够在有监督方式下被良好训练。直觉上, AL 启发了我们去解 CAT, 因为它同样可以忽略我们必须使用哪种机器学习模型。因此, 本文提出一个新颖的**模型无关自适应测试框架 (MAAT)** 来求解 CAT, 我们在宏观层面借鉴了主动学习的通用思想。

为支撑能够全面评估被试知识状态的 MAAT 流程, 我们主张在设计自适应选题策略时应考虑两个必要目标:

(1) **质量 (Quality)**。首要地，为测试选择高质量的题目能使 CAT 流程更高效。例如，如果我们总是让被试去做太难或太易的题目，那是不合适的，因为我们根本无法获得关于他们的准确诊断结果。因此，一种能评估题目信息量的有效方法是迫切需要但又非平凡的。

(2) **多样性 (Diversity)**。在某个特定领域（如数学）中，被试通常需要学习大量知识（如“函数”）。在 CAT 过程中，我们需要评估他们对所有知识概念的掌握情况。然而，如果沿用传统方案，结果可能是次优的，因为它们鲜有直接考虑这种多样性问题，导致在各概念上的选题非常受限。因此，有必要在 MAAT 中选择尽可能覆盖更多概念的题目。

为在兼顾上述两个目标的前提下解决该问题，我们以三个模块——质量模块、多样性模块和重要性模块——来实现 MAAT 框架。具体而言，在一个 CAT 选题步骤中，质量模块首先从题库中生成一个由质量最高题目组成的小候选子集，其中提出一个新颖的评分函数，用以量化被试作答后题目对知识掌握的信息增益。与现有方案不同，该模块是灵活的，因为它通过期望模型变化 (Expected Model Change, EMC) 来评估信息量，而无需知晓变化背后的具体机制。随后，多样性模块从候选集中选出一道在整个 CAT 流程中使概念覆盖最大化的题目。我们还提出重要性模块来估计各概念的重要性，以优化选题流程。此外，我们证明在我们精心设计的覆盖评分函数下，同时最大化质量与多样性的问题是 NP-hard 的，并通过利用次模性质提供了高效算法。最后，我们在两个真实数据集上进行了大量实验。实验结果表明，MAAT 能以模型无关的方式选出既高质量又多样的题目，可以支撑众多 CAT 场景。

二、相关工作

1) 计算机自适应测试 (CAT)：CAT 的发展源于这样一种信念——如果我们为被试量身定制测试，测试就能更有效。尽管近来出现了一些变体，CAT 的主要挑战仍在于设计一种逐步为被试选择合适题目的选择策略。由于当前策略与底层的认知诊断模型 (CDM) 紧密绑定，我们就按其所依赖的 CDM 来综述它们。代表性的 CDM 包括传统的项目反应理论 (IRT) 家族和近来提出的深度学习模型。基于 IRT 的 CAT 策略最小化 IRT 中潜在参数的统计估计误差；基于 MIRT 的策略则是基于 IRT 策略的多变量扩展。据我们所知，由于深度学习模型参数复杂，针对它们设计策略的进展甚少。尽管已有方法成效显著，当前策略仍存在两点局限：第一，它们必须详细理解底层 CDM 的工作方式，使 CAT 系统变得模型相关且不灵活（原文此处写作“model-agnostic and inflexible”，依上下文应为 model-specific/模型相关）；第二，它们忽视了选题中的多样性，可能造成知识概念掌握诊断上的不平衡。我们在所提出的模型无关框架内给出新颖的解决方案，将在第四节讨论。

2) 主动学习 (Active Learning)：主动学习 (AL) 的动机在于这样一种信念——如果我们主动地选择有价值的数据，就能用更少的数据训练出更好的模型；它已被应用于许多有监督学习任务。从一个机器学习模型和一个数据选择策略出发，AL 框架在每一步选出一批未标注数据进行标注，以补充有限的已标注数据，从而使模型获得更好的性能。关键在于如何在策略设计中避免使用模型细节，使其能应用于带有不同模型的各类任务。一般而言，存在两类方案，分别利用模型输出和数据特征：基于不确定性 (uncertainty based) 的算法检查模型输出的标签预测，选出预测中不确定性最大的样本；基于代表性 (representativeness based) 的算法检查数据样本的特征，选出最能代表未标注数据整体模式的样本。这些方法论启发我们也为 CAT 提出一个模型无关的方案，但有着专属于 CAT 的不同目标（即质量与多样性），以及一种优化这些目标的新颖策略。

3) 覆盖度量 (Coverage Measure)：覆盖度量在文档摘要、网络分析、推荐等任务中已被广泛研究，在这些任务中，我们试图找到一个子集，使其覆盖文档或推荐中尽可能多的信息。在推荐等许多场景中，直觉上考虑这种覆盖目标会更好。特别地，一些先前工作在其覆盖评分函数的设计中利用了次模性 (submodularity) 来进行优化——次模性是对直觉上的边际收益递减 (diminishing returns) 性质的一种数学建模。据我们所知，我们的工作首次以一个形式化的覆盖度量在 CAT 中显式地定义知识概念的多样性目标，并通过利用其内在的次模性提供高效的优化算法。

三、预备知识

本节讨论计算机自适应测试 (CAT) 的术语、目标与问题重构。

A. 术语

1) 环境 (Environment)：作为测试的一种具体形式，CAT 系统在一个由被试与题目构成的典型测试环境中运行。设有被试集 $E = \{e_1, e_2, \dots, e_{|E|}\}$ 和题目集 $Q = \{q_1, q_2, \dots, q_{|Q|}\}$ 。我们将被试 e_i 作答题目 q_j 的记录表示为三元组 $r_{ij} = \langle e_i, q_j, a_{ij} \rangle$ ，其中若 e_i 答对 q_j 则 $a_{ij} = 1$ ，否则为 0。我们将全部记录记为 R ，属于某被试 e_i 的记录记为 R_i 。此外，设有一组与题目相关的知识概念 $K = \{k_1, k_2, \dots, k_{|K|}\}$ 。我们将题目与概念之间的关联表示为一个二元关系 $G \subseteq Q \times K$ ，若 q_i 与 k_j 相关则 $(q_i, k_j) \in G$ 。

2) 状态 (Status)：除了静态环境，CAT 系统还维护一些专用于自适应测试的动态状态。具体而言，在对某被试 $e_i \in E$ 的测试中，题目集 Q 被划分为已测集 Q_T 与未测集 Q_U 。初始时 $Q_U = Q$ ， $Q_T = \emptyset$ 。每一步从 Q_U 中选出一道加入 Q_T 。当测试结束时， Q_T 即构成为 e_i 定制的测试序列。

表 1: CAT 与 AL 的概念对应

CAT 概念	AL 概念	记号
认知诊断模型	有监督学习模型	M
题目选择策略	样本查询策略	S
被试	专家标注者	E

CAT 概念	AL 概念	记号
题目	数据样本	Q
已测/未测题目	已标注/未标注样本	Q_T, Q_U

3) 部件 (Components): 最后, 我们形式化 CAT 系统的部件。沿用图 1(a), 我们将一个 CAT 系统形式化地记为 (M, S) , 其中 M 是认知诊断模型 (CDM), S 是题目选择策略。与传统 CAT 系统不同, 在我们的问题中, M 不指代任何具体的 CDM (如 IRT), 而是一个具备两项基本功能的抽象模型: (1) M 用一组参数 θ 刻画被试的知识状态, 且不对其具体形式或机制做任何假设; (2) 给定一位被试 $e_i \in E$ 和一道题 $q_j \in Q$, M 能输出一个表现预测 $M(e_i, q_j | \theta) \in [0, 1]$, 衡量 e_i 答对 q_j 的可能性。 S 接受 Q_U 和 M 作为输入, 输出一道题 $q \in Q_U$, 即 $q = S(Q_U, M)$ 。换言之, 它根据当前估计的知识状态从未测题集中做出选择。

B. 目标

我们现在讨论选择策略 S 的两个目标。

1) 质量 (Quality): 一般而言, 一道高质量的题目有助于降低被试知识状态的不确定性。因此, 我们通过题目的信息量 (informativeness) 来量化其质量, 即底层模型 M 能从该题获得多少信息来更新对知识状态的估计。如此一来, 达成质量目标即意味着选择信息量最大的题目。为评估信息量, 在对 $e_i \in E$ 的测试结束后, 我们用 M 在整个题库上预测其表现, 并用某种指标 (如 AUC) 来度量。我们将此度量记为 $\text{Inf}(S)$, 将在第五节详述。

2) 多样性 (Diversity): 一般而言, 若一组题目满足某些覆盖要求, 我们就认为它是多样的。我们直觉地用知识覆盖度来度量多样性。因此, 达成多样性目标即意味着选择一组具有最大知识概念覆盖的题目。测试结束后, 我们可以用已测题集 Q_T 所覆盖知识概念的比例来评估覆盖度, 记为 $\text{Cov}(S)$, 将在第五节详述。

C. 问题形式化

受主动学习启发 (见表 I), 我们重构我们的模型无关 CAT 问题, 但有一个关键区别: 我们的目标是在同时兼顾上文所述的质量与多样性目标下求解该问题:

问题定义。 给定一位新被试 $e_i \in E$ 、一个带有知识概念 K 的题库 Q , 我们的任务是设计一个策略 S , 逐步选出一个 N 大小的题集 $Q_T = \{q_1^*, q_2^*, \dots, q_N^*\}$, 使其具有最大的质量与多样性。测试前, 我们建立一个带参数 θ 、刻画知识状态的抽象 CDM M 。测试中, 在第 t 步 ($1 \leq t \leq N$), 我们选出一道题 $q_t^* = S(Q_U, M)$, 随即观察到一条新的交互测试记录 $r_{it}^* = \langle e_i, q_t^*, a_{it}^* \rangle$, 并即时更新 M 中的知识状态 (即 θ)。测试后, 我们通过计算 $\text{Inf}(S)$ 与 $\text{Cov}(S)$ 来度量 S 的有效性。

四、MAAT 框架

A. 总览

我们在图 2 中给出 MAAT 框架的总览。对任意被试 $e_i \in E$, 所提框架在与其交互中逐步恰当地生成一个题集。在第 t 步, MAAT 从未测题集 Q_U 中选出一题加入已测题集 Q_T , 同时优化质量与多样性两个目标。整体架构可看作三个模块: 质量模块、多样性模块和重要性模块。具体而言, 在第 t 步, 质量模块从 Q_U 中选出一个候选题集 Q_C , 它由信息量最大的 $\text{top-}K_C$ 高质量题目组成; 随后多样性模块从 Q_C 中选出一道最终题目 q_t^* 加入 Q_T , 该题对 Q_T 的知识覆盖贡献最大的边际增益。此外, 为获得更高效的选题流程, 我们提出重要性模块来评估知识概念的重要性, 它利用历史数据在测试前预先计算。

图 2: MAAT 框架总览。

B. 质量模块 (Quality Module)

我们首先介绍质量模块, 它是第 t 步的第一阶段 (见图 2 左上部分)。该模块的目标是从 Q_U 中选出一个由 $\text{top-}K_C$ 高质量题目组成的候选集 Q_C ($K_C = |Q_C|$)。为此, 我们提出一个评分函数, 即期望模型变化 (Expected Model Change, EMC), 它通过度量题目的信息量 (即所含信息多少) 来量化题目质量。与传统 CAT 启发式函数不同, EMC 独立于 CDM 的细节。

其背后的总体思想如下。我们通过观察到被试的回答后更新对其知识状态的估计, 来利用一道题中所含的信息。因此, 信息量可以由诊断结果经一道题后改变了多少来评分。在 MAAT 中, 知识状态由抽象 CDM 的参数 (即 M 中的 θ) 承载。无论具体机制如何, CDM 改变了多少都意味着从该题获得的信息量。具体而言, 若 θ 有较大改变, 则该题可被视为信息量大; 反之, 若 θ 几乎不变, 则知道该题的回答带来的信息很少。

挑战在于, 在选题之前不可能知道被试的回答。因此, 我们计算模型变化关于“被试答对该题的概率” (由 M 预测) 的期望。形式上, 令 $\Delta M(r_{ij}) = |\theta(R_i \cup \{r_{ij}\}) - \theta(R_i)|$ 为加入记录 $r_{ij} = \langle e_i, q_j, a_{ij} \rangle$ 后所得的模型变化, 其中 $\theta(R_i)$ 表示用 e_i 当前记录 R_i 训练得到的参数, $\theta(R_i \cup \{r_{ij}\})$ 同理。对每个 $q_j \in Q_U$, 我们定义其期望模型变化为:

$$EMC(q_j) = \mathbb{E}_{a_{ij} \sim p} \Delta M(< e_i, q_j, a_{ij} >), \quad (1)$$

$$p = M(e_i, q_j | \theta(R_i)). \quad (2)$$

为提高计算效率，我们用 r_{ij} 所引起的梯度来近似 $\Delta M(r_{ij})$ ，而非重新训练模型。这种近似对那些使用基于梯度训练的 CDM（如神经模型）尤其高效。

有了 EMC 评分函数后，对每道未测题 $q_j \in Q_U$ ，我们评估 $EMC(q_j)$ （式 (1)），然后选出信息量最大的 top- K_C 高质量题目作为候选集 Q_C 。

C. 多样性模块 (Diversity Module)

既然我们已有一个包含高质量题目的候选集 Q_C ，便转向多样性模块——它是第 t 步的第二阶段（见图 2 右上部分）。在该模块中，我们的目标是从 Q_C 中选出一道题 q_t^* 来优化多样性目标。该阶段的必要性来自这样一个观察：若忽视选題中的多样性，我们的诊断很可能是片面的。

为同样实现高多样性，我们首先提出一个量化已测题集 Q_T 知识覆盖的评分函数，然后寻找一种算法，通过逐步加入题目来构造覆盖评分最大的 Q_T 。两个主要挑战是：如何恰当地构造覆盖评分函数，以及如何设计优化算法。

为解决第一个挑战，我们从一个朴素知识覆盖 (Naive Knowledge Coverage, NKC) 函数出发，它简单地计算所选题集 Q_T 覆盖的知识概念占所有知识概念的比例：

$$NKC(Q_T) = \frac{\sum_{k \in K} Cov(k, Q_T)}{|K|}, \quad (3)$$

$$Cov(k, Q_T) = \mathbb{1}[\exists q \in Q_T, (q, k) \in G]. \quad (4)$$

NKC 虽然直观，但我们发现它存在两个实际缺陷：(1) 它平等地对待所有知识概念，无法区分其重要性。例如，在一次数学测试中，如果我们的测试更侧重“代数”而非“几何”，那么在覆盖两者之外，我们应当选更多与“代数”相关的题目。(2) 它过于严格，因为 $Cov(k, Q_T)$ 是二元的——取决于 k 是否被 Q_T 覆盖——这意味着只要 Q_T 中有至少一道题与 k 相关，无论确切数量多少， $Cov(k, Q_T)$ 始终等于 1。这一强条件可能导致所覆盖知识的不平衡。例如，在该条件下，选 9 道“代数”题加 1 道“几何”题，与各选 5 道是等价的，而后者通常是更好的选择。

为此，沿用文献中的思想，我们为 NKC（式 (3)）添加两个新特性：(1) 为考虑知识概念的重要性，我们为每个知识概念 $k \in K$ 加入一个重要性权重 w_k ；(2) 为缓解式 (4) 中严格二元 $Cov(k, Q_T)$ 造成的不平衡，我们将其改进为带有递增性质的软形式——即随着与该知识概念相关的题目越来越多，其取值从 0 逐渐增长到 1。形式上，我们提出一个进阶的评分函数，称为重要性加权知识覆盖 (Importance Weighted Knowledge Coverage, IWKC)：

$$IWKC(Q_T) = \frac{\sum_{k \in K} w_k \times IncCov(k, Q_T)}{\sum_{k \in K} w_k}, \quad (5)$$

$$IncCov(k, Q_T) = \frac{cnt(k, Q_T)}{cnt(k, Q_T) + 1}, \quad (6)$$

$$cnt(k, Q_T) = \sum_{q \in Q_T} \mathbb{1}[(q, k) \in G], \quad (7)$$

其中 w_k 是为概念 k 添加的重要性权重，是一个正常数（其计算将在第四节 D 部分讨论）。 $IncCov(k, Q_T)$ 是对式 (4) 中 $Cov(k, Q_T)$ 的递增式改进。例如，当与 k 相关的题目数量为 0, 1, 2, 3, ... 时， $IncCov(k, Q_T)$ 分别逐渐达到 0, 0.5, 0.67, 0.75, ..., 而 $Cov(k, Q_T)$ 则是从 0 到 1 不连续跳变。

需要注意的是，尽管 IWKC 已构造得当，其精巧的结构仍带来第二个挑战，即如何以逐步方式选出一组具有最大 IWKC 评分的题目。实际上，该优化问题被证明是 NP-hard 的（第四节 E 部分）。所幸，我们通过利用 IWKC 的次模性质找到了一个性能可接受的次优解。一般而言，次模性 (submodularity) 可被视为对自然的边际收益递减性质的一种数学建模。对一个次模集合函数，随着集合变大，再加入一个元素所获得的边际增益会递减。具体到我们的情形，随着选题步骤推进、 Q_T 越来越大，加入同一道题所带来的覆盖增益（即 IWKC）会变得越来越慢。为讨论清晰，我们将形式化证明留到第四节 E 部分。IWKC 的次模性质为我们提供了一个有性能保证的贪心选择算法。一般地，在测试的第 t 步，对每道候选题 $q_j \in Q_C$ ，我们评估若把 q_j 加入 Q_T 时 IWKC 的边际增益，并贪心地选出使边际增益最大的那道题作为第 t 步的选择 q_t^* ：

$$q_t^* = \arg \max_{q_j \in Q_C} \Delta_{q_j} IWKC(Q_T), \quad (8)$$

$$\Delta_{q_j} IWKC(Q_T) = IWKC(Q_T \cup \{q_j\}) - IWKC(Q_T). \quad (9)$$

依据上述算法, Q_T 的 IWKC 与最优值之比被保证至少为 $1 - \frac{1}{e}$ 。

D. 重要性模块 (Importance Module)

在展示了测试中每一步选出最优题目的两阶段流程之后, 我们转向求解 IWKC (式 (5)) 中重要性权重 w_k 的计算问题。如图 2 右下部分所示, 重要性模块在测试开始前为每个知识概念预先计算 w_k 。其总体思想是: 如果一个知识概念所关联的题目更具代表性, 就认为该概念更重要。通常, 若一道题与许多其他题目具有相似特征, 就认为它具有代表性。借助一道有代表性的题目, 我们可以同时隐式地考察许多题目。为量化题目的代表性, 我们首先用特征向量表示题目, 使每道题可看作嵌入度量空间中的一个点。一道题离其邻居越近, 该题就越具代表性。最后, 我们通过对某概念所关联题目的代表性 (即密度) 取平均, 得到该知识概念的重要性权重。为完成计算, 我们利用 CAT 系统的历史数据。具体而言, 我们有历史被试, 其记录被持久保存、可用于训练, 记为 $H = (E_H, R_H)$ 。

1) 测试效应嵌入 (Test-Effect Embedding): 嵌入题目的关键在于定义题目之间的距离度量。总体思想是: 历史被试在题目上的表现可以刻画题目本身, 如难度和区分度。因此我们宣称: 被试在其上表现相似的题目具有**测试效应相似性 (Test-Effect similarity)**, 并按这种相似性定义题目嵌入, 称为测试效应嵌入。为训练测试效应嵌入, 我们扩展了 Item2Vec 的思想。具体而言, 对每条历史记录 $r_{ij} = \langle e_i, q_j, a_{ij} \rangle$, 我们构造一个输入 x_{ij} , 同时表示作答了哪道题以及该题是否答对:

$$x_{ij} = \begin{cases} \mathbb{1}_{|Q|}(j) \oplus \mathbb{1}_{|Q|}(j), & \text{若 } a_{ij} = 1 \\ \mathbb{1}_{|Q|}(j) \oplus \mathbf{0}_{|Q|}, & \text{若 } a_{ij} = 0 \end{cases} \quad (10)$$

其中 $\mathbb{1}_{|Q|}(j)$ 表示一个长度为 $|Q|$ 、仅第 j 位为 1 的独热向量, $\mathbf{0}_{|Q|}$ 表示长度为 $|Q|$ 的零向量, $\oplus$ 表示向量拼接。然后我们训练一个 Skip-Gram 负采样 (SGNS) 模型。具体而言, 给定一位历史被试 $e_k \in E_H$, 优化目标形式化为:

$$\max \frac{1}{|R_k^H|} \sum_{r_{ki} \in R_k^H} \sum_{r_{kj} \in R_k^H, j \neq i} \log p(r_{kj} | r_{ki}), \quad (11)$$

$$p(r_{kj} | r_{ki}) = \sigma((W x_{ki})^T v_j) \prod_{l=1}^{N_{neg}} \sigma(-(W x_{kn_l})^T v_{n_l}), \quad (12)$$

其中 N_{neg} 是负采样数量, $\sigma(x) = \frac{1}{1+e^{-x}}$ 是 Sigmoid 函数, W 是一个 $d \times 2|Q|$ 的参数矩阵, v_j 是 q_j 的测试效应嵌入 (维度为 d), 记为 q_j^{TE} 。

2) 测试效应密度 (Test-Effect Density): 既然题目已在测试效应嵌入空间中表示出来, 我们便量化题目的代表性。首先, 我们计算两道题 q_i 与 q_j 之间的测试效应相似性:

$$Sim_{TE}(q_i, q_j) = e^{-\gamma |q_i^{TE} - q_j^{TE}|}, \quad (13)$$

其中 $|\cdot|$ 是欧几里得范数, γ 是一个正的平滑参数。接着, 我们将每道题 q_j 的测试效应密度定义为它与其邻居的平均相似性:

$$Den_{TE}(q_j) = \frac{1}{K_N} \sum_{q_i \in N(q_j)} Sim_{TE}(q_i, q_j), \quad (14)$$

其中 $N(q_j)$ 包含 q_j 在测试效应嵌入空间中的 K_N 个最近邻。一道题的测试效应密度越大, 它就越具代表性。

3) 知识重要性 (Knowledge Importance): 最后, 我们通过对某知识概念 k 所关联题目的测试效应密度取平均, 来定义该概念的知识重要性 w_k :

$$w_k = \frac{1}{\sum_{(q,k) \in G} 1} \sum_{(q,k) \in G} Den_{TE}(q). \quad (15)$$

将式 (15) 代入式 (5), 便得到完整的 IWKC。

E. 理论分析

为严谨起见，我们补充关于 IWKC 评分函数优化（第四节 C 部分）的理论证明。形式上，我们将 **IWKC 最大化问题** 定义如下：给定一个带有关联知识概念 K 的题集 Q ，目标是找出一个 N 大小的子集 Q_T ，使 IWKC 最大：

$$\max_{Q_T \subset Q, |Q_T|=N} IWKC(Q_T). \quad (16)$$

首先，我们说明该问题的复杂度：

定理。 IWKC 最大化问题是 NP-hard 的。

证明：首先，我们引入一个经典的 NP-hard 问题，即**加权最大覆盖问题 (weighted maximum coverage problem)**：给定一个数 k 、一个集合族 $S = \{S_1, S_2, \dots, S_m\}$ 、一个元素域 $E = \{e_1, e_2, \dots, e_n\}$ （其中每个元素有权重 $w_i, i = 1, \dots, n$ ），目标是找出一个子集 $S_{opt} \subset S$ ，使得 $|S_{opt}| \leq k$ 且被 $\bigcup_{S_i \in S_{opt}} S_i$ 覆盖的元素总权重最大。接着，我们将 IWKC 最大化问题归约到加权最大覆盖问题。我们把知识概念视为对应的元素，把覆盖概念的题集 $Q = \{q_1, q_2, \dots, q_m\}$ 视为对应的集合族。每个概念 k 的权重对应于式 (5) 中定义的 $w_k \times IncCov(k, Q)$ 。在此情形下，IWKC 最大化问题等价于加权最大覆盖问题，因而是 NP-hard 的。■

然后我们验证 IWKC 的次模性质：

定理。 IWKC 是一个非负、单调、次模的函数。

证明：IWKC 的非负性与单调性是显然的，因为它从 0 增长到 1，所以我们专注于证明次模性。首先，我们断言 $IncCov(k, Q_T)$ (式 (6)) 是次模的。令 $\Delta_{q_j} IncCov(k, Q_T) = IncCov(k, Q_T \cup \{q_j\}) - IncCov(k, Q_T)$ 为加入 q_j 时 $IncCov(k, Q_T)$ 的边际增益，其计算为 $\Delta_{q_j} IncCov(k, Q_T) = \frac{cnt(k, Q_T \cup \{q_j\}) - cnt(k, Q_T)}{(cnt(k, Q_T \cup \{q_j\}) + 1)(cnt(k, Q_T) + 1)}$ 。考虑相邻两步的已测题集 $Q'_T \subset Q''_T \subset Q$ 。由于 $Q'_T \subset Q''_T$ ，我们有 $cnt(k, Q'_T \cup \{q_j\}) - cnt(k, Q'_T) \geq cnt(k, Q''_T \cup \{q_j\}) - cnt(k, Q''_T)$ ，且 $(cnt(k, Q'_T \cup \{q_j\}) + 1)(cnt(k, Q'_T) + 1) \leq (cnt(k, Q''_T \cup \{q_j\}) + 1)(cnt(k, Q''_T) + 1)$ 。因此 $\Delta_{q_j} IncCov(k, Q'_T) \geq \Delta_{q_j} IncCov(k, Q''_T)$ ，这正是次模性的定义。由于 IWKC 是 $IncCov$ 的非负线性组合，IWKC 的次模性可由 $IncCov$ 的次模性轻易推得。■

最后，我们回顾基于边际增益的贪心算法的性能保证：

定理。 对任意非负单调次模函数 F ，令 S^* 为性能最佳的 N 元素集合， S 为由贪心算法（每次选取边际增益最大的元素）得到的同等大小集合，则 $F(S) \geq (1 - \frac{1}{e})F(S^*)$ 。

在我们的情形中，IWKC 对应上述的 F ，所选题集 Q_T 对应 S 。

F. 小结

综上，MAAT 框架的流程如算法 1 所示，它采用一种两阶段方案来求解多目标优化。MAAT 具有以下优势：(1) 它是模型无关的，适用于广泛的 CDM，包括传统 CAT 方法无法适配的那些；(2) 它以新颖的评分函数同时优化质量与多样性，并具有一个高效、有性能保证的优化算法。值得注意的是，MAAT 通过超参数 K_C （即连接质量模块与多样性模块的候选集大小）来保持两个目标之间的平衡，这将在第五节进一步探讨。

算法 1: MAAT 流程

- **数据：** Q, K, G, H
- **输入：** $M; e_i \in E$
- **输出：** 一个长度为 N 的测试序列 $Q_T = \{q_1^*, q_2^*, \dots, q_N^*\}$
- **初始化：** 用 H 创建 M 并随机初始化 θ ；为每道题 $q \in Q$ 训练测试效应嵌入 (式 (11)(12))；为每个 $k \in K$ 计算重要性权重 (式 (15))；令 $Q_U = Q, Q_T = \emptyset$
- **for** $t = 1$ to N **do**
 - 对所有 $q_j \in Q_U$ ，计算 $EMC(q_j)$ (式 (1))
 - 令 Q_C 为 EMC 最大的 K_C 道题
 - $q_t^* = \arg \max_{q_j \in Q_C} \Delta_{q_j} IWKC(Q_T)$ (式 (9)(5))
 - $Q_U = Q_U - \{q_t^*\}; Q_T = Q_T \cup \{q_t^*\}$
 - 观察 $r_{it}^* = \langle e_i, q_t^*, a_{it}^* \rangle$ ；更新 $M(\theta)$
- **end for**

五、实验

本节中，我们在两个真实数据集上评估 MAAT 框架。此外，我们就 MAAT 如何在质量与多样性之间保持平衡进行消融研究。我们的代码可在 <https://github.com/bigdata-ustc/MAAT> 获取。

A. 数据集描述

我们使用两个真实的教育数据集，即 EXAM 与 ASSIST。EXAM 数据集由科大讯飞股份有限公司提供，采集自一个学生参加考试以进行测试的在线教育系统。在该系统上，我们采集了初中生在数学测试上的数据记录，以及这些题目所关联的知识概念（如“代数”）。ASSIST 是一个开放数据集，即 Assistments 2009-2010 skill builder，记录了学生在数学上的练习。ASSIST 中的每道题都关联一个或多个知识概念（如“绝对值”）。

B. 实验设置

1) 数据预处理与划分：为保证实验结果的可靠性，我们采用如下数据预处理。第一，在 EXAM 与 ASSIST 中，我们过滤掉相关题目少于 10 道的知识概念；第二，在 ASSIST 中，我们过滤掉被少于 50 名学生作答的题目，以及作答少于 10 道题的学生。详细统计见表 II。

在我们的实验中，出于不同目的，我们将数据划分为历史数据与测试数据。历史数据（此前记为 $H = (E_H, R_H)$ ）被假定在测试开始前已知。 H 用于让 CDM 初始学习一些在测试期间固定的参数，如题目难度。此外，MAAT 利用 H 作为题目嵌入的输入，以计算知识重要性权重（第四节 D 部分）。测试数据用于模拟一个自适应测试环境。测试数据中的学生被当作对 CAT 系统全新的被试，其记录被假定未知，直到我们在测试中为他们选题。另一方面，为便于评估，我们在实验中将选题限制在那些其回答已被记录在测试数据中的题目上。因此，为确保候选集足够大，我们把记录较多的学生划入测试数据。具体而言，对 EXAM，我们把作答至少 100 道题的学生划入测试数据；对 ASSIST，我们把作答至少 150 道题的学生划入测试数据。其余部分留作历史数据。

表 II：数据集统计

数据集	EXAM	ASSIST
学生数	4,307	1,505
题目数	527	932
概念数	31	22
记录数	105,586	59,500
每学生平均记录数	24.5	39.5
每题目平均记录数	200.4	63.8
每概念平均题目数	17.0	44.38

2) 参数设置：我们设测试长度 $N = 50$ ，这对实践中典型的测试而言已相当充足。在质量模块中，我们设输出候选集大小 $K_C = 10$ 。在重要性模块中，我们设 $N_{neg} = 10$ （式 (12)）、 $\gamma = 0.1$ （式 (13)）、 $K_N = 10$ （式 (14)）。

C. 基线方法

为评估我们的模型无关框架，我们将其与两种不同 CDM 设计的经典模型特定方法进行比较。此外，我们还在一个经典方法无法适配的深度学习 CDM 上做实验。首先，随机选择策略 RAND 作为基准，用以量化其他方法的提升。

IRT 是 CAT 中最流行的 CDM，对应的 CAT 基线为：

- **MFI：**最大费舍尔信息 (Maximum Fisher Information) 是最流行的选择策略，用费舍尔信息函数度量题目的信息。
- **KLI：**Kullback-Leibler 信息 (Kullback-Leibler Information) 是一种全局信息启发式方法，用 Kullback-Leibler 散度量信息量。

MIRT 作为 IRT 的多维扩展，在多特质能力估计上展现出潜力。为适配 MIRT，基于 IRT 的方法也被相应扩展。因此我们将 MAAT 与以下 MIRT 上的基线比较：

- **D-Opt：**D-最优性 (D-Optimality，借用优化领域的术语) 是 MFI 的多变量扩展。
- **MKLI：**多变量 Kullback-Leibler 信息 (Multivariate Kullback-Leibler Information) 是其单维版本 KLI 的直接推广。

NCDM (神经认知诊断模型, Neural Cognitive Diagnosis Model) 是最新的深度学习 CDM 之一。尽管 NCDM 已展现出强大威力，但据我们所知，由于其机制极其复杂，尚无现有方法能与之配合工作。因此我们仅将 MAAT 与 RAND 比较以展示我们的提升。关键在于，通过比较 MAAT 在不同 CDM 上的结果，我们可以验证模型无关的优势。

D. 评估指标

我们分别用策略的信息量与覆盖度 (即 $\text{Inf}(S)$ 与 $\text{Cov}(S)$) 来度量质量与多样性 (第三节)。此外, 我们引入一个在传统 CAT 研究中常用的指标。

1) 信息量指标 (Informativeness Metric): 沿用第三节的讨论, 我们通过选择策略的信息量来度量质量。具体而言, 对测试数据中的每位被试 e_i , 我们预测其在每道已记录真值的题 q_j 上的表现, 然后采用常用的 AUC (ROC 曲线下面积) 指标:

$$\text{Inf}(S) = \text{AUC}(\{M(e_i, q_j|\theta)|e_i \in E, q_j \in Q\}). \quad (17)$$

2) 覆盖度指标 (Coverage Metric): 我们通过选择策略的覆盖度来度量多样性。由于没有统一标准, 我们采用 $\text{Cov}(S)$ 的一个简单形式, 即策略所选题目覆盖的知识概念比例:

$$\text{Cov}(S) = \frac{1}{|K|} \sum_{k \in K} \mathbb{1}[k \in Q_T]. \quad (18)$$

3) 模拟估计误差指标 (Simulated Estimate Error Metric): 传统 CAT 研究有一种不同的评估流程, 称为模拟研究 (simulation study), 它生成虚拟数据而非使用真实数据。例如, 对 IRT 模型, 会生成一组模拟参数来代表被试能力、题目难度等。这些参数用项目反应理论生成虚拟记录, 然后反过来用这些记录实验性地估计这些模拟参数。为评估策略的有效性, 在测试的每一步, 我们计算估计参数与模拟参数之间的均方误差, 即模拟估计误差 (Simulated Estimate Error, SEE):

$$\text{SEE}(S) = \frac{1}{|E|} \sum_{e_i \in E} (\theta_i - \theta_i^*)^2, \quad (19)$$

其中 θ_i 与 θ_i^* 分别是与被试 $e_i \in E$ 相关的估计参数与模拟参数。在传统案例研究中, θ_i^* 作为真值随机生成。为表明我们的度量与传统度量一致, 我们也用 SEE 指标评估所提框架。因为我们在真实数据上做实验, 我们用在全部数据记录上训练得到的估计参数作为 θ_i^* , 而非生成它们。

E. 实验结果

1) 质量比较: 表 III 报告了用信息量指标 (即 $\text{AUC}@t$, 式 (17)) 进行的质量比较。我们展示测试中段 (第 $t = 25$ 步) 与末端 (第 $t = 50$ 步) 的结果。第一, MAAT 被证明是模型无关的, 因为它能适配所有 CDM。第二, 我们可以轻易看到, 在两个数据集上、在测试过程中, MAAT 与所有 CDM 配合都表现出超越性结果, 这表明 MAAT 在达成质量目标上相当有效。值得注意的是, 与基线方法相比, MAAT 并不使用 CDM 的细节。第三, 随着 CDM 变得更复杂, 总体结果变得更好, 这是合理的, 因为复杂的 CDM 在捕捉被试能力上做得更好。这一观察印证了模型无关的优势: MAAT 可以通过让 CAT 系统在替换 CDM 时无需重新设计策略, 从而灵活地改进系统。

表 III: 用信息量指标进行的质量比较

(a) EXAM

方法	IRT @25	IRT @50	MIRT @25	MIRT @50	NCDM @25	NCDM @50
RAND	0.6435	0.7076	0.7426	0.7767	0.7081	0.7566
MFI	0.7092	0.7207	-	-	-	-
KLI	0.7081	0.7257	-	-	-	-
D-Opt	-	-	0.7515	0.7710	-	-
MKLI	-	-	0.7502	0.7747	-	-
MAAT	0.7192	0.7319	0.7600	0.7861	0.7614	0.7868

(b) ASSIST

方法	IRT @25	IRT @50	MIRT @25	MIRT @50	NCDM @25	NCDM @50
RAND	0.6619	0.6664	0.6734	0.6902	0.6832	0.7217
MFI	0.6659	0.6691	-	-	-	-
KLI	0.6658	0.6692	-	-	-	-
D-Opt	-	-	0.6832	0.7004	-	-
MKLI	-	-	0.6781	0.6877	-	-

方法	IRT @25	IRT @50	MIRT @25	MIRT @50	NCDM @25	NCDM @50
MAAT	0.6674	0.6703	0.6903	0.7063	0.7084	0.7334

2) 多样性比较: 图 3 展示了用覆盖度指标 (式 (18)) 进行的多样性比较。MAAT 框架在两个数据集上、与所有 CDM 配合时都大幅超越其他方法, 因为它具有一个内在的知识层面覆盖目标和一个有性能保证的优化算法, 而其他方法没有。如曲线图所示, MAAT 的覆盖度在测试早期增长相当迅速, 并很快逼近上限 1。这一特性对 CAT 非常重要, 因为自适应测试通常很短。此外, 我们观察到, MFI、KLI 等传统选择策略尽管内在上只追求信息量, 但也有助于覆盖目标。这一观察揭示了质量与多样性是相关的而非矛盾的——两者都能助益于为被试提供更好诊断结果这一目标。

图 3: 用覆盖度指标进行的多样性比较 [(a) IRT on EXAM; (b) IRT on ASSIST; (c) MIRT on EXAM; (d) MIRT on ASSIST; (e) NCDM on EXAM; (f) NCDM on ASSIST]

3) 一致性验证: 尽管我们已评估了 MAAT 的质量与多样性, 验证我们评估度量的一致性仍然重要。因此, 我们额外用模拟 (平方) 误差指标 (式 (19)) 做实验, 结果报告于图 4。由于模拟研究仅适用于那些参数极其简单且可解释的 CDM, 我们只用 IRT 进行模拟。我们可以看到, MAAT 在 SEE 指标上也表现良好。

图 4: 模拟估计误差比较 [(a) EXAM; (b) ASSIST]

4) 消融研究: 我们就 MAAT 框架如何在“质量遇见多样性”时保持平衡进行消融研究。关键点是候选集大小 K_C , 它连接质量模块与多样性模块。具体而言, 当 $K_C = 1$ 时, 只有质量模块起作用; 当 $K_C \equiv |Q_U|$ 时, 只有多样性模块起作用。因此, 我们观察质量与多样性在这些边界条件下如何随 K_C 变化。由于篇幅有限, 我们以 NCDM 在 EXAM 上的结果为例展示于图 5。多样性的变化是直观的: K_C 越大, 覆盖度指标增长越快。特别地, 当只有多样性模块起作用 ($K_C \equiv |Q_U|$) 时, 我们达到第四节 C 部分讨论的性能保证。此外, 我们观察到当 K_C 取较小值 (即 $K_C = 10$) 时, 多样性已相当逼近理论上限。再次注意, 当只有质量模块起作用 (即 $K_C = 1$) 时, 相比 RAND 基准, 多样性仍有提升, 因为两个目标是相关的。质量的变化则略微更有趣: $K_C = 1$ 并不总是表现最佳, 因为多样性模块和重要性模块通过考虑覆盖与重要性也能助益质量。总而言之, 一个相对较小的 K_C 能保持质量与多样性的最佳平衡。

图 5: 消融研究中质量与多样性随不同 K_C 的变化 [(a) 质量; (b) 多样性]

5) 案例研究: 我们展示 EXAM 中一位典型被试的前 10 步以作案例研究 (表 IV)。为更好地说明, 我们只将 MAAT 与前述实验中的最佳基线 (即 MIRT 上的 D-Opt 与 MKLI) 比较。对每种方法, 我们在第一列展示所关联的知识概念, 在第二列展示对应步的信息量指标 (即 $AUC@t$, 式 (17))。我们对知识概念做了缩写, 例如把“一元一次方程” (Linear Equation in One Variable) 缩写为“方程” (Equation)。我们可以清楚地看到, MAAT 框架能在保持高质量的同时选出多样的题目。具体而言, 在 AUC 略微领先的情况下, MAAT 用前 10 道所选题目覆盖了 9 个知识概念, 而 D-Opt 和 MKLI 分别只覆盖了 5 个和 6 个。此外, 这两个基线倾向于选更多关于“函数”的题目, 而 MAAT 没有。因此, 我们的 MAAT 框架在质量与多样性的良好平衡下做出了更好的选择。

表 IV: 一位典型被试的案例研究结果 (前 10 步, 列出各方法每步所选题目关联的知识概念及对应的 $\text{Inf}=AUC@t$; MAAT 共覆盖 9 个概念, D-Opt 覆盖 5 个, MKLI 覆盖 6 个。原文表格结构较为复杂, 此处仅说明要点。)

六、结论

本文研究了一个新颖的模型无关 CAT 问题。我们提出了一个新颖的模型无关自适应测试框架 (MAAT) 作为解决方案, 以应对在测试流程中同时选择高质量且多样题目的问题。在 MAAT 中, 我们设计了三个协同迭代工作的精巧模块。在每个选题步骤, 质量模块首先用 EMC 评分函数选出一个信息量最大的小候选集; 随后多样性模块通过 IWKC 从候选集中选出一道使知识覆盖最大化的题目, 其中重要性权重在重要性模块中预先计算。此外, 我们证明了我们的问题是 NP-hard 的, 并通过次模性质提供了一个高效且有效的解决方案。大量实验表明, MAAT 对任意 CDM 都是灵活的, 且能在 CAT 中生成既高质量又多样的题目。我们希望这项工作能引出未来更多的研究。

七、致谢

本研究部分得到了中国国家重点研发计划 (National Key Research and Development Program of China) 等项目的资助。(致谢编号及更多资助信息详见原文。)

参考文献 (References) 按约定未翻译, 详见原文。